



X.media.press

**Andreas Blumauer
Tassilo Pellegrini (Hrsg.)**

X.media.press ist eine praxisorientierte Reihe
zur Gestaltung und Produktion von Multimedia-
Projekten sowie von Digital- und Printmedien.

Social Semantic Web

Web 2.0 – Was nun?



Springer

X . media . press



Andreas Blumauer · Tassilo Pellegrini

Social Semantic Web

Web 2.0 – Was nun?

Andreas Blumauer
Semantic Web Company
Lerchenfelder Gürtel 43
1160 Wien
Österreich
a.blumauer@semantic-web.at

Tassilo Pellegrini
Semantic Web Company
Lerchenfelder Gürtel 43
1160 Wien
Österreich
t.pellegrini@semantic-web.at

ISBN 978-3-540-72215-1

e-ISBN 978-3-540-72216-8

DOI 10.1007/978-3-540-72216-8

X.media.press ISSN 1439-3107

Bibliografische Information der Deutschen Nationalbibliothek

Die Deutsche Nationalbibliothek verzeichnet diese Publikation in der Deutschen Nationalbibliografie; detaillierte bibliografische Daten sind im Internet über <http://dnb.d-nb.de> abrufbar.

© 2009 Springer-Verlag Berlin Heidelberg

Dieses Werk ist urheberrechtlich geschützt. Die dadurch begründeten Rechte, insbesondere die der Übersetzung, des Nachdrucks, des Vortrags, der Entnahme von Abbildungen und Tabellen, der Funk-sendung, der Mikroverfilmung oder der Vervielfältigung auf anderen Wegen und der Speicherung in Datenverarbeitungsanlagen, bleiben, auch bei nur auszugsweiser Verwertung, vorbehalten. Eine Vervielfältigung dieses Werkes oder von Teilen dieses Werkes ist auch im Einzelfall nur in den Grenzen der gesetzlichen Bestimmungen des Urheberrechtsgesetzes der Bundesrepublik Deutschland vom 9. September 1965 in der jeweils geltenden Fassung zulässig. Sie ist grundsätzlich vergütungspflichtig. Zuwider-handlungen unterliegen den Strafbestimmungen des Urheberrechtsgesetzes.

Die Wiedergabe von Gebrauchsnamen, Handelsnamen, Warenbezeichnungen usw. in diesem Werk be-rechtigt auch ohne besondere Kennzeichnung nicht zu der Annahme, dass solche Namen im Sinne der Warenzeichen- und Markenschutz-Gesetzgebung als frei zu betrachten wären und daher von jedermann benutzt werden dürften.

Einbandgestaltung: KinkelLopka, Heidelberg

Gedruckt auf säurefreiem Papier

9 8 7 6 5 4 3 2 1

springer.de

Vorwort der Herausgeber

Tassilo Pellegrini und Andreas Blumauer

Semantic Web Company, Wien, Austria
{t.pellegrini; a.blumauer}@semantic-web.at

Knapp zwei Jahre nach der ersten Publikation „Semantic Web – Wege zur vernetzten Wissensgesellschaft“¹ liefern wir mit diesem Buch ein „Update“ zur aktuellen Debatte über die Entwicklung und Perspektiven des Internets im Allgemeinen und des World Wide Web im Speziellen.

Entgegen dem vorherrschenden Trend mittels Modebegriffen und Versions-Metaphern das vermeintlich „Neue“ möglichst plakativ und oftmals undifferenziert den interessierten Beobachtern und Aktivisten zu präsentieren, soll mit dem aktuellen Band eine differenzierte Diskussion über ein Phänomen angeregt werden, das mit dem Zusammenwachsen von Web 2.0 und Semantic Web beschrieben und unter dem Begriff „Social Semantic Web“ zusammengefasst werden kann. Hierbei ist es uns wichtig darauf hinzuweisen, dass der Begriff nicht von Dauer sein kann, zumal – so die Meinung der Herausgeber – in absehbarer Zeit viele der in diesem Band vorgestellten Konzepte und Technologien als Selbstverständlichkeit wahrgenommen werden und sich damit die Einführung neuer Kunstbegriffe weitgehend erübrigt. Unser Buchtitel soll vielmehr als Paraphrase auf einen aktuellen Transformations- und Konvergenzprozess verstanden werden, der keinen Zustand, sondern einen evolutionären Pfad beschreibt, welcher das Web in seinen Funktionen sowohl als technische Infrastruktur als auch als Ort der sozialen Interaktion in den kommenden Jahren prägen, verändern und modernisieren wird.

Das Buch ist dem interessierten Laien und themenfremden Experten gewidmet. Es dient als Einstiegswerk in die breite Fülle an technologischen und methodischen Trends der Web-Entwicklung und soll den LeserInnen in Ansätzen Antworten auf die Frage geben: „Web 2.0 – Was nun?“

¹ Pellegrini, Tassilo; Blumauer, Andreas (2006). Semantic Web. Wege zur vernetzten Wissensgesellschaft. Berlin: Springer Verlag

Hierbei setzen wir voraus, dass die LeserInnen bereits ein grundlegendes Vorwissen in Bezug auf Web 2.0 und Semantic Web mitbringen, weshalb wir insbesondere in Bezug auf die (technischen) Grundlagen des Semantic Web auf eine ausführliche Einführung verzichtet haben, da dies nicht zuletzt mit unserem Vorgängerband abgedeckt wurde.² Das Buch soll vielmehr unterschiedliche Perspektiven eröffnen, worauf bei der Konzeption, Entwicklung und Anwendung der nächsten Generation von Social Web-Anwendungen zu achten ist, ohne sich zu sehr mit den technischen Feinheiten und Detailproblemen zu belasten. Die umfangreichen Quellen, auf denen die einzelnen Beiträge basieren, sind jedoch für eine vertiefende Auseinandersetzung bestens geeignet.

Bei der Zusammenstellung der Beiträge wurde auf hohe Praxisrelevanz geachtet, was dazu geführt hat, dass ausschließlich alle der vorgestellten Technologien, Methoden und Applikationen sich bereits in Anwendung befinden und live getestet werden können. Außerdem haben wir am Ende des Bandes einen umfangreichen Index angefügt, der die Orientierung in diesem neuen und umfangreichen Themenfeld erleichtern soll, um nicht zuletzt die Reichhaltigkeit und Tiefe der einzelnen Beiträge besser zu erschließen. Zusätzlich haben wir den Band in vier Abschnitte eingeteilt, um auch einen besseren Überblick über die Foki der einzelnen Beiträge geben zu können.

Abschnitt 1 bietet einen niedrigschwelligen Einstieg in das Thema Web 2.0 und seine Entwicklungsperspektiven.

Andreas Blumauer und Tassilo Pellegrini beginnen mit einer grundsätzlichen Verortung des Phänomens „Social Semantic Web“ vor dem Hintergrund der Konvergenz von Web 2.0 und Semantic Web.

Sonja Bettel wirft einen eloquenten Blick auf die Entstehungsgeschichte des Phänomens Web 2.0 und fragt anhand plakativer Beispiele nach den Konsequenzen für Gesellschaft, Demokratie und Medien.

Alexander Raabe führt den Begriff der Social Software ein und zeigt am Beispiel unterschiedlicher Einsatzmöglichkeiten, wie sich vor dem Hintergrund der zunehmenden Mobilisierung, aber auch vor dem Hintergrund der wachsenden Metadatenbewirtschaftung – z. B. mittels Semantic Web Technologien – das organisationale, wirtschaftliche und soziale Gefüge verändern könnte.

Alexander Stocker und Klaus Tochtermann geben einen Überblick über die aktuellen Technologien und Anwendungen des Web 2.0 und legen damit die Basis für die weiterführende technologische Diskussion über die Transformation des Social Web zu einem Social Semantic Web.

² Pellegrini, Tassilo; Blumauer, Andreas (2006). Semantic Web. Wege zur vernetzten Wissensgesellschaft. Berlin: Springer Verlag

Aufbauend auf der technologischen Betrachtung stellt **Jörg Linder** die Frage nach der Usability von Rich Internet Applications und thematisiert gleichzeitig die Veränderungen in der hohen Schule des Web-Designs vor dem Hintergrund von AJAX und den darauf basierenden Gestaltungsmöglichkeiten.

Anupriya Ankolekar, Markus Krötzsch, Than Tran und Denny Vrandeic schließen den ersten Abschnitt mit drei Hypothesen über die Konvergenz von Web 2.0 und Semantic Web vor dem Hintergrund der zunehmenden Datenverfügbarkeit am Netz, der Möglichkeit darauf neue Mehrwertdienste zu konzipieren und den unzureichenden Möglichkeiten, diese mit „reinen“ Web 2.0 Technologien zu realisieren.

Abschnitt 2 bietet einen Überblick über die zentralen Technologien und Methoden des Social Semantic Web.

Dazu stellt **Barbara Geyer-Hayden** unterschiedliche Ansätze der Wissensmodellierung vor, und zeigt auf, welche Rolle diese für die Beschreibung von Web-Ressourcen und die Veröffentlichung von strukturierten Daten am Netz spielen.

Michael Hausenblas zeigt an den Beispielen Mikroformate und RDFa unterschiedliche Strategien, um bestehende Web-Ressourcen mit Metadaten zu annotieren, in HTML zu integrieren und damit die maschinelle Erschließbarkeit bestehender Web-Ressourcen zu verbessern.

Armin Ulbrich und Patrick Höfler konzentrieren sich in ihrer Betrachtung auf die Modellierung von Anwenderverhalten im Web und zeigen anhand unterschiedlicher Beispiele, wie eine strukturierte Aufbereitung der gewonnenen Daten zu einer qualitativen Verbesserung von Applikationen und der Nutzer-zentrierten Knowledge Discovery führen kann.

Axel Polleres und Malgorzata Mochol zeigen in ihrem Beitrag unterschiedliche Methoden der Expertensuche im Web. Am Beispiel des Projektes „ExpertFinder“ diskutieren sie die Rahmenbedingungen zur Kombination, Wiederverwendung und Erweiterung bestehender RDF-Vokabulare zur Beschreibung von Personen, Organisationen und Expertise im Web und deren Konsequenz für die Jobsuche der Zukunft.

Erich Gams und Daniel Mitterdorfer diskutieren in ihrem Beitrag die Anforderungen an die nächste Generation von Content Management Systemen und stellen eine generische Architektur eines Semantic Web-tauglichen Systems vor.

Ergänzend dazu vergleichen **Andreas Blumauer und Martin Hochmeister** unterschiedliche Tag-Recommender-Systeme zur gemeinschaftlichen Verschlagwortung und stellen ein ontologiegestütztes Tag-Recommender-System vor, auf Basis dessen sich neue Anwendungen und Mehrwertdienste realisieren lassen.

Sebastian Schaffert, François Bry, Joachim Baumeister und Malte Kiesel führen in die Grundlagen von semantischen Wikis ein und zeigen,

wie durch die Verknüpfung von „sozialer Intelligenz“ und „künstlicher Intelligenz“ das Potential von Wikis weiter erschlossen werden kann.

Sören Auer, Jens Lehmann und Christian Bizer bieten einen Einstieg in die spannende Welt von Open Data und zeigen anhand semantischer Mashups, wie offene Datenquellen am Netz mittels semantischer Technologien und Reasoning (teilautomatisiert) vernetzt und zum weiteren Gebrauch veröffentlicht werden können.

Abschnitt 3 thematisiert bestehende Anwendungen und deren Perspektiven in einem Social Semantic Web.

Am Beispiel Plattform Wissensmanagement geben **Stefanie N. Lindstaedt und Claudia Thurner** einen praxisnahen Einblick in das gelebte Management einer Community of Interest und zeigen, wie soziale Prozesse in der Online- und Offline-Welt mittels semantischer Technologien unterstützt werden können.

Gernot Tscherteu und Christian Langreiter stellen unterschiedliche Methoden und darauf basierende Visualisierungsapplikationen vor, die dazu geeignet sind Online-Communities visuell zu erschließen und so die Nutzer bei der sozialen Interaktion am Netz unterstützen.

Mit dem Semantic Desktop präsentieren **Leo Sauermann, Malte Kiesel, Kinga Schumacher und Ansgar Bernardi** die nächste Generation von Desktop-Anwendungen. Mittels des Konzeptes „persönliches Wissensmanagement“ werden Ansätze aus dem Web 2.0 und dem Semantic Web verknüpft und in eine generische Architektur überführt.

Andreas Hotho, Robert Jäschke, Dominik Benz, Miranda Grahl, Beate Krause, Christoph Schmitz und Gerd Stumme zeigen am Beispiel BibSonomy ein kooperatives Verschlagwortungssystem für Web-Links und Publikationen. Sie gehen auf die bestehenden Funktionalitäten und die dahinter stehende Architektur ein, und zeigen, wie die gewonnenen Daten für weitere Zwecke ausgewertet werden können.

Markus Krötzsch und Denny Vrandečić thematisieren am Beispiel Semantic Wikipedia die Entwicklungsoptionen und verfügbaren Technologien für die nächste Generation der beliebten Grass-Roots-Enzyklopädie und zeigen, wie das gemeinschaftlich generierte Wissen mittels entsprechender Exportmöglichkeiten in anderen Anwendungen weiterverwendet werden kann.

Christoph Wieser und Sebastian Schaffert stellen die Fragen nach der Zeitung der Zukunft, und wie sich das Zeitunglesen auf Basis semantisch gestützter Redaktionsprozesse verändern wird.

Holger Stenzhorn und Matthias Samwald zeigen zum Abschluss die Relevanz des Semantic Web für den Bereich der biomedizinischen Forschung, insbesondere um aus der unfassbaren Datenfülle jene relevanten Erkenntnisse zu extrahieren, die zu Durchbrüchen bei neuen Medikamenten und Heilungsmethoden führen sollen.

Abschnitt 4 versucht eine Reflexion des Phänomens „Social Semantic Web“ aus einer sozialwissenschaftlichen Perspektive³.

Jan Schmidt und Tassilo Pellegrini nähern sich dem Social Semantic Web aus kommunikationssoziologischer Perspektive und identifizieren sowohl unterschiedliche Wissenstypen der sozialen Organisation als auch gängige „Bemächtigungsstrategien“ zur Nutzung und Aneignung von User-Generated Content.

Im einzigen englischsprachigen Aufsatz dieses Bandes fragen **Narayan Kulathuramaiyer und Hermann Maurer** nach den Implikationen des zunehmenden Data Minings im Spannungsfeld zwischen technischer Notwendigkeit für gesteigerte Convenience und Endnutzertauglichkeit von Anwendungen und sozialer Bedrohung durch Informationsasymmetrien und Machtmissbrauch.

Michael Nagenborg beschließt diesen Abschnitt mit einer fundierten Diskussion von Privacy im Social Semantic Web. Aus der Perspektive der Informationsethik stellt er die Forderung das Private als ein normatives, handlungsleitendes Konzept zu verstehen, dem die technische Infrastruktur entsprechen muss um sozial verträglich zu sein.

Wien, im Juni 2008

³ Leider sind zwei wichtige Themenkomplexe unterrepräsentiert: Intellectual Property Rights und Governance. Wir hoffen u. a. mittels dieses Buches den Diskurs zu diesen Themen anzuregen und den Wissenstransfer zwischen den Disziplinen zu fördern.

Danksagung

Bücher schreiben ist Knochenarbeit, sowohl für die Autoren als auch die Herausgeber. Gleich vorweg gilt daher unser Dank allen Autorinnen und Autoren, die mit Eifer und Energie an diesem anspruchsvollen Projekt mitgewirkt haben. Weiters bedanken wir uns bei Eva Pellegrini, die wie schon im letzten Band durch ihr Lektorat einen wertvollen Beitrag zur formalen Qualität beigesteuert hat, ebenso bei Jana Herwig und Jan Krone, die das Buch mit wertvollen Kommentaren bereichert haben. Und last but not least gehört unser Dank dem Springer-Verlag, welcher uns in jeder Phase des Projektes unterstützt hat und uns mit Rat und Tat bei der Erstellung der Druckvorlage zur Seite stand.

Inhaltsverzeichnis

Einstiegspunkte

1. **Semantic Web Revisited – Eine kurze Einführung
in das Social Semantic Web.....** 3
Andreas Blumauer und Tassilo Pellegrini
2. **Warum Web 2.0? Oder: Was vom Web 2.0 wirklich bleiben wird** 23
Sonja Bettel
3. **Entwicklungsperspektiven von Social Software und dem Web 2.0** 43
Alexander Raabe
4. **Anwendungen und Technologien des Web 2.0: Ein Überblick** 63
Alexander Stocker und Klaus Tochtermann
5. **Die Usability von Rich Internet Applications** 83
Jörg Linder
6. **Die zwei Kulturen.....** 99
*Anupriya Ankolekar, Markus Krötzsch, Than Tran
und Denny Vrandečić*

Technologien und Methoden

7. **Wissensmodellierung im Semantic Web.....** 127
Barbara Geyer-Hayden
8. **Anreicherung von Webinhalten mit Semantik –
Microformats und RDFa** 147
Michael Hausenblas

9. Modellierung von Anwenderverhalten im Social Semantic Web.....	159
<i>Armin Ulbrich, Patrick Höfler und Stefanie Lindstaedt</i>	
10. Expertise bewerben und finden im Social Semantic Web.....	175
<i>Axel Polleres und Malgorzata Mochol</i>	
11. Semantische Content Management Systeme.....	207
<i>Erich Gams und Daniel Mitterdorfer</i>	
12. Tag-Recommender gestützte Annotation von Web-Dokumenten.....	227
<i>Andreas Blumauer und Martin Hochmeister</i>	
13. Semantische Wikis.....	245
<i>Sebastian Schaffert, François Bry, Joachim Baumeister und Malte Kiesel</i>	
14. Semantische Mashups auf Basis Vernetzter Daten	259
<i>Sören Auer, Jens Lehmann und Christian Bizer</i>	

Anwendungen und Perspektiven

15. Web-gestütztes Social Networking am Beispiel der „Plattform Wissensmanagement“.....	289
<i>Stefanie N. Lindstaedt und Claudia Thurner</i>	
16. Explorative Netzwerkanalyse im Living Web.....	313
<i>Gernot Tscherteu und Christian Langreiter</i>	
17. Semantic Desktop	337
<i>Leo Sauermann, Malte Kiesel, Kinga Schumacher und Ansgar Bernardi</i>	
18. Social Bookmarking am Beispiel BibSonomy	363
<i>Andreas Hotho, Robert Jäschke, Dominik Benz, Miranda Grahl, Beate Krause, Christoph Schmitz und Gerd Stumme</i>	
19. Semantic Wikipedia	393
<i>Markus Krötzsch und Denny Vrandečić</i>	
20. Die Zeitung der Zukunft.....	423
<i>Christoph Wieser und Sebastian Schaffert</i>	
21. Das Semantic Web als Werkzeug in der biomedizinischen Forschung	435
<i>Holger Stenzhorn und Matthias Samwald</i>	

Reflexion

22. Das Social Semantic Web aus kommunikationssoziologischer Perspektive.....	453
<i>Jan Schmidt und Tassilo Pellegrini</i>	
23. Implications of Emerging Data Mining.....	469
<i>Narayanan Kulathuramaiyer and Hermann Maurer</i>	
24. Privacy im Social Semantic Web.....	485
<i>Michael Nagenborg</i>	
Index	507

I Einstiegspunkte

1. Semantic Web Revisited – Eine kurze Einführung in das Social Semantic Web

Andreas Blumauer und Tassilo Pellegrini

Semantic Web Company, Wien, Österreich
{a.blumauer; t.pellegrini}@semantic-web.at

Zusammenfassung: Während in den vergangenen Monaten Themen wie Web 2.0 und Social Software ein erstaunliches Konjunkturhoch erlebt haben, vollzieht sich weitgehend abseits der öffentlichen Wahrnehmung eine technologische Komplementärinnovation. Die wachsende Adaption semantischer Technologien zu Zwecken der strukturierten Erschließung von „Web 2.0 Content“, aber auch der Einsatz von Social Software zur kollaborativen Anreicherung von Web Content mit maschinenlesbaren Metadaten sind Ausdruck eines Trends in Richtung „Social Semantic Web“. Bezeichnendes Merkmal dieser Entwicklung ist die voranschreitende Konvergenz zwischen Social Software und Semantic Web Technologien. Dieser Beitrag hat das Ziel ein allgemeines Bewusstsein und Verständnis dieser Entwicklung zu schaffen und nähert sich dem Phänomen aus einer nicht-technischen Perspektive.

Ein Blick zurück nach vorne

Noch im Jahr 2005, als der Begriff Web 2.0 erstmals breitenwirksam in Erscheinung trat, hätte sich niemand vorstellen können, welche weitreichenden Auswirkungen der Trend zum Social Web auf das Internet-Business haben würde. Nicht nur, dass die großen Service-Anbieter in atemberaubender Geschwindigkeit mit eigenen Web 2.0-Angeboten in einen scharfen Konkurrenzkampf um die Gunst der Nutzer traten, auch spektakuläre Firmenübernahmen wie etwa Yahoo!'s Kauf der Social Bookmarking Plattform del.icio.us [21] und der Foto-Sharing-Site Flickr [10], Rupert Murdochs Übernahme des Social Networking-Anbieters MySpace [39], sowie eBays Übernahme von Skype für knapp 2,6 Milliarden Dollar [26] markierten den Anfang einer Reihe von Akquisitionen, die dem Dot-Com-Hype der späten 1990er Jahre nicht nachzustehen

schienen.¹ Und noch ist kein Ende der Akquisitionswelle in Sicht, denn seit 2006 bemüht sich Yahoo! sich gegen ein Übernahmeangebot von Microsoft [31] zu behaupten, das im April 2008 bei knapp 45 Milliarden Dollar [24] lag.² Kurz gesagt: Der Internet-Markt ist in Bewegung.

Die Frage nach den wirtschaftlichen Motiven dieser Transaktionen lässt sich ganz trocken auf zwei Aspekte zurückführen: Zum einen geht es um die strategische Besetzung neuer Kunden- und Technologie-Märkte, die sich in Network-Industries [26] herausbilden und jeden Player unter Druck setzen, entsprechende Windows of Opportunity zu nutzen – auch auf die Gefahr hin, Fehlinvestitionen zu machen³; zum anderen geht es um die Erschließung eines der lukrativsten Geschäftsbereiche der Zukunft, nämlich der Online-Werbung, die seit mehreren Jahren mit zweistelligen Wachstumsraten⁴ nicht nur hohe Profite verspricht, sondern mit der voranschreitenden Konvergenz aus Medien, Telekommunikation, Unterhaltung und Internet auch neue Geschäftsmöglichkeiten und Dienstleistungen eröffnet.

Die strategische Sicherung von Marktpositionen, auch ohne ein revolutionäres Geschäftsmodell in der Tasche, ist eine Grundvoraussetzung für den wirtschaftlichen Erfolg von morgen. Und dieser Erfolg ist auf Gedeih und Verderb von der Verfügungsgewalt über die wichtigste strategische Ressource einer vernetzten, auf „Social Production“ basierenden Informationsökonomie [3] abhängig: Daten.⁵

¹ Weitere erwähnenswerte Übernahmen waren z.B. die YouTube-Akquisition durch Google um 1,65 Milliarden Dollar Ende 2006 [8], die Übernahme der deutschen Social Networking Plattform StudiVZ durch die Holtzbrinck-Gruppe um 100 Millionen Euro Anfang 2007 [28] und Microsofts Beteiligung von 1,6% an Facebook für 240 Millionen Dollar im Oktober 2007 [40]. Kleinere Akquisitionen, wie etwa die Übernahme des Technologieanbieters ClearForest durch Reuters für 25 Millionen Dollar [23] oder eBays Kauf des Bookmarking-Dienstes StumbleUpon für 75 Millionen Dollar [7] im Jahr 2007, nehmen sich dabei etwas bescheidener aus.

² Microsoft zog im Monat darauf (Mai 2008) sein Angebot wieder zurück, was mit verheerenden Kurseinbrüchen der Yahoo!-Aktie einherging. Es bleibt zu spekulieren, ob es sich dabei um eine strategische Entscheidung Microsofts im weiteren Übernahmeprozess handelt.

³ Wie etwa am Beispiel eBay-Skype kolportiert wird [34].

⁴ Im Vergleich zur Print- und TV-Werbung befindet sich die Online-Werbung jedoch noch auf relativ geringem Niveau, konkurriert jedoch anteilig mit Radio- und Kinowerbung [42].

⁵ Die aktuelle Debatte über Datenschutz und Privacy in Zusammenhang mit Googles Informationsgebarung [16], das gescheiterte „Beacon-Experiment“ von facebook [15], die peinlichen Änderungen der AGBs von StudiVZ [11], der Überwachungsskandal bei deutschen Lebensmitteldiskontern wie Schlecker [33] und Debatten wie Bundestrojaner [13], Vorratsdatenspeicherung [12],

Von Daten-Webs und Intel-Metaphern

Daten sind der Rohstoff und die Währung in Netzwerk-Industrien. Und die Möglichkeit, diese kostengünstig zu erschließen, ist eine der strategischen Kernkompetenzen der Zukunft. Nicht ganz ohne Zufall verwendet Tim Berners-Lee gerne den Ausdruck „Web of Data“ [32] als Synonym für die etwas glücklose Wahl des Begriffes „Semantic Web“, und auch Tim O'Reilly postuliert in seinen Web 2.0 Design Patterns plakativ: „Data is the Next Intel Inside“ [18].

Die Frage nach der Erschließbarkeit und Logistik von Daten im Web steht im Zentrum der Diskussion um Nutzen und Funktion von Semantic Web Technologien. Und diese Diskussion wird kontroversiell geführt.

Skeptiker des Semantic Web nennen die vom World Wide Web Consortium entwickelten Standards und Methoden als zu kompliziert und Top-Down-getrieben, um im vom Grass-Roots-Ethos gesteuerten Web erfolgreich zu sein.

Im Gegenzug werfen die Vertreter der Semantic Web Community die berechtigte Frage auf, welche technologische und methodische Alternative zur Verfügung steht, um die durch Bottom-Up-Prozesse rasch wachsende Datenflut am Netz erfolgreich in den Griff zu bekommen und gleichzeitig Applikationen zu entwickeln, die in der Lage sind, den Informationsreichtum im weitläufigen, dezentralen Internet und kleinteiligen Intranets zu erschließen.

Beide Fraktionen können einen Gültigkeitsanspruch auf ihre Argumente erheben. Und langsam wächst das Verständnis, dass nur eine kombinierte Form von Top-Down- und Bottom-Up-Ansätzen der Datenorganisation eine nachhaltige Lösung darstellt, die jedoch nicht nur an der technologischen Machbarkeit, sondern auch der sozialen Akzeptanz und Verträglichkeit zu messen ist. Denn die Bewirtschaftung von (Meta-)Daten – ob durch gemeinnützige Communities, profitorientierte Unternehmen oder staatliche Institutionen – geht Hand in Hand mit der Frage über die Verfügungsgehalt der existierenden Datenbestände und fügt dem Technologiediskurs eine Dimension über geistiges Eigentum, Datenschutz und Macht hinzu.

Aus technologischer Perspektive erleben wir eine voranschreitende gegenseitige Annäherung der Semantic Web und Web 2.0 Glaubensgemeinschaften mit dem Effekt, dass parallel zum Web 2.0-Hype eine atemberaubende Dynamik bei der Konvergenz von Web 2.0 und Semantic Web zu

Flugdatenaustausch [9] u. v. a. m. sind Symptome für die gehobene mediale und öffentliche Aufmerksamkeit gegenüber der Datengebarung von Unternehmen und Behörden.

beobachten ist – ein Phänomen, das unter dem Begriff „Social Semantic Web“ Einzug in die akademische Diskussion [2] gefunden hat.

Parallel dazu formiert sich rund um Tim Berners-Lee seit etwa 2005 eine interdisziplinäre Gruppe von Technikern, Ökonomen, Psychologen und Soziologen, die mit einer „Science of the Web“ [36] den komplexen Wechselwirkungen zwischen Technologie, Wirtschaft und Gesellschaft auf den Grund gehen wollen, um u. a. im Sinne einer Technikfolgenabschätzung den disruptiven Effekten, die durch den Einsatz und die Kombination unterschiedlicher Methoden und Technologien des Webs entstehen, nachzuforschen.

Neben der akademischen Diskussion manifestiert sich das Social Semantic Web für den aufmerksamen Beobachter in einer Vielzahl an Ereignissen, die als praktische Beispiele für die voranschreitende Konvergenz aus Web 2.0 und Semantic Web herangezogen werden können.

So hat sich parallel zu Open Source ein weltweites Phänomen etabliert, das unter dem Begriff „Open Data“ firmiert und eine enorme Menge an hoch-strukturierten, frei verfügbaren Daten am Web bezeichnet, die aufeinander referenzieren und daher auch wie eine riesige, verteilte Datenbank abgefragt werden können. Das Open Dataset⁶ speist sich aus Quellen wie der Wikipedia⁷, dem US Census⁸, dem CIA World Factbook⁹, der GeoNames Datenbank¹⁰, der MusicBrainz Datenbank¹¹, Flickr¹² und einer Vielzahl an kleinteiligen Quellen und stellt mit mehr als 2 Milliarden Fakten das derzeit größte offene Daten-Repository der Welt dar [20].

Im Jänner 2008 traten Google, Facebook und Plaxo der Data Portability Group¹³ bei, der u. a. Unternehmen wie Microsoft, Yahoo!, Mozilla, LinkedIn und Digg angehören. Die Data Portability Group und ihre Tochterorganisation Open Data Definition¹⁴ verstehen sich als offene Plattform für alle Stakeholder zum Thema Social Web-Interoperabilität und verfolgen das Ziel, die technischen, sozialen und rechtlichen Implikationen des Datenaustausches über Social Web-Dienste und -Applikationen hinweg zu verstehen und in nachhaltige, sozial verträgliche Geschäftsmodelle umzumünzen.

⁶ Siehe <http://richard.cyganiak.de/2007/10/lod/>

⁷ Siehe <http://dbpedia.org/About>

⁸ Siehe <http://www.rdfabout.com/demo/census/>

⁹ Siehe <http://www4.wiwiss.fu-berlin.de/factbook/>

¹⁰ Siehe <http://www.geonames.org/ontology/>

¹¹ Siehe <http://fgiasson.com/blog/index.php/2007/05/22/browsing-musicbrainzs-dataset-via-uri-dereferencing/>

¹² Siehe <http://apassant.net/blog/2007/12/18/rdf-export-of-flickr-profiles-with-foaf-and-sioc/>

¹³ Siehe <http://dataportability.org/>

¹⁴ Siehe <http://www.openddd.net/>

Yahoo! verlautbarte im Februar 2008, dass es im Rahmen seiner Open Search Strategie [37] verstärkt auf die Einbindung von Mikroformaten und RDF-Daten aufbauen werde, und bekennt sich zu einem „Semantic Web Light“. Die verstärkte Berücksichtigung von Kontextdaten im Rahmen des Dienstes oneSearch 2.0 soll eine bisher unerreichte Qualität der Suchergebnisse auf mobilen Endgeräten gewährleisten.

Im März 2008 ließ Microsoft Research auf der Open Repositories Conference in Southampton / UK verlautbaren, dass sie sich bei ihrer Metadatenstrategie stärker an den Standards und Methoden des W3C orientieren wollen [22].

Und nicht zuletzt sei auf die unzähligen Startups¹⁵ verwiesen, die innovative Methoden aus der Forschung in markttaugliche Produkte und Dienstleistungen umsetzen und dabei nicht unbeträchtliche Finanzierungserfolge durch Risikokapitalgeber verbuchen können oder durch große Player übernommen und vermarktet werden. So bietet Reuters nach einer Übernahme des Technologieanbieters ClearForest seit Anfang des Jahres 2008 den kostenlosen Web-Dienst OpenCalais¹⁶ zur Nutzung an, der unstrukturierten Text automatisch auf Basis des Semantic Web-Standards RDF¹⁷ annotiert. Eine Lektüre der Allgemeinen Geschäftsbedingungen [19] lässt klar erkennen, dass Reuters den Metadatenmarkt als neues Geschäftsfeld ins Auge gefasst hat.

In Anlehnung an den US-Theoretiker Yochai Benkler [3] lässt sich das Social Semantic Web als vielschichtiges klassen- und kulturübergreifendes Phänomen verstehen, das im Sinne der sozialen Produktion von Informationsgütern die organisationale/unternehmerische Ebene ebenso adressiert, wie den individuellen Nutzer.

Wo ist das „Soziale“ im Social Semantic Web?

Web 2.0 und Semantic Web stellen zwei Paradigmen zur Datenbewirtschaftung dar. Diese unterscheiden sich in der Art der Inhaltserschließung (z. B. manuell vs. maschinell) und der Art der Wissensorganisation (z. B. expertengetrieben vs. selbstorganisiert) [20]. Abbildung 1 veranschaulicht prototypisch das Zusammenspiel der unterschiedlichen Paradigmen bei der Herausbildung eines Social Semantic Web.

¹⁵ Exemplarisch zu nennen sind wie Radar Networks, Semantic Arts, Talis, Top-Quadrant, Franz, Ontotext, OpenLink, Powerset u. v. a. m.

¹⁶ Siehe www.opencalais.com

¹⁷ RDF (Resource Description Framework) ist ein zentraler Datenbeschreibungsstandard für das Semantic Web und wurde im Jahr 2004 als offizielle W3C Recommendation verabschiedet [W3C 2004].




Abb. 1. Entwicklungspfade zum Social Semantic Web entlang der Dimensionen Wissensorganisation und Inhaltserschließung [20]

Fügt man die beiden Paradigmen zusammen, so ergeben sich zwei komplementäre Entwicklungspfade, die bei der Herausbildung des Social Semantic Web eine wichtige Rolle spielen [25]:

Einerseits „**Semantically Enabled Social Software**“, also die funktionelle Erweiterung von Social Software zur strukturierten Anreicherung von Web 2.0 Content mit maschinenverarbeitbaren Metadaten; andererseits als „**Socially Enabled Semantic Web**“, die kollaborative Bereitstellung von großen strukturierten Datenbeständen zur Ermöglichung von Mashups und Rich Content Applikationen.

Obwohl diese beiden Szenarien analytisch voneinander getrennt werden können, ist in der Praxis eine Konvergenz beobachtbar, die in Teilbereichen zu einer nahtlosen Verschmelzung von Social Software und semantischen Technologien führt. Im Folgenden werden die beiden Szenarien skizziert.

Semantically Enabled Social Software

Betrachtet man das wohl prominenteste Beispiel eines aktiven und wohl erfolgreichen Social Software Projektes, nämlich Wikipedia, so stellt man schnell fest, dass der überwiegende Content-Anteil unstrukturiert vorliegt. Im Laufe der Zeit haben sich jedoch zahlreiche strukturgebende Merkmale herausgebildet, die von der Community mittlerweile als mehr oder weniger fix betrachtet werden. So existieren zu jeder Wiki-Seite, in der eine Stadt beschrieben wird, strukturierte Angaben darüber, in welcher Region oder in welchem Land die Stadt liegt, oder Angaben über entsprechende Geo-koordinaten. Wie in Abb. 2 dargestellt, werden diese Metadaten übersichtlich und strukturiert zu einer Factbox zusammengefasst und sind damit für die maschinelle Verarbeitung bereits sehr gut geeignet.

Ein Ansatz, der explizit das Ziel verfolgt, Social Software mit der Vision des Semantic Web zu verbinden, ist z. B. bei Semantic-Wiki-Systemen zu finden. Hier werden erweiterte Möglichkeiten angeboten, Inhalte eines Wikis auf Basis von Ontologien zu annotieren. Muss in gegenwärtigen Systemen die inhaltliche Erschließung noch weitestgehend manuell erfolgen, werden in naher Zukunft semi-automatische Verfahren der Annotati-on – z. B. mittels „Tag Recommender“ – sowie der Datenextraktion – z. B. mittels Wrappern oder Screen Scrapern – die Nutzer bei der inhaltlichen Erschließung unterstützen und dabei generierte Metadaten in einer maschinenverarbeitbaren Form zur Verfügung stellen.

 Location of Vienna in Austria Coordinates:  48°12'N 16°21'E	
State	Austria
Government	
- Mayor	Michael Häupl (SPÖ)
Area	
- City	414.90 km² (160.2 sq mi)
- Land	395.51 km² (152.7 sq mi)
- Water	19.39 km² (7.5 sq mi)
Population (2007)	
- City	1,668,737
- Density	4,011/km² (10,388.4/sq mi)
- Metro	2,081,714
Time zone	CET (UTC+1)
- Summer (DST)	CEST (UTC+2)
Website: www.wien.at	

Abb. 2. Beispiel einer Factbox zu Wien: Strukturierte Metadaten in Wikipedia

Socially Enabled Semantic Web

Während also bei „Semantically Enabled Social Software“ darauf fokussiert wird, wie Social Software um semantische Funktionalitäten angereichert werden kann, um letztlich die Generierung von strukturierten Daten zu unterstützen, liegt der Fokus des „Socially Enabled Semantic Web“ auf der Frage, wie Semantic Web-taugliche Daten der Allgemeinheit zur Verfügung gestellt werden können, um Rich Content Anwendungen am Web zu ermöglichen. Aus dieser Perspektive geht es also nicht um die technologische Realisierbarkeit, sondern um den sozio-kulturellen Prozess zur Generierung einer kritischen Masse an maschinenverarbeitbaren Metadaten.

Erste Ansätze wurden vom FOAF-Community-Projekt¹⁸ unternommen, das zum Ziel hat, Personen dazu zu animieren, persönliche Informationen über Interessen oder soziale Beziehungen in einem einheitlichen maschinenverarbeitbaren Format zu veröffentlichen. Auf Basis einer hinreichenden Anzahl von FOAF-Daten können Anwendungen wie z. B. Expertensuchmaschinen entwickelt werden.

Als neueres Beispiel eines Socially Enabled Semantic Web machen sich *DBpedia* und das damit verbundene Community-Projekt *Linking Open Data* [14] den Umstand zunutze, dass im Web Daten in strukturierter Weise gesammelt und auch frei zur Verfügung gestellt werden. Das DBpedia-Dataset beinhaltet (Stand: Mai 2008) 218 Millionen Triples, die aus Wikipedia extrahiert wurden, und bildet gemeinsam mit anderen Quellen wie Geonames (60 Millionen Triples), Musicbrainz (50 Millionen Triples), dem US Census (700 Millionen Triples) und einer Unmenge an kleinteiligen Daten-Repositories die derzeit wohl umfangreichste maschinenverarbeitbare Datenbasis im Internet.

Diese Quellen bilden nicht nur eine wichtige Basis für das in Entstehung befindliche Semantic Web, sondern sind auch der Ausdruck einer auf Kollaboration und Selbstorganisation aufbauenden Informationskultur, die als Alternative zu einer Top-Down, von Experten geleiteten Wissensorganisation im Web verstanden werden muss. Denn in einem Socially Enabled Semantic Web werden Ordnungssysteme (Ontologien) und darauf basierende Anwendungen nicht von oben vorgegeben, sondern von den Nutzern bottom-up auf Grundlage der zur Verfügung stehenden Datenbasis und (syntaktischen) Standards bedarfsgetrieben entwickelt.¹⁹ Erst dadurch ist

¹⁸ FOAF ist die Abkürzung für Friend-Of-A-Friend und bezeichnet einen Beschreibungssstandard für soziale Netzwerke.

¹⁹ Hier wäre spannend zu untersuchen, ob sich der Bazaar-Governance Ansatz, wie er aus der Open Source Forschung hervorgegangen ist [5], auch auf die kollaborative Generierung und Adaption von Ontologien wie etwa FOAF, SIOC, SKOS etc. anwendbar ist.

gewährleistet, dass Daten beliebig und kollaborativ miteinander kombiniert und wieder zur Verfügung gestellt werden können.

Eine kommunikationswissenschaftliche Perspektive

Zieht man den Erkenntnisstand der Kommunikationswissenschaft zur Internetökonomie heran [35; 40], so lässt sich die Entwicklung des Social Semantic Web mittels zweier reziproker Wirkungsprinzipien beschreiben: (1) die Erhöhung von (sozialer) Konnektivität und (2) die Erhöhung von Kontextualisierung. Abbildung 3 veranschaulicht das Zusammenspiel dieser beiden Dimensionen.




Abb. 3. Reziproke Verstärkung von Konnektivität und Kontextualisierung durch das Social Semantic Web

Unter Konnektivität sollen Aspekte der Vernetzung von Personen, Inhalten, Diensten und Daten, sowie dabei entstehende Kosten, wie Suchkosten, Verhandlungskosten, Maßnahmen zur Vertrauensbildung, Rückbindungsmaßnahmen etc. zusammengefasst werden.

Unter Kontextualisierung fallen hingegen Aspekte des Beschreibens, Ordners, Filterns und Bewirtschaftens von Daten und Information, und damit Kosten, die im Zuge der Anreicherung mit Metadaten, des Datenmanagements, der Herstellung von Interoperabilität etc., kurz: der Konnektivitätssteigerung entstehen.

Beide Dimensionen beeinflussen und regulieren sich gegenseitig. So bedingt eine gesteigerte Konnektivität im Zuge höherer Datenverfügbarkeit und Vernetzung im Internet einen höheren Grad an Kontextualisierung, wie sich an der Nutzung von Internet-Suchmaschinen, aber auch an den vielfältigen neuen Visualisierungs- und Navigationsmethoden wie Tag Clouds, Clustering-Verfahren, Recommender-Systemen, facettiertem Browsing etc. sehen lässt.

Wendet man die Prinzipien Konnektivität und Kontextualisierung auf das Web 2.0 und das Semantic Web an, so fällt auf, dass beide Web-Entwicklungen diese Prinzipien beinhalten, jedoch mit diametral entgegengesetzter Gewichtung. Denn während der Fokus des Web 2.0 auf der Herstellung von Konnektivität und dem „Front-End“ von Applikationen liegt, verfolgt das Semantic Web das Ziel der weitläufigen Kontextualisierung von Daten und adressiert primär das „Back End“. Mit anderen Worten: Beide Entwicklungen stehen komplementär zueinander, sowohl aus technologischer als auch aus organisationaler Sicht. Und sieht man von der Diskussion über die technologische Machbarkeit eines Semantic Web im Sinne von Tim Berners-Lee ab, so scheint offensichtlich, dass die Kontextualisierung ein inkrementelles Prinzip der weiteren Webentwicklung ist, wenn auch bei weitem anspruchsvoller zu realisieren und aus Gründen der Komplexitätsreduktion dem technisch unversierten Nutzer weitgehend verborgen.²⁰

Rekapitulieren wir: Vom Web 1.0 zum Web 2.0

Um gleich mit einem weit verbreiteten Missverständnis aufzuräumen: Das Web 1.0, also das „Web der Dokumente“, wird nicht vom Web 2.0, dem „Web der Services“, ersetzt oder verdrängt, sondern angereichert und teilweise überlagert.

Man kann sich das so vorstellen: Den Kern des „alten“ Web machen vorwiegend (X)HTML-Dokumente aus, die aufeinander via Hyperlink verweisen. Einige wenige Service-Provider verursachen im Web 1.0 den Großteil der Seitenzugriffe. Es werden Seiten, die in Google höher gerankt sind, leichter gefunden, da sie einen höheren PageRank haben²¹. Jede Website hat eine Homepage und viele Unterseiten, die zumeist baumartig organisiert sind, teilweise als „statische Dokumente“ am Webserver liegen, oder als dynamische Seiten aus einer Datenbank heraus generiert werden. Zusammengefasst ausgedrückt: Das Web 1.0 ist das „Web der Dokumente“, Dokumente, die von einigen wenigen für viele passive Benutzer publiziert werden.

²⁰ Dies soll jedoch nicht bedeuten, dass der interessierte Nutzer kein Recht auf die Einsicht und Transparenzierung von Kontextualisierungsmethoden hat und dieses auch einfordern muss. Leider ist die Informationsgebarung von Unternehmen und Behörden bei der Offenlegung ihrer Kontextualisierungsmethoden und -strategien bisher mehr als unbefriedigend.

²¹ Wobei der Begriff PageRank eigentlich vom Namen des Google-Mitbegründers Larry Page abgeleitet ist und die Relevanz einer Webseite im WWW berechnet.

Der entscheidende Schritt in Richtung Web 2.0 ist im Wesentlichen auf zwei Entwicklungen zurückzuführen:

User generieren Content

Dieses Grundprinzip im Web 2.0 hätte eigentlich schon in der Anfangsphase des WWW selbstverständlich sein sollen, ist doch gerade diese Möglichkeit der interaktiven Mediennutzung von Anfang an ein spannendes, neues Element im Internet gewesen. Die Nutzungsforschung [29] aber hat uns gelehrt, dass zunächst nur eine geringe Anzahl von Usern auch aktiv Inhalte erstellt und im Web publiziert hat (z. B. in Form einer eigenen Homepage, seltener noch in Form eines eigenen Web-Shops). Die Gründe dafür sind wohl mannigfaltig, u. a. die zu geringen Bandbreiten Anfang des Milleniums, komplizierte User-Interfaces, der zu geringe Kenntnisstand des durchschnittlichen Users, die fehlenden Vermarktungsmodelle und Marktplätze und damit verbundene extrinsische Motivationsfaktoren, oder einfach nur der Umstand, dass es nicht unbedingt als „cool“ galt, im Web besonders aktiv zu sein.

Die Popularität des „Social Web“-Gedankens stieg mit den wachsenden Partizipationsmöglichkeiten, sodass „jeder“ seinen eigenen Shop betreiben kann (Amazon, Ebay), dass jeder wertvolle Inhalte (auch zum Gemeinwohl anderer) publizieren kann (Wikipedia, Blogs), dass jeder Profil zeigen und sich damit für andere interessant machen kann (Facebook, MySpace, Xing) oder dass auch jeder sein eigenes Video drehen oder Photos schießen und publizieren kann und damit zumindest für „drei Minuten berühmt sein kann“ (Flickr, YouTube). Zusätzlich wurden RSS-Feeds gang und gäbe, um (aktuelle) Inhalte schneller im Web verbreiten zu können, bzw. wurde das einfache Einbinden von Content aus anderen Portalen, z. B. Videos aus YouTube in das eigene Weblog, eine einfache Fingerübung, ja sogar das Erstellen eigener Mashups mit Werkzeugen von Yahoo, Google oder IBM. Parallel dazu stieg das kommerzielle Interesse an Communities und den Möglichkeiten ihrer systematischen Bewirtschaftung.

Neben klassischen Medienhäusern waren es also plötzlich auch die Millionen User, die durch die Nutzung kostenloser Tools dafür sorgten, dass sich Content und Nachrichten über das Web verbreiten konnten. *Sie* waren es, die über die Wichtigkeit und Qualität eines Inhaltes, eines „Memes“ oder einer Nachricht bestimmten, und nicht mehr nur einige wenige Medienhäuser. Im Dezember 2006 kürte das renommierte Nachrichtenmagazin „Time“ daher „YOU“ als Person des Jahres 2006²² und die „Revolution“

²² <http://www.time.com/time/magazine/article/0,9171,1569514,00.html>, zuletzt aufgerufen am 9.10.2007

war vollzogen. Die kollektiven Ehren wurden jedem Web 2.0 User zuteil und das „Social Web“ war in aller Munde. Parallel dazu begann die Debatte darüber, ob dieses Mal wieder das Platzen einer Dot-Com-Blase, wie schon im Jahre 2001, bevorstand, oder ob sich das Internet nun zu einem tragfähigen Modell aus ökonomischer Sicht entwickeln werde.

Web Services zu Mashups verknüpfen

Internet-Provider stellen nicht mehr einfach nur in Browsern darstellbare Dokumente zur Verfügung, sondern auch Services, die via wohl definierter Programmierschnittstellen – kurz APIs genannt – abgefragt und miteinander kombiniert werden können. Ein Beispiel: Ein Web Service (oder Webdienst) namens „Geonames“ liefert u. a. wertvolle Länderinformationen. Nach Aufruf z. B. der Adresse <http://ws.geonames.org/countryInfo?country=AT> werden die wichtigsten Stammdaten des Landes mit dem Ländercode „AT“ (der als Wert für den Parameter „country“ übergeben wurde), also Österreich, als XML-Dokument zurückgegeben. Die Informationen können auch via Browser angezeigt werden:

```
<geonames>
  <country>
    <countryCode>AT</countryCode>
    <countryName>Austria</countryName>
    <isoNumeric>040</isoNumeric>
    <isoAlpha3>AUT</isoAlpha3>
    <fipsCode>AU</fipsCode>
    <continent>EU</continent>
    <capital>Wien</capital>
    <areaInSqKm>83858.0</areaInSqKm>
    <population>8184691</population>
    <currencyCode>EUR</currencyCode>
    <languages>de-AT,tr,sr,hr</languages>
    <geonameId>2782113</geonameId>
    <bBoxWest>9.533569</bBoxWest>
    <bBoxNorth>49.018883</bBoxNorth>
    <bBoxEast>17.166386</bBoxEast>
    <bBoxSouth>46.407494</bBoxSouth>
  </country>
</geonames>
```

Abb. 4. Strukturierte Länderinformationen aus der Geonames-Datenbank




Abb. 5. Screenshot von „Postal Code Mapper“ für Österreich als Beispiel eines Mashups

Ein weiteres Service von Geonames erlaubt so genanntes „Reverse Geo-coding“, d. h. nach Angabe von Längen- und Breitengrad wird jenes Land ermittelt, in dem dieser Punkt liegt: <http://ws.geonames.org/countrycode?lat=47.03&lng=10.2> gibt also den String „AT“ zurück.

Die laut ProgrammableWeb²³, einem Verzeichnisdienst verfügbarer APIs, populärsten Web Services werden von GoogleMaps angeboten. Verbindet man nun zwei Webdienste miteinander zu einer neuen Web-Applikation (oder rekursiv wieder zu einem weiteren, neuen Web Service), so spricht man von einem „Mashup“. Ein Beispiel dafür findet sich in Abb. 5: Der „Postal Code Mapper“²⁴ verbindet Geonames und GoogleMaps zu einer Anwendung, die es Nutzern erlaubt, für einen Kartenausschnitt alle Orte und ihre Postleitzahl anzuzeigen und darüber zu navigieren. Die „Web-seite“ vereint also, für den User nicht sichtbar, zwei oder mehrere Web-Services (und die darunter liegenden Datenbanken) zu einer neuen Anwendung.

ProgrammableWeb zählt derzeit (Stand: Mai 2008) 745 APIs, u. a. in den Kategorien „Advertising“, „Blogging“, „Email“, „Dating“, „Finance“, „Mapping“, „Search“, „Tagging“ und insgesamt rund 3.000 Mashups, die

²³ <http://www.programmableweb.com/> (zuletzt aufgerufen am 09.10.2007)

²⁴ <http://www.xs4all.nl/~mnankman/Web20Stuff/PCMapper.html>, aufgerufen am 09.10.2007

darauf aufsetzen. Ist das der Nukleus für gänzlich neue Geschäftsmodelle im Web?

Wie das Semantic Web vom Web 2.0 begonnen hat zu lernen

Während der Begriff „Semantic Web“ und damit verbundene Konzepte spätestens seit dem viel zitierten Artikel „The Semantic Web“ von Tim Berners-Lee, James Hendler und Ora Lassila, veröffentlicht im Jahre 2001 im „Scientific American“ [4], vor allem in akademischen Communities herumgeisterte und bis heute weltweit ein kontinuierliches aber konstantes Echo hervorrufen konnte, erlebte das Web 2.0 Konzept (und vor allem der Begriff selbst) seit dem Jahre 2005, als im Umfeld des US-amerikanischen O'Reilly-Verlags der Begriff erstmals geprägt wurde, einen dramatischen Zulauf und wachsendes öffentliches Interesse. Ein Blick auf den Web-Dienst „Google Trends“ (Abb. 6) veranschaulicht diesen Trend.

Warum wurde das Semantic Web vom Web 2.0 „überholt“? Oder war damit das Semantic Web am Ende gar ein „überholtes Konzept“? Eines ist klar: Schreiben die Medien über ein Thema, so wird danach gesucht, doch dieser Umstand sagt kaum etwas darüber aus, ob sich dahinter ein tragfähiges, nachhaltiges Konzept verbirgt. Dennoch war schnell klar: Was der Semantic Web Community in all den Jahren nicht gelang, nämlich ein „neues“, besseres Internet zu ermöglichen, war innerhalb von zwei Jahren im Zuge der „Web 2.0 Revolution“ Realität geworden. Ein regelrechter Boom an neuen Webdiensten und -anwendungen setzte ein, Risikokapitalgeber witterten das große Geschäft, Medien berichteten fast täglich über neue, tolle Angebote im Web 2.0 und teure Kongresse zum Thema waren schnell ausgebucht. Der Begriff selbst wurde mit zahlreichen Bedeutungsebenen vorwiegend positiv „aufgeladen“: „basisdemokratisch“, „revolutionär“, „User-freundlich“, „neue Geschäftsmodelle“, „praktisch“, „einfach




Abb. 6. Suchanfragen bei Google bzw. Nachrichtenaufkommen im Zeitverlauf zu den Themen „Web 2.0“ bzw. „Semantic Web“

bedienbar“ oder „nicht technologiebezogen“ hörte man da und man konnte damit das große Publikum ansprechen, plötzlich war auf vielen Softwareprodukten die Etikette „Web 2.0“ zu sehen.²⁵

Parallel zu dieser Entwicklung wurden – vor allem von den Proponenten des Semantic Web – zunächst die Unterschiede zwischen diesen beiden Ansätzen eines „Internet der nächsten Generation“ betont, und für kurze Zeit wurde dabei vor allem die nicht-wissenschaftliche Fundierung und das Unexakte am Web 2.0 Ansatz stark kritisiert. 2005 wurde mit dem Aufsatz von Peter Mika [17] zwar erstmals der Versuch unternommen, eine Brücke zwischen Web 2.0-Folksonomien und Semantic Web-Ontologien zu schlagen, dennoch ist der Begriff „Web 2.0“ auf den Webseiten der ISWC²⁶ im selben Jahr (noch) nicht existent. Jedoch im Jahr 2006 wird dem Thema auf der ISWC ein Keynote-Vortrag und sogar ein eigenes Web 2.0-Panel gewidmet. Auf der WWW2007 schließlich wurde die Beziehung zwischen Web 2.0 und dem Semantic Web systematisch reflektiert [1] und ein Plädoyer dafür abgegeben, beide Ansätze miteinander zu kombinieren, um damit verbesserte Anwendungen wie z. B. Blog-Systeme auf Basis von Semantic Web-Technologien zu realisieren. Diese Entwicklung ist symptomatisch für die Einsicht, dass sowohl Web 2.0-Ansätze als auch die Technologien des Semantic Web vor allem eines unterstützen: „Intelligente“, nutzerzentrierte, Web-basierte Anwendungen im Internet und Intranet.

Zusammenfassend lässt sich feststellen, dass das Semantic Web also keine „Alternative“ zum Web 2.0 ist, sondern zunächst eine Reihe interessanter Möglichkeiten zu Zwecken der strukturierten Erschließung von „Web 2.0 Content“ bietet (wie z. B. im Linking Open Data Project²⁷), aber auch zur kollaborativen Anreicherung von Content mit maschinenlesbaren Metadaten (wie z. B. durch Semantic Wikis). Gemeinsam sind diese beiden Strömungen bzw. technologischen Entwicklungen Ausdruck eines Trends in Richtung „Social Semantic Web“, dem 2007 bereits auf zwei internationalen Konferenzen²⁸ das Hauptaugenmerk galt.

²⁵ Nicht nur im IT-Business war das Attribut „2.0“ plötzlich sehr en vogue: „Enterprise 2.0“, „Office 2.0“, „Real Estate 2.0“, „Erde 2.0“, „Stasi 2.0“ oder gar „Family 2.0“ waren in den Medien zu finden. Doch auch der 2.0-Hype hat spätestens seit dem desaströsen Berliner Ableger von Tim O'Reillys Business-Konferenz Web 2.0 Expo im November 2007 und darauf folgenden Kritiken an Glanz verloren [28].

²⁶ International Semantic Web Conference, findet jährlich statt und gilt als der „Weltgipfel“ der akademischen Semantic Web Community.

²⁷ <http://esw.w3.org/topic/SweoIG/TaskForces/CommunityProjects/LinkingOpenData>, aufgerufen am 10.10.2007

²⁸ I-SEMANTICS in Graz (<http://triple-i.tugraz.at/>) bzw. CSSW in Leipzig (http://sabreconference.wifa.uni-leipzig.de/frontend/index.php?folder_id=43)

Conclusio: Social Semantic Web

„Social Semantic Web“ ist eine Paraphrase, die eine Transformations- und eine Konvergenzbewegung gleichzeitig umschreibt, keinen Zustand. Der Begriff an sich hat keine Chance, über Jahre hinweg einen Trend zu ebnet oder gar ein langfristiges Phänomen zu beschreiben. „Social Semantic Web“ wird in wenigen Jahren als Begriff verschwunden und – so die These der Autoren – im Web als Selbstverständlichkeit aufgegangen sein. Auch wird damit keine langfristige Vision umschrieben, da bereits sämtliche technologischen Bausteine zur Realisierung vorhanden sind, die in Kürze im „Backend“ einer Web-Anwendung fast schon selbstverständlich laufen könnten.

Nachdem das Web zu „kollektivem Bewusstsein“ gekommen war und in Form eines Social Webs um Unmengen neuer Ressourcen (User, Gruppen), Relationen (Ratings, Tags) und Inhalte (Blogs, Wikis) angereichert worden war, wurde auch die Frage immer virulenter, wie sich denn das Social Web nun organisieren könnte, um auch plattform- und applikationsübergreifend den User mit Informationen versorgen zu können. Der Wettlauf um die besten Methoden, Technologien und Applikationen zum (1) Information Retrieval, zur (2) Informationsvernetzung und (3) Informationsaggregation hatte begonnen. Einen wesentlichen Mehrwert bieten dabei Semantic Web Technologien:

1. **Informationszugänge:** Sie basieren nicht nur auf untypisierten Such- bzw. Stichwörtern, sondern vermehrt auf „Facetten“: Personen, Orte oder Organisationen gehören zu den wichtigsten „Dingen“, nach denen gesucht wird, also wollen die zugrunde liegenden Stellen eines Textes bzw. Web-Ressourcen auch als solche erkannt werden. Semantische Technologien und Metadaten-Schemata des Semantic Web tragen dazu bei, dass diese Zusatzinformationen mit geringem Mehraufwand größtenteils automatisiert generiert werden können.
2. **Informationsvernetzung:** Die automatisierte Vernetzung von Informationen im Netz basiert im Regelfall auf dem Prinzip der semantischen Ähnlichkeit. Nachrichten, Blogs oder User mit ähnlicher Bedeutung, ähnlichen Profilen oder Inhalten wollen als „nahe liegende“ weitere Stationen im Zuge eines Browsings erfahren werden. Die Methoden zur Erkennung von Ähnlichkeiten werden dementsprechend ausgefeilter und basieren nicht mehr nur auf simpler Begriffsebene, sondern auf Wissensmodellen und Ontologien.
3. **Informationsaggregation:** Aus Mashups werden Semantic Mashups, aus Wikis werden Semantic Wikis, aus Blogs Semantic Blogs, d. h. Web Services oder auch Desktop-Anwendungen bauen auf einer „Semantic Web Middleware“ auf. RDF wird zum universellen Data Access Layer bzw. zur ultimativen Mashup-Sprache, auf deren Basis „Model Driven Architecture“ zur Realität wird.

Die wachsende Adaption semantischer Technologien zu Zwecken der strukturierten Erschließung von „Web 2.0 Content“, aber auch der Einsatz von Social Software zur kollaborativen Anreicherung von Web Content mit maschinenlesbaren Metadaten sind Ausdruck des Trends in Richtung Social Semantic Web, was von einigen Beobachtern auch plakativ als Web 3.0 bezeichnet wird.

An der technologischen Machbarkeit des Social Semantic Web wird an vielen Ecken und Enden gearbeitet. Jedoch die zunehmende Verfügbarkeit von Daten und die Möglichkeit ihrer Vernetzung verändern nachhaltig die wirtschaftlichen, sozialen und kulturellen Bedingungen des Internets und bedürfen einer eingehenden Betrachtung, die über die technologische Machbarkeit hinausgeht. Hier sind vor allem die Sozial- und Geisteswissenschaften gefordert ihren Beitrag zu leisten.

Dieser Forderung kann in diesem Band nur ansatzweise entsprochen werden, zumal nicht der Platz vorhanden ist, um all die auftretenden technischen, wirtschaftlichen, sozialen und politischen Fragen zufriedenstellend zu beantworten. Dennoch sei festgehalten, dass die Transformation des Internet zu einem allumfassenden, universellen Kommunikations- und Informationsmedium kontinuierlich voranschreitet. Das Social Semantic Web sollte in diesem Prozess zwar als temporäre, aber nichts desto weniger als disruptive Entwicklung im Auge behalten werden.

Literatur

1. Ankolekar, Anupriya; Krötzsch, Markus; Tran, Thanh; Vrandečić, Denny (2007). The Two Cultures. Mashing up Web 2.0 and the Semantic Web. In: <http://www2007.org/papers/paper777.pdf>, aufgerufen am 10.04.2008
2. Auer, Sören; Bizer, Christian; Müller, Claudia; Zhdanova, Anna V. (2007). The Social Semantic Web 2007. Proceedings of the 1st Conference of Social Semantic Web. Bonn: Gesellschaft für Informatik
3. Benkler, Yochai (2006). The Wealth of Networks. How Social Production Transforms Markets and Freedom. New Haven: Yale University Press
4. Berners-Lee, Tim; Hendler, James; Lasilla, Ora (2001). The Semantic Web. In: http://www.sciam.com/print_version.cfm?articleID=00048144-10D2-1C70-84A9809EC588EF21, aufgerufen am 09.10.2007
5. Demil, Benoit; Lecocq, Xavier (2006). Neither Market, nor Hierarchy, nor Network: The Emergence of Bazaar Governance. In: Organization Studies, 27/2006, S. 1447 – 1466
6. Die Presse (2008). Yahoo kündigt semantische Suche an. 17.03.2008. In: <http://diepresse.com/home/techscience/internet/yahoo/370355/index.do?parentid=183130&act=0&isanonym=0>, aufgerufen am 10.04.2008

7. eBay (2007). eBay Acquires StumbleUpon. In: http://www.businesswire.com/portal/site/google/index.jsp?ndmViewId=news_view&newsId=20070530006201&newsLang=en, aufgerufen am 10.04.2008
8. Google (2006). Google To Acquire YouTube for \$1.65 Billion in Stock. In: http://www.google.com/press/pressrel/google_youtube.html, aufgerufen am 10.11.2007
9. Heise.de (2007). Datenschützer: EU-Beschluss zum Austausch von Fluggastdaten inakzeptabel. In: <http://www.heise.de/newsticker/suche/ergebnis?rm=result;words=Fluggastdatenaustausch;q=flugdatenaustausch;url=/newsticker/meldung/101018/>, aufgerufen am 20.04.2008
10. Hu, Jim (2005). Yahoo buys photo-sharing site Flickr. In: http://www.news.com/Yahoo-buys-photo-sharing-site-Flickr/2100-1038_3-5627640.html, aufgerufen am 10.11.2007
11. Krempf, Stefan (2008). Offene Fragen zum Datenschutz bei Facebook und StudiVZ. In: <http://www.heise.de/newsticker/suche/ergebnis?rm=result;words=StudiVZ;%20AGB;q=studivz;%20agb;url=/newsticker/meldung/102092/>, aufgerufen am 04.04.2008
12. Krempf, Stefan (2008). Große Koalition will Internetzensur entgegenreten. In: <http://www.heise.de/newsticker/suche/ergebnis?rm=result;words=Bundestrojaner;q=bundestrojaner;url=/newsticker/meldung/106996/>, aufgerufen am 30.04.2008
13. Krempf, Stefan (2008). Rufe nach Globalisierung des Datenschutzrechts. In: <http://www.heise.de/newsticker/suche/ergebnis?rm=result;words=Vorratsdatenspeicherung;q=vorratsdatenspeicherung;url=/newsticker/meldung/107478/>, aufgerufen am 08.05.2008
14. Linking Open Data (2007). In: <http://esw.w3.org/topic/SweoIG/TaskForces/CommunityProjects/LinkingOpenData>, aufgerufen am 10.07.2007
15. Malik, Om (2007). Is Facebook Beacon a Privacy Nightmare?. In: <http://gigaom.com/2007/11/06/facebook-beacon-privacy-issues/>, aufgerufen am 28.03.2008
16. Maurer, Hermann; Balke, Tilo; Kappe, Frank; Kulathuramaiyer, Narayanan; Weber, Stefan (2007). Report on dangers and opportunities posed by large search engines, particularly Google. In: http://www.iicm.tugraz.at:8080/home/hm_hp/publications/_id2348a_/2007/Report%20on%20dangers%20and%20opportunities%20posed%20by%20large%20search%20engines,%20particularly%20Google.htm, aufgerufen am 10.04.2008
17. Mika, Peter (2005). Ontologies Are Us. A Unified Model of Social Networks and Semantics. In Gil, Yolanda; Motta, Enrico; Benjamins, Richard V.; Musen, Mark (Eds.). *The Semantic Web – Proceedings of the 4th International Semantic Web Conference*. New York: Springer
18. O'Reilly, Tim (2005). What is the Web 2.0. In: <http://www.oreillynet.com/pub/a/oreilly/tim/news/2005/09/30/what-is-web-20.html>, aufgerufen am 10.11.2007
19. OpenCalais (2008). Terms of Use. In: <http://opencalais.com/>, aufgerufen am 20.04.2008
20. Pellegrini, Tassilo; Blumauer, Andreas. (2008). Social Semantic Web – Die Konvergenz von Social Software und semantischen Technologien. In: Back,

- Andrea; Baumgartner, Horst; Gronau, Norbert; Tochtermann, Klaus (Hrsg.), Web 2.0 in der Unternehmenspraxis. Grundlagen, Fallstudien und Trends zum Einsatz von Social Software, Oldenburg Wissenschaftsverlag (in Druck)
21. Perez, Juan Carlos (2005). Update: Yahoo buys social bookmarking firm Del.icio.us. In: http://www.infoworld.com/article/05/12/09/HNyahobuyfirm_1.html, aufgerufen am 10.11.2007
 22. Petersen, David (2008). Microsoft set to launch Semantic Web light. In: <http://www.sitepoint.com/blogs/2008/03/26/microsoft-set-to-launch-semantic-web-light/>, aufgerufen am 20.04.2008
 23. Reuters (2007). Reuters to acquire text search firm ClearForest. In: <http://www.reuters.com/article/technology-media-telco-SP/idUSNAAD300120070430>, aufgerufen am 10.11.2007
 24. Riley, Duncan (2008). Microsoft Offers \$44.6 Billion To Acquire Yahoo. In: <http://www.techcrunch.com/2008/02/01/wow-microsoft-offers-446-billion-to-acquire-yahoo/>, aufgerufen am 20.04.2008
 25. Schaffert, Sebastian (2006). Semantic Social Software: Semantically enabled Social Software or Socially enabled Semantic Web. In: Schaffert, Sebastian; Sure, York (Eds.). Semantic Systems. From Visions to Applications. Wien: OCG Verlag
 26. Shy, Oz (2001). The Economics of Network Industries. Cambridge: Cambridge University Press
 27. Skype (2005). eBay to Acquire Skype. In: http://about.skype.com/2005/09/ebay_to_acquire_skype.html, aufgerufen am 10.11.2007
 28. Stöcker, Christian (2007). Holtzbrinck Buys German Web Community StudiVZ. In: <http://www.spiegel.de/international/0,1518,457766,00.html>, aufgerufen am 10.11.2007
 29. Unterluggauer, Mariann (2007). Soziales Web? O'Really?, am 17.11.2007. In: <http://futurezone.orf.at/business/stories/234022/>, aufgerufen am 14.04.2008
 30. van Eimeren, Birgit; Frees, Beate (2007). Internetzung zwischen Pragmatismus und YouTube-Euphorie. ARD/ZDF-Online-Studie 2007. In: Media-Perspektiven, Nr. 8/2007, S. 362–378.
 31. VNUnet (2006). Rumours point to Microsoft acquisition of Yahoo. In: www.vnunet.com/vnunet/news/2155283/rumours-microsoft-pondering, aufgerufen a, 10.01.2008
 32. W3C (2004). Resource Description Framework (RDF). In: <http://www.w3.org/RDF/>, aufgerufen am 20.04.2008
 33. W3C (2008). W3C Semantic Web Activity. In: <http://www.w3.org/2001/sw/>, aufgerufen am 10.11.2007
 34. Welt Online (2008). Auch Schlecker unter Spionage-Verdacht. In: http://www.welt.de/welt_print/article1854411/Auch_Schlecker_unter_Spionage-Verdacht.html, aufgerufen am 02.05.2008
 35. Widmann, Britta (2008). Ebay trennt sich möglicherweise von Skype. In: <http://www.zdnet.de/news/business/0,39023142,39189870,00.htm>, aufgerufen am 05.05.2008
 36. Wirtz, Bernhard (2006). Medien- und Internetmanagement. Wiesbaden: Gabler Verlag

37. WSRI (2008). Creating a Science of the Web. In: <http://webscience.org/>, aufgerufen am 20.04.2008
38. Yahoo! (2008). Yahoo! Announces Next Generation of Mobile Search, to Provide Better Answers and Easier Ways to Search. In: <http://yhoo.client.shareholder.com/press/releasedetail.cfm?ReleaseID=302850>, aufgerufen am 20.04.2008
39. Young, Robert (2005). Why Murdoch Really Bought MySpace? In: <http://gigaom.com/2005/08/06/why-murdoch-bought-myspace/>, aufgerufen am 10.04.2008
40. ZDF (2007). Microsoft steigt bei Facebook ein. In: <http://www.heute.de/ZDFheute/inhalt/12/0,3672,7112556,00.html>, aufgerufen am 10.04.2008
41. Zerdick, Axel; Picot, Arnold; Schrape, Klaus, Artopé, Alexander; Goldhammer, Klaus, Heger, Dominik K.; Lange, Ulrich T.; Vierkant, Eckart, López-Escobar, Esteban; Silverstone, Roger (2001). Die Internet-Ökonomie. Strategien für die Digitale Wirtschaft. Berlin: Springer Verlag
42. APA (2007). Online-Werbung soll Radio 2008 überholen. In: <http://futurezone.orf.at/business/stories/185244/>, aufgerufen am 10.04.2008

2. Warum Web 2.0? Oder: Was vom Web 2.0 wirklich bleiben wird

Sonja Bettel

Wissenschaftsjournalistin, Wien, Österreich;
sonja@bettel.at

Zusammenfassung: Dieser Beitrag diskutiert die Entwicklungsgeschichte und den Facettenreichtum eines Begriffes, der gleichsam für technologische Innovation, soziale Modernisierung und eine schlaue Marketingstrategie steht. Es zeigt sich, dass die Verortung des Phänomens Web 2.0, gerade aufgrund der Polemik und Polarisierung, die der Begriff hervorgerufen hat, schwieriger ist, als man vermuten mag. Doch eines ist gewiss: Seit das Web 2.0 in unser Bewusstsein gelangt ist, ist das Internet wieder „in“.

Eigentlich war der Begriff schlecht gewählt.

„Web 2.0“, das rief ganz bewusst Assoziationen zu Software hervor, bei der sich die chronologisch-inhaltliche Namensführung „Mac OS X Version 10.3.9“ oder „Internet Explorer 5.2.3“ eingebürgert hat. Dafür gibt es eine klare Notwendigkeit, denn bei Software ist es wichtig, dass man Versionen voneinander unterscheiden kann. Durch die Art und Weise, wie Computerprogramme korrigiert und weiterentwickelt werden, hat sich die zwei- oder dreifache Abstufung als sinnvoll erwiesen, wobei jede „Nachkomma“-Stelle kleinere Entwicklungsschritte bedeutet. Die Versionen 1.2.1 und 1.2.2 einer Software unterscheiden sich also nur durch kleine Fehlerkorrekturen, ein Sprung von 1.2 auf 2.0 bedeutet, dass das Programm grundlegend überarbeitet wurde.

Hier beginnt die Irreführung, denn das „Web 2.0“ ist kein neues Internet. Es ist nicht plötzlich neu und anders und schon gar nicht ist es eine neue Version einer Software, von Protokollen oder technischen Spezifikationen.

Dennoch: Der Begriff „Web 2.0“ ist offenbar gut gewählt, sonst würde er sich nicht so inflationär ausbreiten. Seine Qualität besteht wohl darin,

dass er kurz und einprägsam ist und eine Entwicklung – wenn auch nur vage – benennt, die sich eigentlich nur schwer in einem Begriff zusammenfassen lässt. Zwar ist er so aussagekräftig wie der Spruch „I’m lovin’ it“ für eine Fastfood-Kette, aber genauso eingängig. Daran merkt man, dass „Web 2.0“ als Marketing-Schlagwort entwickelt worden war und großteils auch noch als solches verwendet wird.

A name is born

Es war im Jahr 2004 – oder man könnte auch sagen: im Jahr 4 nach dem Platzen der sogenannten „Dot-Com-Blase“ im März 2000. Dale Dougherty, Vizepräsident des kalifornischen Software-Buch-Verlags O’Reilly und Craig Cline von der Firma MediaLive International dachten über eine neue IT-Konferenz nach [1].

Dougherty stellte fest, dass das Internet trotz des Platzens der Dot-Com-Blase nicht an Bedeutung verloren hatte, sondern wichtiger war denn je. Mit schöner Regelmäßigkeit tauchten neue Anwendungen und Websites auf und die, die den Crash überlebt hatten, schienen einige Dinge gemeinsam zu haben. Könnte es sein, dass das Platzen der Dot-Com-Blase einen Wendepunkt des Webs markiert hatte? „Ja“, entschied die kleine Gesprächsrunde, und so wurde der Begriff „Web 2.0“ für dieses quasi „neue World Wide Web“ geprägt.

Im Oktober 2004 fand in San Francisco die erste Konferenz unter diesem Namen statt, die seither jährlich im Herbst abgehalten wird. Der „Web 2.0 Summit“, wie die Konferenz mittlerweile heißt, wird von O’Reilly und CMP United Business Media veranstaltet und bringt einen erlauchten Kreis aus der Geschäftswelt des „neuen“ Web zusammen. Teilnehmen darf man nur auf Einladung, Journalisten sind nur in kleiner Zahl zugelassen.

Seit ihrem ersten Jahr hat die Web 2.0 Konferenz ihre Themen immer wieder den Entwicklungen des Internet-Marktes angepasst. Auf der Konferenz-Website www.web2summit.com heißt es:

Web 2.0 Summit focuses on emerging business and technology developments that utilize the Web as a platform and defines how the Web will drive business in the future. What began as a focused gathering on the implications of the Web becoming a platform has transformed into an industry event focused on the latest Internet innovations – the services, applications, businesses, and models – that are redefining the way companies do business and how people live.

Die Konferenz, die ja den Ausgangspunkt des Begriffes Web 2.0 gebildet hat, ist mittlerweile also sehr breit angelegt. Sie beschäftigt sich nicht

mehr nur oder nicht mehr konkret mit dem, was Dale Dougherty und seine Mitdenker als Web 2.0 bezeichnet hatten (siehe weiter unten), sondern mit neuesten Internet-Innovationen und neuen Internet-Geschäftsmodellen generell. Der Name „Web 2.0“ wird aber weiterhin für die Konferenz verwendet und wurde schon bei der Planung der ersten Konferenz als „Service Mark“ (also als Markenrecht für Dienstleistungen) eingetragen. Das Schlagwort Web 2.0, wie es in den Medien, in wissenschaftlichen Diskursen und von Firmen, die es zur Bewerbung ihrer Produkte und Services nützen, verwendet wird, hat mit dieser Konferenz jedoch längst nichts mehr zu tun. Der Begriff Web 2.0 hat sich verselbständigt, bemerkt auch Tim O'Reilly in seinem Blog-Eintrag „Web 2.0 Service Mark Controversy“: „We created a meme that has legs beyond the conference space (...)“ [2]. Gemessen an der Häufigkeit der Verwendung des Begriffs haben die Entwickler der Web 2.0-Konferenz jedenfalls beste Marketing-Arbeit geleistet.

Bei der Suchmaschine Google klettert die Zahl der Einträge des Begriffs stetig nach oben. Tim O'Reilly selbst schrieb Ende September 2005 in seinem Text zu Web 2.0, dass der Begriff rund 9,5 Millionen Zitierungen in Google aufweise; Ende November 2006 waren es rund 500 Millionen, Ende September 2007 bereits etwa 666 Millionen.

Im allgemeinen Sprachgebrauch ist Web 2.0 aber wohl noch ein Fremdwort. Bei einer spontanen Straßenbefragung würde man wahrscheinlich noch viele gerunzelte Stirnen hervorrufen, würde man fragen: „Wissen Sie, was Web 2.0 bedeutet?“. Selbst wenn ein Passant oder eine Passantin den Begriff schon einmal gehört oder gelesen hätte, könnte er oder sie vermutlich nicht erklären, was damit gemeint ist. Das ist aber auch gar nicht so leicht.

Ein Name – kein Programm?

Was Web 2.0 bedeuten soll, ist kaum in einen Satz zu fassen. In seinem Online-Text „What is Web 2.0“ aus dem Jahr 2005 braucht Tim O'Reilly dafür 14 A4-Druckseiten, die deutsche Ausgabe der Online-Enzyklopädie Wikipedia schafft es auf etwa 7 Seiten und Sir Tim Berners-Lee, der das World Wide Web 1989 federführend mitbegründet hat, meint, dass niemand wisse, was dieses Schlagwort überhaupt bedeuten solle. Als ihn Scott Laningham, der Herausgeber des IBM Developer Works Podcast fragt, ob auch er der Meinung sei, dass es im Web 2.0 um die Vernetzung und die Zusammenarbeit von Menschen gehe, verneint Tim Berners-Lee recht brüsk:

LANINGHAM: You know, with Web 2.0, a common explanation out there is Web 1.0 was about connecting computers and making information avail-

able; and Web 2.0 is about connecting people and facilitating new kinds of collaboration. Is that how you see Web 2.0?

BERNERS-LEE: Totally not. Web 1.0 was all about connecting people. It was an interactive space, and I think Web 2.0 is of course a piece of jargon, nobody even knows what it means. If Web 2.0 for you is blogs and wikis, then that is people to people. But that was what the Web was supposed to be all along. And in fact, you know, this Web 2.0, quote, it means using the standards which have been produced by all these people working on Web 1.0. It means using the document object model, it means for HTML and SVG and so on, it's using HTTP, so it's building stuff using the Web standards, plus Java script of course. So Web 2.0 for some people it means moving some of the thinking client side so making it more immediate, but the idea of the Web as interaction between people is really what the Web is. That was what it was designed to be as a collaborative space where people can interact. [3]

Im Podcast ist deutlich hörbar, dass Sir Tim Berners-Lee über den Web 2.0-Hype verärgert ist – vor allem auch deshalb, weil „sein“ Web damit zum „Web 1.0“ degradiert wird. Beschäftigt man sich auch nur ein bisschen mit den technischen und strukturellen Voraussetzungen des World Wide Web und überlegt man sich, welche Leistung Tim Berners-Lee für die Menschheit erbracht hat (dafür wurde er ja auch im Jahr 2004 durch Königin Elisabeth II. zum Knight Commander of the Order of the British Empire ernannt), so wird sein Ärger verständlich. Aber fragen wir doch einmal die Erfinder des Begriffs Web 2.0, was sie eigentlich damit gemeint haben.

In seinem Text „What is Web 2.0“ beschreibt Tim O'Reilly, wie sie sich in einem Brainstorming dem eben kreierten Begriff angenähert hatten. Das begann zuerst mit einer Unterscheidung zwischen „altem“ und „neuem“ Web. Zum „Web 2.0“ zählten demnach zum Beispiel Google AdSense, Flickr, BitTorrent, Napster, Wikipedia oder Blogging. Deren Pendant aus dem „Web 1.0“ waren DoubleClick, OFoto, Akamai, mp3.com, Britannica Online und persönliche Websites. Bei näherer Betrachtung dieser spontanen Zuordnung konnte die Runde dann verschiedene Merkmale der Anwendungen neuen Stils erkennen: Das Web dient als Plattform; die Anwendungen profitieren von der „kollektiven Intelligenz“ der User; „Infoware“ (gemeint sind die Daten) wird wichtiger als Software; Software wird nicht mehr in Zyklen herausgegeben, sondern laufend verbessert; „leichtgewichtige“ Programmier-Modelle erlauben die lose Kombination von Systemen und regen zum „Hacken“ und „Remixen“ an; Software darf nicht nur für ein Ausgabegerät geschrieben sein; die Anwendung muss dem Nutzer reichhaltige Erlebnisse bieten.

Das ist hier nur eine grobe und aus dem Englischen übersetzte Zusammenfassung dessen, was Tim O'Reilly in seinem Text weit ausführlicher

beschreibt und mit Beispielen illustriert. Dennoch: O'Reilly kann nicht besonders überzeugen, dass es sich beim Web 2.0 seiner Definition nach um ein „neues“ Web handelt, dessen Entstehung man womöglich auch noch am Tag oder zumindest am Jahr X festmachen könnte. Und das ist auch kein Wunder, denn einige der wesentlichen technischen Entwicklungen, die für Wikipedia, Flickr, Napster und dergleichen nötig waren, sind mittlerweile etwa zehn und mehr Jahre alt.

Aus technischer Sicht bezeichnet der Begriff Web 2.0 zumeist eine Kombination von Techniken, die größtenteils Ende der 1990er Jahre entwickelt wurden. Zu diesen Techniken zählen zum Beispiel Web-Service-APIs (etwa 1998 beginnend), AJAX (etwa 1998 entwickelt) und Abonnement-Dienste wie RSS (1997 erstmals als Dienst von UserLand angeboten, 1999 führte Netscape RSS 0.9 ein). Noch häufiger als diese technischen Voraussetzungen werden heute Ausprägungen sogenannter „sozialer Software“ als Kennzeichen des Web 2.0 genannt. Dazu zählen als bekannteste Wikis und Blogs.

Das erste Wiki namens „WikiWikiWeb“ wurde vom US-amerikanischen Softwareautor Ward Cunningham ab 1994 entwickelt und 1995 über Internet anderen verfügbar gemacht. Das Wort „wiki“ stammt aus dem Hawaiianischen und bedeutet „schnell“, „wikiwiki“ steht für eine Steigerung des Wortes, also „sehr schnell“. Cunningham kannte diese Bezeichnung vom Shuttle-Bus am Flughafen auf Hawaii und verwendete sie für das schnell editierbare Web.

Das Konzept von Wikis ähnelt dem, was sich Sir Tim Berners-Lee unter dem World Wide Web vorgestellt hatte, wie er rückblickend in seinem Buch „Weaving The Web“ beschreibt. Die Informationen sollten am privaten Rechner verfügbar und sofort bearbeitbar sein [4].

Auch Weblogs sind im Grunde so alt wie das World Wide Web. „Schon die erste Website überhaupt, info.cern.ch, war ein Weblog.“, schreibt Erik Möller in seinem Buch „Die heimliche Medienrevolution. Wie Weblogs, Wikis und freie Software die Welt verändern“ [5]. Denn „(...) Tim Berners-Lee publizierte dort regelmäßig Links auf neue Fundstellen im noch überschaubaren Web.“

Das erste bekannte Online-Tagebuch schrieb laut Erik Möller Carolyn Burke aus Toronto im Jahr 1995. Ab 1996 wurden Services wie Xanga eingerichtet, die Internetnutzern das Erstellen eines eigenen Online-Tagebuchs erleichterten. Der Begriff „Weblog“ tauchte erstmals 1997 auf der Website von Jorn Barger auf, der damit Websites bezeichnete, die mit dem jeweils aktuellsten Eintrag oben auf andere Seiten verweisen. Aus der verkürzten Wortkombination für „World Wide Web“ und „Log“ wurde 1999, im Jahr, als diese Publikationsform weithin beliebt wurde, die noch kürzere Bezeichnung „Blog“.

Viele Elemente des sogenannten Web 2.0 sind also nicht neu und existierten schon vor dem Dot-Com-Crash. Viele heute weithin bekannte Anwendungen, Services und Plattformen wurden großteils aber erst in den Jahren ab 2000 gegründet, wie zum Beispiel Wikipedia (März 2001), Flickr (ab 2002, ursprünglich zum Hochladen von Bildern für ein Online-Spiel) oder YouTube (Februar 2005); Google wurde bereits im Herbst 1998 gegründet, der richtige Durchbruch erfolgte aber erst im Jahr 2000. Die Dynamik der Entstehung und Verbreitung dieser Anwendungen war und ist sicherlich durch die Verbreitung von Internet-Zugängen und vor allem die massive Zunahme an Breitband-Anschlüssen bedingt oder mitbedingt. Um die Wandlung des World Wide Web in den vergangenen zehn Jahren zu verstehen – will man diese nun „Web 2.0“, irgendwie anders oder gar nicht dezidiert benennen – muss man sich vor Augen führen, wie das WWW anfänglich ausgesehen hat.

Von der „Homepage“ zur Website

Das World Wide Web ist ein Dienst im Internet und macht es möglich, im Internet multimedial aufgebaute Dokumente zu präsentieren und mit so genannten Hyperlinks aktiv auf andere Quellen zu verweisen. Das WWW entstand 1989 am Kernforschungszentrum CERN in Genf, an dem Tim Berners-Lee ein Hypertext-System aufbaute. Das ursprüngliche Ziel des Systems war, Forschungsergebnisse auf einfache Weise mit Kollegen austauschen und interaktiv „verflechten“ zu können – deshalb „Web“. 1990 schrieb Berners-Lee das erste Web-Anzeigeprogramm, also den Webbrowser, mit dem man erstmals im Web „stöbern“ konnte.

Spätere Browser, wie Pei Weis 1992 entwickelter „Viola“, fügten die Fähigkeit hinzu, Grafiken anzuzeigen. Marc Andreessen veröffentlichte im Jahre 1993 einen Browser namens „Mosaic für X“, der bald dem Web und auch dem gesamten Internet große Popularität jenseits der wissenschaftlichen Nutzerkreise bescherte. Aus der Firma „Mosaic Communications Corporation“ wurde später „Netscape Communication“.

Die Entwicklungen Ende der 1980er und Anfang der 1990er Jahre waren also radikal, im Vergleich zu heute wirken sie jedoch wie lahme Enten.

Das WWW bestand in den 1990er Jahren vor allem aus statischen Seiten, manchmal sogar nur aus einer Seite, die über längere Zeit unverändert im Netz stand und von den Nutzern bloß gelesen oder betrachtet werden konnte. Ab Mitte der 1990er Jahre entstand langsam die Idee, dass man als Firma, Institution oder vielleicht sogar als Privatperson so eine „Homepage“, wie es technisch ungenau hieß, haben müsse. Eine „Homepage“ ins Netz zu stellen oder ihre Inhalte auszutauschen erforderte gewisse Programmier-

kenntnisse und wurde deshalb nur vom „Webmaster“ durchgeführt. Mit der Zeit entstanden dafür HTML-Editoren, bei denen man für das Befüllen einer Website keine Code-Kenntnisse mehr benötigte.

Weil es langweilig und für Kunden oder Besucher wenig attraktiv war, sich ewig die gleiche Webseite anzuschauen, und weil Websites auch von mehreren Menschen mit Inhalten befüllt werden können sollten, wurden Content Management Systeme und aus Datenbanken gespeiste Systeme entwickelt. Neuere Browser konnten diese dynamischen Inhalte sowie Musik, Video und Animationen wiedergeben. Heute besteht das WWW längst aus umfangreichen Web-Sites, also Orten, an denen viele „Häuser“ mit vielen „Trakten“ und „Zimmern“ zu finden sind.

Das Web – Einkaufszentrum oder Kaffeehaus?

Menschen wollen aber nicht nur konsumieren oder sich informieren, sondern auch und vor allem kommunizieren. Dafür waren das Internet und das World Wide Web ja gedacht und dafür wurden sie zu Beginn auch genutzt, wenn auch nur von einem kleinen Kreis. Das Usenet zum Beispiel war interaktiv, die Inhalte wurden von den Nutzern erstellt und es ging um Meinungsaustausch, das Knüpfen und Erhalten von Kontakten und um soziale Bedürfnisse – also im Grunde all das, was jetzt mit dem „Web 2.0“ angeblich so neu ist.

Während des Dot-Com-Hypes beginnend ab Mitte der 1990er Jahre witterten viele „Start-Up“-Unternehmer, zur „New Economy“ gewandelte alteingesessene Firmen und eine Reihe von Venture-Kapitalisten das ganz große Geld im Web. Jeden Tag wurden neue Geschäftsideen entwickelt, neue „Killer-Applikationen“ erfunden und neue Bedürfnisse geweckt.

Manches ist geblieben, das meiste traf jedoch nicht die wahren Bedürfnisse der Nutzer. Was sie wollen – und im Grunde in anderer Form immer schon wollten – wird im sogenannten Web 2.0 deutlich: Kontakte knüpfen und halten, Freunde und (Sexual-)Partner finden, sich darstellen, ihre Meinung äußern, ihre Interessen pflegen und sich mit Gleichgesinnten darüber austauschen, spielen, sich unterhalten, Informationen suchen und finden, Erlebnisse in Form von Fotos, Videos und Geschichten mit anderen teilen und ab und zu einen Urlaub oder eine Reise planen. All diese Bedürfnisse haben schon vor dem Internet und erst recht vor dem „Web 2.0“ bestanden – sie wurden bloß auf andere Weise gedeckt.

Natürlich gehört auch das Konsumieren zum Leben und dient der Erfüllung von Bedürfnissen. Die Frage ist nur, was im Vordergrund steht, wenn Menschen das Web nutzen. Vergleichen wir es einmal mit dem „real life“:

In einem Kaffeehaus wird konsumiert, in erster Linie ist es aber ein Ort sozialer Kontakte. In einem Einkaufszentrum kann man meist auch einen

Imbiss zu sich nehmen, in erster Linie dient es aber dem Konsumieren. Nun stellt sich die Frage: Was ist das World Wide Web? Ist es mehr ein Kaffeehaus oder mehr ein Einkaufszentrum? Natürlich ist es vieles beziehungsweise kann es für vieles dienen. Zwischen jenen, die das Web nutzen wollen, und jenen, die damit verdienen wollen, scheinen aber sehr unterschiedliche Vorstellungen davon zu herrschen.

Dale Doherty von O'Reilly war vom Internet der sogenannten Dot-Com-Ära ausgegangen, als er den Begriff Web 2.0 prägte. Er fragte sich, was die Unternehmen des Jahres 2004 von jenen der Jahre von etwa 1998 bis 2000 unterschied. Das World Wide Web der Dot-Com-Ära war jedoch nicht DAS Web, sondern nur ein sehr kleiner Ausschnitt einer Entwicklung und eine Sichtweise eines großen und komplexen „Dings“ aus Technik, Infrastruktur, Daten und Menschen. In der Dot-Com-Hochblüte war es in erster Linie um die Frage gegangen, wie man mit dem Internet und dem World Wide Web Geld verdienen kann – viel Geld. In vielen Fällen, in denen das sogenannte Web 2.0 heute gehypet wird, geht es wieder in erster Linie ums Geschäft. Manche sprechen sogar von einer neuen Dot-Com-Blase (oder sogar von einer „Dot-Com-Blase 2.0“, weil die Namensgebung im Stil von Software-Version für alles Mögliche modern geworden ist) angesichts der Milliarden US-Dollar, die in jüngerer Zeit für sogenannte Web 2.0-Anwendungen über den Ladentisch gegangen sind. Nehmen wir zum Beispiel das Videportal YouTube.

Komm, wir kaufen uns eine Community

YouTube wurde im Februar 2005 von den drei ehemaligen PayPal-Mitarbeitern Chad Hurley, Steve Chen und Jawed Karim gegründet. Die Plattform bietet Nutzern die Möglichkeit, Videos kostenlos hochzuladen und anzuschauen. Zu Beginn waren die Videos von extrem schlechter Qualität und der Eindruck entstand: Wen soll das bloß interessieren?! Absolut schlechte Videos gibt es auf YouTube immer noch zuhauf, vereinzelt aber auch gute, spannende, lustige, skurrile und auch politisch bedeutende.

Im November 2005 erhielt YouTube 3,5 Millionen US-Dollar vom Risikokapitalgeber Sequoia Capital aus dem Silicon-Valley, der auch den Start von Google finanziert hatte, im April 2006 weitere 8 Millionen Dollar. Im Frühjahr 2006 wurde YouTube mit 600 Millionen US-Dollar bewertet, ein halbes Jahr später schon mit 1,5 Milliarden und eine Reihe von großen Medienunternehmen hatten Interesse an einer Übernahme. Anfang Oktober 2006 war es dann so weit: Google kaufte YouTube um umgerechnet rund 1,31 Milliarden Euro in Aktien. Täglich werden Zehntausende

Videos hochgeladen und von wahrscheinlich Millionen Nutzern angeschaut – das ergibt einen sehr großen Markt für Werbung und andere Einnahmemöglichkeiten.

Viele der großen Deals der vergangenen zwei Jahre betrafen Plattformen, die zuerst scheinbar aus purer Menschenfreundlichkeit als Treffpunkt für bestimmte Interessen gedient hatten. Die Web-Plattform MySpace, das Fotoportal Flickr, das Videoportal YouTube, der Voice over IP-Dienst Skype, das Online-Bezahlungssystem PayPal, die Musikempfehlungsplattform Last.fm und, wie sie alle heißen, haben Menschen angelockt, die sogenannte Online-Communities gebildet haben. Diese Menschen haben viele persönliche Daten teilweise bewusst in die Systeme eingegeben und teilweise unbewusst als Datenspuren hinterlassen. Diese Menschen und die dahinterstehenden Daten, mit denen man detaillierte Nutzerprofile (Konsumentenprofile!) erstellen kann, waren Rupert Murdoch 580 Millionen Dollar für MySpace, Ebay-Chefin Meg Whitman 2,5 Milliarden Dollar für Skype oder Ex-Paramount-Studio-Boss Barry Diller 1,85 Milliarden Dollar für die Suchmaschine AskJeeves wert. Das ist die eine Seite des Web 2.0-Geschäfts.

Web 2.0 inside!

Die andere Seite ist jene, an der die Werkzeuge des Web 2.0 genutzt werden – meist in weitaus kleinerem Geschäftsumfang. Dafür gibt es mehrere Einsatzmöglichkeiten. Da gibt es zuerst einmal die Hoffnung, dass ein Mehrwert generiert wird, wenn Menschen (Kunden) Web 2.0-Anwendungen nützen oder eine Firma sich zumindest ein modernes Image verpassen kann.

Ende August 2007 veröffentlichte die Firma novomind AG, ein Hamburger Softwareanbieter für prozess- und kostenoptimierende Kundenkommunikation, eine Studie mit dem Titel „Vernetzte Kunden – Wie Web 2.0 das Online-Shopping verändert“, die gemeinsam mit wiwo.de und handelsblatt.com durchgeführt worden war. In der Pressemeldung heißt es dazu:

Im Zuge von Web 2.0 haben Kundenforen im Internet einen regen Zulauf. 75 Prozent der Internetnutzer lesen regelmäßig Empfehlungen anderer Käufer. Immer mehr Online-Shopper wenden sich allerdings mit ihrer Kritik direkt an den Händler oder Anbieter. Knapp 15 Prozent der Online-Kunden schreiben Verbesserungsvorschläge. Damit wirken sie aktiv an der Gestaltung und Weiterentwicklung von Produkten und Dienstleistungen mit. Für Händler und Anbieter bedeutet diese Auskunftsfreude eine ideale Gelegenheit, Kunden durch persönliche Beteiligung in Fans und damit in loyale Kunden zu verwandeln. [6]

Für die Studie wurden im Zeitraum von 30. Jänner bis 28. Februar 2007 374 Verbraucher befragt. Auf die Frage, „Unterbreiten Sie Online-Händlern und Anbietern Vorschläge zur Verbesserung ihrer Produkte?“ hatten 2,3 Prozent „häufig“ angegeben, 12,4 Prozent „gelegentlich“ und 21,1 Prozent „selten“. Besonders repräsentativ war die Studie also nicht und besonders aufregend ist auch nicht die Beteiligung der Kunden an der Produktverbesserung. Die eigentliche Botschaft ist jedoch die Presseaussendung von novomind. Web 2.0 wird als Marketing-Begriff genützt, vor allem für und von Medien, die knappe und schlagkräftige Headlines brauchen. Die österreichische Online-Zeitung derStandard.at zum Beispiel berichtete über diese Studie am 26. September mit dem Titel „Wunderwaffe Web 2.0: Kritik von Kunden minimiert Kosten“ [7].

Der sogenannte „user generated content“ wird in einigen Geschäftsbereichen bereits gerne genützt – einerseits, um Kunden Informationen eingeben zu lassen, andererseits, um den Kunden das Gefühl zu vermitteln, man sei bei neuen technischen Entwicklungen vornweg dabei. So begann vor etwa zwei Jahren ein regelrechter Hype mit Firmenblogs, in denen irgendwelche CEOs oder Mitarbeiter so tun sollen, als ob sie die Besucher ihrer Websites mit Insiderinformationen beliefern oder an der Unternehmenskultur teilhaben lassen würden.

Der „Web 2.0“-Hype hat sich mittlerweile aber völlig verselbständigt. Vieles, was nicht einmal mehr im Entferntesten mit dem zu tun hat, was Dale Dougherty und seine Mitdenker sich darunter vorgestellt hatten, wird mit „Web 2.0“ betitelt, weil das „modern“ klingt. Und es geht noch weiter: die Software-Version-Bezeichnung greift seit „Web 2.0“ seuchenartig um sich. Da gab es einen Vortrag bei den Medientagen in Wien Ende September 2007 mit dem Titel „Radio 2.0 – wird jetzt alles anders?“, bei der Ars Electronica in Linz Anfang September 2007 konnte man über „Identity 2.0“ diskutieren und den „campus 2.0“ besuchen und Ende November 2007 wurde in Berlin das interaktive Theaterstück „Antigone 2.0“ aufgeführt. Und nicht zuletzt wird das Semantic Web gerne auch als „Web 3.0“ bezeichnet.

Web-Anwendungen zum Zusammenbauen

Viel interessanter als die Überlegungen, was Web 2.0 nun bedeuten soll und ob es eine gute Idee war, einen so prägnanten Begriff für etwas so Schwammiges einzuführen, erscheinen die Möglichkeiten, die sich durch Wikis, Weblogs, Foto-, Video-, Bookmark- und sonstige Plattformen eröffnen. Was rund um „social software“ laufend neu entsteht, gewandelt wird, verschränkt wird und wie zum Einsatz kommt, ist sehr komplex und wird immer unübersichtlicher. Umso mehr man jedoch über konkrete Ein-

zelentwicklungen nachdenkt, umso klarer wird, dass diese Anwendungen tatsächliche massive Veränderungen auf vielen Ebenen bewirken können. Welche Möglichkeiten die Anwendungen bieten, sei deshalb ausschnittsweise an drei konkreten Beispielen beschrieben:

Fall A: MoCookin

Im Frühjahr 2007 produzierte die Firma Blinklicht Medienproduktions GesmbH aus Wien für den Österreichischen Rundfunk ORF einige Folgen einer Kochsendung mit dem Titel „MoCookin“ als Pilotsendungen für Handy-TV. Im Zentrum der wenige Minuten langen Folgen steht der „mobile Koch“ (deshalb „MoCookin“) Bernie Rieder, der mit den Zutaten und einem orangen MoCookin-Auto an einen jeweils anderen Ort fährt, um dort zu kochen. In einer Brauerei im Waldviertel kreiert er zum Beispiel ein Dessert, das aussieht wie ein Glas Bier, bei einem Konservenhersteller in Wien Ottakring einen Salat aus Gemüsekonserven.

Die Videos kann man sich von der Website www.mocookin.at herunterladen oder gleich dort anschauen. Die Website basiert auf Blog-Software von Six Apart, erinnert gestalterisch ein bisschen an MySpace und nützt eine ganze Reihe von Web 2.0-Anwendungen. Bernie Rieder schreibt tagebuch-artige Einträge über seine Koch-Reisen auf der Website und kurze „was ich gerade mache“-Schnipsel für die Tratsch-Plattform Twitter, es gibt einen Eintrag für den Firmensitz von Blinklicht beim Dienst plazes (Werbespruch von plazes: „Right Plaze, Right People, Right Time“), „Backstage“-Fotos von der Produktion kann man sich auf der Fotoplattform Flickr anschauen, es gibt RSS-Feeds für neue Einträge auf der MoCookin-Website und Links mit allerlei zum Thema Kochen zu anderen Blogs, Portalen und Online-Shops über den Dienst Feedburner.

Interessanterweise ist auch die Website der Blinklicht Medienproduktions GesmbH www.blinklicht.at im Grunde bloß ein Blog mit RSS-Feeds, Thumbnails von MoCookin-Fotos, die auf Flickr stehen, Feedburner-Werbe-Links und dem plazes-Link. Prominentestes Element auf der Website ist (Stand Ende September 2007) ein Faksimile des Printmagazins „News“ mit einem Porträt der Firma bzw. von zweien der drei Inhaber, das betitelt ist: „Die Web 2.0-Macher“. Korrekterweise hätte der Titel lauten müssen: Die Web 2.0-Nutzer.

Die Sache ist jedenfalls klar: durch Web 2.0-Anwendungen konnte die Firma Blinklicht sehr rasch und sehr preisgünstig größtmögliche Wirksamkeit für „MoCookin“ erreichen. Die Software kommt fix-fertig aus dem Netz und ist größtenteils gratis, die Anwendungen mussten bloß zu einem „mashup“ zusammengesetzt werden, Speicherplatz für Fotos ist an Flickr ausgelagert, bezahlte Werbe-Links, zum Beispiel von Amazon,

werden automatisch generiert, Plattformen wie Flickr, plazes und dergleichen sorgen für gratis Marketing, erzeugen Aufmerksamkeit und „web-traffic“, der wiederum die Werbeeinnahmen steigert. Darin liegt also das eigentliche ökonomische Potential von Web 2.0.

Fall B: fair music

Diese Chancen des Web 2.0 nutzen auch Initiativen, deren Währung nicht unbedingt Produktionsbudget oder Werbeeinnahmen, sondern „nur“ Aufmerksamkeit ist. Im August 2007 wurde zum Beispiel die Initiative „fair music“ – die sich weltweit für Fairness im Musikgeschäft einsetzt – der Öffentlichkeit vorgestellt. Neben den „klassischen“ PR-Werkzeugen Presseaussendung, Pressekonferenz und öffentliche Diskussion nützt die Initiative ein eigenes Blog mit der Software von WordPress, um über ihre Anliegen und Neuigkeiten zu ihrem Thema zu informieren. Um als neue Initiative möglichst rasch Bekanntheit zu erreichen, werden Dienste wie RSS-Feeds, Technorati (Echtzeit-Internet-Suchmaschine, speziell für Weblogs), del.icio.us (social bookmark manager), Digg-it (eine Plattform für das Entdecken und Tauschen von Informationen) oder die Präsentation eines eigens produzierten Videos auf YouTube eingesetzt. Üblicherweise verbreiten sich Informationen im „Web 2.0-Zeitalter“ relativ rasch, wenn eine in der jeweiligen Szene angesehene Person darüber in ihrem Blog berichtet oder einen Link auf ein Video, Foto oder die Ursprungssite veröffentlicht. Wenn zum Beispiel der US-amerikanische Journalist und Autor Howard Rheingold über die Initiative schreibt, verbreitet sich dieser Umstand über Technorati, Digg-it, RSS-Feeds und dergleichen oder über Leute, die Howard Rheingolds Website regelmäßig besuchen, in die „Szene“. Und wenn Rheingold ein Thema interessant, eine Initiative unterstützenswert findet, dann verbreiten andere diese Informationen weiter. Die Bekanntheit einer Website oder eines Projektes wächst dadurch exponential, weil Links gerne und oft wieder weiterverlinkt, Blog-Einträge zitiert und die Zitate wieder zitiert werden.

Das sind die Chancen des Web 2.0 in Zeiten der Medienkonzentration: Man kann eine gewisse Aufmerksamkeit auch mit wenig zeitlichem oder finanziellem Aufwand erreichen, wenn man die richtigen Kanäle nützt.

Fall C: Das Business-Modell des Boris Frigge

Manche „Prosumer“ (Produzenten-Konsumenten) nutzen die Möglichkeiten des sogenannten Web 2.0 aber nicht, weil sie etwas zu sagen oder zu verkaufen haben, sondern einfach, weil es da ist. Nicht wenige posten zum

Beispiel auf YouTube Videos, die einfach nur abgefilmte oder kopierte Fernsehsendungen sind. Und manche Blogger begnügen sich damit, Einträge, Artikel oder Ideen von anderen zu verlinken, zu zitieren oder zu kopieren, um so zu zeigen, dass sie dabei sind, oder vorzugeben, dass sie etwas zu sagen hätten.

Eine Person namens Boris Frigge aus Frankfurt hat diese Methode offenbar gewinnbringend perfektioniert und die Mechanismen des Web 2.0 an sich zum Geschäftsmodell erklärt. Boris Frigge steht im Impressum von mehreren Websites wie www.admin-treff.com, www.online-sport-treff.com, www.it-service-24.com, www.news4people.de, www.football-fan-magazin.com, www.onlinesex-treff.com ... und vermutlich noch einigen mehr. Die Sites sind mit Wordpress mit vorgefertigten Themen – oft sogar den gleichen Themen für verschiedene Sites – gestaltet und in Blog-Form größtenteils mit Meldungen der Nachrichtenagentur presstext gefüllt. Zwischen und neben den Meldungen finden sich Google-Ads und andere Werbung, weiters werden RSS-Feeds, Werbe-Links, eine Wetter-Vorschau und ähnliche Dienste genutzt. Auf der Website admin-treff findet sich unter dem Impressum auch noch der Hinweis „Wir berichten über“ und dann sind etwa hundert Schlagworte gelistet wie „Netzwerksicherheit“, „Mailserver“, „Red Hat Linux“, „Office 2003“, „XBox“ usw. Der Zweck ist klar ersichtlich: die Begriffe sorgen für ein häufiges Auftauchen der Sites in den Ergebnissen von Suchmaschinen-Anfragen zu diesen Themen. Die Blog-Form sorgt durch laufende Postings für scheinbare Aktualität und die gegenseitige Verlinkung der verschiedenen Sites für scheinbar hohe Relevanz, was ein hohes Suchmaschinen-Ranking ergibt, das wiederum die Werbeeinnahmen der automatisch generierten Google- und sonstigen Ads erhöht.

Eigentlich genial: Boris Frigge, wer immer er sei, hat das System verstanden und geschickt für seine Zwecke genutzt. Vermutlich kopiert er die im Internet frei verfügbaren Presstexte auch nicht händisch in seine Blogs, sondern lässt einen Bot für sich arbeiten und sonnt sich derweilen auf den Bahamas.

„Wir sind das Netz“?

Das Magazin Wired, einst DIE Instanz, wenn es um neue Entwicklungen rund um das Web ging, blickte in seiner Ausgabe 13.08 vom August 2005 auf zehn Jahre Web-Entwicklungen zurück – von Marc Andreessens Netscape bis zur Bloggerin Ana Marie Cox, die im September 2004 in Jeans und einem abgeschnittenen T-Shirt an der Republican National Convention im New York Yacht Club teilgenommen hatte. Der Artikel von Kevin Kelly ist betitelt: „We are the web“ und der Lead lautet:

The Netscape IPO wasn't really about dot-commerce. At its heart was a new cultural force based on mass collaboration. Blogs, Wikipedia, open source, peer-to-peer – behold the power of the people. [8]

Die Visionäre des World Wide Web, wie Vannevar Bush oder Ted Nelson, und deren Verwirklicher hätten vor allem an die Möglichkeiten einer Welt gedacht, die mit Hyperlinks vernetzt ist, schreibt Kelly. Dabei hätten alle „the big story“ übersehen: im Zentrum sei eine neue Form der Beteiligung gestanden, aus der sich eine Kultur des Teilens entwickle. Kevin Kelly beschreibt in seinem Artikel die Entwicklung der Jahre zwischen 1995 und 2005 und welche Fülle an Inhalten in dieser Zeit im Web entstanden ist. Kaum jemand hätte geahnt, so Kelly, dass ein großer Teil dieser Inhalte von Usern generiert würde, und nicht aufgrund von Firmeninteressen.

Wie Hyperlinks und Blog-Einträge wanderte auch der Titel „We are the web“ weiter: In der Ausgabe 29/2006 des deutschen Nachrichtenmagazins Der Spiegel erschien ein mehrseitiger Artikel mit dem Titel „Du bist das Netz!“, am 13. Dezember 2006 widmete das amerikanische Printmagazin Time das Titelblatt den Internet-Usern. „Person of the Year: You“ stand groß über und unter einem Computer, der gleichzeitig wie ein Abspielfenster für ein Video aussah. Zahlreiche „Wir sind das Netz“ und ähnliche Titel in verschiedenen Medien folgten. Journalisten sind ja stets im Stress und freuen sich, wenn sie nichts Neues erfinden müssen.

Die vielen Artikel zu nutzergenerierten Web-Inhalten, digitalen Gemeinschaften, Foren und Blogs sind jedoch ein Barometer für die Entwicklungen, die erkannt werden.

Das ist die andere Seite der anderen Seite. Hört man auf, in Schlagworten zu denken, dann wird es leichter, zu sehen, was vor sich geht im Web und durch das Web.

Ein Netz von Fragen

Ja, die Buchrezensionen auf der Website von Amazon, die von Usern geschrieben werden, sind immer wieder hilfreich für potentielle Käufer. Ja, die Hinweise auf interessante Orte, die von Nutzern in Google Earth eingetragen werden, machen die virtuelle Weltkugel erst richtig zu einem hilfreichen Werkzeug. Über die große Hilfe, die das Online-Lexikon Wikipedia für die schnelle Suche nach allen möglichen und unmöglichen Dingen bietet, muss man nicht mehr reden; aber es sei auch das Online-Wörterbuch www.leo.org erwähnt, das wie Tausende und Abertausende anderer Plattformen und Sites gratis unglaublich wertvolle Informationen

bietet. Natürlich gibt es jede Menge Datenmüll im World Wide Web, aber es gibt auch Kleinode, Engagement, gegenseitige Unterstützung und wertvolle Informationen aller Art, deren Erstellung niemand bezahlen würde und könnte. Kostengünstig gewordene Foto- und Videokameras, leistbarer und verfügbarer Breitband-Internetzugang, Kamerahandys und eine sich ausbreitende „IT-Literacy“ potenzieren laufend die Menge an Informationen, die von „ganz normalen Menschen“ ins Web gestellt und über das Web verbreitet werden. Das (individuell) Wertvolle aus der Fülle herauszufiltern, ist heute die eigentliche Schwierigkeit – aber auch dabei helfen neue Anwendungen und Plattformen.

Die Beteiligung der Nutzer an der Erstellung von Inhalten und Services ist nicht zu leugnen. Vieles davon ist sehr brauchbar, aber was bedeutet das gesellschaftspolitisch?

Viele Fragen und der Versuch einiger Antworten:

Fördern das Web 2.0 und digitale Techniken die Demokratie und die Freiheit?

Das ist noch nicht unbedingt erkennbar, aber sie sind offenbar eine Bedrohung für die Machterhaltung. Nicht umsonst zensurieren und limitieren Diktaturen den Zugang zum Internet. Die Technik an sich ist nicht automatisch demokratiefördernd, denn auch Diktaturen und Terroristen können sie zur Verbreitung ihrer Botschaften nützen – teilweise weit besser, als der durchschnittliche Bürger. Es wird aber auf jeden Fall leichter, Informationen zu verbreiten; Zeitungen kann man beschlagnahmen und vernichten, digitale Daten lassen sich – einmal ins Netz entwichen – nicht mehr zurückholen.

Durch das Web und seine einfache Benutzbarkeit ist es vielen leichter möglich geworden, ihre Meinung zu äußern. Mehr heißt aber nicht automatisch besser. Verfolgt man zum Beispiel die Postings, die zu Nachrichten auf ORF.at geschrieben werden, wünscht man sich manchmal, die Kommentar-Funktion wäre nie erfunden worden. Liest man die Postings auf derStandard.at, ist man wieder ein wenig versöhnt, weil dort immer wieder sehr treffende, witzige oder kritische Kommentare zu finden sind.

Überlegt man sich, ob das Web 2.0 oder das Internet generell die Demokratie fördern, so muss man sich vor Augen führen, dass (noch) nicht alle Menschen Zugang zu diesem Medium haben und nicht alle Menschen damit adäquat umgehen können. Außerdem haben wohl nicht alle Menschen das Bedürfnis oder den Mut, sich im Web zu äußern oder darzustellen. Würde man also von den Meinungen, denen man im Web begegnet, auf die gesamte Gesellschaft schließen, könnte man ziemlich falsch liegen.

Ändert das Web 2.0 das soziale Gefüge?

Soziale Netzwerke, Foto- und Videoplattformen, Blogs, Foren, Suchmaschinen und von Nutzern generierte „tags“ sorgen dafür, dass viel mehr private Informationen an die Öffentlichkeit getragen werden, als vor Entstehung dieser technischen Möglichkeiten. Welche Auswirkungen und Konsequenzen das haben kann, wurde bei der Ars Electronica 2007 mit dem Titel „Goodbye Privacy“ ausführlich diskutiert. Von mehreren Symposiumsteilnehmern wurde zur Sprache gebracht, dass das, was andere über uns wissen, darauf rückwirkt, wie wir uns ihnen gegenüber oder in der Gesellschaft generell verhalten. Blogs, soziale Netzwerke und Reputationssysteme haben jedenfalls dazu geführt, dass die Anonymisierung eines Users im Web keine Tugend mehr ist – im Gegenteil. Wer seine Daten preisgibt und sich von Netzwerken neue Freundschaften oder Geschäftskontakte erhofft, möchte wissen, mit welchen anderen er oder sie es zu tun hat.

Menschen sind soziale Wesen und wollen mit anderen kommunizieren. Sofern dies technisch möglich ist, nützen sie deshalb Medien in erster Linie dazu, mit anderen Menschen in Kontakt zu treten. Oft geht es dabei einfach nur darum, zu sagen „ich bin da“ oder „mir geht es...“. Besonders Mobiltelefone sind diesem Bedürfnis stark entgegengekommen. Menschen rufen einander in allen möglichen und unmöglichen Situationen an, nur um zu sagen, dass sie gerade im Bus sitzen, die Straße überqueren, Milch kaufen oder der Chef gerade in die Mittagspause gegangen ist. Oft schicken sie einander auch nur SMS.

In Japan, so erzählt der japanische Internetaktivist Joi Ito, der unter anderem auch Vorstandsmitglied der Internetverwaltung ICANN ist, leben Kinder und Jugendliche mithilfe ihres Computers und mobiler Geräte in einer ständigen Ko-Präsenz. Sie chatten neben den Hausübungen und schreiben SMS vom Mobiltelefon in der Hosentasche, nur um ihren Freunden mitzuteilen, wo sie gerade sind und was sie gerade machen.

Die Technik hat aber noch etwas verändert: junge Menschen machen sich mit ihren Freunden nichts mehr vorab aus für den Nachmittag oder das Wochenende. Sie rufen einander an, erzählen sich gegenseitig, wo sie gerade sind, und treffen sich dann, um gemeinsam noch ein paar andere Freunde anzurufen. Sie müssen einander auch nicht mehr unbedingt erzählen, was sie erlebt haben oder worüber sie sich Gedanken machen – sie schreiben es einfach in ihren Blog oder auf ihre MySpace-Seite und kommunizieren so mit dem gesamten Freundeskreis. Wenn sie einen lustigen Film gesehen oder ein schönes Lied gehört haben, schicken sie sich gegenseitig den Link per e-mail. Und Liebeserklärungen stehen als romantische Fotos in Flickr oder als jämmerlich auf dem Klavier geklimpertes Liebeslied auf YouTube.

Ja, das Web 2.0 verändert das soziale Gefüge, allerdings in erster Linie bei der jüngeren Generation. Wie werden sie in einigen Jahren miteinander leben und kommunizieren, wenn sie älter geworden sind und wenn es Anwendungen und Dienste geben wird, die wir uns heute noch nicht einmal vorstellen können? Wer wagt, das vorherzusagen?

Beeinflusst das Web 2.0 die klassischen Medien?

Während des Dot-Com-Booms waren in den „klassischen“ Medien – vor allem in Zeitungen, Printmagazinen und dem Fernsehen – skurrile Veränderungen zu beobachten. Im österreichischen Nachrichtenmagazin Profil zum Beispiel ähnelte das Seiten-Layout etwa um 1995 oder 1996 für kurze Zeit einer Website – mit Menüpunkten und „Hyperlinks“, also Markierungen von Begriffen, die in einem Kasten am Rande erklärt wurden. Auch im österreichischen Fernsehen tauchte die damals typische Menüstruktur einer Website auf.

Die Übertragung der Entwicklungen und der Ästhetik des „Web 2.0“ in „klassische“ Medien ist (zum Glück) nicht so einfach. Die klassischen Medien nutzen Anwendungen und Dienste des Web 2.0 allerdings für ihre Arbeit und teilweise auch als Quelle. Auf den Online-Ausgaben von „klassischen“ Zeitungen, Zeitschriften, Fernsehen und Radio gibt es seit längerem Foren und Möglichkeiten, Kommentare zu posten, teilweise gibt es Blogs oder Podcasts und es gibt die Möglichkeit, neue Nachrichten als RSS-Feeds zu abonnieren. Die „klassischen“ Medien selbst haben sich dadurch bisher aber kaum verändert – zumindest sind sie nicht bürger näher oder interaktiver geworden.

Inhaltlich wird vereinzelt aus Blogs und Wikipedia zitiert oder über Videos auf YouTube berichtet. Inhalte von Blogs, Foren, Foto- und Videoplattformen lösen vereinzelt auch eine Berichterstattung in den „klassischen“ Medien aus oder ergänzen diese wesentlich, wie zum Beispiel zu Beginn des Irakkriegs das Blog „Where is Read?“, die Google Earth-Bilder nach dem Hurrikan Katrina in New Orleans oder Berichte und Suchmeldungen nach dem Tsunami in Indonesien im Dezember 2004. Skandale, politische Ereignisse und dergleichen mehr können ebenfalls in Blogs oder auf YouTube aufgeworfen werden.

Bringt das Web 2.0 den Bürgerjournalismus?

Digitale Technologien, insbesondere das Internet und das World Wide Web, haben zweifelsohne mehr Menschen die Möglichkeit gegeben, ihre Interessen, Beobachtungen, Anliegen, Meinungen und Kritik zu publizieren und an

eine breitere Öffentlichkeit zu bringen. Einige dieser Veröffentlichungen tragen alle oder zumindest einen Teil der Kennzeichen von Journalismus: die periodische publizistische Veröffentlichung von aktuellen Beiträgen, die für ein breiteres Publikum von Interesse sind. Was ein Journalist ist, ist vage definiert, jedenfalls verstehen Journalisten sich selbst meist als Berufsgruppe und nicht als Hobbyverein. Ist deshalb jemand, der in seinem Blog über etwas schreibt, das aktuell ist und einen größeren Leserkreis interessieren könnte, kein Journalist, nur weil er oder sie damit kein Geld verdienen? Ist dieser jemand ein Journalist, wenn er mit seinem Blog Einnahmen über Google Ads generiert? Ist er ein Journalist, wenn er im Auftrag einer Firma Blog-Einträge zu deren Produkten schreibt und dafür Geld erhält? Und spielen Blogs und vergleichbare Online-Publikationen bei den Rezipienten die gleiche Rolle wie „klassische“ Medien?

Mit derartigen Fragen muss sich die Kommunikations- und Medienforschung wohl noch ausführlich beschäftigen. Die technischen Veränderungen werden wohl einige strukturelle und inhaltliche Veränderungen mit sich bringen.

Interessant wird es, wenn womöglich das Interesse des Publikums an den klassischen Medien schwindet und sich die Menschen nur noch über „user-generated content“ informieren. Andererseits befinden sich viele Web 2.0-Plattformen mittlerweile im Eigentum großer Medienkonzerne. Insofern wäre zu überlegen, ob die User in Zukunft im Interesse dieser Konzerne nicht einfach nur zu Gratis- oder Billig-Arbeitskräften für Medieninhalte werden.

Was vom Web 2.0 bleiben wird?

Prognosen sind immer heikel, aber versuchen wir es einmal mit ein paar Überlegungen:

- Der Begriff Web 2.0 wird vermutlich wieder verschwinden oder nur mehr als historisch interessant in Erinnerung bleiben – genauso, wie heute kaum noch jemand vom „Datenhighway“ spricht.
- Die Technik wird generell immer mehr in den Hintergrund treten. Das Internet und das World Wide Web werden zur selbstverständlichen Infrastruktur werden, deren Existenz kaum noch wahrgenommen wird – höchstens, wenn sie einmal fehlt oder fehlerhaft ist.
- Applikationen werden ebenfalls immer mehr in den Hintergrund treten – zumindest für die User. Wer denkt – auch heute schon – über die Funktionsweise oder gar die Existenz von Suchmaschinen nach? Dass sie da sind und benutzt werden können, wird als Selbstverständlichkeit wahr-

genommen. Umso besser sie den Menschen das liefern werden können, was diese suchen, umso mehr werden sie ins Unbewusste abtauchen.

- Die Verschränkung von Desktop-Computer, serverbasierten Diensten und Datenbanken und verteilten Filesharing-Datenhaltungen wird weiter voranschreiten. Auch die Kombination verschiedener Dienste und Anwendungen – sogenannter Mashups – wird weitergehen. Ausgabegeräte werden noch mobiler werden und – womöglich – nichts mehr mit dem Desktop-Computer zu tun haben.
- Wo Menschen und Firmen die neuesten technischen Entwicklungen dazu nutzen können, Geld oder geldwerte Vorteile zu erlangen, werden sie es tun – egal ob legal oder illegal.
- Neue Dienste und Plattformen werden noch eine Weile in schneller Abfolge auftauchen, mit der Zeit werden sich einige relevante behaupten und bestehen bleiben, am Rande wird es ein wechselndes Rauschen neuer Hypes und Abstürze geben.

Was sonst noch bleiben wird? Sicherlich das, wofür die Werkzeuge des WWW, des Web 2.0, Web 3.0 oder welcher Begriff auch immer dafür erfunden werden wird, letztendlich dienen: zur Befriedigung von menschlichen Bedürfnissen. Deren aktuelle Version ist 0.0.9 – oder so.

Literatur

1. Tim O'Reilly: What is Web 2.0. Design Patterns and Business Models for the Next Generation of Software. 30.9.2005, www.oreilly.com/lpt/a/6226
2. Tim O'Reilly: Web 2.0 Service Mark Controversy (Tim responding this time). 30.5.2006, http://radar.oreilly.com/archives/2006/05/web_20_service_mark_controvers.html
3. aus dem Transkript des Interviews vom 28.7.2006, <http://www128.ibm.com/developerworks/podcast/dwi/cm-int082206.txt>
4. Tim Berners-Lee, Mark Fischetti: Weaving the Web: The Original Design and Ultimate Destiny of the World Wide Web by Its Inventor. San Francisco, 1999
5. Erik Möller: Die heimliche Medienrevolution. Wie Weblogs, Wikis und freie Software die Welt verändern. Hannover 2005
6. www.novomind.de, Presse-News vom 28. August 2007
7. Wunderwaffe Web 2.0: Kritik von Kunden minimiert Kosten. 26.9.2007, <http://derstandard.at>, Archiv
8. Kevin Kelly: We are the web. In: Wired 13.08, August 2005, S. 109

3. Entwicklungsperspektiven von Social Software und dem Web 2.0

Alexander Raabe

ProSiebenSat.1 Produktion, Berlin, Deutschland;
Alexander.Raabe@gmx.de

Zusammenfassung: Der Artikel beschäftigt sich zunächst mit dem derzeitigen und zukünftigen Einsatz von Social Software in Unternehmen. Nach dem großen Erfolg von Social Software im Web beginnen viele Unternehmen eigene Social Software-Initiativen zu entwickeln. Der Artikel zeigt die derzeit wahrgenommenen Einsatzmöglichkeiten von Social Software im Unternehmen auf, erörtert Erfolgsfaktoren für die Einführung und präsentiert mögliche Wege für die Zukunft. Nach der Diskussion des Spezialfalles Social Software in Unternehmen werden anschließend die globalen Trends und Zukunftsperspektiven des Web 2.0 in ihren technischen, wirtschaftlichen und sozialen Dimensionen dargestellt. Wie aus den besprochenen Haupttrends hervorgeht, wird die Masse an digital im Web verfügbaren Informationen stetig weiterwachsen. So stellt sich die Frage, wie es in Zukunft möglich sein wird, die Qualität der Informationssuche und der Wissensgenerierung zu verbessern. Mit dem Einsatz von semantischen Technologien im Web wird hier eine revolutionäre Möglichkeit geboten, Informationen zu filtern und intelligente, gewissermaßen „verstehende“ Anwendungen zu entwerfen. Auf dem Weg zu einem intelligenten Web werden sich das Semantic Web und Social Software annähern: Anwendungen wie Semantic Wikis, Semantic Weblogs, lightweight Semantic Web-Sprachen wie Microformats oder auch kommerzielle Angebote wie Freebase von Metaweb werden die ersten Vorzeichen einer dritten Generation des Webs sein.

Einleitung

Social Software hat vor einigen Jahren begonnen die Art und Weise, wie das Internet genutzt wird, zu revolutionieren und dafür gesorgt, dass Menschen im Mittelpunkt des „neuen“ Webs stehen. Menschen erstellen gemeinschaftlich mit Hilfe von Wikis Enzyklopädien wie die Wikipedia, publizieren selbst erstellte Inhalte mithilfe von Weblogs, nutzen RSS-Feeds, stellen mit Social Sharing-Plattformen wie Flickr oder YouTube

ihre Fotos und Videos online oder bilden über Social Networking-Sites wie Facebook, XING oder StudiVZ Netzwerke. Die Wirtschaft profitiert von dem Web 2.0, sei es durch den Einsatz von Social Software im Unternehmen oder durch neue Geschäftsmodelle wie dem Long Tail. Doch welche Bestandteile des Web 2.0 werden weiterhin einen großen Einfluss haben und in welche Richtung wird sich das Web weiterentwickeln? Der Artikel veranschaulicht die Rolle eines wichtigen Teils der Web 2.0-Entwicklung, Social Software in Unternehmen, und beleuchtet anschließend mögliche Perspektiven für das gesamte Web 2.0.

Social Software im Unternehmen

Aufgrund des enormen Erfolges von Social Software in Form von Wikis und Weblogs im World Wide Web haben mittlerweile Unternehmen begonnen dessen Potentiale zu prüfen und einzusetzen. Im Jahre 2006 hat das Interesse an Social Software im Unternehmen durch die Besetzung des Begriffes Enterprise 2.0 weiteren Antrieb bekommen. Angelehnt an die Metapher des Web 2.0 und ähnlichen Begriffsbildungen wie TV 2.0, Games 2.0, Design 2.0 oder sogar Handy 2.0, kann Enterprise 2.0 als Schlagwort für den Einsatz von Social Software in Unternehmen und den damit verbundenen kulturellen Änderungen verstanden werden. Das Thema rückt desgleichen bei einer Reihe von Konferenzen seit einigen Jahren verstärkt in den Fokus von Wissenschaft und Praxis.¹ Zudem wächst die Zahl an Fallstudien über erfolgreich in Unternehmen genutzte Social Software beständig, genau wie klassische Medien, etwa die New York Times, Business Week, Times Magazine oder der SPIEGEL, das Thema aufgreifen und darüber berichten. Wie verbreitet derzeit die Nutzung von Web 2.0-Technologien in Unternehmen ist, legen mehrere aktuelle Studien nahe. Nach einer Umfrage von McKinsey, bei der weltweit 2.847 Manager befragt worden sind, antworteten zwischen 13% und 19% der Befragten, dass sie momentan in Wikis, Weblogs, Social Networking und RSS investierten; zwischen 32% und 37% der Befragten antworteten, sie setzten diese Techniken ein oder planten dieses. Auffällig war außerdem, dass die Mehrzahl der Befragten angab mit den Investitionen zufrieden zu sein [13]. Die Befragung macht deutlich, dass bei vielen Unternehmen Social Software zwar noch nicht angekommen ist, doch die ersten Erfolge stimmen zuversichtlich für eine zunehmende Verbreitung.

¹ Wie um diesen Trend zu bestätigen wurde 2007 die jährlich in Boston stattfindende Collaborative Technologies Conference in Enterprise 2.0 Conference umbenannt, siehe <http://www.enterprise2conf.com/>

Einsatzmöglichkeiten

Social Software kann entweder für die unternehmensinterne Zusammenarbeit benutzt werden oder extern, um auf den Beziehungen zwischen Geschäftspartnern und Kunden aufzubauen. Folgende Einsatzmöglichkeiten für Social Software sind denkbar:

Wikis können bspw.

- im Bereich des Wissensmanagements,
- als Dokumentationswerkzeug zum gemeinsamen Bearbeiten von Inhalten,
- als Brainstorming-Plattform,
- als Ergänzung oder Alternative zum Intranet,
- im Bereich E-Learning und Weiterbildung (z. B. um Material aus Seminaren abzulegen, gemeinschaftlich zu verwalten und zu erweitern oder Diskussionen anzuregen),
- als Unterstützung im Projektmanagement (Datenbank, Zeitplanung, Besprechungen) oder der Abteilungszusammenarbeit

eingesetzt werden.

Weblogs unterstützen kommunikative Prozesse, gleichzeitig können sie genutzt werden, um Informationen abrufbereit zu halten. Blogs können von Mitarbeitern als Notizsammlung verwendet werden, um Ideen oder offene Fragen festzuhalten, die eigene Arbeit zu dokumentieren oder Problemlösungen aufzunehmen. Weblogs können darüber hinaus die Projektarbeit unterstützen, genau wie sich Chancen zur Verbesserung der Kommunikation zwischen und innerhalb von Abteilungen ergeben. Sie eignen sich ferner als Kommunikationsmedium für die Versorgung von Mitarbeitern, Kunden und Partnern mit Informationen. Dabei sind durch die Kommentarfunktionen immer Rückkoppelungsoptionen gegeben.

Social Sharing und Tagging: Tagging ermöglicht das gemeinschaftliche Indexieren von Inhalten und erlaubt so eine Form des sozialen Navigierens und der Orientierung in der Informationslandschaft. Das Tagging kann prinzipiell in vielen Anwendungen wie in Wikis oder Weblogs zum Einsatz kommen; in Social Bookmarking- oder allgemeiner gefasst, in Social Sharing-Anwendungen (z. B. auch für Medien wie Bilder, Videos oder Präsentationen) ist das Tagging neben der zur Verfügung Stellung von Daten eine der wesentlichen Funktionen.

Social Awareness-Tools

- Instant Messengers sind seit Jahren in Unternehmen im Einsatz; bei verteilt arbeitenden Teams bieten sie schnelle und unkomplizierte Möglichkeiten des Informationsaustausches.
- Micro-Blogging-Dienste (kommerzielles Beispiel: Twitter) ermöglichen das Veröffentlichen von kurzen Inhalten wie Status-Updates oder Berichten auf Micro-Sites. Da sie auch von unterwegs per Mobiltelefon aktualisiert werden können, bieten sie sich insbesondere für sehr zeitnah benötigte Informationen an (um z. B. ein verteilt arbeitendes Projektteam auf dem aktuellen Stand zu halten).

Social Networking-Software kann innerbetrieblich genutzt werden um gerade in großen Unternehmen Kompetenznetzwerke zu bilden. Hingegen können die im World Wide Web verfügbaren Plattformen wie beispielsweise XING im Bereich des Personalmanagements für die Rekrutierung von neuen Mitarbeitern dienen.

Mit **RSS-Feeds** können Inhalte von Websites abonniert werden, so dass diese automatisch bei Änderungen oder Neuigkeiten geladen werden. Wenn Blogs oder Wikis genutzt werden, ist der Einsatz von RSS nur folgerichtig: die Anwender können sich Informationen individuell zusammenstellen und behalten auch bei einer Vielzahl an Quellen den Überblick. Die Nutzung von RSS-Feeds stellt gerade bei einer $n:m$ -Kommunikation (z. B. in Projekt-Blogs oder -Wikis) eine effizienter zu nutzende Alternative zu E-Mails dar. Zudem gewinnt diese Technologie an Bedeutung, weil sehr viele Web 2.0-Anwendungen wie Wikis, Weblogs oder auch andere externe Dienste sie unterstützen. Sie dienen somit als Mittel gegen die Informationsüberflutung und unterstützen die individuelle Informationsverteilung.

Erfolgsfaktoren

Damit Social Software von den Mitarbeitern in Unternehmen genutzt wird, reicht es keinesfalls, diese wie klassische Office-Produkte lediglich zur Verfügung zu stellen und davon auszugehen, dass sie sofort angenommen werden und sich die erhofften Vorteile wie effektiveres und effizienteres Arbeiten einstellen. Für den Einsatz von Social Software haben sich diverse Erfolgsfaktoren bewährt, welche zum einen auf den Menschen als Nutzer, zum anderen auf die Gestaltung der Software abzielen:

Zuerst ist entscheidend, dass das Top-Management die Social Software-Initiative voll und ganz unterstützt. Führungskräfte sollten die Software

ebenfalls nutzen und so mit gutem Beispiel vorangehen. Überaus bedeutend ist die Rolle von Mitarbeitern, die von Social Software bzw. von der eingesetzten Social Software-Lösung begeistert sind – sie können das Thema als Multiplikatoren bei anderen Mitarbeitern propagieren und diese mitreißen. Ausschlaggebend ist, dass den Mitarbeitern der Nutzen deutlich wird, der sich aus dem Einsatz ergibt, und sie an die Techniken und die Philosophie von Social Software herangeführt werden. Die Aktivitäten sollten begleitet werden von internen Marketing-Maßnahmen, d. h. im Vorfeld der Einführung sollte mit den Mitteln der Unternehmenskommunikation (Mitarbeiter-Zeitschriften, Newslettern, Vorträgen) über die Maßnahmen informiert und auf den Einsatz vorbereitet werden; auch während des laufenden Betriebes sollten Erfolgsbeispiele publiziert werden, um auch bisher eher passive Mitarbeiter von dem Konzept zu überzeugen. Die Mitarbeiter müssen motiviert und von dem Nutzen überzeugt werden, andernfalls besteht die Gefahr, dass die Anwendungen ignoriert werden. Schon zu Beginn müssen die Anwendungen in den täglichen Arbeitsalltag eingegliedert werden und nach Möglichkeit in die Arbeitsprozesse eingebaut werden.

Daher ist es wichtig im Vorfeld zu definieren, welche Prozesse unterstützt werden sollen um genau jene Software auszuwählen, die die erforderlichen Bedürfnisse abdeckt. Des Weiteren sollte Wert auf die Usability, also die Gebrauchstauglichkeit der Software gelegt werden – so ist nicht zu unterschätzen, wie wichtig für einige Benutzer beispielsweise bei Wikis ein WYSIWYG-Editor ist, im Gegensatz zu einem Editor mit zwar spezieller, aber leicht zu lernender Wiki-Syntax². Speziell bei Wikis sollte initial eine durchdachte Informationsarchitektur vorhanden sein. Ein für einen bestimmten Bereich des Wiki verantwortlicher Moderator kann dafür sorgen, dass sinnvolle Strukturen eingehalten werden und ein gewisses Maß an „Ordnung“ bestehen bleibt. Für alle Systeme ist es wichtig, dass Informationen schnell gefunden werden. Tagging- und Bewertungs-Funktionalitäten können dieses ebenso unterstützen wie eine performant arbeitende Suche mit nützlichen Filterfunktionen. Wenn mehrere Systeme genutzt werden, sollten diese integriert angeboten werden, etwa in Form einer Metaplatform ansteuerbar sein, so dass beispielsweise alle Wikis, Weblogs und weitere Quellen durchsucht werden können. Vor der Nutzung sind je nach technischem Stand der Mitarbeiter Kurz-Schulungen in die Systeme sinnvoll; zwingend ist auch eine ständige Support-Möglichkeit für die Mitarbeiter, etwa in Form einer Telefon-Hotline mit kompetenten Ansprechpartnern.

² Vergleiche bspw. die Syntax des Standard-Editors der Wikipedia <http://de.wikipedia.org/wiki/Hilfe:Textgestaltung>, zuletzt abgerufen am 19.07.07, mit einem WYSIWYG-Editor wie Microsoft Word.

Perspektiven

Für die Zukunft ist mit einer weiteren Durchdringung von Social Software und Web 2.0-Technologien in Unternehmen zu rechnen. Spätestens seitdem es Social Software auch als Kaufsoftware von Größen wie IBM, Oracle oder Intel³ gibt, deren Professionalisierungsgrad mitunter weit von den leichtgewichtigen Open-Source-Anwendungen für Privatanwender im Web entfernt ist (und überdies die Vorbehalte von vielen Chief Information Officers gegenüber Open-Source-Lösungen nicht unerheblich sind), kann davon ausgegangen werden, dass mehr und mehr Unternehmen sie zukünftig einsetzen. Analysten der Gartner Group prophezeien, dass in naher Zukunft die Mehrheit der großen Unternehmen Web 2.0-Technologien einsetzen werden, warnen aber davor, die nicht-technische, soziale Komponente zu vernachlässigen [7].

In vielen Unternehmen wird durch Social Software möglicherweise auch ein kultureller Wandel eintreten: Durch ein entscheidendes Prinzip von Social Software, der Sichtbarkeit, sind nicht nur die Beziehungen der Beteiligten oftmals erkennbar, auch Informationen aller Art, Ideen, Verbesserungsvorschläge, Kommentare, Lob und Kritik sind für alle Nutzer – je nach Einsatzbereich interne Mitarbeiter, externe Geschäftspartner oder Kunden – offenkundig. Dies erfordert ein Umdenken, weil es bisherige hierarchische Grenzen aufweichen kann und Geschäftsprozesse transparenter werden. Entscheidend für den Erfolg von Web 2.0-Technologien in Unternehmen ist letztlich auch, inwiefern Menschen lernen mit dem neuen Web 2.0 privat umzugehen, also inwiefern sich die jetzt für viele noch neuen Technologien komplett in den Alltag integriert haben werden.

Entwicklungsperspektiven des Web 2.0

Nach dem Spezialfall von Social Software im Unternehmenseinsatz werden nun die Perspektiven und zukünftigen Entwicklungen des Web 2.0 auf der Grundlage dessen jetziger Charakteristika diskutiert.⁴ Sicherlich nicht immer trennscharf wird dabei zwischen technischen, wirtschaftlichen und sozialen Entwicklungen unterschieden.

³ Siehe IBM Lotus Connections, Oracle WebCenter Suite und Intel SuiteTwo

⁴ Social Software wird als ein Teil des Web 2.0 verstanden. Für eine ausführliche Diskussion der Charakteristika des Web 2.0 siehe beispielsweise [16].

Technische Entwicklungen

Bei den technischen Entwicklungen, die das Web 2.0 beeinflussen, sei zuerst die absehbare technische Konvergenz von Endgeräten erwähnt. Zukünftig wird man überall und mit vielen verschiedenen Geräten Dienste des Internets nutzen können. Dies kann mit mobilen Geräten wie Mobiltelefonen, Organizern, MP3-Playern, Handheld-Konsolen und Kameras geschehen oder Geräten aus dem Umfeld des Home Entertainment wie Set-Top-Boxen, Spielekonsolen oder Fernsehern. Gerade die mobilen, internetfähigen Geräte ermöglichen eine bedeutende Erweiterung der bisherigen Web 2.0-Anwendungen. Neben speziellen mobilen Versionen (den mobilen Verlängerungen) von etablierten Web 2.0-Angeboten wie Facebook und YouTube, die von ihrer hohen Mitgliederzahl profitieren, wird eine neue, mobile Generation von Social Software geschaffen:

Moblogs: Fotos, Videos, Texte, die unterwegs erstellt werden, können direkt von dem mobilen Gerät in dem Blog publiziert werden. Dies ist zwar bereits per SMS möglich, aber eine kostenlose Nutzung per Web-Zugriff wird die Nutzung sicherlich erhöhen.

Micro-Blogging-Dienste erlauben ebenso das Publizieren von Inhalten auf Microsites.

Mobile Social Software, die ihren Zusatznutzen dadurch erzielt, dass die geographische Position des benutzten Endgerätes entweder durch einen Dienst des Mobilfunkbetreibers oder durch ein satellitengestütztes Positionsbestimmungssystem wie GPS bestimmt wird:

- Mobile Social Networks arbeiten mit Location-Awareness, d. h. man kann sehen, ob sich ein Bekannter in seiner unmittelbaren Nähe aufhält, und sodann per Instant Messaging Kontakt mit diesem aufnehmen. Ein anderes Prinzip kann als erweiterte Form des Geotagging verstanden werden. Dabei können Orte mit einer Art virtueller Notiz versehen werden, die andere Nutzer (ggf. nicht nur Bekannte) sehen können, wenn sie sich an diesem Ort aufhalten. Zu den mobilen Social Networking-Sites zählen bspw. Sociallight oder Dodgeball.⁵
- Micro-Blogging-Dienste, die ihre Shoutbox-Funktion z. B. mit Google Maps verbinden. Als Perspektive ist hier eine Art „Echtzeit-Bürgerjournalismus“ denkbar.
- Durch die Kombination eines Ortungssystems wie GPS und einem mobilen Web-Zugang können Kameras oder mit Kameras ausgestattete

⁵ <http://sociallight.com> bzw. <http://www.dodgeball.com>

Mobiltelefone ortsbezogene Daten wie die aktuelle Ortsposition oder die vorher besuchten Orte direkt in den aufgenommenen Bildern speichern. Diese Bilder wiederum können direkt von unterwegs an eine Foto-Community wie Flickr übertragen werden (und dort auf einer Landkarte via Google Maps dargestellt werden).

Für die Akzeptanz dieser mobilen Anwendungen ist zum einen die Durchsetzung von Breitband-Mobilanschlüssen nach einem für den Verbraucher bezahlbaren und transparenten Preissystem notwendig. Außerdem ist die Benutzbarkeit der mobilen Geräte gefordert: die Benutzerschnittstellen müssen unkompliziert zu bedienen sein, der Zugriff sollte ähnlich schnell und komfortabel möglich sein, wie man es von stationären Anwendungen gewohnt ist. Möglicherweise wird eine verbesserte Spracherkennung in den kommenden Jahren dieses Ziel unterstützen.⁶

Bereits jetzt ist charakteristisch für das Web 2.0, dass Anwendungen nicht mehr auf dem PC, sondern stattdessen überall verfügbare alternative Web-Anwendungen genutzt werden, verbunden mit der Speicherung von vielen persönlichen Daten und Dateien wie Fotos im Netz. Diese Entwicklung „vom Desktop zum Webtop“ findet ihren Ausdruck in Anwendungen wie Google Calendar oder Google Docs & Spreadsheet, in Online-Graphik-Programmen oder in Anbietern, die digitalen Speicherplatz in Form einer virtuellen Festplatte (oftmals kostenlos im Gigabyte-Bereich) anbieten. Technisch werden diese Anwendungen ermöglicht durch den Einsatz von AJAX oder Flash. Es wird sich zeigen, ob Anbieter irgendwann komplett dazu übergehen werden, Anwendungen nur noch web-basiert anzubieten, da das Internet als Infrastruktur immer und überall vorhanden ist und wir infolgedessen sogar ein Web-Betriebssystem nutzen werden. Obwohl wir heute noch viele Desktop-Anwendungen nutzen, geht der Trend bisher also ganz eindeutig davon weg, gerade bei der Vielzahl an neu entstehenden Websites und damit verbundenen Webanwendungen.

Aus diesen Entwicklungen ergibt sich die Notwendigkeit für ein Online-Identitätsmanagementkonzept. Die Anzahl an Websites, die eine Anmeldung erfordern, die somit einen Teil der personenbezogenen Daten verlangen, wächst von Tag zu Tag, somit auch die Anzahl an pro Benutzer vorhandenen Benutzernamen und zu verwaltenden Passwörtern. Ein Single-Sign-On-Service, ein Identitätsprovider, bei dem man sich einmalig anmeldet und über diesen seine Identität(en) verwaltet und sich pro Website damit identifizieren kann, scheint hier die Lösung zu sein. Dick Hardt hat den Begriff Identity 2.0 geprägt und verbindet damit einen Ansatz, sich mit einer Online-Identität bei Websites wie mit einem Führerschein ausweisen zu können [9]. Derzeit verwalten Anbieter wie Google, Amazon

⁶ Vergleiche zum Thema Spracherkennung [10].

oder Yahoo für ihr jeweiliges System die Identitäten der Nutzer; allerdings handelt es sich dabei um Identitäts-Silos: Identitäten oder Teile davon können nicht in andere Systeme übernommen oder sogar kombiniert werden. Ein Identity 2.0-Ansatz stellt wie das Web 2.0 den User in den Mittelpunkt und lässt den Benutzer seine Identität selbst bzw. über einen Identitätsprovider, den man sich wie einen heutigen E-Mail-Provider vorstellen kann, verwalten. Die vier derzeit konkurrierenden Systeme sind OpenID, Microsoft Windows CardSpace, SAML und Liberty Alliance Specifications, wobei die beiden erstgenannten zurzeit die aussichtsreichsten Kandidaten für eine Erreichung der kritischen Nutzermasse sind (und sogar eine Zusammenarbeit vorantreiben) [1]. Als Mengenbeispiel sei hier OpenID angeführt: Derzeit gibt es 120 Millionen OpenID-Inhaber (inklusive aller AOL-Nutzer) und ungefähr 4.500 Websites haben den OpenID-Standard implementiert [12]. Das Thema Identity 2.0 wird sich weiterentwickeln und etablieren: spätestens mit der Einbindung von Identity 2.0-Standards in viele populäre Websites sowie einem gleichzeitigen Aufkommen von Identitätsprovidern wird das Thema einer breiten Masse im Web 2.0 zugänglich werden.

Wirtschaftliche und organisationale Entwicklungen

Es wurde bereits dargelegt, dass Social Software im betrieblichen Alltag mehr und mehr an Bedeutung gewinnt. Doch das Web 2.0 besteht aus mehr als nur Social Software. Das Web 2.0 und dessen Infrastruktur bieten als Ganzes betrachtet viele Möglichkeiten für Unternehmensaktivitäten. Die Kollaborationskosten können drastisch gesenkt werden. Als Konsequenz und um dem immer stärker werdenden Konkurrenzdruck in einer zunehmend globalisierten Welt standzuhalten, um nach wie vor effektiv und effizient Innovationen hervorbringen zu können, werden Unternehmen und Organisationen sich zunehmend öffnen um mit anderen Unternehmen, Lieferanten oder Kunden zu kooperieren; die kollektive Intelligenz von vielen Parteien wird dabei ausgenutzt. In der oben angesprochenen Studie zur Web 2.0-Nutzung in Unternehmen geben 48% der Befragten an, kollektive Intelligenz derzeit zu nutzen oder dieses zu planen [13]. Wie kollektive Intelligenz über das Web genutzt werden kann, sei an einigen Beispielen von Organisationen angeführt:

- Eine Reihe von Unternehmen versucht schon seit längerem über das Web mit dem Kunden zusammenzuarbeiten. Unternehmen wie Adobe oder die Kelterei Walther („Saftblog“)⁷ nutzen Weblogs, um die Kunden

⁷ <http://www.saftblog.de>

zu informieren und in einen Dialog mit ihnen zu treten. Die Kunden wiederum loben, entdecken Probleme und äußern Änderungsbedürfnisse. Letztlich werden die Produkte und Prozesse dadurch besser, entsprechen mehr den Wünschen der Kunden und die Unternehmen gewinnen durch die transparente Vorgehensweise an Vertrauen bei den Kunden.

- Proctor & Gamble ist ein Unternehmen, welches vor einigen Jahren dazu übergegangen ist, Innovationen aus dem Bereich Forschung und Entwicklung zu einem großen Teil über Online-Netzwerke wie beispielsweise Yet2.com oder das InnoCentive Network abzuwickeln.⁸ Auf der InnoCentive Plattform können Unternehmen eine Aufgabe stellen, die von den mehr als 70.000 registrierten Wissenschaftlern (z. B. Selbstständige, Hobby-Wissenschaftler, Pensionäre) bearbeitet werden. Im Erfolgsfall bekommen die Wissenschaftler eine Prämie [11].
- Encyclopedia of Life ist ein Projekt, welches von einem Verbund aus mehreren renommierten Museen und Forschungseinrichtungen gegründet wurde. Es hat sich das Ziel gesetzt bis 2010 alle 1,8 Millionen Spezies der Welt zu erfassen und zu katalogisieren, um das gesammelte Wissen schließlich allen Menschen auf einer Website zur Verfügung stellen zu können. Anders als bei der Wikipedia handelt es sich um ein geschlossenes System, bei der nur Experten etwas beitragen können um den Anspruch der Wissenschaftlichkeit zu gewährleisten [5].

Genau wie klassische Unternehmen sich öffnen werden um zusammenzuarbeiten, werden Anbieter ihre Web 2.0-Websites zunehmend öffnen und ihre Services in Form von APIs zur Nutzung in anderen Anwendungen anbieten oder die Dienste anderer Anbieter auf die eigene Seite einbinden, also sogenannte Mashups ermöglichen. Dies stellt ebenso eine Option für die klassischen Unternehmen dar: sie können ihre Anwendungen mit öffentlich verfügbaren oder von kooperierenden Unternehmen angebotenen Web Services verknüpfen um neue Einsatzmöglichkeiten zu entwickeln. Einen anderen Weg, Dienste auf der eigenen Website zu integrieren, geht das nach MySpace derzeit populärste Social Network Facebook. Externe Anbieter können eigene Applikationen entwickeln und erlauben den Nutzern diese selbst in die Menüs und Seitenelemente von Facebook einzubinden. Mittlerweile⁹ gibt es über 2.000 Anwendungen für Facebook (zumeist aus dem Web 2.0-Umfeld). Wenn Social Networking-Sites wie Facebook sich öffnen, können sie somit bestehende Communities verbinden. Werden die Dienste anderer Anbieter in den eigenen sozialen Rahmen eingebunden, profitieren die externen Anbieter von der Größe des bereits bestehenden Netzwerkes und den viralen Marketing-Effekten, durch die

⁸ <http://www.yet2.com> bzw. <http://de.innocentive.com/>

⁹ Stand August 2007

sich neue Anwendungen schnell verbreiten können. Gleichzeitig erhöht sich die Attraktivität der Networking-Sites durch die vielen neuen Möglichkeiten.

Der Long Tail wird als besonders prägender Bestandteil des Web 2.0 erachtet, sowohl in kultureller als auch in wirtschaftlicher Sicht. Da der Einfluss dieses Modells nicht von kurzfristiger Dauer ist, sondern sich seine Auswirkungen vielmehr noch verstärken werden, sei darauf eingegangen. Chris Anderson beschreibt in dieser Theorie, dass nicht nur mit Bestseller-Artikeln ein hoher Umsatz erreicht werden kann, sondern auch mit Nischenprodukten. Es geht dabei um die Haupteckenkenntnisse, dass alle Nischen zusammen einen bedeutenden Markt ergeben und Long Tail-Modelle durch neue Vertriebstechiken oder die Digitalisierung der Güter inzwischen ökonomisch durchsetzbar sind. Über Google, Blogs und kollaborative Filter (z. B. bei Amazon) werden die angebotenen Artikel von potentiellen Kunden gefunden und eine entsprechende Nachfrage dafür entwickelt. Wenn diese Filterfunktionen weiter verbessert werden, so dass der Nutzer noch schneller Produkte finden kann, ohne viel recherchieren oder querlesen zu müssen, werden die Effekte des Long Tail weiter zunehmen. Das Web wird viele Branchen transformieren: immer dann, wenn es logistisch möglich ist oder die Güter digitaler Art sind und die Nutzer die Produkte durch intelligente Filter finden, wird man diesen Effekt sehen [2]. Der Long Tail kann auch in Verbindung mit dem Prinzip des Crowd Sourcing auftreten: dabei übernimmt der Kunde einen Großteil der zu erbringenden Leistung selbst. Ein Beispiel hierfür ist der T-Shirt-Anbieter Spreadshirt¹⁰: Kunden können T-Shirts selbst gestalten und von Spreadshirt herstellen lassen; selbst gestaltete Motive wiederum können allen Kunden zur Verfügung gestellt werden, wobei der Ersteller des Motivs an dessen Verkäufen beteiligt wird.

Soziale Entwicklungen

Die Entwicklung des Konsumenten zum Prosumenten kann per definitionem als hervorzuhebender Wesensfaktor des Web 2.0 erachtet werden. Social Software senkt die Barriere etwas zu veröffentlichen – jeder kann Inhalte jeglicher Art einfach ins Netz stellen; die Onlinestellung ist einfach und schnell durchführbar, meist kostenlos oder nur mit geringen Kosten verbunden; die vorherigen Herausgeber wie Verlage, Musiklabels oder Fernsehsender, die als Gatekeeper agierten, wenn man etwas veröffentlichen wollte, entfallen. Doch es kann nicht davon ausgegangen werden, dass von heute auf morgen alle passiven Konsumenten, Menschen, die im

¹⁰ <http://www.spreadshirt.net>

20. Jahrhunderts der passiven Konsumkultur gelebt haben, sich sofort umstellen und Inhalte produzieren werden. Jedes neue Medium braucht eine gewisse Zeit um sich durchzusetzen. Der Medientheoretiker Marshall McLuhan vergleicht das Aufkommen einer neuen Technologie mit der Amputation eines Körperteiles und gleichzeitigen Ersetzung dessen durch eben jene neue technische Komponente; Technik wird als Ausweitung des Menschen begriffen. Der so neu ausgestattete Mensch benötige erst eine gewisse Zeit, bis ein Verhältnis mit den neuen Körperteilen gefunden wird [14].

Die jährlich durchgeführte ARD/ZDF-Online-Studie gibt Aufschlüsse über die Internet- und auch Web 2.0-Nutzung in Deutschland. Demnach hat sich das Internet von einer frühen Phase, in der es nur durch Info-Eliten genutzt wurde, inzwischen „veralltäglicht“, so dass es auch ein Medium für eher internetferne Bevölkerungsgruppen geworden ist. Das vielfach zitierte Mitmach-Web wird hingegen relativiert: zwar hat sich die Nutzung von Web 2.0-Angeboten wie der Wikipedia, YouTube oder Weblogs in den letzten Jahren stark erhöht, aber die Zahl derer, die aktiv Inhalte ändern oder erstellen, ist im Vergleich eher gering. Schon jetzt wird aber deutlich, dass die Jüngeren die Möglichkeiten des Internets wesentlich intensiver nutzen [23, 8].

So wird auch die Art und Weise, wie Menschen mit dem neuen Web künftig umgehen werden, dessen Zukunft prägen. Die Generation der jetzt 16- bis 27-Jährigen, die „Digital Natives“ oder auch Generation Millennial genannt wird, kennt die neuen I- und K-Technologien seit frühester Kindheit. Deren Vertreter können sich an eine Zeit ohne Internet kaum noch erinnern, kommunizieren mit Freunden per Instant Messenger, Mobiltelefon und Social Networks und bedienen sich, anstatt Zeitung zu lesen, Radio zu hören oder linear Fernsehen zu sehen, des gezielten Ansurfens von relevanten News-Sites, hören Podcasts und MP3s auf digitalen MP3-Playern und sehen Videos auf Abruf oder auf digitalen Speichermedien, wann und wo sie möchten. Sie bewegen sich völlig natürlich im Cyberspace, können Informationen aus vielen Quellen besser und schneller verarbeiten und sind offener zu partizipieren, als nur passiv zu konsumieren [17, 6]. Das Web bestimmt diese Generation maßgeblich, ebenso wird diese Generation die Zukunft des Webs maßgeblich bestimmen. Wie schon das Web 1.0 seinen Weg in den Alltag gefunden hat, so wird auch das Web 2.0 zukünftig noch stärker genutzt und mit all seinen Vor- und Nachteilen in das Leben der Nutzer (und nicht nur der jüngeren Generation) verwoben werden; dies lässt desgleichen erahnen, dass es zu einer veränderten, stark selektiven und individualisierten Mediennutzung innerhalb der Gesellschaft kommen wird.

Letztlich geht die Entwicklung also dahin, dass das Web insgesamt weiter wachsen wird und mit ihm die verfügbaren Informationen. Die Frage ist, wie diese Inhalte genutzt werden können und wie es möglich sein wird,

die Qualität der Informationssuche und -auffindbarkeit und nicht zuletzt der Wissensgenerierung zu verbessern. Bisher spielen dabei Filter, die durch menschliche Handlungen ermöglicht werden, eine große Rolle; das heutige Netz basiert in vielen Elementen auf der „Weisheit der Massen“:

- Waren es bei den klassischen Medien Journalisten, die Informationen für die Konsumenten aufbereiten, so übernehmen beispielsweise Blogger dieses für die digitale Welt. Durch den hohen Verlinkungsgrad in der Blogosphäre, bei der von vielen Personen als relevant empfundene Informationen öfter verlinkt und kommentiert werden, sind diese somit besser auffindbar.
- Gemeinschaftliches Tagging etwa in Form von Social Bookmarking sei gleichfalls erwähnt.
- Kollaboratives Filtern, wie es aus dem E-Commerce bekannt ist („Kunden, die diesen Artikel kauften, kauften auch diesen Artikel“) oder auch bei dem Google-Suchalgorithmus benutzt wird (der Algorithmus stuft eine häufiger verlinkte Seite als höherwertiger ein, dadurch steigt sie in der Trefferliste nach oben), stellt eine andere Möglichkeit dar.

Doch alle Möglichkeiten Informationen zu finden, stellen nach wie vor viele Anforderungen an den Nutzer, indem er durch Querlesen und Vergleichen mit den anderen Dokumenten schließlich das richtige Ergebnis, die gesuchte Erkenntnis herausfinden muss. Daran wird deutlich, dass das World Wide Web für die Nutzung durch den Menschen gedacht ist. Der Benutzer versteht die Dokumente; der Computer bisher nicht. Darin liegt der Ansatz des semantischen Webs: es wird eine semantische Ebene über das Web gelegt, so dass der Computer die Bedeutungen versteht:

„The Semantic Web is not a separate Web but an extension of the current one, in which information is given well-defined meaning, better enabling computers and people to work in cooperation.“ [3]

Die von dem W3C¹¹ erarbeitete Vision des Semantic Web basiert auf diversen Technologien und Konzepten, die jeweils unterschiedlich weit entwickelt sind. Sie lassen sich in einem aus mehreren, ineinander verschachtelten Schichten bestehenden Rahmenwerk zusammenfassen: Informationen müssen *eindeutig auffindbar* sein (URI/IRI) und in *Datenbereiche* unterteilt sein (XML). Als *semantischer Baustein* werden beschreibend Metadaten hinzugefügt (RDF, RDFS), wobei um ein tatsächliches Verständnis für bestimmte Anwendungsdomänen zu entwickeln, die damit zusammenhängenden Begriffe und deren Beziehungen untereinander

¹¹ Das World Wide Web Consortium ist ein unabhängiges Gremium, welches sich mit der Standardisierung von Techniken für das WWW befasst.

in *Ontologien* zusammengefasst werden (OWL). Mit *Abfragesprachen* (SPARQL) sowie *Regel-Systemen* (RIF), welche die Voraussetzung bilden automatisch Entscheidungen und Schlussfolgerungen treffen zu können, lassen sich die Inhalte nutzen. Über diesen Technologien stehen eine vereinheitlichende *Logik* sowie *Sicherheitskonzepte*, die die Vertrauenswürdigkeit der Inhalte gewährleisten. Schließlich müssen auf der *Darstellungsebene* die Anwendungen und Benutzerschnittstellen in der Lage sein jene Technologien sinnvoll zu nutzen [24, 19]. Mit dem Semantic Web oder dem Einsatz von semantischen Technologien im Web würde sich somit eine revolutionäre Möglichkeit bieten, Informationen zu filtern und intelligente, gewissermaßen „verstehende“ Anwendungen zu entwerfen.

Darstellung einer Annäherung: Semantic Web und Social Software ergeben das Social Semantic Web

Das Semantic Web wird folglich auf dem bisherigen Web aufbauen und einen evolutionären Schritt darstellen. Dabei gibt es für eine Annäherung des Web 2.0 mit dem Semantic Web zwei Perspektiven: Zum einen kann Social Software um eine semantische Ebene, also Metadaten erweitert werden, so dass verbesserte Such- und Navigationsfunktionen, individuelle Inhaltspräsentation und verbesserte Interoperabilität zwischen unterschiedlichen Systemen die Folge sind. Auf der anderen Seite kann Social Software selbst unterstützend benutzt werden um Metadaten für das semantische Web zu erstellen; die Erstellung von Metadaten ist schwierig, weil Expertenwissen auf dem Domänengebiet benötigt wird, gleichzeitig müssen die Modellierungssprachen (z. B. RDF oder OWL) beherrscht werden. Social Software kann hier die Koordination, Kommunikation und Kollaboration zwischen Domänenexperten und Ontologie-Experten für die damit verbundenen Prozesse unterstützen [18].

Doch während das semantische Web in der Form, wie es das W3C sieht, noch eine Vision darstellt, kann heute schon mit darauf aufbauenden semantischen Technologien das Web 2.0 bereichert werden. Dies sei an einigen Beispielen gezeigt:

Mikroformate erweitern HTML um semantische Annotationen. Es existieren z. B. Mikroformate, welche Kontaktdaten, Kalenderereignisse als solche kennzeichnen oder Hyperlinks (steht der Inhaber der Website dem Verweisziel zustimmend oder ablehnend gegenüber, Bedeutung des Verweisziels im Sinne von Tags, etc.) näher beschreiben.¹² Diese Informatio-

¹² Siehe <http://www.microformats.org>

nen können beispielsweise von anderen Anwendungen wie Suchmaschinen leicht herausgefiltert werden und in Terminkalender oder Adressbuch übernommen werden.

Semantische Wikis sind um semantische Technologien erweiterte Wikis.¹³ Einer der bedeutendsten Unterschiede besteht in der Verwendung von annotierten Links. Diese mit Metadaten versehenen Links wiederum sind maschinenlesbar. Aus der Gesamtheit aller Links kann das Wiki wesentlich verbesserte Suchfunktionen oder Navigationen anbieten oder auf den Wiki-Seiten selbst zusätzliche Informationen anzeigen, die sich aus den semantischen Verknüpfungen ergeben. Bereits einsatzfähige Semantic Wiki-Systeme existieren schon heute und werden weiterentwickelt.¹⁴

Mit **semantischen Weblogs** wird es ermöglicht Informationen einfacher miteinander zu verbinden und diese abzufragen.¹⁵ Das Prinzip ist dabei ähnlich wie bei semantischen Wikis, auch hier werden Links annotiert.

Weiterhin entstehen auf kommerzieller Seite die ersten Produkte, die sich semantischer Technologien bedienen. Zwei viel versprechende Anwendungen sind Freebase von Metaweb und Twine von Radar Networks:

Freebase¹⁶ ist eine Art semantischer Web-Datenbank, die Daten von vielen unter einer Creative Commons-Lizenz stehenden Projekten wie der Wikipedia oder Musicbrainz¹⁷ übernommen hat und um Metadaten und Ontologien ergänzt hat, so dass prinzipiell alle Daten miteinander verknüpft werden können. Jedes Datenelement ist ein Objekt, dieses wiederum gehört einem oder mehreren Typen an, die bestimmte Eigenschaften haben; Typen sind in Domänen unterteilt. Über die Web-Oberfläche können selbst Daten eingegeben oder Verknüpfungen erstellt werden, sogar neue Typen können erstellt werden. Über eine API lassen sich die Daten auslesen und somit auch anderen Systemen zur Verfügung stellen. Freebase orientiert sich zwar nicht an den Standards des W3C wie RDF, doch laut Aussage von Jamie Taylor arbeitet Metaweb bereits daran, es mit der großen Semantic Web-Vision kompatibel zu machen [22]. Man sieht auch an diesem Produkt die Annäherung von Social Web und Semantic Web:

¹³ Siehe dazu auch den Beitrag von Schaffert in diesem Band.

¹⁴ Siehe http://wiki.ontoworld.org/inde.php/Semantic_Wiki_State_Of_The_Art

¹⁵ Siehe dazu auch den Beitrag von Vrandecic/Kroetzsch in diesem Band.

¹⁶ Siehe <http://www.freebase.com>, im März 2007 ist es in eine halböffentliche Beta-Phase getreten

¹⁷ <http://musicbrainz.org/>

Freebase basiert auf User-Generated-Content und sowohl die Inhalte als auch die semantischen Strukturen werden durch die Nutzer erweitert.

Radar Networks ist ein anderes Unternehmen, welches eine vielversprechende semantische Web-Anwendung namens **Twine** entwickelt.¹⁸ Es handelt sich um eine Art persönlichen Data Organizer. „It will allow you to bring in e-mail, contacts, photos, video, music – anything digital, really – from anywhere on the Web, turn it into RDF, and access it in one place.“ [4] So kann ein persönliches semantisches Web für ein Projekt, eine Gruppe oder eine Einzelperson selbst gestaltet werden, welches mit allen Daten aus der Radar Network-Datenbank verknüpft werden kann.

Vielleicht benötigt es solche Anwendungen wie jene von Metaweb oder Radar Networks erstellten, die bereits über einen großen Pool an Daten und Metadaten verfügen, so dass man der Webgemeinde demonstrieren kann, wie mächtig solche Anwendungen sind, damit sich Schritt für Schritt semantische Technologien weiter durchsetzen werden bis letztlich die große Vision des Semantic Webs erreicht ist.

Nova Spivack, Gründer und CEO von Radar Networks schlägt vor, die begonnene Indexierung mit Web x.0 fortzusetzen und somit die Dekaden des Webs zu beschreiben. Während bei dem Web 1.0 der Fokus eher auf das Back-End orientiert war wie HTML und http, geht es bei dem Web 2.0 um das Front-End mit dem Schwerpunkt auf Usability, AJAX, Tagging, etc. Das Web 3.0 sieht er wieder als eine Erweiterung des Back-Ends (RDF, etc.), während das Web 4.0 ein intelligenteres, proaktives und produktives Web mit intelligenten Anwendungen bietet (Front-End-bezogen) [21]. Die Abbildung veranschaulicht seine Einschätzung der zukünftigen Entwicklung des Semantic Webs.

Wie schnell sich das Semantic Web bzw. das Social Semantic Web durchsetzen wird, kann letztlich nicht beantwortet werden. Es ist offensichtlich, dass es einen enormen Aufwand bedeuten wird (sobald die Technologien „markttauglich“ sind), all die im World Wide Web vorhandenen Daten mit Metadaten zu versehen und dafür entsprechende Ontologien zu entwickeln. Einen enormen Auftrieb wird das semantische Web bekommen, sobald Plattformen wie z. B. das bereits erwähnte Freebase mit riesigen Datenmengen entstehen oder wenn die bisherigen großen Schlüsselunternehmen wie Amazon, Google oder Projekte wie die Wikipedia anfangen, aufbauend auf ihrem enormen Datenpool, semantische Technologien einzusetzen.

¹⁸ <http://www.radarnetworks.com> bzw. <http://www.twine.com>, im September 2006 befand sich das Projekt noch in einer geschlossenen Alpha-Phase, lediglich Einzelheiten waren bekannt.




Abb. 1. Technologietzeitstrahl von der PC Ära zum Web 4.0. [20]

Die Menschen müssen eine Notwendigkeit erkennen die semantischen Technologien zu nutzen. Solange sie mit der Art und Weise, wie das Web jetzt funktioniert, mit Google und Folksonomies, zufrieden sind, wird wahrscheinlich keine große Veränderung eintreten. Möglicherweise werden die ersten Erfolge dieses Mal eher im institutionellen Umfeld als im privaten Bereich zu finden sein. Firmen wie Kodak oder Eli Lilly, die mit semantischen Technologien experimentieren [4], Metawebs Freebase-Ansatz als Variante im betrieblichen Einsatz oder Institutionen, die semantische Wikis und Weblogs als Alternative zu den „normalen“ Social Software-Pendants einsetzen, könnten die ersten Anzeichen eines Corporate Semantic Web-Aufkommens darstellen. Klar ist, dass der semantische Faktor vieles möglich machen wird, was vor einigen Jahren noch wie kühne Utopien anmuten musste. Das bevorstehende intelligente Web wird sich massiv von dem bisherigen Internet unterscheiden. Bei dem derzeit vorliegenden World Wide Web handelt es sich um ein Docuverse¹⁹, ein Universum aus miteinander verbundenen Dokumenten, welches durch Hypertext, also den Links geformt wird und seit der Web 2.0-Ära zusätzlich auf sozialen Netzwerken aufbaut. Das semantische Web wird hingegen durch die zusätzliche semantische Ebene zu einem „Knowledgeverse“ werden – einem Universum des Wissens, welches mit eigenen Regeln und Struktu-

¹⁹ Der Begriff wurde von Ted Nelson geprägt, vgl. [15].

ren versehen ist und das es tatsächlich ermöglicht, Wissen einfach zu finden, zu erweitern und durch Kombination neu zu erschaffen.

Literatur

1. Ammirati, S. (2007). Overview of the Identity Landscape. In: Read/WriteWeb, http://www.readwriteweb.com/archives/overview_identity_landscape.php, zuletzt aufgerufen am 30.08.2007
2. Anderson, C. (2007). The Long Tail. Der lange Schwanz. Carl Hanser Verlag, München.
3. Berners-Lee, T.; Hendler, J.; Lassila, O. (2001). The Semantic Web. A new form of Web content that is meaningful to computers will unleash a revolution of new possibilities. In: Scientific American, May 2001. Online verfügbar: <http://www.sciam.com/article.cfm?articleID=00048144-10D2-1C70-84A9809EC588EF21>, zuletzt aufgerufen am 21.08.2007
4. Copeland, M. V. (2007). Web 3.0. No humans required. In: http://money.cnn.com/magazines/business2/business2_archive/2007/07/01/100117068/index.htm, zuletzt abgerufen am 21.08.2007
5. Encyclopedia of Life (2007). Pressemitteilung: A Leap for All Life: World's Leading Scientists Announce Creation of „Encyclopedia of Life“. In: http://www.eol.org/press_release.html, zuletzt aufgerufen am 19.07.2007
6. Forrester Consulting (2007): Is Europe Ready For The Millenials? InnovateTo Meet The Needs Of The Emerging Generation.
7. Gartner (2006). Gartner Says Web 2.0 Offers Many Opportunities for Growth, But Few Enterprises Will Immediately Adopt All Aspects Necessary for Significant Business Impact. In: <http://www.gartner.com/it/page.jsp?id=492461>, zuletzt abgerufen am 19.07.2007
8. Gscheidle, C.; Fisch, M. (2007). Online 2007: Das „Mitmach-Netz“ im Breitbandzeitalter. In: Media Perspektiven 8/2007
9. Hardt, D. (2005). OSCON 2005 Keynote – Identity 2.0. In: <http://identity20.com/media/OSCON2005/>, zuletzt aufgerufen am 19.08.2007
10. Heidmann, F. (2007). Mensch-Computer-Kooperation. In: Bullinger, Hans-Jörg: Technologieführer. Grundlagen-Anwendungen-Trends. Springer-Verlag Berlin Heidelberg 2007.
11. Huston, L; Sakkab, N. (2006). Connect and Develop: Inside Procter & Gamble's New Model for Innovation. In: Harvard Business Review, Vol. 84, No. 3, March 2006
12. Kveton, S. (2007). The State of OpenID. In: <http://openid.net/pres/openid-solt-final.pdf>, zuletzt abgerufen am 20.07.2007
13. McKinsey (2007). How businesses are using Web 2.0: A McKinsey Global Survey. In: The McKinsey Quarterly
14. McLuhan, Marshall (1992). Die magischen Kanäle. „Understanding Media“, Düsseldorf, Wien 1968 und 1992. Seite 62
15. Nelson, T. H. (1992). Literary machines. Mindful Press, Sausalito, CA.

16. O'Reilly, T. (2005): What Is Web 2.0. Design Patterns and Business Models for the Next Generation of Software. In: <http://www.oreillynet.com/pub/a/oreilly/tim/news/2005/09/30/what-is-web-20.html>, zuletzt abgerufen am 20.07.2007
17. Prensky, M. (2001). Digital Natives, Digital Immigrants. In: One The Horizon. NCB University Press, Vol. 9 No. 5, October 2001.
18. Schaffert, S. (2006). Semantic Social Software: Semantically Enabled Social Software or Socially Enabled Semantic Web? In: http://www.schaffert.eu/download/paper/Schaffert2006_SemanticSocialSoftware.pdf, zuletzt aufgerufen am 21.08.2007
19. Shadbolt, N.; Berners-Lee, T.; Hall, W. (2006). The Semantic Web Revisited. In: IEEE Intelligent Systems 21(3) Seiten 96–101, May/June 2006
20. Spivack, N. (2007). How the WebOS Evolves? In: Minding the Planet. http://novaspivack.typepad.com/nova_spivacks_weblog/2007/02/steps_toward_s_a.html, zuletzt aufgerufen am 21.08.2007
21. Spivack, N. (2007): Web 3.0 will combine the Semantic Web with social media, enabling a new generation of richer, more shareable, mashable content. In: <http://www.semantic-web.at/10.36.175.article.nova-spivack-web-3-0-will-combine-the-semantic-web-with-social-media-enabling-a-new-genera.htm>, zuletzt abgerufen am 20.08.2007
22. Talking with Talis (2007). Jamie Taylor Talks with Talis about Metaweb and Freebase. In: <http://talk.talis.com/> bzw. http://talis-podcasts.s3.amazonaws.com/twt20070525-Jamie_Taylor.mp3, zuletzt aufgerufen am 19.08.2007
23. Van Eimeren, B.; Frees, B. (2007). Internet-Nutzung zwischen Pragmatismus und YouTube-Euphorie. In: Media Perspektiven 8/2007
24. W3C (2007). Semantic Web „layercake“ diagram. In: <http://www.w3.org/2007/03/layerCake.png>, zuletzt abgerufen am 04.09.2007
25. Zerfaß, A.; Boelter, D. (2005). Die neuen Meinungsmacher: Weblogs als Herausforderung für Kampagnen, Marketing, PR und Medien. Nausner & Nausner, Graz.

4. Anwendungen und Technologien des Web 2.0: Ein Überblick

Alexander Stocker¹ und Klaus Tochtermann^{1,2,3}

¹ Know-Center, Graz, Austria;

² Knowledge Management Institute, Graz University of Technology;

³ Institute for Networked Media, Joanneum Research
{astocker; ktocchter}@know-center.at

Zusammenfassung: Das World Wide Web (im Folgenden kurz als Web bezeichnet) verwandelt sich seit einigen Jahren von einem Medium der passiven Konsumenten von Inhalten hin zu einem Netz für aktive User, die Weblogs schreiben, in Foren diskutieren oder Podcasts veröffentlichen. Diese User der zweiten Generation gebrauchen das Web zum Gedankenaustausch und knüpfen als Knoten in virtuellen sozialen Netzwerken Beziehungen zu Gleichgesinnten, mit denen sie sich zu virtuellen Communities formieren. Folglich definiert sich die soziale Komponente des Web 2.0 über ein verändertes Verhalten seiner User. Web-2.0-Plattformen sind jedoch vielmehr sozio-technische Artefakte und basieren auf speziellen Anwendungen und Technologien. Erst die technologische Komponente des Web 2.0 ermöglicht, dass die sozialen Prozesse der User unterstützt werden. Der folgende Grundlagenbeitrag stellt wesentliche Anwendungen und Technologien des Web 2.0 vor.

Einleitung

Der Ausdruck Web 2.0 wurde vom Verlagsgründer Tim O'Reilly und Dale Dougherty 2004 geprägt, um den im Web stattfindenden Wandel zu erklären. O'Reilly beschreibt in seinem Aufsatz „What is Web 2.0. Design Patterns and Business Models for the Next Generation of Software“ [19] die Geschäftsperspektive des neuen Web und argumentiert, dass Web 2.0 neue Geschäftsmodelle hervorbringen wird: Lassen sich Unternehmen nämlich darauf ein, ihr Kerngeschäft im Web abzubilden, werden sie feststellen, dass das Web als ein Netzwerk Eigenschaften besitzt, die es zunächst erschweren, Erlöse zu lukrieren. Die Herausforderung für Unternehmen besteht darin, die von ihnen entwickelten Web-2.0-Plattformen gewissermaßen mit einer Logik zu versehen, die sie besser werden lässt, je mehr User sie verwenden.

Obwohl O'Reilly im Bezug auf Web-Applikationen u. a. die Abkehr der aus der klassischen Softwareentwicklung bekannten durch Versionsnummern gekennzeichneten Releases sieht, verwendet er Versionierung bei der Generierung des Terms Web 2.0. Seine Vorgehensweise wurde bereits kurze Zeit später aufgegriffen, um den durch das neue Web resultierenden Wandel auf andere Bereiche zu bezeichnen. Dadurch entstanden zahlreiche, meist wiederum die Geschäftsperspektive betreffende Modeworte wie Enterprise 2.0, Business 2.0, Marketing 2.0, Identity 2.0 oder Web 3.0 [15] – die Kombination des Social Web mit dem Semantic Web. Allen sich hinter diesen Begriffen verbergenden Ideen gemeinsam ist die Tatsache, dass sie eine klare Definition, ein einheitliches Verständnis und eine Abgrenzung von verwandten Konzepten vermissen. Diese Anhäufung von Modeworten vermag beim Leser den Eindruck hervorrufen, Web 2.0 sei bloß ein Hype. Eine gründliche Auseinandersetzung mit den Veränderungen im Web führt jedoch zu einem gegensätzlichen Ergebnis.

Allgegenwärtig zeigt sich, dass sich das Web vom Netz der großen institutionalisierten Produzenten von Web-Inhalten, hin zu einem Web für den gewöhnlichen User mit einer weitaus geringeren Affinität zur Technik bewegt. In der Folge schließen sich User zu völlig neuen Formen von virtuellen Communities [21] zusammen und wandeln sich vom bloßen User zum Produzenten von Inhalten. Sie können aufgrund dieser Eigenschaft, explizit oder implizit Inhalte zu erstellen, auch „prodUser“ genannt werden.¹ Der Futurologe Toffler behauptete bereits 1980, dass sich die Rollen von Konsumenten und Produzenten in absehbarer Zukunft überlagern und dann gänzlich zusammenfallen werden [22] und führte dazu den Begriff „prosumer“ ein. Auch Unternehmen beginnen das Web 2.0 einzusetzen, in der Hoffnung, sich damit einen Wettbewerbsvorteil gegenüber der Konkurrenz zu verschaffen [2].

Im Web 2.0 tritt eine Vielzahl an neuen Wissensstrukturen, hervorgerufen durch die stattfindende Verschmelzung von sozialen und technischen Aspekten, in Erscheinung [12]. Zahlreiche Anwendungen wie Wikis, Blogs oder Podcasts, die sich Web-2.0-Technologien wie Ajax, Folksonomies oder auch Mikroformaten bemächtigen, gelten als Geburtsstätte für diese neuen Wissensstrukturen. Neben der sozialen Komponente des Web 2.0, existiert auch eine technologische Komponente. Auf diese Technologien sowie typische Anwendungen wird im weiteren Verlauf dieses Kapitels eingegangen.

¹ Für eine vertiefende Auseinandersetzung mit dem Konzept der „Prodnutzung“ siehe den Beitrag von Schmidt und Pellegrini in diesem Band.

Anwendungen im Web 2.0

Eine Vielzahl an Web-Anwendungen wie Wikis, Blogs oder PodCasts wird dem Web 2.0 zugezählt. In diesem Abschnitt werden die geläufigsten Anwendungen unter Berücksichtigung der dahinter stehenden Technologien vorgestellt.

Weblogs

Ein Weblog (aus dem englischen „Web“ und „log“, Kurzform „blog“) stellt eine Online-Publikation mit umgekehrt chronologischen Einträgen und einer starken Dialogorientierung dar. Die ersten Blogs traten Mitte der 90er Jahre auf und nahmen die Form von einfachen Online-Tagebüchern an, in denen die Web-User in periodischen Abständen über ihr Leben berichteten. Für den Autor des Blogs, den so genannten Blogger, stellt der Blog ein einfach handhabbares Medium dar, um seine Leser mit das eigene Leben betreffenden Aspekten oder Meinungen zu bestimmten fachspezifischen Themen zu erreichen. Blogs werden zudem gerne von der Leserschaft als eine besonders glaubwürdige interaktive Alternative zu den traditionellen Webportalen und Medien wahrgenommen und zeichnen sich meist durch einen reißerischen, emotionellen Kommunikationsstil aus [23].

Weblog-Publishing-Systeme stellen als technische Basis Content-Management-Systeme zur Verwaltung von Weblogs dar. Kenntnisse im Webdesign sind für den Blogger unter Berücksichtigung der modernen Systeme zumeist nicht mehr notwendig. Eine Vielzahl von unterschiedlichen, teilweise anspruchsvollen Vorlagen (Templates) ermöglicht eine individuelle Gestaltung ohne tief greifende technische Kenntnisse. Bekannte Systeme basieren zumeist auf einer einfachen PHP-Lösung mit einer MySQL Datenbank im Hintergrund. Die stark verbreitete Blog-Software Wordpress² lässt sich beispielsweise sowohl auf einem eigenen Serverrechner installieren, als auch als Dienst³ mittels application service providing (ASP) verwenden. Demgegenüber lässt sich Google Blogger⁴ lediglich als ASP verwenden.

Auf der technischen Seite stellen Blog-Inhalte so genannte „Microcontents“ dar, die über Permalinks – ein Kombinationswort aus „permanent“ und „link“ – von anderen Stellen dauerhaft verlinkt werden können. Ein Permalink bezeichnet einen Uniform Resource Locator (URL), der direkt auf einen spezifischen Blog-Eintrag zeigt, unabhängig davon, an welcher Stelle sich dieser Inhalt im Blog befindet.

² www.wordpress.org

³ www.wordpress.com

⁴ www.blogger.com

Hingegen ermöglicht ein Trackback [20] dem Autor eines Blogs festzustellen, ob ein anderer Blog auf einen seiner Einträge Bezug nimmt. Wird die Trackback-Funktion genutzt, sendet die eigene Web-Site ein Netzwerksignal (Ping) an eine bestimmte URL der Ziel-Website. Die empfangende Website erstellt einen Link zur sendenden Site zurück und definiert damit Beziehung zwischen diesen beiden Seiten. Durch diesen Benachrichtigungsdienst können Weblogs automatisiert Informationen untereinander austauschen.

Durch die Verwendung von Trackbacks entstand auch die Verlinkung der Blogs untereinander zur Blogosphäre, welche die Gesamtheit aller Blogs als ein virtuelles soziales Netzwerk bezeichnet. Diese eben beschriebene spezifische Verlinkung trägt zur Eigendynamik der Blogosphäre bei, aufgrund dieser sich interessante oder brisante Blog-Einträge schneeballartig verbreiten können und durch die Wechselwirkungen zwischen den Medien auch von traditionellen Medien aufgenommen werden können [23].

Während ein Blog den Autor und seine subjektive Sichtweise in den Mittelpunkt stellt, führt bei einem Wiki, eine kollektive Autorenschaft dazu, dass die einzelne Meinung zugunsten der Meinung einer kollektiven Masse verschwindet. Dies bezeichnet O'Reilly im Web als „kollektive Intelligenz“ [19].

Wikis

Als ein Medium, das eine offene Kollaboration ermöglicht, entspricht das Wiki der ursprünglichen Idee des Web-Pioniers Tim Berners-Lee, das Web als Schreib-Lese-Web zu erfahren. Ein Wiki, auch WikiWiki oder Wiki-Web genannt, bezeichnet Webseiten, deren Inhalte von Usern nicht nur gelesen, sondern auch online verändert werden können und mittels Querverweisen (Hyperlinks) miteinander verbunden sind. Der Name Wiki stammt vom hawaiianischen Wort „wikiwiki“, was soviel wie „schnell“ bedeutet.

Wikis ähneln klassischen Content-Management-Systemen, verfügen aber im Gegensatz zu diesen gemäß ihrer Philosophie über keine ausdifferenzierten Benutzerrollen. In einem Wiki sind grundsätzlich alle Inhalte durch den User aufgrund des elementaren Prinzips der Selbstorganisation abänderbar. Um die durch Vandalismus zwangsläufig auftretenden Schäden zu beheben, können jedoch jederzeit unzerstörte Fassungen von betroffenen Seiten schnell und einfach mit Hilfe der integrierten Versionsverwaltung wiederhergestellt werden. Ein Wiki wird aufgrund seiner speziellen Eigenschaften bevorzugt für Tätigkeiten eingesetzt, die im höchsten Maße kollaborativ sind. Beispielsweise sind das gemeinsame Erstellen eines

Dokuments, oder das gemeinsame Planen einer Veranstaltung innerhalb eines Teams oder einer Gruppe geeignete Anwendungsbereiche.

Eine sehr bekannte und weit verbreitete Open-Source Wiki-Software ist MediaWiki⁵, auf der auch die freie Online Enzyklopädie Wikipedia⁶ basiert. Neben der Installationsmöglichkeit auf einem eigenen Serverrechner kann MediaWiki auch als ASP⁷ verwendet werden.

Das erste Wiki-System wurde 1995 von Ward Cunningham entwickelt. Auf der technischen Seite stellt die Wiki-Software einen Typ kollaborativer Software da, die ein Wiki-System betreibt. Für gewöhnlich wird das Wiki als serverseitiges Skript implementiert, welches auf einem oder mehreren Web-Servern läuft. Für das persönliche Wissensmanagement finden allerdings auch clientseitige Wikis, wie beispielsweise das von Jeremy Ruston entwickelte TiddlyWiki⁸ Verwendung. Der von den Usern erstellte Content wird üblicherweise in einer Datenbank gespeichert. Die Wiki-Engine implementiert die eigentliche Wiki-Technologie, während „Wiki-Software“ die gesamte Software bezeichnet, die nötig ist, um ein Wiki zu betreiben, und somit auch andere Komponenten wie beispielsweise den Web-Server beinhaltet. Mittlerweile existieren über 100 unterschiedliche Wiki-Engines [4], meist Open-Source. Allen gemeinsam ist die Tatsache, dass sie ein minimales Set an Wiki-Prinzipien integrieren. Beispielsweise ermöglichen Wikis die einfache Generation von Hyperlinks, wodurch User befähigt werden, die entsprechenden Seiten auf dem Wiki zu besuchen. Wikis weisen zudem eine ähnliche, sehr einfach zu erlernende Formatierungssyntax auf.

Änderungen von Seiten in einem Wiki sind stets nachvollziehbar: Mittels einfachen Wiederherstellens, durchzuführen auf der Seite mit den zuletzt gemachten Änderungen, können dem Vandalismus unterliegende Seiten rasch in ihre ursprüngliche Form zurück gebracht werden. Dabei reicht die Historie an Änderungen teilweise bis zur ersten Version einer Seite zurück. Unterschiede zwischen zwei Versionen eines Artikels können anhand einer speziellen Ansicht, in der diese nach Zeilen geordnet hervorgehoben sind, festgestellt werden.

Podcasts (Videocasts)

Während in Wikis und Blogs der Text im Mittelpunkt steht, fokussieren Podcasts auf das gesprochene Wort, oft in Kombination mit Musik. Im Gegensatz zum Podcasting, das die Produktion und Distribution von Au-

⁵ www.mediawiki.org

⁶ www.wikipedia.com

⁷ www.wikia.com

⁸ www.tiddlywiki.org

dio-Dateien über das Web bezeichnet, werden beim Videocasting ganze Videos übertragen bzw. gestreamt.

Der Host oder Autor eines Podcasts wird Podcaster genannt, wobei der Term Podcast als Kofferwort aus „iPod“ und „broadcast“ gebildet wird. Podcasts stellen Audio-Dateien dar, die im Web durch Feeds – mittels spezieller Software abonnierbare Nachrichten – plattformunabhängig bereitgestellt werden können und damit einen automatisierten Empfang bei den Hörern ermöglichen. Der Unterschied zu normalen Audio-Streams oder Audio-Downloads besteht darin, dass Podcasts zusätzlich als Content syndiziert, abonniert und automatisch mittels News-Aggregatoren bezogen werden können. Podcasts werden zunehmend als MP3-Dateien im Rahmen von Life-Mitschnitten veröffentlicht und können auch mobil unter Verwendung eines geeigneten Abspielgerätes konsumiert werden. Um Podcasts abzuspielen, werden portable Media-Player wie beispielsweise Apples iPod bzw. Software-Player auf Desktop-Rechnern wie iTunes⁹ oder WinAmp¹⁰ verwendet. Um sich über das Angebot an Podcasts zu informieren, existieren zahlreiche Plattformen im Web. Odeo¹¹ bietet eine umfassende, nach Themen geordnete Liste zu Podcasts. LibriVox¹² hat sich zum Ziel gesetzt, Bücher als Podcasts im Web bereit zu stellen.

Podcasting wird als eine soziale Evolution des Radios angesehen. Verglichen mit Blogs und Online-Videos zeichnet sich jedoch bereits eine Stagnation beim Podcasten ab [9]. Eine Ursache dafür mag unter anderem darin bestehen, dass Podcasts oft Diskussionen behandeln, die der gesamten Aufmerksamkeit der Zuhörer bedürfen, während normale Musik auch während der Arbeit genossen werden kann. Verglichen mit Blogs verlangen Podcasts auch erhöhte Konzentration, da User nicht wie bei Blogs die Möglichkeit haben, den Content einfach zu überfliegen. Wer einer längeren Diskussion beiwohnen möchte, greift lieber gleich auf das Medium Video und die damit verbundene visuelle Unterstützung zurück. Für das Erstellen von Pod- und Videocasts ist ein entsprechend höherer Produktionsaufwand zu veranschlagen. Technisches Vorwissen ist eine weitere Bedingung für den erfolgreichen Einsatz dieser Anwendung.

Rich Internet Applications

Viele Web 2.0 Applikationen haben gemeinsam, dass zwar die Datenverarbeitungskapazität des Clients für die Darstellung des User Interfaces und die

⁹ www.apple.com/itunes

¹⁰ www.winamp.com

¹¹ www.odeo.com

¹² www.librivox.org

Verarbeitung von Benutzereingaben herangezogen wird, jedoch die Daten selbst auf dem Anwendungsserver verwaltet werden. Solche die Features und die Funktionalität von klassischen Desktop-Anwendungen annehmende Web-Applikationen werden im allgemeinen „Rich Internet Applications“ (RIA) [1] oder auch „Rich Web Clients“ (RWC) [24] genannt.

Rich Internet Applications können im Vergleich zu klassischen Web-Anwendungen, bei denen die gesamte Datenverarbeitung auf dem Server durchgeführt wird und der Client nur statischen Content darstellt, besonders leistungsfähig sein, da sie sich der Rechenleistung des Clients bedienen. Sie benötigen für ihr Funktionieren lediglich einen kompatiblen Web-Browser und bedürfen keiner Installation. Derartige Anwendungen kommen, was Leistungsfähigkeit und Funktionsvielfalt betrifft, bereits sehr nahe an moderne Desktop-Programme heran.

Als moderne Web-2.0-Applikationen bedienen sich Rich Web Applications bevorzugt Adobe Flash/Flex und Ajax als technischer Grundlage. Zu bekannten Beispielen für RIAs zählen das kostenlose On-Demand-Office ThinkFree¹³, das kostenlose webbasierte Mind-Mapping-Tool MindMeister¹⁴ oder die Foto-Sharing-Lösung Flickr¹⁵. Aufgrund der rasanten technologischen Weiterentwicklung im Web verschwimmen die Maßstäbe und Grenzen, wenn es um die Frage geht, welche Anwendungen von der Web-Community zu den Rich Internet Applications gezählt werden.

Im Zusammenhang mit RIA wird auch vom Konzept Software as a Service (SaaS) gesprochen. Mit SaaS bewegt sich die Software-Industrie terminologisch von ASP (application service providing) und On-Demand weg. SaaS bezeichnet ein Software-Distributions-Modell, bei dem die native Web-Software durch den Entwickler selbst, oder durch Dritte gehostet wird. SaaS bedient sich jedoch im Gegensatz zum „alten“ ASP-Modell einer Software, die originär für das Web entwickelt wurde und Application Programming Interfaces (APIs), also Schnittstellen besitzt, auf die mit der Hilfe von Web-Services zugegriffen werden kann. Web-Services sind dabei die Kommunikation zwischen Maschinen unterstützende Dienste.

Ein prägendes Beispiel für SaaS ist die im Business to Business Umfeld angesiedelte Firma Salesforce¹⁶, die Services für das Customer Relationship Management (CRM) bereitstellt. Ein weiteres Beispiel ist ein von Google angebotener Web-Service, der dieselbe Funktionalität wie die Google-Suche¹⁷ anbietet. Während User über www.google.com suchen, verwenden Computer den Web-Service. Elektronische Programme richten

¹³ www.thinkfree.com

¹⁴ www.mindmister.com

¹⁵ www.flickr.com

¹⁶ www.salesforce.com

¹⁷ www.google.com

Suchanfragen an den Web-Service und empfangen über eine API die Ergebnisliste, welche sie für eigene Zwecke weiterverarbeiten.

Technologien des Web 2.0

Im Gegensatz zum Semantic Web, dem Web der Daten, beschreibt das Web 2.0 im Allgemeinen das Web der User. Aus der Sicht der Semantic-Web-Community stellt das Web 2.0 hauptsächlich die soziale Revolution in der Benutzung von Web-Technologien dar. Das Web bewegt sich von einem reinen Publikations-Medium hin zu einem Medium, geprägt von Interaktion und Partizipation der User [14].

Das semantische Web soll jedoch gemäß seiner Bestimmung [3] Maschinen und somit auch Menschen alle semantischen Informationen hinsichtlich seiner Inhalte preisgeben. Von der semantischen Seite zählen Folksonomies und Mikroformate aufgrund ihrer Fähigkeit, einer Webseite eine bestimmte Bedeutung zuzuweisen, zu den besonders interessanten technischen Aspekten im Web 2.0 [14]. Im folgenden Abschnitt werden zahlreiche Web-2.0-Technologien erläutert, die die Entwicklung der im ersten Teil des Beitrags beschriebenen Anwendungen erst ermöglichen.

Folksonomies

Eine *folksonomy* (aus dem Englischen „folk“ und „taxonomy“) stellt eine durch die User einer Website generierte Taxonomie dar.¹⁸ Folksonomies werden seit den Anfängen des Web 2.0 zur Kategorisierung und zum Auffinden von Web-Content wie Fotos (www.flickr.com), Videos (www.youtube.com) oder Bookmarks (del.icio.us) eingesetzt. Sie entstehen durch kollaboratives „Tagging“ [16] und bezeichnen eine durch die Community selbst organisierte und selbst vorgenommene Form der Klassifikation und Stukturbildung. Schlagwörter, so genannte „Tags“, werden als Deskriptoren für die als „Tagging“, einem Zuweisen von Schlagwörtern zu Web-Inhalten, bezeichnete Indexierung herangezogen. Das gesamte für die Klassifikation der Inhalte verwendete Vokabular entstammt der jeweiligen die Website nutzenden Community. Diese neue Generation von Web-2.0-Communities gebraucht Tags, um die von den Mitgliedern erstellten Web-Inhalte in eine bestimmte Struktur zu bringen, um diese dann einfacher aufzufinden.

¹⁸ Für eine detaillierte Auseinandersetzung mit dem Folksonomy-Konzept siehe den Beitrag von Hotho et al. in diesem Band.

Verwendete Tags werden häufig alphabetisch sortiert und in zweidimensionaler Form visualisiert. Je nach Verwendungshäufigkeit, werden Worte in unterschiedlicher Schriftgröße oder -breite dargestellt und dadurch hervorgehoben (vgl. Abb. 1). Das entstehende Objekt ähnelt einer Wolke aus unterschiedlich großen Schlagworten, was für die Namensgebung „Tag-Cloud“ – Wolke aus Schlagworten – ausschlaggebend war. Klickt der User auf ein Wort in der Tag-Cloud, werden ihm typischerweise alle Informationsobjekte angezeigt, die mit diesem Wort annotiert wurden.

Die soziale Komponente des Web 2.0 zeigt sich im Kontext von Folksonomies darin, dass jeder User zur Verschlagwortung der Inhalte beiträgt, wodurch der Aufwand der Verschlagwortung durch gemeinsame Ressourcennutzung in Communities auf viele Köpfe verteilt werden kann. Vorherrschendes Prinzip ist, dass Informationsobjekte, die von denjenigen klassifiziert werden, die sie auch benutzen, schneller gefunden werden. Das Tagging von Inhalten auf Webseiten reichert diese in gewisser Weise mit Semantik an, die auch von Maschinen interpretiert werden kann. Anders als im Semantic Web, in dem mit Ontologien gearbeitet wird, ist hier die Idee der Semantik, dass die Häufigkeit des Vorkommens eines Tags eine inhaltliche Aussage über eine getaggte Webseite macht. Suchmaschinen könnten diese semantische Annotation einer Webseite in ihre Suchergebnisse mit einbeziehen und somit relevantere Suchergebnisse liefern.

Tagging kann ein Werkzeug darstellen, das die Bildung von virtuellen Gemeinschaften verstärkt (vgl. Abb. 2): Einerseits annotieren ähnliche User Informationsobjekte häufig mit denselben Tags und können sich somit rasch gegenseitig finden. Andererseits erkennt ein User weitere User mit gleichen Interessen insofern, dass eben diese Gleichgesinnten ein relevantes Informa-



Abb. 1. Web-2.0-Tag-Cloud [6]




Abb. 2. Tagging ermöglicht die Bildung sozialer Netzwerke

tionsojekt annotiert haben. Die durch das Tagging von Informationsobjekten entstehenden Netzwerke können in sozialen Graphen visualisiert werden.

Durch Tags werden Beziehungsnetzwerke zwischen Usern sichtbar und somit auch nutzbar. Beispielsweise können User anhand der Tags prüfen, wer sich weiters für ihre Inhalte interessiert, und mit diesen Usern in Interaktion treten. Neue Arten von Web 2.0 Communities bringen Menschen über Tags zusammen. Auf 43things¹⁹ können User beispielsweise beschreiben, was sie in ihrem Leben noch erreichen möchten. Tags generieren Werte, indem sie zeigen, welche User gleiche oder ähnliche Absichten haben. Obwohl das alleinige Beschreiben eines Wunsches an sich eine fruchtlose Tätigkeit darstellt, reichern Tags die Informationsobjekte soweit mit Semantik an, dass sie, kollektives Tagging vorausgesetzt, maschinengestützt Gleichgesinnte zusammen bringen.

Die Informationswissenschaft hat eine Reihe von Problemen identifiziert, die im Zusammenhang mit Folksonomies auftreten und deren Ursprung in der Autonomie der Communities begraben ist: Die völlig benutzergetriebene Auswahl der Schlagwörter führt zu einer Zersplitterung der Kategorien, etwa wenn derselbe Tag im Singular („Mensch“) bzw. im Plu-

¹⁹ www.43things.com

ral („Menschen“) verwendet wird. Gleichzeitig kann ein und dasselbe Wort auch in unterschiedlichen Sprachen als Tag verwendet werden („human“ und „Mensch“), was die Zuweisung des Informationsobjektes zu einer Kategorie weiter erschwert. Einige Wörter können mehrere Bedeutungen aufweisen, beispielsweise kann „Apache“ einen Indianerstamm, einen Kampfhubschrauber oder auch einen Webserver bezeichnen. Oftmals ist der Kontext entscheidend, in dem ein Schlagwort verwendet wird.

Nun existieren unterschiedliche Konzepte, um dieser Zersplitterung entgegenzuwirken: Beispielsweise können ausgehend von der Benutzereingabe mittels Wortvervollständigung von der Applikation ähnliche bereits verwendete Tags angezeigt werden, wodurch der User eine Hilfe bei der Suche oder der Vergabe eines geeigneten Schlagworts erhält. Nach einem angezeigten Tag kann beispielsweise in Klammern auch die Anzahl der bisherigen durch die Community vorgenommenen Verwendungen dieses Schlagwortes angeführt werden. User tendieren dazu, Schlagwörter zu verwenden, die auch von anderen besonders häufig herangezogen werden.

Mikroformate

Mikroformate stellen ein Set von einfachen, offenen Datenformat-Standards dar, die von einer Community entwickelt und implementiert werden, um eine strukturierte Veröffentlichung von Micro Contents zu erhalten. Gemäß ihrer Definition wurden sie in erster Linie für den User und erst in zweiter Linie für die Maschine entworfen und stellen offene Datenformate dar, die auf existierenden und verbreiteten Standards aufbauen [17].

Mikroformate verwenden HTML-Markups zur Dekodierung von strukturierten Daten und beschreiben somit die erweiterte Semantik einer HTML- oder XHTML-Seite, so dass Maschinen die Bedeutung von Teilen einer Webseite erkennen können. Durch diese im HTML-Code der Web-Seite vorgenommenen Erweiterungen kann beispielsweise eine Suchmaschine die Bedeutung des Seiteninhalts verstehen und somit ein präziseres Suchergebnis liefern, als über eine bloße Indizierung von Wörtern. Mikroformate werden aufgrund ihrer besonderen Beziehung zu (X)HTML auch als Real World Semantics oder Lowercase Semantic Web [11] bezeichnet.

Mikroformate sind modular aufgebaut und ermöglichen dezentrale Entwicklungen, Inhalte und Services. Eine Mikroformat-Annotation stellt kein Semantic-Web-Format dar, kann jedoch in ein Format wie Resource Description Framework (RDF) [25] oder OWL [26] transformiert werden, um von Semantic-Web-Agenten verarbeitet zu werden. Diesbezüglich arbeitet das W3C an Konzepten, wie Gleaning Resource Descriptions from Dialects of Languages (GRDDL) [28] oder RDFa [27], die dazu dienen, die Verbindung von strukturierten Daten zusammen mit Anweisungen, wie

diese transformiert oder in bestehende Web-Ressourcen eingebunden werden, zu standardisieren [14].

Eine Reihe von Mikroformaten wurde entwickelt, um bestimmte Typen von Information mittels semantischer Annotationen zu versehen [11]. Zur Veranschaulichung der Arbeitsweise von Mikroformaten wird folgendes Beispiel basierend auf dem Mikroformat *hCalendar* [5] vorgestellt:

```
Im Jahr 2008 findet die I-KNOW in der Zeit von 3. bis 5. September in der Stadthalle Graz statt.
```

Obwohl die Bedeutung dieses Absatzes für einen Menschen sehr leicht zu begreifen ist, stellt sich die Frage, wie eine Suchmaschine diese Passage interpretiert. Eine Suchmaschine indiziert (1) entweder alle Wörter einzeln, oder achtet darauf, ob (2) die Daten in einem maschinenlesbaren Format ausgezeichnet sind.

Nach der Annotation unter Zuhilfenahme des Mikroformats *hCalendar* zeigt sich das eben vorgestellte Beispiel im HTML-Quelltext folgendermaßen:

```
<p class="vevent">
  Im Jahr 2008 findet die
  <a class="url" href="http://www.i-know.at">
  <span class="summary">I-KNOW</span></a>
  in der Zeit von
  <abbr class="dtstart" title="2008-09-03T10:00:00Z">
  3. September</abbr>
  bis
  <abbr class="dtend" title="2008-09-05T16:00:00Z">
  5. September</abbr>
  in der
  <abbr class="location" title="Stadthalle Graz, Messeplatz 1,
  8010 Graz"> Stadthalle Graz </abbr>
  statt.
</p>
```

Nach den gemäß *hCalendar* vorgenommenen Annotationen im Quelltext der Website versteht eine Suchmaschine die Bedeutung dieser Aussage. Es findet ein Event mit dem Namen „*I-KNOW*“ in der „*Stadthalle Graz, Messeplatz 1, 8010 Graz*“, das am „*3. September 2008*“ beginnt und bis zum „*5. September 2008*“ dauert. Auf Clientseite unterstützt der Browser Mozilla Firefox²⁰ bereits Mikroformate, wobei Firefox ein spezielles Add-

²⁰ www.mozilla.com/firefox

On – Operator [8] – benötigt. Damit kann dieses Mikroformat durch den User beispielsweise als Termin nach Microsoft Outlook exportiert werden.

Technologien für Rich Internet Applications

Die im Kapitel Anwendungen des Web 2.0 diskutierten Rich Internet Applications (RIA) werden durch Technologien wie Ajax [7], Adobe Flash²¹ und Flex²², Microsoft Silverlight²³ oder die Open Source Plattform OpenLaszlo²⁴ erst ermöglicht. Die populärste Technologie stellt dabei Ajax dar, gefolgt von den beiden Adobe Produkten Flash und Flex.

Ajax steht für Aynchronous JavaScript and XML und umfasst ein Set von Technologien, um die für Web-2.0-Anwendungen typische „Rich User Experience“, was soviel wie bessere Benutzerführung bedeutet, zu ermöglichen. Der Begriff Ajax wurde im Februar 2005 durch Jesse James Garrett von Adaptive Path geprägt [7]. Ajax ermöglicht asynchrone Datenübertragung zwischen dem Browser und dem Webserver und erlaubt, dass innerhalb einer HTML-Seite eine HTTP-Abfrage durchgeführt wird, ohne die jeweilige Seite komplett neu laden zu müssen. Ajax ist jedoch im eigentlichen Sinne keine einzelne Technologie, sondern beinhaltet ein Bündel von bekannten Technologien. Es kombiniert Technologien zur standardisierten Präsentation von Web-Seiten (XHTML, CSS), zur dynamischen Anzeige und Interaktion mittels Document Object Model (DOM), zu Datenaustausch und -manipulation mittels XML und XLST, sowie zur asynchronen Datenabfrage mittels XMLHttpRequest und JavaScript.

Das klassische Modell einer Web-Anwendung zeichnet sich dahingehend aus, dass durch einen User vorgenommene Interaktionen auf einer Webseite einen HTTP-Request zum Webserver auslösen. Auf diesem Webserver wird dann eine Verarbeitung der auf der Webseite in die Formularfelder eingegebenen Daten durchgeführt und als Resultat erneut eine Webseite zum Client zurückgeliefert. Der ständige Ablauf von Interaktion, Senden, Verarbeiten und Empfangen der Daten sowie der nachfolgende Aufbau der geänderten Webseite führt aus Benutzersicht zu Wartezeiten. Diese beschränken die Eigenschaft einer klassischen Web-Seite, vom User als eine Desktop-ähnliche Anwendung wahrgenommen zu werden. Klassische Webseiten lassen somit keine ansprechende Benutzerführung zu.

Ein auf Ajax basierendes Modell verkürzt diese Wartezeiten, indem es einen Intermediär, die Ajax-Engine einführt (vgl. Abb. 3). Die beim Auf-

²¹ www.adobe.com/products/flash

²² www.adobe.com/products/flex

²³ www.microsoft.com/silverlight

²⁴ www.openlaszlo.org




Abb. 3. Klassische vs. auf Ajax basierende Web-Anwendungen (nach [7])

rufen der Webseite einmalig geladene Ajax-Engine fungiert somit wie eine Zwischenschicht zwischen User und Server. Sie ist sowohl für die Kommunikation mit dem Server, als auch für das Interface zum User hin verantwortlich. Erst dadurch sind Web-Anwendungen implementierbar, die ähnliche Funktionsvielfalt und Benutzerführung wie Desktop-Anwendungen erlauben.

Zusammengefasst liegt der größte Vorteil von Ajax darin, dass vom User eingegebene Daten verändert werden können, ohne die komplette Webseite neu zu laden. Webseiten zeichnen sich durch eine schnellere Reaktion auf Benutzereingaben aus und ermöglichen eine reichhaltige Benutzerführung. Moderne Anwendungen übertragen statische Daten nicht erneut. Ajax-Technologien basieren auf Java-Script, sind frei zugänglich und werden unabhängig vom Betriebssystem von den Web-Browsern unterstützt, die auch JavaScript unterstützen.

Content Syndication und Content Aggregation

Der Begriff Content Syndication bezieht sich im Zusammenhang mit dem Web auf die Mehrfachverwendung von Inhalten in verschiedenen Websites. Content-Syndication erlaubt den Websites untereinander Inhalte aus-

zutauschen. Beispielsweise kann Website A – der Content Syndicator – einen Teil des Contents für weitere Websites verfügbar machen. In diesem Fall sieht es jedoch für den Betrachter von Website B – dem Content Aggregator – aus, als befände sich der Content „physikalisch“ auf Website B, obwohl diese ihn tatsächlich nur über Website A holt. Ändert sich der jeweilige Content auf Site A, wird Site B automatisch aktualisiert.

Die herkömmlichste Ausprägung von Syndikation und Aggregation im Web stellen Feeds dar. Ein Feed ist ein Datenformat, welches dazu genutzt wird, um User mit häufig aktualisierten Inhalten von Web-Sites zu versorgen. Web-Sites können beispielsweise News-Feeds bereitstellen, um ihren Lesern auf einfache Weise Änderungen des Contents, wie aktuelle Nachrichten zu einem bestimmten Thema, mitzuteilen, ohne einen Besuch des Lesers auf der Webseite notwendig zu machen. In diesem Fall abonnieren Leser den vom Betreiber der Web-Site syndizierten News-Feed und nutzen einen Feed-Reader um Schlagzeilen oder Blog-Einträge herunterzuladen und diese zu aggregieren. Somit ersparen sich Leser das mühsame Browsen von einer Website zur anderen und wandeln die Hol- in eine Bringschuld um. So kann das Web als Informationsmedium effektiver und effizienter eingesetzt werden.

Content Aggregation führt themenbezogene Inhalte aus unterschiedlichen Online-Quellen auf einer Seite bzw. in einer Applikation zusammen. Die Verwendung von XML unterstützt die einfache Wiederverwendung und -verteilung des Contents. Really Simple Syndication (RSS) und Atom bilden diesbezüglich die beiden am weitesten verbreiteten Standards und werden mittlerweile von allen verbreiteten Web-Browsern native unterstützt.

Webbasierte Feed-Reader wie Bloglines²⁵, oder Google Reader²⁶ werden im Gegenzug zu lokal installierten Desktop-Readern immer populärer. Auch die Betreiber von Web-Sites haben die Nachfrage seitens der User-Community erkannt und sorgen für eine verstärkte Verfügbarkeit von Feeds, welche immer detailliertere Informationen bereitstellen. Manche Social Networking Plattformen wie Facebook²⁷ syndizieren sogar die Aktivitäten der User im jeweiligen sozialen Netzwerk. Auch mit Twitter²⁸ können User über Web oder SMS berichten, was sie gerade unternehmen, und dadurch Beziehungspflege betreiben.

²⁵ www.bloglines.com

²⁶ www.google.com/reader

²⁷ www.facebook.com

²⁸ www.twitter.com

Services und Mashups

Mashups sind Web-Anwendungen, die Daten aus mehreren unterschiedlichen Applikationen kombinieren und daraus für den User einen vollkommen neuen Service generieren [18]. Mashups zählen zu den bedeutenden Zukunftsthemen des Web 2.0. Während es Weblogs jedem User ermöglichen, Inhalte ins Web zu stellen, stimulieren Mashups die Web-Entwicklung und erlauben es theoretisch jedem User, existierende Daten miteinander zu kombinieren, um neue Services zu generieren [13]. Eine detaillierte Übersicht zu den derzeit vorhandenen APIs und Mashups findet sich auf www.programmableweb.com.

Mashups bedienen sich der Application Programming Interfaces (APIs), also der von den Betreibern von Web-Sites angebotenen Schnittstellen. Durch die Kombination von Daten aus unterschiedlichen Quellen unter Nutzung der bereitgestellten APIs entsteht eine völlig neue Applikation – ein Web-Service. Dieser Web-Service erzeugt für den User ein Informationsobjekt, welches nicht durch eine einzelne Datenquelle originär bereitgestellt werden könnte. Erst die Kombination von unterschiedlichen Datenquellen liefert diesen neuen Service für den User.

Ein bekanntes und häufig zitiertes Beispiel für einen Mashup stellt HousingMaps²⁹ dar, welches die APIs von Google-Maps nutzt. HousingMaps kombiniert kartographische Daten aus Google-Maps³⁰ mit den Immobilien-Daten der Kleinanzeigendatenbank Craigslist³¹ und generiert für den User ein weiteres Informationsgut mit einem höheren Grad an Wertschöpfung (vgl. Abb. 4). User können bevorzugte Immobilien nun direkt anhand der Karte von Google-Maps selektieren und so die Immobiliensuche einfacher und präziser durchführen.

Eine große Herausforderung für den Durchbruch von Mashups besteht darin, dem gewöhnlichen User ohne besondere Affinität zur Technik eine Möglichkeit bereitzustellen, Mashups einfach und rasch zu erstellen. Diesbezügliche Design-Tools kommen jedoch erst langsam auf und sind noch sehr gering verbreitet [13]. Erwähnenswerte verfügbare Tools sind in diesem Zusammenhang Yahoo Pipes (pipes.yahoo.com), Microsoft Popfly³² oder IBM QEDWiki³³.

Yahoo Pipes stellt beispielsweise eine graphische Oberfläche zur Verfügung, mit der User per Drag & Drop Daten aus dem Web – bevorzugt RSS-Feeds, oder Dienste, die RSS Feeds generieren können – beliebig in

²⁹ www.housingmaps.com

³⁰ maps.google.com

³¹ www.craigslist.org

³² www.popfly.com

³³ services.alphaworks.ibm.com/qedwiki




Abb. 4. Immobiliensuche 2.0 mit HousingMaps (www.housingmaps.com)

benutzerdefinierten Feeds bündeln können. Eine Reihe von Werkzeugen erlaubt die gewünschte Konfiguration. Beispielsweise können sich User aus einer von ihnen definierten Menge an Feeds, die bestimmte Schlagwörter in Überschrift oder Textkörper enthalten, einen individuellen Feed basteln. In wenigen Schritten kann der User so einen personalisierten Web-Service erstellen.

Conclusio und Ausblick

Technologische Änderungen gelten als Enabler von sozialen Veränderungen im Web. Ausgehend von neuen Anwendungen und Technologien kommt es zu dem Phänomen, dass soziale Prozesse wie Gleichgesinnte finden, mit diesen zu kommunizieren oder sogar zu kollaborieren durch das Web unterstützt werden, bzw. sogar gänzlich im Web stattfinden.

Die neuen Technologien führen zu einer nachhaltigen Veränderung, was die Herausbildung von virtuellen Communities und sozialen Netzwerken [21] betrifft. User formieren sich zunehmend über Wikis, Weblogs und andere soziale Rich Internet Applications und bedienen sich der neuen Wissensstrukturen, um ihren persönlichen Absichten nachzukommen. In Zukunft werden User das Web nicht nur bloß mit neuen Inhalten anreichern, sondern auch – durch die rasche technologische Entwicklung stimu-

liert – individuelle Web-Services kreieren, die auf ihre Bedürfnisse zugeschnittene Daten liefern.

Die fortlaufende Sozialisierung des Webs stellt abermals Herausforderungen an die Technologie. Soziale Plattformen zeichnen sich dadurch aus, dass sie unglaubliche Mengen an durch ihre User erstellten Daten speichern, sich jedoch im Gegenzug, was Weitergabe und Export eben dieser betrifft, sehr restriktiv zeigen. Eine zentrale Frage ist in diesem Zusammenhang, wie User ihre Daten – zum Beispiel ihr Freundesnetzwerk – von einer Plattform zur anderen Plattform transportieren können. Da User im realen Leben zumeist in unterschiedlichen Communities aktiv sind, werden sie das auch im Web sein. Immer wiederkehrende Vorgänge wie Anmeldung, Login, Benutzerprofilerstellung oder das Hinzufügen von Freunden verschlingen die knappen zeitlichen Ressourcen der User.

Von dem Hintergrund einer „social network fatigue“, dem Stress, den Benutzer erfahren, die gleichzeitig auf mehreren sozialen Plattformen präsent sind, wurden bereits zahlreiche Initiativen von engagierten Einzelpersonen mit Unterstützung der Industrie ins Leben gerufen. Dazu zählen etwa OpenSocial³⁴, DataPortability³⁵ und Open Social Web³⁶. Die zu meistenden Herausforderungen können unter dem Begriff Cross-Plattform-Aspekte zusammengefasst werden.

Danksagung

Das Know-Center wird im Rahmen des Österreichischen COMET-Programms – Competence Centers for Excellent Technologies – gefördert. Das Programm steht unter der Schirmherrschaft des Österreichischen Bundesministeriums für Verkehr, Innovation und Technologie, des Österreichischen Bundesministeriums für Wirtschaft und Arbeit und des Landes Steiermark. Die Abwicklung des Programms erfolgt durch die Österreichische Forschungsförderungsgesellschaft FFG.

Literatur

1. Allaire, Jeremy, Macromedia Flash MX-A next-generation rich client, Macromedia White-Paper, <http://download.macromedia.com/pub/flash/whitepapers/richclient.pdf>, 2002

³⁴ code.google.com/apis/opensocial/

³⁵ www.dataportability.org

³⁶ opensocialweb.org

2. Back, Andrea; Baumgartner, Horst; Gronau, Norbert; Tochtermann, Klaus (Hrsg.), Web 2.0 in der Unternehmenspraxis. Grundlagen, Fallstudien und Trends zum Einsatz von Social Software, Oldenburg Wissenschaftsverlag, 2008.
3. Berners-Lee, Tim, Semantic Web Roadmap, <http://www.w3.org/DesignIssues/Semantic.html>, Zugriff am 30.09.07
4. Wiki Engines, <http://www.c2.com/cgi/wiki?WikiEngines>, Zugriff am 30.08.07
5. Tantek, Çelik; Suda, Brian, hCalendar Specification, <http://microformats.org/wiki/hcalendar>, Zugriff am 30.09.07
6. Cremonini, Luca, Web 2.0 Tag-Cloud <http://www.railsonwave.it/railsonwave/2007/1/2/web-2-0-map>, Zugriff am 30.10.07. *Creative Commons Attribution ShareAlike 2.5* http://commons.wikimedia.org/wiki/Image:Web_2.0_Map.svg, Zugriff am 10.03.2008
7. Garrett, Jesse James, Ajax: A New Approach to Web Applications, <http://www.adaptivepath.com/publications/essays/archives/000385.php>, 2005, Zugriff am 30.09.07
8. Kaply, Michael, Operator 0.8 Firefox Add-on, <https://addons.mozilla.org/de/firefox/addon/4106>, Zugriff am 15.02.08
9. Iskold, Alex, Will Podcasting Survive, http://www.readwriteWeb.com/archives/will_podcasting_survive.php, Zugriff am 30.08.07
10. Khare, Rohit, Microformats: The Next (Small) Thing on the Semantic Web, in: IEEE Web Computing, Volume 10, Issue 1, January, 2006.
11. Khare, Rohit; Tantek Çelik, Microformats: A Pragmatic Path to the Semantic Web, CommerceNet Labs Technical Report, 2006.
12. Kolbitsch, Josef; Maurer, Hermann, The Transformation of the Web: How Emerging Communities Shape the Information we Consume, in: Journal of Universal Computer Science, 2006.
13. Kulathuramaiyer, Narayanan, Mashups: Emerging Application Development Paradigm, in: Journal of Universal Computer Science, 2007.
14. Lassila, Ora; Hendler, James, Embracing „Web 3.0“, in: IEEE Web Computing, Volume 11, Issue 3, May, 2007.
15. Markoff, John, Entrepreneurs See a Web Guided by Common Sense, in: The New York Times, November 12, 2006.
16. Marlow, Cameron; Naaman, Mor; Boyd, Danah; Davis, Marc, HT06, tagging paper, taxonomy, Flickr, academic article, to read, in: Proceedings of the Seventeenth Conference on Hypertext and Hypermedia, 2006.
17. Microformats, <http://microformats.org>, Zugriff am 15.02.08
18. Merrill, Duane, Mashups: The new breed of Web app, IBM developerWorks, <http://www.ibm.com/developerworks/xml/library/x-mashups.html>, Zugriff am 15.12.2007
19. Tim O'Reilly, What is Web 2.0. Design Patterns and Business Models for the Next Generation of Software, <http://www.oreillynet.com/pub/a/oreilly/tim/news/2005/09/30/what-is-Web-20.html>, Zugriff am 30.08.07

20. Trackback Technical Specification,
http://www.sixapart.com/pronet/docs/trackback_spec, Zugriff am 15.01.08
21. Stocker, Alexander; Tochtermann, Klaus, (Virtuelle) Communities und soziale Netwerke, in: Back, Andrea u. a. (Hrsg.), Web 2.0 in der Unternehmenspraxis. Grundlagen, Fallstudien und Trends zum Einsatz von Social Software, Oldenburg Wissenschaftsverlag, 2008.
22. Toffler, Alvin, The Third Wave, Bantam Books, 1980.
23. Zerfaß, Ansgar; Boelter, Dietrich, Die neuen Meinungsmacher. Weblogs als Herausforderung für Kampagnen, Marketing, PR und Medien, Nausner & Nausner, 2005.
24. W3C Rich Web Clients,
<http://www.w3.org/2006/rwc/> Rich Web Clients, Zugriff am 15.02.08
25. Resource Description Framework (RDF),
<http://www.w3.org/RDF/>, Zugriff am 15.02.08
26. OWL Web Ontology Language Overview,
<http://www.w3.org/TR/owl-features/>, Zugriff am 15.02.08
27. RDFa in HTML Overview, <http://www.w3.org/2006/07/SWD/RDFa/>, Zugriff am 15.02.08
28. W3C Gleaning Resource Descriptions from Dialects of Languages (GRDDL), <http://www.w3.org/TR/grddl/>, Zugriff am 15.02.08

5. Die Usability von Rich Internet Applications

Jörg Linder

Usability Engineer, Wien, Österreich;
joerg.linder@japhy.at

Zusammenfassung: Interaktiven Services, die dem Themenkreis Web 2.0 zugeordnet werden, haftet unter anderem das Attribut an, besonders leicht bedienbar zu sein. Flickr, Youtube und Wikipedia gelten als Erfolgsprojekte dieser neuen Art von interaktiven Websites. Wodurch zeichnet sich nun eine Usability 2.0 (so es sie überhaupt geben sollte) aus? Was ist zu beachten, wenn so genannte Rich Internet Applications gestaltet werden?

Einleitung

Der von Tim O'Reilly [12] geprägte Begriff Web 2.0 steht für ein Konglomerat aus Techniken und Konzepten, die den aktuellen Zustand des WWW beschreiben. Web 2.0-Sites zeichnen sich generell durch einen höheren Grad an Interaktivität – gestützt durch neue Technologien, wie etwa AJAX, „fühlen“ sich Web 2.0-Sites oft wie Desktop-Anwendungen an – und durch User Generated Content (Blogbeiträge, Wikipedia-Artikel oder Multimediacontent wie etwa Photos, Videos oder Filme) aus. Meist besteht auch zumindest die Möglichkeit der sozialen Interaktion mit anderen Benutzern der Website, oft liegt darin auch der eigentliche Sinn und Zweck (soziale Netzwerke).

Dieses „neue“ Web 2.0 verspricht dem Benutzer vieles: Partizipatives Miteinander im Netz anstatt einseitigen Konsumierens von Inhalt, jeder wird zum Medienproduzenten, alles wird einfacher und vieles wird erst jetzt überhaupt möglich. Der neue Begriff beschreibt eine Art des WWW, die eigentlich doch nur das beinhaltet, was das Web 1.0 schon vorgegeben hat zu sein: Eine demokratische Plattform, die jeden Teilnehmer sowohl zu einem Konsumenten als auch zu einem Produzenten von Inhalten macht.

Doch neben wirtschaftlichen und sozialen Barrieren drängt sich auch im Web 2.0 (oder vielleicht gerade im Web 2.0) ein Aspekt in den Vordergrund, der wesentlich für den Erfolg dieser Idee ist: Die angebotenen Tools wie Blogs, Wikis, soziale Netzwerke, Online Office-Anwendungen, Foto-Sharing-Dienste und Videoplattformen müssen einerseits Bedürfnisse des Users befriedigen, andererseits aber auch leicht bedienbar sein, um angenommen zu werden. Viele Web 2.0-Sites stellen nur ein Gerüst zur Verfügung, welches die Benutzergemeinde mit Inhalten füllen soll. In der Folge bedeutet dies, dass die Nützlichkeit der Site für den einzelnen User zunimmt, je mehr andere User Inhalte beisteuern. Es ist deshalb umso wichtiger dem User zu einem positiven Erlebnis zu verhelfen, während er sich auf der Site bewegt. Es geht dabei um Stichworte wie Usability, Interaction Design, User Experience oder Information Architecture. All diese Themengebiete spielen zusammen und sind für das verantwortlich, was der User im Endeffekt sieht und erfährt. Da es im Zusammenhang mit diesen Professionen oft zu Missinterpretationen und Verwechslungen kommt, soll hier zunächst ein kurzer Überblick gegeben werden, bevor auf die Besonderheit von Web 2.0-Sites in diesem Zusammenhang eingegangen wird.

Usability – Interaction Design – Information Architecture: Versuch einer Begriffsdefinition

Beschäftigt man sich damit, wie interaktive Produkte gestaltet werden sollten, so stößt man früher oder später auf den Begriff Usability. Usability ist der vielleicht bekannteste Begriff aus dem Bereich der Human Computer Interaction-Forschung und wird häufig mit Usability-Testing gleichgesetzt. Schon aus diesem Grund erscheint es angebracht, hier eine Definition zu geben. Diese liefert beispielsweise die ISO-Norm 9241-11 (zitiert nach [4]): Usability ist die Effektivität, Effizienz und das Ausmaß der Zufriedenheit, mit denen bestimmte Benutzer spezifizierte Ziele in vorgegebenen Umgebungen erreichen.

Laut einer anderen Definition ist Usability ein Fachgebiet, welches sich damit beschäftigt, wie interaktive Systeme möglichst einfach erlernbar und benutzbar gestaltet werden können [14]. Der Begriff Usability bezeichnet also, inwieweit eine Software oder ein Verwendungsgegenstand im weitesten Sinne die eben aufgezählten Bedingungen erfüllt. Ein Usabilitytest hingegen ist ein Mittel, um den Grad der Usability zu erheben. Dabei müssen User vorgegebene Aufgaben mit Hilfe des Systems lösen. Während dessen werden sie von einem Usability Engineer beobachtet und mittels der so genannten Thinking Aloud-Technik [11] zu ihren Eindrücken befragt. Es gibt verschiedene Arten von Usabilitytests: Sie können in einem

Labor (wenn etwa eine Office-Software getestet werden soll) oder im Freien (beim Test von Handheld-Geräten) stattfinden, die Datenerhebung kann sowohl qualitativ (mittels des beschriebenen Thinking Aloud-Verfahrens) als auch quantitativ (wie lange benötigt der User um die Aufgabe durchzuführen, wie viele Fehler macht er dabei usw.) erfolgen.

Im Gegensatz zum Usabilitytest handelt es sich bei Usability Engineering sowie Interaction Design um Methoden, um Software und Gebrauchsgegenstände von Grund auf so zu entwerfen, dass sie ein möglichst hohes Maß an Usability erreichen. Im Gegensatz zu einer Softwareentwicklung, die sich beim Interface vorrangig an technischen Modellen (Implementation Models, [2]) orientiert, steht hier das mentale Modell des Benutzers im Vordergrund. Es geht darum, die Erwartungen und Wünsche des Benutzers möglichst gut im System abzubilden. Alan Coopers Goal Directed Design gibt einen detaillierten Prozess für die Entwicklung von interaktiven Produkten vor: Von der Research-Phase, in der die Wünsche und Ziele der einzelnen Benutzergruppen erhoben werden, über die Entwicklung von Personas (fiktive Benutzer), mit deren Hilfe Benutzungsszenarien entworfen und getestet werden können, bis hin zur Entwicklung von Prototypen und dem Feinschliff am Interface. Während der gesamten Entwicklung sollten auch stets so genannte Usability-Heuristiken beachtet werden. Diese meist in kurzen Regeln formulierten Empfehlungen können helfen, die richtigen Designentscheidungen zu treffen. Sie sind allerdings nicht als Rezeptsammlung zu verstehen: Im Usability Engineering gilt stets, dass die Vorgehensweise beim Lösen eines Problems immer auch vom jeweiligen Kontext abhängt. Usability-Heuristiken finden sich etwa bei Jakob Nielsen [7] oder, etwas ausführlicher, bei Bruce Tognazzi [17].

Wichtig ist in diesem Zusammenhang zu erwähnen, dass diese Methoden nicht ausschließlich mit dem Ziel eingesetzt werden sollten, besonders leicht bedienbare Systeme zu schaffen. Es geht vielmehr darum, benutzergerechte Designs zu entwerfen, die den User effektiver machen [2]. Der Unterschied ist rasch erklärt: Ein Webshop, der Uhren verkauft, muss leicht bedienbar sein, sodass auch der User, der zum ersten Mal hier einkauft, zurechtkommt. Bei einer Anwendung, die im Bereich der Flugsicherung zum Einsatz kommt, kann hingegen davon ausgegangen werden, dass sie nur von Experten bedient wird. Hier sind andere Aspekte, wie etwa Absicherung gegen Fehlbedienung und Effizienz, wichtiger als leichte Erlernbarkeit.

Die Informationsarchitektur schließlich beschäftigt sich damit, wo und unter welchen Begriffen Inhalte auf der Website abgebildet werden [2]. Auch hier gibt es Techniken, wie etwa das Cardsorting, welche dazu dienen, schon in der Planungsphase eine optimale Aufteilung der Information zu erreichen.

Was ist neu im Web 2.0?

Nun stellt sich die Frage, ob sich die neue Generation von Websites in Hinblick auf Usability von ihren „Vorgängern“ im Web 1.0 unterscheidet. Da die meisten Usability-Heuristiken nicht auf technischer Ebene angesiedelt sind sonder eher eine Vogelperspektive einnehmen, ist zu erwarten, dass sie auch zur Evaluation von Webanwendungen (um die handelt es sich in der Regel bei Web 2.0-Sites) herangezogen werden können. Im Folgenden sollen nun die für das Web 2.0 typischen Webanwendungen auf ihre speziellen Anforderungen in Hinblick auf Usability untersucht werden.

Rich Internet Applications

Viele der neuen Web 2.0-Services wie etwa Google Maps, Flickr oder Gmail unterscheiden sich stark von Webanwendungen, wie sie noch vor fünf Jahren geschaffen wurden. Anwender von flickr.com¹ (einer Foto-Sharing-Anwendung) können etwa den Namen eines Bildes ändern, ohne



Abb. 1. Der Titel eines Fotos kann in Flickr direkt editiert werden

¹ <http://flickr.com>, aufgerufen am 18.3.2008

dass dazu die ganze Seite neu geladen werden müsste (Inline-Editing). Auf Google Maps² kann der User die Landkarte mit der Maus verschieben, ohne dass dadurch größere Verzögerungen durch Ladezeiten entstehen würden. Diese verbesserte Interaktion ist deshalb möglich, weil diese Services mit der bisher gültigen Seiten-Metapher des World Wide Web brechen.

Die Seitenmetapher

Die Seitenmetapher versteht das WWW als eine Verkettung einzelner statischer Seiten. Jede Seite repräsentiert genau einen Zustand. Klickt der Benutzer auf einen Link oder einen Button, so wird eine andere Seite im Browser aufgerufen. Dieses Verhalten resultiert aus dem technischen Unterbau des WWW, dem HTTP-Protokoll. Durch diesen langsamen, aber vorhersagbaren Ablauf kommt das typische Browsing-Verhalten zustande.

Auswirkungen auf den User hat die Seitenmetapher sowohl in negativer als auch in positiver Hinsicht. Durch das notwendige Laden ganzer neuer Seiten schon bei kleinsten Änderungen, wenn etwa nur ein Satz ausgetauscht werden soll, ist das Navigieren im World Wide Web eher langsam (natürlich immer abhängig von der jeweiligen verfügbaren Bandbreite, die dem User zur Verfügung steht). Besonders Anwendungen, wie etwa Web-mail, Kalenderprogramme sowie E-Banking-Systeme, leiden unter dieser Einschränkung.

Andererseits haben die Anwender die Seitenmetapher mittlerweile verinnerlicht und erwarten, dass Websites nach diesem Muster funktionieren. Die Seitenmetapher entspricht dem mentalen Modell [2], welches die User vom WWW haben. Wird beispielsweise nach Anklicken eines Links nicht sofort eine Seite geladen, so hält der Benutzer den Link für „tot“. Benutzer erwarten außerdem, dass auf jede Seite ein Lesezeichen (Bookmark) gelegt werden kann, und dass bei Aufruf dieses Bookmarks stets die gleiche Seite am Bildschirm erscheint. Zusammenfassend kann gesagt werden, dass die Seitenmetapher vier Aspekte umfasst [15]:

- Jede Seite kann mit ihrer Darstellung im Browserfenster gleichgesetzt werden.
- Seiten haben eine Eins-zu-eins-Beziehung zu der Adresse (URL), unter der sie aufgerufen wurden.
- Jede Seite kann auch als Navigationseinheit (Node) verstanden werden, über die zu anderen Seiten gesprungen werden kann.
- Und schließlich ist, im einfachsten Fall, eine Seite einer Datei auf einem Server gleichzusetzen.

² <http://maps.google.com>, aufgerufen am 18.3.2008

Das Ende der Seitenmetapher

Diese Seitenmetapher wird nun durch Techniken wie AJAX oder Flash immer mehr aufgeweicht. Der Grund für den Einsatz dieser Technologien liegt darin, dass Websites immer interaktiver werden und vielfach dazu übergegangen wird, ganze Anwendungen im WWW abzubilden. Dafür aber war die Seitenmetapher nie vorgesehen, was man unter anderem an der, im Gegensatz zu Desktop-Anwendungen, zähflüssigen Interaktion merkt.

So genannte Rich Internet Applications [5] setzen Technologien wie AJAX oder Flash ein, um so die Einschränkungen des HTTP-Protokolls (und damit die der Seitenmetapher) zu umgehen. Gleichzeitig laufen diese Anwendungen aber innerhalb des Browser-Fensters und sehen auf den ersten Blick auch wie Websites aus [15], wodurch sich eine Anzahl von Problemen für den Benutzer ergeben kann.

AJAX

AJAX ist eines der Buzz-Words aus dem Web 2.0-Umfeld und steht für Asynchronous JavaScript and XML [21]. Der Einsatz dieser Technik bringt den Vorteil mit sich, dass Aktionen auf Websites unabhängig von den Eingaben des Users ausgeführt werden können, was innerhalb des Konzeptes der Seitenmetapher weder vorgesehen noch möglich war. So kann etwa die Anwendung Google Maps Kartenmaterial außerhalb des Bereichs, der dem User angezeigt wird, im Hintergrund laden. Bewegt der Anwender dann die Karte, so sind die Daten schon vorhanden und müssen nur noch durch JavaScript eingeblendet werden. Es ist nun nicht mehr nötig, für jede Aktion eine neue Seite zu laden [13]. Teile der Seite können einfach ausgetauscht werden, wodurch eine fließendere und übersichtlichere Art der Interaktion ermöglicht wird. Das Look & Feel dieser Anwendungen erinnert mehr an Desktop-Applikationen als an Websites.

Inkrementelle Änderungen am Interface

Wie bereits erwähnt, ermöglicht AJAX raschere und gezieltere Änderungen auf Websites [20]. Problematisch wird dieses Verhalten dort, wo es von Benutzern nicht erwartet wird. Diese haben im Lauf der Zeit das Modell der Seitenmetapher verinnerlicht und erwarten nach einem Klick eine zumindest kurzfristige Verzögerung samt Anzeige eines leeren Bildschirms, bis die neue Seite erscheint. Durch diesen, eigentlich unerwünschten Prozess wird allerdings auch die Statusänderung kommuniziert: Der User weiß, dass er die Funktion korrekt ausgelöst hat und dass mit einem Ergebnis in Kürze zu rechnen ist. Bei Webanwendungen, die mit AJAX oder ähnlichen Technologien arbeiten, kann es passieren, dass der Benutzer die

Änderung im Interface nicht wahrnimmt, da er immer noch auf eine neue Seite wartet.

Um zu verhindern, dass User diese Änderungen am Interface übersehen, müssen Webdesigner mit Techniken wie Farbänderungen oder Animationen arbeiten, um die Aufmerksamkeit der Benutzer auf den relevanten Bereich am Bildschirm zu lenken [20]. Bekannte und weit verbreitete JavaScript-Bibliotheken, wie zum Beispiel script.aculo.us³ bieten vorgefertigte Lösungen für diesen Zweck an. Um zu erheben, ob das Design in der Lage ist, die Aufmerksamkeit des Benutzers erfolgreich zu lenken, kann mittels Eyetracking der Blickverlauf des Users am Bildschirm aufgezeichnet und anschließend ausgewertet werden. Der Vorteil dieses Ansatzes liegt darin, dass dadurch Daten über interne kognitive Vorgänge gesammelt werden können, die sich mit der Thinking Aloud-Methode nicht erheben lassen. Eyetracking bietet sich besonders an, wenn festgestellt werden soll, ob und wann der User eine Änderung im Interface wahrnimmt [19].

Feedback: Auch im Web 2.0 ein Thema

Obwohl Rich Internet Applications in der Interaktion typischerweise schneller reagieren als Anwendungen, die mit dem Page Refresh-Modell arbeiten, kann es auch hier zu Verzögerungen kommen, etwa weil die Anwendung gerade umfangreiche Operationen durchführt um neue Daten darstellen zu können. Für diesen Fall ist es wichtig, dem User Feedback über den aktuellen Systemstatus zu geben. Dies kann zum Beispiel über eine animierte Fortschrittsanzeige geschehen [8]. Anderenfalls kann es vorkommen, dass der User den Button, der die Berechnung ausgelöst hat, noch einmal zu drücken versucht, da er glaubt, dass die Anfrage nicht registriert wurde. Zusätzlich zur Fortschrittsanzeige kann auch der Button, über den der User den Prozess ausgelöst hat, deaktiviert werden. Dadurch erhält der Anwender einerseits Feedback darüber, dass seine Anfrage angenommen wurde, andererseits wird er zusätzlich noch daran gehindert, den Button noch einmal zu betätigen und dadurch möglicherweise ungewollte Aktionen auszulösen [15]. Während die Fortschrittsanzeige eingeblendet ist und Berechnungen im Hintergrund stattfinden, sollte der User auch davon abgehalten werden, neue Prozesse (etwa durch Anklicken von Links) zu starten. Einen Button, um den Vorgang abubrechen, sollte es natürlich trotzdem geben.

³ <http://script.aculo.us>, aufgerufen am 18.3.2008

Kommunikation des Systemstatus nach Abwesenheit

Dauert die Berechnungszeit sehr lange (für eine Übersicht siehe etwa [6]), so muss außerdem damit gerechnet werden, dass der User seine Aufmerksamkeit von der aktuellen Aufgabe abwendet um andere Tätigkeiten zu erledigen. Er minimiert dann möglicherweise das Fenster und öffnet es erst wieder, wenn er glaubt, dass die Wartezeit nun vorbei sein müsse. Das Ein- und Ausblenden der Website führt zu einem kurzen Orientierungsverlust: Der Benutzer muss sich erst wieder vergegenwärtigen, was der Status war und was er erreichen wollte. Um diesen Orientierungsverlust zu minimieren, müssen, nachdem der User wieder zurückgekehrt ist, alle Änderungen im System klar gekennzeichnet werden (etwa durch Hervorhebungen, wie dies beim Löschen einer Nachricht in Gmail passiert).

Nicht standardkonforme UI-Elemente

Um für ihre Webanwendung ein eigenes Look & Feel zu kreieren, verwenden viele Designer selbst gestaltete GUI (Graphical User Interface)-Elemente (Radiobuttons, Eingabefelder, Checkboxes usw.), worunter die Affordance [9] dieser Elemente leiden kann. Unter der Affordance eines Elements wird der Aufforderungscharakter desselben verstanden: Eine Türklinke muss signalisieren, wie sie betätigt werden muss um die Türe zu öffnen. Ein Hammer wiederum signalisiert, dass er dazu da ist um damit auf etwas zu schlagen. Werden GUI-Elemente verwendet, die der User nicht wieder erkennt, so kann es dazu kommen, dass er deren Bedeutung und Funktion nicht versteht, oder, im schlimmsten Fall, die Elemente übersieht, da er sie für graphische Stilelemente hält. Auf einigen Seiten⁴ werden zum Beispiel Eingabefelder verwendet, die für den User nicht von vornherein als solche erkennbar sind.

Zusätzlich zu den Interaktionselementen, die vom Desktop her bekannt sind, gibt es im Web 2.0 auch neue Elemente, für die sich allerdings noch keine Standards herauskristallisiert haben. Hier sind zum Beispiel Objekte, die im Zusammenhang mit Tagging stehen oder Reload-Funktionen für einzelne Seitenbereiche zu nennen. Diese neuen Funktionen führen für den Anwender zwar oft zu einer verbesserten Bedienbarkeit, ihre Bedeutung muss ihm allerdings beim ersten Auftreten kommuniziert werden. Andernfalls kann es zum so genannten Minesweeping-Effekt [18] kommen: Der Anwender fährt mit der Maus über jedes ihm nicht bekannte Element und hofft, dass ein Tooltipp samt Erklärung zur Funktionsweise erscheint.

Ein positives Beispiel bietet in dieser Hinsicht das RSS-Icon, welches sich, nachdem es nun auch in Microsoft-Produkten verwendet wird, bereits

⁴ Siehe etwa <http://www.baekdal.com/x/xmlhttprequest/>, aufgerufen am 18.3.2008

zu einem de-facto-Standard entwickelt hat. Natürlich kann es nicht Sinn und Zweck von Usability-Heuristiken sein, eine Designphilosophie zu propagieren, die rein auf Standardelementen basiert und jegliche Individualität im Webdesign verbietet. Dagegen spricht schon allein die Tatsache, dass jedes Design unterschiedliche Bedürfnisse des Users anspricht [10]: Es muss nicht nur bedienbar sein, sondern dem User auch eine einzigartige Erfahrung bieten. Jedoch sollten Designer, so sie stark von den Standards abweichen, besonderes Augenmerk auf die Usability der von ihnen entworfenen Elemente legen und diese im Zweifelsfall durch Tests erheben.

Instant save und der Vertrauensverlust

Werden bei Webanwendungen herkömmliche Interaktionsmuster verlassen, und wird dies dem User nicht ausreichend gut kommuniziert, so kann dies ebenfalls zu Usability-Problemen führen. So wird bei Internetanwendungen etwa gern das Instant Save-Muster verwendet, bei dem alle Änderungen, die ein User an einem Dokument vornimmt, sofort und ohne nötiges Eingreifen des Users gespeichert werden. Wird dann zusätzlich noch auf den Save-Button verzichtet, so kann der Anwender in der Folge das Vertrauen in die Anwendung verlieren (und das, obwohl das automatische Anlegen einer Sicherheitskopie im Hintergrund vom Usability-Standpunkt aus gesehen eigentlich ein wünschenswertes Verhalten darstellt).




Abb. 2. GoogleDocs bietet sowohl eine Speichern-Funktion (im File-Menü) als auch eine automatische Versionierung an

Einen möglichen Weg dieses Dilemma zu umgehen zeigt die Textverarbeitung von Google⁵: Hier steht dem User sowohl ein Speichern-Button als auch eine automatische Versionierung zur Verfügung. Sobald die Website eine Version des vom User erstellten Dokuments speichert, wird dem User auch ein deutliches Feedback dazu gegeben. Zusätzlich zum Instant Save wird dem Benutzer auch ein eigener Speichern-Button angeboten, den er

⁵ <http://docs.google.com>, aufgerufen am 18.3.2008

jederzeit betätigen und so seine Arbeit sichern kann. Auf diese Weise werden einerseits Konventionen eingehalten, andererseits werden die neuen Möglichkeiten zum Nutzen des Users eingesetzt [20]. Das mentale Modell [2] des Benutzers darüber, wie ein Speicherprozess funktioniert, wird von der Programmlogik eins-zu-eins nachgebildet, wodurch die Benutzbarkeit verbessert wird.

Probleme mit den Browser-Controls

Wie bereits erwähnt kommt es bei Webanwendungen häufig dazu, dass die bekannte Seitenmetapher fallen gelassen wird um das Verhalten der Anwendung an das einer Desktop-Applikation anzugleichen. Nun sind aber Browser-Controls (Vor- und Zurück-Button, Reload, die Bookmarking-Funktion, ...) in ihrer Funktion auf die Benutzung innerhalb der Seitenmetapher ausgelegt. In Rich Internet Applications verlieren sie einen Großteil ihrer Funktionalität: Meist können weder Bookmarks gesetzt werden, noch funktioniert der Back-Button wie gewohnt [21].

Designer von Webanwendungen sollten daher, wenn die Funktionen der Standard-Browser-Controls aufgrund technischer Einschränkungen nicht sinnvoll in die Anwendung integriert werden können, ein eigenes Look & Feel für die Applikation schaffen, welches dem Benutzer kommuniziert, dass er sich gerade in einer Anwendung und nicht auf einer statischen Website befindet [2]. Dadurch können Designer in der Folge auch aus dem engen Rahmen der Seitenmetapher ausbrechen und die Möglichkeiten von AJAX oder Flash besser ausnützen.

Neue Interaktionstechniken

Die Verwendung von technischen Hilfsmitteln wie AJAX oder Flash führt auch dazu, dass Funktionen wie Drag & Drop, Inline-Editing oder direkte Manipulation nun auf Websites eingesetzt werden können. Dadurch, dass diese Interaktionsmöglichkeiten im Web erst seit relativ kurzer Zeit möglich sind, werden sie vom User allerdings meist nicht erwartet.

Auch hier gilt es, durch das Design des Elements und des Kontextes eine Affordance zu erzeugen, um die Bedeutung der neuen Elemente zu kommunizieren. Reicht dies allein nicht aus, so müssen dem User textuelle Hilfestellungen gegeben werden. Greg Rosenberg von Yahoo beschreibt seine Herangehensweise im Artikel „A Look Into the Interaction Design of the New Yahoo! Mail... and the Pros and Cons of AJAX“ [16]. In der AJAX-Anwendung Yahoo! Mail werden, im Gegensatz zu einer globalen Hilfe, kontextuelle Hilfestellungen angeboten. Werden neue Features eingeführt, so erscheint, sobald sich der User das nächste Mal einloggt, ein kurzer Hinweis auf die neue Funktion. Genau so werden auch neue User




Abb. 3. Yahoo! Mail zeigt sog. Nuggets an, die den Benutzer auf neue Funktionen hinweisen

an die Funktionsweise des Interface herangeführt: Um den Anwender bei seiner Aufgabe nicht zu stören, dürfen diese Funktionen nicht allzu aufdringlich sein: Sie sollten nur dort angeboten werden, wo sie auch wirklich benötigt werden, und müssen sich jederzeit schließen lassen. Nachdem der Anwender die Funktion zum ersten Mal benutzt hat, sollten diese Hilfs-Nuggets (Raymond, 2007) nicht mehr angezeigt werden.

Leere Seiten

Viele Web 2.0-Sites stehen vor dem Problem, dass sie dem User der zum ersten Mal eingeloggt ist, komplexe Prozesse vermitteln müssen. Viele Wiki-Systeme etwa sind vom User selbst zu befüllen, und dieser sieht sich im schlimmsten Fall einer weißen Seite gegenüber, die er nun mit Inhalt füllen soll [15]. Für solche und ähnliche Fälle hat es sich bewährt, Beispielinhalte vorzugeben, um dem User eine Idee davon zu vermitteln, was er mit der Anwendung alles machen könnte. Der Anwender soll diese Inhalte natürlich jederzeit löschen können (und wird dies in der Regel auch gleich tun), dennoch verringert diese Technik das unangenehme Gefühl, vor einer leeren Seite zu stehen.

Tastaturshortcuts

Jeder Designer, der interaktive Anwendungen plant, steht vor dem Problem, die Zielgruppe definieren zu müssen: Wird die Applikation hauptsächlich von Anfängern oder von erfahrenen Usern benutzt werden? Im

schlimmsten Fall gibt es wenig bis gar keine Einschränkungen, und das System soll für so gut wie alle Benutzer gleich gut funktionieren. Cooper [2] empfiehlt für solche Fälle, das System für fortgeschrittene Benutzer zu planen mit der Begründung, dass kein User sehr lange ein Anfänger bleibt. Eine Möglichkeit um fortgeschrittenen Usern die Arbeit mit Webanwendungen zu erleichtern sind Keyboard-Shortcuts. Sie bieten neben dem Geschwindigkeitszuwachs in der Interaktion noch zusätzlich den Vorteil, dass sie von Anfängern meist nicht wahrgenommen werden und somit den Komplexitätsgrad der Anwendung für diese User nicht erhöhen [15]. Für Webanwendungen bieten JavaScript-Frameworks wie Prototype⁶ eigene Methoden an, die den Einsatz von Tastaturshortcuts erleichtern.

Problematischer Einsatz von AJAX

Sobald im WWW neue Technologien verfügbar sind, kommt es meist zu einem unkritischen Einsatz derselben. So hatte etwa Macromedias Flash lange Zeit mit einem schlechten Ruf zu kämpfen, da es hauptsächlich verwendet wurde um animierte Intro-Seiten zu erstellen. Jakob Nielsen bezeichnete Flash in den neunziger Jahren gar als „99 percent bad“ [8].

Auch im Rahmen von Rich Internet Applications muss beim Einsatz von AJAX oder Flash immer auf die Verhältnismäßigkeit geachtet werden. Im Folgenden werden einige Szenarien aufgezählt, innerhalb derer der Einsatz von AJAX und Flash zumindest fragwürdig ist.

AJAX als Selbstzweck

Ähnlich wie in der Zeit der Flash-Intros ist auch bei Techniken wie AJAX zu befürchten, dass sie viel zu oft verwendet werden nur um optische Effekte zu erzielen [1]. Vor dem Einsatz solcher Techniken ist aber immer abzuwägen, ob für den User dadurch auch wirklich ein Mehrwert entsteht oder nicht. Geht es etwa nur darum, eine Animation zu realisieren, so ist die Verwendung von AJAX oder Flash keinesfalls gerechtfertigt.

Navigation

Wie bereits erwähnt, kann der Einsatz von Techniken, die mit der Seitenmetapher brechen, dazu führen, dass die Browser-Controls ihre Funktion verlieren. Besonders dramatisch wirkt sich dies aus, wenn die ganze Navigation einer Website mittels AJAX realisiert wurde. In diesem Fall kann es dazu kommen, dass der Status der dargestellten Seite in der URL nicht

⁶ <http://www.prototypejs.org>, aufgerufen am 18.3.2008

vollständig beschrieben werden kann [15]: Setzt der User ein Bookmark/Lesezeichen und ruft die Seite später wieder auf, so kann sich das, was dargestellt wird, sehr stark von dem unterscheiden, was er beim letzten Besuch der Seite gesehen hat. Jeder, der schon einmal einem Bekannten beschrieben hat, wo etwas auf einer komplett in Flash programmierten Seite zu finden ist („Klick zuerst auf der Startseite links oben, und auf der nächsten Seite dann auf den Button Produkte, dann auf MP3-Player, ...“), kennt das Problem. Eine Hauptnavigation sollte deshalb in der Regel nicht durch AJAX oder Flash realisiert werden.

Natürlich stellt sich in diesem Fall auch die Frage, was unter Navigation jeweils zu verstehen ist. Bei Google Maps wird AJAX verwendet um den Benutzer den Kartenausschnitt wählen zu lassen. In diesem Fall könnte man dies durchaus auch als Navigation betrachten [15]. Die URL bleibt aufgrund der Verwendung von AJAX die ganze Zeit über gleich. Jedoch bietet Google hier eine zusätzliche Funktion genannt „URL zu dieser Seite“ an, um dem User doch noch die Möglichkeit zu geben, die aktuell dargestellte Karte an einen Bekannten zu senden. Im Zweifelsfall sollte also immer genau abgewogen werden, ob die Vorteile einer AJAX-Navigation die Nachteile aufwiegen. Gibt es dann zusätzlich noch die Möglichkeit Workarounds einzusetzen um dem User trotzdem noch die gewohnten Funktionen zur Verfügung zu stellen, so kann AJAX auch zur Navigation eingesetzt werden.

Performance

Generell führt der Einsatz von AJAX zu schneller reagierenden Webanwendungen [15]. Wird dieser Einsatz jedoch übertrieben, so kann auch das Gegenteil eintreten: Der User wartet übermäßig lange darauf, bis der Browser die jeweilige Seite darstellen kann [1]. Es sollte also immer darauf geachtet werden, dass auch Computer mit geringer Rechenleistung die Anwendung noch flüssig darstellen können.

Fazit

Rich Internet Applications treten immer zahlreicher auf und werden immer komplexer. Dem Vorteil einer flüssigeren Interaktion, ermöglicht durch AJAX und Flash, stehen mögliche Usability-Probleme gegenüber, die beachtet werden müssen. Durch neue Technologien (wie etwa Adobe Air⁷) kommt es dazu, dass der Unterschied zwischen Web und Desktop immer

⁷ <http://www.adobe.com/products/air/>, aufgerufen am 18.3.2008

mehr verschwimmt. GUI-Standards für neue Interaktionsformen haben sich zum Teil schon gebildet, an vielen Stellen wird aber fleißig herumprobiert. Usabilitytests und Heuristiken sind wichtige und unabkömmliche Tools auf dem Weg zur optimalen User Experience.

Literatur

1. Bosworth A (2007) Ajax Mistakes. <http://alexbosworth.backpackit.com/pub/67688>.
2. Cooper, A (2007) About Face 3. The Essentials of Interaction Design. Wiley Publishing, Indianapolis.
3. Golder S A & Huberman B A (2006) The Structure of Collaborative Tagging Systems. *Journal of Information Science*, 32(2). 198–208.
4. Manhartsberger M (2001) Web Usability. Das Prinzip des Vertrauens. Galileo Press GmbH, Bonn.
5. McMullin J & Skinner G. (2007) Usability Heuristics for Rich Internet Applications. http://www.boxesandarrows.com/view/usability_heuristics_for_rich_internet_applications.
6. Nielsen J (1994a) Response Times: The Three Important Limits. <http://www.useit.com/papers/responsetime.html>.
7. Nielsen J (1994b) Ten Usability Heuristics. http://www.useit.com/papers/heuristic/heuristic_list.html.
8. Nielsen J & Loranger H (2006) Prioritizing Web Usability. New Riders, Berkeley, CA.
9. Norman D A (1988) The Design of Everyday Things. Basic Books, New York.
10. Norman D A (2004) Emotional Design. Why we love (or hate) everyday things. Basic Books, New York.
11. Nørgaard M & Hornbæk K (2006) Seeking inspiration from design: What do usability evaluators do in practice?: an explorative study of think-aloud testing. Proceedings of the 6th ACM conference on Designing Interactive systems DIS '06. ACM Press, New York.
12. O'Reilly T (2005) What Is Web 2.0. Design Patterns and Business Models for the Next Generation of Software. <http://www.oreillynet.com/pub/a/oreilly/tim/news/2005/09/30/what-is-web-20.html>.
13. Porter J (2005) Using Ajax for Creating Web Applications. <http://www.uie.com/articles/ajax/>.
14. Preece P (1994) Human-Computer Interaction. Addison-Wesley, Harlow.
15. Raymond S (2007) Ajax Usability. O'Reilly TecFeed <http://www.tecfeeds.de>.
16. Rosenberg G (2007) A Look Into the Interaction Design of the New Yahoo! Mail... and the Pros and Cons of AJAX. Interactions march + april. ACM Press, New York.
17. Tognazzi B (2003) First Principles of Interaction Design. <http://www.asktog.com/basics/firstPrinciples.html>.

18. U.S. Department of Health and Human Services (2006). Research Based Web Design and Usability Guidelines. u.S. Government Printing Office, Washington DC.
19. Wilhelm T (2007) Usability-Evaluationen im Web 2.0: Was wird sich ändern? <http://usability.germanblogs.de/archive/2007/06/03/usability-evaluationen-im-web-20-was-wird-sich-aendern-1.htm>
20. Wroblewski L (2006) AJAX & Interface Design. http://www.lukew.com/resources/articles/ajax_design.asp
21. Zucker, D F (2007) What Does Ajax Mean for You? ACM Press, New York

6. Die zwei Kulturen

Anupriya Ankolekar, Markus Krötzsch, Than Tran und Denny Vrandečić

Institut AIFB, Universität Karlsruhe (TH);
{ankolekar; kroetzsch; tran; vrandečić}@aifb.uni-karlsruhe.de

Zusammenfassung: Oft werden zwei mögliche Entwicklungen des Webs diskutiert – das Web 2.0 und das Semantic Web. Wenn wir diese zwei Visionen für das zukünftige Web unter die Lupe nehmen, dann lässt sich feststellen, dass sich die Ideen in ihrem Kern und ihren Technologien gegenseitig ergänzen. Dementsprechend können und sollen beide Visionen von den Erfahrungen und Stärken der anderen profitieren. Wir glauben daran, dass zukünftige Webanwendungen den Web 2.0-Fokus auf Community und Benutzerfreundlichkeit beibehalten und, darüber hinaus, auch von Technologien des Semantic Web zur Vereinfachung der mashupähnlichen Datenintegration profitieren werden. Auf Basis eines Semantic Blog-Szenarios werden wir hier die Vorteile einer möglichen Kombination von Semantic Web und Web 2.0 illustrieren, die zeitnah realisiert werden kann. Wir werden auch auf technische Probleme eingehen, die bei der Erweiterung dieses Szenarios entstehen. Wir stellen dar, wie aktuelle Entwicklungen in der Semantic Web Forschung diese Probleme angehen können, und setzen zugleich auch Schwerpunkte für die zukünftige Forschung, die in diesem Zusammenhang relevant sind.

Einführung

Oft werden diese beiden als angeblich miteinander konkurrierende Visionen für die zukünftige Entwicklung des Webs gesehen: das Semantic Web und Web 2.0. Wir glauben, dass die Techniken, Stärken und Kernelemente dieser beiden Visionen sich ergänzen und nicht im Wettstreit zu einander stehen. Wir gehen sogar davon aus, dass die beiden einander brauchen, um ihre jeweiligen Hochburgen zu verlassen und darüber hinaus wachsen zu können. Das Semantic Web kann von den Erfahrungen des Web 2.0 mit Communities und hochinteraktiven Elementen lernen, während das Web 2.0 auf der reichen, stabilen und standardisierten technischen Infrastruktur

des Semantic Webs aufbauen kann, um Informationen über die Anwendungsgrenzen hinweg austauschen zu können.

Die Vision des Semantic Webs, wie sie in [6] dargestellt wurde, hat eine große Gemeinschaft von Forschern und Praktikern inspiriert, und eine ganze Reihe von Zielen konnte schon erreicht werden: Sprachen wie RDF [36] und RDFS [12] wurden überarbeitet, die Ontologiesprache für das Web, OWL, wurde standardisiert [46]. Die Forschung konnte Methoden für das Erstellen [47, 50], für die dynamische Evolution [35], das Korrigieren [30] und Aufteilen [45] von Ontologien beisteuern. Ein tiefes und gründliches Verständnis für Komplexität und Entscheidbarkeit vieler Ontologiesprachen konnte gewonnen werden [4]. Diese Einsichten erlaubten die Implementierung zunehmend skalierender Lösungen für das automatische Schlussfolgern über Ontologien [29] und führten zu verbesserten Modellierungsumgebungen für Ontologien [32]. Aufgrund dieser Fortschritte arbeiten große Firmen wie Oracle und IBM an großen und skalierbaren Speicherlösungen, welche die Semantic Web Sprache unterstützen. Eine wachsende Zahl kleiner, spezialisierter Firmen wie Aduna, Altova, Ontoprise und TopQuadrant bieten stabile und in der Industrie einsetzbare Lösungen, die semantische Technologien im betrieblichen Einsatz nutzen.

Web 2.0 Technologien, wie sie in [41] dargestellt wurden und beispielhaft durch Seiten wie Wikipedia¹, flickr² und HousingMaps³ vertreten werden, reichern das klassische Web an und ermöglichen eine einfache, verteilte Zusammenarbeit vieler Teilnehmer. Sie unterscheiden sich von klassischen Webtechnologien durch folgende Merkmale:

- **Community:** Web 2.0-Seiten machen die Benutzer zu Mitarbeitern. Sie erlauben es, Beiträge gemeinschaftlich zu erstellen und diese miteinander zu teilen. Die daraus entstehenden Ergebnisse hätten von keinem Einzelnen erbracht werden können, ob es sich dabei um eine Musikdatenbank wie freedb⁴ handelt oder einen Kalender für öffentliche Ereignisse wie upcoming.⁵ Jeder Beitragende bekommt vom System mehr zurück, als er selber investiert.
- **Mashups:** Bestimmte Dienste von verschiedenen Anbietern können zusammengeführt werden, um so die Daten auf eine neue Art und Weise erlebbar zu machen. Diese Verbindungen können verschiedene Formen annehmen, vom Einbetten von AdSense-Werbung⁶ im eigenen Blog bis

¹ <http://wikipedia.org>

² <http://www.flickr.com>

³ <http://www.housingmaps.com>

⁴ <http://www.freedb.org>

⁵ <http://upcoming.org>

⁶ <http://www.google.com/adsense>

zu der Darstellung der zu verkaufenden Immobilien von Craigslist⁷ auf einer Satellitenkarte von Google Map⁸, wie es HousingMap⁹ macht.

- **AJAX:** Die technische Säule des Web 2.0 erlaubt interaktive und schnell reagierende grafische Schnittstellen zum Benutzer, und unterstützt derart die beiden anderen Säulen: Community-Seiten mit einer ansprechenden Oberfläche erreichen potenziell ein größeres Publikum, während das dynamische Abfragen von Informationen von mehreren Seiten durch die asynchrone Kommunikation zu Anwendungen unterstützt und beschleunigt wird.

Der Begriff Web 2.0 wurde anfangs nicht eingeführt, um eine Vision, sondern um die Unterschiede zum klassischen Web zu beschreiben, welche die neuen, schon existierenden Dienste erbrachten [41].

Wir glauben, dass sich diese zwei Ideen gegenseitig ergänzen und nicht miteinander wetteifern – eine Sichtweise, die innerhalb der Semantic Web Community an Akzeptanz gewinnt, wie an den Diskussionsrunden auf der WWW Konferenz 2006¹⁰ und auf der ISWC 2006¹¹ zu sehen war. Das Semantic Web und das Web 2.0 haben gemeinsame Ziele, und beide bringen eigene Stärken mit.

Die Vision des Semantic Webs ist älter als das Web 2.0 und sah weder das Entstehen des Web 2.0 voraus, noch betrachtete sie die einhergehenden Konsequenzen. Das Web 2.0 veränderte das Ökosystem des Webs grundlegend, aber der größte Teil des Semantic Webs verpasste diesen Wechsel. Nach vielen Jahren Fortschritt im Bereich der semantischen Technologien glauben wir, dass die Zeit reif ist für die Semantic Web Community um auf das Web zu blicken, insbesondere auf die Anwendungen und Werkzeuge des Web 2.0, und sich neu zu orientieren. Dabei erkennt die Semantic Web Community das Potenzial, welches sich durch Communities und AJAX für das Semantic Web erschließen und wie es beispielhaft an den Arbeiten zu der Beziehung zwischen Folksonomien und Ontologien beobachtet werden kann [38] oder an der wachsenden Zahl von Semantic Web Anwendungen, die AJAX einsetzen [42].

Auf der anderen Seite ist es auch an der Zeit, Web 2.0-Mashups kritisch zu untersuchen, ihre Grenzen zu erforschen und bestehende Semantic Web-Lösungen so einzusetzen, um kühn jenseits dieser Grenzen zu gelangen.

Um zu zeigen, wie sich die beiden Ideen ergänzen können, beschreiben wir ein Web 2.0-Szenario, welches mit semantischen Technologien ange-

⁷ <http://www.craigslist.org>

⁸ <http://maps.google.com>

⁹ <http://www.housingmaps.com>

¹⁰ <http://www2006.org/programme/item.php?id=panelk01>

¹¹ <http://iswc2006.semanticweb.org/program/webpanel.php>

reichert wird. Wir behaupten, dass das hier vorgestellte Szenario innerhalb von weniger als zwei Jahren umgesetzt werden kann. Wir skizzieren eine Architektur und identifizieren die Teile der Vision, die noch fehlen. Keiner der fehlenden Teile verlangt nach großem Entwicklungsaufwand oder beruht auf noch ungelösten Fragen der Forschung. Dennoch wird das Erstellen dieser Teile ohne Zweifel zu einer ganzen Reihe neuer Anforderungen und Fragen führen, die auch der Forschung dabei helfen können, sich auf die Fragen zu konzentrieren, die für das kommende Semantic Web am wichtigsten sein werden.

Wir gründen unsere Arbeit auf den folgenden drei Hypothesen. Sie kritisieren gewisse Annahmen, die man oft bei manchen Forschern des Semantic Web finden kann, und sie helfen uns, das hier vorgestellte Szenario zu beschreiben. Wir denken, dass diese Hypothesen dabei helfen können, die beiden Kulturen zu vereinen, wie auch der Rest dieses Kapitels zeigen soll.

1. **Das Semantic Web wird ein weltweites Web sein.** Das bedeutet, es ist nicht auf betriebliche Intranets beschränkt und wird auch nicht aus einzelnen Wissensinseln bestehen. Stattdessen wird es weite Teile des Webs umfassen, bestehende URIs oft wieder verwenden und eng miteinander verknüpft sein. Das bedeutet nicht, dass es keine betrieblichen Intranets geben wird: Es ist sogar zu erwarten, dass diese oft Vorteile gegenüber dem weltweiten Semantic Web haben werden, doch letzteres wird im Allgemeinen den bekanntesten, wichtigsten und anspruchsvollsten Teil der Infrastruktur darstellen.
2. **Das Semantic Web wird von unten nach oben durch die Benutzer erstellt werden, um zu gelingen.** Auch das Web wurde nicht von großen Firmen begründet: Es begann in Forschungseinrichtungen und mit privaten, persönlichen Webseiten. Erst Jahre später erkannte die Industrie die Notwendigkeit einer Webpräsenz. Wir glauben, dass die ersten semantischen Webseiten communityzentrierte Anwendungen wie semantisch erweiterte Blogs und Wikis sein werden. Doch viele große Forschungsprojekte setzen auf die Unterstützung großer Firmen.
3. **Mit ein wenig Semantik kann man viel erreichen.**¹² Die erste Version des Semantic Web wird enorm von leichtgewichtigen Sprachen und Vokabularen profitieren. Sie werden wohl die Ausdrucksstärke von RDFS übertreffen, um etwa Instanzidentifikation und einfache Vokabularintegration zu ermöglichen, doch bleiben die Sprachen dabei weit unter der Ausdrucksmächtigkeit von OWL DL oder OWL Lite.¹³

¹² „A little semantics goes a long way“, Jim Hendler, in der Eröffnungsrede der International Semantic Web Conference 2003

¹³ Beispiele hierfür sind die tractable fragments in OWL 1.1, siehe <http://owl11.cs.manchester.ac.uk/tractable.html>

Szenario

Wir beschreiben in diesem Abschnitt ein konkretes Szenario, in dem Semantic Web Technologien die derzeitigen Werkzeuge und Erfahrungen des Benutzers mit dem Web 2.0 ergänzen und verbessern können. Wir wählen das Bloggen als ein typisches Beispiel für eine Webanwendung aus, die weit verbreitet ist, insbesondere um Meinungen und Links zu anderen Inhalten im Web zu veröffentlichen. Das macht das Bloggen zu einem interessanten Beispiel, um die Möglichkeiten der Datenintegration und Wiederverwendung im Semantic Web zu veranschaulichen.¹⁴

Betrachten wir Chrissie, die seit drei Jahren bloggt. Sie begann mit einem webbasierten Blogdienst, aber wechselte kürzlich auf ihren eigenen Webspace, der es ihr erlaubt PHP und MySQL zu verwenden. Dadurch kann sie beliebte Blog-Systeme wie Movable Type¹⁵ oder WordPress¹⁶ verwenden.

Chrissie ist ein recht typischer Blogger. Sie beherrscht ein wenig HTML und CSS, ihr Blog verfügt über einen RSS-Feed [5], doch wird dieser automatisch durch die Blogging-Anwendung erstellt. Sie weiß nicht wie ein RSS Feed aufgebaut ist, doch sie weiß, wie man sie abonniert, um bei den Blogs ihrer Freunde einfacher auf dem Laufenden zu bleiben. Sie hat noch nie von RDF gehört und weiß deswegen auch nicht, dass ihr RSS-Feed wahrscheinlich auf RDF basiert. Sie hat natürlich keine Ahnung von Semantic Web Standards wie OWL, SPARQL [44] und XML [10].

Chrissie geht regelmäßig ins Kino und schreibt danach gerne eine Filmkritik für ihren Blog. Ihr Publikum ist recht klein, größtenteils Freunde und Bekannte, und einige wenige Leser, die zufällig über die Filmkritiken auf ihren Blog aufmerksam wurden. Sie folgt einem einfachen Arbeitsablauf beim Erstellen der Kritiken. Wie auch bei jedem anderen Blogbeitrag wählt sie zunächst einen Titel, schreibt die Rezension und vergibt ein paar Tags, wie etwa das Filmgenre [37]. Dann klickt sie auf ‚Veröffentlichen‘, und das Blogsystem kümmert sich um den Rest: Der Eintrag wird in der Datenbank abgespeichert und auf der Startseite des Blogs angezeigt, die Archive werden entsprechend aktualisiert, und der RSS-Feed wird um den neuen Eintrag ergänzt, so dass abonnierte Leser die neue Kritik erhalten und lesen können.

¹⁴ Die Idee des semantischen Bloggens ist nicht neu, sondern wurde schon in [15, 16, 31] beschrieben.

¹⁵ <http://www.movabletype.org/>

¹⁶ <http://wordpress.org/>

Daten aus dem Web wiederverwenden

Stellen wir uns nun eine Erweiterung für Chrissies Blogsystem vor, welches Semantic Web Technologien verwendet, so dass Blogger leicht Informationen zu den Filmen in die Blogeinträge übernehmen können. Zufällig stolpert Chrissie über diese Erweiterung – wir nennen sie Smoov – und installiert sie in ihr System. Ihr Arbeitsablauf zum Schreiben von Filmkritiken ändert sich nun leicht. Gleich zu Anfang muss Chrissie nun explizit angeben, dass sie nicht einfach nur einen neuen Blogeintrag erstellen möchte, sondern eine Filmkritik. Dadurch taucht eine Reihe von neuen Feldern in der Anwendung auf. Ein Feld erlaubt es ihr, den Film auszuwählen. Sie kann dabei entweder den Titel eingeben oder über Schauspieler, den Regisseur oder ähnliche Metadaten den Film suchen. Chrissie kann auch externe Quellen wie IMDb¹⁷ oder Wikipedia benutzen, um den Film zu identifizieren. Der Artikel der Wikipedia würde wiederum auf die IMDb-Seite verweisen, so dass klar ist, dass beide denselben Film bezeichnen.

Da Chrissie den Film identifiziert hat, kann Smoov weitere Daten zu dem Film aus dem Netz beziehen und eine Seitenleiste mit diesen Informationen erstellen, wie man es in Abb. 1 sehen kann.

Chrissie hat die Seitenleiste so eingestellt, dass sie einerseits weitere Informationen zu dem Film anzeigt, wie etwa den Regisseur, Hauptdarsteller, Dauer, die Produktionsfirma, das Veröffentlichungsjahr, aber auch die URL des Filmplakats, weitere Bilder zum Film und einen Link auf die offizielle Seite des Films. Jetzt überprüft sie, ob die Seite gut aussieht und wählt eines der Bilder für ihren Blog aus. Mit Hilfe der angehängten Lizenzinformation im RDF-Format [17] kann Smoov Chrissie dabei helfen, Bilder und Materialien lizenzkonform auszuwählen.

Die Filmdaten, die Smoov bezieht, stammen von einer zentralen Datenstelle im Netz. Dies kann eine semantisch erweiterte Wikipedia sein, Freebase,¹⁸ ein semantisch erweitertes IMDb oder ein Skript, welches von Seiten wie IMDb die Informationen extrahiert (wie etwa die Skripte, die das SIMILE Projekt erstellt hat).¹⁹ Es gibt heute schon ausgereifte Technologien, um solche Daten über das Netz verfügbar zu machen, und es ist nur eine Frage der Zeit, bis diese Datenmengen in weiteren Bereichen erhältlich werden.

Ein Beispiel hierfür ist DBLP,²⁰ ein Dienst, der bibliographische Metadaten sammelt und zur Verfügung stellt und vor kurzem um eine SPARQL

¹⁷ <http://www.imdb.com>

¹⁸ <http://www.freebase.com>

¹⁹ [http://simile.mit.edu/wiki/Category:Javascript screen scraper](http://simile.mit.edu/wiki/Category:Javascript_screen_scraper)

²⁰ <http://dblp.uni-trier.de>

Everything pink - Chrissies blog

Archive

June 2007
May 2007
April 2007
March 2007

About me RSS-Feed

Blogroll

nutkidz
nakit-arts
Blog of the rings
Matrix Reblogged

Links

Gloria Cinema
Ecoshop
Legolas fanzine

Pirates of the Caribbean 3

June 21st, 2007

I just went with **Till** into the last part of the Pirates of the Caribbean, where our heroes (the adoringly cute **Orlando Bloom** and Keira Knightly reprise their roles) go to the end of the world to save the one and only Captain Jack Sparrow (**Johnny Depp!** xOxOx!) from the claws of the Kraken. And guess what - Jack Sparrows daddy has a special appearance, played by old Rolling Stone Keith Richards! Weeeeha!

Best movie of the year, until know, without a question! Tons of fun, and colorful action.

no comments yet - [post your comment](#) - [backtrack](#)



Director **George Verbinski**
Running time 125 minutes
Starring **Johnny Depp, Keira Knightley, Bill Nighy, Orlando Bloom, Geoffrey Rush**
Info from [Wikipedia](#)

See Pirates of the Caribbean 3 in the [Gloria](#):
Today 16:00, 18:30, 21:00
Tomorrow 16:00, 18:30, 21:00
[Reserve tickets now](#)

Abb. 1. Ein Bild der Film-Erweiterung im Einsatz bei einem Blogbeitrag. Die Erweiterung führt eine Leiste ein, die Informationen über den Film enthält (ein Poster, Dauer, Schauspieler, Regisseur etc.) sowie weitere Links, welche die Spielzeiten lokaler Kinos dynamisch einblenden

Schnittstelle erweitert wurde, die Abfragen auf und das Weiterverwenden von DBLP Daten vereinfacht und standardisiert zur Verfügung stellt.

Die Filminformationen, die Chrissie verwendet, können statisch sein (z. B. der Regisseur oder Hauptdarsteller des Filmes). Solche Informationen können einmal abgerufen werden und bleiben dann meist unverändert, abgesehen von inhaltlichen oder Schreibfehlern. Entsprechend können sie auch lokal gespeichert werden und müssen nicht jedes Mal abgefragt werden. Andere Informationen können halb-statisch sein, wie etwa Preise, die der Film erhielt, oder ganz dynamisch, wie etwa die Position des Films in den Ranglisten oder die Verfügbarkeit von Eintrittskarten für den Film für eine bestimmte Veranstaltung im örtlichen Kino.

Je nach Art der Daten muss ein anderer Caching-Mechanismus verwendet werden. Auch sollte die Seitenleiste vom Browser bereits dargestellt werden, wenn noch gar nicht alle Daten vorliegen, um erst danach dynamisch etwa mit AJAX diese Daten zu beziehen und darzustellen. Diese Maßnahmen sind notwendig, um die Antwortzeiten von Chrissies Blog möglichst klein zu halten.

Dynamische Datenquellen

Chrissie kann bei Smoov in den Präferenzen eine Liste (der URLs) ihrer Lieblingskinos eingeben. Die Erweiterung kann dadurch weitere lokale und dynamische Informationen von den Kinos beziehen, wie etwa die derzeit laufenden Filme. So ein Dienst könnte entweder von den Kinos selbst angeboten werden oder von einem externen Dienstleister, der aus den ohnehin vorhandenen Webseiten der Kinos die entsprechenden Informationen extrahiert und als RDF zur Verfügung stellt, oder von einem Stadtmagazin, welches die Daten ohnehin sammelt. Sobald der Film nicht mehr im Kino läuft, würde Smoov das bemerken und die entsprechenden Links nicht mehr anzeigen. Wenn dann die DVD zum Film erscheint, was Smoov zum Beispiel von IMDb erfahren könnte, könnte Smoov zu Chrissies Lieblingsladen oder Online-Verleih linken und auch gleich die Preise anzeigen.

Ist dieses Szenario mit dynamischen Datenquellen wirklich realistisch? Kinos haben eine Reihe von Vorteilen, wenn sie die Zeiten ihrer Aufführungen und ihr Programm in RDF anbieten. Auf XML basierend ist RDF ein universell einsetzbares Modell zur Repräsentation beliebiger Daten und erlaubt insbesondere die notwendigen Prozesse wie das Integrieren von Daten aus verschiedenen Quellen, was deutlich das Erstellen von Mashups vereinfacht. So können leicht die Programme zweier verschiedener Kinos abgerufen, zusammengefügt und dann gefiltert werden. Zudem erlauben es Ontologien, die mit den RDF-Daten verbunden sind, eine formale Semantik zu definieren, welche die maschinenbasierte Interpretation und Verarbeitung der Daten unterstützt. Es gibt jetzt schon eine Reihe von verschiedenen RDF-Speichern und -Infrastrukturen, welche es erlauben, diese Vorteile zu nutzen. Diese Standards erlauben eine größere Interoperabilität, Kontrolle, Korrektheit und Konsistenz der über das Web übertragenen Daten. Kinos können dadurch größere Personenkreise erreichen, und auch kurzfristige Programmänderungen effizient und schnell an viele Stellen gleichzeitig weitergeben. Viele Kinos verwalten diese Daten ohnehin in einer Datenbank, und der Aufwand beschränkt sich dann darauf, ein SPARQL System wie D2R²¹ an die Datenbank zu hängen oder einen RDF-Export zu schreiben, der den bereits vorhandenen HTML-Export ergänzt (und der deutlich leichter zu schreiben ist als der letztere, weil man sich keine Gedanken über das Aussehen der Daten machen muss).

Die Interoperabilität der Daten setzt natürlich die Verfügbarkeit eines gemeinsamen und weit verbreiteten Vokabulars für diese Daten voraus. Ein neues Vokabular zu erstellen ist aufwändig und ein einzelnes Kino wird diesen Aufwand weder betreiben können noch sollen. Doch die stän-

²¹ <http://sites.wiwiwiss.fu-berlin.de/suhl/bizer/d2r-server/>

dig wachsende Zahl von Ontologien, die wieder verwendet werden können – Swoogle²² allein hat mehr als 10.000 Ontologien im Index – deutet darauf hin, dass bald passende Ontologien zur Verfügung stehen werden.

Andere Datenquellen wie Amazon²³ können von diesem System auch profitieren: Die Daten, die an die verschiedenen Zielgruppen gegeben werden, sind so unter ihrer Kontrolle, und Preise und weitere Produktinformationen können dynamisch angepasst werden – auch auf den Webseiten Dritter.

Blogger wie Chrissie profitieren auch, und das mit nur wenig Aufwand. Sie kann die Webdienste in Smoov einstellen und erhält dadurch stets aktuelle Daten in ihrem Blog, und vielleicht genießt sie sogar finanzielle Vorteile, etwa durch eine Art Partnerprogramm, wie es Amazon für Links auf ihre Verkaufsseiten anbietet.

Personalisierung von Webseiten

In diesem Szenario eröffnen sich auch einige interessante Möglichkeiten zur Personalisierung. Leser von Chrissies Blog, die nicht in geographischer Nähe zu Chrissie leben, können mit dem Programm von Chrissies Lieblingskinos nur wenig anfangen. Was wäre aber, wenn Chrissies Blog Informationen von Kinos anzeigen würde, die in der Nähe des Lesers liegen oder gar von den Lieblingskinos des Lesers? Es gibt eine Reihe von Möglichkeiten, diese Idee umzusetzen.

- Smoov könnte anhand der IP des Lesers raten, wo er herkommt. Auch wenn Werbungen im Web gerne diese Form der Personalisierung verwenden, hat es eine Reihe von Nachteilen. Smoov könnte falsch liegen, oder den Ort nicht genau genug bestimmen können, um sinnvolle Daten anzuzeigen. Weiterhin ist es auch nur nützlich, um den Ort festzustellen, weitere Informationen über den Leser sind kaum erhältlich.
- Wenn Chrissie auf ihrem Blog die Möglichkeit zur Registrierung der Benutzer anbieten würde, könnte dieser in den Einstellungen seine Lieblingskinos und weitere Informationen angeben. Diese Daten könnten dann entweder über ein Cookie oder über einen Login-Mechanismus gespeichert werden. Zwar erlaubt das eine hervorragende Personalisierung, doch es macht auch Chrissies Anwendung deutlich komplizierter, weil sie nunmehr auch Konten für die Leser verwalten muss. Leser müssen sich zudem auf verschiedenen Seiten ihre Logins und Passwörter merken und potenziell häufig dieselben Informationen eingeben und warten.

²² <http://swoogle.umbc.edu/>

²³ <http://www.amazon.com>

Es verhindert auch das beiläufige und eher zufällige Wiederverwenden von Informationen, wenn zum Beispiel ein Leser über eine Suchmaschine auf Chrissies Seite stößt. Stattdessen muss er sich zuerst registrieren und seine Präferenzen eingeben, bevor er die Vorteile von Smoov wirklich nutzen kann – ein sehr umständlicher Prozess.

- Die ideale Lösung erlaubt es Smoov, Informationen über den Benutzer wiederzuverwenden, die in offenen Web-Standards beschrieben sind. In [1] wird zum Beispiel eine Infrastruktur beschrieben, die eine Erweiterung des HTTP-GET-Befehls vorsieht, um auch eine Referenz auf die FOAF-Datei [13] des Lesers an den Server mitzugeben. Die FOAF-Datei würde dann Informationen über den Ort des Lesers enthalten oder sogar direkt die bevorzugten Kinos. Das Wissen über den Leser kann von Smoov sofort wiederverwendet werden, und Smoov kann dem Leser ein angepasstes, auf ihn personalisiertes Erlebnis anbieten, ohne dass der Benutzer sich anmelden und für jede Seite ein Konto anlegen muss. Andere Möglichkeiten verwenden eine Verbindung von FOAF und OpenID,²⁴ um so eine stärkere Identifikation des Benutzers zu ermöglichen. Die FOAF-Datei kann auch auf einen persönlichen SPARQL-Dienst verweisen, was von Smoov wiederum benutzt werden kann, um weitere Informationen über den Leser zu erhalten. Dieser SPARQL-Dienst kann wiederum je nach Fragendem unterschiedlich ausführlich antworten und so eine feinere Kontrolle der Privatsphäre ermöglichen. Smoov könnte auch weitere Dienste wie revyu²⁵ [27] benutzen, um weitere Kritiken von Freunden und Bekannten des Lesers zu finden und anzuzeigen.

Diese Erweiterungen verlangen von Chrissie keinen weiteren Aufwand, aber erbringen für sie und ihre Leser sofortige Vorteile. Ihre Leser bekommen ein stark auf sie zugeschnittenes Weberlebnis angeboten. Sollte Smoov nichts über den Leser in Erfahrung bringen können, kann es stattdessen immer noch Chrissies Voreinstellungen verwenden.

Dem Web zurückgeben

Für Chrissie und ihre Leser bietet Smoov durch seine Datenintegration, Wiederverwendung und Personalisierungsmöglichkeiten deutliche Vorteile. Aber profitiert auch das Web von Chrissies semantischem Blog? Was wäre, wenn Chrissie, während sie eine Kritik über den Film schreibt und Metadaten zu ihm sammeln lässt, auch den Film auf ihrer bevorzugten Bewertungsskala bewertet? Was, wenn Smoov diese Bewertungen und

²⁴ <http://openid.net>

²⁵ <http://revyu.com>

Rezensionen exportieren und dem Semantic Web zur Verfügung stellen würde? Dies wäre ein echter Beitrag für das Semantic Web.

Das Semantic Web basiert auf einer offenen und dezentralen Infrastruktur, die den Datenaustausch mit Hilfe von einheitlichen Vokabularen und Ontologien ermöglicht. Solche Vokabulare vereinfachen den Austausch von Daten verschiedener Webseiten. Viel Potenzial ruht in der Möglichkeit, dass sich alle an einem offenen Netz aus Daten beteiligen. Entweder als Datenquellen, wie Chrissie mit ihren Kritiken, oder als Datenkonsumenten, um diese Daten zu sammeln, zusammenzufügen und an die Leser angepasst zu präsentieren – wie es Smoov macht, um weitere Daten anzuzeigen. Chrissie verwendet also Informationen aus dem Semantic Web und stellt weitere Informationen in das Semantic Web wieder ein. Andere Webseiten können dann diese Daten von vielen verschiedenen, sehr heterogenen Quellen sammeln – wie eben Chrissies Blog. Sie können aggregierte Kritiken und Bewertungen erstellen und anzeigen und auf Trends reagieren (die Blogosphäre ist üblicherweise ein deutlich schnellerer Indikator für Trends als die meisten anderen zugänglichen Quellen). Maschinenvverständliche Bewertungen ermöglichen es, Seiten wie Googles Movie Ratings²⁶ zu erstellen. Das würde auch das Erstellen von experimentellen und neuartigen Diensten wie FilmTrust²⁷ [26] ermöglichen, die von vorneherein genug Daten hätten, um sofort relevante Ergebnisse zu erzielen.

Infrastruktur

Natürlich beschreibt das Szenario im vorhergehenden Abschnitt keine reine Semantic Web Anwendung, sondern verwendet eine Reihe von weiteren Webtechnologien, und – wohl am wichtigsten – auch wichtige menschliche Beiträge. Wir glauben, insbesondere in diesem Band, dass die übermäßig maschinenorientierte KI-Sichtweise auf das Semantic Web überholt ist, und dass ein stärkerer Fokus auf Menschen und Gruppen von Menschen notwendig und gesund ist, sowohl für die Forschung aber auch für das Web als Ganzes. Diese Behauptung provoziert zwei kritische Bemerkungen:

1. „Das Szenario ist nicht realistisch, weil es wichtige Komponenten in der Infrastruktur im Hintergrund annimmt, die schlicht noch nicht verfügbar sind – dem Semantic Web fehlen noch essentielle Bestandteile um solche Szenarien zu ermöglichen“.

²⁶ <http://www.google.com/movies>

²⁷ <http://trust.mindswap.org/FilmTrust/>

2. „Das Szenario ist gar kein Semantic Web-Szenario, da es überhaupt keiner semantischen Technologien bedarf – alles, was darin beschrieben wird, kann auch mit Hilfe von XML erreicht werden.“

Im Folgenden werden wir auf diese beiden Kritiken eingehen. In diesem Abschnitt begründen wir, dass das Szenario realistisch ist. Im folgenden Abschnitt beleuchten wir die komplexen Forschungsfragen, die sich durch die Umsetzung des Szenarios ergeben werden.

Im Rest dieses Abschnitts diskutieren wir die grundlegende Semantic Web-Infrastruktur, die unser Szenario verlangt. Wir zeigen, wie diese mit den heute vorhandenen Werkzeugen umgesetzt werden kann. Wenn wir uns auf die Aufgaben des Semantic Webs konzentrieren, Daten zu teilen und wiederzuverwenden, müssen folgende Aufgaben erfüllt werden:

- **Erstellen.** Was sind die Quellen semantischer Daten?
- **Austausch.** Wie verteilt, sammelt und kombiniert man semantische Daten?
- **Wiederverwenden.** Wie setzt man semantische Daten praktisch ein?

Das Semantic Web verlangt die vollständige Umsetzung der oben gegebenen ‚Nahrungskette‘. Unser Szenario nimmt die Existenz der entsprechenden Komponenten und Diensteanbieter an.

Erstellen

Das Semantic Web verwendet eine (wachsende) Anzahl von maschinenlesbaren Datenformaten, welche die Grundlage für die semantischen Technologien bilden. Jeglicher praktische Einsatz semantischer Technologien erfordert dementsprechend die Verfügbarkeit solcher Daten. Doch im Gegensatz zum klassischen Web sind semantische Datenformate nicht einfach eine Repräsentation von nur für Menschen gedachten Multimediainhalten. Es ist oft nicht einmal klar, wie man semantische Daten dem menschlichen Benutzer überhaupt präsentieren soll. Und Daten, die Menschen kaum lesen können, geschweige denn schreiben – wo sollen die herkommen?

Einen frühen Versuch diese Frage zu beantworten stellte das FOAF-Projekt dar. Dessen Antwort war, dass viele Menschen jeweils eine kleine Menge semantischer Daten erstellen werden. Trotz des relativen Erfolgs von FOAF ist es blauäugig anzunehmen, dass dieser Ansatz das Problem der Datenerstellung lösen kann: Daten in OWL/RDF zu schreiben ist für die meisten Webbenutzer viel zu schwer. Werkzeuge wie FOAF-a-matic²⁸

²⁸ <http://www.ldodds.com/foaf/foaf-a-matic.html>

vereinfachen das erste Erstellen von FOAF-Dateien, doch das Publizieren und Warten von FOAF-Dateien ist weiterhin ein anstrengender und fehleranfälliger manueller Prozess.

Doch viele Webanwendungen basieren bereits auf einer Menge strukturierter Daten, oft in einer Datenbank verwaltet und in einem anwendungsspezifischen, proprietären Format gespeichert. Semantische Datenformate eignen sich hervorragend, solche bereits existierenden Daten zu veröffentlichen. Die Details des Exportierens dieser Daten verlangen noch nach manueller Arbeit, aber sie sind selten ein technisches Problem.

Flickr bettet RDF-Daten in ihre HTML-Seiten, um verfügbare Lizenzinformationen zu exportieren. Jedes wichtige Blogsystem bietet auf RDF basierende RSS-Feeds an. Unzählige weitere Daten, etwa Millionen von Einträgen in Bibliothekskatalogen, können auf diese Weise veröffentlicht werden. Auf der anderen Seite sieht man auch Bemühungen, das direkte Erstellen von semantischen Daten zu vereinfachen.

Beispiele hierfür sind das Semantic MediaWiki, in dem semantische Daten in einem Wiki gepflegt werden, oder die so genannten „machine tags“ in flickr,²⁹ die (RDF) Namensräume in Tags ermöglichen. Das Erstellen semantischer Daten in bestehenden Anwendungen – Blogs, Foren, Onlineverzeichnissen, etc. – kann leicht weitere semantische Datenquellen eröffnen.

Austausch

Der Austausch vorhandener Daten scheint auf den ersten Blick eine einfache Aufgabe, und in bestimmten Szenarien ist es das auch. Im Semantic Web können Daten aber auch transformiert, vereinigt und für die spätere Verwendung gesammelt werden.

Die bekannteste Aufgabe ist dabei das so genannte Mapping, das Abbilden und Übersetzen von Daten, die in verschiedenen Vokabularen beschrieben sind, in eine gemeinsame, integrierte Datenquelle, die einheitlich abgefragt werden kann. RDF vereinfacht den Austausch strukturierter Informationen, doch beschreibt es nicht die Bedeutung dieser Strukturen. Dennoch müssen Anwendungen auch die Bedeutung der Strukturen explizit und formal bearbeiten können, um sie in einer der Aufgabe angemessenen Weise zu behandeln.

Eine Lösung für dieses Problem ist der Rückgriff auf verbreitete Ontologien. Diese bestehen aus wohl spezifizierten URIs oder Begriffen und einer maschinenverarbeitbaren Menge von Axiomen, welche formalsemantisch die Beziehung zwischen den Begriffen, weitere Einschränkungen

²⁹ <http://www.flickr.com/groups/api/discuss/72157594497877875/>




Abb. 2. Yahoo! Pipes (<http://pipes.yahoo.com/>) ermöglicht Benutzern das Erstellen eigener Mash-Ups. Es verbindet erfolgreich eine moderne AJAX-basierte Web 2.0 Schnittstelle mit den Vorteilen maschinenlesbarer Datenquellen. Das Bild zeigt, wie mehrere RSS-Feeds aggregiert, sortiert, und schließlich gefiltert werden, um so einen neuen Feed zu erzeugen

und die Beziehung zu weiteren Ontologien definieren. Anwendungen, die mit einer gegebenen Ontologie umgehen können, können leicht einen Datensatz lesen, der diese Ontologie verwendet – eine Annahme, die wir in unserem Szenario gemacht haben.

Der Austausch von Daten kann weitere Vorverarbeitungsschritte erfordern. Zum Beispiel sammeln Planet Blogs³⁰ die maschinenlesbaren Feeds von vielen verschiedenen Blogs, sortieren die gesammelten Einträge nach Datum und filtern die Einträge nach dem Thema des Planet Blogs. Dadurch kann man sich von vielen Quellen gleichzeitig zu einem Thema informieren lassen. Eine vollständig anpassbare Webanwendung zum Erstellen und Verarbeiten zahlreicher Arten von Datenfeeds ist Yahoo! Pipes³¹ (siehe Abb. 2). In beiden Fällen stehen die Ergebnisse wiederum in einer Reihe von maschinenlesbaren Formaten zur Verfügung. Wir glauben, dass solche Aggregatoren im entstehenden Semantic Web eine entscheidende Rolle spielen werden, insbesondere durch das Auftauchen von mehr und mehr Ontologien und die komplexer werdenden Filter.

³⁰ <http://www.planetplanet.org/>

³¹ <http://pipes.yahoo.com/>

Wiederverwenden

Das Erstellen, Veröffentlichen und der Austausch von Daten ist nur nützlich, wenn diese Daten auch genutzt werden können. Eine große Zahl von Werkzeugen nutzen semantische Daten in der einen oder anderen Art, doch viele sind auf ein enges, akademisches Umfeld beschränkt. Zahlreiche Werkzeuge lesen und bearbeiten FOAF- und RSS-Daten (und wir können sie hier nicht alle nennen), doch zum gegebenen Zeitpunkt haben es nur RSS-Anwendungen auf den Desktop der Benutzer geschafft [52].

Beispiele von großen Anwendungen im Semantic Web umfassen semantische Suchmaschinen wie die Suchmaschine der Creative Commons³² oder Swoogle [20]. Diese Anwendungen sind vor allem deswegen interessant, weil sie neben dem einfachen Darstellen der Daten weitere Dienste anbieten und im Hintergrund komplexe technische Lösungen verwenden, um die nicht triviale Bearbeitung der Daten zu lösen.

Eine weitere wichtige Anwendung semantischer Daten ist die Kombination von Datenquellen aus dem Netz, üblicherweise als Mashup bezeichnet. Mashups werden bereits heute auf normalen HTML-Daten umgesetzt, aber diese Lösungen verlangen nach einer nicht zu unterschätzenden Menge an Programmierarbeit: Sie beruhen auf den proprietären Schnittstellen einzelner Anwendungen, reagieren empfindlich auf Änderungen dieser Anwendungen und müssen für jede Kombination einzeln umgesetzt werden. Semantische Technologien beruhen auf dem Einsatz von standardisierten Datenformaten, die über Anwendungen und Domänen hinweg gemeinsam genutzt werden können. Das Erstellen von Mashups würde viel einfacher werden. Ohne gemeinsame Datenformate wäre es unklar, wie man ein Tool wie Yahoo! Pipes hätte umsetzen können, das einfach auf diverse Datenquellen im Web zugreifen kann.

Neben den Daten, die in standardisierten Semantic Web-Formaten verfügbar sind, existieren auch Unmengen von Daten in anderen, wohl spezifizierten Formaten. Dazu gehören iCalendar [19], Atom [40], vCard [18] oder hReview [22]. Diese Standards, insbesondere die Reihe von so genannten Microformats,³³ können leicht in das RDF-Datenmodell übertragen und so in die Vision des Semantic Web integriert werden. Dasselbe gilt für Daten, die in Datenbanken enthalten sind und über das Web zugänglich gemacht werden sollen [8].

³² <http://search.creativecommons.org/>

³³ <http://microformats.org>

Nächste Schritte

Der vorhergehende Abschnitt mag den Eindruck hinterlassen haben, dass die Verwirklichung der Vision des Semantic Web nur noch eine Frage der Implementierung und der Annahme durch die Benutzer ist, und am Ende steht dann eine ausgeklügeltere Variante von RSS. Doch es ist nicht unsere Absicht, das Semantic Web darauf zu reduzieren. Wir glauben, dass semantische Technologien viele weitere Möglichkeiten mit sich bringen.

Unser Szenario soll zeigen, dass manche, bereits verfügbare Technologien angewendet werden können, wenn auch in einem eingeschränkten Szenario mit einer überschaubaren Anzahl und Auswahl von Teilnehmern. Wir möchten durchaus den Einsatz semantischer Technologien in bestimmten Bereichen vorantreiben, weil wir glauben, dass das notwendige erste Schritte zu einem vollständigen Umsetzen der großen Semantic Web Vision [6] sind. Die Vorteile semantischer Technologien müssen sich beweisen und sich in realistischen und vor allem realen Anwendungen einer breiten Öffentlichkeit eröffnen. Aber schon in dem hier gegebenen Szenario, und vor allem wenn wir darüber hinausgehen, werden sich sowohl in der Grundlagen- wie auch in der anwendungsorientierten Forschung neue Fragen und Herausforderungen zeigen. Diese offenen Forschungsfragen werden zu Schlüsselfaktoren für den Erfolg der Vision.

In diesem Abschnitt verweisen wir auf eine Anzahl viel versprechender Technologien und Forschungsthemen, von denen wir erwarten, dass sie sich in naher Zukunft für das Web als sehr wichtig erweisen werden. Wir erheben aber keinen Anspruch auf Vollständigkeit.

Ausdrucksstarke Ontologien

Leichtgewichtige Ontologiesprachen wie RDF sind oft einfacher zu verstehen und zu bearbeiten als komplexere Formalismen wie OWL, sowohl für den Menschen als auch für die Maschine. Die beeindruckenden Vorteile, die selbst einfache Sprachen mitbringen, legen schnell den Schluss nahe, dass das Semantic Web nicht mehr Ausdrucksfähigkeit benötigen wird, als es RDFS mitbringt. Allerdings haben sich mächtigere Ontologiesprachen in vielen Anwendungsbereichen als notwendig erwiesen, und es ist wahrscheinlich, dass sie auch im Web an Bedeutung gewinnen werden.

Komplexes Domänenwissen lässt sich oft nicht ohne mächtigere Ausdrucksmöglichkeiten darstellen, was in vielen praktischen Anwendungen offenbar wurde. Beispiele dafür finden sich in der Medizin (z. B. [51]) oder den Naturwissenschaften (wie etwa Projekt Halo³⁴ [25]). Doch auch in

³⁴ <http://www.projecthalo.com/>

einfacheren Beispielen sind weitere Ausdrucksmöglichkeiten häufig erwünscht. Einerseits ist das deklarative Beschreiben von Wissen essentiell um Wissensbasen abfragen zu können. Andererseits kann ontologisches Hintergrundwissen genutzt werden, um Anfragen zu vereinfachen und um Bedingungen an die Daten zu formulieren, wie sie in relationalen Datenbanken oft verwendet werden [14, 39].

Es ist offensichtlich, dass ausdrucksstarke Ontologien eine Reihe von Herausforderungen mitführen, von denen einige im Folgenden genannt werden. Ein Großteil dieser Herausforderungen wird von der derzeitigen Semantic Web-Forschung aktiv angegangen. Doch Web 2.0-Anwendungen und ihre Kombination mit semantischen Technologien können weitere Einschränkungen und Bedingungen für den Einsatz ausdrucksstarker Ontologien mit sich bringen. Zum Beispiel ist der Einsatz komplexer Ontologien in semantischen Wikis [49] vor allem auch durch die Verständlichkeit der Ontologie und ihrer automatischen Schlussfolgerungen eingeschränkt und muss durch entsprechende Schnittstellen für die Benutzer unterstützt werden.

Skalierbarkeit

Skalierbarkeit und Geschwindigkeit sind für das Semantic Web sehr wichtig, was offensichtlich wird, sobald man über ein paar wenige, semantisch annotierte Webseiten hinaus kommt. Die schiere Menge von Daten im Web ist ebenso herausfordernd wie der Wunsch nach mehr Ausdrucksmöglichkeiten. Aus technischer Sicht wird diesem Problem mit besseren und stärkeren Implementierungen begegnet. Klassische Webseiten, selbst wenn sie dynamisch sind, verlassen sich auf kontrollierte Datenquellen mit bekannten Eigenschaften bezüglich ihrer Veränderlichkeit und Antwortzeiten. Dadurch können leicht Caching-Mechanismen implementiert werden, die für die gegebenen Bedingungen optimiert sind. Wenn aber Datenquellen über das ganze Semantic Web verteilt sind und die Annahme wohl kontrollierter Datenquellen hinfällig ist, muss auch das Caching neu untersucht und umgesetzt werden, so dass es mit dem neuartigen Interaktionsmodell umgehen kann, welches von dynamischen und datengesteuerten Webseiten propagiert wird.

Auf einer grundlegenden Ebene muss der sorgfältige Entwurf mächtiger und dennoch effizient berechenbarer Ontologiesprachen weiter vorangetrieben werden. Vor kurzem führte diese Forschung zu einer Erweiterung der Ausdruckstärke von OWL DL [21] und zu der Identifizierung einer Reihe einfacher aber dennoch nützlicher Ontologiesprachen wie EL++ [3] oder RDFS++ [34].

Untersuchungen der Semantik und Komplexität von Anfragesprachen sind gleichfalls wichtige Beiträge zur Forschung (wie zum Beispiel in [2]). Im Semantic Web können Anfragen auch auf Daten aus verschiedenen Datenquellen verweisen, die auch geographisch getrennt sein können. Das Aggregieren von Daten wie auch das verteilte Beantworten einzelner Anfragen sind mögliche Ansätze um diese Probleme zu lösen.

Benutzbarkeit

Einfache Schnittstellen sowohl für den Endbenutzer wie auch für den Entwickler sind essentiell. Viele Semantic Web Werkzeuge verlangen, um benutzt zu werden, immer noch tiefer gehende Kenntnisse semantischer Technologien und derzeitiger Web-Standards. Diese hohen Anforderungen können Webentwickler leicht abstoßen oder zurückschrecken lassen. Es ist möglich – und notwendig – die Komplexität der zugrunde liegenden Technologien vor den Endbenutzern wie auch den Entwicklern zu verstecken, ganz genau so, wie die heutigen Nutzer des Webs ja auch die Feinheiten von XHTML, HTTP oder Unicode nicht verstehen oder auch nur kennen müssen. Es ist notwendig, semantische Technologie in Anwendungen so zu integrieren, dass sie eine intuitive Verwendung ermöglichen, wie es Anwendungen wie Semantic MediaWiki beispielhaft propagieren.

Semantic Web-Anwendungen burden ihren Anwendern oft das eigene interne Modell und ihre Ontologien explizit auf. Stattdessen benötigen wir ein besseres Verständnis der ‚Mensch-Semantik-Interaktion‘. Wir müssen untersuchen und verstehen, wie Menschen semantisch reiche Applikationen verwenden und die Arbeit mit den semantischen Modellen vereinfachen, die den Werkzeugen und ihren Anwendungen zugrunde liegen. Leider gibt es in diese Richtung, mit einigen wenigen Ausnahmen [7], noch zu wenig Forschung.

Eine der Stärken des Semantic Webs ist die einfache Erweiterbarkeit. Es wird ein Vokabular zur Beschreibung einer Salz und Pfeffer Streusammlung benötigt? Es gibt keine zu finden? Man kann leicht und schnell ein eigenes Vokabular erstellen. Aber eine gute Ontologie zu erstellen ist schwer, und viele Benutzer würden lieber eine Ontologie wiederverwenden als eine eigene zu erstellen. Wenn keine der vorhandenen Ontologien den Bedürfnissen der Benutzer entspricht, kann dies leicht die Qualität der semantischen Daten verschlechtern. Darum wird das einfache Erstellen, Prüfen und Bewerten von Ontologien zu einem wichtiger werdenden Forschungsbereich, als er heute ist. Es gibt erste viel versprechende Ergebnisse, wie etwa Diligent als eine Methode für das verteilte Erstellen und Warten von Ontologien [48] oder Soboleo [9], ein AJAX-basiertes Werkzeug für das gemeinschaftliche Erstellen von Ontologien.

Vertrauen und Kontrolle

Eine besondere Herausforderung verteilter Informationssysteme ist es, die Quelle einer Information zurückverfolgen zu können. Dem Benutzer erlaubt eine Kenntnis der Quellen die Entscheidung, ob er der Information vertrauen möchte, weil er der Quelle vertraut. Autoren von Inhalten können aus vielen verschiedenen Gründen daran interessiert sein, die Spur ihrer Daten verfolgen zu können. Es gibt im Allgemeinen nur wenige Möglichkeiten, um die Vertrauenswürdigkeit eines bestimmten Autors oder Konsumenten in einem offenen Web zu gewährleisten. Als Folge daraus werden Metatags in HTML, obwohl potenziell nützlich, interessant und weit verbreitet, von den Suchmaschinen eher ignoriert, weil die Vertrauenswürdigkeit dieser Informationen nicht festgestellt werden kann. Menschen hingegen sind viel besser in der Lage, vertrauenswürdige Datenquellen zu erkennen – RSS-Feeds sind ein Beispiel für die selektive Verwendung von Daten.

Die Herkunft von Daten kann entweder durch digitale Signaturen festgestellt werden, wie sie bereits breite Anwendung beim Signieren von Emails oder sicherem HTTP findet, oder durch Ketten von vertrauenswürdigen Inhaltenanbietern, die durch die Benutzer ausgewählt werden können. In beiden Fällen ist es möglich, Daten aus diesem vertrauenswürdigen Kontext zu entfernen: Benutzer können vertrauenswürdige Quellen identifizieren, aber Autoren haben keine Möglichkeit, ihre Inhalte und deren Verbreitung zu kontrollieren. Dies hat wichtige Folgen. Das Kontrollieren semantischer Daten wird sehr schwierig, und private, vertrauliche oder geheime Informationen können kaum eingesperrt werden. Dies ist auch im heutigen Web ein bekanntes Problem, doch das Herunterbrechen semantischer Daten in einzelne Axiome macht es auch unmöglich, Wasserzeichen und ähnliche Methoden zu verwenden, wie sie heute zum Beispiel bei PDFs oder MP3s verwendet werden. Auch eröffnet das ein weites Feld juristischer Fragen, die bislang noch weitgehend unbearbeitet blieben.

Datenintegration

In dem beschriebenen Szenario gingen wir davon aus, dass die Daten alle mit Hilfe einer zuvor festgelegten Ontologie beschrieben wurden, und dass alle Anwendungen in unserem Szenario diese Ontologie kennen und unterstützen. Es gibt eine Reihe von Ontologien zu bestimmten Domänen, die für verschiedene Zwecke erstellt wurden, wie zum Beispiel FOAF oder SIOC [11], und sie können in vielen Fällen für den einfachen Austausch von Daten nützlich sein. Aber in einem echten Webszenario werden zweifelsohne inhaltlich überlappende und heterogen erstellte Ontologien zum Einsatz kommen. Da aber ein reibungsfreier Austausch ein

verteiltes, gemeinsames Verständnis der betroffenen Daten verlangt, müssen die Unterschiede in den Ontologien ausgeglichen werden. Das Problem des Abbildens verschiedener Ontologien aufeinander und das Integrieren verschiedener Vokabulare (ontology alignment and mapping) ist ein aktiver Forschungsbereich im Semantic Web (Beispiele sind [23, 24, 43]). Doch es sind noch weitere Schritte nötig, um überzeugende Mappings zu erstellen. Es ist auch noch offen, wie viel mit automatischen Methoden erreicht werden kann und wie halb-automatische Verfahren den Menschen am effizientesten nutzen können.

Während korrekte Mappings das Problem des Datenaustausches angehen, wirft die Datenintegration weitere Fragen auf. Der Einsatz von Ontologien und vollständige semantische Exporte verlangen oft nach einer Erweiterung und Abwandlung des verwendeten Vokabulars. Auch wenn im Prinzip klar sein sollte, wie zwei Datenquellen integriert werden können, könnten beide Quellen die ursprüngliche Ontologie und ihre Annahmen auf nicht zusammenpassende Weise erweitert haben. Im schlimmsten Fall führt das zu logischen Inkonsistenzen, die repariert werden müssen [33], in anderen Fällen verlangt die Anwendung wenigstens nach einer vernünftigen Unterstützung der Versionierung unabhängig verwalteten semantischen Wissens [28]. Beide Probleme sind hochrelevant für das Erstellen und Warten semantischer Mashups.

Schließlich ist auch das Integrieren von Instanzdaten wichtig. Meistens sind Instanzen nicht Teil weit verbreiteter Ontologien, aber sie kommen in Anwendungen sehr zahlreich vor. Solche Daten aus verschiedenen Quellen müssen automatisch vereint werden. Dazu müssen Instanzen identifiziert werden und Konflikte bei Daten aufgelöst werden. Im Gegensatz zum Schema-Mapping sind manuelle Mappings von Instanzen durch die große Menge von Daten kaum tatsächlich durchzuführen. Zurzeit wird viel Aufwand in die Lösung dieses Problems gesteckt, und die ersten viel versprechenden Resultate konnten erreicht werden. Das Linking Open Data-Projekt³⁵ ist ein gemeinsames Projekt der Semantic Web Community, die das Ziel verfolgt, neue semantische Datenquellen zu erstellen und diese miteinander zu verbinden und Instanzen zu identifizieren.

Zusammenfassung und Ausblick

Die Ideen, die dem Semantic Web und dem Web 2.0 zugrunde liegen, werden oft als wettstreitende Visionen um die Zukunft des Webs dargestellt.

³⁵ <http://esw.w3.org/topic/SweoIG/TaskForces/CommunityProjects/LinkingOpenData>

Beide Ideen haben Communities, die eigene Annahmen, Kulturen und Schwerpunkte haben. Langsam aber wächst die Erkenntnis, dass die beiden Ideen sich ergänzen, und dass beide Communities Ideen und Technologien der anderen benötigen, um die eigenen Grenzen zu überwinden.

In diesem Kapitel haben wir gezeigt, dass einfache Szenarien im Web wie semantisches Blogging lohnenswerte Ziele für die weitere Entwicklung semantischer Technologien sind. Wir verfechten einen Paradigmenwechsel von einer übertrieben maschinenzentrierten, KI-beeinflussten Sicht auf das Semantic Web zu einem stärker benutzer- und community-zentrierten Ansatz, der stärker auf den Erkenntnissen und Ergebnissen des Web 2.0 aufbaut. Das bedeutet nicht, dass Grundlagenforschung in unserer Vision des zukünftigen Semantic Webs keine Rolle spielt – ohne ausdrucksstarke Ontologiesprachen und die damit verbundenen Techniken und Methoden gelangen wir schnell zu einem kümmerlichen Rest-Semantic Web, welches nur wenige Vorteile gegenüber dem klassischen Web mit RSS Feeds und Mikroformaten aufweist. Dies mag ein nützlicher, erster Schritt sein, doch würde er nur wenig von dem vollen Potenzial semantischer Technologien ausschöpfen.

Wir denken, dass semantische Technologien im Gegenzug hervorragend geeignet sind, um eine stabile und erweiterbare Grundlage für neue Web 2.0-Anwendungen zu bieten. Der Austausch und die kreative Wiederverwendung von Daten kann durch die Infrastruktur, die das Semantic Web bietet, unterstützt werden. Web 2.0-Projekte sollten die Gelegenheit ergreifen und die frei erhältlichen Technologien und Ergebnisse nutzen. Wenn sie zusammen und gegenseitig die erreichten Erfolge untersuchen und ihre Einsichten austauschen, können beide Communities ihre jeweiligen Visionen von der Zukunft des Webs verwirklichen – und letzten Endes gibt es ohnehin nur ein Web.

Danksagung

Mit Dank und Respekt an C.P. Snow, von dem wir den Titel ausgeliehen haben. Wir danken auch allen, die mit uns über die Ideen in diesem Kapitel diskutiert haben, was so ziemlich alle Mitarbeiter des Lehrstuhls Wissensbasierte Systeme am AIFB umfasst sowie die Gruppe Wissensmanagement am FZI. Wir möchten uns insbesondere bei Valentin Zacharias, Tom Heath und Peter Haase bedanken, für ihre sehr wertvollen und ausführlichen Reviews. Dieses Kapitel ist eine Übersetzung eines Beitrags, der zum ersten Mal auf der Konferenz WWW 2007 in Banff, Kanada vorgestellt wurde.

Literatur

1. Ankolekar, A., Vrandečić, D.: Personalizing Web surfing with semantically enriched personal profiles. In: M. Bouzid, N. Henze (eds.) *Proc. Semantic Web Personalization Workshop*. Budva, Montenegro (2006). URL <http://www.aifb.uni-karlsruhe.de/WBS/dvr/publications/swp2006.pdf>.
2. Arenas, M., Perez, J.A., Gutierrez, C.: Semantics and complexity of SPARQL. In: I. Cruz, S. Decker (eds.) *Proc. 5th International Semantic Web Conference (ISWC06)*, pp. 30–43. Athens, GA, USA (2006).
3. Baader, F., Brandt, S., Lutz, C.: Pushing the EL envelope. In: *Proc. 19th Int. Joint Conf. on Artificial Intelligence (IJCAI'05)*. Morgan-Kaufmann Publishers, Edinburgh, UK (2005).
4. Baader, F., Calvanese, D., McGuinness, D., Nardi, D., Patel-Schneider, P. (eds.): *The Description Logic Handbook: Theory, Implementation and Applications*. Cambridge University Press (2003).
5. Beged-Dov, G., Brickley, D., Dornfest, R., Davis, I., Dodds, L., Eisenzopf, J., Galbraith, D., Guha, R., MacLeod, K., Miller, E., Swartz, A., van der Vlist, E.: *RDF Site Summary 1.0* (9 December 2000). Available at <http://web.resource.org/rss/1.0/spec>.
6. Berners-Lee, T., Hendler, J., Lassila, O.: *The Semantic Web*. Scientific American 5 (2001).
7. Bernstein, A., Kaufmann, E., Göhring, A., Kiefer, C.: Querying ontologies: A controlled english interface for end-users. In: *Proc. 4th International Semantic Web Conference (ISWC05)*, pp. 112–126 (2005).
8. Bizer, C., Seaborne, A.: D2RQ – treating non-RDF databases as virtual RDF graphs. In: *Proc. 3rd International Semantic Web Conference (ISWC04)* (2004).
9. Braun, S., Schmidt, A., Zacharias, V.: Ontology maturing with lightweight collaborative ontology editing tools. In: *Proc. Workshop on Productive Knowledge Work: Management and Technological Challenges (ProKW)* (2007).
10. Bray, T., Paoli, J., Sperberg-McQueen, C.M.: *Extensible markup language (XML) 1.0* (second edition). W3C Recommendation REC-xml-20001006, World Wide Web Consortium (W3C) (2000). Available at <http://www.w3.org/XML/>.
11. Breslin, J.G., Harth, A., Bojārs, U., Decker, S.: Towards semantically-interlinked online communities. In: *Proc. 2nd European Semantic Web Conference (ESWC05)*, Heraklion, Greece, Proceedings, LNCS 3532, pp. 500–514 (2005).
12. Brickley, D., Guha, R.V.: *RDF Vocabulary Description Language 1.0: RDF Schema*. W3C Recommendation (10 February 2004). Available at <http://www.w3.org/TR/rdf-schema/>.
13. Brickley, D., Miller, L.: *FOAF vocabulary specification, revision* (2003). Available at <http://xmlns.com/foaf/0.1/>.

14. Cali, A., Kifer, M.: Containment of conjunctive object meta-queries. In: Proc. 32nd Int. Conf. on Very Large Data Bases (VLDB06), pp. 942–952. VLDB Endowment (2006).
15. Cayzer, S.: Semantic blogging and decentralized knowledge management. *Communications of the ACM* 47(12), 47–52 (2004). URL <http://www.hpl.hp.com/techreports/2004/HPL-2004-223.html>.
16. Cayzer, S.: What next for semantic blogging? Tech. Rep. HPL-2006-149, Hewlett-Packard Laboratories, Bristol, UK (2006). URL <http://www.hpl.hp.com/techreports/2006/HPL-2006-149.html>.
17. Creative Commons: „Some Rights Reserved“: Building a layer of reasonable copyright. <http://creativecommons.org>
18. Dawson, F., Howes, T.: vcard mime directory profile. RFC 2426, Internet Engineering Task Force (1998). URL <ftp://ftp.isi.edu/in-notes/rfc2426.txt>
19. Dawson, F., Stenerson, D.: Internet calendaring and scheduling core object specification (icalendar). RFC 2445, Internet Engineering Task Force (1998). URL <ftp://ftp.isi.edu/in-notes/rfc2445.txt>.
20. Ding, L., Finin, T., Joshi, A., Pan, R., Cost, R.S., Peng, Y., Reddivari, P., Doshi, V., Sachs, J.: Swoogle: A search and metadata engine for the Semantic Web. In: Proc. 13th ACM Conf. on Information and Knowledge Management, pp. 58–61 (2004).
21. (ed.), B.C.G.: OWL 1.1 web ontology language (November 2006). Available at <http://owl11.cs.manchester.ac.uk/>
22. (ed.), T.C.: hReview 0.3 (22 February 2006). Available at <http://microformats.org/wiki/hreview>.
23. Ehrig, M., Staab, S.: QOM – Quick ontology mapping. In: Proc. 3rd International Semantic Web Conference (ISWC04), pp. 683–697. Springer (2004).
24. Ehrig, M., Sure, Y.: Ontology mapping – an integrated approach. In: Proc. 1st European Semantic Web Symposium, vol. 3053, pp. 76–91. Springer (2004).
25. Friedland, N., Allen, P., Matthews, G., Witbrock, M., Baxter, D., Curtis, J., Shepard, B., Miraglia, P., Angele, J., Staab, S., Mönch, E., Oppermann, H., Wenke, D., Porter, B., Barker, K., Fan, J., Chaw, S.Y., Yeh, P., Tecuci, D., Clark, P.: Project Halo: Towards a digital Aristotle. *AI Magazine* (2004). URL <http://www.aifb.uni-karlsruhe.de/sst/Research/Publications/2004/ai-mag-pre-print04.pdf>.
26. Golbeck, J., Hendler, J.: FilmTrust: movie recommendations using trust in web-based social networks. In: Proc. IEEE Consumer Communications and Networking Conference (2006).
27. Heath, T., Motta, E.: Reviews and ratings on the semantic web. In: Poster Track, 5th International Semantic Web Conference (ISWC2006). Athens, Georgia, USA (2006).
28. Heflin, J., Pan, J.Z.: A model theoretic semantics for ontology versioning. In: Third International Semantic Web Conference, pp. 62–76. Springer, Hiroshima, Japan (2004).
29. Hustadt, U., Motik, B., Sattler, U.: Reducing SH IQ– description logic to disjunctive datalog programs. In: Proc. of KR2004, pp. 152–162. AAAI Press (2004).

30. Kalyanpur, A., Parsia, B., Sirin, E., Hendler, J.: Debugging unsatisfiable classes in OWL ontologies. *Journal of Web Semantics* 3 (2005).
31. Karger, D.R., Quan, D.: What would it mean to blog on the semantic web? In: S.A. McIlraith, D. Plexousakis, F. van Harmelen (eds.) *Proc. 3rd International Semantic Web Conference (ISWC04)*, Hiroshima, Japan, pp. 214–228. Springer (2004).
32. Knublauch, H., Fergerson, R.W., Noy, N.F., Musen, M.A.: The Protege OWL plugin: An open development environment for SemanticWeb applications. In: *Proc. 3rd International Semantic Web Conference (ISWC04)*. Springer (2004).
33. Lam, J., Pan, J.Z., Sleeman, D., Vasconcelos, W.: A fine-grained approach to resolving unsatisfiable ontologies. In: *Proc. of the 2006 IEEE/WIC/ACM International Conference on Web Intelligence (WI-2006)* (2006).
34. Lassila, O.: Identity crisis and serendipity (May 2006). Available at <http://www.lassila.org/publications/2006/IdentityCrisisAndSerendipity.pdf>.
35. Maedche, A., Motik, B., Stojanovic, L.: Managing multiple and distributed ontologies in the Semantic Web. *VLDB Journal* 12(4), 286–302 (2003). URL <http://www.fzi.de/KCMS/kcms file.php?action=link&id=158>.
36. Manola, F., Miller, E.: Resource Description Framework (RDF) primer. W3C Recommendation (10 February 2004). Available at <http://www.w3.org/TR/rdf-primer/>.
37. Marlow, C., Naaman, M., Boyd, D., Davis, M.: HT06, tagging paper, taxonomy, flickr, academic article, to read. In: *Proc. 17th Conf. on Hypertext and Hypermedia (HYPERTEXT'06)*, pp. 31–40 (2006). URL <http://doi.acm.org/10.1145/1149941.1149949>.
38. Mika, P.: Ontologies are us: A unified model of social networks and semantics. In: *Proc. 4th International Semantic Web Conferences (ISWC05)*, pp. 522–536 (2005).
39. Motik, B., Horrocks, I., Sattler, U.: Integrating description logics and relational databases (Dec 6, 2006). Technical Report, University of Manchester, UK.
40. Nottingham, M., Sayre, R.: The atom syndication format. RFC 4287, Internet Engineering Task Force (2005). URL <ftp://ftp.isi.edu/in-notes/rfc4287.txt>.
41. O'Reilly, T.: What is Web 2.0 – design patterns and business models for the next generation of software (2005). Available at <http://www.oreillynet.com/pub/a/oreilly/tim/news/2005/09/30/what-is-web-20.html>.
42. Oren, E., Delbru, R., Decker, S.: Extending faceted navigation for rdf data. In: I. Cruz, S. Decker (eds.) *Proc. 5th International Semantic Web Conference (ISWC06)*, pp. 559–572 (2006).
43. Pan, R., Ding, Z., Yu, Y., Peng, Y.: A Bayesian network approach to ontology mapping. In: *Proc. 4th International Semantic Web Conference (ISWC05)* (2005).
44. Seaborne, A., Prud'hommeaux, E.: SPARQL query language for RDF. Tech. Rep. <http://www.w3.org/TR/2006/CR-rdf-sparql-query-20060406/>, W3C (2006).
45. Seidenberg, J., Rector, A.: Web ontology segmentation: Analysis, classification and use. In: *Proc. 15th Int. Conf. on World Wide Web (WWW 2006)*, Edinburgh, Scotland, May 23–26 (2006).

46. Smith, M.K., Welty, C., McGuinness, D.: OWL Web Ontology Language Guide (2004). W3C Recommendation 10 February 2004, available at <http://www.w3.org/TR/owl-guide/>.
47. Sure, Y., Staab, S., Studer, R.: On-to-knowledge methodology. In: S. Staab, R.S. (eds.) (eds.) Handbook on Ontologies, Series on Handbooks in Information Systems, chap. 6, pp. 117–132. Springer (2003). URL <http://www.aifb.uni-karlsruhe.de/WBS/ysu/publications/2003ontohandbookotkmethodology.pdf>.
48. Tempich, C., Pinto, H.S., Sure, Y., Staab, S.: An argumentation ontology for distributed, loosely-controlled and evolving engineering processes of ontologies (DILIGENT). In: Proc. 2nd European Semantic Web Conference (ESWC05), LNCS 3532, pp. 241–256. Springer (2005).
49. Vrandečić, D., Krötzsch, M.: Reusing ontological background knowledge in semantic wikis. In: Proceedings of 1st Workshop „From Wiki to Semantics“ (SemWiki’06) (2006).
50. Vrandečić, D., Pinto, H.S., Sure, Y., Tempich, C.: The DILIGENT knowledge processes. Journal of Knowledge Management 9(5), 85–96 (2005). URL http://www.aifb.uni-karlsruhe.de/WBS/ysu/publications/2005_kmjournal_diligent.pdf.
51. Wolstencroft, K., Lord, P., Taberner, L., Brass, A., Stevens, R.: Using ontology reasoning to classify protein phosphatases. 8th Annual Bio-Ontologies Meeting 2005 24 (2005).
52. Zacharias, V., Sibler, M.: Semantic announcement sharing. In: Proc. Fachgruppentreffen Wissensmanagement (2004).

II Technologien und Methoden

7. Wissensmodellierung im Semantic Web

Barbara Geyer-Hayden

howknow, Mattersburg, Österreich;
barbara.geyer-hayden@howknow.at

Zusammenfassung: Wir sind sowohl in unserem „offline“ als auch in unserem „online“ Alltag von einer Vielzahl von Wissensorganisationssystemen umgeben. Die Komplexität dieser Systeme steigt mit dem Umfang und der Heterogenität der Informationen, die (wieder)gefunden werden sollen. In diesem Beitrag werden unterschiedliche Wissensorganisationssysteme beschrieben und gegenübergestellt. Für die Modellierung dieser Systeme wird ein generisches Verfahren vorgestellt, das für alle geschilderten Wissensorganisationssysteme geeignet ist. Ergänzt wird diese Methode durch die Darstellung der persönlichen Nutzung von Wissensorganisationssystemen.

Einleitung

In unserem täglichen Umfeld schaffen und nutzen wir täglich Systeme, mit deren Hilfe Dinge geordnet werden, um sie wiederauffindbar zu machen. Im privaten Umfeld ordnen wir unsere Bücher, z. B. nach Themen, nach Farben oder Größen. Wir ordnen Dateien, Wäsche, Werkzeug, usw.

Ordnungssysteme werden immer dann eingesetzt, wenn man unter vielen ähnlichen Objekten ein einzelnes wiederfinden will. Im beruflichen Umfeld, das meist sehr stark spezialisiert ist und in dem daher mehr ähnliche Objekte auftreten, sind komplexe Ordnungssysteme bei weitem häufiger im Einsatz als im privaten. Mit der elektronischen Erstellung und Verwaltung von Inhalten steigen die Anzahl der gespeicherten Objekte stetig und damit auch der Einsatz von immer komplexeren Ordnungssystemen.

Die ersten Systeme zur Organisation von Informationen wurden in Organisationen entwickelt, die die Aufgabe hatten eine Vielzahl von ähnlichen Objekten zum Zweck der Wiederauffindbarkeit zu bewahren. Sie

wurden entwickelt, um Gesetzestexte und Bücher in Bibliotheken und Archiven zu verwalten.

Diese Wissensorganisationssysteme, wie z. B. Klassifikationen und Thesauri, werden bis heute für die Organisation von digitalen Inhalten genutzt. Selbst die meisten Ontologien gehen zurzeit oft nicht über die Funktionen eines Thesaurus hinaus. Das kann zwar teilweise damit erklärt werden, dass bereits die Erstellung eines Thesaurus aufwändig ist, nutzt jedoch nicht die vorhandenen Möglichkeiten aus.

Daher wird in diesem Beitrag sowohl auf die gegenwärtig meist eingesetzten Wissensorganisationssysteme eingegangen als auch auf die Möglichkeiten, die neue Technologien gegenwärtig und für die Zukunft bieten. Ein Schwerpunkt liegt dabei auf der Erstellung, d. h. Modellierung von Wissensorganisationssystemen. Für den Leser kann dieser Beitrag auch als Leitfaden zur Auswahl und Modellierung eines Wissensorganisationssystems dienen.

Sobald eine Anwendung entwickelt wird, wird auch ein System modelliert, mit dem Benutzer Inhalte finden (sollen). Ein nicht benutzerfreundliches System zur Wissensorganisation führt dazu, dass die Benutzer Inhalte nicht finden (bzw. nicht kaufen können) und Anwendungen weniger nutzen.

Wissensorganisationssysteme

Das Ziel der Wissensorganisation ist, dass Wissensordnung, Retrieval (das Wiederfinden von Informationen) und Navigation innerhalb einer Anwendung optimal funktionieren. Um dieses Ziel zu erreichen, werden Wissen, Dokumente und Benennungen analysiert und modelliert.

Wissensorganisationssysteme sind strukturierte Darstellungen von Metadaten (Informationen über Informationen). Das können beschreibende, beinhaltende oder verwaltende Metadaten sein:

- Beschreibende Metadaten sind Informationen über den Inhalt des Gegenstandes, z. B. ein Artikel zum Thema Social Semantic Web.
- Beinhaltende Metadaten des Objektes sind z. B. das Format (pdf).
- Verwaltende Metadaten sind Informationen zum Umgang mit dem Gegenstand z. B., dass es sich um ein temporäres Dokument des Autors Maier handelt, das nicht publiziert wird.

Jede Anwendung, in der Informationen wiederauffindbar sein sollen, besteht einerseits aus den Komponenten Speicherung und Organisation sowie dem Retrieval. Die Qualität der Ergebnisse einer Suchanfrage hän-

gen insbesondere von der Aufbereitung und Organisation mit Wissensorganisationssystemen ab.

Hinter jedem Wissensorganisationssystem steht eine Sichtweise auf das abzubildende Gebiet. Derselbe Begriff kann unterschiedlich beschrieben werden, je nach Standpunkt der modellierenden Person(en). Weitere Details und Beispiele dazu finden Sie in Lakoff [11] und Bowker und Leigh [1].

Wenn die Benutzer Informationen (wieder)finden sollen, muss dem System eine Struktur zugrunde liegen, die der Sichtweise der User für dieses Gebiet entspricht. Das beinhaltet die Verwendung von Begriffen, die Benutzer mit Konzepten aus ihrer Erfahrungswelt in Zusammenhang bringen können.

Ordnungstypen

Einige Prinzipien zur Organisation von Informationen gelten für alle Systeme, mit denen Objekte organisiert werden [13], das betrifft das eigene Bücherregal genauso wie eine Social Web Applikation.

Das sind die Ordnungstypen Alphabet, Kategorie, Ort (Geographie), Zeit und Hierarchie. Beispiele aus dem täglichen Umfeld sind:

- alphabetisch – z. B. für Wörterbücher, Adressbücher, ...
- kategorisch – z. B. für Enzyklopädien, Gruppierungen, ...
- geographisch – z. B. für Reiseführer, Atlanten, ...
- zeitlich – (wenn die Abfolge wichtig ist) z. B. für Anleitungen, Witze, Geschichten, ...
- hierarchisch – um Informationen z. B. vom Besten zum Schlechtesten, vom Größten zum Kleinsten, vom Teuersten zum Günstigsten, ... zu ordnen.

Auf diesen Ordnungstypen basieren die unterschiedlichen Wissensorganisationssysteme.

Relationstypen

Die Ordnungstypen stellen unterschiedlichen Optionen für die Art von Beziehungen dar. Daneben können folgende unterschiedliche Relationstypen innerhalb eines Wissensorganisationssystems unterschieden werden:

- gleichbedeutende Relationen (alphabetisch, geographisch, chronologisch)
- hierarchische Relationen
- assoziative Relationen

Diese Relationstypen sind für die Komplexität eines Wissensorganisationssystems entscheidend. Je nach Nutzung der unterschiedlichen Relationstypen können verschiedenen Gruppen von Wissensorganisationssystemen unterschieden werden:

1. *gleichbedeutende Relationen*: Begriffslisten
2. *gleichbedeutende* + *hierarchische Relationen*: Klassifikationen und Kategorien
3. *gleichbedeutende* + *hierarchische* + *assoziative Relationen*: Relationssysteme

Die folgende Darstellung stellt diesen Zusammenhang grafisch dar:




Abb. 1. Relationstypen und Wissensorganisationssysteme

Wissensorganisationssysteme werden mit der Anzahl der genutzten unterschiedlichen Relationstypen komplexer zu erstellen und zu bedienen.

Die Nutzung eines zusätzlichen Relationstyps führt immer zu einem erhöhten Grad an Komplexität. Jeder weitere Relationstyp ergänzt nur die weniger komplexen Relationstypen, ersetzt sie jedoch nicht. Bei der Erstellung einer Klassifikation arbeitet man z. B. nicht nur mit hierarchischen sondern auch mit gleichbedeutenden Relationen. Relationssysteme beinhalten alle Relationstypen gleichzeitig.

Im folgenden Abschnitt werden die bekanntesten Wissensorganisationssysteme beschrieben. Die Einteilung in Begriffslisten, Klassifikationen und Kategorien sowie Relationssystemen basiert auf Hodge [9].

Begriffslisten

Begriffslisten sind eine Sammlung von Bezeichnungen, die ein Objekt oder eine Sammlung von Objekten beschreiben. Zur Organisation dieser Begriffe werden gleichbedeutende Relationen genutzt.

Glossare

In Glossaren werden Begriffe, deren Bedeutungen erklärt werden, alphabetisch gereiht. Sie sind Teile von Büchern oder eigenständige Publikationen, Teile von Websites oder eigenständige Websites¹, können aber auch als Teile von anderen Wissensorganisationssystemen eingesetzt werden.

Wörterbücher und Ortsnamenverzeichnisse

Sind spezielle Formen von Begriffslisten. Wörterbücher listen Begriffe und deren Übersetzung in eine Fremdsprache alphabetisch auf. Ortsnamenverzeichnisse² ordnen Orte geographisch.

Stichwort- und Schlagwortsysteme

Stichwort- und Schlagwortsysteme sind alphabetisch gereichte Begriffslisten, die für die Beschreibung von Dokumentensammlungen zum Einsatz kommen. Sie sind oft grammatikalisch normiert, z. B. werden meist nur Begriffe im Singular oder Plural verwendet. Stichwortlisten nutzen ausschließlich Begriffe, die auch im jeweiligen Dokument vorkommen. Daher kommen Schlagwortlisten, mit Begriffen, die den Inhalt eines Dokumentes beschreiben, diesen aber nicht entnommen sein müssen, weitaus häufiger vor.

Folksonomy

Eine Folksonomy³ ist das Ergebnis der Beschlagwortung (tagging) von Webseiten durch viele Benutzer. Die Benutzer vergeben Schlagwörter (Tags) innerhalb eines sozialen Umfeldes, in dem Sie auch die bisher vergebenen Schlagwörter der anderen Benutzer für diese Website sehen. Das führt zur häufigeren Vergabe von gleichlautenden Schlagwörtern. Die Be-

¹ Siehe dazu z. B.: http://europa.eu/scadplus/glossary/index_en.htm, aufgerufen im Januar 2008

² Siehe dazu z. B.: <http://www.avotaynu.com/books/Kredel.htm>, aufgerufen im Januar 2008

³ Der Begriff wurde von Thomas Vander Wal geprägt. Siehe dazu auch: <http://www.vanderwal.net/folksonomy.html>, aufgerufen im Januar 2008

nutzer verwenden die vergebenen Tags um Webseiten (wieder) aufzufinden. Die Darstellung der Folksonomy erfolgt meist über eine „Tagcloud“, d. h. die vergebenen Schlagwörter werden mit zunehmender Häufigkeit mit größerer und mit stärkerer Schrift dargestellt.⁴ In einigen Anwendungen werden die „Tags“ bereits geclustert⁵, wodurch eine einfache Form eines hierarchischen Ordnungssystems entstehen kann.

Eine Folksonomy hat Eigenschaften, die von anderen Wissensorganisationssystemen explizit vermieden werden. Sie sind unkontrolliert und chaotisch, nicht präzise und mehrdeutig. Keine Instanz legt fest, welche Schlagwörter verwendet werden dürfen. Im Sinne dieser Kriterien sind Folksonomies keine „echten“ Wissensorganisationssysteme, aber sie werden von den Benutzern als solche verwendet.

Andererseits können mit einer Folksonomy Ansprüche realisiert werden, die traditionelle Wissensorganisationssysteme nicht leisten können. Sie ermöglichen es den Benutzern, eigene Schlagwörter zu vergeben und damit Informationen selbst zu organisieren. Bei der Erstellung sind die User in jeder Phase mit einbezogen, sie steuern diesen Prozess sogar.

Die Erstellung von Metadaten und damit auch von Wissensorganisationssystemen erfolgte in der Vergangenheit immer von einer kleinen Gruppe von Spezialisten. Tagging hingegen ist eine gemeinsame, kommunikative Tätigkeit. Die Kombination einer Folksonomy mit anderen Wissensorganisationssystemen, sowohl im Erstellungsprozess als auch in der Erweiterung und Wartung, wird neue Systeme zur Wissensorganisation hervorbringen. Das wird besonders in folgendem Zitat deutlich:

„What can happen if we combine the best ideas from the Social Web and the Semantic Web? The Social Web is an ecosystem of participation, where value is created by the aggregation of many individual user contributions. The Semantic Web is an ecosystem of data where value is created by the integration of structured data from many sources“ [7].

Klassifikationen und Kategorien

Die Einteilung von Objekten mit einer gemeinsamen Eigenschaft in Klassen und die Anordnung dieser Klassen in hierarchischer Form hat eine lange Tradition.

⁴ Siehe dazu z. B.: <http://del.icio.us/tag/>, aufgerufen im Januar 2008

⁵ Siehe dazu z. B.: <http://www.flickr.com/photos/tags/knowledge/clusters/>, aufgerufen im Januar 2008

Stichwort- und Schlagwortsysteme mit hierarchischen Ordnungselementen

Ein einfaches System zur Einteilung in Kategorien sind Schlagwortlisten mit hierarchischen Ordnungselementen. Das sind z. B. die meisten Navigationsleisten. Trotz der begrenzten vertikalen Tiefe dieses Wissensorganisationssystems können Schlagwortlisten jedoch auch umfangreich und detailliert sein.⁶

Klassifikationen/Taxonomien

Die Begriffe Klassifikation und Taxonomie werden häufig für dieselben Systeme verwendet. In diesen Wissensorganisationssystemen werden Begriffe nach gemeinsamen Merkmalen in Gruppen eingeteilt. Ein Begriff hat dabei einen Oberbegriff, kann aber auch Oberbegriff für andere Begriffe sein. Einige Klassifikationen erlauben eine polyhierarchische Struktur, d. h. dass ein Begriff mehrere Oberbegriffe haben kann.

In traditionellen Klassifikationen werden oft Nummern und/oder Buchstaben als Notationen für Klassen eingesetzt. In Bibliotheken sind eine Reihe von umfassenden Klassifikationen, zum Teil weltweit⁷, im Einsatz.

Relationssysteme

Relationssysteme sind im Vergleich mit anderen Wissensorganisationssystemen weit komplexer. Sie bieten jedoch auch mehr Möglichkeiten zur Abbildung von unterschiedlichen Beziehungstypen.

Thesaurus

Ein Thesaurus enthält eine systematische Sammlung von Begriffen, zwischen denen auch assoziative (thematische) Beziehungen hergestellt werden. Was ein Thesaurus ist und welche Beziehungstypen in diesem Rahmen erlaubt sind, ist durch Normen (ISO 2788, BS 5723, ANSI/NISO Z39/19) reglementiert.

⁶ Siehe dazu z. B.: <http://www.nlm.nih.gov/mesh/MBrowser.html>, aufgerufen im Januar 2008

⁷ Die international am weitesten verbreitete Universalklassifikation ist die Dewey-Dezimalklassifikation (DDC). Siehe dazu auch: <http://www.ddc-deutsch.de/produkte/uebersichten/index.htm>, aufgerufen im Januar 2008

Ein Thesaurus zur Dokumentation enthält eindeutige Benennungen, die auch als Deskriptoren bezeichnet werden, für jeden Begriff. Abkürzungen, Übersetzungen, unterschiedliche Schreibweisen und Synonyme (Wörter, die dieselbe oder beinahe dieselbe Bedeutung wie ein anderes Wort haben) werden durch Äquivalenzrelationen miteinander in Beziehung gesetzt.⁸

Semantische Netze

Semantische Netze strukturieren Begriffe nicht in einer Hierarchie sondern als Netzwerk. Begriffe werden dabei als Knoten verstanden, die durch beliebige Beziehungen miteinander verbunden sind. In vielen Fällen kann in semantischen Netzwerken grafisch navigiert werden.

Ontologien

Der Ontologiebegriff wird – nicht zuletzt aufgrund seiner erkenntnistheoretischen „Überladung“ – sehr unterschiedlich verwendet.

„In the context of computer and information sciences, an ontology defines a set of representational primitives with which to model a domain of knowledge or discourse. The representational primitives are typically classes (or sets), attributes (or properties), and relationships (or relations among class members). The definitions of the representational primitives include information about their meaning and constraints on their logically consistent application.“⁹[8].

Ontologien können mächtige Werkzeuge, und zwar nicht nur zur Modellierung, sein. In der Praxis wurden Ontologien jedoch bereits als Klassifikationen, Thesauri, Wörterbücher usw. realisiert [10]. Für die Modellierung gibt es keinen offiziellen Standard. Das W3C (World Wide Web Consortium) hat aber Empfehlungen für Notationen herausgegeben.

Wissensmodellierung im Semantic Web

Wissensorganisationssysteme werden vor allem erstellt um Inhalte für Benutzer leichter (wieder)auffindbar zu machen. Weitere Gründe für das

⁸ Siehe dazu z.B. auch: <http://databases.unesco.org/thesaurus/>, aufgerufen im Januar 2008

⁹ Siehe dazu z. B. auch: <http://www.plantontology.org/docs/otherdocs/pocproject.html>, aufgerufen im Januar 2008

Modellieren eines Wissensorganisationssystems sind die Analyse des expliziten Wissens, eines Gebietes und die Abgrenzung dieses Wissens. Im Laufe der Erstellung wird ein gemeinsames Verständnis über die Struktur des behandelten Gebietes entwickelt.

Wissensmodellierung im Semantic Web bedeutet Informationen über Inhalte (Metadaten) so zu modellieren, dass sie eindeutig referenzierbar und maschinenverstehbar sind.

Die Herstellung von Eindeutigkeit erfolgt über so genannte Universal Resource Identifier (URIs), welche sicherstellen, dass ein Datenobjekt eindeutig referenziert werden kann und es zu keiner Verwechslung zwischen zwei Datenobjekten kommt, die zufällig die selbe Bezeichnung (Label) haben, wie etwa „Jaguar“ als Tier oder als Automarke. Bekannte URIs sind entsprechend Autonummern für Kraftfahrzeuge, ISBN-Nummern für Publikationen oder Sozialversicherungsnummern für Personen. Im Web erfolgt die Herstellung von Eindeutigkeit über Universal Resource Locators (URLs), die als persistente Identifikatoren für Dokumente (Web-Seiten) dienen, jedoch auch auf die Datenebene ausgedehnt werden können.¹⁰

Die Maschinenverarbeitbarkeit wird durch die Verwendung einer einheitlichen Datenbeschreibungssyntax gewährleistet. Die beiden bekanntesten Spezifikationen sind RDF und OWL.

RDF

RDF (**R**esource **D**escription **F**ramework) ist eine Spezifikation um Inhalte im Web zu beschreiben. Mittels RDF können Webseiten mit maschinenlesbarer Informationen über Inhalte (Metadaten) angereichert werden z. B. Titel, Autor, Änderungsdatum, Copyright Informationen, Informationen über den Inhalt, usw.

RDF setzt auf XML auf; die Sprache, die von RDF verwendet wird, ist RDF/XML. Daher können RDF Informationen einfach zwischen Computern ausgetauscht werden. RDF wurde erstellt um von Maschinen und nicht von Personen gelesen zu werden. Deshalb werden diese Informationen auch nicht für User im Web sichtbar dargestellt.

Sie können als Graph (RDF-Modell) oder als XML (RDF-Syntax) dargestellt werden. Komplexere Beziehungen zwischen Quellen werden durch das RDF-Schema beschrieben.

¹⁰ Im Semantic Web muss also hinter einer URL nicht notwendigerweise ein Dokument liegen, was bei Neulingen in der Thematik nicht selten gehörige Verwirrung hervorruft.

Aussagen über Inhalte werden im RDF-Modell mittels eines *Subjekt-Prädikat-Objekt-Schemas* zum Ausdruck gebracht. Eine Aussage im Semantic Web wird auch als Triple bezeichnet. Das *Subjekt* ist der Gegenstand der Beschreibung. Die Beziehung zwischen Subjekt und Objekt wird durch das *Prädikat* beschrieben. Das *Objekt* ist der Wert des Merkmals.

Ein Beispiel als RDF als Satz ausgedrückt:

Subjekt:

„<http://www.springer.com/computer/database+management+&+information+retrieval/book/978-3-540-72215-1>“

Prädikat:

hat Herausgeber

Objekt:

<http://www.semantic-web.at/1.6191.resource.1745.tassilo-pellegrini.htm>
und
<http://www.semantic-web.at/1.6191.resource.6.andreas-blumauer.htm>

Dieselbe Aussage kann auch in einem RDF-Graph dargestellt werden:



Abb. 2. Beispiel für einen RDF-Graph

Die einzelnen Ressourcen können und sollen mit einer URI (Uniform Resource Identifier), d. h. der einheitlichen Bezeichnung einer Ressource, dargestellt werden.

RDF ist seit dem Februar 2004 eine W3C (World Wide Web Consortium) Empfehlung. Die offizielle W3C Empfehlung ist unter folgendem Link abrufbar: <http://www.w3.org/RDF/>.

Dieser Standard dient als Grundlage für das Semantic Web. Mit ihm können Inhalte im Web eine maschinenlesbare Bedeutung erhalten. Das Ziel ist, dass Computer Informationen aus dem Web verarbeiten können.

OWL

Eine weitere formale Beschreibungssprache im Semantic Web ist OWL (**Web Ontology Language**). Sie dient zur Erstellung von komplexeren Ontologien.

Sowohl OWL als auch RDF wurden zur Realisierung des Semantic Web konzipiert, beide dienen dazu Inhalte maschinenlesbar zu machen und sind W3C Empfehlungen. OWL basiert technisch auf der RDF-Syntax.

Aber OWL geht über die Ausdrucksmöglichkeiten von RDF weit hinaus. Mit Ontologien kann ein gesamtes Umfeld und die Bedeutung der verwendeten Begriffe definiert werden. Maschinen benötigen diesen definierten Kontext aus Begriffen um Daten interpretieren zu können. Zu diesem Zweck gibt es unterschiedliche Versionen von OWL: OWL Lite (für einfache Ordnungssysteme), OWL DL (für maximale Beschreibungslogik, deren Ausdrücke von einer Maschine in einem klar definierten Zeitfenster prozessiert werden kann und dadurch *noch* maschinenverarbeitbar ist) und OWL Full (für maximale Beschreibungsmöglichkeiten, die aber nicht vollständig maschinenverarbeitbar sind, da die Berechnung unendlich lange dauern würde).

In OWL wird zwischen Klassen, Eigenschaften und Individuen unterschieden. Klassen stehen für Begriffe (z. B. <Autor>), sie können Eigenschaften besitzen (z. B. <Geschlecht> mit der Ausprägung <männlich>) und diese können konkreten Individuen zugeordnet werden (z. B. <Tassilo Pellegrini>). Durch Schlussfolgerungen können in einer Ontologie Zugehörigkeiten ermittelt werden.

Phasen der Wissensmodellierung

In der Literatur werden unterschiedliche Vorgehensweisen zur Modellierung von Wissensorganisationssystemen vorgeschlagen [12; 2; 6] und teilweise auch verglichen [5].

Die hier vorgestellte Vorgehensweise ist im Gegensatz dazu ein generischer Ansatz, der für alle vorgestellten Typen von Wissensorganisationssystemen geeignet ist. Diese Methode erfordert vor Beginn der Modellierung keine Entscheidung für ein bestimmtes Wissensorganisationssystem, da dies im Rahmen des vorgeschlagenen Verfahrens erfolgt.

Die einzelnen Schritte der Vorgehensweise gliedern sich, wie in Abb. 2 dargestellt, in 10 Phasen:




Abb. 3. Phasen der Wissensmodellierung

Die Phasen 1 bis 3 sowie 8 bis 10 sind für die Modellierung von allen Wissensorganisationssystemen relevant. Die Phasen 4 bis 7 sind für unterschiedliche Systeme von Bedeutung (siehe dazu den Punkt „Erste Spezifizierung des Wissensorganisationssystems“ sowie Abb. 3).

Rahmen, Zweck und Umfang eingrenzen

Als erster Schritt der Modellierung sind Rahmen, Zweck und Umfang des Wissensorganisationssystems einzugrenzen. Dazu ist die Beantwortung einer Reihe von Fragen erforderlich. Die Antworten werden je nach Projekt unterschiedlich umfangreich ausfallen.

Kontext:

- Warum wird das Wissensorganisationssystem erstellt? Welche expliziten und impliziten Ziele werden damit verfolgt?
- Welche personellen Kapazitäten stehen für die Modellierung des Systems zur Verfügung (zeitlich und fachlich)?
- In welchem Zeitraum soll das Wissensorganisationssystem erstellt werden?
- Welche technologische Infrastruktur steht für die Umsetzung des Wissensorganisationssystems zur Verfügung? Welche Vorgaben ergeben sich daraus für ein Tool zur Modellierung und für die Integration des Wissensorganisationssystems?
- Welche vom Auftraggeber vorgegeben Rahmenbedingungen sind weiters zu beachten?

Benutzer:

- Wer sind die potentiellen Benutzer des Systems?
- Welche (unterschiedlichen) Benutzergruppen sollen das Wissensorganisationssystem benutzen (die Definition eines prototypischen Benutzers pro Benutzergruppe hat sich zur Diskussion dieser Punkte bewährt)? Welche Daten (Alter, Geschlecht, Beruf, usw.) liegen zu diesen Benutzergruppen vor?

Inhalt:

- Welche Arten von Dokumenten sollen erschlossen werden (Struktur der Dokumente und Dateitypen)?
- Welchen Umfang haben die zu erschließenden Dokumente (Anzahl, Länge der Dokumente und Speicherkapazität)?
- Wie schnell ist der Dokumentenbestand bisher gewachsen? Welches Wachstum des zu erschließenden Dokumentenbestandes ist zu erwarten?
- Wer hat diese Dokumente erstellt? Gibt es für die Verwendung der Dokumente rechtliche Einschränkungen?

Vokabular:

- In welcher Form sind diese Dokumente bisher erschlossen? Gibt es bereits Metadaten (auch Tags) zu diesen Dokumenten?
- Was sind die inhaltlichen Schwerpunkte und Randgebiete dieser Dokumentenbasis? Welche Inhalte sollen nicht modelliert werden?

- Wie spezifisch soll das Wissensorganisationssystem werden? Wie allgemein oder spezifisch sollen die verwendeten Begriffe sein?
- In welchem Sprachstil soll das Wissensorganisationssystem erstellt sein (z. B. wissenschaftlich oder für Laien verständlich)?
- Wie viele Begriffe werden voraussichtlich für die Beschreibung dieser Dokumente erforderlich sein (von – bis Schätzung)?
- Welche Arten von Relationen sollen zwischen den Begriffen voraussichtlich hergestellt werden (gleichbedeutend, hierarchisch, assoziativ)?

Erste Spezifizierung des Wissensorganisationssystems

Mit der Festlegung auf unterschiedliche Relationstypen erfolgt auch automatisch die Festlegung auf einen Typ von Wissensorganisationssystem (siehe dazu auch Abb. 1).

- Ausschließlich alphabetische Relationen: z. B. Glossare, Wörterbücher, Stichwort- und Schlagwortsysteme.
- Ausschließlich geographische Relationen: z. B. Ortsnamenverzeichnisse.
- Ein nicht definierter Relationstyp: Folksonomy.




Abb. 4. Phasen der Wissensmodellierung für unterschiedliche Typen von Wissensorganisationssystemen

- Gleichbedeutende und hierarchische Relationen: Stichwort- Schlagwort-systeme mit hierarchischem Ordnungselement (z. B. Navigationsleiste) sowie Klassifikationen/Taxonomien.
- Assoziative Relationen: Thesaurus, semantische Netze und Ontologien.

In diesem Schritt sollte festgelegt werden, ob eine Begriffsliste, eine Klassifikation oder Kategorien oder ein Relationssystem modelliert werden sollen.

Wenn ein komplexeres Wissensorganisationssystem (Klassifikation oder Relationssystem) umgesetzt werden soll, kann die Entscheidung für ein konkretes System auch erst in Schritt 5 (Relationstyp festlegen) getroffen werden (siehe dazu auch Abb. 4 zu den Unterschieden zwischen den verschiedenen komplexen Systemen).

Abbildung 4 stellt die Relevanz der nächsten Phasen für die Erstellung der jeweiligen Wissensorganisationssysteme dar.

Wörter (auch aus bestehenden Modellen) sammeln

Für jedes zu erstellende Wissensorganisationssystem gibt es Vokabulare, die wiederverwendet werden können. Abhängig von gewünschtem Umfang, Sprachstil und Detaillierung kann auf folgende Quellen zurückgegriffen werden:

- Metadaten von Dokumenten
- Struktur (Navigationsleiste, Sitemap) von Webseiten
- bestehende Wissensorganisationssysteme (Klassifikationen, Thesauri und Ontologien aber auch eine Folksonomy)
- Statistisches Material zum Gegenstand
- Lehrbücher und Standardwerke
- Aktuelle Fachliteratur (und die darin vergebenen Schlagwörter)
- Register von Fachzeitschriften
- Nationale und internationale Fachwörterbücher und Normen
- Befragung von potentiellen Benutzern und Experten
- aber auch bestehende Datenbanken und Tabellen.

Um einen repräsentativen Querschnitt eines Vokabulars zu erhalten, sollte sowohl auf Quellen zurückgegriffen werden, die die Grundlagen des Fachgebietes abbilden, als auch auf aktuelle Fachliteratur und den aktuellen Sprachgebrauch von Benutzern.

Wesentliche Begriffe identifizieren und kontrollieren

Alle Wörter, die aus den unterschiedlichen Quellen gesammelt wurden, müssen nun nach einem einheitlichen Schema erfasst werden.

Die Begriffe werden zu diesem Zweck formal angeglichen. Das erfolgt, indem alle Wörter entweder im Singular oder Plural erfasst und alle Abkürzungen und Fremdwörter aufgelöst werden. Begriffe, die doppelt gesammelt wurden, werden aussortiert, wobei es sinnvoll ist zu vermerken, welche Begriffe oft genannt wurden und daher auch oft wichtiger sind.

Der gesammelte Wortschatz wird nun terminologisch kontrolliert, um die Mehrdeutigkeiten und Unschärfen der natürlichen Sprache zu reduzieren. Dabei wird vor allem auf die Reduzierung von Begriffen mit derselben Bedeutung aber unterschiedlicher Schreibweise oder Sprachstile geachtet.

In jedem zu modellierenden Gebiet existieren nahezu unendlich viele Begriffe. Die Herausforderung bei der Erstellung eines Wissensorganisationssystems liegt darin, jene Begriffe herauszufinden, die im Sinne der Anforderungen wesentlich sind. Dabei kann eine Sammlung von konkreten Fokusfragen, die das fertige Wissensorganisationssystem beantworten soll, als wichtige Hilfe dienen.

Für die Erstellung einer Begriffsliste werden die Begriffe nun nach einem Ordnungsprinzip (meist alphabetisch) sortiert. Sollen hierarchische oder assoziative Relationen im Wissensorganisationssystem eingesetzt werden, erfolgt stattdessen die Bildung von Klassen.

Klassen bilden

Wenn eine Klassifikation oder ein Relationssystem erstellt wird, werden die identifizierten Begriffe nun in eine Struktur gebracht. Dabei hat es sich bewährt den Beginn dieser Phase nicht digital durchzuführen.

Neben der einfachen Skizzierung der Struktur auf einem Flipchart kann die Sortierung der Begriffe auch mittels der „Kärtchenmethode“ erfolgen. Dafür wird jeder Begriff auf ein separates (kleines) Blatt Papier (bzw. Karteikarte) geschrieben. Die Begriffe werden danach von einer oder mehreren Personen in Gruppen von „Kärtchen“ sortiert. Die gemeinsame Eigenschaft der Begriffe innerhalb einer Gruppe sowie der Titel der Klasse werden erst nach Abschluss der Gruppierung explizit festgelegt. Dieser Vorgang kann auch von unterschiedlichen Personen und Gruppen durchgeführt werden um unterschiedliche Sichtweisen auf das selbe Gebiet zu erfassen.

Der Vorteil dieser Methode besteht darin, dass Änderungsvorschläge unkompliziert umgesetzt werden können und daher auch öfter geäußert werden. Von vielen Teilnehmern wird auch der spielerische Aspekt dieser

Vorgehensweise geschätzt. Damit wird auch die Bereitschaft sich bei der Erstellung mit einzubringen gefördert.

Die identifizierten Gruppen sind danach noch in eine (meist) hierarchische Struktur zu bringen. Zu diesem Zweck sind die konkreten Relationstypen innerhalb des Wissensorganisationssystems festzulegen.

Relationstypen festlegen

Mit den konkreten Relationstypen wird die Art des Wissensorganisationssystems festgelegt. Die unterschiedlichen Systeme beinhalten dabei in Bezug auf Relationen folgende Einschränkungen:

- *Klassifikation*: Hierarchische Beziehungen (Oberbegriff, Unterbegriff)
- *Thesaurus*: BF (Benutzt für), BS (Benutze Synonym), OB (Oberbegriff), UB (Unterbegriff) und VB (Verwandter Begriff). Manchmal werden auch weniger gebräuchliche Relationen eingesetzt, z. B. BSU (Benutze spezifischen Unterbegriff), BSO (Benutze spezifischen Oberbegriff), BK (Benutze Kombination), KB (Kombinationsbegriff), BIK (Benutzt in Kombination) und BFK (Benutzt für Kombination).

Semantische Netze und Ontologien bieten im Vergleich dazu die Möglichkeit jede beliebige Relation zu vergeben. Bei Ontologie ist jedoch zu beachten, dass viele Sachverhalte sowohl als Relation als auch als Eigenschaft einer Klasse modelliert werden können.

Die Entscheidung für einen bestimmten Typ von Wissensorganisationssystem hängt nicht nur von der Auswahl der Relationstypen ab, sondern wird auch von vorgegebenen Standards für die unterschiedlichen Systeme beeinflusst. Abbildung 5 gibt dazu einen Überblick:

	Klassifikation	Thesaurus	Semantisches Netz	Ontologie
Standard zur Modellierung		 ISO 2798, BS 5723, ANSI/NISO Z39/19		
Standard für Bezeichnungen		Thesaurus Notationen: BF, BS, OB, UB, VB		

Abb. 5. Standards für die Modellierung von Wissensorganisationssystemen

Definition der Eigenschaften der Klassen

Wenn eine Ontologie modelliert wird, ist für jede Klasse festzulegen, welche Relationen oder Attribute von den ihnen zugeordneten Individuen wahrgenommen werden. Die Möglichkeiten für die konkrete Ausführung dieses Schrittes variiert zwischen den unterschiedlichen Tools zur Modellierung von Ontologien. Ein Beispiel dazu finden Sie in [12].

Vervollständigung durch die Individualebene

Mit den bisherigen Schritten wurde ein Schema für das jeweilige Wissensorganisationssystem festgelegt. Doch erst durch die Zuordnung konkreter Ausprägungen, Dokumente oder Objekte zu den normierten Begriffen entsteht eine Wissensbasis.

Evaluierung

Die Evaluierung des Wissensorganisationssystems kann z. B. mit den definierten Fokusfragen erfolgen. Eine weitere Variante besteht darin Nutzern, die das Wissensorganisationssystem noch nicht kennen, konkrete Fragen zur Recherche mit dem Wissensorganisationssystem zu stellen und zu testen, ob sie mit dem System arbeiten können.

Weiters sollte das Wissensorganisationssystem nach folgenden typischen Fehlern durchsucht werden:

- widersprüchliche Begriffe,
- ungenaue Begriffe und
- Begriffe, die voraussichtlich nicht verwendet werden.

Diese Begriffe sind entweder zu ändern oder ganz zu entfernen.

Wartung

Traditionell wurden Wissensorganisationssysteme manuell erstellt und gewartet. Je größer und komplexer ein Wissensorganisationssystem wird, desto schwieriger wird allerdings auch die manuelle Wartung. Da sich jedoch die Sicht der Benutzer auf ein Gebiet mit der Zeit verändert, ist eine Wartung erforderlich, selbst wenn keine neuen Dokumente mit dem Wissensorganisationssystem erschlossen werden.

Wissensmodellierung in der Praxis

Die im vorherigen Abschnitt vorgestellte Methode ist ein generischer Ansatz für die Modellierung unterschiedlicher Wissensorganisationssysteme. In der Praxis wird die Modellierung jedoch auch stark vom Projektumfeld und den gewählten Tools zur Umsetzung dominiert.

Tools zur Wissensmodellierung

Für die Modellierung von Klassifikationen, Thesauri und Ontologien stehen sowohl Open Source [3, 4] als auch kommerzielle Tools, insbesondere auch aus dem deutschsprachigen Raum¹¹, zur Verfügung. Das Angebot an Werkzeugen in diesem Bereich ist in den letzten Jahren stetig gewachsen.

Wissensorganisationssysteme nutzen

Wir nutzen Wissensorganisationssysteme meist täglich um innerhalb einer Anwendung zu navigieren. Doch wie können wir diese Systeme sonst noch für uns nutzen?

Ein wichtiger Bereich für die persönliche Nutzung von Wissensorganisationssystemen ist die (Internet)Recherche. Wissensorganisationssysteme sind eine Quelle für das Auffinden von Begriffen um die Suche zu erweitern oder einzugrenzen. Synonyme können hier strukturiert dargestellt aufgefunden werden. Außerdem werden die wichtigsten Schlagwörter zu einem Fachgebiet dargestellt.

Um den Nutzen einer Folksonomy zu verbessern, können bei der Vergabe von Tags folgende Hinweise beachtet werden:

- Nur in Kleinbuchstaben schreiben
- Plural verwenden (statt Singular)
- Zusammenhängende Begriffe durch Unterstrich trennen
- Tags vergeben, die bereits häufig verwendet wurden
- Synonyme (andere Wörter für denselben Sachverhalt) vergeben.

Jedes Wissensorganisationssystem bildet die Sichtweise der Organisation, die sie erstellt hat, ab. Eine Beschäftigung mit diesem System ist gleichzeitig ein Blick in die Organisation. Hierfür sind sowohl das Labeling (also die Bezeichnung für einzelne Begriffe) als auch die Hierarchie

¹¹ Siehe dazu z. B. für Ontologien auch: <http://www.moresophy.com>, <http://www.i-views.de> und <http://www.ontoprise.de>, aufgerufen im Januar 2008

bzw. Relationen zwischen den Objekten aussagekräftig. Das gilt bereits für eine einfache Navigationsleiste und noch viel mehr für umfangreichere Systeme.

Literatur

1. G.C. Bowker, and S. Leigh Star. *Sorting things out: Classification and its consequences*. Cambridge, Mass.: MIT Press, 2000.
2. M. Burkart. *Thesaurus*, in: *Grundlagen der praktischen Information und Dokumentation: Ein Handbuch zur Einführung in die fachliche Informationsarbeit*, M. Buder, and K. Laisiepen, Eds., München: Saur, 1997, pp. 160–179.
3. A. Das, W. Wu, and D.L. McGuines, *Industrial Strength Ontology Management*. Stanford Knowledge Systems Laboratory Technical Report KSL-01-09 2001. in: *Proceedings of the International Semantic Web Working Symposium*. Stanford, CA, July 2001.
4. A. Duineveld, R. Stoter, M.R. Weiden, B. Kenep, and V.R. Benjamins, *Wonder Tools? A Comparative Study of Ontological Engineering Tools*. Paper presented at the Twelfth Workshop on Knowledge Acquisition, Modeling, and Management (KAW99), 16–21 October, Banff, Canada.
5. M. Fernández-López, *Overview of Methodologies for Building Ontologies*, in: *IJCAI99 Workshop on Ontologies and Problem-Solving Methods: Lessons Learned and Future Trends*, Stockholm, 1999.
6. A. Gomez-Perez, M. Fernandez-Lopez, and O. Corcho. *Ontological Engineering*. Advanced Information and Knowledge Processing. Springer, 2003.
7. T. Gruber. *Collective Knowledge Systems: Where the Social Web meets the Semantic Web*. in: *Journal of Web Semantics* 6 (1), 2008.
8. T. Gruber. *Ontology*. in: *Encyclopedia of Database Systems*, L. Liu, and T.M. Özsu, Eds.: Springer-Verlag, 2008.
9. G. Hodge. *Systems of Knowledge Organization for Digital Libraries: Beyond Traditional Authority Files*. Washington, DC: Digital Library Federation Council on Library and Information Resources, 2000.
10. E.K. Jacob. *Ontologies and the Semantic Web*. in: *Bulletin of the American Society for Information Science and Technology*, April/May 2003, pp. 19–22.
11. G. Lakoff. *Women, fire, and dangerous things: What categories reveal about the mind*. Chicago: Chicago Press, 1990.
12. N.F. Noy, and D.L. McGuinness. *Ontology Development 101: A Guide to Creating Your First Ontology*. Available at http://protege.stanford.edu/publications/ontology_development/ontology101-noy-mcguinness.html.
13. R. Saul Wurman, L. Leifer, D. Sume, and K. Whitehouse, *Information anxiety 2*. Indianapolis, Ind: Que, 2001.

8. Anreicherung von Webinhalten mit Semantik – Microformats und RDFa

Michael Hausenblas

Institut für Informationssysteme & Informationsmanagement,
JOANNEUM RESEARCH Forschungsgesellschaft mbH, Graz,
michael.hausenblas@joanneum.at

Zusammenfassung: Semantik in Webinhalten wird heftig diskutiert. Teilweise wird es auch schon praktiziert. Dieser Beitrag geht auf semantisches HTML, Microformats und RDFa näher ein und zeigt anhand von praktischen Beispielen, wie und wo diese verwendet werden können.

Einleitung

Das Web – wie wir es kennen – war schon immer semantisch. Mit dem Semantic Web wird alles einfach ein Stück expliziter. In diesem Beitrag gehen wir der Frage nach, was an HTML semantisch ist und wie Metadaten mit expliziter Semantik in HTML ausgedrückt werden können. Die praktische Realisierung von semantischen HTML wird anhand von zwei komplementären Ansätzen, Microformats und das von W3C standardisierte RDFa (RDF in Attributen), erläutert.

Während Microformats einen sehr einfachen, zielorientierten Ansatz darstellen, Metadaten in HTML einzubetten, stellt RDFa eine vollwertige Semantic Web Technologie dar, da es die Einbettung beliebiger RDF Graphen in HTML erlaubt. Dieser generische Ansatz von RDFa, in Verbindung mit der Verwendung von URIs¹ zur Identifikation von Entitäten im Web macht RDFa zum Standard für semantisches HTML.

Das derzeitige Web ist von Menschen für Menschen geschrieben. Um die maschinelle Verarbeitung zu erleichtern (Ziel: explizite Semantik), kann eine Reihe von Techniken angewandt werden.

¹ <http://www.w3.org/DesignIssues/LinkedData.html>

Semantisches HTML ermöglicht die Repräsentation von Metadaten und Schemata in HTML-Seiten, sodass nicht nur ein Mensch, sondern auch Software sinnvoll eine Webseite verarbeiten können.

Um die grundlegende Problematik zu verdeutlichen wird im Beitrag durchgehend ein Beispiel verwendet – zu diesem Zweck outet sich der Autor:

Michael's interest

I am a **Queen** aficionado and especially like the gig „Live at Wembley ‘86“, which took place in **1986** at the **Wembley** stadium.

In diesem kurzen Beispiel steckt viel kontextuelle Information, sowie zeitliche und örtliche Angaben. Ein Mensch, der diesen Satz liest, kann verstehen was gemeint ist und könnte – so er dem Autor eine Freude machen will – z. B. den entsprechenden Live-Mitschnitt auf CD zum Geschenk machen. Für eine Maschine, also ein Stück Software, ist es jedoch ungleich schwieriger zu interpretieren, dass mit Queen die Rockgruppe und nicht die Monarchin gemeint ist. Weiters kann ein Semantische Web Agent mit 1986 und ‚Wembley stadium‘ wenig anfangen. Im Folgenden werden die schrittweise Umstrukturierung in aussagekräftigeres HTML und weiters die Anreicherung mit Semantik diskutiert.

In diesem Kapitel werden nun eingangs die verfügbaren HTML Konstrukte beschrieben, und weiters die unterschiedlichen Methoden der Anreicherung von Webinhalten mit Semantik vorgestellt.

(X)HTML, Metadaten und Semantik

HTML selbst ist durchwegs keine reine Präsentations-Markupsprache. So gibt es unterschiedliche HTML Elemente, die zwar für den menschlichen Betrachter gleichwertig erscheinen (gerendert) werden, allerdings bei der Interpretation durch die Maschine (d.h. ein Softwareprogramm) zusätzliche Semantik transportieren können. Anhand unseres durchgängigen Beispiels sehen wir uns dies nun Schritt für Schritt an: Ausgehend von einer primitiven Tag-Soup² Implementierung bis zur Verwendung von RDFa in HTML. Unter Tag-Soup versteht man allgemein die, in vielen HTML-Seiten anzutreffende, nicht-standardkonforme (d.h. DTD-fremde) Verwendung von HTML (z.B. werden Elemente wie `<li>` nicht geschlossen, oder die Kaskadierungsvorschriften werden ignoriert). Eine einfache Tag-Soup Implementierung könnte nun wie folgt aussehen:

² http://en.wikipedia.org/wiki/Tag_soup

```
<b>Michael's interest<br>
I am a Queen aficionado and especially like the gig „Live at Wembley ‘86“,
which took place in 1986 at the
<a href="http://www.wembleystadium.com">Wembley sta-
dium</a>.
```

Um gültiges HTML zu erhalten wäre beispielsweise folgendes Markup nötig:

```
<h2>Michael's interest</h2>
<p>I am a Queen aficionado and especially like the gig „Live at Wembley
‘86“, which took place in 1986 at the
<a href="http://www.wembleystadium.com">Wembley sta-
dium</a>. </p>
```

Und damit haben wir schon den ersten Schritt in Richtung semantisches HTML gemacht: Plain Old Semantic HTML (POSH)³, ein kürzlich geprägter Begriff, umfasst diese und andere Ideen (gültiges HTML, keine `<table>` für Layouts, Verwendung von semantischen statt reinen Präsentations-Markups, etc.). Der Semantik Begriff, wie er in diesem Kontextgebraucht wird, zielt allerdings rein auf die logische Strukturierung ab und hat nichts mit einer Domain-Semantik (Vokabular für z. B. Leute, Bücher, Musik, etc.) zu tun. Der POSH-Ansatz ist aus Sicht des Semantic Web sicherlich ein erster, wichtiger Schritt, löst aber für sich genommen noch keine Probleme.

Weiters bietet auch HTML 4 schon die Möglichkeit, einfach (globale) Metadaten einzubinden: das `<meta>`-Element. Dieses HTML Element wird zumeist im Umfeld von Suchmaschinen(optimierung) eingesetzt, z. B. um Zusammenfassungen oder Stichworte unterzubringen. Dabei handelt es sich um globale Metadaten, d. h. Metadaten über das gesamte Dokument.

Um die Anreicherung zu demonstrieren, gehen wir nun einen Schritt weiter und fügen zum `<head>` unserer HTML Seite folgendes hinzu:

```
<meta name="keywords" content="Michael, interest,
Queen, Wembley, 1986">
```

Damit kann zum Beispiel ein Agent schon etwas sinnvolles Anfangen. Wird die Seite indiziert, kann über die Stichworte effektiv auf den Inhalt geschlossen werden. Schließlich lässt sich die Aussage wie folgt interpretieren: „Michael Hausenblas ist an der Rockgruppe Queen interessiert, ganz speziell an dem Livekonzert 1986 im Wembley Stadium“. Der

³ <http://microformats.org/wiki/posh>

Schwachpunkt ist allerdings auch klar: Die Aussage ist nicht strukturiert, die Bezeichner sind einfache Zeichenketten und keine eindeutigen Identifikationen von Entitäten. Das erkennt man daran, wenn eine alternative Interpretation der Stichworte vorgenommen wird, wie z. B.: „Michael Ballak hat im Wembley Stadion gespielt. Er hat zu seinem zehnten Geburtstag (1986) eine Reise nach London gemacht, da ihn die Queen interessierte.“

Vom Scraping zur Auszeichnung

In diesem Abschnitt beschäftigen wir uns nun weniger mit konkreten Marcups, sondern diskutieren die prinzipiellen Möglichkeiten in HTML Semantik zu ‚transportieren‘. Schon lange existiert die Möglichkeit, HTML-Seiten von Maschinen auswerten zu lassen: Screen-Scraping, Web-Scraping, etc. Dabei wird der Vorgang verstanden, dass die impliziten Semantiken in einer HTML-Seite von einem Menschen manuell beschrieben werden, und darauf basierend dann automatisch von einer Maschine extrahiert und in ein strukturiertes Format gebracht werden. Die Hauptlast der Erkennung und Repräsentation der Semantik liegt bei diesem Verfahren also beim (menschlichen) Empfänger der Nachricht.

So ist zum Beispiel der Harvester/Mapper, welcher im Rahmen des Understanding Advertisting Projekts⁴ entwickelt wurde, ein Vertreter dieser Klasse. Diese Art von Tools arbeitet so lange zufriedenstellend, solange sich das Layout einer Seite nicht ändert und die Arbeit, um ein Mapping (Layout → Semantik) zu erstellen, in Relation zu der Anzahl der Seiten gering ist. Der Nachteil dieser Methode liegt auf der Hand: es handelt sich um ein end-of-pipe System, bei dem der Konsument einer Webseite die Semantik des Inhaltes explizit festlegen und der Maschine mitteilen muss (consumer-driven approach).

Der Inhalt einer Webseite trägt stets eine Bedeutung. Wird allerdings hauptsächlich Präsentations-Markup eingesetzt und keine explizite Vorschrift mitgeliefert, wie der Inhalt zu interpretieren ist, ist die maschinelle Verarbeitung aufwändig und nicht generisch umsetzbar.

⁴ <http://www.sembase.at/index.php/UAd>




Abb. 1. Konsumenten von Webinhalten

Statt dem Konsumenten einer Webseite die Arbeit aufzubürden den Inhalt zu interpretieren scheint es weitaus sinnvollere Weg zu geben, den Erzeuger einer Webseite die Semantik der Inhalte explizit festlegen zu lassen (publisher-driven approach). Ob dies nun mittels Gleaning Resource Descriptions from Dialects of Languages (GRDDL) [1], oder den unten besprochenen Methoden – microformats und RDFa – erfolgt, ist dabei zweitrangig. Wesentlich bei diesem Ansatz ist, dass quasi auf Senderseite eine selbstbeschreibende Nachricht erstellt wird, und nicht wie im klassischen Verfahren der Empfänger der Nachricht diese deuten muss.

Die Abb. 1 verdeutlicht die Situation. Es gibt einerseits den menschlichen Benutzer, der via Browser eine HTML-Seite konsumiert; andererseits sind maschinelle Benutzer (Agenten, Bots, etc.) im Web unterwegs, welche aufgabenorientiert die Inhalte konsumieren.

Microformats (μF)

Die Verbreitung der Microformats⁵ (μF) ist wohl aufgrund ihrer Einfachheit und absoluten Zweckausrichtung erklärbar. Die Kernidee von μF besteht darin, Metadaten in HTML-Attributen unterzubringen. Einerseits werden unter μF einfache Patterns wie das rel-Tag⁶ verstanden, andererseits Übersetzungen von verbreiteten Vokabularen wie z.B. hCard

⁵ <http://microformats.org/>

⁶ <http://microformats.org/wiki/rel-tag>




Abb. 2. Übersicht über μ F

(basierend auf vCard [2], welches zur Repräsentation von Kontaktdaten wie Name, Adresse, usw. dient).

In Abb. 2 sind die elementaren und die zusammengesetzten μ F schematisch dargestellt.

Unser Beispiel von oben könnte mit μ F nun, wie folgt, beschrieben werden:

```
<div class="vcard">
<span class="n">
<h2>
<a class="url given-name"
href="http://sw-app.org/about.html ">Michael's</a>
  interest
</h2>
</span>
<p>
I am a <a
href="http://en.wikipedia.org/wiki/Queen_(band)"
rel="tag">Queen</a> aficionado and especially like
the gig "Live at Wembley '86", which took place in
1986 at the
<a href="http://www.wembleystadium.com">Wembley
stadium</a>.
</p>
</div>
```

Mit der Verwendung von den beiden μ F hCard und rel-tag im obigen Beispiel wurde die Semantik der Aussage ein Stück expliziter gemacht. Allerdings werden dabei auch die Unzulänglichkeiten der Microformats im Kontext des Semantic Web deutlich. Da μ F im Wesentlichen Abbildungs-

regeln für bestimmte Vokabulare oder Patterns in genau definierte HTML-Attribute sind, ergeben sich folgende Probleme:

- URIs werden von μF nicht zur Identifikation von Entitäten unterstützt; dies macht die Interoperabilität mit dem auf URIs basierendem Semantic Web schwer bzw. gar nicht möglich.
- Microformats besitzen kein gemeinsames Datenmodell (wie z. B. RDF), d. h. es muss für jedes Vokabular eine eigene Abbildungsregel definiert werden. Dies bedeutet entsprechenden Implementierungsaufwand bei Tools, die entsprechende Formate unterstützen wollen.
- Aufgrund der flachen Vokabularstruktur (keine Namensräume) gibt es keine (einfache) Kombinationsmöglichkeit verschiedener Vokabulare (z. B. hCard mit hCalendar⁷ auf einer Seite einsetzen).
- Die Definition der Vokabulare ist einer kleinen, geschlossenen Gemeinde vorbehalten; eigene Erweiterungen sind nicht möglich. So kann zum Beispiel nicht einfach für einen Fachbereich (Biologie, Ökonomie, etc.) ein Vokabular definiert werden; nur existierende Vokabulare werden anerkannt und erhalten entsprechenden Support. Soll ein neues μF eingeführt werden, muss zuerst seine praktische Verwendung anhand von bestehenden Webseiten nachgewiesen werden.

RDF in Attributen – RDFa

Das Semantic Web besitzt mit RDF ein Datenmodell, welches erlaubt strukturierte Aussagen zu machen. Eine Aussage ist dabei stets in der Form **Subjekt – Prädikat – Objekt**. Die Gesamtheit aller Aussagen bildet dabei einen gerichteten, beschrifteten Graphen. Das Subjekt kann eine URI (oder ein anonymer Knoten) sein, das Prädikat ist immer eine URI und schließlich das Objekt, welches eine URI, ein anonymer Knoten oder ein Literal (ein einfacher oder auch typisierter Wert, eine reine Zeichenfolge) sein kann.

RDF in HTML

Soweit zum Datenmodell, d. h. zur Theorie. Tatsächlich gibt es aber in der Praxis ein Problem: Wie werden die Metadaten tatsächlich ausgeliefert, also technisch gesehen RDF und HTML miteinander verheiratet (vgl. auch Abb. 1)? Es gibt eine Reihe von Ansätzen, wie RDF mit HTML verknüpft werden kann [3], sei es nun über eine Verknüpfung oder eingebettet.

⁷ <http://microformats.org/wiki/hcalendar>

Eine Lösung liegt nahe: Wie bei den μF werden ausgesuchte HTML-Attribute verwendet, um Metadaten (also den RDF Graphen) einzubetten. RDF in Attributen (RDFa) macht genau das. Microformats und RDFa haben eine Menge Gemeinsamkeiten. Es geht in erster Linie darum, Metadaten in HTML einzubetten. Beide sind von einem Container abhängig, in dem sie eingebettet sind: eben dem (X)HTML Dokument. Das primäre Ziel von beiden Technologien ist es, die Daten für die maschinelle Verarbeitung eindeutig zu kennzeichnen. Da der Inhalt von HTML-Attributen im Gegensatz zu Elementen (wie z. B. `<table>`) nicht strukturiert ist, gibt es Freiheiten, diesen Inhalt zu interpretieren. Ein weiterer Freiheitsgrad besteht in der Auswahl der Zielattribute. Verwendet man einige wenige (vgl. auch eRDF⁸), werden bestehende Attribute benützt, oder definiert man neue? Welcher Weg auch immer verfolgt wird, stets wird nach dem DRY-Prinzip vorgegangen. DRY steht für **Don't Repeat Yourself**⁹ und meint Redundanzen zu minimieren und damit Inkonsistenzen zu vermeiden.

Hier setzt RDFa an: Statt für jedes Vokabular eine Abbildung in das Zielformat (Container) zu definieren, wird festgelegt, wie ein RDF Graph in (X)HTML abgebildet wird. Da mit RDF (bzw. RDF Schema, OWL, etc.) beliebige Vokabulare wie FOAF¹⁰, etc. repräsentiert werden können, erhält man somit eine Art generisches Mikroformat. Die Vorteile von RDFa sind damit offensichtlich:

- Das Datenmodell ist einheitlich, es ist das Resource Description Framework (RDF) [4].
- Es ist nur einmal ein generischer Extraktor zu implementieren, der in weiterer Folge jedes beliebige Vokabular versteht (z. B. von RDFa nach RDF/XML, etc.).
- Durch Namespaces ist die Skalierbarkeit garantiert, d. h. es können beliebige Vokabulare gemeinsam in einer Seite verwendet werden.
- RDFa hat alle Vorteile von μF (self-contained data, DRY Prinzip, etc.).

Der resultierende RDF Graph kann in weiterer Folge in andere Informationsbestände integriert werden, bzw. es kann eine Abfrage durchgeführt werden (mit SPARQL [5]). In der Abb. 3 ist die Verwendung von einer mit RDFa annotierten Webseite (ein FOAF Dokument) dargestellt. Die Webseite (1) ist für einen menschlichen Betrachter wie gewohnt lesbar. Sieht man sich den Quelltext der HTML-Seite (2) an, erkennt man das eingebettete RDFa. Mit einem RDFa-Prozessor (siehe <http://rdfa.info/rdfa-implementations/>) kann ein RDF Graph erzeugt werden, der für die maschinelle Verarbeitung zur Verfügung steht.

⁸ <http://research.talis.com/2005/erdf/wiki/Main/RdfInHtml>

⁹ <http://www.formsplayer.com/node/272>

¹⁰ <http://xmlns.com/foaf/0.1/>

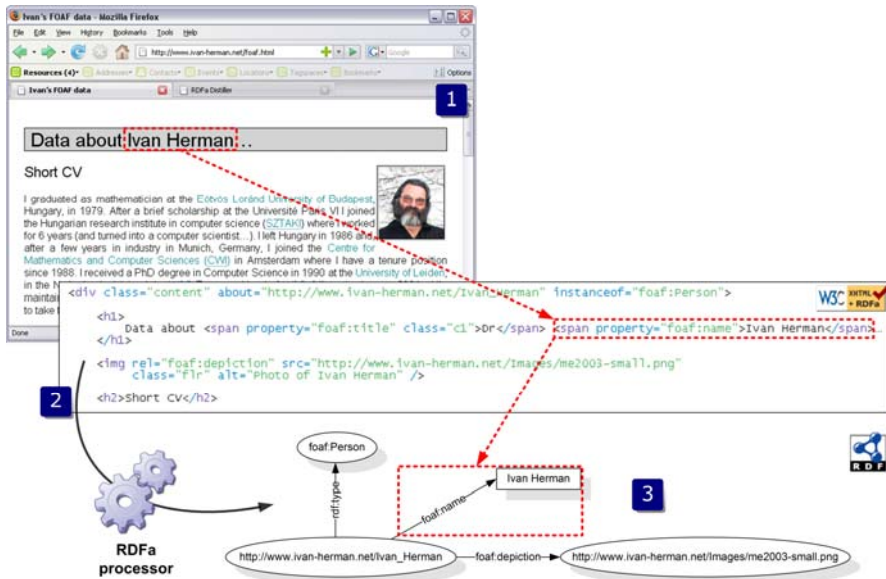


Abb. 3. Ein FOAF-Dokument mit RDFa

Unser laufendes Beispiel von oben könnte mit XHTML+RDFa nun wie folgt aussehen:

```
<div about="#michael">
  <h2>
    <a href="http://sw-app.org/about.html"
      property="vcard:given-name">Michael's inter-
est
    </h2>
  <p>
    I am a <a
      href="http://en.wikipedia.org/wiki/Queen_(band)"
      rel="foaf:topic_interest">Queen</a> aficionado
    and especially like the <span
      about="#queen_86">gig "Live at Wembley '86",
    which took place in 1986 at the
    <a href="http://www.wembleystadium.com"
      rel="geo:location"
      resource="http://dbpedia.org/resource/Wembley">
      Wembley stadium</a></span>.
    </p>
</div>
```

Der resultierende RDF Graph (in N3 Notation) des obigen Beispiels ist dann folglich:

```
@prefix: <http://sw-app.org/rdfa/social-sw-
example.html#>.
@prefix foaf: <http://xmlns.com/foaf/0.1/>.
@prefix geo: <http://www.example.org/geo#>.
@prefix rdf: <http://www.w3.org/1999/02/22-rdf-
syntax-ns#>.
@prefix vcard: <http://www.w3.org/2001/vcard-
rdf/3.0#>.

:michael vcard:given-name "Michael";
foaf:topic_interest
<http://en.wikipedia.org/wiki/Queen_(band)>,
:queen_86.

:queen_86 geo:location
<http://dbpedia.org/resource/Wembley>.
```

Das Beispiel demonstriert nebenbei auch die eigentliche Idee des Semantic Web. Für einen Menschen ergibt sich auf den ersten Blick kein Unterschied, tatsächlich erlauben die eingebetteten, maschinenverarbeitbaren Metadaten eine Menge neuer Anwendungsfälle. So können z. B. durch einfaches Markieren des entsprechenden Bereiches auf der Webseite (mit Hilfe eines Bookmarklets) die Metadaten in den eigenen Blog übernommen werden. Weiters ist durch die Anwendung des DRY-Prinzips sichergestellt, dass sich Änderungen in den (menschenslesbaren) Daten konsistent in den Metadaten auswirken.

Für weitere Anwendungsgebiete seien die RDFa Use Cases [6] zur Lektüre empfohlen. In den RDFa Syntax Regeln [7] wird der generische Interpretationsablauf beschrieben, ein kürzlich veröffentlichtes Paper [8] diskutiert die hier beschriebenen Methoden und ihre Performance weiters. Anwendungen von RDFa sind auf <http://rdfa.info/rdfa-in-the-wild/> gelistet.

Nachdem XHTML+RDFa zum W3C-Standard wird (Mitte 2008), sind entsprechende Erweiterungen auch für andere XML-basierte Sprachen (SVG, SMIL, etc.) zu erwarten. In XHTML 2.0 ist RDFa schon von Haus aus integriert. Vieles wird sicher vom Tool-Support abhängen, einige native RDFa-Werkzeuge gibt es heute schon, wie z. B. den TopBraid Composer¹¹.

¹¹ <http://composing-the-semantic-web.blogspot.com/2007/01/topbraid-is-now-also-rdfa-editor.html>

Conclusio

Semantische HTML ist im Vormarsch. In der praktischen Umsetzung gibt es unterschiedliche Zugänge, wie μF , RDFa oder GRDDL. Das gemeinsame Ziel aller Technologien ist es, die Informationen in einer Webseite maschinenverarbeitbar zu machen, d.h. eine automatische Verarbeitung von HTML-Seiten durch Software zu ermöglichen. Dabei legt der Erzeuger einer Webseite explizit die Semantik in der HTML-Seite fest.

Je nach dem, ob man sich mit einfachen, fixierten Vokabularen und limitierten – dafür schon weiter verbreiteten – Möglichkeiten (μF) begnügt, oder gleich im Semantic Web (RDFa) mitmischen will: Semantisches HTML stellt einen wesentlichen Schritt in Richtung Realisierung des lange erwarteten und versprochenen Semantic Webs dar.

Danksagung

Der Autor dankt den Kollegen in der W3C RDFa Task Force, und in der W3C Semantic Web Activity Domain, welche direkt oder indirekt durchgehend mit wertvollen Hinweisen und durch zahlreiche Diskussionen das Zustandekommen dieses Beitrages erst ermöglicht haben (in alphabetischer Reihenfolge): Ben Adida, Mark Birbeck, Dan Connolly, Ivan Herman, Shane McCarron, Benjamin Nowack, Steven Pemberton, Manu Sporny und, last but not least, Ralph Swick.

Literatur

1. D. Connolly. Gleaning Resource Descriptions from Dialects of Languages (GRDDL), <http://www.w3.org/TR/grddl/>, W3C Recommendation, 2007.
2. F. Dawson and T. Howes. vCard MIME Directory Profile. RFC 2426, IETF—Network Working Group, 1998.
3. Sean B. Palmer. RDF in HTML, <http://infomesh.net/2002/rdfinhtml/>
4. G. Klyne, J. J. Carroll, and B. McBride. RDF/XML Syntax Specification (Revised). <http://www.w3.org/TR/rdf-concepts/>, W3C Recommendation, 2004.
5. E. Prud'hommeaux and A. Seaborne. SPARQL Query Language for RDF. <http://www.w3.org/TR/rdf-sparql-query/>, W3C Recommendation, 2008.
6. B. Adida and M. Hausenblas. RDFa Use Cases: Scenarios for Embedding RDF in HTML, <http://www.w3.org/TR/xhtml-rdfa-scenarios/>, W3C Working Draft, 2007

7. B. Adida, M. Birbeck, S. McCarron, and S. Pemberton. RDFa in XHTML: Syntax and Processing, <http://www.w3.org/TR/rdfa-syntax/>, W3C Working Draft, 2007.
8. M. Hausenblas, W. Slany, and D. Ayers. A Performance and Scalability Metric for Virtual RDF Graphs. In 3rd Workshop on Scripting for the Semantic Web (SFSW07), Innsbruck, Austria, 2007.

9. Modellierung von Anwenderverhalten im Social Semantic Web

Armin Ulbrich, Patrick Höfler und Stefanie Lindstaedt

Know-Center, Graz, Austria

{aulbrich; phoefler; slind}@know-center.at

Zusammenfassung: Ziel dieses Kapitels ist es, gemeinsame Verwendungsszenarien des Semantic Web und des Social Web zu identifizieren und zu benennen. Dabei wird ein Teilaspekt des Themengebiets im Detail betrachtet: die Nutzung von Services, die Beobachtungen des Verhaltens von Anwendern analysieren, um daraus maschinell interpretierbare Informationen zu erhalten und diese als Modelle zu organisieren. Es werden zunächst einige Eigenschaften und Unterscheidungsmerkmale von Anwenderverhalten und organisierten Modellen dargestellt. Anschließend wird der mögliche wechselseitige Nutzen von Anwenderverhalten und Modellen diskutiert. Den Abschluss bildet eine Betrachtung einiger exemplarischer Software-Services, die heute schon verwendet werden, um Anwenderverhalten in Modelle überzuführen.

Einleitung

Das World Wide Web hat eine außerordentliche Größe und Wichtigkeit in Wissenschaft, Wirtschaft und Unterhaltung erreicht. Laut Internet Usage Statistics¹ sind zurzeit mehr als 1,2 Milliarden Menschen Nutzer des Internet und damit zum großen Teil auch des World Wide Web. Diese gewaltige Menge an Menschen liest Inhalte, tauscht sich aus, bildet soziale Netzwerke oder kauft Produkte über Services, die von den mehr als 60 Millionen aktiven Websites² des Internet angeboten werden. Ein bemerkenswerter Aspekt an der Internetnutzung ist, dass sich Anwender mehr und mehr aktiv einbringen und Inhalte unterschiedlichster Art selbst produzieren anstatt lediglich vorab erstellte Inhalte passiv zu konsumieren. Die absolute Zahl der Webnutzer, die aktiv an der Erstellung von Inhalten

¹ <http://www.internetworldstats.com/stats.htm>

² <http://www.netcraft.com/Survey/>

mitarbeiten, hat sich in den vergangenen Jahren ver Hundertfacht [8]. Ein Ergebnis dieser Entwicklung ist die Transformation des World Wide Web hin zu einem *neuen Web*, dem so genannten „Web 2.0“, „Social Web“ oder „Read-Write Web“. Dieses neue Web ist durch Eigenschaften charakterisiert, die Tim O'Reilly und andere in [18] und [21] als Entwurfsmuster (auf Englisch „Design Patterns“) zusammengefasst haben: „The Long Tail, Data is the Next ‚Intel Inside‘, Users Add Values, Network Effects by Default, Some Rights Reserved, The Perpetual Beta, Cooperate, Don't Control, Software above the Level of the Single Device“. Anwendungen, die diese Muster des Web 2.0 aufweisen, haben zumindest zwei Eigenschaften gemeinsam:

- Die wichtigen Teile der Datenbestände und Analysemöglichkeiten, die den Mehrwert einer Anwendung ausmachen, ergeben sich *aufgrund* der Verwendung durch eine möglichst große Zahl von Personen.
- Anwendungen, die mit weiteren Angeboten des Web 2.0 kooperieren, erweitern ihre Datenbestände und Analysemöglichkeiten und können potentiell erfolgreicher sein als andere.

Die zahlenmäßig massive und aktive Nutzung von Web 2.0 Angeboten und die Kooperationen auf Ebene von Daten und Anwendungen zeichnen das Neue des Web 2.0 aus.

Technologische und andere Bedingungen

Die Bedingungen, unter denen dies möglich geworden ist, besitzen naturgemäß eine starke *technologische* Dimension: Seit den Anfängen des World Wide Web 1989 werden Web-Technologien ständig weiter entwickelt. Die Technologien ermöglichen es – zunächst unabhängig voneinander – das Layout der Webseiten zu verbessern (das Center-Tag, eingeführt mit dem Mosaic Netscape Browser 1994, sei hier beispielhaft erwähnt oder CSS, das 1996 vom World Wide Web Consortium empfohlen wird), vormals statische Webseiten mit Interaktivität auszustatten (etwa durch eine 1995 von Netscape und Sun als LiveScript, später JavaScript, eingeführte Programmiersprache) und die Kommunikation zwischen Browser und Webserver dynamisch zu machen (durch die Einführung des asynchronen Austausches von XML-basierten Daten mit dem Internet Explorer 5 im Jahr 1999). Im Jahr 2005 werden diese und einige weitere Technologien unter dem griffigen Namen AJAX zusammengefasst [4]. Daraufhin beginnen Entwickler in großer Zahl neue Webanwendungen zu erstellen und die Einsatzmöglichkeiten dieser Technologien auszureizen. Bislang unbekannte Interaktionsmöglichkeiten werden im Web durch schnelle, interaktive

Anwendungen, wie sie Anwender bislang nur vom Desktop des PC gewohnt sind, möglich. Heute ist die Entwicklung der Technologien schon einen Schritt weiter, und hybride Applikationen auf Basis von Adobe Flex/AIR³, Microsoft Silverlight⁴ oder Sun JavaFX⁵, die sowohl im Web als auch auf regulären Desktops oder mobilen Endgeräten laufen können, bilden momentan die Speerspitze der „Rich Internet Applications“.

Für den Anwender unsichtbar greifen einige der Web-2.0-Anwendungen im Hintergrund auf hochkomplexe Services zu, die aufgrund der sozialen Interaktionen der Anwender zusätzliche nutzenstiftende Daten generieren. Solche Web-2.0-Anwendungen werden üblicherweise als „Social Software“ bezeichnet. Der Teilbereich des Web, in dem Social Software eine wesentliche Rolle spielt, wird auch das „Social Web“ genannt (vgl. [7]). Social Software lässt sich derzeit in sechs Kategorien einteilen:

- Social Bookmarking (z. B. del.icio.us⁶),
- Social Media Sharing (z. B. flickr⁷),
- Social Networking (z. B. Xing⁸),
- Social Task Sharing (z. B. 43things.com⁹),
- Wikis (z. B. Wikipedia¹⁰) und
- Blogs (z. B. Technorati¹¹).

Anwendungen, die sich einer oder mehrerer dieser Kategorien zuordnen lassen, bieten in aller Regel ein klar auf die Interessen der Anwender abgestimmtes Service an. Auf der Serverseite werden in optimierten und von den Services gemeinsam genutzten Programmen oft Berechnungen und Algorithmen aus der maschinellen Intelligenz [24], Statistik (zum Beispiel [9, 23]) oder Graphenanalyse (zum Beispiel [10, 20]) eingesetzt, um die Daten zu interpretieren. Die Interpretation besteht in der Regel darin, aus dem beobachteten Verhalten und einer auf Erfahrung und Expertise beruhenden Kenntnis von dessen Bedeutung Schlussfolgerungen abzuleiten. In diesem Zusammenhang ergeben sich drei grundlegende technologische Herausforderungen, die Gegenstand von aktuellen Forschungsbestrebungen sind:

³ <http://www.adobe.com/>

⁴ <http://silverlight.net/>

⁵ <http://www.sun.com/software/javafx/>

⁶ <http://del.icio.us/>

⁷ <http://www.flickr.com/>

⁸ <http://www.xing.com/>

⁹ <http://www.43things.com/>

¹⁰ <http://de.wikipedia.org/>

¹¹ <http://www.technorati.com/>

- Beobachtung des Anwenderverhaltens unter größtmöglicher Wahrung der Privatsphäre der Anwender.
- Modellierung beziehungsweise Generierung von Kenntnissen in Bezug auf die Bedeutung des beobachteten Verhaltens.
- Ableitung von Schlussfolgerungen basierend auf erworbenen Kenntnissen und beobachtetem Verhalten.

Das vorliegende Kapitel widmet sich einzelnen Gesichtspunkten dieser Herausforderungen und beschreibt Möglichkeiten zur Generierung von Kenntnissen aus Beobachtungen. Zunächst werden im folgenden Abschnitt bestimmende Eigenschaften herausgearbeitet, die sich aufgrund des Anwender-Verhaltens im Social Web ergeben. Danach werden beispielhaft Architekturen und Systeme dargestellt, in denen die Kombination zu gelingen scheint.

Eigenschaften des Anwenderverhaltens

In Expertenkreisen besteht Übereinkunft darüber, dass Kenntnis, die auf Erfahrung und Expertise beruht, in Formaten und Formalismen des Semantic Web kodiert werden kann, um bestmöglich genutzt werden zu können (zum Beispiel [3, 28]). Ebenso besteht weitgehend Übereinkunft darüber, dass Beobachtungen des Anwenderverhaltens verwendet werden *können*, um daraus formalisierte Kenntnisse zu erzeugen (zum Beispiel [6, 15, 26]). Die Herausforderung besteht darin, Beobachtungen so zu repräsentieren, dass sie formalisierbar sind. Um dieser Herausforderung begegnen zu können, sollen nachfolgend relevant erscheinende Eigenschaften von beobachtbarem Verhalten und modellierten Daten herausgearbeitet werden.

Die Entwicklungen des World Wide Web hin zum Web 2.0 (beziehungsweise in der allerjüngsten Vergangenheit zum Web 3.0) haben dazu geführt, dass Anwender aktiv mitgestalten, welche Entwicklung das Web nimmt und welche Inhalte verbreitet werden. Man spricht in diesem Zusammenhang von Bottom-Up-Strategien, also von Entwicklungen, die quasi „von unten“ getrieben und gestaltet werden. Beispiele dafür finden sich beispielsweise in der Softwareentwicklung beim Einsatz von Projekt-Wikis wie Twiki¹² in agilen Entwicklungsprozessen: Ein Projektteam, das aus Kunden und Entwicklern besteht, entwickelt gemeinsam im Wiki Anforderungen an ein Softwareprojekt und setzt diese selbstgesteuert um. Der Projektfortschritt wird im Wiki festgehalten. Das Projektteam behält auf diese Weise einen Überblick und kann anhand der Erfahrungen der vorangegangenen Projektphasen den Entwicklungsprozess kontinuierlich verbes-

¹² <http://twiki.org/>

sern. Ein anderes Beispiel ist die Entwicklung von Folksonomien in Social Bookmarking Systemen wie *del.icio.us* oder *Bibsonomy*¹³ ([30]): Anwender vergeben Begriffe zu Ressourcen wie Bookmarks oder Literaturreferenzen, die ihrem eigenen Erfahrungshintergrund entsprechen. Aggregiert über die Gesamtheit der Anwender kann aufgrund der Begriffe darauf geschlossen werden, wie ein Thema innerhalb des sozialen Kontextes des Social Bookmarking Systems interpretiert wird. In diesem Zusammenhang wird oftmals davon gesprochen, dass die so entstehenden Strukturen von „emergenter Natur“ sind, sich also ohne Ordnungsvorgaben dynamisch entwickeln und manifestieren.

Top-Down-Strategien dagegen nutzen vorab etablierte Strukturen, um Ressourcen oder Ereignisse innerhalb dieses Bezugssystems einzuordnen. Beispiele dafür sind Katalogsysteme, die nach einem Klassifikationssystem wie dem Dewey Decimal Classification System (DDC, [16]) bestückt werden, aber auch die Struktur, die sich durch die Ressortzugehörigkeit bestimmter Nachrichten in einer Tageszeitung ergibt.

Ein wesentliches Unterscheidungsmerkmal der beiden Ansätze ist, wie neue Inhalte in das Bezugssystem eingeordnet werden: Bottom-Up-Ansätze legen eine Einordnung anhand des sozialen Kontextes nahe, wohingegen in Top-Down-Ansätzen primär inhaltliche Zuordnungen eine Rolle spielen. Neue Inhalte werden also einerseits anhand der sozialen Dimension mit bestehenden Inhalten vernetzt, andererseits anhand der semantischen Dimension. Die technologischen Ansätze, die verwendet werden, um die entsprechenden Tätigkeiten zu unterstützen, können daher grob dem Social Web zugeordnet werden (Bottom-Up) beziehungsweise dem Semantic Web (Top-Down). Eine Analyse von Technologien und Paradigmen der Informationstechnologie zeigt, dass beide Ansätze offensichtlich seit jeher eine Rolle gespielt haben, allerdings nur selten miteinander verbunden worden sind. Seit relativ kurzer Zeit gibt es einen erkennbaren Trend, beide Ansätze miteinander zu verschmelzen. Das Diagramm in Abb. 1 lässt sich auf diese Weise interpretieren.

Das Datenmaterial hinter dem Diagramm in Abb. 1 basiert auf den Arbeiten in [14, 25 und 27] und ist durch Fachleute des Know-Centers¹⁴ erweitert und quantitativ bewertet worden. Darin finden sich Informationstechnologien auf einer Zeitachse (horizontale Achse). Die vertikale Achse gibt an, wie sehr die Technologie die Vernetzung von Daten unterstützen kann, und die Größe der Blase gibt an, wie sehr die Technologie die Vernetzung von Personen unterstützen kann. Das Diagramm kann so interpretiert werden: Technologien, die entweder Daten primär maschinenverstehbar repräsentieren (hoher Wert auf der vertikalen Achse) oder pri-

¹³ <http://bibsonomy.org/>

¹⁴ <http://www.know-center.at/>




Abb. 1. Zeitleiste von Informationstechnologien. Die Fähigkeit einer Technologie, die soziale Dimension zu vernetzen (Größe der Blase), wird der Fähigkeit gegenübergestellt, die Datendimension zu vernetzen (Position auf der vertikalen Achse)

mär der Verbindung von Personen dienen (große Blase), sind größtenteils unabhängig voneinander entwickelt worden. Ab dem Jahr 1995 scheinen diese Technologie-Ansätze zu konvergieren. Nach 2008 soll die Konvergenz verstärkt fortgesetzt werden, wobei das eine Prognose ist, die, so wie alle Vorhersagen, kritisch hinterfragt werden und erst noch durch Beobachtungen belegt werden muss.

Systeme, die Bottom-Up- und Top-Down-Ansätze miteinander verbinden, bereiten üblicherweise das Verhalten von Anwendern so auf, dass es in eine maschinen-verstehbare Form transformiert werden kann. Auf diese Weise kann das Anwenderverhalten in das System zurückgeführt und in bestehende Strukturen integriert werden. Anwenderverhalten – speziell das Verhalten von Gruppen von Anwendern – wird dazu oft in Form von Netzwerken (und damit als Graphen) aufbereitet. Dadurch kann auch die Analyse und Auswertung der Verhaltensdaten auf den mathematischen und formalen Apparat der Netzwerkanalyse beziehungsweise linearen Algebra zurückgreifen. Durch die Analyse von Kenngrößen von Netzwerken können qualitative Aussagen über diese Netzwerke getroffen werden (vgl. [10,

19, 20]). Diese Aussagen beziehen sich beispielsweise auf die Zentralität und damit Wichtigkeit einzelner Teile des Netzwerks oder das voraussichtliche Wachstum des gesamten Netzwerks (anhand von Clustering-Koeffizient, Gradverteilung und den Pfadlängen). Wichtig ist vorab herauszufinden, welche Natur ein gegebener Graph besitzt. So unterscheiden sich etwa „Zufallsgraphen“, Markov-Graphen und Small-World-Graphen, um nur einige zu nennen, stark hinsichtlich ihrer Eigenschaften und der Aussagen, die darüber getroffen werden können. Im Kontext des Social Web spielt das Gesetz von Pareto („80-20-Regel“) eine wesentliche Rolle. Das gilt speziell für Netzwerke, in denen das Web 2.0 Design Pattern des „Long Tail“ gültig ist [1], die also dem Skalengesetz unterliegen.

Die Eintrittswahrscheinlichkeiten der verschiedenen Ereignisse sind nicht gleich verteilt: Einige Ereignisse treten massiv gehäuft auf, wohingegen andere äußerst selten sind. Das Social Web macht sich nun die Tatsache zunutze, dass die sehr große Anzahl von Anwendern dazu führt, dass selbst äußerst unwahrscheinliche Ereignisse eintreten können und werden. Ein Ereignis kann im Social Web beispielsweise der Kauf eines bestimmten Produkts sein oder die Tatsache, dass eine Website zu einer anderen einen Link besitzt. Die Menge an Ereignissen, die im „Long Tail“ – wie in Abb. 2 dargestellt – eintritt, kann groß genug sein, um zahlenmäßig relevant zu sein. Diese und andere Erkenntnisse, die aus der Beobachtung von Graphen gewonnen werden können, machen sehr mächtige mathematisch (und zum Teil empirisch) fundierte Analysen von bestehenden Datenbeständen möglich. Die Analyseergebnisse wiederum können dazu verwendet werden, die Top-Down-Strategien einer Organisation anzupassen.



Abb. 2. Konzeptionelle Grafik eines „Long Tails“. Ereignisse und deren Auftretenswahrscheinlichkeit sind gegeneinander aufgetragen. Im linken Bereich ist die (kleine) Menge sehr häufiger Ereignisse dargestellt. Rechts (im „Tail“ des Graphen) ist die große Menge an seltenen (unwahrscheinlichen) Ereignissen dargestellt. Das Bild stammt von Hay Kranen/PD

Beispiele für Anwendungsmöglichkeiten finden sich in der Analyse sozialer Netzwerke [31], von Koautoren-Netzwerken [15], Produktempfehlungen auf Basis anderer Kunden [11, 12] oder Vorhersagen über das zukünftige Verhalten eines Anwenders [22].

Organisation der Ergebnisse

Die Analyseergebnisse werden in Modellen organisiert, um sie beherrschbar und vergleichbar zu machen. Die Auswahl der Art des Modells und der Eigenschaften, die abgebildet werden sollen, ist vom Anwendungsfall abhängig. Eine sehr anschauliche Darstellung von Modellen findet sich in [17]. In [13] wird ein spezifisches Modell aus der Domäne des arbeitsplatzintegrierten Lernens präsentiert. Für einige andere Anwendungsfälle sind die Modelle als semantische Technologien implementiert worden. Das Friend of a Friend (FOAF) Projekt¹⁵ beispielsweise modelliert soziale Netzwerke mittels eines RDF Schemas¹⁶. Personen, die ein gemeinsames Netzwerk aufbauen, werden als Mitglieder von Gruppen modelliert. Der Vorteil von FOAF liegt in der Flexibilität. Es können beliebige Ausdrücke in RDF und der Web Ontology Language (OWL¹⁷) verwendet werden, um die Klasse oder Eigenschaften einer Klasse zu definieren, zu der eine Person gehören muss, um Mitglied einer Gruppe zu werden. Software, die in der Lage ist diese Ausdrücke und Regeln zu interpretieren, kann auf Basis von beobachtetem Anwender-Verhalten Mitgliedschaften feststellen oder Vorschläge für Mitgliedschaften generieren. Die Struktur und die Bildungsregeln eines sozialen Netzwerkes, das so entsteht, müssen also vorab nicht bekannt sein. Das Netzwerk ist „emergent“, da es durch Anwender-Verhalten dynamisch Struktur annimmt, und es ist dennoch formal modelliert und kann maschinell interpretiert werden. Die Semantically-Interlinked Online Communities (SIOC¹⁸) Ontologie folgt einem ähnlichen Grundprinzip wie FOAF. SIOC modelliert Online Communities, die sich auf Social-Software-Plattformen bilden. Das Ziel ist es, Gruppen, Personen und Inhalte unterschiedlicher Communities miteinander in Verbindung zu setzen [2]. SIOC und FOAF sind in Teilen aufeinander abbildbar und können gemeinsam genutzt werden, um beispielsweise über die Grenzen einer Community oder Social Software Plattform hinweg soziale Netzwerke zu erfassen.

¹⁵ <http://www.foaf-project.org/>

¹⁶ <http://www.w3.org/TR/rdf-schema/>

¹⁷ <http://www.w3.org/TR/owl-features/>

¹⁸ <http://sioc-project.org/>

Die inhaltliche Dimension kann über ein Wissensorganisationssystem (englisch Knowledge Organisation System, KOS) modelliert werden. Der Onlinehändler Amazon beispielsweise nutzt bekanntermaßen das Kaufverhalten von Kunden, um Produkte zu charakterisieren und zu empfehlen. Daneben macht sich Amazon allerdings eine selbst erstellte Taxonomie zunutze, um Produkte zu klassifizieren [31]. Die Taxonomie umfasst mehr als 13.000 Konzepte, nach denen Bücher klassifiziert werden können, und mehr als 16.000 Konzepte für DVDs. Eine RDF-basierte Organisationsform für das Modellieren von Wissen ist Simple Knowledge Organisation System(s) (SKOS¹⁹). Mit SKOS können Inhalte hinsichtlich der enthaltenen Konzepte beschrieben werden. Die Konzepte können in ihrer Beziehung zu anderen Konzepten beschrieben werden (beispielsweise „verwandt zu“, „Überbegriff“, „engerer Begriff“). Durch die Integration von beispielsweise SKOS und FOAF können soziale Netzwerke auf Basis inhaltlicher Beziehungen modelliert werden und die Information mittels Einbeziehung von SIOC auf anderen Plattformen weiter verwendet werden.

Die Kombination von beispielsweise FOAF, SIOC und SKOS wird im Wesentlichen durch zwei Aktivitäten möglich gemacht: die Vernetzung der Daten und Modelle und die Nutzung von Services. Die Vernetzung der Daten und der Modelle (eine technisch absolut nicht-triviale Aufgabe, vergleiche [29]) wird, wie gezeigt, durch die Anwendung semantischer Technologien unterstützt, die problemlos nebeneinander eingesetzt werden können. Der Begriff der Services bedarf noch einer weiteren Klärung; im Prinzip handelt es sich dabei aber um eine funktionale Dekomposition von Anwendungen in Sub-Anwendungen (die Services). Diese arbeiten dabei auf der Datenbasis der übergeordneten Anwendung und produzieren ein exakt definiertes Ergebnis, das idealerweise ganz genau darauf abgestimmt ist, ein spezifisches Anwender-Interesse zu befriedigen. Beispiele für Services sind Google Alerts²⁰, in denen Anwender ein Service nutzen können, das autonom die gesamte Google-Datenbasis nach vorab definierten Suchwörtern durchsucht und jedes Mal, wenn ein neues Dokument dazu gefunden wird, den Anwender benachrichtigt. Ein anderes Beispiel bietet Amazon: Das Amazon eCommerce Portal besteht laut Gray ([5]) aus hunderten von einzelnen Services, die alle gemeinsam auf der Datenbasis von Amazon operieren und die bestmögliche Nutzung des Portals durch Anwender ermöglichen sollen. Zwei Beispiele für Services sind das Sales Rank Service, das die Verkaufszahlen eines Produkts relativ zu anderen Produkten angibt, und ein Service, das aufgrund des Inhalts ähnliche Bücher gruppiert (Statistically-Improbable Phrases Service). Einige dieser Services werden von Amazon nach außen hin frei angeboten und können

¹⁹ <http://www.w3.org/2004/02/skos/>

²⁰ <http://www.google.com/alerts>

von externen Entwicklern kostenfrei für deren eigene Anwendungen genutzt werden. Eine mögliche Weiterentwicklung der Idee der Service-Orientierung ist durch den „Service-basierten, individualisierten Wissensdesktop“ beschrieben. Dieser nutzt und orchestriert verteilte Services und stellt die Ergebnisse in funktional abgeschlossenen, aber auf der Datenebene vernetzten Anwendungen dar. Diese Anwendungen können auf der Basis der oben erwähnten Technologien wie AIR, Silverlight oder JavaFX als so genannte Widgets oder Gadgets implementiert werden. Die Realisierung von Widgets ist technisch derzeit leicht machbar. Tatsächlich aber sind erst wenige nutzenstiftende Widgets aus den Entwicklungslabors hervorgegangen. Die industrielle Softwareentwicklung beginnt erst, das Potential zu erfassen. Der folgende, abschließende Absatz dient dazu, den Status Quo in der Softwareentwicklung anhand von bestehenden Applikationen, Frameworks oder Services zu skizzieren.

Anwendungen in Software heute

Es verwundert nicht weiter, dass die Kombination von Beobachtung und Modellierungen im Social Web bereits Anwendung findet. Für die Blog-Software WordPress²¹ steht ein Plugin namens „FOAF Output“ zur Verfügung²². Dieses Plugin analysiert Blog-Einträge und exportiert den Inhalt als FOAF- und SKOS-Modelle. Ein anderes Plugin für WordPress ist „Yahoo! Shortcuts“²³. Dieses Plugin erkennt während der Erstellung eines Blogeintrags Wörter, die Personennamen, Orte, Produkte oder Firmen sein können, und hinterlegt die entsprechenden Wörter mit semantischer Information. Anwender können die erstellten Vorschläge akzeptieren oder verwerfen und abhängig von der Art und dem Inhalt der semantischen Information Fotos, Kartenmaterial oder Börseninformationen hinzufügen, um den Blogeintrag aufzuwerten.

Microsoft Office nutzt einen ähnlichen Ansatz, die sogenannten SmartTags (siehe Abb. 3). SmartTags sind semantische Informationen, die zu Wörtern erzeugt werden, wenn diese als Adresse, Datum, Person, Ort oder Ähnliches identifiziert werden können. Diese Informationen können genutzt werden, um zu einem SmartTag bestimmte Funktionen zu aktivieren, wie beispielsweise das Öffnen des Kalenders, um ein Datum anzuzeigen, oder das Versenden einer Email an eine identifizierte Person.

²¹ <http://www.wordpress.org/>

²² <http://www.wasab.dk/morten/blog/archives/2004/07/05/wordpress-plugin-foaf-output>

²³ <http://shortcuts.yahoo.com/>




Abb. 3. Anreicherung von Texten mit semantischer Information mit Microsoft Office SmartTags. SmartTags erkennen Adressen, Datumsangaben, Maßeinheiten, Orte, Kontakte, Telefonnummern und Uhrzeiten und stellen informationsspezifische Aktionen zur Verfügung

Die oben skizzierten Funktionen beobachten das Verhalten des Anwenders beim Verfassen von Texten und extrahieren aus dem Inhalt semantische Informationen, modellieren diese (mehr oder weniger transparent) und stellen zusätzliche Funktionalität zur Verfügung, um die extrahierte Information unmittelbar nutzen zu können. Ein anderer Ansatz besteht darin, das Verhalten von Anwendern zu analysieren, um daraus soziale Strukturen abzuleiten, wie es auf Social Networking Plattformen üblich ist. Für Facebook²⁴ beispielsweise gibt es zahlreiche Erweiterungen, die auf die soziale Struktur eines Anwenders zugreifen und diese visualisieren. Fravity²⁵ beispielsweise erstellt eine Struktur aus den Profildaten eines Anwenders und bereitet diese so auf, dass Personen, die viele Freunde gemeinsam haben, näher beieinander dargestellt werden als Personen, deren Netzwerke sich nicht überlappen (siehe Abb. 4). Das typische Kommunikationsverhalten von Anwendern kann ebenfalls für solche Analysen verwendet werden. Das Outlook-Plugin Xobni Insight²⁶ analysiert den Email-Verkehr und errechnet Beziehungsstrukturen auf Basis der gemeinsamen Adressaten von Emails. Außerdem bietet Xobni den Zugriff auf Email-Konversationen mit einer Person und weitere statistische Kenngrößen, die über soziale Beziehungen Auskunft geben (siehe Abb. 4).

²⁴ <http://www.facebook.com/>

²⁵ <http://apps.facebook.com/fravity/>

²⁶ <http://www.xobni.com/>




Abb. 4. Soziale Netzwerke lassen sich beispielsweise aus dem Verhalten eines Anwenders auf einer Social Networking Plattform errechnen oder aus dem Email-Verkehr. Zwei Beispiele: Facebook-Applikation Fravity (A) und das Outlook-Plugin Xobni (B)

Soziale Netzwerke und Netzwerkanalyse spielen auch bei dem (derzeit nicht weitergeführten) Projekt Flink²⁷ eine Rolle. Flink verwendet FOAF zum Aufbau von Netzwerken von Koautoren ([15]). Die Beziehungen von Autoren und die Relevanz von Autoren innerhalb einer Gruppe können über Beobachtung von Artikeln, Analyse der Beziehungsstrukturen, Modellierung als FOAF-Graphen und Visualisierung der Netzwerkstruktur ermittelt werden. Die Website They Rule²⁸ verfolgt einen ähnlichen Ansatz, allerdings ein anderes Ziel: Die Website beobachtet Aufsichtsräte der 500 größten Firmen in den USA, analysiert, welche Firmen Aufsichtsräte gemeinsam haben, modelliert die Netzwerke mit FOAF und visualisiert die so ermittelte Beziehungsstruktur.

Ein anderer Ansatz wird von Twine²⁹ verfolgt: Twine speichert und analysiert alle Inhalte, die ein Anwender während des täglichen Umgangs mit dem Computer als wichtig kennzeichnet. Inhalte werden mit semantischen Informationen (RDF und OWL) versehen und die semantischen Informationen werden von Algorithmen im Hintergrund dafür benutzt, ein maschi-

²⁷ <http://flink.semanticweb.org/>

²⁸ <http://www.theyrule.net/>

²⁹ <http://www.twine.com/>

nell interpretierbares Interessensprofil des Anwenders zu erzeugen. Das Profil wird mit den Profilen anderer Twine-Anwender verglichen, und Twine ist so in der Lage, für Anwender Empfehlungen zu generieren, die sich auf das tägliche Verhalten während der Arbeit oder Freizeit beziehen. Dazu gehören potentiell interessante Inhalte, Menschen mit vergleichbaren Interessensprofilen und neue Interessensgebiete, die zum Profil des Anwenders passen könnten.

Die vorgestellten Services sind fest in dem Software-Kontext eingebettet, für den sie geschrieben worden sind. Einen komplementären Ansatz verfolgt die Nachrichtenagentur Reuters mit dem 2007 erworbenen servicebasierten System OpenCalais³⁰. OpenCalais ist über Webservice-Schnittstellen zugänglich und extrahiert aus (englischen) Texten Konzepte wie Personennamen, Währungen, Orte, Fachbegriffe oder Firmen. Dann wendet OpenCalais Algorithmen an, um Fakten (Person arbeitet für Firma) und Ereignisse (Firma übernimmt andere Firma) zu extrahieren. Zu diesen Informationen wird ein RDF-Graph erstellt, der an den Konsumenten des Web-Service zurück geliefert wird. Die solcherart erstellte semantische Information kann in externen Systemen weiter verwendet werden. Reuters bietet OpenCalais für Entwickler derzeit kostenlos an. Der einzige Lohn, der Reuters verbleibt, sind die erzeugten Metadaten – nicht einmal die Inhalte, die übermittelt worden sind, werden gespeichert.

Fazit

Dieser Beitrag befasste sich mit der Fragestellung, wie beobachtetes Verhalten in organisiertes „Wissen“ transformiert werden kann und wie das heute schon tatsächlich in Software geschieht. Es zeigt sich, dass das Social Web und das Semantic Web zunehmend konvergieren, also Eigenschaften des jeweils anderen annehmen und sich vernetzen. Beobachtungen im Social Web werden aufbereitet und so organisiert, dass sie im Semantic Web nutzbar sind. Aktuell scheint es so zu sein, dass die Themen semantische Anreicherung von Anwender-erstellten Texten und Analyse von sozialen Netzwerken dominieren. Ein Trend, der künftig vielleicht eine größere Rolle spielt, ist ebenfalls herausgearbeitet worden: die Nutzung und Vernetzung von verteilten Services durch Widgets und die Abstimmung auf klar definierte und kommunizierbare Interessen oder Erwartungen von Anwendern. Diese Trends werden im Web der Zukunft, unabhängig von dessen Versionsnummer, zweifellos eine große Rolle spielen.

³⁰ <http://www.opencalais.com/>

Danksagung

Das Know-Center wird im Rahmen des Österreichischen COMET-Programms – Competence Centers for Excellent Technologies – gefördert. Das Programm steht unter der Schirmherrschaft des Österreichischen Bundesministeriums für Verkehr, Innovation und Technologie, des Österreichischen Bundesministeriums für Wirtschaft und Arbeit und des Landes Steiermark. Die Abwicklung des Programms erfolgt durch die Österreichische Forschungsförderungsgesellschaft FFG.

Literatur

1. C. Anderson: The Long Tail, in: Wired, 10, 2004, pp. 170–177.
2. J.G. Breslin et al., Towards Semantically-Interlinked Online Communities, in: Lecture Notes in Computer Science, 3532, 2005, pp. 500–514.
3. M. Davis: Semantic Wave 2008 Report: Industry Roadmap to Web 3.0 & Multibillion Dollar Market Opportunities, Project10X, 2007.
4. J.J. Garrett: Ajax: A New Approach to Web Applications, Adaptive Path, 2005. 6.3.2008:
<http://www.adaptivepath.com/ideas/essays/archives/000385.php>
5. J. Gray: A Conversation with Werner Vogels, in: ACM Queue, 4(4), 2006, 15.3.2008.
6. T. Gruber: Ontology of Folksonomy: A Mash-Up of Apples and Oranges, in: International Journal of Semantic Web and Information Systems, 3(1), 2007, pp. 1–11.
7. T. Gruber: Collective knowledge systems: Where the Social Web meets the Semantic Web, in: Web Semantics: Science, Services and Agents on the World Wide Web, 6(1), 2008, pp. 4–13.
8. D. Hinchcliffe: All We Got Was Web 1.0, When Tim Berners-Lee Actually Gave Us Web 2.0, Dion Hinchcliffe's Web 2.0 Blog, 2006. 11.3.2008:
<http://web2.socialcomputingmagazine.com/>
9. J.M. Kleinberg et al.: The Web as a Graph: Measurements, Models, and Methods, in: T. Asano et al. (Ed.): Lecture Notes in Computer Science, 1627, 1999, pp. 1–17.
10. J. Leskovec, J.M. Kleinberg and C. Faloutsos: Graph Evolution: Densification and Shrinking Diameters, in: ACM Transactions on Knowledge Discovery from data, 1(1), 2007.
11. G. Linden, J.A. Jacobi and E.A. Benson,: Collaborative Recommendations Using Item-to-Item Similarity Mappings, U.S. Patent 6,266,649 B1, 2001.
12. G. Linden, B. Smith and J. York: Amazon.com Recommendations Item-to-Item Collaborative Filtering, in: IEEE Internet Computing, January/February, 2003.
13. S.N. Lindstaedt & A. Ulbrich: Integration von Arbeiten und Lernen – Kompetenzentwicklung in Arbeitsprozessen, in: A. Blumauer & T. Pellegrini (Ed.): Semantic Web – Wege zur vernetzten Wissensgesellschaft, Springer Verlag, 2006.

14. R. MacManus: 10 Semantic Apps to Watch, in: ReadWriteWeb, 2007, 15.3.2008
http://www.readwriteweb.com/archives/10_semantic_apps_to_watch.php
15. P. Mika: Ontologies Are Us: A Unified model of Social Networks and Semantics, in: Lecture Notes in Computer Science, 3729, 2005, pp. 522–536.
16. J.S. Mitchell and M. Dewey: Dewey-Dezimalklassifikation DDC 22 und Register, 4 Bände, München: K.G. Saur, 2005.
17. M. Montaner, B. López and J.L. De la Rosa: A Taxonomy of Recommender Agents on the Internet, in: Artificial Intelligence Review, 19, 2003, pp. 285–330.
18. J. Musser and T. O'Reilly: Web 2.0 Principles and Best Practices, in O'Reilly Radar, O'Reilly Media Inc., 2006.
19. M.E.J. Newman: The Structure and Function of Complex Networks, in: Society for Industrial and Applied Mathematics Review, 45(2), 2003, pp. 167–256.
20. M.E.J. Newman: Power laws, Pareto distributions and Zipf's law, in: Contemporary Physics, 46, 2005.
21. T. O'Reilly: What Is Web 2.0 – Design Patterns and Business Models for the Next Generation of Software, 2005. 10.5.2006
<http://www.oreillynet.com/lpt/a/6228>
22. C.O. Paepke: Method for Predicting Ratings, U.S. Paten 6,249,785 B1, 2001.
23. L. Page & S. Brin et al.: The PageRank Citation Ranking: Bringing Order to the Web, 1998.
24. S.J. Russell & P. Norvig: Artificial Intelligence: A Modern Approach, Prentice Hall International, 2003.
25. N. Spivack: New Version of my „Metaweb“ Graph – The Future of the Net, in: Minding the Planet, 2004, 15.3.2008 http://novaspivack.typepad.com/nova_spivacks_weblog/2004/04/new_version_of_.html
26. N. Spivack: Minding the Planet – The Meaning and Future of the Semantic Web, in: Minding the Planet, 2006, 15.3.2008
http://novaspivack.typepad.com/Minding_the_Planet_Article.pdf
27. N. Spivack: Web 3.0 – The Best Official Definition Imaginable, in: Minding the Planet, 2007, 15.3.2008 http://novaspivack.typepad.com/nova_spivacks_weblog/2007/10/web-30----the-a.html
28. S. Staab et al.: Knowledge processes and ontologies, in: IEEE Intelligent Systems and Their Applications, 16(1), 2001, pp. 26–34.
29. P. Tan, S. Madnick and K. Tan: Context Mediation in the Semantic Web: Handling OWL Ontology and Data Disparity through Context Interchange, MIT Sloan Working Paper 4496-04, 2004.
30. T. vander Wal: Feed on This, in: Off the Top: Folksonomy Entries, 2004, 15.3.2008 <http://www.vanderwal.net/random/category.php?cat=153>
31. S. Wassermann and K. Faust: Social Network Analysis. Methods and Applications (Structural Analysis in the Social Sciences), Cambridge: Cambridge University Press, 1994.
32. C. Ziegler, L. Schmidt-Thieme and G. Lausen. Exploiting semantic product descriptions for recommender systems, IN. Proceedings of the 2nd ACM SIGIR Semantic Web and Information Retrieval Workshop, 2004.

10. Expertise bewerben und finden im Social Semantic Web

Axel Polleres¹ und Malgorzata Mochol²

¹ Digital Enterprise Research Institute National University of Ireland
axel@polleres.net

² Freie Universität Berlin, AG Netzbasierte Informationssysteme
mochol@inf.fu-berlin.de

Zusammenfassung: Im vorliegenden Beitrag diskutieren wir Rahmenbedingungen zur Kombination, Wiederverwendung und Erweiterung bestehender RDF-Vokabulare im Social Semantic Web. Hierbei konzentrieren wir uns auf das Anwendungsszenario des Auffindens und Bewerbens von Experten im Web oder Intranet. Wir präsentieren, wie RDF-Vokabulare einerseits und de facto Standardformate andererseits, die von täglich verwendeten Applikationen benutzt werden (z. B. vCard, iCal oder Dublin Core), kombiniert werden können, um konkrete Anwendungsfälle der Expertensuche und zum Management von Expertise zu lösen. Unser Fokus liegt darauf aufzuzeigen, dass für praktische Anwendungsszenarien nicht notwendigerweise neue Ontologien entwickelt werden müssen, sondern der Schlüssel vielmehr in der Integration von bestehenden, weit verbreiteten und sich ergänzenden Formaten zu einem kohärenten Netzwerk von Ontologien liegt. Dieser Ansatz garantiert sowohl direkte Anwendbarkeit von als auch niedrige Einstiegsbarrieren in Semantic Web-Technologien sowie einfache Integrierbarkeit in bestehende Applikationen. Die im Web verfügbaren und verwendeten RDF-Formate decken zwar einen großen Bereich der Aspekte zur Beschreibung von Personen und Expertisen ab, zeigen aber auch signifikante Überlappungen. Bisher gibt es wenig systematische Ansätze, um diese Vokabulare zu verbinden, sei es in Form von allgemeingültigen Praktiken, die definieren, wann welches Format zu benutzen ist, oder in Form von Regeln, die Überlappungen zwischen einzelnen Formaten formalisieren. Der vorliegende Artikel analysiert, wie bestehende Formate zur Beschreibung von Personen, Organisationen und deren Expertise kombiniert und, wo nötig, erweitert werden können. Darüber hinaus diskutieren wir Regelsprachen zur Beschreibung von Formatüberlappungen sowie deren praktische Verwendbarkeit zur Erstellung eines Ontologie-Netzwerks zur Beschreibung von Experten.

Einführung

Das Semantic Web ist da! Eine stetig wachsende Anzahl von Individuen und Organisationen beginnt damit, Metadaten in Form von RDF-Annotationen auf ihren Webseiten zur Verfügung zu stellen. Neben RDF/XML [27] bieten neue Technologien wie Mikroformate¹ die Möglichkeit, Metadaten einfacher als bisher direkt in beliebige HTML- oder XHTML-Dokumente einzubetten. Die vom World Wide Web Consortium (W3C) kürzlich ins Leben gerufene GRDDL [17] Arbeitsgruppe² entwickelt standardisierte Mechanismen, um semantisch reichhaltigere Daten in RDF aus (semi-)strukturierten Daten zu extrahieren. Eine weitere W3C-Arbeitsgruppe – Semantic Web Best Practices and Deployment³ – bietet Richtlinien zur Publikation und syntaktischen Kombination von RDF-Daten [27, 12] und OWL-Ontologien [37] an. Darüber hinaus helfen Browsererweiterungen wie Semantic Radar⁴ RDF-Annotationen auf Webseiten zu entdecken, und eine Reihe von generischen RDF Browsern wie Tabulator⁵ und Suchmaschinen wie SWSE [23] oder Sindice [44] erlauben Anwendern, direkt im Semantic Web zu ‚surfen‘.

Nachdem also die Infrastruktur des Semantic Web beachtliche Fortschritte gemacht hat und syntaktische Hindernisse zum Verbinden von Metadaten weitgehend beseitigt scheinen, wollen wir uns hier genauer mit der Frage befassen, welche RDF-Vokabulare und -Ontologien tatsächlich verwendet werden können, um eine bestimmte Domäne, in unserem Fall Metadaten über Personen und Organisationen, zu beschreiben. Für diesen Zweck widmen wir uns einer viel versprechenden Schlüsselapplikation von Semantic Web-Technologien: dem Auffinden von Experten (Individuen, Teams, Organisationen) im Web.

Obwohl ein Gutteil existierender Webseiten genau darauf abzielt, Expertisen von Personen oder Organisationen zu bewerben, bleiben Suchmöglichkeiten auf Schlagwörter oder Branchenverzeichnisse, die manuell aggregiert wurden, beschränkt. Unsere Annahme ist, dass im Web beworbene Institutionen, Projekte, Personen und Events durch eine Handvoll maschinenlesbarer Formate beschrieben werden können. Dadurch wird das automatische Auffinden von Expertise/Experten in einer bestimmten Domäne oder für eine bestimmte Aufgabe möglich. Um dieses Ziel zu erreichen und ähnliche Anwendungsszenarien von semantischer Suche im

¹ <http://microformats.org/>

² <http://www.w3.org/2001/sw/grddl-wg/>

³ <http://www.w3.org/2001/sw/BestPractices/>

⁴ <http://sioc-project.org/firefox/>

⁵ <http://www.w3.org/2005/ajar/tab>

Web zu verwirklichen, lassen sich drei kritische Erfolgskriterien, die sich gegenseitig beeinflussen, festmachen:

1. Gemeinsam verwendete, maschinenlesbare Formate
2. Kritische Masse von Anwendern/Nutzern
3. Zusätzlich benötigte Technologien

Gemeinsame Formate und Ontologien sind im Web nur dann nützlich, wenn sie von einer *kritischen Masse* von Anwendern und Applikationen unterstützt werden. Die Erfahrung zeigt, dass nicht unbedingt umfangreiche und detaillierte Ontologien den höchsten Verbreitungsgrad erfahren, sondern oft einfache Formate, die auf das Wesentliche reduziert sind wie beispielsweise FOAF [13] oder SIOC [6]. *Zusätzliche Technologien* sind nötig, um diese Formate miteinander zu verbinden. Dies ist insbesondere dann der Fall, wenn man sich noch nicht auf ein Format oder geeignete Algorithmen geeinigt hat. Zusätzliche Technologien wie Regel- und Abfragesprachen werden hier beispielsweise benötigt, um Überlappungen und Übersetzungen zwischen verschiedenen Formaten deklarativ zu beschreiben oder um gezielte Anfragen nach bestimmten Expertenprofilen zu stellen.

Wir werden im Folgenden auf jeden dieser Faktoren im Einzelnen eingehen (siehe Abschn. 2) und Implikationen für die Anwendungsdomäne des Auffindens und Bewerbens von Experten im Web erläutern. Anschließend stellen wir in Abschn. 3 die ExpertFinder-Initiative vor, welche sich zum Ziel gesetzt hat, das Semantic Web in dieser Anwendungsdomäne anhand von etlichen konkreten Szenarien zur Anwendung zu bringen. In Abschn. 4 stellen wir Standardformate und Ontologien vor, welche direkt zur Beschreibung von Experten im Web verwendet werden können oder indirekt eine Bedeutung für diese Domäne haben. Weitere relevante Projekte und Anwendungen werden in Abschn. 5 diskutiert. Abschließende Bemerkungen samt Ausblick finden sich in Abschn. 6.

Erfolgskriterien für Semantic Web-basierte Expertensuche

In diesem Abschnitt wollen wir im Einzelnen die drei oben genannten Faktoren in Hinblick auf die Anwendungsdomäne webbasierte Expertensuche diskutieren.

Gemeinsam verwendete, maschinenlesbare Formate

Für den Moment nehmen wir an, dass syntaktische Fragen bezüglich der Form, in welcher Metadaten publiziert werden sollen, um im Web auffindbar zu sein, geklärt sind, d. h. dass:

- RDF als Standardformat zur Publikation von Metadaten dient,
- Informationsanbieter wissen, wie sie semantische Annotationen zu ihren Webseiten hinzufügen können,
- Werkzeuge zur Verfügung stehen, um diese Metadaten auszulesen und zu sammeln.

Zu klären bleibt die Frage nach semantischen Aspekten, d. h. die Frage nach existierenden und verbreiteten Ontologien und RDF-Vokabularen, auf die Informationsanbieter zurückgreifen können, um ihre Expertise und andere relevante Aspekte präzise und umfassend zu beschreiben. Neben eigentlichen Qualifikationen und Geschäftssektoren sollen diese Vokabulare auch Aspekte beschreiben, die man typischerweise in Organisationsprofilen oder Lebensläufen findet, wie Adressen, Publikationen, Projekte und Projektpartner, Referenzen und relevante Kontakte, aber auch Informationen zur Verfügbarkeit, zu sozialen Netzwerken und dergleichen mehr. In Abschn. 4 werden wir relevante RDF-Vokabulare, die all diese Bereiche abdecken, analysieren und sie evtl. vorhandenen Standards aus der Geschäftswelt gegenüberstellen.

Kritische Masse

Unabhängig davon, welche(s) RDF-Vokabular(e) wir zur Beschreibung von Expertise im (Semantic) Web verwenden wollen, um Webskalierbarkeit zu erreichen, ist es unumgänglich, dass:

1. eine kritische Masse von Anwendern und Informationsanbietern überzeugt wird, die vorgeschlagenen Formate zu benutzen oder zu unterstützen,
2. existierende Inhalte in die gewählten Formate übersetzt/importiert werden können,
3. Mechanismen zur Verfügung stehen, um die ausgewählten Formate mit bereits im Web verwendeten Formaten zu kombinieren (z. B. unter Verwendung von `owl:equivalentClass`, `owl:equivalentProperty`) bzw. die existierenden Formate weitestgehend wiederzuverwenden.

In Bezug auf Punkt (1) sei angemerkt, dass eine neue Ontologie zu entwickeln, eine aktive User-Community zu akquirieren, bzw. eine neue Ontologie in einer bestehenden Community zu etablieren sehr schwierig ist. In der offenen Community der Webbenutzer kann man annehmen, dass dieses Unterfangen nicht nur wenig erfolgversprechend sondern schlichtweg unmöglich ist. Individuelle User oder Organisationen benutzen Teile von Ontologien, erweitern diese für ihre eigenen Bedürfnisse und benutzen verschiedene URIs, um gleiche oder zumindest überlappende Konzepte zu

beschreiben. Bezüglich Punkt (2) haben Textextraktionsmethoden oder Wrapper Technologien⁶ in den letzten Jahren höhere Stabilität erreicht. Projekte wie PiggyBank [25] haben gezeigt, dass gemeinsame Nutzung von dezentralen Wrappern ein durchaus erfolgreicher Ansatz sein kann, um RDF-Daten aus bestehenden Quellen im Web zu gewinnen. In diesem Zusammenhang könnten Semantic Web Pipes [35] im Stil von Yahoo's Web Pipes⁷ der nächste logische Schritt sein. Dennoch lösen solche Ansätze das Problem nur zum Teil, da die Qualität von „Wrappern“ oder „Pipes“ stark von der Qualität und Stabilität der Formate der Quelldaten abhängig ist. Das grundlegende Problem bezüglich der Frage, welche RDF-Ontologien/Vokabulare für die generierten Metadaten zu verwenden sind, bleibt bestehen. Außerdem gibt es in den meisten Domänen, speziell im Bereich Expertensuche nicht „die richtige“ Ontologie, weshalb sich unsere Arbeit hauptsächlich auf Punkt (3) konzentriert. Wir wollen versuchen, so effektiv wie möglich existierende Formate, welche sich durch einen kritischen *Verbreitungsgrad* bereits etabliert haben, wiederzuverwenden. Zu diesem Zweck wollen wir bestehende Formate analysieren, eventuelle Überlappungen formal beschreiben und Richtlinien erstellen, wie diese Formate gemeinsam zu verwenden sind. Die ExpertFinder-Initiative folgt dieser Idee. Ein praktischer Nebeneffekt der Wiederverwendung bestehender Formate und Vokabulare ist neben Feedback von bestehenden User-Communitys, dass wir auf bestehende Tools zurückgreifen können. Formate wie iCal [16], vCard [46], oder BibTeX [36] und deren RDF-Varianten werden beispielsweise von Werkzeugen wie Kalender- und Adressbuchapplikationen oder Online-Publikationsverzeichnissen wie DBLP⁸ und CiteSeer⁹ unterstützt und können somit als Standardaustauschformate für die jeweilige Teildomäne, die sie abdecken, verwendet werden.

Zusätzlich benötigte Technologien

Während wir uns bisher ausschließlich damit befassen haben, wie die nötigen Metadaten im Web repräsentiert werden, wollen wir uns nun fragen, welche zusätzlichen Technologien fehlen, um diese Metadaten für praktische Anwendungsfälle (mehr dazu in Abschn. 3) zu nutzen. Hier spielen

⁶ Der Überbegriff „Wrapper“ wird oft für semi-deklarative Extraktionsmethoden wie XSLT [18] oder spezielle Tools verwendet, die semi-strukturierte Daten wie Webseiten oder allgemeiner XML Formate in andere XML Formate oder auch RDF übersetzen.

⁷ <http://pipes.yahoo.com/>

⁸ <http://dblp.uni-trier.de/>

⁹ <http://citeseer.ist.psu.edu/>

einerseits Regeln, z. B. in Form von formalisierten Business-Strategien und -Richtlinien, aber auch Empfehlungsalgorithmen, kollaborative Filter-Algorithmen, statistische Methoden etc. eine wichtige Rolle. All diese Methoden können hilfreich, sein um Metadaten zu generieren und zu verbinden, Suchergebnisse richtig zu reihen und zu bewerten. Zudem werden Mechanismen zur Sicherstellung von Datenschutz und Datensicherheit, sowie Verhandlung von Vertrauensverhältnissen zwischen Partnern benötigt, um zu vermeiden, dass personenspezifische oder andere schützenswerte Daten im Web in die falschen Hände geraten. In mehreren dieser Teilfragen werden Regelsprachen und Regelverarbeitungssysteme eine Schlüsselrolle spielen. Denn:

1. solche Regeln (gemeinsam mit ausdrucksstarken Ontologiesprachen wie OWL) erlauben uns die exakten Verbindungen und Überlappungen zwischen bestehenden RDF-Vokabularen und Ontologien formal zu beschreiben,
2. durch Regeln lassen sich Richtlinien ausdrücken, die z. B. festlegen, unter welchen Umständen man bereit ist, bestimmte Metadaten zu teilen oder an Dritte weiterzugeben [10].

Grundsätzlich ist festzustellen, dass einerseits viele RDF-Vokabulare wie z. B. FOAF und SIOC zwar schon weitgehend in OWL formalisiert sind, aber viele Features von OWL gar nicht nutzen und größtenteils mit Sprachkonstrukten des ausdrucksschwächeren RDF-Schemas [12] auskommen. Andererseits jedoch sind die Möglichkeiten von OWL nicht ausreichend, um die Überlappungen zwischen bestehenden RDF-Vokabularen exakt zu beschreiben, wie wir an einem kleinen Beispiel zeigen können: Nehmen wir an, wir wollen RDF-Daten austauschen, welche einerseits das FOAF-Format [13] und andererseits vCard [26] verwenden, d. h. wir wollen von RDF-Tripeln, die das `vCard:homeTel` Attribut verwenden nach `foaf:phone` übersetzen, wobei ersteres ein sogenanntes Datatype-Property (dessen Wertebereich RDF-Literale, also Zeichenketten, vorschreibt) und letzteres ein sogenanntes Object-Property (dessen Wertebereich RDF-Ressourcen, also URIs, vorschreibt) ist. So eine Übersetzung lässt sich klarerweise nicht durch die normale Subproperty-Relation in RDFS oder OWL ausdrücken, da hier eine Wertkonversion nötig ist, um eine URI aus einem RDF-Literal zu generieren.

Nachdem das W3C bisweilen noch keinen Standard entwickelt hat, um solche Übersetzungen deklarativ zu beschreiben,¹⁰ könnte man versuchen

¹⁰ Man könnte XSLT [18] verwenden, um von einer RDF/XML Datei in eine andere zu übersetzen, aber das birgt mögliche Probleme in sich, da die RDF/XML Darstellung desselben RDF-Graphen nicht notwendigerweise eindeutig ist.

SPARQLs CONSTRUCT-Anfragen zur Beschreibung solcher Übersetzungsregeln zu ‚missbrauchen‘. SPARQL [40] ist die kommende Abfragesprache für RDF-Daten, welche Anfang 2008 durch das W3C empfohlen wurde. CONSTRUCT-Anfragen in SPARQL dienen dazu, neue RDF-Daten aus bestehenden RDF-Graphen zu generieren.

Für unsere Beispielübersetzung müssten wir eine Featureerweiterung in SPARQL, wie die Verwendung von XPath 2.0-Funktionen [31] in CONSTRUCTs, annehmen:

```
CONSTRUCT
{ ?X foaf:phone xsd:anyURI (fn:concat ("tel:", fn:encode-
for-uri (?T))) . }
WHERE
{ ?X vCard:tel ?T . }
```

Diese einfache Abfrage ist in der aktuellen Spezifikation von SPARQL jedoch noch nicht möglich. Entsprechende Erweiterungen werden in [3, 39] ausführlich diskutiert.

Neben Übersetzungsregeln können Regeln, die gemeinsam mit RDF-Daten publiziert werden, auch dazu dienen, implizite Metadaten zu beschreiben [29, 38]. Dies würde es ermöglichen, Metadaten von verschiedenen Informationsanbietern über (möglicherweise negative) Abhängigkeiten zu „verlinken“.¹¹ Hier ein paar für die Expertensuche relevante Beispieregeln:

Alle aufgelisteten Personen unter der URI

<http://www.w3.org/People/>

sind Experten in

<http://en.wikipedia.org/wiki/Semanticweb>.¹²

Alle aufgelisteten Personen unter der URI

<http://www.myExample.org/Contacts.rdf>,

die NICHT für aufgelistete Firmen unter

<http://www.myCompetitors/list.rdf>

arbeiten, sind meine Freunde.

<http://www.w3.org/People/Berners-Lee/cardi>

ist der Autor aller Publikationen, die unter

<http://dblp.uni-trier.de/Berners=Lee:Tim.html>

aufgelistet sind.

¹¹ Siehe dazu auch [21, Abschn. 2.10].

¹² Wikipedia-Adressenlinks sind eine von vielen Möglichkeiten um Themenbereichen von Expertisen eine eindeutige URI im Semantic Web zuzuordnen.

Syntaktisch könnte man hier wieder CONSTRUCT-Anfragen von SPARQL als View/Link-Definitionen benutzen, aber ein dezidierter Standard ist derzeit noch nicht verfügbar. Wir erwarten jedoch, dass das W3C, und insbesondere die RDF Data Access (DAWG) Arbeitsgruppe,¹³ die an SPARQL arbeitet, sowie die Rule Interchange Format (RIF) Arbeitsgruppe¹⁴ [7], die derzeit an einem Standardaustauschformat für Regeln im Web arbeitet, in absehbarer Zukunft entsprechende Spezifikationen liefern werden.

Praktische Anwendungsszenarien der ExpertFinder Initiative

Die ExpertFinder-Initiative¹⁵ ist eine lose Vereinigung diverser akademischer Partner und Proponenten der FOAF und SIOC Communities. Die Initiative strebt an, RDF-Vokabulare und Regelerweiterungen zu einem größeren Ganzen zu vereinen, um persönliche Homepages, Webseiten von Organisationen, Publikationsverzeichnisse oder auch akademische Konferenzwebseiten mit adäquaten Metadaten zu versehen. Dadurch soll die automatisierte Expertensuche im Web ermöglicht werden. Dazu sollen nicht nur bestehende RDF Vokabulare und deren Überlappungen analysiert werden, sondern auch Richtlinien erstellt werden, wie diese Formate gemeinsam zu verwenden sind. Die Initiative wurde 2006 gegründet, um relevante Forschungsprojekte zusammenzubringen und den in Abschn. 2 genannten Erfolgskriterien näher zu kommen. Ein konkretes Ziel der Initiative ist die Identifikation von tatsächlichen Anwendungsszenarien, in denen Mechanismen zur Expertensuche, basierend auf Semantic Web Technologien, angewandt werden können und für die ein solches Netzwerk von RDF-Vokabularen nützlich sein kann. Im Folgenden werden wir diese Szenarien kurz beschreiben.

Generierung von Instituts- und persönlichen Webseiten aus RDF-Metadaten

RDF-Metadaten sind an sich ein geeignetes Datenformat für Content Management Systeme (CMS), welche dynamische Inhalte vom Layout trennen. Obwohl solche Systeme derzeit meist auf traditionellen, relationalen Datenmodellen beruhen, ist zu erwarten, dass rein RDF-basierte CMS weit flexiblere Lösungen erlauben. Viele Forscher und Entwickler, die mit Semantic Web-Technologien zu tun haben, beginnen derzeit ihre persön-

¹³ <http://www.w3.org/2001/sw/DataAccess/>

¹⁴ <http://www.w3.org/2005/rules/>

¹⁵ <http://www.rdfweb.org/topic/ExpertFinder>

lichen Homepages mit dem Friend-of-a-Friend (FOAF) Vokabular zu annotieren. Mithilfe von CMS, die solche RDF-Daten direkt integrieren können, könnten einerseits Institutsangehörige ihre persönliche Information in ihren erweiterten FOAF-Dateien up-to-date halten; diese würden automatisch mit dem CMS der Organisation synchronisiert. Andererseits kann die Organisation Default-Regeln angeben, um evtl. fehlende Daten zu ergänzen. Solche Regeln können auch die Integration von Metadaten von Drittanbietern (siehe dazu die Beispielregeln in Abschn. 3) beinhalten und würden dynamische, dezentral verwaltete Webseiten ermöglichen.

Nehmen wir an, unser Kollege hat keine Zeit oder Lust, eigene Metadaten für die Institutswebseite zur Verfügung zu stellen. In unserem RDF-basierten Szenario wäre das kein Problem: Basisdaten können aus der Universitätsdatenbank übernommen werden, eine Publikationsliste kann aus den Daten von DBLP¹⁶ automatisch generiert werden etc. Sobald die zugrundeliegenden Quellen ihre Daten ihrerseits in RDF zur Verfügung stellen und gemeinsam verwendete Vokabulare unterstützen, kann eine solche Anwendung mithilfe von Regeln (vgl. Abschn. 2) ohne größere Schwierigkeiten die notwendigen Daten aggregieren. Indem man gemeinsam verwendete RDF-Formate direkt unterstützt, werden Export, Abfragen und die Kombination von Daten verschiedener Quellen zum Kinderspiel. Vorläufige Resultate des Gebrauchs von FOAF und anderen Metadaten-Formaten direkt als Grundlage von Homepages wurden beispielsweise im RDFHomepage Projekt [22] realisiert. Auch in Open Source CMS-Architekturen wie Drupal¹⁷ ist die direkte Integration von RDF-Datenquellen derzeit ein Thema¹⁸.

Personalwesen

Mithilfe von geeigneten RDF-Vokabularen können Jobsuchende ihr Profil oder ihren detaillierten Lebenslauf in Form von maschinenlesbaren Metadaten im Web publizieren oder Angestellte in einer Firma können unter Verwendung derselben Vokabulare ein Profil ihrer Fähigkeiten und Erfahrungen im Intranet zur Verfügung stellen. Im Gegenzug können öffentliche oder private Jobvermittlungsagenturen mittels Web-Agenten präferierte Profile im Netz finden, um geeignete Kandidaten für eine offene Stelle zu

¹⁶ DBLP-Daten stehen bereits in Form von RDF zur Verfügung:
<http://dblp.l3s.de/d2r>.

¹⁷ <http://drupal.org/>

¹⁸ <http://barcelona2007.drupalcon.org/node/633>,
<http://barcelona2007.drupalcon.org/node/438>,
<http://drupal.org/project/semanticsearchc>

finden oder ihrerseits die gesuchten Profile im selben Format im Netz zu veröffentlichen. Des Weiteren könnte die Teambildung innerhalb von Organisationen aufgrund von im Intranet verfügbaren Profilinformatoren, die über die Fähigkeiten der Mitarbeiter Aufschluss geben, teilweise automatisiert werden. In diesem Fall wird die Auswahl von geeigneten Mitarbeitern, die eine bestimmte Aufgabe kollaborativ lösen sollen, mithilfe von semantischer Suche und Regeln erleichtert. Im Gegensatz zu derzeit verfügbaren, zentralen Jobportalen soll das ExpertFinder-Vokabular ermöglichen, solche Szenarien flexibel und weitestgehend dezentral zu lösen.

Semantisch annotierte Wissenschaftsportale

Die ExpertFinder-Idee ließe sich in ähnlicher Weise wie auf Jobportale auch auf öffentliche Wissenschaftsportale wie zum Beispiel die erfolgreiche CORDIS-Plattform der EU¹⁹ übertragen. Semantische Annotation solcher Portale mit dem ExpertFinder-Vokabular würde die gezielte Suche bis hinunter zu Informationen zu einzelnen Forschern ermöglichen. Außerdem wäre denkbar, dass jede Institution die entsprechenden Metadaten direkt, dezentral veröffentlicht, anstatt eventuelle Änderungen jedes Mal über das CORDIS Portal eingeben zu müssen. Ein solchermaßen dezentrales Szenario stellt selbstverständlich erhöhte Anforderungen in Bezug auf die Zertifizierung vertrauenswürdiger Inhalte: Anstatt ein zentrales Portal zu verwalten, könnten sich öffentliche Institutionen wie die EU darauf beschränken, Metadaten von Institutionen entsprechend eigener Richtlinien zu zertifizieren und spezielle Websuchmaschinen für dermaßen zertifizierte Inhalte anbieten.

Semantische Auswahl von wissenschaftlichen Gutachtern

Im akademischen Bereich unterliegen Beiträge für Konferenzen, Zeitschriften oder Projektanträge einem strengen Begutachtungsprozess. Geeignete Gutachter zu finden, die in der Lage sind Beiträge zu teils sehr speziellen Themen zu bewerten, ist oft kein einfaches Unterfangen. Auf der anderen Seite werden Autoren bei der heutzutage meist elektronischen Einreichung solcher Beiträge bereits jetzt aufgefordert, ihren Beitrag durch Beschlagwortung oder Zuordnung, beispielsweise in eine von der Associa-

¹⁹ CORDIS bietet akademischen Institutionen, Klein- und Mittelbetrieben bis hin zu weltweit operierenden Konzernen ein Forum, um Partner für gemeinsame Forschungs- und Entwicklungsprojekte innerhalb des siebten Rahmenprogramms der EU zu finden, <http://cordis.europa.eu/>.

tion for Computing Machinery (ACM) veröffentlichten Kategorien, semantisch vorzuklassifizieren. Anhand dieser Information, der Analyse der zitierten Beiträge oder weiterer Textanalyse lässt sich ein relativ genaues Profil für geeignete Gutachter ableiten. Aus Online-Publikationsverzeichnissen oder Verzeichnissen von Programmkomitees zu thematisch relevanten Tagungen und Konferenzen, etc., ließen sich, sofern diese Daten in einem gemeinsam verwendeten Format wie dem Expertfinder-Vokabular verfügbar sind, Kriterien für geeignete Experten in einer entsprechenden deklarativen Regel- oder Abfragesprache (wie Rule Interchange Format RIF oder SPARQL) formulieren oder bereits definierte Kriterien von früheren Events wieder verwenden. Unter Verwendung von akzeptierten Metadaten-Vokabularen für Wissenskategorien, Publikationen, etc., könnten Lehrmodell-Beispiele, wie in [19] präsentiert, die eine Kombination von OWL und Regeln zur Auswahl der Gutachter verwenden, tatsächlich im größeren Rahmen realisiert werden. Portale zum Management von Tagungen wie Easychair²⁰ könnten in Zukunft solche fortschrittlichen Features beinhalten, um den Wissenschaftsprozess objektiver, transparenter und einfacher verwaltbar zu machen.

Datensicherheit und Vertrauensabkommen für personenbezogene Metadaten

In allen bisher genannten Szenarien ist es unabdingbar, Teile der veröffentlichten Metadaten vor unauthorisiertem Zugriff zu schützen. Dies könnte beispielsweise durch den Austausch (zeitlich beschränkter) Zugangsschlüssel für verschlüsselte Metadaten oder mittels regelbasierter Verhandlung von Vertrauensabkommen (siehe z.B. [9, 10] oder das unter [21, Abschn. 2.2] beschriebene Anwendungsszenario für weitere Details) realisiert werden. Regeln wie die in Abschn. 2 können so eine automatische Verhandlung zwischen Agenten steuern. Auf FOAF beschränkt wäre es etwa denkbar, Mechanismen zu definieren, die sicherstellen, dass Personen, die meine Telefonnummer sehen wollen, ein Service aufrufen müssen, wo nur jene Personen Zugang haben, die ich kenne. Die Konfiguration solcher Services ließe sich mittels einer erweiterten FOAF-Datei vornehmen. Diese Datei würde dann die eindeutigen URIs der Personen, die ich kenne (mittels `foaf:knows` Property), eine verschlüsselte Telefonnummer sowie die Adresse eines Services zur Entschlüsselung enthalten. An dieser Stelle ist beispielsweise denkbar, dass das Service nur die bekannten Personen mittels Angabe ihrer OpenID²¹ aufrufen könnten. Erweiterungen von

²⁰ <http://www.easychair.org/>

²¹ <http://openid.net/>

FOAF um OpenID werden derzeit auf der FOAF Entwickler Mailingliste aktiv diskutiert.²²

Die Erweiterung von FOAF um Verschlüsselung und Protokolle zum sicheren Metadaten austausch zwischen Agenten im Web ist nur ein Beispiel. Verschiedenste Erweiterungen von RDF-Vokabularen um Digitale Signaturen, Zertifikate oder beliebig komplexe Verhandlungsprotokolle wären an dieser Stelle denkbar.²³

Das ExpertFinder-Vokabular-Framework

Wie bereits erwähnt ist der Ansatz, eine neue Ontologie zu entwickeln, eine aktive User-Community zu akquirieren bzw. eine neue Ontologie in einer bestehenden Community zu etablieren, wenig Erfolg versprechend. Statt eine vollkommen neue Ontologie zu entwickeln, die allen Anforderungen der Expertensuchdomäne genügt, schlagen wir daher ein Framework vor, das auf existierenden Vokabularen (Industriestandards, bestehenden Klassifikationen und Taxonomien) basiert und diese sinnvoll miteinander kombiniert. Wie in Abb. 1 dargestellt lassen sich mehrere relevante „Komponenten“ für die Beschreibung von Experten (d. h. Personen, Organisationen, Communities) identifizieren:

- allgemeine Beschreibungsdaten für Personen, Communities und Organisationen,
- Beziehungen zwischen Personen, Communities und Organisationen,
- vergangene und gegenwärtige Aktivitäten und Projekte,
- Ausbildungsaspekte (Schulbildung, Universitätsabschlüsse, Kurse, etc.), sowie
- sonstige Qualifikationen und Fähigkeiten.

Zusätzliche Bereiche wie Ereignisse (Konferenzen, Tagungen), Publikationen, Meinungen und Bewertungen (Ratings) durch Dritte sowie Empfehlungen und Referenzen, die nicht direkt mit der Beschreibung konkreter Personen oder Organisationen verbunden sind, aber aufgrund ihrer Rele-

²² <http://lists.usefulinc.com/pipermail/foaf-dev/2007-September/008674.html>,
<http://lists.usefulinc.com/pipermail/foaf-dev/2007-August/008648.html>,
<http://lists.usefulinc.com/pipermail/foaf-dev/2007-June/008568.html>

²³ Eine umfassende Beschreibung der ExpertFinder-Anwendungsszenarien mit weiteren Links findet sich unter <http://rdfweb.org/topic/ExpertFinderUseCases>. Des Weiteren hat die ExpertFinder-Initiative bisher zwei Workshops veranstaltet, deren Beiträge sich mit den Fragestellungen der semantischen Expertensuche im Web befassen. Details hierzu finden sich unter:
<http://fews.semanticweb.org>.




Abb. 1. Teilaspekte der Beschreibung von Expertise [2]

vanz für die Expertensuche abgedeckt sein sollten, werden ebenfalls in das Framework integriert. In all diesen Bereichen wollen wir unter Berücksichtigung der speziellen Anforderungen der Expertensuche die meist verbreiteten Vokabulare (i) identifizieren, (ii) überprüfen, inwieweit sie formalisiert sind, (iii) untersuchen, welche Überschneidungen und Überlappungen oder auch Widersprüche zwischen den bestehenden Ontologien bestehen, um letztendlich (iv) Richtlinien und Vorschläge zu erarbeiten, wie diese Vokabulare wiederverwendet, miteinander kombiniert und für die Beschreibung von und Suche nach Expertise optimal eingesetzt werden können.

Im nachfolgenden Abschnitt geben wir einen kurzen Überblick über die unserer Meinung nach wichtigsten Ausgangsformate. Wir stellen dabei nicht den Anspruch, eine vollständige Liste aller unterschiedlichen Ontologien für die verschiedenen relevanten Bereiche zu erstellen, wollen aber weithin verbreitete und akzeptierte Formate abdecken.

Ausgangspunkte: FOAF, SIOC & SKOS

Unser Überblick beginnt mit drei Projekten/Vokabularen, die als Ausgangspunkt unserer Arbeit dienen: Dies sind zum einen die Ontologien Friend of a Friend (FOAF)²⁴ [13] und die Semantically-Interlinked Online Communities (SIOC)²⁵ [11, 6] und zum anderen das Simple Knowledge Organisation System (SKOS).²⁶ Diese drei Vokabulare dienen als solide Basis, die viele der erwähnten ‚Komponenten‘, die in der Expertenbeschreibung eine entscheidende Rolle spielen, abdeckt. Darüber hinaus vereinen sie Formate, die innerhalb von Online-Communities zunehmend Verbreitung finden und somit bereits auf eine große Anzahl von Anwen-

²⁴ <http://www.foaf-project.org>

²⁵ <http://sioc-project.org>

²⁶ <http://www.w3.org/2004/02/skos/>

dern verweisen können. Die Wiederverwendung dieser Vokabulare kommt unserem Vorhaben also sehr entgegen, erhöht die Wahrscheinlichkeit eine kritische Masse für das Framework zu erreichen und erleichtert die Integration unseres Vokabulars in existierende Organisationsstrukturen.

Friend of a Friend (FOAF)

Die FOAF-Ontologie [13], die ursprünglich quasi als Metadatenbasis für eine maschinenlesbare Homepage gedacht war, stellt Informationen bzw. Metadaten über Menschen, Gruppen, Organisationen und andere relevante Konzepte bereit. FOAF erlaubt hauptsächlich, Personen zu beschreiben (z. B.: was sie machen und wie sie miteinander interagieren). Eine der wichtigsten FOAF Properties ist, wie bereits in einem Beispiel erwähnt, das Attribut „foaf:knows“. Durch das Einfügen von „foaf:knows“-Verknüpfungen kann man die Beziehungen zwischen Personen oberflächlich darstellen. Damit bietet FOAF einen einfachen Mechanismus um soziale Netzwerke abzubilden. Mit anderen Worten, die Aggregation von FOAF-Daten aus vielen einzelnen persönlichen Homepages führt zur Bildung von verteilten sozialen Netzwerken, die wiederum mit größeren sozialen Onlinenetzwerken wie LiveJournal²⁷ oder Tribe²⁸ verbunden werden können. Wenn wir FOAF vom Blickwinkel der Expertenbeschreibung betrachten, finden wir eine Reihe relevanter Properties wie z. B.:

- foaf:interest, das die Interessen einer Person definiert.
- Mit foaf:publications oder foaf:Documents können Publikationen oder weitere Dokumente einer bestimmten Person zugeordnet werden.
- Durch die Attribute foaf:topic und foaf:primaryTopic, die Publikationen/Dokumente einem bestimmten Thema zuweisen, lassen sich Themen mit einer bestimmten Person verknüpfen (Zuweisung eines Dokuments zu einer bestimmten Person, d. h. Autorenschaft, erfolgt über foaf:made/maker).
- foaf:currentProject/pastProject gibt Aufschluss über gemeinsame oder individuelle Vorhaben und Projekte, an denen eine bestimmte Person beteiligt ist oder war.²⁹

Es existieren bereits mehrere Erweiterungen, Ergänzungen und zusätzliche Module für die FOAF-Ontologie, die für die erwähnten Anwendungs-

²⁷ <http://rdfweb.org/topic/LiveJournal/>

²⁸ <http://www.tribe.net>

²⁹ Die zeitliche Granularität dieser Zuordnung ist allerdings mit lediglich einer Unterscheidung zwischen gegenwärtigen und vergangenen Projekten sehr grob, mehr dazu später.

szenarien der ExpertFinder-Initiative relevant sind. An dieser Stelle sei beispielsweise ein Managementsystem für Benutzerprofile, FOAFRealm [28], erwähnt, das auf FOAF basiert und Funktionalitäten wie Authentifizierung, Zugriffskontrolle und Semantic Social Collaborative Filtering anbietet. Das System erlaubt Benutzern, die persönlichen Taxonomien mit anderen Nutzern zu teilen und diese entlang des sozialen Netzwerks unter Verwendung von WordNet,³⁰ DDC³¹ und DMoz³² als Basisklassifikationen zu annotieren. Darüber hinaus können User ihre Dokumente oder Bookmarks klassifizieren und anderen Benutzern erlauben, auf diese Ressourcen mit Hilfe von FOAFRealm zuzugreifen. Dies wird beispielsweise in einem System für den Dokumentenaustausch wie JeromeDL³³ – einer ‚semantischen‘ digitalen Bibliothek – implementiert. In FOAFRealm wird zudem jeder Benutzergruppierung ein Kompetenzwert zugewiesen, der die Qualität der Informationen reflektiert, die diese Gruppe bereitstellt. Der Kompetenzwert wird auf Basis eines Algorithmus³⁴ berechnet, der das soziale Netzwerk analysiert. Dies verschafft dem Benutzer einen Überblick über die Qualität der Expertise anderer Beteiligter seines sozialen Netzwerks zum gegebenen Thema.

Semantically-Interlinked Online Communities (SIOC)

Das SIOC-Projekt [11, 6] stellt ein Framework zur Verknüpfung und zum Austausch von Informationen zur Verfügung, die aus internetbasierten Diskussionsforen und Community-Portalen kommen. Communities werden durch Benutzer gebildet, die themenbezogene Einträge verfassen und an bestimmten Diskussionsforen teilnehmen, die von einer Vielzahl von Webseiten und Diskussionsplattformen abonniert werden können – z. B. durch aktive Anmeldung oder über RSS (Really Simple Syndication Format). Die Basis der SIOC-Ontologie bildet ein RDF-Schema, das die Hauptkonzepte einer Online-Community beschreibt [11]. Auch wenn SIOC viel mehr Klassen und Properties beinhaltet, die generelle Notation ist wie folgt:

Ein Benutzer (`sIOC:User`) erstellt einen Eintrag (`sIOC:Post`), der in einem Forum (`sIOC:Forum`) publiziert wird, das wiederum auf einer bestimmten Seite (`sIOC:Site`) zu finden ist.

³⁰ <http://wordnet.princeton.edu>

³¹ <http://www.oclc.org/dewey/>

³² <http://dmoz.de>

³³ <http://www.jeromedl.org>

³⁴ Dieser Algorithmus ähnelt dem Google zugrunde liegenden PageRank Algorithmus [14].

In Bezug auf die Expertensuche in sozialen Netzwerken ist `sioc:topic` das wichtigste Property. Dieses Property definiert Ressourcen, die mit einem Eintrag in Verbindung gesetzt werden können. Durch Zusammenführung von allen Themen (`sioc:topic`), die mit Einträgen eines bestimmten Benutzers über mehrere Webseiten assoziiert werden können, entsteht eine Art von Abbildung darüber, wo Interessensgebiete und themenbezogene Expertise zu finden sind. Darüber hinaus können neben einzelnen Einträgen auch Foren (`sioc:Forum`) oder Seiten mit bestimmten Themen assoziiert werden und Benutzer, die Interesse an einem bestimmten Thema haben, können die Rolle des Abonnenten (`sioc:subscriber_of`) für themenrelevante Diskussionskanäle annehmen.

Simple Knowledge Organisation System (SKOS)

Das Simple Knowledge Organisation System (SKOS) [32] rundet die Basis unseres Frameworks ab. SKOS:

- erlaubt die Spezifikation von allgemeinen Konzepten und Bezeichnungen,
- definiert zusätzlich Eigenschaften von Bezeichnungen und Beziehungen zwischen Konzepten, die beschreiben, ob ein Konzept breiter oder enger (`broader/narrower`) gefasst ist als ein anderes,
- erlaubt, bevorzugte oder alternative Bezeichnungen in verschiedenen Sprachen zu definieren,
- erleichtert sowohl die Repräsentation als auch die gemeinsame Nutzung von Terminologien, die nicht unbedingt die Ausdruckstärke von Sprachen wie RDFS und OWL brauchen oder wo eine strenge durch `rdfs:subClassOf` definierbare Hierarchie nicht auferlegt werden kann.

In Bezug auf ExpertFinder und in Relation mit FOAF und SIOC kann SKOS (i) als Basis für die Definition und Zuordnung von Qualifikationen, (ii) für die Beschreibung von Expertisen- und Interessensbereichen (über `foaf:interest`) oder auch (iii) für die Beschreibung der Themen, die in SIOC-basierten Online-Communities diskutiert wurden (mittels `sioc:topic`), benutzt werden. Außerdem ermöglicht der Einsatz von SKOS neben der Beschreibung von diskutierten Themen in Kombination mit zusätzlichen Regeln, die im nächsten Schritt in das ExpertFinder-Framework eingebaut werden sollen, flexiblere Definitionen von Relationen zwischen verschiedenen SKOS-formalisierten Qualifikationen.

Um unnötige Duplikate oder Konflikte zwischen den Konzepten und Relationen in verschiedenen Vokabularen zu vermeiden, haben die Entwickler der SIOC-Ontologie zusammen mit den Autoren von FOAF und SKOS am Konzeptabgleich gearbeitet. Diese Kooperation hat sich unter anderem auf folgende Konventionen geeinigt:




Abb. 2. Verbindungen zwischen SIOC, FOAF und SKOS [2]

- Das Konzept `sio:User` wurde als Subklasse von `foaf:online Account` definiert, sodass die existierenden Properties aus FOAF wiederverwendet werden können, aber gleichzeitig auch neue Properties für Benutzer von Foren in SIOC definiert werden können, ohne direkte Auswirkungen auf die FOAF Ontologie zu haben.
- Wie in Abb. 2 ersichtlich erlaubt das Konzept `foaf:Person` mehrere `sio:User` Profile (über die Beziehung `foaf:holdsOnline Account`) mit einer Person zu assoziieren.
- Inhalte, die durch einen Benutzer (`sio:User`) in einem bestimmten Forum (e.g., Weblog, Mailingliste, Bulletin Board) veröffentlicht wurden, können über das Property `sio:topic` mit einem SKOS-Konzept (`skos:Concept`) verlinkt werden (z. B.: vgl. Abb. 2: ein Eintrag behandelt „Wolken“ und ein weiterer bezieht sich auf ein engeres Konzept „Regenwolken“).

Erweiterungen des ExpertFinder Frameworks

Zwar decken FOAF, SIOC und SKOS zum großen Teil die allgemeine Beschreibung von Relationen zwischen Personen, Communities und Orga-

nisationen ab, doch fehlen nach wie vor entscheidende Komponenten, um das in Abb. 1 gezeigte Gesamtbild zu vervollständigen. An dieser Stelle wollen wir einige existierende Vokabulare und Standards, die die fehlenden Teile abdecken können, kurz erläutern.

- In FOAF fehlen etwa detaillierte Informationen über Adressen, die durch komplementäre Standards wie vCard abgedeckt sind.
- Die einzige Beziehung zwischen Personen, die in FOAF definierbar ist, ist die `foaf:knows` Relation. Da wir zwischenmenschliche Beziehungen in unserem Framework genauer beschreiben wollen, werden wir die RELATIONSHIP & XFN Vokabulare integrieren.
- Projekte können mit Personen oder Gruppen durch die `foaf:currentProject` und `foaf:pastProject` Properties verlinkt werden. Allerdings erscheint diese Beschreibung zu grobkörnig und zu allgemein, um Projekte genau annotieren zu können, wenn beispielsweise der exakte Zeitrahmen des Projektes von Bedeutung sein soll. Durch weiter zurückliegende Projekte erlangte Expertise ist oft weniger wichtig als unmittelbar abgeschlossene Projekte. Hier schlagen wir die Benutzung des DOAP (Description of a Project) Vokabulars vor.
- Detaillierte Informationen zum Lebenslauf können beispielsweise mit Hilfe der DOAC (Description of a Career) oder BIO-Vokabulare spezifiziert werden.
- Im wissenschaftlichen Kontext sind oft die Publikationen der entscheidende Maßstab für Qualität und Niveau der Expertise einer bestimmten Person. Die Verbindung zwischen Personen und ihren Publikationen, die mit dem Konzept `foaf:Document` annotiert werden, kann durch die Properties `foaf:maker`, sein inverses Attribut `foaf:made` und `foaf:publications`³⁵ erstellt werden. Detaillierte Beschreibungen der jeweiligen Publikationen sind mit dem erwähnten Basis-Vokabular jedoch nicht abgedeckt. Diese Lücke kann durch BibTex, ein de facto Standard im wissenschaftlichen Publikationsbereich, geschlossen werden.
- Informationen über Veranstaltungen und Veranstaltungsteilnehmer sind mit den existierenden Vokabularen nur unzureichend abgedeckt. Als de facto Standard wäre iCal ein nahe liegender Kandidat für diese Aufgabe.
- SKOS bietet zwar ein allgemeines Framework für die Beschreibung von Qualifikationen und Interessen, dennoch fehlt eine konkrete Klassifikation, die verschiedene Themen und Interessensgebiete abdecken würde. Detaillierte Terminologien aus verschiedenen Domänen, die die Qualifikationen und Fähigkeiten einer Person beschreiben können, sind an

³⁵ `foaf:publications` verweist, im Gegensatz zu `foaf:made`, auf eine Liste von Publikationen

dieser Stelle unabdingbar. Wir werden im Folgenden einige mögliche Ausgangspunkte diskutieren.

Verfeinerung von Personaldaten: vCard

vCard ist ein Standard zur Beschreibung von personenbezogenen Daten für Visitenkarten oder Adressbücher. Mittlerweile existieren verschiedene Repräsentationen von vCard-Daten. Für unsere Zwecke ist allerdings hauptsächlich die RDF-basierte Syntax³⁶ relevant. Kontaktinformationen wie Telefonnummern oder E-Mail Adressen können mit Hilfe von vCard beispielsweise durch die Unterscheidung zwischen privaten und geschäftlichen Telefonnummern (`vCard:homeTel` und `vCard:workTel`) genauer und feingranularer ausgedrückt werden, als das mit dem FOAF-Vokabular möglich wäre. An dieser Stelle sei angemerkt, dass sich Telefonnummern von vCard nicht einfach als Unterklassen von `foaf:phone` beschreiben lassen, weil vCard RDF-Literalwerte benutzt. FOAF-URIs hingegen werden mit dem `tel:-` Schema qualifiziert. Um mit dieser Situation umgehen zu können, schlagen wir vor, entweder die FOAF-Repräsentation in vCard/RDF zu adoptieren und die entsprechenden Properties als Subproperties von `foaf:phone` zu definieren oder direkte Übersetzungsregeln für die entsprechende Konvertierung in einer geeigneten Regelsprache zu definieren, wie bereits im kleinen SPARQL-Beispiel weiter oben vorgeschlagen. Solche Übersetzungsregeln müssen nicht immer bidirektional sein. Beispielsweise kann nicht jede `vCard:email` einfach auf eine `foaf:mbox` abgebildet werden, weil das `foaf:mbox` Property in FOAF entsprechend der Ontologiedefinition eindeutig einer bestimmten Person zugeordnet sein muss. Im Gegensatz dazu sind in vCard auch mehrdeutige Email-Adressen zulässig. Ferner können Informationen über die organisatorische Zugehörigkeit oder Rolle einer Person in einer Organisation auf eine bestimmte Expertise oder Grad des Wissens hindeuten, was wiederum mit SKOS-Konzepten annotiert werden kann.

Verfeinerung von Relationen: RELATIONSHIP & XFN

RELATIONSHIP³⁷ und XFN (XHTML Friends Network)³⁸ sind zwei Vokabulare, die für Beschreibungen von zwischenmenschlichen Beziehungen benutzt werden können. Nachdem das FOAF Property `foaf:knows` die Relationen zwischen Personen für viele Anwendungen zu oberflächlich beschreibt, schließen diese Vokabulare diese Lücke durch Festlegung von detaillierteren Subproperties.

³⁶ <http://www.w3.org/TR/vcard-rdf>, <http://www.w3.org/2006/vcard/ns>

³⁷ <http://vocab.org/relationship/>

³⁸ <http://gmpg.org/xfn/join>

Verfeinerung von Projektbeschreibungen: *Description of a Project (DOAP)*

DOAP (Description of a Project)³⁹ ist ein weiteres RDF-Vokabular, das ursprünglich für die Beschreibung von Open-Source-Projekten gedacht war, das sich aber zunehmend auch für andere Projekte verbreitet hat. DOAP konzentriert sich dabei auf:

- die internationalisierte Beschreibung von Softwareprojekten und ihren Ressourcen,
- den Datenaustausch zwischen offenen Softwareverzeichnissen,
- automatische Konfiguration von Ressourcen wie CVS-Repositories,
- Interoperabilität mit anderen bekannten Web-Metadaten-Projekten (RSS, FOAF, DC),
- die Erweiterungsmöglichkeit des Vokabulars für spezielle Zwecke.

DOAP beschreibt den aktuellen Zustand eines Projekts ohne jedoch explizit auf Änderungen und Updates einzugehen. Allerdings kann, um ein Repository auf dem neuesten Stand zu halten, CodeZoo mit Atom-Feed⁴⁰ samt eingebettetem DOAP-Vokabular eingesetzt werden. Jedoch auch wenn so ein Feed für DOAP benutzt werden kann um ältere Versionen beizubehalten, ist eine Methode zur Transformation der Informationen nach RDF und zur Unterscheidung zwischen aktuellen und vergangenen Versionen dringend notwendig. DOAP verwendet das `foaf:Person` Konzept, um Personen, die am jeweiligen Teil des Projektes beteiligt sind, zu referenzieren. Trotz der relativ einfachen Integration der beiden Vokabulare kann die genaue Dauer der Teilnahme einer Person an einem bestimmten Projekt nicht spezifiziert werden. Das Problem kann weder durch die Benutzung der FOAF-Properties `foaf:project`, `foaf:currentProject` oder `foaf:pastProject` noch durch den Einsatz von DOAP gelöst werden. An dieser Stelle schlagen wir das Hinzufügen neuer Attribute für den Beginn und das Ende der Projektbeteiligung (möglicherweise unter Verwendung von iCal) vor. Auch die Nutzung von temporalem RDF [15] wäre an dieser Stelle denkbar.

Verfeinerung von typischen Lebenslaufdaten: *DOAC, Resume RDF und BIO*

DOAC (Description of a Career)⁴¹ ist ein RDF-Vokabular für die Beschreibung von fachlichen Qualitäten und Erfahrungen, wie man sie in Lebensläufen findet. Die Metadaten dieses Vokabulars erlauben die Be-

³⁹ <http://usefulinc.com/doap/>

⁴⁰ http://www.codezoo.com/about/doap_over_atom.csp

⁴¹ <http://ramonantonio.net/doac/>

schreibung von und erleichtern Suche nach passenden Stellen bzw. Bewerbungen im Sinne von Anforderungen eines Jobangebots. DOAC wurde als komplementäres RDF-Vokabular zum Europäischen Lebenslauf (auch bekannt als Europass)⁴² entwickelt, der aus einer FOAF+DOAC Datei generiert werden kann. DOAC beinhaltet Informationen über die Ausbildung, den beruflichen Werdegang, Publikationen, Sprachen und weitere Qualifikationen, die normalerweise in einem Lebenslauf Platz finden.

DOAC benutzt die FOAF Klasse `foaf:Person` für die allgemeine Beschreibung von Arbeitssuchenden und das Konzept `foaf:Organisation` für Schulen und andere Institutionen, die die jeweilige Person besucht hat und die in einem Lebenslauf eine Rolle spielen können. Darüber hinaus könnte das Konzept `foaf:pastProject` als Subklasse des Konzepts `doac:Experience` angesehen werden (wenn auch nicht explizit so im Vokabular definiert). Dies würde uns erlauben, nicht nur die Erfahrungen eines Jobsuchenden bei einer Firma als einzelnen Attributwert darzustellen, sondern feingranulare Beschreibungen der Erfahrungen bezüglich verschiedener Projekte, an denen die Person während der Beschäftigungszeit bei einer bestimmten Organisation beteiligt war, zu erstellen. Weiter hin mag man das Property `doac:publication`, das eine Beziehung zwischen einer Person (`foaf:Person`) und einer Publikation (`doac:Publication`) herstellt, als Subproperty von `foaf:made` bzw. als Verfeinerung von `foaf:publications` ansehen.

In ähnlicher Weise erweitert das Resume RDF-Schema⁴³ FOAF Profile mit Lebenslaufinformationen und kann somit als Alternative zu DOAC gesehen werden. Das Schema beinhaltet Konzepte und Properties, um berufliche und akademische Erfahrungen, Qualifikationen, Kurse und Zertifikate, Publikationen und weitere Referenzen annotieren zu können. Auch hier schlagen wir einen Link zum SKOS-Vokabular vor, um für die Beschreibung entsprechender Konzepte bestehende Taxonomien wiederverwenden zu können.

Das letzte Vokabular im Bereich von Lebenslaufinformationen ist das BIO-Vokabular,⁴⁴ das minimale biographische Informationen über lebende und verstorbene Personen umfasst.

Verfeinerung von bibliographischen Informationen: BibTeX, DC, etc.

BibTeX, das von Patashnik und Lamport 1985 als Format für die Verwaltung bibliographischer Daten in LaTeX entwickelt wurde [36], hat sich

⁴² <http://europass.cedefop.europa.eu>

⁴³ <http://purl.org/captsolo/semweb/>

⁴⁴ <http://vocab.org/bio/0.1/>

mittlerweile als de facto Standard für Veröffentlichungen bibliographischer Informationen besonders in Online-Publikationsdatenbanken wie DBLP⁴⁵ und Citeseer⁴⁶ etabliert. Da verschiedene RDF-Versionen von BibTeX existieren, z.B. `bibtex2rdf`, `bib2rdf`, `bibTeX/RDF`,⁴⁷ die vorhandene Formate auf ähnliche Art und Weise wie ExpertFinder (wieder) verwenden, können diese direkt übernommen oder mit umfangreicheren und reichhaltigeren Ontologien für digitale Bibliotheken wie MarcOnt⁴⁸ kombiniert werden. Da MarcOnt selbst auch den Import und Export von BibTeX Daten ermöglicht, schlagen wir ein RDF Vokabular vor, das von `bibtex2rdf` (cf. [22]) unterstützt wird. Zu guter Letzt sei die Dublin Core Metadaten Initiative (DCMI⁴⁹) erwähnt, die vor 10 Jahren durch Bibliothekare mit dem Ziel der Erstellung von Metadaten für die Beschreibung von Dokumenten gestartet wurde. Das Vokabular von Dublin Core kann als Untermenge von BibTeX angesehen werden und wird beispielsweise in `bibtex2rdf` so weit wie möglich wieder verwendet.

Klassifikationen & Standards für Qualifikationen und Themengebiete

Wie bereits erwähnt fehlen uns zur Komplettierung des ExpertFinder-Frameworks nach wie vor konkrete Konzeptionshierarchien und Taxonomien für Themen und Kompetenzbereiche. Im folgenden Abschnitt beschreiben wir ausgewählte Standards und Klassifikationen von Berufen, Kompetenzen und ökonomischen Aktivitäten, die als solche Schemata für die Beschreibung von Qualifikationen und Themengebieten dienen können. Einige dieser Standards werden beispielsweise als Werkzeuge für die Präsentation von Statistiken über Ausbildung und Training auf nationaler als auch internationaler Ebene benutzt. Andere wiederum werden für die Förderung der internationalen Vergleichbarkeit von Daten bezüglich ökonomischer Phänomene und der internationalen Kommunikation eingesetzt.

- Das *Standard Occupational Classification (SOC) System*⁵⁰ wird von föderalen Statistikagenturen der USA benutzt, um Berufsgruppen in 820 Kategorien, 23 Hauptgruppen, 96 Untergruppen und 449 Tätigkeitsberei-

⁴⁵ <http://dblp.uni-trier.de>

⁴⁶ <http://citeseer.ist.psu.edu>

⁴⁷ <http://www.l3s.de/siberski/bibtex2rdf/>,
<http://www.cs.vu.nl/mcaklein/bib2rdf/>,
<http://zeitkunst.org/bibtex/0.1/>

⁴⁸ <http://www.marcont.org>

⁴⁹ <http://dublincore.org>

⁵⁰ <http://www.bls.gov/soc/>

che zu klassifizieren. Jeder Tätigkeitsbereich beinhaltet detaillierte Berufe mit ähnlichen Qualifikations-, Ausbildungs- und Erfahrungsprofilen.

- Die *Berufskennziffer (BKZ)*⁵¹ ist ein deutsches Pendant zum SOC-System und klassifiziert Arbeitnehmer sehr feingranular in 5597 Berufskategorien.
- Die *International Standard Classification of Occupations (ISCO-88)* wurde entwickelt, um die internationale Kommunikation bezüglich Berufen und Berufsgruppen zu erleichtern. Personen werden hier nicht nur aufgrund einer einzelnen Tätigkeit, sondern basierend auf ihre in der Vergangenheit und Gegenwart ausgeübten Tätigkeiten klassifiziert.
- Die *International Standard Industrial Classification of All Economic Activities (ISIC)*⁵² ist eine Standardklassifikation für ökonomische Aktivitäten, in der ebenfalls anhand der ausgeübten Tätigkeiten klassifiziert wird.
- Das *North American Industry Classification System (NAICS)*⁵³ bietet eine allgemeine Definition der Industriezweige für Kanada, Mexiko und die USA und ist ursprünglich dafür konzipiert, ökonomische Analysen zu erleichtern.

Weitere Standards, die Produkte oder Dienstleistungen klassifizieren, wie eCl@ss,⁵⁴ eOTD oder RosettaNet Technical Dictionary⁵⁵ und UNSPSC⁵⁶, können ebenfalls in der Beschreibung von Qualifikationen und Themenbereichen eingesetzt werden. Allerdings sind fast alle der hier genannten Standards und Klassifikationen, mit wenigen Ausnahmen wie etwa eCl@ssOWL [24], derzeit leider (noch) nicht in einer ontologisierten Form verfügbar. Abgesehen von speziellen Klassifikationssystemen, die noch web-fähig gemacht werden müssen, können Online-Enzyklopädien wie Wikipedia für die Themenklassifikation eingesetzt werden. Jüngste Versuche einer semantischen Strukturierung von Wikis (vgl. [30]) unterstützen genau diesen Ansatz. Für abgeschlossene, spezifische Domänen wie etwa Informatik, können beispielsweise spezielle Kategorisierungen benutzt werden. Hier seien die ACM-Kategorien⁵⁷ oder die Semantic Web-Themenhierarchie⁵⁸ als Beispiele genannt, die bereits URI-adressierbare

⁵¹ www.arbeitsamt.de/hst/markt/news/BKZ_alpha.txt

⁵² <http://unstats.un.org/unsd/cr/registry/isic-4.asp>

⁵³ <http://www.census.gov/epcd/www/naics.html>

⁵⁴ <http://www.eclass.de>

⁵⁵ <http://portal.rosettanet.org/cms/sites/RosettaNet/Standards/RStandards/dictionary/technical/>

⁵⁶ <http://www.unspsc.org>

⁵⁷ <http://www.acm.org/class/1998/>

⁵⁸ http://ontoworld.org/wiki/Semantic_Web_Topic_Hierarchy

Kategorien zur Verfügung stellen und damit direkt als SKOS-Ausdrücke einsetzbar sind. In diesem Sinne könnten wir das Beispiel vom Abschn. 2 unter Verwendung einer spezifischeren Klassifikation wie folgt ändern bzw. verfeinern:

Alle aufgelisteten Personen unter der URI

<http://www.w3.org/People/>

sind Experten in

http://ontoworld.org/wiki/Category:Topic_Semantic_Web

wobei wir folgendes hinzufügen können:

http://ontoworld.org/wiki/Category:Topic_Semantic_Web

is skos:narrower_than

<http://en.wikipedia.org/wiki/Semanticweb>.

Veranstaltungsdaten und temporale Informationen

iCal [16] als de facto Standard für Kalender- und Eventinformationen, der von vielen Anwendungen und Applikationen benutzt und unterstützt wird, ist ein naheliegender Kandidat für ExpertFinder, wenn es darum geht, Verweise auf Veranstaltungen oder zeitliche Intervalle zu beschreiben. Für den Einsatz von iCal spricht auch die Tatsache, dass bereits RDF-Formate und Konvertierung für iCal verfügbar sind.⁵⁹ Allerdings ist anzunehmen, dass der Wortschatz von iCal allein nicht ausreicht (beispielsweise für die Annotation der Gültigkeitsdauer bestimmter RDF-Informationen wie die Dauer der Teilnahme an einem Projekt). Die Benutzung von RDF-Erweiterungen um temporale Informationen [15] wäre eine alternative interessante Möglichkeit, um die Gültigkeitsdauer von Triples oder Graphen auszudrücken. Diese Ideen nehmen allerdings noch keinen festen Platz im Portfolio etablierter Standards ein.

Beschreibung von Überlappungen und Mappings

Die einzelnen vorgestellten Vokabulare bilden ein loses, teilweise überlappendes Framework von Ontologien und RDF-Vokabularen und Kategorisierungen, um die in Abb. 1 genannten Aspekte abdecken zu können. Der Schwerpunkt lag hier darauf, bestehende Formate weitestgehend wiederzuverwenden und einen Überblick zu geben, inwieweit diese kombiniert werden können. Dennoch decken die genannten Formate viele Aspekte

⁵⁹ <http://www.w3.org/2002/12/cal/>,
<http://www.kanzaki.com/courier/ical2rdf>,
<http://torrez.us/ics2rdf/>

doppelt ab, bzw. es gibt mehrere Möglichkeiten, unter Verwendung verschiedener der genannten Formate, ein und denselben Sachverhalt auszudrücken. Die ExpertFinder-Initiative zielt darauf ab, für jeden dieser mehrdeutigen Aspekte ein bestimmtes designiertes Format vorzuschlagen und Mappings von und nach evtl. überlappenden anderen Formaten zu definieren. Eine vorläufige, unvollständige Liste von Mappings und Überschneidungen der Konzepte und Attribute in den vorgestellten Vokabularen ist in Arbeit und online verfügbar.⁶⁰ Die Autoren sind über Anregungen zur Vervollständigung dieser Liste dankbar. Das Nichtvorhandensein eines dezidierten Standards zur Beschreibung solcher Mappings wurde bereits durch Vorschläge entsprechender Erweiterungen für SPARQL [39] in Angriff genommen.

Relevante Projekte

Mehrere Projekte im Semantic Web Bereich haben bereits ihre eigenen Ontologien entwickelt um Personen, Organisation und Aktivitäten zu beschreiben. So decken beispielsweise die KnowledgeWeb-Plattform-Ontologien⁶¹ [20], die AKT Portal Ontologie⁶², die SWRC Portal Ontologie⁶³ [42] oder die Ontologie der DERI Semantic Web Portal (SWP) Arbeitsgruppe⁶⁴ [34] viele Aspekte der Expertensuche ab und könnten somit als adäquate Ausgangspunkte angesehen werden. Allerdings scheinen diese Ontologien sich nur mäßig außerhalb der Projekte, in denen sie entwickelt wurden, verbreitet zu haben und bei ihrer Erstellung wurden existierende Quellen und de facto Standards zu einem weit geringeren Grad wiederverwendet, als wir es hier vorgeschlagen haben. Die DERI SWP-Ontologie basiert als einzige aus dieser Liste zum Teil auf FOAF, RSS und BibTeX.

Im Gegensatz zu den oben genannten Ontologien, die in den jeweiligen Projekten von Grund auf neu entwickelt wurden, setzen andere Projekte wie Wissensnetze, SemDis, FindXpRT und SIOC zu einem höheren Grad auf die Wiederverwendung existierender Vokabulare. Diese Projekte, auf die wir im Folgenden etwas näher eingehen wollen, behandeln auch sehr ähnliche Anwendungsszenarien, wie wir sie in Abschn. 3 beschrieben haben.

⁶⁰ http://www.rdfweb.org/topic/ExpertFinder_2fmappings

⁶¹ <http://knowledgeweb.semanticweb.org/semanticportal/OWL/>

⁶² <http://www.aktors.org/ontology/portal>

⁶³ <http://swrc.ontoware.org/ontology>

⁶⁴ <http://sw-portal.deri.org/ontologies/swportal>

Wissensnetze

Das Projekt Wissensnetze⁶⁵ analysiert anhand von konkreten Anwendungsszenarien das Potential semantischer Technologien zur Veränderung elektronischer Märkte und branchenspezifischer Wertschöpfungsketten. Grundlage der Szenarioentwicklung ist die Kombination verschiedener Anwendungsbereiche im Lichte der neuen Technologien. Die auf diese Weise entwickelten „Zukunftsszenarien“ sind anschließend Gegenstand von Experimenten und Analysen. Das erste Szenario, das im Rahmen des Projektes untersucht und prototypisch entwickelt wurde, kommt aus der e-Recruitment-Domäne und befasst sich mit Online-Jobsuche auf einem ‚semantischen‘ Jobportal [5, 33, 43]. Im Human Resource bzw. HR-Szenario bilden Ontologien eine wesentliche Grundlage für die Beschreibung von Jobangeboten und -anfragen und deren semantischen Vergleich. Anhand verschiedener Kostenfaktoren, nach einem Kostenmodell für Ontologieentwicklung (ONTOCOM) [41], wurde entschieden, dass die Wiederverwendung von existierenden Ontologien kostengünstiger als eine Neuentwicklung der HR-Ontologie ist. Insgesamt wurden 24 Klassifikationen und Standards aus der HR-Domäne untersucht, von denen schließlich sechs angepasst und in der HR-Ontologie wieder verwendet wurden (SOC,⁶⁶ BKZ,⁶⁷ WZ2003,⁶⁸ NAICS,⁶⁹ HR-XML⁷⁰ und die Skill Ontology [1]), um die Job- und Stellenangebote annotieren und diese einfacher in die industrielle Umgebung integrieren zu können. Wiederverwendung von Standards und Klassifikationen trägt hier zur Realisierung von leistungsfähigeren und flexibleren Lösungen im e-Recruitment Szenario bei.

SemDis

Das SemDis-Projekt adressiert die Entwicklung von Techniken für die Abfrage/Ermittlung von semantischen Relationen zwischen Personen. Beispielsweise werden `dblp:co-authorship` und `foaf:knows` benutzt um mögliche Interessenskonflikte zwischen Gutachtern und Autoren in wissenschaftlichen Begutachtungsprozessen zu erkennen [4]. Eine Erweiterung dieser Arbeit zielt auf Ermittlung von möglichen Gutachtern durch

⁶⁵ <http://wissensnetze.ag-nbi.de>

⁶⁶ <http://www.bls.gov/soc/>

⁶⁷ http://infobub.arbeitsagentur.de/download/public/dkz_daten

⁶⁸ <https://www-ec.destatis.de/csp/shop/sfg/bpm.html.cms.cBroker.cls?cmspath=struktur,vollanzeige.cspID=1018484>

⁶⁹ <http://www.census.gov/epcd/www/naics.html>

⁷⁰ Entwickelt vom HR-XML Consortium, <http://www.hr-xml.org>

Vergleich ihrer Expertise mit Themen einer Publikation, die sie beurteilen sollen. Die Expertise von Personen bezüglich verschiedener Themen oder Bereiche kann mit Hilfe der SwetoDblp-Ontologie⁷¹ beschrieben werden. SwetoDblp ist eine Ontologie basierend auf der bereits erwähnten DBLP Online-Publikationsdatenbank.

FindXpRT

Das Projekt FindXpRT (Find an eXpert via Rules and Taxonomies) [29] konzentriert sich auf Regelaspekte im Sinne der Kombinationen von FOAF-Daten mit Regeln, die in RuleML [8] spezifiziert sind. Das implementierte System⁷² erlaubt Benutzern, FOAF-Daten durch Anwendung von personenbezogenen Regeln entweder vor der Publikation (als eine Art von Filter) oder, auf Wunsch, aufgrund von bereits publizierten RuleML+ FOAF Seiten (als Sichten/Views) abzuleiten.

SEEMP

Das SEEMP-Projekt (Single European Employment Market Place)⁷³ hat zum Ziel, eine Infrastruktur bereitzustellen, um Interoperabilität zwischen öffentlichen und privaten Arbeitsmarktdiensten über europäische Grenzen hinweg zu ermöglichen [45]. Der Ansatz von SEEMP basiert auf zwei Hauptkonzepten: Dienste und Semantik. Die Dienste, die von den Marktteilnehmern angeboten werden, werden als spezielle Web Services modelliert. Die Semantik von Inhalten, die durch das System verwaltet wird, wurde in Ontologien verpackt, die wiederum als Basis für den Datenaustausch benutzt werden. Auch bei der Entwicklung der SEEMP-Referenzontologie wurde soweit wie möglich auf die Wiederverwendung von existierenden Standards (ökonomische Aktivitäten: NACE Rev. 1.1⁷⁴, Berufsbezeichnungen: ISCO-88 (COM)⁷⁵, ONET⁷⁶ und ISCED97⁷⁷, Qualifikationen: EURES Qualifikationsklassifikation⁷⁸, usw.) gesetzt.

⁷¹ <http://lsdis.cs.uga.edu/projects/semdis/swetodblp/>

⁷² <http://www.ruleml.org/usecases/foaf/JieLiMCSThesis.pdf>

⁷³ <http://www.seemp.org>

⁷⁴ http://www.fifoost.org/database/nace/nace-de_2002c.php

⁷⁵ www.gesis.org/dauerbeobachtung/gml/Daten/mz/allgemein/isco88com.pdf

⁷⁶ <http://std.en.vicdir.com/1021>

⁷⁷ http://www.uis.unesco.org/ev.php?ID=3813201ID2=DO_TOPIC

⁷⁸ <http://europa.eu.int/eures/home.jsp?lang=de>

Zusammenfassung und Ausblick

Im Verlauf dieses Kapitels wurden Rahmenbedingungen zur Kombination, Wiederverwendung und Erweiterung bestehender RDF-Vokabulare im Social Semantic Web diskutiert und die Vision des ExpertFinder-Vokabular Frameworks vorgestellt. Wir haben existierende Vokabulare und Formate analysiert, die der Spezifikation von Personen, Communities und Organisationen samt deren Expertise dienen können. Außerdem haben wir uns mit der Problematik der Kombination und Erweiterungen verschiedener Quellformate auseinander gesetzt, wobei wir die Einschränkungen von FOAF, SIOC und SKOS, die wir als Ausgangspunkte betrachten, durch die Kopplung mit anderen existierenden Vokabularen zumindest teilweise auflösen können. Darüber hinaus haben wir die Möglichkeit der Benutzung von Regelsprachen zur Beschreibung von Formatüberlappungen sowie deren praktischer Anwendbarkeit zur Erstellung eines Ontologie-Netzwerks zur Beschreibung von Experten skizziert und anhand von Beispielen vorgestellt. Des Weiteren stellten wir einige Projekte genauer vor, die neue Ontologien in den für uns relevanten Bereichen auf Basis von Wiederverwendung vorhandener Vokabulare entwickelt haben. Alle Untersuchungen bezüglich des ExpertFinder-Frameworks, die in dieser Arbeit präsentiert wurden, wurden im Hinblick auf die kritischen Erfolgskriterien (gemeinsam verwendete, maschinenlesbare Formate, kritische Masse von Anwendern/Nutzern und zusätzlich benötigte Technologien) durchgeführt, die wir eingangs definiert haben. Obwohl die Arbeit am ExpertFinder-Framework sich gerade erst in der Anfangsphase befindet, können wir mit dem vorgestellten Vokabular bereits wesentliche Teile der vorgestellten Anwendungsszenarien abdecken. Zu guter Letzt sei gesagt, dass das vorgestellte Vokabular in Kombination mit Regeln für Formatüberlappungen nicht auf die erwähnten Szenarien beschränkt bleiben muss. Das ExpertFinder-Vokabular-Framework kann in unterschiedlichen Domänen rund um die Beschreibung und Suche von Expertisen und Personen benutzt werden, auch wenn wir noch intensiv an Mechanismen arbeiten müssen, die Datensicherheit und Vertrauensgarantien von Inhalten sicherstellen. Diese Aspekte scheinen derzeit in der Semantic Web Architektur generell noch nicht ausreichend abgedeckt.

Acknowledgements

Die Autoren danken den Mitgliedern der ExpertFinder-Initiative für ihren Beitrag zum vorliegenden Artikel. Speziell danken wir Boanerges Aleman-Meza, Uldis Bojars, Harold Boley, John G. Breslin, Lyndon J.B. Nixon

und Anna V. Zhdanova, die als Mitverfasser an einem Tagungsbeitrag [2] mitgewirkt haben, auf dem dieses Kapitel basiert. Die Arbeit von Axel Polleres wurde durch die Europäische Kommission im Rahmen des inContext Projekts (IST-034718) sowie durch die Science Foundation Ireland im Rahmen des DERI-Lion Projekts (SFI/02/CE1/I131) gefördert. Die Arbeit von Malgorzata Mochol wurde durch das Projekt Wissensnetze, ein Teilprojekt im Berliner Forschungszentrum InterVal (Internet and Value Chains) im Rahmen des Projektes Internetökonomie vom Bundesministerium für Bildung und Forschung (BMBF), gefördert.

Literaturverzeichnis

1. Y. Alan. Konstruktion der KOWIENOntologie. Projektbericht 2, Institut für Produktion und Industrielles Informationsmanagement, Universität Duisburg-Essen, 2003.
2. B. Aleman-Meza, U. Bojars, H. Boley, J.G. Breslin, M. Mochol, L.J.B. Nixon, A. Polleres, and A.V. Zhdanova. Combining RDF Vocabularies for Expert Finding. In 4th European Semantic Web Conference (ESWC2007), pages 235–250, Innsbruck, Austria, June 2007. Springer.
3. F. Alkhateeb, J. Baget, and J. Euzenat. Extending SPARQL with Regular Expression Patterns. Technical Report 6191, Institut National de Recherche en Informatique et Automatique (INRIA), May 2007.
4. B. Aleman-Meza, et al. Semantic Analytics on Social Networks: Experiences in Addressing the Problem of Conflict of Interest Detection. In 15th International World Wide Web Conference (WWW2006), 2006.
5. C. Bizer, R. Heese, M. Mochol, R. Oldakowski, R. Tolksdorf, and R. Eckstein. The Impact of Semantic Web Technologies on Job Recruitment Processes. In 7. Internationale Tagung Wirtschaftsinformatik 2005, pages 1367–1383, 2005.
6. U. Bojars, J.G. Breslin, D. Berrueta, D. Brickley, S. Decker, S. Fernández, C. Görn, A. Harth, T. Heath, K. Idehen, K. Kjernsmo, A. Miles, A. Passant, A. Polleres, L. Polo, and M. Sintek. SIOC Core Ontology Specification, June 2007. W3C member submission, <http://www.w3.org/Submission/sioc-spec/>.
7. H. Boley, M. Kifer, P.-L. Pătrânjan, and A. Polleres. Rule Interchange on the Web. In Reasoning Web 2007, pages 269–309. Springer, September 2007.
8. H. Boley, S. Tabet, and G. Wagner. Design Rationale of RuleML: A Markup Language for Semantic Web Rules. In Semantic Web Working Symposium (SWWS'01), pages 381–401. Stanford University, July/August 2001.
9. P.A. Bonatti and D. Olmedilla. Semantic Web Policies: Where are we and What is still missing? Tutorial at the European Semantic Web Conference (ESWC), June 2006.
10. P.A. Bonatti and D. Olmedilla. Rule-Based Policy Representation and Reasoning for the Semantic Web. In Reasoning Web 2007, pages 240–268. Springer, September 2007.

11. J.G. Breslin, A. Harth, U. Bojars, and S. Decker. Towards Semantically-Interlinked Online Communities. In 2nd European Semantic Web Conference (ESWC '05, pages 500–514, 2005.
12. D. Brickley and R. V. Guha (eds.). RDF Vocabulary Description Language 1.0: RDF Schema, February 2004. W3C Recommendation, 10 February 2004. Available from <http://www.w3.org/TR/rdf-schema/>.
13. D. Brickley and L. Miller. FOAF Vocabulary Specification, July 2005. <http://xmlns.com/foaf/0.1/>.
14. S. Brin and L. Page. The anatomy of a large-scale hypertextual Web search engine. In 7th International World Wide Web Conference (WWW1998), pages 107–117, 1998.
15. A. Vaisman, C. Gutierrez, C. Hurtado. Temporal RDF. In 2nd European Semantic Web Conference (ESWC'05), 2005.
16. F. Dawson and D. Stenerson. Internet Calendaring and Scheduling Core Object Specification (iCalendar). <http://www.ietf.org/rfc/rfc2445.txt>, 1998.
17. D. Connolly (ed.). Gleaning Resource Descriptions from Dialects of Languages (GRDDL), July 2007. W3C Proposed Recommendation, <http://www.w3.org/TR/grddl/>.
18. J. Clark (ed.). XSL Transformations (XSLT) Version 1.0, November 1999. W3C Recommendation, <http://www.w3.org/TR/xquery/>.
19. T. Eiter, G. Ianni, A. Polleres, and R. Schindlauer. Answer Set Programming for the Semantic Web. Tutorial at the European Semantic Web Conference (ESWC), June 2006. Tutorial at the European Semantic Web Conference (ESWC), slides available at <http://asptut.gibbi.com/>.
20. E. Franconi. The Knowledge Web Network of Excellence. http://interop-esa05.unige.ch/INTEROP/Proceedings/IST/IST1_kweb-.pdf, 2005.
21. A. Ginsberg, D. Hirtle, F. McCabe, and P.-L. Patranjan (eds.). RIF Use Cases and Requirements. W3C Working Draft.
22. G.A. Grimnes, S. Schwarz, and L. Sauermann. RDFHomepage or „Finally, a use for your FOAF file“. In 2nd Workshop on Scripting for the Semantic Web (SFSW '06), June 2006.
23. A. Harth, J. Umbrich, and S. Decker. MultiCrawler: A Pipelined Architecture for Crawling and Indexing SemanticWeb Data. In 5th Int.l Semantic Web Conference, Athens, GA, USA, November 2006.
24. M. Hepp. Products and Services Ontologies: A Methodology for Deriving OWL Ontologies from Industrial Categorization Standards. International Journal on Semantic Web & Information Systems, 1(2):72–99, 2006.
25. D. Huynh, S. Mazzocchi, and D. Karger. Piggy Bank: Experience the Semantic Web Inside Your Web Browser. In International Semantic Web Conference 2005 (ISWC2005), 2005.
26. R. Iannella. Representing vCard Objects in RDF/XML, February 2001. W3C Note, available at <http://www.w3.org/TR/vcard-rdf>.
27. G. Klyne and J.J. Carroll (eds.). Resource Description Framework (RDF): Concepts and Abstract Syntax, February 2004. W3C Recommendation, <http://www.w3.org/TR/rdf-concepts/>.

28. S.R. Kruk and S. Decker. Semantic Social Collaborative Filtering with FOA-FRealm. In *Semantic Desktop Workshop co-located with ISWC2005*, 2005.
29. J.Li, H. Boley, V.C. Bhavsar, and J. Mei. Expert Finding for eCollaboration Using FOAF with RuleML Rules.
<http://www.ruleml.org/papers/FindXpRT.pdf>.
30. S. Schaffert M. Krötzsch and D. Vrandečić. Reasoning in Semantic Wikis. In *Reasoning Web 2007*, pages 310–329. Springer, September 2007.
31. A. Malhotra, J. Melton, and N. Walsh (eds.). XQuery 1.0 and XPath 2.0 Functions and Operators, January 2007. W3C Recommendation,
<http://www.w3.org/TR/xpath-functions/>.
32. A. Miles and D. Brickley (eds.). SKOS Core Vocabulary Specification, November 2005. W3C Working Draft,
<http://www.w3.org/TR/swbp-skos-core-spec>.
33. M. Mochol, R. Oldakowski, and R. Heese. Ontology-based Recruitment Process. In *GI Conference (GI2004)*, 2004.
34. K. Möller, L. Predoiu, and D. Bachlechner. Portal Ontology – Semantic Web Portal Project. Technical Report Project Deliverable, V1.2., DERI Research Report, 2004.
35. C. Morbidoni, A. Polleres, and G. Tummarello. Who the FOAF knows Alice? A needed step towards Semantic Web Pipes. In *ISWC 2007 Workshop on New forms of Reasoning for the Semantic Web: Scaleable, Tolerant and Dynamic*, Busan, Korea, November 2007.
36. O. Patashnik. BIBTeXing, 1998.
37. P.F. Patel-Schneider, P. Hayes, and I. Horrocks (eds.). OWL Web Ontology Language Semantics and Abstract Syntax, February 2004. W3C Recommendation, <http://www.w3.org/TR/owl-semantics/>.
38. A. Polleres and C. Feier and A. Harth. Rules with Contextually Scoped Negation. In *3rd European Semantic Web Conference (ESWC2006)*, Budva, Montenegro, June 2006. Springer.
39. A. Polleres, F. Scharffe, and R. Schindlauer. SPARQL++ for Mapping between RDF Vocabularies. In *6th International Conference on Ontologies, DataBases, and Applications of Semantics (ODBASE 2007)*, Vilamoura, Algarve, Portugal, November 2007.
40. E. Prud'hommeaux and A. Seaborne (eds.). SPARQL Query Language for RDF, June 2007. W3C Candidate Recommendation,
<http://www.w3.org/TR/2007/CR-rdf-sparql-query-20070614/>.
41. E. Paslaru Simperl, C. Tempich, and M. Mochol. Technologies for Business Information Systems, chapter Cost estimation for ontology development: applying the ONTOCOM model, pages 432–447. Springer, 2007.
42. Y. Sure, S. Bloehdorn, P. Haase, J. Hartmann, and D. Oberle. The SWRC Ontology – Semantic Web for Research Communities. In *12th Portuguese Conference on Artificial Intelligence – Progress in Artificial Intelligence (EPIA 2005)*, volume 3803, pages 218–231, 2005.
43. R. Tolsdorf, M. Mochol, R. Heese, R. Eckstein, R. Oldakowski, and C. Bizer. Semantic-Web-Technologien im Arbeitsvermittlungsprozess. *Wirtschaftsinformatik: Internetoeconomie*, 48(1):17–26, 2006.

44. G. Tummarello, R. Delbru, and E. Oren. Sindice.com: Weaving the Open Linked Data. In 6th Int.l Semantic Web Conf. (ISWC2007), Busan, Korea, November 2007.
45. E. Della Valle and et. al. SEEMP: A Semantic Interoperability Infrastructure for e-Government Services in the Employment Sector. In European Semantic Web Conference'07 (ESWC2007), pages 220–234. Springer, 2007.
46. A versit Consortium. vCard: The Electronic Business Card, 1997.
<http://www.imc.org/pdi/vcardwhite.html>.

11. Semantische Content Management Systeme

Erich Gams und Daniel Mitterdorfer

Salzburg Research Forschungsgesellschaft mbH, Österreich;
{egams; dmitter}@salzburgresearch.at

Zusammenfassung: Content Management Systeme (CMS) sind in vielen Organisationen bereits seit längerer Zeit fester Bestandteil zur Verwaltung und kollaborativen Bearbeitung von Text- und Multimedia-Inhalten. Im Zuge der rasch ansteigenden Fülle an Informationen und somit auch Wissen wird die Überschaubarkeit der Datenbestände jedoch massiv eingeschränkt. Diese und zusätzliche Anforderungen, wie automatisch Datenquellen aus dem World Wide Web (WWW) zu extrahieren, lassen traditionelle CMS immer mehr an ihre Grenzen stoßen. Dieser Beitrag diskutiert die neuen Herausforderungen an traditionelle CMS und bietet Lösungsvorschläge, wie CMS kombiniert mit semantischen Technologien diesen Herausforderungen begegnen können. Die Autoren stellen eine generische Systemarchitektur für Content Management Systeme vor, die einerseits Inhalte für das Semantic Web generieren, andererseits Content aus dem Web 2.0 syndizieren können und bei der Aufbereitung des Content den User mittels semantischer Technologien wie Reasoning oder Informationsextraktion unterstützen. Dabei wird auf Erfahrungen bei der prototypischen Implementierung von semantischer Technologie in ein bestehendes CMS System zurückgegriffen.

Einleitung

Informationen zu archivieren, zu verwalten und jederzeit rasch und effizient den Mitarbeitern zur Verfügung stellen zu können, ist eine der Anforderungen von wissensorientierten Unternehmen. Diese Aufgaben werden aufgrund der Fülle und ständig wachsenden Menge an Informationen, z. B. in Form elektronischer Dokumente, zu einer immer größeren Herausforderung.

Zur Bewältigung dieser Anforderungen bieten CMS-Organisationen Unterstützung sowohl auf technischer als auch auf prozessorientierter Ebene. Diese CMS sind meist auf die Verwaltung unternehmensinterner Informationen spezialisiert oder zur alleinigen Publizierung von Information

gedacht. Die Einbindung neuer Konzepte wie des semantischen Webs, dessen im Web veröffentlichte Information nicht nur für Menschen lesbar sind, sondern auch für Maschinen „semantisch“ interpretier- und verarbeitbar sein sollen, oder die Möglichkeit im Web 2.0, Inhalte interaktiv und kollaborativ zu bearbeiten, stellen auch neue Anforderungen an CMS. Die Verwaltung und die Nutzung externer Dienste oder Informationsquellen aus dem WWW gewinnt immer mehr an Bedeutung und konfrontiert die traditionellen Systeme mit weiteren Problemen, wie z. B. die Heterogenität der Daten und die dadurch erschwerte Integration. Durch so genannte Mashups werden kommerzielle oder auch freie Dienste aus dem WWW eingebunden, um Redakteure dabei zu unterstützen, ihren Content entsprechend den Semantic Web Standards aufzubereiten. Dieser Artikel erörtert zunächst die Aufgaben, die traditionelle CMS zu erfüllen hatten und haben, und beleuchtet die neuen Herausforderungen, die teilweise bereits bestehen oder in Zukunft auf die Systeme zukommen werden. Basierend auf dieser Analyse wird eine generische Architektur eines semantischen CMS vorgestellt und konzeptuell auf die technische Umsetzung eingegangen. Diese Architektur bildet die Ausgangsbasis für den Ausbau eines bereits bestehenden traditionellen CMS. In den folgenden Kapiteln wird auf die Erfahrungen bei der prototypischen Implementierung einzelner Komponenten mit semantischen Funktionalitäten eingegangen. Den Abschluss bildet ein Ausblick auf Semantische CMS der nächsten Generation, und wie Social Semantic Web Komponenten in CMS Funktionalität integriert werden können.

Aufgaben von Content Management Systemen

Unternehmen werden mit einer ständig steigenden Anzahl an Daten und Informationen zur Unterstützung von Geschäftsprozessen konfrontiert. Diese Informationen erfordern eine systematische Verarbeitung und Ablage und sollen effizient verwaltet und zugänglich gemacht werden. Abhängig vom Einsatzgebiet werden die verschiedensten Qualitätskriterien, wie Aktualität, Genauigkeit, Richtigkeit, Vollständigkeit usw., an den Inhalt gestellt. Die Erfüllung der genannten Kriterien kann allerdings nur durch IT-gestützte Verarbeitung und Verwaltung von Informationen unterstützt bzw. sichergestellt werden.

Die digitalen Informationen, die in elektronischen Systemen zur Nutzung bereitgestellt werden, werden als **Content (Inhalt)** bezeichnet. Laut Kampffmeyer [8] setzt sich Content aus dem eigentlichen Inhalt (z. B. ein Dokument, ein Bild etc.) und den dazugehörigen Metadaten zusammen. Diese Metadaten enthalten Informationen (Metainformationen) über den

Inhalt, die vorrangig der Verwaltung und Kontrolle des eigentlichen Inhalts dienen. So genannte semantische Metadaten bezeichnen dabei den Dokumentinhalt und versuchen diesen zu abstrahieren und für eine maschinelle Verarbeitung erschließbar zu machen. Ganz generell können Inhalte nach dem Grad ihrer Strukturiertheit unterteilt werden:

- **strukturiert:** d. h. der Content liegt in einem standardisierten Format vor und ist mit strukturierten Metadaten, wie beispielsweise Informationen zum Autor, zu Urheberrechten, Erstellungsdatum und Formatinformationen und Inhaltsbeschreibungen versehen.
- **schwach strukturiert:** der Content beinhaltet nur zum Teil Layout und Metadateninformationen, die meist nicht standardisiert sind.
- **unstrukturiert:** d. h. der Content besteht aus beliebigen Informationsobjekten, wie Bildern, Grafiken, Präsentationen oder Rich-Media-Inhalten wie Audio und Video. Layout, Inhalt und Metainformationen sind meist nicht getrennt.

Die Verwaltung dieser verschiedenen Contenttypen erfordert hohe Flexibilität und Aufwand. CMS sollen nun eben diesen Aufwand bei der Verwaltung von Content verringern. **Content Management** generell ist die Zusammenfassung aller Tätigkeiten, Prozesse und Hilfsmittel, die den Lebenszyklus digitaler Informationen, bezeichnet als Content, in Form von Unterlagen und Dokumenten unterstützen¹. Content Management Systeme unterstützen Content Management mit IT-Werkzeugen und erfüllen im übergreifenden Sinn die folgenden fünf Aufgaben:

- die **Erstellung** von Content (direkt oder mit Hilfe weiterer Programme)
- die **Verwaltung** von Content
- die **Bereitstellung** von Content (Präsentation, Distribution)
- die **Kontrolle** von Content (Rechte, Versionierung)
- die **Individualisierung** von Content (Personalisierung)

Für die Begriffe Content Management und CMS haben sich zwei spezielle Ausprägungen gebildet: **Enterprise Content Management (ECMS)** und **Web Content Management (WCMS)**.

Die zentralen Funktionen und Aufgaben eines klassischen Web Content Management Systems (z. B. Typo3², Joomla³), welches in der Praxis eingesetzt wird, sind das Erstellen und Verändern von Inhalten (Webseiten) in einem kontrollierten Erstellungs- und Veröffentlichungsprozess, Bereitstel-

¹ Wikipedia, http://de.wikipedia.org/wiki/Content_Management, zuletzt besucht am 12.12.2007

² <http://typo3.org/>

³ <http://www.joomla.de/>

lung und Verwaltung von Information (z. B. Bildern, Download-Dateien, Dateimport, Workflow-Management & Versionisierung von Webseiten, Benutzer- und Zugriffsverwaltung, sowie die Aufbereitung für die Präsentation (Browser-Darstellung, HTML, XML u. a.). Web Content Management Systeme haben sich somit zu vielfältigen und komplexen Redaktionssystemen entwickelt, die die Abläufe eines kooperativen, webbasierten Arbeitsablaufes koordinieren und bei der Online-Erstellung der Inhalte unterstützen [3].

Im Gegensatz zum Web Content Management kennzeichnet ECM den Einsatz eines CMS im geschlossenen, unternehmensinternen Bereich zur Unterstützung von Prozessen und Verwaltung von Informationen. Der Dachverband AIIM international definiert ECM folgendermaßen:

„Enterprise Content Management (ECM) is the technologies used to capture, manage, store, preserve, and deliver content and documents related to organizational processes. ECM tools and strategies allow the management of an organization's unstructured information, wherever that information exists.“[1]

Enterprise Content Management umfasst die Technologien zur Erfassung, Verwaltung, Speicherung, Bewahrung und Bereitstellung von Content und Dokumenten zur Unterstützung von organisatorischen Prozessen im Unternehmen. Die ECM-Komponenten und -Techniken lassen sich nach der Definition von AIIM international [1] in fünf Hauptkomponenten einordnen:

- Erfassung (Capture)
- Verwaltung (Manage)
- Speicherung (Store)
- Bewahrung (Preserve)
- Ausgabe (Deliver)

Eine besondere Bedeutung kommt dabei der Verwaltungskomponente zu, die noch in fünf Unterkomponenten unterteilt werden kann:

- Document Management,
- Collaboration (die Zusammenarbeit unterstützende Systeme, wie z. B. Groupware),
- Web Content Management,
- Records Management (Archiv und Ablageverwaltungssysteme) und
- Workflow- und Business Process Management.

Rod Dilnutt [5] identifiziert weiters noch die Komponente Search and Retrieval als eigene Komponente und unterstreicht damit den besonderen Stellenwert des Suchens und Wiederauffindens der Inhalte im Content

Repository, einem Teilsystem, das jedes CMS gemein hat. Die breite Beschreibung von Enterprise Content Management schließt also auch Web Content Management als Sub-Funktionalität mit ein.

Im nun folgenden Kapitel werden anhand einiger schwerpunktmäßig herausgegriffener Aufgaben – sowohl bereits bestehende als auch zukünftige – Herausforderungen für moderne CMS diskutiert.

Neue Herausforderungen an CMS Systeme

Ausgehend von den traditionellen Aufgaben eines CMS, wie dem Einsatz eines ECMS im geschlossenen, unternehmensinternen Bereich, bilden sich durch den veränderten Kontext (Kollaborative Prozesse der Contentgenerierung im Web 2.0, die nicht immer kontrollierbar sind) und das Umfeld, in denen CMS eingebettet sind, neue Herausforderungen.

- **Einbeziehung neuer Quellen und Bereitstellung von Inhalten:** Wie bereits einleitend beschrieben, ist in den letzten Jahren die Attraktivität des WWW als neue und größte Informationsressource immens gestiegen. Durch den Versuch, das WWW als Informationsträger anzubinden, steigt aber auch die Menge an Daten im Allgemeinen und die Menge an schwach strukturiertem Multimedia-Content im Speziellen an. Die Konzepte des Web 2.0 (kollaborative Inhalte zu erstellen, z. B. Wikipedia) und des Semantic Web (Informationen maschinenlesbar zur Verfügung zu stellen) zeigen das Öffnen der Prozesse der Contenterstellung in Richtung der Kunden an. Webservices und Contentsyndication dienen zur Bereitstellung von Content in unterschiedlichen Formaten, Selektionen und Aufbereitungsformen im Umfeld des Content Management. Durch Syndication kann der gleiche Inhalt mehrfach in verschiedener Form und für verschiedene Anwendungszwecke genutzt werden.
- **Unterstützung des Wissensmanagements:** Wissensmanagement gewinnt in Unternehmen zunehmend an Bedeutung. Wissen wird durch die Anwendung von Informationen also „durch den Einbau von Informationen in Erfahrungskontexte generiert“ [11]. Um Wissensmanagement effektiv und effizient betreiben zu können, ist es sinnvoll, Informationen aus den heterogenen Quellen in einem CMS zentral und über einen Einstiegspunkt zugänglich zu machen. Dies erfordert entweder die Inhalte aus unterschiedlichen Quellen zu integrieren oder einen zentralen Einstiegspunkt zu schaffen. In vielen Unternehmen existieren dazu oft unterschiedliche Repositorien mit eigenen, unabhängigen Schnittstellen.
- **Zunehmende Informationsmenge und Metadaten:** Die mit der zunehmenden Anzahl der Informationsquellen einhergehende steigende Infor-

mationsmenge stellt aber auch eine neue Herausforderung an die verschiedenen Phasen der Verarbeitung dar. Besonders bei der Erfassung der Information im System haben Benutzer vermehrt Unterstützung nötig. Die Qualität der Suche steigt mit der Qualität der Inhalte der Metadaten. Standards, als allgemein gültige, an Regeln und Richtlinien orientierte Empfehlungen, sollen die Benutzerfreundlichkeit und die Plattformunabhängigkeit unterstützen. Der Dublin Core Standard ist z. B. ein vom W3C unterstützter Metadatenstandard zur Auszeichnung von Inhalten im WWW. Unterstützung bei der Metadatenauszeichnung ist aber auch durch eine Automatisierung wie z. B. durch Vorschläge und vorausgefüllte Felder vom System bei der Metadateneingabe gefordert. Binäre Bilddateien enthalten bereits automatisch generierte Metadaten, die automatisch extrahiert werden können (EXIF-Daten bei JPG-Dateien), aber auch die Analyse der semantischen Inhalte durch das System, ermöglicht es Metadaten zu erzeugen. Begleitend zu den Vorschlägen, können Systeme bereits eine automatische Validierung zur Steigerung der Qualität durchführen.

- **Intelligente Suchmechanismen:** Traditionelle CMS bieten Benutzern eine Volltextsuche, in der Benutzer ihre Suchanfrage in Form von Begriffen absetzen können. Populär wurde diese Suchform durch Internet-Suchmaschinen. Dennoch birgt diese Art der Suche einige Beschränkungen. Dieses Suchverfahren funktioniert nur für Textdokumente, deren Inhalt auch vom System analysiert und damit auch indiziert werden kann. Multimediale Inhalte, wie Bilder und Filme, sind so nicht durchsuchbar. Das Auffinden dieser Inhaltstypen, beruht auf der vollständigen Beschreibung durch Metadaten. Durch die zunehmende zu erfassende Informationsmenge steigt auch der Bedarf an intelligenteren Mechanismen zum Wiederauffinden der benötigten Informationen.
- **Klassifizierung der Daten:** Um neben der Suche im Volltext einen alternativen Zugang zu Inhalten zu schaffen, werden Inhalte beim Einstellen in das System kategorisiert. Dabei kann der Publizierer den Inhalt in eine Kategorie, aufbauend auf einem meist vom CMS vorgegeben Thesaurus, einordnen. Eine Mehrfachzuordnung oder die Verwendung von Benutzern gewählter Schemen wird meist nicht unterstützt. Durch Browsen der Kategorien können Suchende an den Blättern des Baumes zu den Inhalten gelangen. Stimmt die vom Ersteller getroffene Zuteilung mit der imaginären Zuteilung bei der Suche überein, wird der Inhalt gefunden und führt die Suche zum gewünschten Ergebnis.
- **Personalisierung:** Die Menge der unterschiedlichen Daten und Informationen und ihre Heterogenität erfordern aber auch neue alternative Zugänge zur Volltextsuche, die an die Benutzer individuell angepasst sein sollen. Die Anpassung von Diensten, aber auch die Anpassung der

Auswahl des Contents an die jeweiligen Nutzerbedürfnisse, ermöglicht einen effektiveren und effizienteren Zugang zu Informationen. Bekannte Web-Portale, wie z. B. Amazon, bauen auf Personalisierung als Marketinginstrument und verwenden dazu Verfahren wie kollaboratives Filtern oder regelbasierte Personalisierung.

Wie diese gesammelten Herausforderungen für CMS mit Hilfe semantischer Technologien bewältigt werden können, wird im nun folgenden Kapitel diskutiert.

Semantische Technologien und Content Management Systeme

Semantische Technologien, abgeleitet aus dem Semantic Web, einem Begriff geprägt von Tim Berners-Lee, dem Erfinder des WWW [2], basieren vor allem auf der Ablage von Wissen und Metadaten in Wissensmodellen. Ontologien ermöglichen die Ablage und den Zugang zu maschinenverständlicher Repräsentation von Wissen und den Zugang zur Bedeutung des Wissens durch Semantik.

Die Erweiterung von CMS durch semantische Technologien, umfasst sowohl das Management von semantischem Content in Form von Metadaten oder Auszeichnungen, als auch die Erweiterung der Funktionalität durch semantische Konzepte, wie die Suche über Wissensmodelle.

Wie semantische Konzepte und Technologien CMS erweitern können und den genannten Herausforderungen begegnet werden kann, wird im Folgenden diskutiert:

Semantische Mittelschicht: Durch die Heterogenität der Daten greifen Unternehmen oft auf verteilte, meist proprietäre CMS zurück. Auf der Suche nach Inhalten müssen die Benutzer verschiedene Systeme abfragen. Um einen einheitlichen Zugang oder einen zentralen Einstiegspunkt zu schaffen bzw. die Inhalte aus unterschiedlichen Quellen zu integrieren, müsste jede Datenquelle mit jeder Anwendung verbunden werden – man erhält n mal m Verbindungen. Jede neue Datenquelle eines Drittanbieters müsste wieder mit jeder bestehenden Anwendung verbunden werden.

Könnte man alle Datenquellen durch eine einheitliche Schnittstelle abstrahieren, würde sich die Anzahl der Verbindungen auf $n+m$ reduzieren. Eine solche Schnittstelle, realisiert mit semantischen Technologien und Konzepten, kann als semantische Mittelschicht oder semantische Middleware bezeichnet werden. Folgende Basiskonzepte sind notwendig um so eine semantische Mittelschicht zu realisieren:

- **Uniform Resource Identifier (URI⁴):** Ein URI ist eine Zeichenfolge, die zur Identifizierung einer abstrakten oder physischen Ressource (z. B. Webseiten, Dateien, Personen oder auch Webservices), bevorzugt im WWW eingesetzt, benutzt wird. Alle Daten im semantischen Web sollen durch ein URI eindeutig identifiziert werden. Tim Berners Lee prägte dazu den Ausspruch: „Don’t say „colour“. say <http://example.com/2002/std6#col>“. In einem semantischen CMS werden alle Dokumente und Fakten in einem URI kodiert.
- **Resource Description Framework (RDF⁵):** Die Grundstruktur des Semantic Web baut auf RDF auf. Alle Informationen sollen in RDF abgelegt werden. RDF ist eine Auszeichnungssprache für Metadaten, die in Form von Tripeln, bestehend aus Subjekt, Prädikat und Objekt abgelegt werden. Im Sinne des Semantic Web wird RDF mittels XML als RDF/XML serialisiert. Es werden auch XML-Namespaces eingesetzt, welche die XML-Elemente und Attribute qualifizieren, Ressourcen und Properties können eindeutig mittels URIs bestimmt werden. (Für eine weiterführende Einführung in das Thema siehe [9].) Mittels RDF-Schema (RDF-S) ist es möglich, das Vokabular für eine bestimmte Domäne zu definieren. RDF-S legt für Eigenschaften fest, welche Werte erlaubt sind, welche Bedeutung diese haben, welche Beziehungen zu anderen Eigenschaften bestehen, und welche Arten von Ressourcen die Eigenschaft verwenden darf. Abfragen der Informationen sind über die SQL ähnliche Sprache SPARQL⁶ möglich.
- **Ontologien:** Ontologien bezeichnen eine Spezifikation einer Konzeptualisierung einer Domäne [7]. Ontologien sind aus Konzepten, die Typen von Entitäten bezeichnen, aufgebaut, die durch Relationen miteinander verbunden sind. Über Regeln lassen sich neue Relationen und Zusammenhänge aus der Ontologie ableiten und abfragen. Ontologien oder Wissensmodelle können in RDF-S oder in Repräsentationssprachen, die auf RDF-S aufbauen (SKOS, OWL), beschrieben werden. Mit Ontologien lässt sich nicht nur domänenspezifisches Wissen ablegen, sondern auch Klassifikationsschemen oder Abbildungen zwischen verschiedenen Schemen modellieren.

⁴ RFC 3986 URI Generic Syntax, <http://tools.ietf.org/html/rfc3986>, zuletzt besucht am 23.11.2007

⁵ Resource Description Framework RDF, <http://www.w3.org/RDF/>, zuletzt besucht am 23.11.2007

⁶ SPARQL Query Language for RDF, W3C Proposed Recommendation 12 November 2007, <http://www.w3.org/TR/rdf-sparql-query/>, zuletzt besucht am 23.11.2007

Aufbauend auf diesen Basiskonzepten kann eine semantische Mittelschicht einen einheitlichen und zentralen Zugriff auf Wissensstrukturen gewährleisten. Die Zuordnung mit Hilfe von Ontologien integriert das vorhandene Wissen auch für alle zukünftigen Bedürfnisse. Tim Berners Lee bezeichnet die Schicht, die das Abbilden realisiert und die Schnittstelle zu allen anderen Services und Applikationen darstellt, auch als RDF-Bus⁷. Eine semantische Mittelschicht unterstützt nicht nur die inhaltliche Integration von Information, sondern reduziert auch die Komplexität von Schnittstellen. Natürlichsprachliche und wartbare Begriffsstrukturen können Informationen zwischen beliebigen Anwendungen und Quellen austauschen. Das Anbinden von Datenquellen von Drittanbietern ist jederzeit möglich.

Neue Klassifikationsschemen durch Ontologien: Durch den Einsatz von Social Software, können Communities neue Klassifikations- und Organisationsschemen generieren und so die Sichtweise auf den Content erweitern. Mit der erweiterten Sichtweise wird auch die Suche durch den Einsatz von Ontologien vielfältiger. So kann nicht nur nach Synonymen gesucht werden, sondern die Suchbegriffe können auch generalisiert (Oberbegriffe) oder spezialisiert (Unterbegriffe) werden und so dem Benutzer mehr Suchmöglichkeiten bieten. Die Zuordnung von Dokumenten ist dabei nicht nur auf ein Konzept einer Ontologie oder einer Ontologie als Ganzes beschränkt, sondern kann über mehrere Ontologien erfolgen.

Semantische Analyse und Automatische Klassifizierung: Die semantische Analyse benutzt verschiedene Methoden und Werkzeuge, um die semantische Bedeutung von Inhalten zu erfassen. Dabei können sowohl Communitywissen (wie z. B. das gemeinsame Beschlagworten von Inhalten oder Einordnen in Kategorien) zum Einsatz kommen, als auch statistische Verfahren, die Inhalte vergleichen und die Beschreibungen aus ähnlichen Inhalten zur Klassifizierung verwenden. Eine weitere semantische Klassifizierungsmethode ist die Untersuchung von Inhalten auf Konzepte eines Wissensmodells und die Zuweisung der einzelnen Informationen zu diesen Konzepten. Durch die Zuordnung zu mehreren Konzepten, besteht keine strikte Zuordnung wie in einem Thesaurus.

Personalisierung: Durch die Zuordnung zu mehreren Konzepten und den Einsatz verschiedener Ontologien als Klassifikationsschemen entstehen verschiedene Sichten auf die Inhalte. Das System kann Benutzern sowohl eine allgemeine Sicht als auch eine eigene, personalisierte Sicht auf die

⁷ Tim Berners-Lee, Talk March 2006, <http://www.w3.org/2006/Talks/0314-ox-tbl/>, aufgerufen am 10.10.2007

Daten und Inhalte ermöglichen. Es werden nur jene Inhalte, die den Benutzer auch unmittelbar betreffen, zur Verfügung gestellt.

Content Syndication und Web Services: Content Syndication bezeichnet das Zusammenführen von Inhalten aus unterschiedlichen Quellen. Der Inhalt wird dabei nicht einfach nur referenziert, sondern in ein neues Dokument (z. B. eine Webseite) integriert. So können z. B. Börsenkurse, aktuelle Nachrichten, aber auch speziell ausgewählte Inhalte anderer Webseiten in einer neuen Webseite integriert werden. Über so genannte RSS-Feeds (auch „Channels“ genannt) kann Content angeboten werden. Ursprünglich wurden RSS-Feeds von Nachrichtenseiten zur Content-Syndication verwendet.

Die automatisierte und standardisierte Weiterverarbeitung von Informationen war schon der Grundgedanke für die Entstehung des Semantic Web [2]. Tim Berners-Lee stellte dabei das Konzept der Agenten vor, die maschinenlesbare Informationen (z. B. in RDF) von verschiedenen Quellen zusammentragen und zu neuem Wissen verarbeiten können. Für die Verbreitung von Funktionalität und Services über das Internet haben sich so genannte Web Services etabliert. Diese unterstützen die Kommunikation mit anderen Softwarekomponenten unter Verwendung XML-basierter Nachrichten durch den Austausch über internetbasierte Protokolle. Web Services sind über URIs eindeutig identifizier- und über das WWW abrufbar.

Wie diese Konzepte in den Aufbau eines CMS einfließen, soll das nächste Kapitel exemplarisch zeigen.

Eine generische semantische Content Management Architektur

Die nachfolgende Abbildung zeigt die generische Schichtenarchitektur eines semantischen CMS. Eine Schichtenarchitektur ist die Zerlegung eines Software-Systems in Komponenten, deren Abhängigkeitsbeziehungen untereinander durch die Architektur eingeschränkt sind. Die Komponenten oder Schichten (englisch „Tier“) werden dabei sinnbildlich übereinander angeordnet. Die untergeordnete Komponente darf nur auf Schichten über ihr zugreifen.

Das Diagramm zeigt vier verschiedene Schichten. Um in der Referenzarchitektur die höchstmögliche Flexibilität zu erreichen, sind die Komponenten auf einem hohen abstrakten Level gehalten. Die unterste Schicht kennzeichnet die Komponenten der Datenhaltung. Die Daten-Zugriffsschicht stellt die logische Daten-Unabhängigkeit des CMS sicher. Dabei werden zwei verschiedene Datenspeicher unterschieden, das Content Repository, welches den eigentlichen Content enthält und das Knowledge




Abb. 1. Referenzarchitektur eines semantischen Content Management Systems

Repository, in dem alle Wissensmodelle (Thesauri, Ontologien) und Metadaten der Inhalte und Benutzer abgelegt sind. Das Content Repository legt Inhalte, wie PDF-Dokumente oder Audio-Dateien, versioniert ab. Diese müssen eindeutig über einen URI identifizierbar sein.

Um höchste Flexibilität zu gewährleisten und gleichzeitig die Vorteile von Wissensrepräsentationssprachen zu nutzen, werden sämtliche Informationen im CMS in RDF-Tripeln abgelegt. Das Knowledge Repository ist somit ein Container zur Verwaltung dieser Tripel. Abgelegt werden Metadaten über Seiten genauso wie die Lokalisierung von Seiten oder anderer Inhalte über URIs. Da Wissensdatenbanken oder Ontologien in RDF implementiert werden können, ist das Knowledge Repository auch die Komponente, die Ontologien, wie z. B. SKOS oder FOAF, zur Verfügung stellt.

Die Service- und Integrationsschicht stellt basierend auf der Datenzugriffsschicht höherwertige Dienste zur Verfügung oder integriert externe Dienste. Der Semantic Analyzer extrahiert Metadaten aus dem Content, die den Benutzern bei der Contentauszeichnung vorgeschlagen werden können. Einerseits geschieht dies über bereits bestehende eingebettete Metadaten bei Asset-Formaten wie MPEG oder PDF. Andererseits werden Metadaten z. B. durch statistische Verfahren vom Semantic Analyzer ermittelt. Solche ermittelten Metadaten können beispielsweise als Basis für eine Klassifizierung mit einem Tagging-Plugin dem Benutzer bei der Erstellung von Metadaten helfen. Der Knowledge Manager repräsentiert Fakten und Regeln über die abzubildende Domäne, z. B. in Form von Ontologien oder Thesauri. Dabei ist der Knowledge Manager die zentrale Schnittstelle für die meisten Dienste der API-Schicht. Jegliche Informationen und jegliches Wissen soll hier repräsentiert werden. Der Index Manager hält einen Index aller im Content Repository abgelegten Inhalte vor. Dieser Volltextindex dient zur Beschleunigung der Volltextsuche.

Die Applikationsschicht implementiert die Schnittstelle für Anwendungsentwickler. Diese Schicht soll einen möglichst bequemen Zugriff auf die Funktionalitäten der unteren Schichten zulassen. Über implizite Abläufe, wie beispielsweise die semantische Analyse von Content bei der Speicherung, soll hier abstrahiert werden. Der Content Manager verwaltet den Inhalt aller Seiten, die für die Applikation benötigt werden. Die Aufgaben inkludieren das Speichern und Laden von Seiten sowie die Versionsverwaltung.

Im Profile Manager werden neben den üblichen Aufgaben einer Benutzerverwaltung, wie dem Anlegen, Ändern oder Löschen von Benutzern sowie der Verwaltung von Benutzergruppen, darüber hinaus noch weitere Features unterstützt. Benutzer können selbst Beziehungen zu anderen Benutzern definieren. Informationen über User werden im Knowledge Repository gehalten. Als Daten-Modell bieten sich Formate wie FOAF oder vCard an. Der Workflow Manager ist für die Steuerung sämtlicher grobgranularer Businessprozesse bzw. Workflows, die im System abgewickelt werden, zuständig.

Über eine Suchfunktionalität können z. B. Inhalte (z. B. mit Hilfe einer Volltextssuche) oder Personen (Suche von Experten zu einem bestimmten Thema) gefunden werden. Dazu bedient sich die Suche sowohl des Knowledge Managers als auch des Index Managers (je nach Suchanfrage). Der Query Manager ist dabei für die Verwaltung von Anfragen zuständig. Darunter fallen Anfragen sowohl an die Inhalte als auch an die Metadaten. Die Komponente soll so eine einfache Abstraktion über Anfragen zur Verfügung stellen, die separate Anfragen für Volltext-Suche und Metadaten-Suche ggf. mit Reasoning überflüssig machen. Der Query Manager übernimmt neben der Abfrage der Datenquellen auch das Mapping zwischen Ontologierepräsentation und Domänenmodellrepräsentation.

Die Präsentationsschicht ist die direkte Schnittstelle des Systems zum Benutzer oder zu anderen Systemen. Dort wird die Darstellung für den Benutzer aufbereitet, Eingaben entgegengenommen und von den darunterliegenden Schichten verarbeitet. Die Komponente Presentation ist vor allem für die Darstellung der Anwendung in einem Web-Browser verantwortlich. Die Syndication-Komponente bietet Schnittstellen zur Verwendung der Inhalte in externen Systemen an. Hierunter fallen die verschiedenen Versionen von RSS und Atom. Syndication-Software ist in der Lage den Inhalt von verschiedenen Web-Sites in einheitlicher Form darzustellen. Die Komponente WebService bietet eine Programmier-Schnittstelle für den Anwender. Im nächsten Kapitel soll nun näher auf die technischen Besonderheiten der komponentenorientierten Implementierung eingegangen werden.

Technische Implementierung auf Basis einer Service-orientierten Architektur

Die im vorhergehenden Abschnitt vorgestellte Architektur ist als Plattform konzipiert, mit der eine Reihe von Anwendungsfällen im Content-Management-Bereich abgedeckt werden kann. Sowohl das technische, als auch das organisatorische Umfeld kann sich in den verschiedenen Einsatzszenarien stark unterscheiden. Deshalb ist es sinnvoll, die einzelnen Architekturkomponenten in Form einer Service-orientierten Architektur (SOA) zu implementieren. Die zwei Kernbausteine einer SOA sind Services, die die eigentliche Funktionalität bereitstellen, und eine Orchestrierungskomponente, die die Ablaufsteuerung basierend auf einem einfachen Interaktionsmodell übernimmt. Eine SOA hat in diesem Fall folgende Vorteile:

- Wenn die Komponenten eines bestehenden CMS klar genug strukturiert sind, können diese leicht integriert werden.
- Neue Komponenten können mit relativ geringem Aufwand in die Plattform integriert werden.
- Services von Drittanbietern oder interne Services können relativ einfach integriert werden.
- Es gibt eine klare Abgrenzung zwischen den Komponenten mit wohl definierten Schnittstellen. Die Komponenten sind außerdem lose gekoppelt.

Der Großteil der Komponenten wird in den meisten Einsatzszenarien relativ oft miteinander interagieren. Deshalb ist anzustreben, diese zur Laufzeit so eng wie möglich zu koppeln, um eine ausreichende Performance zu gewährleisten. Die Laufzeitplattform basiert auf der OSGi Framework Spezifikation der OSGi Alliance. Die einzelnen Komponenten, in OSGi Bundles genannt, genügen dabei der Komponentendefinition nach [10]. Ist es notwendig, externe Services zu integrieren, so wird ein Adapter [6] implementiert, der diesen Service als OSGi Bundle zur Verfügung stellt. Der OSGi Container vereint somit die Vorteile einer klaren konzeptionellen Trennung der Komponenten mit einer engen Kopplung zur Laufzeit.

Eine besonders wichtige Komponente der Gesamtarchitektur aus Sicht der Anwendungsintegration ist das Knowledge Repository. Je nach Anwendungssituation wird es notwendig sein, bestehende Daten entweder zu migrieren oder auf bereits bestehende Daten zuzugreifen. Im zweiten Fall ermöglicht das D2RQ Framework ein Mapping zwischen den bestehenden Datenbanksystemen und der Anwendung.

Social Semantic Web Komponenten eines CMS

Das Social Semantic Web bezeichnet die Verknüpfung der „Social“ Eigenschaft des WWW (soziale Phänomene wie die Möglichkeit der Gruppenkollaboration) mit dem Semantic Web.

Das Semantic Web unterstützt die maschinenlesbare und auswertbare Verarbeitung von Daten im WWW. Die Daten sollen mit Metadaten versehen werden, um die Erfassbarkeit der Bedeutung der Daten durch Maschinen zu erhöhen. So genannte Social Software, Anwendungen und Services, die die Interaktion von Benutzern untereinander und zur Content-Erstellung unterstützen, prägte eine neue Art der Nutzung des WWW (die Kombination der dafür eingesetzten Technologien wird auch als Web 2.0 bezeichnet). Das Social Semantic Web kombiniert nun die soziale Interaktion und den kollaborativen Aspekt der Content-Erstellung und die Weiterverarbeitung und automatisierte Nutzung durch Maschinen. Mit Hilfe von Social Semantic Web Anwendungen können Benutzer z. B. Ressourcen im Internet gemeinsam mit Metadaten versehen und in eine Semantic Web konforme Struktur bringen und vernetzen.

Social Semantic Web Komponenten kombinieren die Eigenschaften aus beiden Bereichen und ermöglichen somit Funktionen, die vom Web 2.0 als auch vom Semantic Web her bekannt sind. Im Folgenden werden einige mögliche Komponenten, sowie Dienste eines semantischen CMS beschrieben.

Die im Folgenden beschriebenen Komponenten bzw. Dienste können in drei Kategorien eingeteilt werden:

- *Basisdienste*: Darunter werden grundlegende Funktionalitäten wie z. B. die Verwaltung von Personenprofilen verstanden.
- *Integrationsschnittstellen*: Integrationsschnittstellen können sowohl vom System genutzt werden als auch von diesem zur Verfügung gestellt werden.
- *Höherwertige Dienste*: Höherwertige Dienste nutzen die Basisdienste und stellen komplexere Funktionalitäten zur Verfügung.

Die Komponenten und Dienste greifen dabei auf die bereits diskutierten Basistechnologien wie Ontologien, RDF und das URI-Konzept zurück.

Verwaltung von Profildaten

In herkömmlichen CMS werden Benutzerdaten üblicherweise in einer relationalen Datenbank gespeichert. Welche Benutzerstammdaten von der Applikation erfasst und verwaltet werden, unterscheidet sich von System

zu System. Ebenso ist es nicht möglich die Benutzerstammdaten über mehrere Applikationen zu nutzen oder zu warten. Jede Applikation setzt ihre eigene Benutzerverwaltung um, sodass eine Person in der Regel eine eigene Identität pro System benötigt und diese auch warten soll. Durch diese Zersplitterung der Daten entstehen in der Praxis oftmals Inkonsistenzen zwischen den Daten. Die Ursachen dafür können unterschiedlich sein, am häufigsten tritt diese Problematik wohl auf, wenn ein Webdienst nicht mehr intensiv oder überhaupt nicht mehr genutzt wird.

Eine Alternative bietet das Friend-of-a-Friend (FOAF) Format. FOAF ist ein Format, das in RDF abgebildet wird. In der FOAF-Datei werden die Benutzerstammdaten abgelegt. Diese kann öffentlich zugänglich gemacht werden, sodass diese Informationen auch anderen Diensten zur Verfügung stehen. Es ist natürlich zu beachten, dass rechtliche Bestimmungen eingehalten werden, d. h. es ist notwendig, dass Benutzer dieser Veröffentlichung auch explizit zustimmen.

Neben der Verwaltung herkömmlicher Profildaten (z. B. Name, Kontaktdaten) ist ein zentraler Aspekt von FOAF die Vernetzung von Personen untereinander. Dazu wird in der FOAF-Datei auf die FOAF-Dateien der vernetzten Personen verlinkt. Einige Ontologien erweitern und verfeinern FOAF. Die Charette Relationship Set Ontologie⁸ ermöglicht es z. B. zu spezifizieren, welcher Art eine Beziehung zu einer anderen Person ist. Damit ermöglicht FOAF sowohl die Verwaltung persönlicher Stammdaten als auch die Kontaktverwaltung in maschinenlesbarer Form.

Verwandte Projekte zu FOAF sind die VCard/RDF⁹ Spezifikation des W3C und XHTML Friends Network (XFN)¹⁰. VCard/RDF spezifiziert das Ablegen von VCard Daten in RDF und deckt somit vorrangig die Beschreibung von Metadaten einer Person ab. Beziehungen zwischen Personen werden weder von VCard noch von VCard/RDF berücksichtigt. XFN bildet ebenso wie FOAF Beziehungen zwischen Menschen ab, jedoch durch Hyperlinks. Dieses Format hat jedoch einige Schwächen: es kann z. B. nicht zwischen einer Person und einer Webseite unterschieden werden.

Ganzheitliche Sicht auf verteilte Konversationen

Heutzutage existieren verschiedenste Medien zur Online-Kommunikation wie Foren, Blogs, Wikis, Newsgroups oder Mailinglisten. Problematisch dabei ist, dass bestimmte Themen immer wieder diskutiert werden, es aber

⁸ <http://www.charette.com/SemanticWeb/crs.html>, zuletzt besucht am 28.1.2008

⁹ <http://www.w3.org/TR/vcard-rdf>, zuletzt besucht am 28.1.2008

¹⁰ <http://gmpg.org/xfn/>, zuletzt besucht am 28.1.2008

nur bedingt einen technologieunabhängigen Zugang zu den einzelnen Medien gibt.

Das Semantically Interlinked Online Communities (SIOC) Projekt wird vom Digital Enterprise Research Institute (DERI) in Galway, Irland durchgeführt. Die Idee hinter SIOC ist das Herstellen von Verbindungen zwischen verschiedenen diskussionsbasierten Medien im Internet (Foren, Blogs, Newsgroups). SIOC abstrahiert vom konkreten Diskussionsmedium und ermöglicht somit Diskussionen über Plattformen hinweg. So ist es im Web durchaus üblich, dass ein Thema von mehreren Blogautoren diskutiert wird, während sie immer wieder gegenseitig Bezug aufeinander nehmen.

Die Architektur von SIOC definiert zwei Typen von Diskussionsmedien:

- *Web-basierte Dienste:* Für diese kann ein SIOC Interface direkt bereitgestellt werden.
- *Andere Dienste wie E-Mail oder Newsgroups:* Für diese Medien müssen Wrapper implementiert werden, um die Daten SIOC-kompatibel anbieten zu können.

Die Daten werden gesammelt und in einem persistenten Speicher als RDF-Graph abgelegt. Dieser RDF-Graph kann anschließend Abfragen beantworten.

SIOC ermöglicht also das Integrieren verschiedener Medien zu einer ganzheitlichen Sicht auf ein Thema bzw. eine Diskussion. Eine Integration zwischen FOAF und SIOC ist ebenfalls vorgesehen: Die FOAF Dateien der Autoren einzelner Beiträge können mittels SIOC referenziert werden.

SIOC wird bereits heute von einer Reihe von Open Source Anwendungen sowie proprietären Anwendungen verwendet. In einem Interview [11] nennt SIOC-Projektinitiator John Breslin etwa das Produkt DataSpaces von OpenLink. DataSpaces ist eine verteilte Plattform, um über verschiedene Medien (Blogs, Wikis, Diskussionsforen, ...) kollaborativ arbeiten zu können. In OpenLink wird SIOC als Schicht zwischen den einzelnen Plattformen eingesetzt, um dem Benutzer einheitliche Abfragen zu ermöglichen. Neben OpenLink setzen u. a. auch Talis und Seismic auf SIOC¹¹.

Mashups und Web Services – Rekombination von Inhalten

Ein weiterer wichtiger Aspekt ist die Integration eines semantischen CMS im Dienste von Drittanbietern. Dazu kann ein CMS offene Schnittstellen z. B. in Form einer Web Service API anbieten. Drittanbieter können diese Dienste in ihre eigene Software integrieren, was auch als Mashup bezeich-

¹¹ <http://rdfs.org/sioc/applications/> (zuletzt zugegriffen am 1.2.2008)

net wird. Weitere beliebte Varianten, um Mashups erstellen zu können, sind REST Web Services oder JavaScript bzw. AJAX APIs. Von Mashups profitieren sowohl die Hersteller als auch die Nutzer: Nutzer können ihre eigene Software auf einfache Weise mit Funktionen aufwerten, die in anderen Realisierungsformen sowohl in der Anschaffung als auch in der Wartung zu kostspielig wären (z. B. eigene Beschaffung von Kartenmaterial vs. Integration von Google Maps). Der Hersteller behält die volle Kontrolle über seinen Dienst und kann gegebenenfalls auch kostenpflichtige Premiumpreismodelle einführen. Zum anderen erhöht sich der Markenwert aufgrund der weiteren Verbreitung.

Selbstadaptive Suche

Suchkomponenten gehören zu den wichtigsten Komponenten eines CMS: Wird ein wenig geeigneter Suchalgorithmus verwendet, so werden die relevanten Inhalte von den Benutzern nicht gefunden. Die Folge ist, dass entweder zu viel Zeit mit der Suche nach relevanten Informationen verbracht wird oder die Benutzer sich gar nicht erst die Mühe machen nach Inhalten zu suchen und das System umgehen. Die Akzeptanz eines CMS hängt also auch entscheidend von der Güte der Suchergebnisse ab.

Herkömmliche Suchverfahren betrachten Benutzer getrennt vom System: Benutzer spezifizieren eine Suchanfrage und erhalten anschließend ein Suchergebnis in Form einer Ergebnisliste o. ä. Darstellungen. Darüber hinaus interagieren Benutzer nicht mit der Suchkomponente.

Die Suchkomponente kann Benutzer aber auch in die Adaptierung der Relevanzbestimmung von Suchergebnissen einbeziehen. Dazu geht man davon aus, dass Benutzer immer das „relevanteste“ Ergebnis zu einer bestimmten Suchanfrage auswählen. Die Suchkomponente speichert, welches Suchergebnis bei welchen Suchanfragen den Benutzern am relevantesten erschien. Wenn genügend Daten vorliegen, kann die Suchkomponente das Ranking entsprechend dem Benutzerfeedback anpassen.

Das beschriebene Verfahren setzt wie einige weitere Techniken des Web 2.0 auf die kollektive Intelligenz der Benutzer. Das Verfahren ist auch robust gegen Manipulation, da „Ausreißer“ mit statistischen Methoden erkannt und eliminiert werden können. Mit einer Reihe weiterer Verfahren kann absichtlicher Missbrauch gezielt verringert werden. Strategien zur Vermeidung missbräuchlicher Verwendung spielen aber im Kontext der innerbetrieblichen Verwendung im Vergleich zum Internet eine untergeordnete Rolle. Verschiedene Suchmaschinen wie etwa Assista¹² nutzen bereits eine ähnliche Technik.

¹² <http://assista.com>, zuletzt zugegriffen am 1.2.2008

Recommender Systeme

Recommender Systeme können in semantischen CMS auf vielfältige Weise eingesetzt werden. Es können z. B. Dokumente vorgeschlagen werden. Bei der Abspeicherung von Dokumenten können mittels eines Tag Recommenders charakteristische Tags für ein Dokument vorgeschlagen werden.

Das wohl bekannteste Recommender System ist jenes von Amazon.com. Es schlägt Kunden basierend auf den begutachteten Artikeln ähnliche Artikel vor, die für sie interessant sein könnten. Die Technik, die hinter diesem System steckt, nennt sich kollaboratives Filtern.

Voraussetzung für das kollaborative Filtern ist eine eindeutige Zuordnungsmöglichkeit von Verhaltensmustern zu Benutzern. Von den Benutzern werden Nutzungsdaten gesammelt, bei Amazon.com z.B. welche Artikel angesehen oder in den Warenkorb gelegt wurden. Basierend auf einem Vergleich mit den Nutzungsdaten anderer Benutzer können so Vorschläge gemacht werden. Im Prinzip fasst das System also nur das Verhalten vieler anderer, ähnlicher Benutzer in Form eines Vorschlags für den aktuellen Benutzer zusammen.

Herkömmliche Recommender Systeme weisen eine Reihe von Schwächen auf:

- Es muss eine hohe Anzahl an Datensätzen vorhanden sein, sonst liefert das Recommender System gar keine oder zumindest keine verlässlichen Bewertungen (das so genannte „Cold Start“ Problem tritt auf). Dies betrifft sowohl neue Benutzer, über die bisher noch wenige Daten gesammelt wurden, als auch neue vorzuschlagende Objekte (Produkte, Dokumente, ...).
- Benutzer, die nicht in das Schema passen, erhalten keine sinnvollen Bewertungen.

Die Problematik bei herkömmlichen Recommender Systemen ist, dass diese die Semantik der vorzuschlagenden Objekte nicht kennen. Jedes Objekt wird als Black-Box betrachtet, die für sich ohne eigene Semantik ist. Erst im Kontext mit vielen anderen Objekten können Aussagen über ein bestimmtes Objekt gemacht werden.

Besonders das erstgenannte Problem kann mit semantischen Technologien signifikant verbessert werden, sodass ein neues Dokument schneller vorgeschlagen werden könnte. Angenommen ein neuer Kriminalroman eines bekannten Autors würde neu in einen Produktkatalog aufgenommen. Durch die Beziehung des Buchs zu einem bestimmten Autor sowie einem bestimmten Genre könnte dieses Buch auch ohne konkrete Daten Benutzern vorgeschlagen werden, die gerne Bücher von diesem Autor oder Kriminalromane lesen.

Zusammenfassung und Ausblick

Das immens schnelle Voranschreiten technologischer Entwicklungen fordert ein Umdenken in Hinsicht auf die Erstellung von Systemarchitekturen. Die Erfahrung zeigt, dass in vielen Organisationen veraltete und starre Systeme eingebunden sind, die lange nicht mehr aktuell sind und auch den Anforderungen nicht mehr gerecht werden. Eine Umstellung oder Neuanschaffung von Software ist oft mit erheblichen Ressourcen und hohem Zeitaufwand verbunden. Über den Ansatz der SOA wird versucht dieser Problematik entgegenzuwirken. Plattform- und Beschreibungssprachen-unabhängige Dienste bzw. Anwendungen können eingebunden, verändert und entfernt werden, ohne dabei die Gesamtarchitektur im Wesentlichen zu gefährden.

Wünschenswert wäre, dass sich bestehende CMS gegenüber semantischen Technologien öffnen, z.B. durch offene Schnittstellen, oder sich über komponentenorientierte Architektur flexibel gestalten.

Literatur

1. AIIM – The Enterprise Content Management Association
<http://www.aiim.org/about-ecm.asp>, [zugegriffen am 05.03.2008].
2. Tim Berners-Lee, James Hendler, and Ora Lassila, The Semantic Web, *Scientific American* 284 (2001), no. 5, 34–43.
3. Evaluation von Content Management Systemen, Im Auftrag des Bundesministeriums für Bildung, Wissenschaft und Kultur (bm:bwk), MR Dr. Robert Kristöfl, 2003, http://www.bildung.at/filedatabase/downloader.php?file_code=7c118969b830e22982ea612a23ac80fc&filedb_dir=bmbwk/dateidb/bildung2 [zugegriffen am 16.01.2008].
4. Dilnut, R.: Enterprise Content Management. Supporting knowledge management capability. *International Journal of Knowledge, Culture and Change Management*, 5(8, 2006)
5. Rod Dilnutt, Enterprise Content Management: Supporting Knowledge Management Capability, *International Journal of Knowledge, Culture and Change Management*, Volume 5, Issue 8, pp. 73–84, 2005.
6. Erich Gamma, Richard Helm, Ralph Johnson, und John Vlissides. *Design Patterns: Elements of Reusable Object-Oriented Software*. Addison Wesley, 2003.
7. T. R. Gruber. A translation approach to portable ontologies. *Knowledge Acquisition*, 5(2):199–220, 1993.
8. Kampffmeyer, U.: Enterprise Content Management – Zwischen Vision und Realität. In *contentmanager.de, das content management portal*, 2003 http://www.contentmanager.de/magazin/artikel_398-97_ecm_zwischen_vision_und_realitaet.html, [zugegriffen am 21.11.2007].

9. RDF Primer, W3C Recommendation 10 February 2004, Editors: Frank Manola, fmanola@acm.org, Eric Miller, W3C, em@w3.org, <http://www.w3.org/TR/rdf-primer/> [zugegriffen am 20.12.2007].
10. Clemens Szyperski. Component Software. Addison Wesley, 2002.
11. Willke, Helmut: Systemisches Wissensmanagement. Stuttgart: Lucius & Lucius, 1998.
12. Zaino, J.: SIOC-ing the Semantic Web, 2008, <http://www.semanticweb.com/insight/article.php/3721111> [zugegriffen am 1.2.2008].

12. Tag-Recommender gestützte Annotation von Web-Dokumenten

Andreas Blumauer und Martin Hochmeister

Semantic Web Company, Wien

{a.blumauer; m.hochmeister}@semantic-web.at

Zusammenfassung: In diesem Kapitel wird die zentrale Bedeutung der Annotation von Webdokumenten bzw. von Ressourcen in einem Semantischen Web diskutiert. Es wird auf aktuelle Methoden und Techniken in diesem Gebiet eingegangen, insbesondere wird das Phänomen „Social Tagging“ als zentrales Element eines „Social Semantic Webs“ beleuchtet. Weiters wird der Frage nachgegangen, welchen Mehrwert „Tag Recommender“ beim Annotationsvorgang bieten, sowohl aus Sicht des End-Users aber auch im Sinne eines kollaborativen Ontologieerstellungsprozesses. Schließlich wird ein Funktionsprinzip für einen semi-automatischen Tag-Recommender vorgestellt unter besonderer Berücksichtigung der Anwendbarkeit in einem Corporate Semantic Web.

Einleitung

Zu den häufigsten Einwänden an der Umsetzung der Idee des Semantic Web (oder an einem Web of Data), wie sie von Tim Berners-Lee gebetsmühlenartig immer wieder formuliert [2] wird, zählen folgende drei Punkte, die sich gegenseitig bedingen:

- Die Annotation von Web-Inhalten ist aufwändig und mühsam, End-User sind dabei überfordert und sehen diesen Vorgang als zeitraubenden Mehraufwand an.
- Das Annotieren von Web-Ressourcen¹ bedeutet auch, dass User persönliches Wissen preisgeben müssen. In unterschiedlichen Settings, z. B.

¹ Mit Web-Ressourcen sind neben „klassischen“ Webseiten auch andere Ressourcentypen gemeint, wie z. B. User, Bilder oder Videos, jeweils eindeutig identifizierbar durch eine URI. Ein Beispiel dafür ist die URI <http://www.semantic-web.at/people/blumauer/card#me>, die als Individual einer

innerhalb von Unternehmen, die oft hierarchisch organisiert sind, ist der User daher zögerlich, dieses Wissen zu teilen.

- Die Möglichkeiten, Dokumente mit semantischen Annotationen mit Hilfe von automatisierbaren Algorithmen anzureichern, sind unzulänglich und funktionieren nur eingeschränkt.

Diese drei möglichen Barrieren sprechen auch jene drei Ebenen an, die bei der Realisierung eines semantischen Webs stets als Gesamtheit berücksichtigt werden müssen [2]:

Anwendungsebene: Welche Rolle spielt der End-User im Semantic Web? Wie können User-Interaktionen so gestaltet werden, dass er einerseits möglichst von der „im Backend“ implementierten Semantik am Userinterface profitiert, und dass er andererseits als inhärent „bedeutungsverarbeitender Agent“ selbst das vorliegende Informationsnetzwerk um Semantik anreichern kann (u. U. vom User explizit gar nicht intendiert, z. B. auf Basis einer Analyse der häufigsten Suchanfragen)?

Organisationale Ebene: Die Bereitschaft von Millionen von Usern, die auf diversen Social Networking- und Social Bookmarking-Plattformen ohne große Bedenken „semantische Spuren“ im Sinne von sozialen Beziehungsgeflechten (Wer kennt wen? Wer weiß was?) und Social Tags hinterlassen, lässt jeden Wissensmanagement-Beauftragten zuversichtlich werden, dass sich diese Bereitschaft auch auf innerbetriebliche Verhältnisse ummünzen lassen könnte. Dieser Optimismus, gespeist von globalen Bewegungen, wie der Open Source Community [4] oder der Open Data Bewegung², ist in der Tat nicht ganz abwegig: Immer mehr Digital Natives [6], die mit großer Selbstverständlichkeit vernetzt kommunizieren, treffen auf jene tendenziell hierarchischen Strukturen, die von Digital Immigrants oder gar Netzverweigerern in den Jahren davor aufgebaut wurden. Wie diese beiden Denkart nun ineinander greifen werden, lässt sich nur vermuten – bekannter Weise sind aber hierarchisch strukturierte Taxonomien kein Widerspruch zu semantischen Netzen, sondern Teil dieser Struktur.

Infrastruktur/Technik: Das Semantic Web ist ein globales Projekt, um Transaktionskosten durch den Einsatz von syntaktischen und semantischen Übereinkünften (in Form so genannter „Ontologien“) zu reduzieren, die aufgrund der unverbindlichen Form der inhaltlichen Organisation im

foaf:Person konzipiert ist, basierend auf dem im Semantic Web gebräuchlichen FOAF- („friend-of-a-friend“) Schema.

² Siehe dazu: http://en.wikipedia.org/wiki/Open_data, zuletzt aufgerufen am 04.03.2008

bestehenden HTML-dominierten WWW im Zuge jeglicher Bedeutungsübertragung entstehen. Auf Basis von Standards, wie vom W3C im Resource Description Framework vorgeschlagen³, entstehen interoperable Strukturen, die die „Kosten der Re-Kontextualisierung als unabdingbarer Vorleistung von zielbezogenen Koordinationsvorgängen“ (siehe dazu [14]) reduzieren. Damit kompatible Basis-Technologien wurden in den letzten Jahren – in Europa auch im Zuge diverser von der Europäischen Union finanzierter Forschungsprojekte⁴ – prototypisch implementiert und aktuell in marktfähige Produkte umgesetzt. Als Beispiel für eine markttaugliche Technologie, die einerseits den Annotationsprozess auf Basis geeigneter automatischer Textextraktionsverfahren unterstützt und andererseits auf Standards wie RDF aufsetzt, sei Open Calais⁵ genannt, das von Reuters angeboten wird.

Tagging im Social Semantic Web

„Tagging“ bezeichnet den Vorgang der Annotation von Ressourcen im Social Web. Im Gegensatz zu Annotationen im Bibliothekswesen, wo es um eine kurze, sachliche inhaltliche Zusammenfassung eines Werkes geht, zeichnet sich das Tagging zunächst dadurch aus, dass es frei von jeglichen Vorgaben wie z. B. Kategoriensystemen vom User (und nicht vom Experten) durchgeführt werden kann. In Wu et al. [15] wird „Social Annotation“ und „Social Tagging“ synonym gebraucht und als besondere Form der Annotation wie folgt beschrieben:

„Compared to the formal annotations, although social annotations are coarse-grained, informal and vague, they are also more accessible to more people and better reflect the web resources’ meaning from the users’ point of views during their actual usage of the web resources“.

Die Grundidee jedes Annotationsvorganges ist es, eine Verbindung zwischen einer Ressource (z. B. einem Web-Dokument) und einer Annotation (oder eines „Tags“, wie diese im Social Web gerne bezeichnet werden) im Sinne eines Meta-Datums zu generieren, um somit anschließend z. B. Suchvorgänge effizienter ausführen zu können oder verwandte Dokumente schneller identifizieren zu können.

³ <http://www.w3.org/RDF/>, zuletzt aufgerufen am 06.03.2008

⁴ http://ec.europa.eu/research/fp6/index_en.cfm, zuletzt aufgerufen am 06.03.2008

⁵ <http://www.opencalais.com/>, zuletzt aufgerufen am 29.2.2008

Hierfür gibt es drei Möglichkeiten, abhängig von der Frage, welcher Agent diesen Vorgang ausführt:

Der End-User führt die Annotation durch: Systeme, bei denen die End-User in den Annotationsprozess eingebunden sind, repräsentieren die prototypische Variante für ein Social Tagging Portal. Dabei kann jeder User seine individuelle Sicht der Welt in das System einbringen und Tags grundsätzlich frei wählen. In großen Tagging-Portalen bleiben aufgrund des „Gesetzes der großen Zahlen“ „statistische Ausreißer“ nahezu ohne Wirkung, dieser Ansatz ist daher für Corporate Tagging nur bedingt sinnvoll [12]. End-User-generierte Annotationen können auch für andere User sichtbar sein, wie dies auf Social Tagging-Portalen üblich ist, oder sie dienen ausschließlich dem privaten Gebrauch, um z. B. Bookmarks schneller wieder zu finden.

Ein Experte führt die Annotation durch: In dieser oft kostspieligen Variante greift der (z. B. vom Portalbetreiber beauftragte) Experte während der Annotation auf ein existierendes kontrolliertes Vokabular (in Form einer Taxonomie, eines Thesaurus oder einer Ontologie) zurück. Das „freie Taggen“ tritt hier in den Hintergrund zurück. Es wird versucht, Inkonsistenzen bei der Annotation zu vermeiden oder Mehrfachschreibweisen bzw. Rechtschreibfehler systematisch zu unterdrücken. Durch den Einsatz geeigneter Tag-Recommender kann der End-User selbst in die Rolle des Experten schlüpfen, wie an anderer Stelle in diesem Beitrag dargestellt wird.

Die Annotation erfolgt automatisiert: Die offensichtlich wünschenswerteste Variante zur Annotation von Textinhalten (und in weiterer Folge auch von anderen Medientypen wie Bildern oder Videos) ist die automatisierbare. Verfahren zur Extraktion von Stichworten, Schlagworten oder Schlüsselphrasen bedienen sich statistischer und computer-linguistischer Verfahren und stammen aus dem Umfeld der automatischen Sprachverarbeitung und der Künstlichen Intelligenz. Zu unterscheiden ist also zwischen Verfahren, die unabhängig von der zu erschließenden Wissensdomäne funktionieren (empirische Ansätze), und solchen, die grundsätzlich auf Fachthesauri, Listen von Eigennamen oder Gazetteers aufbauen (strukturalistische Ansätze).

Diese drei Ansätze können auch miteinander kombiniert werden, so kann z. B. die automatische Textextraktion Vorschläge unterbreiten, die dann vom End-User oder vom Experten bestätigt oder verworfen werden können. Abhängig von den Qualitätsansprüchen an das System, vom Umfang der Dokumente und nicht zuletzt vom Projektbudget, kann man sich für eine geeignete Systemkonfiguration entscheiden.

Welch hohen Stellenwert Taxonomien oder andere kontrollierte Vokabulare als Basis für jedes Tagging-System haben, wird in Lambe [11] wie folgt beschrieben:

„Building a taxonomy is more a journey of discovery than a piece of analysis. The Babel Instinct requires that a successful taxonomist be more a diplomat than a scientist. In a knowledge management context, pragmatism will always trump tidiness, and the connection with organisational effectiveness must never be lost. This is why the people we assume might make good taxonomy ‚specialists‘ (records managers, librarians, information scientists) may not necessarily be the best equipped to develop your taxonomy for you – unless they understand what drives your organisation’s performance and effectiveness.“

Annotationen drücken also typischerweise den Themenbereich aus, mit dem die Ressource zu tun hat, können aber auch andere Dimensionen einer Ressource ansprechen: Nach Golder & Hubermann [5] können Tags in 7 verschiedene Kategorien eingeteilt werden, die u. a. die Möglichkeit vorsehen, die Ressourcenart (Blog, Buch, ...) zu beschreiben oder vielmehr den Bezug, den der User zur Ressource hat, als die Ressource selbst, z. B. persönliche Meinungen („großartig“, „langweilig“, „informativ“).

Annotationen bzw. Tags können nach Reif [13] auf folgende drei Arten gespeichert werden:

1. Die Annotationen werden in das Dokument eingebettet.
2. Das Dokument verweist auf ein externes Dokument mit den Annotationen.
3. Die Annotationen verweisen auf das annotierte Dokument; das Dokument selbst enthält keine Hinweise auf Annotationen.

Handelt es sich bei der Trägerinformation um ein (X)HTML-Dokument, so steht für die Realisierung der ersten Variante neben den weniger flexiblen Mikroformaten⁶ das vom W3C vorgeschlagene RDFa als Technologie zur Verfügung⁷. Bei dieser Variante genießt man den Vorteil, dass die Annotation *innerhalb* des Dokuments erfolgt, also auch Aussagen über einzelne Textpassagen erlaubt.⁸ Will man allerdings Aussagen treffen, die

⁶ <http://microformats.org/>, zuletzt aufgerufen am 29.02.2008

⁷ Ein Beispiel für ein XHTML/RDFa Dokument ist <http://www.ivan-herman.net/foaf.html>, in dem der W3C Mitarbeiter Dr. Ivan Herman sein persönliches Profil sowohl als für Menschen lesbares Dokument (XHTML), als auch für Maschinen verarbeitbar (RDFa) aufbereitet hat. Mit Hilfe z. B. des RDFa Extractors von Elias Torres (<http://torrez.us/rdfa/>) kann dieses Dokument nun in ein RDF-Dokument übersetzt und via SPARQL abgefragt werden.

⁸ Siehe dazu den Beitrag von Michael Hausenblas in diesem Band.

sich generell auf das gesamte Dokument beziehen, so bieten sich neben RDFa auch „klassische“ Vorgehensweisen an, z. B. durch das Verknüpfen des Basis-Dokuments mit einem Metadaten-Dokument mittels `<link>` Element im `<head>` der Web-Seite, oder durch das Einbetten von RDF/XML im `<head>` der Web-Seite.

Liegt die Information nicht als HTML-Dokument vor, sondern z. B. im OpenOffice Format, so bietet in diesem Fall das RDF Metadata Model für OpenDocument Format (ODF)⁹ entsprechende Möglichkeiten an, Annotationen und Metadaten in Office Dokumente einzubetten.

Auch Semantic Wiki Systeme, wie z. B. das Semantic MediaWiki (SMW)¹⁰, verfolgen das Ziel, semantische Annotationen im Dokument einzubetten. Wie Krötzsch und Vrandečić in ihrem Beitrag „Semantic Wikipedia“ in diesem Band erläutern, werden Strukturierungsmöglichkeiten des „klassischen“ MediaWikis (insbesondere das Kategoriensystem) um zahlreiche Möglichkeiten erweitert, u. a. um die Bedeutung von Hyperlinks zwischen den Wiki-Seiten durch Attribute festzulegen.

Grundlegende Prinzipien des Social Taggings am Beispiel „del.icio.us“

del.icio.us¹¹ gehört neben Digg¹² und StumbleUpon¹³ zu den populärsten Social Tagging Portalen im Web. Ende 2005 wurde del.icio.us von Yahoo! übernommen¹⁴ und Ende 2007 wurden Tagging-Informationen daraus auch in die Yahoo! Suche integriert¹⁵.

Mittels del.icio.us kann jeder User mit geringem Aufwand Web-Ressourcen bookmarken, taggen und kommentieren. Diese Form des „Micro-Publishings“ nutzen regelmäßig (Stand: Februar 2008) über 3 Millionen User, die insgesamt bereits über 100 Millionen verschiedene Ressourcen annotiert bzw. kommentiert haben.

⁹ Siehe <http://www.slideshare.net/jza/the-openofficeorg-odf-toolkit-project>, zuletzt aufgerufen am 29.02.2008

¹⁰ <http://semantic-mediawiki.org/>, zuletzt aufgerufen am 02.03.2008

¹¹ Siehe <http://del.icio.us/>, zuletzt aufgerufen am 29.02.2008

¹² Siehe <http://digg.com>, zuletzt aufgerufen am 29.02.2008

¹³ Siehe <http://www.stumbleupon.com/>, zuletzt aufgerufen am 29.02.2008

¹⁴ Siehe <http://ablvienna.wordpress.com/2007/06/09/why-yahoo-bought-delicious/>, zuletzt aufgerufen am 04.03.2008

¹⁵ Siehe <http://searchengineland.com/080121-095345.php>, zuletzt aufgerufen am 29.02.2008

Der Annotations-Vorgang ist denkbar einfach: Hat man einmal einen User-Account angelegt, sich eingeloggt (und üblicherweise entscheidet man sich dazu, permanent eingeloggt zu bleiben) und das entsprechende Bookmarklet in den Browser integriert, so kann man durch einen einfachen Klick auf das Bookmarklet, durch das Auswählen geeigneter Tags und – optional – durch das Hinzufügen eines kurzen Kommentars jede Website (bzw. jede Ressource, die über eine URI mit dem Browser ansteuerbar ist) in die persönliche Liste der favorisierten Links aufnehmen und gleichzeitig auch allen anderen Usern der Community empfehlen. Damit entsteht in Summe ein Netzwerk von folgenden Aussage-Typen (die als RDF-Triples repräsentiert werden können):

1. User taggt Web-Ressource
2. User verwendet Tag
3. Tag beschreibt Web-Ressource

Diese Aussagen können zu einem „Tag-Event“ zusammengefasst werden. Jedes Tag-Event besteht also zumindest aus diesen drei Triples, werden mehrere Tags in einem Tag-Event vergeben, so werden auch entsprechend mehr Aussagen generiert.

Als konkreter Fall zur Veranschaulichung soll folgendes Tag-Event dienen: User *ABLVienna* (mit der URI <http://del.icio.us/ABLVienna> ruft in seinem Browser die Website <http://social.semantic-web.at/> auf und taggt diese mit den Tags *semanticwiki*, *social_software* und *social_semantic_web* (wobei del.icio.us für jeden Tag eine eigene URI nach dem Muster http://del.icio.us/tag/name_des_tags bzw. für jede getaggte Ressource ebenfalls eine eigene URI anlegt, nämlich als interne Hash-URI nach dem Muster http://del.icio.us/url/interne_hash_uri¹⁶). Es wird also folgendes Tag-Event generiert:




Abb. 1. Struktur eines Tag-Events

¹⁶ Für <http://social.semantic-web.at/> hat del.icio.us z. B. die URI <http://del.icio.us/url/e938ce440a54ef90db5bca61ad31623c> angelegt.

Tag-Events verknüpfen also Web-Ressourcen mit Themen bzw. Tags und diese wiederum mit Usern (Für jedes Tag-Event können darüber hinaus weitere Informationen, wie z. B. ein Timestamp, abgelegt werden, um z. B. Trends im Tagging-System erkennen zu können). Ein formales Modell der so entstehenden „Folksonomy“¹⁷, das User, getaggte Ressource und Tags (und nicht, wie fälschlicherweise oft angenommen wird, die Tags allein) in Beziehung setzt, wird von Jäschke et al. [10] vorgeschlagen.

Um nun das generelle Konzept „TagEvent“, das in allen Social Tagging Plattformen zum Einsatz kommt, in den Systemen jedoch auf unterschiedliche Weise repräsentiert wird bzw. abgefragt werden kann, auch Plattform-übergreifend einsetzen und vernetzen zu können, wurde SCOT¹⁸, ein RDF-Schema, mit dem Tag-Events und Folksonomies ausgedrückt werden können, entwickelt. SCOT baut selbst wiederum auf bestehende Semantic Web Ontologien wie FOAF¹⁹ oder SKOS²⁰ auf.

Bei Portalen, die eine große Anzahl von Tag-Events verwalten, kann es nun sinnvoll sein, folgende Abfragen durchzuführen:

Häufigkeiten²¹:

1. Zeige zu jeder Ressource an, mit welchen Tags diese beschrieben wird und wie häufig dies jeweils der Fall ist.
2. Zeige für jeden User an, welche Tags dieser verwendet und wie häufig dies jeweils geschieht.
3. Zeige für jeden Tag an, wie häufig dieser insgesamt im System verwendet wird.

Relationen und Ähnlichkeiten:

1. Zeige alle Ressourcen an, die mit einem oder mehreren bestimmten Tags versehen sind.
2. Zeige alle Ressourcen an, die von einem oder mehreren bestimmten Usern getaggt sind.

¹⁷ Der Begriff „Folksonomy“ wurde von Thomas Vander Wal von der Firma Infocloud Solutions (<http://infocloudsolutions.com/>) geprägt und beschreibt das Resultat freien Taggings von Ressourcen zum Zwecke des Wiederauffindens. Eine Folksonomy entsteht, wenn Personen zu einem System zusammengefasst werden, in dem die Ressourcen und die von den Personen zugewiesenen Tags offen zugänglich sind.

¹⁸ <http://www.scot-project.org>, zuletzt aufgerufen am 02.03.2008

¹⁹ <http://www.foaf-project.org>, zuletzt aufgerufen am 04.03.2008

²⁰ <http://www.w3.org/2004/02/skos/>, zuletzt aufgerufen am 04.03.2008

²¹ Tag-Häufigkeiten werden oft als TagClouds in einer intuitiv verständlichen Form visualisiert. Sie ermöglichen einen schnellen Überblick über die Interessenslagen eines Users oder generell über den Inhalt einer Web-Ressource.

3. Zeige alle User an, die eine oder mehrere bestimmte Ressourcen taggen.
4. Zeige alle User an, die eine oder mehrere bestimmte Tags (häufig) verwenden.
5. Zeige alle Tags an, die häufig gemeinsam mit einem anderen bestimmten Tag während eines Tag-Events verwendet wurden.
6. Zeige alle Tags an, die bereits von anderen Usern für eine bestimmte Ressource vergeben wurden.

Mit 4. und 5. können zu einer gegebenen Ressource (und dem über ihre Tag-Cloud ableitbaren Termvektor) ähnliche Ressourcen ermittelt werden (z. B. unter Einsatz von Vektorraummodellen²²). Mit 6. und 7. lassen sich dann sinngemäß für eine spezielle Art von Ressource, nämlich für einen User, ähnliche andere User herausfiltern.

Mit 8. lassen sich u. a. Tagcluster berechnen, wie dies z. B. von der Online-Fotoplattform Flickr²³ eingesetzt wird: Unter dem URI-Muster http://www.flickr.com/photos/tags/tag_name/clusters werden für einen bestimmten Tag „tag_name“ Cluster berechnet, die sich u. a. aufgrund von Ko-Okkurenzen ergeben [1].

Abfragen, wie unter 9. beschrieben, werden von del.icio.us dazu eingesetzt, um Vorschläge für geeignete Tags zu machen. Diese Form und weiter fortgeschrittene Varianten eines Tag-Recommenders werden im folgenden Abschnitt ausführlich behandelt.

Im Beitrag von Hotho et al. über Social Bookmarking wird in diesem Band der FolkRank-Algorithmus [9] angesprochen, der es erlaubt, ähnlich wie Google's PageRank-Algorithmus [3], der Rankings auf Knoten mit der Idee berechnet, dass ein Knoten dann wichtig ist, wenn viele andere wichtige Knoten auf diesen zeigen, die Relevanz von Usern, Tags oder Ressourcen in einer Folksonomy zu berechnen. Eine Ressource ist umso wichtiger, je häufiger sie mit wichtigen Tags oder Benutzern verbunden ist. Dasselbe Prinzip gilt symmetrisch auch für Tags und Benutzer.

Tag-Recommender in der Praxis

Ein Hauptargument für den Einsatz von Tag-Recommendern in Tagging-Systemen liegt auf der Hand: Die Bereitschaft der User, Tags zu vergeben, ist deutlich höher, wenn die User beim Tagging-Vorgang mit sinnvollen Vorschlägen versorgt werden.

²² Siehe dazu http://en.wikipedia.org/wiki/Vector_space_model, zuletzt aufgerufen am 01.03.2008

²³ Siehe dazu <http://www.flickr.com>, zuletzt aufgerufen am 01.03.2008

Beispiel 1: Tag-Recommender von del.icio.us

Möchte ein User bei del.icio.us eine Web-Ressource bookmarken und taggen, so werden vom System mögliche sinnvolle Tags vorgeschlagen: Es werden dabei jene Tags zur Auswahl angezeigt, die bereits von anderen Usern für diese Ressource vergeben wurden.

Diese Art von Tag-Recommender, der auf dem Prinzip des „Collaborative Filtering“ [16] basiert, ist jedoch nur dann geeignet, wenn davon ausgegangen werden kann, dass eine verhältnismäßig große Anzahl von Usern das System nutzt, also mit hoher Wahrscheinlichkeit eine Ressource auch mehrmals getaggt wird. Gerade beim Corporate Tagging ist diese Voraussetzung, auch in großen Unternehmen, aber oft nicht gegeben. Ein Nachteil dieses Verfahrens besteht außerdem darin, dass es schnell zu „Trampelpfaden“ kommt, d. h. Tags, die bereits häufig von anderen Usern für eine Ressource verwendet wurden, werden erst recht wieder vom nächsten User verwendet.

Dennoch hilft bereits diese Variante eines Tag-Recommenders dabei, Rechtschreibfehler bei der Vergabe von Tags bzw. Mehrfachschreibweisen tendenziell zu unterbinden.

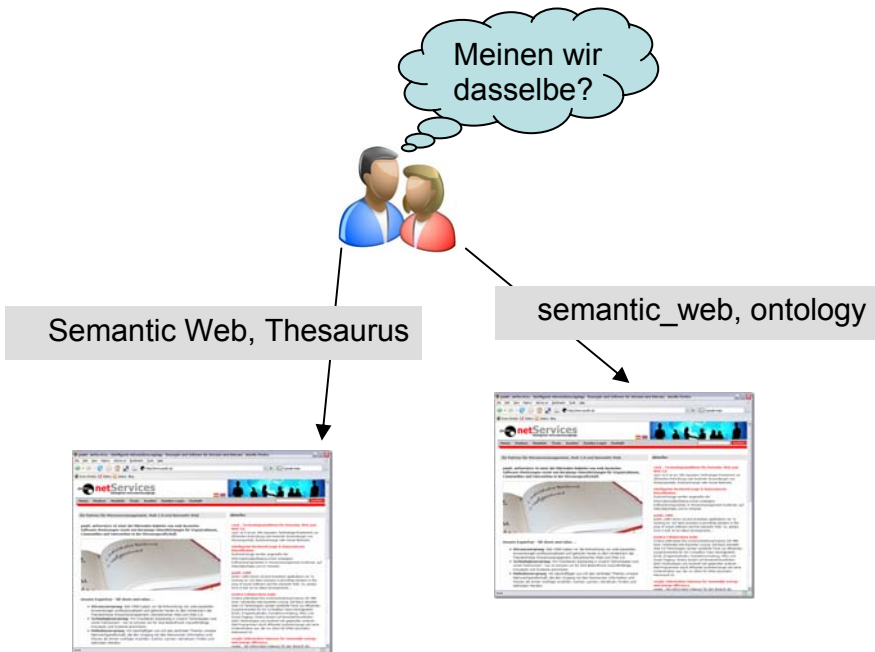


Abb. 2. Das Problem des freien Taggens

Das generelle Problem von Tag-Recommendern nach der Bauart „del.icio.us“ besteht jedoch darin, dass bei der freien Vergabe von Tags unterschiedliche Schreibweisen entstehen können. Vergibt der eine User den Tag „semantic web“, ein anderer User den Tag „semantic_web“ und wieder ein anderer „Semantisches Web“ für ein und dieselbe Ressource, so kann das System später keinerlei Beziehung zwischen den vergebenen Tags herstellen, obwohl sich alle User wahrscheinlich auf dasselbe Konzept beziehen, nämlich auf http://dbpedia.org/resource/Semantic_Web.

Ein Ausweg aus dieser Misere könnte also entweder ein Ontologie-gestützter Tag-Recommender sein, wie weiter unten ausgeführt, oder eine umfassende Auto-Complete Funktion bei der Eingabe von User-Tags.

Beispiel 2: Tag-Recommender von xing.com

Xing²⁴ gehört mit über 4,5 Millionen registrierten Usern (Stand: Anfang 2008) zu den größten Social-Networking Plattformen im Business-Segment. Seit Mai 2007 betreibt das Portal einen „Marketplace“, auf dem freie Jobs angeboten und gesucht werden können.

Veröffentlicht der User nun eine neue Jobausschreibung, so kann er diese mit Schlagworten versehen, um schließlich ein besseres Matchmaking zwischen „Angebot“ und „Nachfrage“ zu ermöglichen. Dieser Vergleich zwischen den Profilen wird nun erheblich effizienter, da das System von Xing den User bei der Eingabe durch eine ausgetüftelte Auto-Complete Funktion unterstützt, zum Beispiel: Bei der Eingabe von „sq“ werden folgende Tag-Vorschläge gemacht: „sql“, „softwareentwicklung“, „entwickler“, „java“ etc. Es werden also nicht nur Tags vorgeschlagen, die aufgrund der ersten beiden Buchstaben „sq“ noch passen könnten, also „sql“, sondern es werden Wahrscheinlichkeiten ermittelt, womit der Job zu tun haben könnte, und davon abhängig werden verbundene Begriffe angezeigt. Wählt man nun z.B. „java“ als ersten Tag aus, so hat dies auch direkten Einfluss auf die Tag-Vorschläge bei der Eingabe weiterer Begriffe. Der Tag-Recommender verbessert also laufend sein „Verständnis“, worum es sich beim jeweiligen Jobprofil dreht.

Trotz der offensichtlichen Vorteile, die diese Variante bereits gegenüber Beispiel 1 hat, ließen sich erhebliche Effizienzvorteile erzielen, würde man den Tag-Recommender mit folgenden Zusatzmerkmalen ausstatten:

²⁴ <http://www.xing.com>, zuletzt aufgerufen am 02.03.2008

1. Der Tag-Recommender schlägt Tags vor, die sich aus der detaillierten Beschreibung der Stelle ableiten lassen z. B. mit Hilfe automatischer Phrasenextraktion.
2. Der Tag-Recommender kann semantische Beziehungen zwischen zwei Tags interpretieren, die entweder synonym für dasselbe Konzept gebraucht werden können oder die zwei unterschiedliche Konzepte bezeichnen, die zueinander in einer Ober- bzw. Unterbegriffsrelation stehen oder als verwandt eingestuft werden können.

Im folgenden Abschnitt wird das Funktionsprinzip eines Ontologie-gestützten Tag-Recommenders vorgestellt, der diese Merkmale aufweist, ergänzt um Einsatzszenarien, die auf dieser Basis umgesetzt werden können.

Beispiel 3: Ontologie-gestützte Tag-Recommender

In dieser fortgeschrittenen Bauart eines Tag-Recommenders tragen jene drei Typen von möglichen Agenten (End-User, Experte, Computer), die ein Tag-Event auslösen können (wie in Kap. 2 dieses Beitrags beschrieben), auf unterschiedliche Art und Weise dazu bei, dass folgende Kriterien vom Tagging-System erfüllt werden können:

1. Tags können zwar von End-Usern nach wie vor frei vergeben werden, können aber dennoch an ein kontrolliertes Vokabular (typischerweise in Form eines Thesaurus, z. B. mittels SKOS repräsentiert) rückgebunden werden.
2. End-User werden während des Tag-Events mit umfassenden Vorschlägen für passende Tags unterstützt, die auch von der Information, die in unstrukturierten Texten vorliegen kann, abgeleitet werden können; End-User profitieren dabei in höchstem Maße von den zugrunde liegenden semantischen Strukturen, ohne diese kennen oder gar warten zu müssen.
3. Der zugrunde liegende Thesaurus kann laufend mit neuen Begriffen, die im täglichen Sprachgebrauch von End-Usern verwendet werden, angereichert werden.
4. Der Thesaurus bleibt dennoch wohlstrukturiert und konsistent, da das Thesaurus-Management von einem Experten wahrgenommen wird.

Folgende Abbildung soll das Prinzip eines Ontologie-gestützten Tag-Recommenders veranschaulichen:

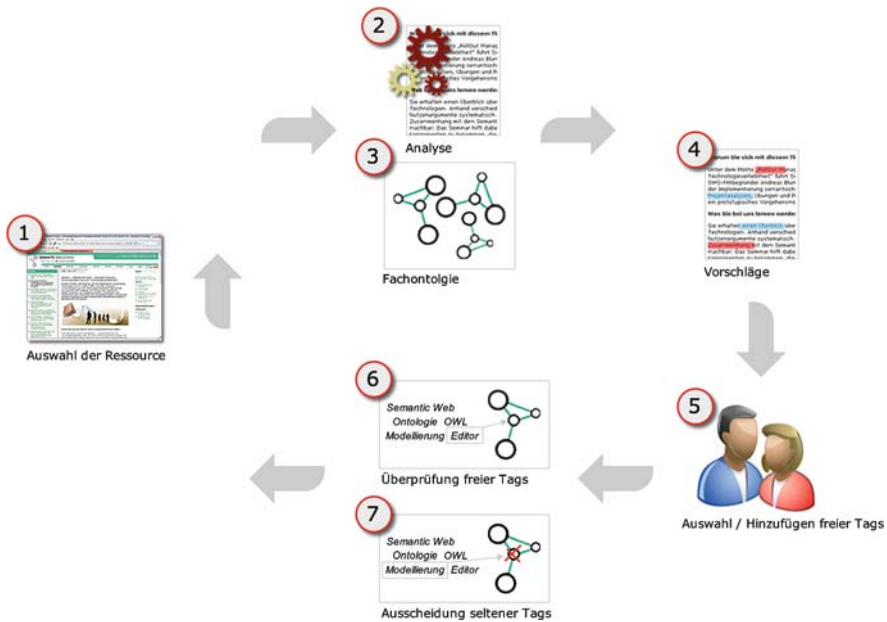


Abb. 3. Funktionsprinzip eines Ontologie-gestützten Tag-Recommenders

Schritt 1 und 2:

Der User übergibt die zu taggende Ressource (Webseite, Office-Dokument etc.) an die Analyse-Komponente des Tag-Recommendors. Mit Hilfe geeigneter statistischer Methoden, z. B. der tf-idf-Maßzahl²⁵, können jene Begriffe im Dokument automatisch extrahiert werden, die mit hoher Wahrscheinlichkeit für den jeweiligen Text von großer Bedeutung sind. Einige Web-Services, die dafür herangezogen werden können, bzw. Möglichkeiten, das Textdokument für diesen Schritt mit geeigneten Verfahren des Natural Language Processings (NLP) vorzubereiten, sind bei Horak [8] angeführt. Eine weitere attraktive Möglichkeit, diesen Schritt zu implementieren, bietet das Text-Extraktionsservice „Open Calais“, wie in der Einleitung dieses Beitrags bereits angeführt²⁶.

²⁵ tf-idf ist die Abkürzung für Termfrequency/Inverse Document Frequency, siehe dazu: <http://en.wikipedia.org/wiki/TFIDF>, zuletzt aufgerufen am 04.03.2008

²⁶ Beispielanwendungen dazu sind unter <http://labs.punkt.at/>, zuletzt aufgerufen am 04.03.2008, zu finden.

Schritt 3 und 4:

Die extrahierten Terme und Phrasen werden nun mit dem Fachthesaurus verglichen und darin existierende Begriffe (bevorzugt) für das Tagging vorgeschlagen.

Schritt 5:

Die End-User (oder in anderen Settings z. B. die Online-Redakteure) wählen nun aus den vorgeschlagenen Tags jene aus, die als zutreffend eingestuft werden, und können darüber hinaus auch eigene, neue Tags vergeben.

Schritt 6 und 7:

Neue von den End-Usern vergebene Tags werden vom Experten bzw. Thesaurus-Manager in das bestehende kontrollierte Vokabular eingefügt. Konzepte, die selten oder gar nicht von Usern beim Taggen verwendet werden, können u. U. aus der Ontologie ausgeschieden werden.

Tagging-Systeme, die den hier beschriebenen Tag-Recommender einsetzen, können folgende Anwendungen unterstützen:

- 1. Moderierte Suche:** Das System bildet die Basis für eine moderierte Suche²⁷. Dabei werden dem Anwender für die jeweils eingegebenen Suchbegriffe verwandte Begriffe aus dem Thesaurus vorgeschlagen, um die Suchanfrage weiter zu verfeinern.
- 2. Suchoptimierung:** Such-Services, die auf dieses System aufsetzen, liefern gute Recall-Werte²⁸, da Begriffe aus dem Thesaurus häufig aus den indizierten Dokumenten stammen, die selbst wiederum häufig die Quelle für einen Tag bzw. einen Begriff aus dem Thesaurus darstellen.
- 3. Ähnlichkeitssuche:** Die Suche nach ähnlichen Dokumenten wird beim Einsatz eines Ontologie-gestützten Recommender-Systems in vielen Fällen effektiver erfolgen, als auf Grundlage vollautomatischer Verfahren der semantischen Indizierung bzw. im Rahmen eines Social Tagging-Systems.
- 4. Trend Scouting:** Die Erkennung von Trends innerhalb eines Unternehmens lässt sich über das Tagging-Verhalten der User ablesen.

²⁷ Ein Beispiel für die Implementierung einer moderierten Suche ist unter <http://www.reegle.info>, zuletzt aufgerufen am 04.03.2008, zu finden.

²⁸ Siehe dazu http://de.wikipedia.org/wiki/Recall_und_Precision, zuletzt aufgerufen am 04.03.2008

5. Dynamisches Skill-Management: Wie bei Hochmeister [7] ausführlich beschrieben, lassen sich Tag-Clouds auch als Skill-Profil eines Mitarbeiters interpretieren. Dies bietet die Grundlage für den Einsatz eines Tagging-Systems zur Erfassung von Qualifikationen und Kompetenzen eines Mitarbeiters.

Fazit und Ausblick

Tag-Clouds everywhere! Noch vor wenigen Jahren war es nahezu undenkbar, dass Millionen von Webseiten ein in seiner Grundfunktion fast standardisiertes, zentrales Navigationselement anbieten werden: Tag-Clouds, die thematische Einstiegspunkte für jedes Web-Informationssystem in einer intuitiv begreifbaren Visualisierungsform anbieten.

Neben streng hierarchischen Navigationsbäumen, unter denen sich Inhalte, die oft wenige Links zu anderen Bereichen einer Website aufweisen, und dem „klassischen“ Suchfeld ist also ein drittes Paradigma hinzugetreten, wie man an die gewünschte Information herankommen kann.

Bei aller Web 2.0-Euphorie, die bis Ende 2007 den Diskurs über die fortlaufende Web-Evolution geprägt hat, wurde jedoch zuwenig darüber nachgedacht, welche Voraussetzungen ein Tagging-System haben muss, um auch erfolgreich in anderen Umgebungen als in den bekannten, äußerst frequentierten Web 2.0-Portalen eingesetzt werden zu können.

Als Anfang 2008 Reuters mit der Veröffentlichung ihres äußerst effizienten automatischen Annotationsservices „Open Calais“ zunächst in Entwickler-Communities und in der Presse für Furore sorgte, schien auch kurzfristig die Sinnhaftigkeit der manuellen Verschlagwortung in Frage gestellt.

Obwohl nun technische Entwicklungen, Methoden und Denkweisen bzw. Ziele, die das Social Web prägen, immer mehr mit jenen, die das Semantic Web auszeichnen, verschmelzen, kann letztlich mit großer Klarheit festgestellt werden: Die Grundprinzipien des Social Web haben den Web-User neu definiert und damit ein großes, produktives Chaos produziert, das nun mittels Semantic Web-Technologien in ein „Web of Data“ transformiert wird. Semantisch gestützte Tag-Recommender spielen in dieser Architektur eine zentrale Rolle.

Literatur

1. Begelman, G., Keller, P., Smadja, F. (2006). In: Proceedings of WWW2006, Collaborative Web Tagging Workshop. Online verfügbar unter http://www.pui.ch/phred/automated_tag_clustering/automated_tag_clustering.pdf, zuletzt aufgerufen am 06.03.08
2. Berners-Lee, T. (2007). Testimony of Sir Timothy Berners-Lee, CSAIL Decentralized Information Group, Massachusetts Institute of Technology, Before the United States House of Representatives Committee on Energy and Commerce, Online verfügbar unter <http://dig.csail.mit.edu/2007/03/01-ushouse-future-of-the-web.html>, zuletzt aufgerufen am 04.03.2008
3. Blumauer, A., Pellegrini, T. (2006). Semantic Web und semantische Technologien: Zentrale Begriffe und Unterscheidungen, In: Pellegrini/Blumauer (eds.): Semantic. Web: Wege zur vernetzten Wissensgesellschaft. Reihe X.media.press, Springer, Berlin
4. Brin, S., Page, L. (1998). The Anatomy of a Large-Scale Hypertextual Web Search Engine. *Computer Networks and ISDN Systems* 30(1–7):107–117
5. Brügge, B., Harhoff, D., Picot, A. (2007). Open -Source -Software. Eine ökonomische und technische Analyse. Springer, Berlin
6. Golder, Scott A., Hubermann, Bernardo A. (2005). The Structure of Collaborative Tagging Systems, Online verfügbar unter <http://arxiv.org/abs/cs.DL/0508082>, zuletzt aufgerufen am 04.03.2008
7. Günther, J. (2007). Digital Natives & Digital Immigrants. Studienverlag
8. Hochmeister, M. (2008). Aspekte für den Entwurf eines dynamischen Skill-Management-Systems zur computergestützten Konfiguration von Teams auf Basis semantischer Technologien, Masterarbeit, Fachhochschule Technikum Wien
9. Horak, B. (2006). ConTag – A Tagging System Linking the Semantic Desktop with Web 2.0, Diplomarbeit, University of Kaiserslautern Department of Computer Science, Online verfügbar unter <http://www.dfki.uni-kl.de/~horak/mypubs/ConTag.pdf>, zuletzt aufgerufen am 04.03.08
10. Jäschke, R., Leandro, Balby M., Hotho, A., Schmidt-Thieme, L., Stumme, G. (2007). Tag recommendations in folksonomies. In: Joost, K., Koronacki, J., López de Mántaras, R., Matwin, S., Mladenic, D., Skowron, A. (Editors). *Knowledge Discovery in Databases: PKDD 2007*, 11th European Conference on Principles and Practice of Knowledge Discovery in Databases, volume 4702 of Lecture Notes in Computer Science, pages 506–514, Springer, Berlin, Heidelberg
11. Jäschke, R., Marinho, L., Hotho, A., Schmidt-Thieme, L., Stumme, G. (2007). Tag Recommendations in Folksonomies, in: Hinneburg, A. (Hrsg.): *Workshop Proceedings of Lernen – Wissensentdeckung – Adaptivität (LWA 2007)*, Martin-Luther-Universität Halle-Wittenberg, September 2007, S. 13–20, Online verfügbar unter: http://www.kde.cs.uni-kassel.de/hotho/pub/2007/kdml_recommender_final.pdf, zuletzt aufgerufen am 16.02.2008
12. Lambe, P. (2007). *Organising Knowledge: Taxonomies, Knowledge and Organisational Effectiveness*. Chandos Publishing, Oxford

13. Ramamoorthy, A. (2007). Corporate ‚Tagging‘ For Information Management through Work Place Democracy, Online verfügbar unter URL: http://msalliance.satyam.com/MSAlliance%20-CaseStudy_PDF/CorporateTagging.pdf [16.02.2008]
14. Reif, G. (2006). Semantische Annotation, In: Pellegrini/Blumauer (eds.): Semantic. Web: Wege zur vernetzten Wissensgesellschaft. Reihe X.media.press, Springer, Berlin
15. Weber, M., Fröschl, K. (2006). Das Semantic Web als Innovation in der ökonomischen Koordination, In: Pellegrini/Blumauer (eds.): Semantic. Web: Wege zur vernetzten Wissensgesellschaft. Reihe X.media.press, Springer, Berlin
16. Wu X., Zhang L., Wu Y. (2006). Exploring social annotations for the semantic web. In: World Wide Web Conference 2006. S. 417–426.
17. Xu, Z. et al. (2006). Towards the Semantic Web: Collaborative Tag Suggestions. WWW2006, May 22–26, 2006, Edinburgh, UK. Online verfügbar unter <http://www.rawsugar.com/www2006/13.pdf>, zuletzt aufgerufen am 04.03.2008

13. Semantische Wikis

Sebastian Schaffert¹, François Bry², Joachim Baumeister³ und Malte Kiesel⁴

¹ Salzburg Research Forschungsgesellschaft, Salzburg, Österreich;
sebastian.schaffert@salzburgresearch.at

² Institut für Informatik, Ludwig-Maximilians-Universität München, bry@ifi.lmu.de

³ Institut für Informatik, Universität Würzburg, joba@uni-wuerzburg.de

⁴ DFKI GmbH, malte.kiesel@dfki.de

Zusammenfassung: Das Thema „Semantic Wikis“ als Verknüpfung von Wiki-Konzepten mit semantischen Technologien gewinnt in den letzten Jahren zunehmend an Bedeutung, weil es „soziale Intelligenz“ und „künstliche Intelligenz“ miteinander verknüpft. Ziel des Artikels ist es, einen Überblick über das Thema Semantic Wikis zu schaffen. Wir gehen dabei insbesondere auch auf Anwendungsfelder ein und geben einen kurzen Vergleich ausgewählter Systeme.

Wiki und Semantic Wiki

Ein *Wiki* [1] ist ein Web-basiertes System, das das kollaborative Verfassen und Aktualisieren von Webseiten ermöglicht. Die wichtigsten Eigenschaften eines Wikis sind die *Offenheit*, welche es jedem Benutzer erlaubt, an der Erstellung von Inhalten teilzunehmen, und die *Flexibilität* bezüglich der unterschiedlichen Arbeitsweisen verschiedener Benutzer ohne einen technologischen Zwang auszuüben. Weitere Eigenschaften eines typischen Wikis sind ein aus einem Webbrowser abrufbarer Texteditor mit einer einfachen Wiki-Syntax zur Erstellung von Webseiten, eine Versionsverwaltung der verwalteten Seiten zwecks Verfolgung von Änderungen, eine einfache Möglichkeit zur Verknüpfung von Seiten mit Hilfe von Hyperlinks, sowie Suche über die im Wiki enthaltenen Texte.

Mit der Nutzung eines Wikis ergibt sich meist das Bedürfnis, zusätzlich zur Volltextsuche inhaltliche Informationen durchsuchen bzw. zu Übersichtsseiten zusammenfassen zu können. In Wikipedia z. B. fallen strukturierte Daten in großen Mengen zu Orten und Personen an (bei Orten Geokoordinaten oder Relationen wie *liegt-in*; bei Personen Lebensdaten oder erstellte Werke). Um den Umgang mit diesen Informationen für den Benutzer komfortabler zu gestalten werden meist zwei unterschiedliche

Ansätze verfolgt: Zum einen werden von Hand Übersichtsseiten erstellt, die Wiki-Seiten nach dem jeweiligen Kriterium ordnen, was allerdings einen hohen Wartungsaufwand darstellt. Zum anderen bieten die meisten Wikis Hilfsmittel wie Kategoriensysteme oder Erweiterungen für bestimmte Arten von Metadaten. Kategoriensysteme sind leider verhältnismäßig unflexibel; bei Erweiterungen für spezielle Metadaten muss abgewogen werden, ob der Aufwand für die Einarbeitung der Benutzer den Gesamtnutzen rechtfertigt.

Ein *Semantic Wiki* versucht, die Flexibilität eines normalen Wikis bei der Bearbeitung von Texten auch auf strukturierte Daten auszuweiten. Dazu unterstützt es Metadaten in Form von semantischen Annotationen zu Wiki-Seiten und zu Verknüpfungen zwischen Seiten¹. Semantische Annotationen können beispielsweise für erweiterte Anfragen oder sogar Adaption der Darstellung an verschiedene Benutzer und Domänen genutzt werden.

Der Begriff „Semantic Wiki“ wird für eine Vielzahl verschiedener Systeme verwendet. Allgemein vereinen Semantic Wikis Methoden des Semantic Webs mit den Funktionalitäten eines gewöhnlichen Wiki. Durch die interne Repräsentation der Annotation in RDF/OWL wird der Austausch von Daten mit anderen Applikationen erleichtert, so kann z. B. eine externe Suche benutzt werden. Außerdem können Deduktionsverfahren genutzt werden, um weitere Schlussfolgerungen abzuleiten. Semantic Wikis bieten darüber hinaus folgende Funktionalitäten:

- einen einfachen Formalismus zur semantischen Annotation von Links und von Wiki-Artikeln oder anderen Inhalten (hochgeladene Dateien...),
- eine semantische Suche, welche nicht nur nach Schlüsselwörtern, sondern auch nach semantisch zusammenhängenden Inhalten (z. B. Oberbegriffe des Suchwortes oder Suchbegriffe, welche eine bestimmte Eigenschaft erfüllen) suchen kann,
- zusätzlich eine möglicherweise automatische oder halbautomatische Extraktion von Metadaten aus den Wiki-Artikeln, um die Annotation zu erleichtern.

Die verschiedenen Semantic Wiki-Systeme haben unterschiedliche Ziele: die einen versuchen mit semantischen Annotationen die Navigation und die kollaborative Arbeit zu erleichtern, die anderen möchten Wikis als Werkzeug für die kollaborative Entwicklung von Ontologien etablieren. Das Spannungsfeld der Forschung und Entwicklung um Semantic Wikis

¹ Semantische Annotationen korrespondieren in der Regel mit einer Ontologie, in der definiert wird, welche Eigenschaften welchen Objekttypen zugeordnet werden können. Die Ontologie wird ebenfalls durch die einzelnen Wiki-Artikel erstellt und gewartet. Die erstellten Wissensmodelle werden meist in den Ontologiesprachen RDF/S bzw. OWL repräsentiert.

liegt also zwischen dem Einsatz von Semantic Web-Methoden für Wikis und der Konzeption von Wikis für das Semantic Web. Semantic Wikis werden folglich auch „Semantic Web im Kleinen“ genannt.

Semantic Wiki am Beispiel

Erstellen von Annotationen

Die Ontologie innerhalb eines Semantic Wiki wird erstellt und aktualisiert, indem jeder Instanz und jedem Konzept der Ontologie eine Seite im Wiki zugeordnet wird. Über Links bzw. Annotationen werden die jeweiligen Konzepte bzw. Artikel miteinander verknüpft. Semantic Wiki-Systeme verfolgen bei der eigentlichen Annotation zwei unterschiedliche Ansätze: Während die meisten eine erweiterte Wiki-Syntax im Editor verwenden, bieten einige eine Annotation der Artikel durch Formulare.

In Abb. 1 ist eine direkte Annotation im Wiki-Artikel am Beispiel des Systems Semantic MediaWiki [3] gezeigt. Hier kennzeichnet beispielsweise die Annotation `[[coded in::Java]]`, dass zwischen den Konzepten *IkeWiki* und *Java* eine Relation mit dem Namen *coded in* existiert. Diese formal repräsentierte Relation kann beispielsweise genutzt werden, um nach allen *Semantic Wikis* zu suchen, die in *Java* geschrieben wurden.

Annotation mittels Formularen zeigt Abb. 2 am Beispiel von IkeWiki [2]. Im dargestellten Artikel wird im Rahmen einer Bioinformatik-Anwendung der Begriff *Bilberry* näher beschrieben. Im System können Benutzer durch entsprechende Links auf der linken Menüseite sowohl Wiki-Seiten als auch Klassen und Eigenschaften erzeugen und ändern.



Abb. 1. Semantische Annotation am Beispiel des Systems *Semantic MediaWiki*



Abb. 2. Semantische Annotationen am Beispiel des Systems IkeWiki

Die zugeordneten Typen des Wiki-Artikels sind unter dem Seitentitel aufgelistet (im Beispiel *bio:Species*, *skos:Concept*, *rdfs:Resource*); bereits annotierte Textphrasen werden durch Icons entsprechend im Text gekennzeichnet. Beziehungen zu anderen Wiki-Artikeln bzw. Konzepten der Ontologie sind auf der rechten Seite unter *References* aufgeführt und visualisieren die vorhandenen Annotationen. Diese „Referenzbox“ dient ebenfalls einer erleichterten Navigation durch das erstellte semantische Netz. Durch Anklicken der +-Symbole können neue Annotationen einer Seite oder einem Link hinzugefügt werden. Abbildung 2 zeigt die Erstellung einer neuen Instanz der Relation *bio:isSpeciesFor* mit dem Subjekt *Bilberry* und dem Objekt *Vaccinium*. Der Benutzer kann im Formular dialog-unterstützt für das gewählte Attribut einen passenden Typ aus der Ontologie wählen.

Verwendung von Annotationen

Die einem semantischen Wiki hinzugefügten Informationen können den Benutzer auf verschiedene Art und Weise unterstützen. Im Folgenden werden wir drei verschiedene Möglichkeiten der Unterstützung beschreiben: semantische Navigation, semantische Suche, sowie Adaption der Darstellung.

Semantische Navigation

Die semantische Navigation ist die einfachste Form der Unterstützung von Benutzern. Dabei werden die dem Wiki hinzugefügten semantischen Strukturen zum Zweck der Navigation dargestellt. Abbildung 3 zeigt die Umsetzung semantischer Navigation in Semantic MediaWiki. Semantic

Facts about Sebastian Schaffert — Click + 🔍 to find similar pages. View as RDF 🔗

Relations to other articles

Is affiliated with Salzburg Research + 🔍, and Salzburg NewMediaLab + 🔍

Knows Semantic Web + 🔍, Social Software + 🔍, eLearning + 🔍, Wissensrepräsentation + 🔍, Reasoning + 🔍, Wernher Behrendt + 🔍, Georg Güntner + 🔍, Rupert Westenthaler + 🔍, Andreas Gruber + 🔍, Max Hamoncourt + 🔍, Andreas Blumauer + 🔍, Tassilo Pellegrini + 🔍, Francois Bry + 🔍, York Sure + 🔍, Stefan Decker + 🔍, Hans Tompits + 🔍, Roman Schindlauer + 🔍, Grigoris Antoniou + 🔍, Nicola Henze + 🔍, Max Völkel + 🔍, and Denny Vrandečić + 🔍

KnowsAbout Semantic Wiki + 🔍, Reasoning + 🔍, Description Logics + 🔍, Logics + 🔍, Social Software + 🔍, Semantic Web + 🔍, Ontology Engineering + 🔍, Knowledge Management + 🔍, Ontologien + 🔍, and ePortfolio + 🔍

IsProjectMember IkeWiki + 🔍, Xcerpt + 🔍, REWERSE + 🔍, and Salzburg NewMediaLab + 🔍

Attribute values

Title [Cops/No type defined for attribute]

Vorname Sebastian + 🔍

Nachname Schaffert + 🔍

Abb. 3. Semantische Navigation in Semantic MediaWiki

MediaWiki zeigt alle Relationen eines Artikels in einer sogenannten „Factbox“ an. Die Factbox stellt alle ausgehenden Relationen gruppiert nach Annotation dar. Ein Klick auf die Lupe führt zu einem Suchdialog, der es erlaubt weitere Kriterien anzugeben.

In IkeWiki wird die semantische Navigation auf ähnliche Art und Weise mit Hilfe einer „References Box“ dargestellt (Abb. 4).

Edit Annotate History

Languages: [en] [de] [pl] [it] [bg]

shrub s in the genus *Vaccinium* (family Ericaceae) : *Vaccinium myrtillus* L., also known as blaeberry, robably other names regionally. They were called Thomas Hardy 's 1878 novel, *The Return of the Native*

Bilberry
Scientific Classification
 Class: Magnoliopsida
 Family: Ericaceae
 Genus: *Vaccinium*

ames of other species of the genus, including *Vaccinium uliginosum* L. (bog . northern bilberry), *Vaccinium caespitosum* Michx. (dwarf bilberry), *Vaccinium eum* (mountain bilberry, black mountain huckleberry, black huckleberry, leafed blueberry, oval-leaved bilberry, mountain blueberry, high-bush

imperate and subarctic regions of the world. They are closely related to North : in the genus *Vaccinium*. The easiest way to distinguish the bilberry is that it usters like the blueberry. Bilberry is used as a food plant by the larva e of some *Vaccinium* .

lected from wild plants growing on publicly accessible lands, notably in ndia, it is an *everyman's right* to collect bilberries, irrespective of land glish, from the Irish *fraoch?*, and is traditionally gathered on the last Sunday in

References

outgoing

- + untyped
- bio:hasFamily
 - ↳ Ericaceae
- bio:hasGenus
 - ↳ Vaccinium
- + ikewiki:hasAuthor
- rdf:type
 - ↳ rdfs:Resource
 - ↳ Concept
- + rdfs:seeAlso
- sioc:link
- + related to
- + semantic relation

incoming

- + untyped
- + bio:isFamilyFor
- + bio:isGenusFor
- + rdfs:seeAlso
- + related to
- + semantic relation

Social Networks

Abb. 4. Semantische Navigation in IkeWiki. Die References Box gruppiert alle ausgehenden und eingehenden Referenzen nach Annotation

Semantische Suche

Die semantische Suche erlaubt es, Wiki-Inhalte anhand von Annotationen und Zusammenhängen zu finden. Beispielsweise können so alle Artikel gefunden werden, die ein semantisches Wiki beschreiben, welches in Java implementiert wurde. Suchanfragen können sowohl in einem Suchformular angegeben werden, als auch in „dynamische“ Wikiseiten eingebettet werden. Grundsätzlich ist die semantische Suche in den verschiedenen Systemen ähnlich umgesetzt, jedoch kommen unterschiedliche Anfragesprachen zum Einsatz. Abbildung 5 zeigt die semantische Suche mit Hilfe eines Formulars in Semantic MediaWiki.

In IkeWiki wird für die semantische Suche derzeit die vom W3C empfohlene Anfragesprache SPARQL² verwendet. Damit lassen sich auch komplexe Suchanfragen ausdrücken. Abbildung 6 zeigt eine Anfrage nach allen semantischen Wikis, die in Java implementiert wurden, eingebettet in eine dynamisch erstellte Wikiseite.

Spezialseite

Simple semantic search

Fill in either the upper or lower row of the input form to search for relations or attributes, respectively. Some of the fields can be left empty to obtain more results. However, if an attribute value is given, the attribute name must be specified as well. As usual, attribute values can be entered with a unit of measurement.

Be aware that you must press the right button to obtain results. Just pressing *Return* might not trigger the search you wanted.

Subject article:	Relation name:	Object article:	
	Is affiliated with	Salzburg Research	Search Relations
	Attribute name:	Attribute value:	
			Search Attributes

Search results (relations)

Rupert Westenthaler	Is affiliated with	Salzburg Research
Wernher Behrendt	Is affiliated with	Salzburg Research
Tobias Bürger	Is affiliated with	Salzburg Research
Andreas Gruber	Is affiliated with	Salzburg Research
Georg Güntner	Is affiliated with	Salzburg Research
Sebastian Schaffert	Is affiliated with	Salzburg Research

Abb. 5. Formbasierte semantische Suche in Semantic MediaWiki. Das Formular kann ähnlich wie in „Query By Example“ mit Werten gefüllt werden, wobei die freigelassenen Eingabefelder die Ergebnisfelder bezeichnen

² <http://www.w3.org/TR/rdf-sparql-query/>




Abb. 6. In Artikel eingebettete semantische Suche in IkeWiki. Die zwischen den Klammern `<?sparql` und `?>` angegebene SPARQL-Anfrage wird bei jeder Darstellung des Artikels neu ausgewertet

Adaption der Darstellung

Neben der verhältnismäßig einfachen semantischen Suche und Navigation können semantische Annotationen auch für weitergehende Funktionalitäten genutzt werden. Ein Beispiel dafür ist die Anpassung der Darstellung abhängig von semantischen Annotationen. So kann beispielsweise für einen Artikel, der eine Spezies oder Gattung im Biologiebereich beschreibt, automatisch eine Taxonomiebox angezeigt werden, welche die Zugehörigkeit zu den Kategorien der Hierarchie automatisch aus den Annotationen ableitet. Abbildung 7 zeigt das anhand eines Artikels über die Bilberry im System IkeWiki. Die Taxonomiebox wird dabei bei jedem Biologieartikel automatisch im rechten oberen Bereich mit eingeblendet.

Ähnliche kontextabhängige Adaptionen der Darstellung sind in vielen Bereichen nützlich. So wurde beispielsweise im Rahmen des Projektes MOSEP („More Self-Esteem with my ePortfolio“)³ mit Hilfe von IkeWiki ein Tutorial-Wiki entwickelt, welches die Lernpfade innerhalb von Kursmodulen darstellt. Neben der Anpassung der reinen Darstellung ist es auch vorstellbar, die Editierfunktionalität an den Kontext anzupassen – damit würde die Eingabe von Daten an die jeweilige Domäne angepasst und für den Benutzer stark vereinfacht.

³ <http://www.mosep.org>

The screenshot shows a Semantic Wiki page for 'Bilberry'. At the top, there are tabs for 'Edit', 'Annotate', and 'History'. Below these, a language selector shows 'en', 'de', 'pl', 'it', and 'bg'. The main content area contains text about the genus *Vaccinium* and its species, with a red box highlighting the 'Bilberry' section. To the right, a 'References' panel shows a hierarchical tree of semantic annotations, including 'outgoing' and 'incoming' links. The 'Bilberry' section is highlighted with a red box and contains the following text:

Bilberry
Scientific Classification
 Class: **Magnoliopsida**
 Family: **Ericaceae**
 Genus: **Vaccinium**

Abb. 7. Adaption der Darstellung anhand semantischer Annotationen. Das Beispiel zeigt eine automatisch generierte Taxonomiebox, die für jeden Biologieartikel angezeigt wird

Systeme im Vergleich

Im Folgenden versuchen wir, wesentliche Gesichtspunkte einiger ausgewählter Semantic Wikis herauszustellen. Zu beachten ist jedoch, dass sich die meisten Semantic Wiki-Systeme derzeit noch im Prototyp-Stadium befinden, sich deren Merkmale also schnell ändern können.

Semantic MediaWiki⁴ konzentriert sich auf den Wikipedia/Enzyklopädie-Anwendungsfall und legt dementsprechend Wert auf Skalierbarkeit und Abwärtskompatibilität. Außerdem wird kein festes Schema für Annotationen verlangt – Benutzer können Annotationen hinzufügen, für die noch kein Schema definiert wurde. Da in näherer Zukunft nicht mit frei verfügbaren Inferenzmaschinen zu rechnen ist, die bis zur Größe der Wikipedia skalieren, wird Inferenz in Semantic MediaWiki nicht abgedeckt.

⁴ http://ontoworld.org/wiki/Semantic_MediaWiki

IkeWiki⁵ wurde entwickelt als Werkzeug zur kollaborativen Entwicklung von Ontologien und für das Wissensmanagement und ist in Java implementiert. Im Gegensatz zu Semantic MediaWiki liegt der Fokus auf einer möglichst umfangreichen semantischen Unterstützung des Benutzers; dafür wird eine geringere Skalierbarkeit in Kauf genommen. IkeWiki unterstützt sowohl das Verwenden als auch das Bearbeiten von OWL-Ontologien. Als Inferenzmechanismen können derzeit OWL-RDFS und OWL-DL verwendet werden; eine regelbasierte Inferenz befindet sich derzeit in Entwicklung.

Kaukolu⁶ ist ein Forschungsprototyp, der auf JSPWiki aufbaut. Es erlaubt sowohl Annotationen mittels erweiterter Wiki-Markups als auch mittels Web-Formularen, die dynamisch aus den dem Wiki zur Verfügung stehenden Ontologien generiert werden. Annotationen können sich dabei auf die ganze Seite, aber auch auf beliebige Textteile beziehen und können auch automatisch von externen Systemen generiert werden – zur Zeit wird u. a. mit einem Eyetracker experimentiert. Anwendungsfall ist dabei die Annotation von bestehenden Dokumenten wie z. B. juristischen Texten.

SWEET Wiki⁷ ist ein Forschungsprototyp von INRIA Sophia-Antipolis und wurde in Java implementiert. SWEET Wiki zeichnet sich einerseits aus durch die Kombination von Social Tagging-Ansätzen und formalen Ontologien: Benutzer können auf einfache Weise Seiten mit Tags versehen, die wiederum an Ontologien angebunden werden können. Andererseits verwendet SWEET Wiki die CORESE-Inferenzmaschine, die für Conceptual Graphs entwickelt wurde und weitreichende Funktionalitäten bietet.

OntoWiki⁸ unterscheidet sich von den obigen drei Systemen insofern, als dass der klassische textuelle Inhalt nicht mehr im Vordergrund steht. Stattdessen bietet OntoWiki eine leicht zu verwendende Schnittstelle zur kollaborativen Erstellung und Wartung von Ontologien. Hervorzuheben sind zusätzlich die weit reichenden Möglichkeiten der semantischen Suche und Navigation und die Unterstützung der Versionierung von Metadaten.

Einen einheitlichen Standard wird es für Semantic Wikis genauso wenig wie für konventionelle Wikis geben, weil jedes System einen eigenen Fokus hat, und damit seine eigenen Stärken und Schwächen aufweist. Eine ausführlichere Übersicht gibt es u. a. auf den Seiten zum Thema Semantic Wiki im Ontoworld-Wiki⁹.

⁵ <http://ikewiki.salzburgresearch.at/>

⁶ <http://kaukoluwiki.opendfki.de/>

⁷ <http://www.sop.inria.fr/acacia/soft/sweetwiki.html>

⁸ <http://3ba.se>

⁹ http://wiki.ontoworld.org/wiki/Category:Semantic_wiki

Anwendungsbereiche

Da Semantic Wikis eine Erweiterung von herkömmlichen Wikis darstellen, überschneiden sich die Anwendungsbereiche der beiden Ansätze in weiten Teilen. Darüber hinaus können Semantic Wikis dem Benutzer durch die explizite Repräsentation von Metadaten in vielen Anwendungsgebieten eine stärkere Unterstützung bieten, beispielsweise durch verbesserte Navigation und Suche, kontextabhängige Darstellung oder Personalisierung. Exemplarisch wollen wir im Folgenden die zwei Anwendungsbereiche Wissensmanagement und Ontology Engineering diskutieren, die unterschiedliche Aspekte des Einsatzes von Semantic Wikis betrachten.

Wissensmanagement

In den letzten Jahren werden zunehmend Wikis als Werkzeug zur Unterstützung des Wissensmanagements eingesetzt. Beispielsweise wird das Wissen über Softwareprojekte (Source Code, Dokumentation, Projektpläne, Bug Tickets, Screencasts, etc.) inzwischen in vielen Firmen und Projekten über Wikis verwaltet und miteinander geteilt. Das so in Wikis erfasste Wissen ist zwar leicht zu erstellen, aber zunehmend schwer wieder zu finden. Auch ist das Projektwissen oft über eine Vielzahl von Wikis verteilt. So werden beispielsweise für die Entwicklung der IDE Netbeans bei Sun Microsystems inzwischen mehr als ein Dutzend Wikis eingesetzt, die nicht interoperabel sind.

Semantic Wikis bieten das Potential, diese Probleme zu lösen, ohne gleichzeitig die Flexibilität und Offenheit von Wikis aufzugeben. Wo semantische Annotationen und damit Strukturen vorhanden sind, kann das System gezielt unterstützen, beispielsweise durch eine Visualisierung eines semantisch repräsentierten Projektplans, durch Austausch von Annotationen bzw. Ontologien mit Geschwister-Wikis, oder durch eine semantische Suchfunktion. Wo (noch) keine semantischen Annotationen vorhanden sind oder noch nicht alle Benutzer Annotationen nutzen, kann ein Semantic Wiki wie ein herkömmliches Wiki funktionieren. Wie bei einem normalen Wiki, bei dem häufig Kurzzeitzutzer Inhalte beitragen und die saubere Einbettung in das restliche Wiki von Langzeitzutzern übernommen wird, können bei einem Semantic Wiki Kurzzeitzutzer – ohne lange Einarbeitungszeit – Informationen beitragen, die dann von Langzeitzutzern „semantifiziert“ werden. Ein schöner Nebeneffekt dieser „evolutionären Formalisierung“ ist, dass Benutzer einen unmittelbaren Nutzen (verschiedene Formen der Unterstützung) für den Mehraufwand der Annotation erhalten. Letzteres ist ein entscheidendes Kriterium in der Motivation von Benutzern. Wissensmanagement mit Hilfe von Semantic Wikis wird u. a.

in den EU-Projekten *KIWI*¹⁰ (Knowledge in a Wiki) und *NEPOMUK*¹¹ (Social Semantic Desktop), aber auch im Project Halo¹² untersucht.

Ontology Engineering

Die Entwicklung von Ontologien für das Semantic Web ist ein sehr aufwändiger Prozess, ähnlich der Softwareentwicklung. Ein wesentliches Problem ist, dass Domänenexperten (z. B. Biologen) zwar ihre jeweilige Domäne sehr gut kennen, aber mit den Formalismen zur Wissensrepräsentation nicht vertraut sind, und umgekehrt Informatiker zwar mit den Formalismen vertraut sind, aber meist keinen tiefen Einblick in die jeweilige Domäne haben. Als Konsequenz gibt es außerhalb der Informatik derzeit nur für einige Spezialbereiche gute Ontologien.

Semantic Wikis können den Prozess der Ontologieentwicklung entscheidend vereinfachen. Ausgehend von einer durch den Domänenexperten erstellten textuellen Beschreibung der Domäne, die als Sammlung von Wiki-Seiten repräsentiert ist, kann das Wissen schrittweise und in enger Interaktion zwischen Domänenexperten und Informatikern formalisiert werden. Die so entstandene Ontologie kann dann beispielsweise in anderen Werkzeugen oder Anwendungen weiterverwendet werden. Semantic Wikis sind auch für die Aktualisierung und Pflege einer Ontologie interessant: Während Werkzeuge wie Protégé [6] auch für solche Aufgaben viel Verständnis für die Formalismen erfordern, können die meisten Änderungen in einem Semantic Wiki auch von Domänenexperten vorgenommen werden. Erste Erfahrungen im Projekt *Dynamont*¹³ sind vielversprechend.

Aktuelle Forschung

Die derzeit vorhandenen Semantic Wiki-Systeme bieten nur sehr einfache Annotationen und – wenn überhaupt – nur sehr elementare Deduktionsmöglichkeiten, die für die oben erwähnten Anwendungen kaum ausreichen. Im Allgemeinen überschneiden sich viele Forschungsgegenstände mit denen des allgemeinen Themas Semantic Web, wobei für das Thema Semantic Wiki oft ein starker Fokus auf die Benutzbarkeit der Methoden gelegt wird. Die Einfachheit der Schnittstelle für den Benutzer ist für den

¹⁰ KIWI befindet sich derzeit in der Verhandlungsphase, Start voraussichtlich März 2008

¹¹ <http://nepomuk.semanticdesktop.org>

¹² <http://www.projecthalo.org>

¹³ <http://dynamont.factlink.net>

Erfolg entscheidend, da bei Semantic Wikis auch ungeübte Personen zum Benutzer der Technologie gemacht werden sollen. Folgende Punkte sind Gegenstand der aktuellen Forschung:

Flexibilität. Normale Wikis stellen kaum Anforderungen an die Struktur der verwalteten Daten. Semantic Wikis dagegen haben als Ziel, den Benutzer strukturierte Daten hoher Qualität erzeugen zu lassen. Dabei treten die gleichen Probleme auf, wie sie von Ontologieeditoren bzw. Datenbanksystemen bekannt sind und die in erster Linie den Bereich Usability betreffen – letztendlich befinden sich Semantic Wikis im Spannungsfeld der unstrukturierten Daten (Daten ohne Schema – leicht einzugeben, aber von geringer Qualität und mit hohem Rauschen) und dem Erzwingen des Einhaltens von Schemata (schwer einzugeben, hoher Aufwand bei der Pflege der Ontologien).

Anfragesprachen. Mit SPARQL ist ein Standard für Ontologie-Anfragesprachen entstanden, welcher sich in seiner Notation an SQL orientiert. Für normale Wiki-Benutzer dürfte diese Syntax aber weniger geeignet sein, weil die Formulierung von konkreten Anfragen für ungeübte Anwender oft zu schwierig ist. Eine deutlich vereinfachte Sprache, welche sich eventuell an der Wiki-Syntax orientiert, erscheint für die Zukunft wünschenswert. Visuelle Web- und Semantic Web-Anfragesprachen, wie visXcerpt [4], stellen einen erfolgversprechenden Ansatz dar.

Extraktion von semantischen Annotationen. Die Erstellung von Annotationen in Semantic Wikis ist häufig eine zeitaufwändige und komplexe Aufgabe. Die automatische oder halbautomatische Extraktion von semantischen Annotationen aus Wiki-Seiten ist daher ein attraktiver Ansatz. Hier werden Ergebnisse aus dem Bereich Ontologie-Lernen und Text Mining zur Anwendung kommen.

Reasoning. Mit einfachen Annotationen wie RDF-Tripeln lassen sich nur grundlegende semantische Eigenschaften ausdrücken. Neben Ontologiesprachen wie OWL ist für ein Semantic Wiki die Existenz einer Regelsprache von Interesse, mit der einfache Schlussfolgerungen ausgedrückt werden können. Die Schwierigkeit in Bezug auf Semantic Wikis liegt hierbei darin, eine Regelsprache zu entwickeln, die einfach benutzbar ist und es auch „normalen“ Wiki-Benutzern ermöglicht, Schlussfolgerungen zu spezifizieren.

Visualisierung. Eine nicht rein textuelle Visualisierung von möglicherweise komplexen semantischen Annotationen, einschließlich Regeln, wäre für viele potentielle Benutzer sehr wichtig. Die Visualisierung von Tabel-

len, Gantt-Diagrammen, UML-Diagrammen und von Terminbüchern ist für viele der oben erwähnten Anwendungsbereiche unabdingbar.

Personalisierung. Viele der oben erwähnten Anwendungen verlangen eine Anpassung oder „Adaptation“ der Inhalte sowie der semantischen Annotationen auf die Vorlieben und Eigenschaften einzelner Benutzer oder Benutzergruppen.

Ausblick & Zusammenfassung

Semantic Wikis bieten im Vergleich zu herkömmlichen Wikis durch die semantische Annotation eine explizite Repräsentation des beinhalteten Wissens. Diese Erweiterung ermöglicht unter anderem die Verwendung von semantischer Suche, automatischer Deduktion und intelligenter Navigation. Als Anwendungen bieten sich diese Systeme besonders für das verteilte Wissensmanagement und Ontologie-Engineering an.

In den nächsten Jahren wird es erhebliche Fortschritte im Bereich der Semantischen Wikis geben: Im März 2008 werden im 7. Rahmenprogramm der EU zwei große Projekte starten, in denen Semantische Wikis einen Schwerpunkt bilden: KIWI („Knowledge in a Wiki“)¹⁴ und ACTIVE („Knowledge Powered Enterprise“)¹⁵. Während KIWI sich damit beschäftigt, wie man die Funktionalitäten eines semantischen Wikis erweitern kann, um den Benutzer möglichst gut zu unterstützen (z. B. Reasoning, Personalisierung, automatische Annotation), wird sich ACTIVE primär mit der Integration vieler verschiedener Wissensquellen beschäftigen. Beide Projekte werden eng zusammenarbeiten, so dass mit spannenden Ergebnissen gerechnet werden kann.

Literatur

1. Anja Ebersbach und Markus Glaser: Wiki (Aktuelles Schlagwort), Informatik Spektrum, 28(2), Springer Verlag, 2005.
2. Sebastian Schaffert: IkeWiki: A Semantic Wiki for Collaborative Knowledge Management. In: Proceedings of the 1st International Workshop on Semantic Technologies in Collaborative Applications (STICA), 2006.
3. Markus Krötzsch, Denny Vrandečić, Max Völkel: Semantic MediaWiki, In Isabel Cruz and Stefan Decker and Dean Allemang and Chris Preist and Daniel Schwabe and Peter Mika and Mike Uschold and Lora Aroyo, Proceedings of

¹⁴ <http://www.kiwi-project.eu>

¹⁵ <http://www.active-project.eu/>

the 5th International Semantic Web Conference (ISWC06), volume 4273 of Lecture Notes in Computer Science, pp. 935–942. Springer, Athens, GA, USA, November 2006.

4. Sacha Berger, François Bry, Oliver Bolzer, Tim Furche, Sebastian Schaffert, and Christoph Wieser: Querying the standard and Semantic Web using Xcerpt and visXcerpt. In: Proceedings of the 2nd European Semantic Web Conference (ESWC), 2005.
5. Sören Auer, Sebastian Dietzold and Thomas Riechert: OntoWiki – A Tool for Social, Semantic Collaboration, In: The Semantic Web (ISWC 2006), LNCS 4273, pp. 736–749, Springer, 2006.
6. Holger Knublauch, Ray W. Fergerson, Natalya F. Noy, and Mark A. Musen. The Protégé OWL Plugin: An Open Development Environment for Semantic Web Applications. Third International Semantic Web Conference, Hiroshima, Japan, 2004.

14. Semantische Mashups auf Basis Vernetzter Daten

Sören Auer¹, Jens Lehmann¹ und Christian Bizer²

¹ Institut für Informatik (IfI), Universität Leipzig;
nachname@informatik.uni-leipzig.de

² Web-based Systems Group, Freie Universität Berlin;
chris@bizer.de

Zusammenfassung: Semantische Mashups sind Anwendungen, die vernetzte Daten aus mehreren Web-Datenquellen mittels standardisierter Datenformate und Zugriffsmechanismen nutzen. Der Artikel gibt einen Überblick über die Idee und Motivation der Vernetzung von Daten. Es werden verschiedene Architekturen und Ansätze zur Generierung von RDF-Daten aus bestehenden Web 2.0-Datenquellen, zur Vernetzung der extrahierten Daten sowie zur Veröffentlichung der Daten im Web anhand konkreter Beispiele diskutiert. Hierbei wird insbesondere auf Datenquellen, die aus sozialen Interaktionen hervorgegangen sind eingegangen. Anschließend wird ein Überblick über verschiedene, im Web frei zugängliche semantische Mashups gegeben und auf leichtgewichtige Inferenzansätze eingegangen, mittels derer sich die Funktionalität von semantischen Mashups weiter verbessern lässt.

Einleitung

Das Web wandelt sich zunehmend von einem Medium zur Veröffentlichung von Texten hin zu einem Medium zur Veröffentlichung von strukturierten Daten. Ein Beispiel für diese Entwicklung ist die zunehmende Verbreitung von Inhaltsformaten wie RSS, ATOM und Microformats, sowie Web-APIs, die Anfragen gegen Datenquellen wie Google, Yahoo! und Amazon ermöglichen.

Aufgrund der diversen Schnittstellen und Ergebnisformate, die derzeit von Web-APIs angeboten werden, ist die Integration von Daten aus mehreren Datenquellen nach wie vor mit einem relativ hohen Programmieraufwand verbunden.

In diesem Beitrag stellen wir das Konzept semantischer Mashups als Ansatz zur Integration von Daten aus unterschiedlichen Quellen vor.

Semantische Mashups sind Anwendungen, die vernetzte RDF-Daten aus mehreren Web-Datenquellen nutzen. Das Spektrum semantischer Mashups ist groß. Es reicht von generischen Daten-Browsern, über themenspezifische Portale bis hin zu Suchmaschinen, die expressive Anfragen gegen Web-Daten aus unterschiedlichen Quellen ermöglichen.

Im Konzept semantischer Mashups im Social Semantic Web spielen drei Elemente eine zentrale Rolle: (1) Vernetzte Daten (engl. Linked Data [7]) als Rahmenwerk für die Repräsentation und den Zugriff auf semantische Daten im Web, (2) DBpedia als ein Kristallisationskern für die Vernetzung von Daten aus unterschiedlichen Quellen sowie (3) leichtgewichtige Inferenzstrategien für die Integration und Strukturierung der Daten.

Im Gegensatz zu den diversen Schnittstellen und Ergebnisformaten, die derzeit von Web-APIs angeboten werden, bieten vernetzte Daten den Vorteil eines flexiblen, standardisierten Datenformats (RDF), eines standardisierten Zugriffsmechanismus (HTTP) sowie die Möglichkeit Verweise zwischen Daten in unterschiedlichen Datenquellen zu setzen. Anhand dieser Links und eines generischen Daten-Browsers können Nutzer von Datensätzen in einer Datenquelle zu Datensätzen in einer anderen Datenquelle navigieren. Verweise können auch von Suchmaschinen verwendet werden, um die Inhalte vernetzter Web-Datenquellen zu sammeln (mittels Web-Crawler) sowie expressive Abfrage- und Suchfunktionalitäten über die gesammelten Daten anzubieten.

Die Enzyklopädie Wikipedia beinhaltet Informationen zu einer sehr breiten Palette unterschiedlicher Themen. Das Projekt DBpedia extrahiert strukturierte Informationen aus Wikipedia und veröffentlicht diese Informationen als vernetzte Daten im Web. DBpedia bietet derzeit Informationen zu mehr als 1,95 Millionen ‚Dingen‘, inklusive 80.000 Personen, 70.000 Orten, 35.000 Musik-Alben, 12.000 Filmen. Durch die breite thematische Abdeckung lassen sich DBpedia-Daten mit Daten aus einer Vielzahl anderer Datenquellen verknüpfen. Hierdurch und durch die Vernetzung anderer Datenquellen untereinander entwickelt sich derzeit ein dezentrales Daten-Web. Dieses Daten-Web wuchs im Laufe des letzten Jahres sehr schnell und umfasste im Oktober 2007 mehr als 2 Milliarden Informationen (RDF Triples).

Dieser Beitrag gliedert sich wie folgt: Wir stellen zunächst die Basis-Prinzipien vernetzter Daten vor (Abschn. 2), beschreiben am Beispiel von DBpedia, wie eine Fülle strukturierter Daten mittels sozialer Interaktionen gewonnen werden kann (Abschn. 3). Anschließend wird ein Überblick über verschiedene, im Web frei zugängliche semantische Mashups gegeben sowie auf Inferenzansätze eingegangen, mittels derer sich die Funktionalität der semantischen Mashups weiter verbessern lässt.

Vernetzte Daten im Web

Dieser Abschnitt erklärt die technischen Grundlagen vernetzter Daten und gibt einen Überblick über Werkzeuge zur Veröffentlichung vernetzter Daten im Web. Anschließend werden verschiedene, existierende Quellen vernetzter Daten vorgestellt.

Die Prinzipien vernetzter Daten

Das Konzept vernetzter Daten greift verschiedene Entwicklungen aus dem Bereich webbasierter Datenintegration auf und versucht die unterschiedlichen Entwicklungstendenzen auf einer gemeinsamen technologischen Basis zusammenzuführen. Das Konzept zielt darauf ab, es Informationsanbietern genau so einfach zu machen, strukturierte Daten im Web zu veröffentlichen und Datensätze in unterschiedlichen Datenquellen zu verknüpfen, wie sie heute klassische HTML-Dokumente im Web veröffentlichen und Verweise zwischen verschiedenen Dokumenten setzen.

Der Begriff *Vernetzte Daten* (engl. Linked Data) wurde von Tim Berners-Lee in [7] geprägt. Der Begriff bezieht sich auf eine Menge von Best-Practices zur Veröffentlichung und Verknüpfung von strukturierten Daten im Web. Grundannahme von Linked Data ist, dass der Wert und die Nützlichkeit von Daten steigen, je stärker sie mit Daten aus anderen Datenquellen verknüpft sind.

Die technischen Grundprinzipien vernetzter Daten bestehen darin,

1. das Resource Description Framework (RDF) [19] als universelles Datenmodell zur Veröffentlichung von strukturierten Daten im Web zu verwenden,
2. alle URIs, die in RDF-Graphen verwendet werden, über das Web dereferenzierbar zu machen, sowie
3. RDF-Verweise zwischen Daten in verschiedenen Datenquellen zu setzen.

Die Anwendung dieser beiden Prinzipien führt zur Entstehung eines Daten-Webs, eines offenen Informationsraums mit ähnlichen Eigenschaften wie denen des klassischen World Wide Webs.

Auf diesen Informationsraum lässt sich mittels generischer Daten-Browser zugreifen, ähnlich, wie auf das klassische Web mittels HTML-Browsern zugegriffen wird. Nutzer können sich Daten aus einer Quelle anzeigen lassen und anschließend anhand von RDF-Verweisen zu Daten in einer anderen Quelle navigieren. Ähnlich wie Suchmaschinen das klassische Web anhand von HTML-Verweisen crawlen, lassen sich anhand von RDF-Verweisen Daten aus verschiedenen Quellen zusammenführen.

RDF-Verweise [11] verknüpfen Datensätze aus unterschiedlichen Datenquellen. Sie repräsentieren typisierte Beziehungen zwischen den Datensätzen. So lässt sich beispielsweise mittels RDF-Verweisen ausdrücken, dass mehrere Datensätze in unterschiedlichen Datenquellen die gleiche Person beschreiben. Oder es lässt sich ausdrücken, dass eine Person, die in einer Datenquelle beschrieben wird, sich für ein Thema interessiert, über das es in einer anderen Datenquelle weitere Informationen gibt.

Der folgende RDF Graph besteht aus zwei RDF-Verweisen. Das Beispiel verwendet die Turtle Syntax [5].

```
1. # RDF link taken from Tim Berners-Lee's FOAF profile
2. <http://www.w3.org/People/Berners-Lee/card#i>
3. owl:sameAs
4. <http://www4.wiwiss.fu-
berlin.de/dblp/resource/person/100007>.
5.
6. # RDF link taken from Richard Cyganiak's FOAF profile
7. <http://richard.cyganiak.de/foaf.rdf#cygri>
8. foaf:based_near
9. <http://dbpedia.org/resource/Berlin>.
```

Abb. 1. Beispiele für RDF-Verweise

Der erste RDF-Verweis (Zeile 2–4) drückt aus, dass die URI `http://www.w3.org/People/Berners-Lee/card#i` die gleiche Ressource identifiziert wie die URI `http://www4.wiwiss.fu-berlin.de/dblp/resource/person/100007`. Der zweite RDF-Verweis (Zeile 7–9) drückt aus, dass die URI `http://richard.cyganiak.de/foaf.rdf#cygri` eine Ressource identifiziert, die in der Nähe einer anderen Ressource wohnt, welche mittels der URI `http://dbpedia.org/resource/Berlin` identifiziert wird.

Gemäß der Prinzipien vernetzter Daten sollen alle URIs, die in RDF-Graphen verwendet werden, dereferenzierbar sein. Dies bedeutet, dass Web-Clients zu jeder URI mittels der HTTP-Operation GET weitere Informationen abrufen können. Sendet ein Web-Client zusammen mit seiner Anfrage den HTTP-Accept-Header `text/html`, sendet ihm der Server eine Repräsentation der Ressource im HTML-Format. Fragt der Client mittels des HTTP-Accept-Headers `application/rdf+xml` nach RDF-Daten, sendet ihm der Server Informationen über die Ressource im RDF/XML Format.




Abb. 2. Dereferenzierung von HTTP-URIs

Das folgende Beispiel illustriert, wie Web-Clients mittels URI-Dereferenzierung durchs Daten-Web navigieren. Interessiert sich der Benutzer eines Daten-Browsers beispielsweise dafür, was für eine Ressource mit der URI <http://richard.cyganiak.de/foaf.rdfcygri> identifiziert wird, weist er seinen Browser an, diese Ressource zu dereferenzieren. Als Antwort erhält er vom Server <http://richard.cyganiak.de> beispielsweise den in Abb. 2 links oben dargestellten RDF Graphen. Der Graph enthält die Information, dass es sich bei der Ressource um eine Person handelt, die Richard Cyganiak heißt. Interessiert sich der Benutzer darüber hinaus für den Ort, in dem Richard wohnt, dereferenziert er die URI <http://dbpedia.org/resource/Berlin> und bekommt vom Server <http://dbpedia.org> einen RDF-Graphen, der die Stadt Berlin beschreibt. Da sowohl der Graph über Richard als auch der Graph über Berlin die gleiche URI zur Identifikation der Stadt Berlin verwenden, fügen sich beide Graphen natürlich zusammen (Abb. 2 rechts oben und links unten). Der Graph, der Berlin beschreibt, beinhaltet die Information, dass Berlin zur Gruppe der deutschen Städte gehört. Interessiert sich der Nutzer für weitere deutsche Städte, dereferenziert er die URI http://dbpedia.org/resource/Cities_in_Germany und erhält eine Liste deutscher Städte, von der aus er zu weiteren Städten navigieren kann (Abb. 2 rechts unten).

Veröffentlichung vernetzter Daten im Web

Vernetzte Daten lassen sich im Web in Form von RDF/XML-Dateien, die auf einem Webserver abgelegt werden, veröffentlichen. Im Laufe des letzten Jahres wurden zusätzlich verschiedene Werkzeuge zur Veröffentlichung vernetzter Daten entwickelt, mit Hilfe derer sich Sichten auf die Inhalte relationaler Datenbanken und RDF-Stores im Web publizieren lassen. Beispiele derartiger Veröffentlichungs-Werkzeuge für relationale Datenbanken sind D2R-Server [8] und OpenLink Virtuoso [14]. Ein Tool, mit dem sich die Inhalte von RDF-Datenbanken publizieren lassen, ist Pubby [13].

Ein weiterer Ansatz zur Veröffentlichung vernetzter Daten besteht in der Implementierung von Wrappern um existierende Anwendungen oder Web-APIs. Beispiele für Wrapper auf Anwendungsebene sind die SIOC-Exporter für WordPress, Drupal und phpBB [12]. Ein Beispiel eines Wrappers um Web-APIs ist das RDF Book-Mashup, das auf die Amazon und Google Base-API zugreift, um RDF-Daten über Bücher bereitzustellen [10].

Eine detaillierte Beschreibung der verschiedenen Techniken zum Publizieren vernetzter Daten im Web findet sich in [11].

Quellen vernetzter Daten im Web

Die Menge der im Oktober 2007 als vernetzte Daten im Web veröffentlichten Informationen wird auf über 2 Milliarden RDF-Triples geschätzt. Dieser Datenbestand ist mittels circa 3 Millionen RDF-Verweisen zwischen unterschiedlichen Datenquellen vernetzt.

Unterschiedliche Datenquellen veröffentlichen Informationen über Länder, Städte, Personen, Firmen, Bücher, Filme, Musik, wissenschaftliche Veröffentlichungen, Konferenzen, Projekte und Arbeitsgruppen, sowie statistische Daten über die Europäische Gemeinschaft und die Vereinigten Staaten.

Das Linking Open Data Projekt [26] der Semantic Web Education and Outreach Arbeitsgruppe des World Wide Web Konsortiums führt ein Verzeichnis aller bekannten Quellen vernetzter Daten, die ihre Inhalte unter einer offenen Lizenz bereitstellen. Abbildung 3 gibt einen Überblick über einen Teil der vom Linking Open Data Projekt erfassten Datenquellen sowie über die Verknüpfungen zwischen Datensätzen in unterschiedlichen Datenquellen.

Die Datenquellen, die im Oktober 2007 neu in das Verzeichnis aufgenommen worden sind, sind in der Abbildung mit ‚NEW‘ gekennzeichnet. Die Datenquelle Wiki-Company bietet beispielsweise Informationen über circa 20.000 Firmen an. Der Flickr Wrapp ermöglicht den Zugriff auf die Fotodatenbank von Flickr¹ und generiert Bildersammlungen zu Dingen, die

¹ www.flickr.com/




Abb. 3. Überblick über Quellen vernetzter Daten

in DBpedia beschrieben sind. Die Datenquelle Open-Cyc veröffentlicht einen Teil der Cyc-Ontologie² als vernetzte Daten.

Anhand von RDF-Verweisen können Nutzer zwischen Datensätzen in unterschiedlichen Datenquellen des Netzwerks navigieren. So ist es beispielsweise möglich, von Informationen über eine Person in einer FOAF-Datei zu Informationen über die Stadt, in der die Person wohnt, in DBpedia und anschließend zu weiteren Informationen über diese Stadt in der Geonames- sowie der US-Census-Datenbank zu navigieren. Alternativ lässt sich in DBpedia beispielsweise von der Stadt zu einer Liste von Musikgruppen, die aus dieser Stadt stammen, und anschließend zu detaillierten Informationen über die Alben dieser Bands in der MusicBrainz-Datenbank navigieren.

DBpedia als Kristallisationskern für die Vernetzung von Datenquellen

Um Daten aus thematisch unterschiedlichen Datenquellen miteinander verknüpfen zu können, ist es sehr wichtig über Datensätze zu verfügen, die

² <http://www.opencyc.org/>

ein sehr breites Themenspektrum abdecken sowie Dinge aus unterschiedlichen Domänen miteinander in Beziehung setzen. Einer der größten Datensätze dieser Art wird zurzeit vom DBpedia-Projekt bereitgestellt. Die Bedeutung dieses Datensatzes für die Verknüpfung anderer Datenquellen verdeutlicht die zentrale Stellung von DBpedia in Abb. 3.

Die DBpedia Daten werden aus den Inhalten der Enzyklopädie Wikipedia extrahiert. Seit dem Beginn des Wikipedia-Projektes im Jahr 2001 hat sich Wikipedia zur umfassendsten Enzyklopädie und dem erfolgreichsten kollaborativen Gemeinschaftsprojekt im Internet entwickelt. Inzwischen gibt es Wikipedia-Versionen in mehr als 250 Sprachen. Im September 2004 überschritt der Umfang des Gesamtprojekts die Grenze von einer Million Artikel, mittlerweile sind es über 7,5 Millionen. Die deutschsprachige Wikipedia ist dabei eines der aktivsten und bestkoordinierten Teilprojekte. Sie enthält derzeit mehr als 655.000 Artikel, die englische Ausgabe umfasst über 2,07 Millionen (Stand: November 2007). Inzwischen ist Wikipedia eine der 10 am meisten besuchten Informationsangebote im Internet (vgl. alexa.com).

Eines der Wikipedia-Grundprinzipien ist die gemeinschaftliche Erstellung der Artikel. Dies resultiert in einer Reihe von Vor- und Nachteilen. Zu den Vorteilen gehört, dass Artikel oft einen Konsens repräsentieren, die Mitarbeit und Beteiligung angeregt wird und eine große Bandbreite von Themen umfassend und oft enorm aktuell abgedeckt wird. Folgende Nachteile des kollektiven Editierens haben sich ergeben: Manche (Rand-) Themen sind ungenau oder unvollständig dargestellt und dies ist für Leser nicht immer ersichtlich, einige Nutzer versuchen in Wikipedia einseitige oder werbende Darstellungen zu platzieren, die Inhalte sind nicht einheitlich strukturiert. Diese Nachteile wurden von der Wikipedia-Gemeinschaft inzwischen erkannt und es wird versucht Lösungsmöglichkeiten zu entwickeln: Stabile Artikelversionen sollen vor Vandalismus schützen, Artikel werden zunehmend kategorisiert und (z. B. mit Infoboxen) strukturiert, es gibt Wettbewerbe für die besten Beiträge und schlecht geschriebene Artikel und solche mit fehlenden Informationen werden entsprechend gekennzeichnet.

Das DBpedia-Projekt versucht nun strukturierte Informationen aus Wikipedia-Inhalten (z. B. Infoboxen) zu extrahieren. In diesen strukturierten Informationen liegt ein sehr großes Potential, das heute noch nicht genutzt wird. Durch die Extraktion von Informationen aus Wikipedia und deren Repräsentation mittels eines strukturierten Datenmodells lassen sich z. B. folgende Anwendungen realisieren:

- Es lassen sich komplexe Anfragen an Wikipedia stellen. Beispiele sind: „Welche deutschen Komponisten wurden im 18. Jahrhundert in Berlin geboren?“, „In welchen Filmen tritt Quentin Tarantino als Schauspieler auf?“ oder „Wer sind die Bürgermeister von Städten in den USA, die hö-

her als 1000m gelegen sind?“. Diese erweiterten Anfragemöglichkeiten revolutionieren den Zugriff auf Wikipedia-Inhalte für den Endnutzer und ermöglichen eine wesentlich spezifischere Nutzung dieser Wissensbasis.

- Über die gewonnenen strukturierten Informationen lässt sich die Konsistenz von Wikipedia, insbesondere auch die Konsistenz zwischen den verschiedenen Sprachversionen, überprüfen. Hiermit lässt sich die Qualität von Wikipedia und damit ihr Wert als eine der zentralen Wissensressourcen der Menschheit insgesamt verbessern.
- Aus Sicht der Wissensrepräsentation stellen die gewonnenen Daten eine der größten Ontologien dar. Diese Ontologie unterscheidet sich von bisherigen Ontologien darin, dass die in ihr definierten Konzepte ein tatsächliches ‚Community Agreement‘ darstellen und von der Gemeinschaft permanent aktualisiert werden.

Einen Überblick über die Struktur des DBpedia-Projektes gibt Abb. 4. Die DBpedia-Extraktion arbeitet auf der Basis der von Wikipedia veröffentlichten Datenexporte. In den folgenden Abschnitten stellen wir die DBpedia-Extraktion, die resultierenden Datenpakete als auch Beispiele von bestehenden DBpedia-Anwendungen vor. Detaillierte Informationen zu DBpedia finden sich in [2] und [3].




Abb. 4. Überblick über die einzelnen DBpedia-Komponenten

Extraktion

Wikipedia-Artikel bestehen zum größten Teil aus Freitext, enthalten aber auch verschiedene Arten strukturierter Informationen, wie z. B. Infobox-Templates, Kategorisierungen, Bilder, Geo-Koordinaten, Verweise zu externen Webseiten und zu Wikipedia-Editionen in anderen Sprachen.

Die Software hinter der Wikipedia-Webseite ist dabei Mediawiki³. In der Natur dieses Wiki-Systems liegt es dabei auch, dass alle Bearbeitungen, Verknüpfungen und Annotationen mit Meta-Daten innerhalb der Artikeltexte mit speziellen syntaktischen Konstrukten realisiert werden. Strukturierte Informationen können daher mittels einer Analyse und Verarbeitung der Artikel und der darin enthaltenen syntaktischen Konstrukte erreicht werden.

Da MediaWiki einige dieser Informationen intern selbst zur Erstellung der Benutzerschnittstelle nutzt, liegen einige extrahierte Informationen bereits in relationalen Datenbanktabellen vor. Exporte der zentralen Datenbank-Tabellen (inklusive der, welche den Artikelvolltext enthält) werden monatlich von Wikipedia im Netz bereitgestellt⁴. Basierend auf diesen Datenbankexporten, nutzt DBpedia im Moment zwei Arten der Extraktion semantischer Beziehungen: (1) Wir bilden relationale Beziehungen, die bereits in Form von Datenbank-Tabellen vorliegen, in RDF ab und (2) wir extrahieren zusätzliche Informationen direkt aus den Artikel-Texten und den Infobox-Vorlagen innerhalb dieser Texte.

Wir illustrieren die Extraktion von Semantik aus dem Artikel-Text anhand einer Wikipedia-Infobox-Vorlage. Abbildung 2 zeigt die Infobox-Vorlage (die im Quelltext eines Wikipedia-Artikels zu finden ist) und die daraus erstellte Ausgabe auf der Wikipedia-Seite zu der süd-koreanischen Stadt Busan. Der Infobox-Extraktions-Algorithmus entdeckt solche Vorlagen und erkennt deren Struktur mit Hilfe von Techniken der Mustererkennung. Er wählt signifikante Vorlagen aus, die dann verarbeitet und in RDF-Tripel konvertiert werden. Der Algorithmus bearbeitet die so extrahierten Daten nach, um die Qualität der Extraktion zu erhöhen. Beispielsweise werden Verweise zu anderen Artikeln erkannt und in passende URIs übersetzt, Maßeinheiten werden als entsprechende Datentypen zu RDF-Literalen hinzugefügt. Darüber hinaus erkennt der Algorithmus Listen von Objekten, die als RDF-Listen repräsentiert werden. Ein Auszug der aus der Wikipedia-Seite über Busan extrahierten RDF-Tripel ist in Abb. 6 dargestellt. Details zur Infobox-Extraktion (inklusive Angaben zur Datentypen-Erkennung, Heuristiken zur Datensäuberung und Generierung von

³ <http://www.mediawiki.org>

⁴ <http://download.wikimedia.org/>

```
{{infobox City Korea|
  full_name=Busan Metropolitan City|
  image=[[Image:Haeundaebeachbusan.jpg|
    250px|Haeundae Beach, Busan]]|
  rr=Busan Gwangyeoksi|
  mr=Pusan Kwangyŏksi|
  hangul=부산 광역시|
  hanja=釜山廣域市|
  short_name=Busan (Pusan; 부산; 釜山)|
  population=3,635,389 ...|
  area=763.46 km²|
  government=[[Metropolitan cities of
    South Korea|Metropolitan City]]|
  divisions=15 wards (Gu),
    <br>1 county (Gun)|
  region=[[Yeongnam]]|
  dialect=[[Gyeongsang Dialect|
    Gyeongsang]]|
  map=[[Image:Busan map.png|Map of
    South Korea highlighting the city]]|
}}
```

Busan Metropolitan City



Korean name

Revised Romanization	Busan Gwangyeoksi
McCune-Reischauer	Pusan Kwangyŏksi
Hangul	부산 광역시
Hanja	釜山廣域市
Short name	Busan (Pusan; 부산; 釜山)

Abb. 5. Beispiel einer Wikipedia-Infobox-Vorlage und der erstellten Web-Ausgabe (Ausschnitt)

Busan	full_name	„Busan Metropolitan City“
Busan	image	Haeundaebeachbusan.jpg
Busan	rr	„Busan Gwangyeoksi“
Busan	mr	„Pusan Kwangyŏksi“
Busan	short	„Busan (Pusan;...)“
Busan	population	„3,657,840...“
Busan	area	„763.46 km2“
Busan	government	Metropolitan_cities_of_South_Korea
Busan	divisions	„15 wards (Gu), 1 county (Gun)“
Busan	region	Yeongnam
Busan	dialect	Gyeongsang_Dialect
Busan	map	Busan_map.png

Abb. 6. Auszug der aus der Wikipedia-Seite über Busan extrahierten RDF-Tripel

URIs) enthält die Publikation [3]. Alle Extraktionsalgorithmen sind in der Skriptsprache PHP implementiert und unter einer Open-Source-Lizenz veröffentlicht⁵.

⁵ <http://sf.net/projects/dbpedia>

Die DBpedia-Wissensbasis

Die DBpedia-Wissensbasis umfasst derzeit Informationen über mehr als 1,95 Millionen ‚Dinge‘, inklusive 80.000 Personen, 70.000 Orte, 35.000 Musik-Alben, 12.000 Filme. Sie enthält 657.000 Verweise zu Bildern, 1.600.000 Verweise zu relevanten externen Webseiten, 180.000 Verweise zu anderen RDF-Daten, 207.000 Wikipedia-Kategorien und 75.000 YAGO-Kategorien (siehe [28]). DBpedia-Konzepte sind darüberhinaus durch Kurz- und Langzusammenfassungen in 13 Sprachen beschrieben. Insgesamt besteht die DBpedia-Wissensbasis aus ca. 103 Millionen RDF-Tripeln.

Jede der 1,95 Millionen Ressourcen in den DBpedia-Datenpaketen ist durch einen eindeutigen URI-Bezeichner der Form `http://dbpedia.org/resource/Name` identifiziert. Name ist dabei vom Titel des jeweiligen Wikipedia-Artikels abgeleitet, der sich auch in den Web-Adressen der Wikipedia-Artikel widerspiegelt (z.B. `http://en.wikipedia.org/wiki/Name`). Damit ist jede DBpedia-Ressource direkt mit dem entsprechenden englischsprachigen Wikipedia-Artikel verknüpft. Dies resultiert in einer Reihe von vorteilhaften Eigenschaften der DBpedia-URI-Bezeichner:

- Es wird ein breites Spektrum enzyklopädischer Themen abgedeckt.
- Die Bezeichner sind Ergebnis eines Gemeinschaftskonsens.
- Es existieren klare Regeln für deren Management.
- Es existieren eine umfassende textuelle Beschreibung der Konzepte und Verweise zu einer maßgeblichen Webseite (der entsprechenden Wikipedia-Seite).

Die DBpedia-Wissensbasis wird in drei verschiedenen Formen über das Web zugänglich gemacht:

- *Vernetzte Daten*: Die Wissensbasis wird in Form vernetzter Daten veröffentlicht. Dies bedeutet, dass jede DBpedia-URI über das HTTP-Protokoll dereferenzierbar ist.
- *SPARQL-Endpoint*: Der DBpedia-SPARQL-Endpoint ermöglicht es Client-Anwendungen, Anfragen an DBpedia über das SPARQL-Protokoll zu stellen. Zusätzlich zur Standard-konformen SPARQL-Funktionalität, werden einige Funktionen bereitgestellt, die sich als besonders nützlich zur Generierung spezifischer Benutzerschnittstellen erwiesen haben. Dazu gehört eine Volltext-Suche über RDF-Literale, Aggregat-Funktionen zur statistischen Auswertung insbesondere zum Zählen von Anfrageergebnissen. Der SPARQL-Endpunkt wird durch einen Virtuoso Universal Server⁶ bereitgestellt.

⁶ <http://virtuoso.openlinksw.com>

- *RDF-Datenpakete*: Zusätzlich wird die DBpedia Wissensbasis auch in Form mehrerer Datenpakete, die jeweils zwischen einer und 60 Millionen RDF-Triples enthalten, zum Download angeboten.

DBpedia-Benutzerschnittstellen

Im Folgenden werden verschiedene Benutzerschnittstellen vorgestellt, über die sich die DBpedia-Wissensbasis erforschen und abfragen lässt.

Graph-Pattern-Builder

Verglichen mit anderen Semantic Web-Wissensbasen, die derzeit verfügbar sind, haben die DBpedia-Datenpakete eine andere Struktur. DBpedia enthält eine Fülle von relativ ungenau definierten Schema-Elementen, insbesondere RDF-Properties. Darüber hinaus beinhalten die DBpedia-Daten eine enorme Menge an Informationen zu diesem relativ vagen Informationsschema. Für einen Anwender ist es daher sehr schwer zu erkennen, welche Objekte und Properties in Anfragen verwendet werden können. Bestehende Werkzeuge fokussieren zudem meist auf große Mengen in nur einer der beiden Informationskategorien: Daten- oder Schemainformationen. Um Anwender trotzdem zu befähigen, diese Fülle an Informationen zu erschließen, müssen neue, alternative Benutzerschnittstellen entwickelt werden.

Eine solche neue Benutzerschnittstelle für große und inhomogen strukturierte Daten ist der Graph-Pattern-Builder. Anwender können mit ihm die Wissensbasis mittels Graph-Pattern bestehend aus mehreren Triple-Patterns anfragen. Ein Web-Formular erlaubt die Eingabe der Triple-Patterns. Für jedes Triple-Pattern existieren drei Formularfelder, in welche Variablen, Objektbezeichner oder Filteroperatoren für Subjekte, Prädikate oder Objekte eines Triples eingetragen werden können. Während Nutzer Objektbezeichner in die entsprechenden Formularfelder eintragen, wird im Hintergrund (per AJAX-Autovervollständigung) in der Wissensbasis nach passenden Objekten gesucht und diese werden dem Nutzer zur Auswahl angeboten. Die passenden Objekte sind dabei nicht beliebige, in denen der eingegebene Suchbegriff auftritt, sondern die komplette Suchanfrage wird mit dem entsprechenden Suchbegriff ausgeführt, und nur solche passenden Resultate werden angeboten, für die letztendlich auch Suchergebnisse für den kompletten Graph-Pattern existieren. Dies ermöglicht den Benutzern Suchanfragen zu stellen, ohne die genaue Struktur der Wissensbasis zu kennen und trotzdem relevante Ergebnisse zu bekommen. Abbildung 7 zeigt den Graph-Pattern-Builder.

UNIVERSITÄT LEIPZIG **DBpedia**

Query Wikipedia

This semantic database contains over 10 million statements extracted from the English Wikipedia.

search for queries

[Most popular](#) | [Upcoming](#)

[Tennis players from Moscow](#)

[Sitcoms set in NYC](#)

[Soccer player with tricot nr. 11, playing for a club having a stadium with >40.000 seats, born in a country with >10M inhabitants](#)

[People influenced by Friedrich Nietzsche](#)

[Films longer than 5 hours](#)

[Space Missions](#)

[Film music composer born 1965](#)

[People being 1.80m tall](#)

[List of Web browser software](#)

[Mayors of US cities higher than 1000m](#)

[Pictures of American guitarists](#)

[Battles in Saxony](#)

[What connects Innsbruck and Leipzig](#)

[Hip hop CDs from Texas Artists](#)

[Scientists and their doctoral advisors](#)

<< 1 >>

Soccer player with tricot nr. 11, playing for a club having a stadium with >40.000 seats, born in a country with >10M inhabitants

Subject	Predicate	Object
?player	currentclub	?club
?player	clubnumber	11
?player	countryofbirth	?country
?club	capacity	>40000
?country		>10000000
[+]	GDP_PPP (11)	
	population_estimate (10)	
	population_census (9)	
	established_date2 (8)	
	established_date1 (6)	
	established_date3 (5)	
	GDP_nominal (3)	
	accessionEUIDate (2)	

Click on a column header to filter results on this page. Results: 10

10 results found in 0.00s

Nr.	?player	?country	>40000	>10000000
1	Cicinho	Brazil	80354	187560000
2	Gonzalo Fierro	Colo-Colo	62000	16432674
3	Lukas Podolski	FC Bayern Munich	69901	38536869
4	Mark González	Liverpool F.C.	45362	47432000
5	Michael Thurk	Eintracht Frankfurt	52000	82438000
6	Ramón Morales	Chivas de Guadalajara	72480	107784179
7	Robin van Persie	Arsenal F.C.	60432	16336346
8	Stefano Mauri	S.S. Lazio	82656	58751711

Abb. 7. Formularbasierter Graph Pattern Builder für inhomogen strukturierte Wissensbasen wie z. B. DBpedia

DBpedia Relationship Finder

Der DBpedia Relationship Finder (Abb. 8) ist ein Werkzeug, um Verbindungen zwischen Objekten in Semantic Web Ontologien aufzudecken. Das bedeutet, dass zwischen zwei gegebenen Objekten, die einen Nutzer interessieren, mehrere mögliche Pfade über verschiedene in der betrachteten Wissensbasis vorhandene Objekteigenschaften präsentiert werden. Momentan wird der Relationship Finder speziell für DBpedia eingesetzt, aber kann mit leichten Änderungen auch für andere RDF-basierte Wissensbasen eingesetzt werden. Im Bereich Social Semantic Web könnten dies zum Beispiel die Analyse von Verbindungen zwischen Personen, Ereignissen und Plätzen sein. Für viele große Wissensbasen wären andere Darstellungsformen wie RDF-Graphen zu unübersichtlich.

Auf die Funktionsweise des DBpedia Relationship Finder soll hier nur kurz eingegangen werden: In einem ersten Vorverarbeitungsschritt zerlegt er den vorgegebenen RDF-Graphen in Komponenten, d.h. nicht zusammenhängende Knotenmengen, und speichert einige Zusatzinformationen zu den Objekten in den einzelnen Komponenten. Mit diesen Zusatzinformationen ist der Relationship Finder schnell in der Lage eine Verbindung zwischen zwei Objekten zu ermitteln. Um dann – wie in vielen Fällen gewünscht – auch die kürzesten Verbindungen zwischen Objekten zu errechnen, werden entsprechende Abfragen an den zugrunde liegenden Triple Store generiert.

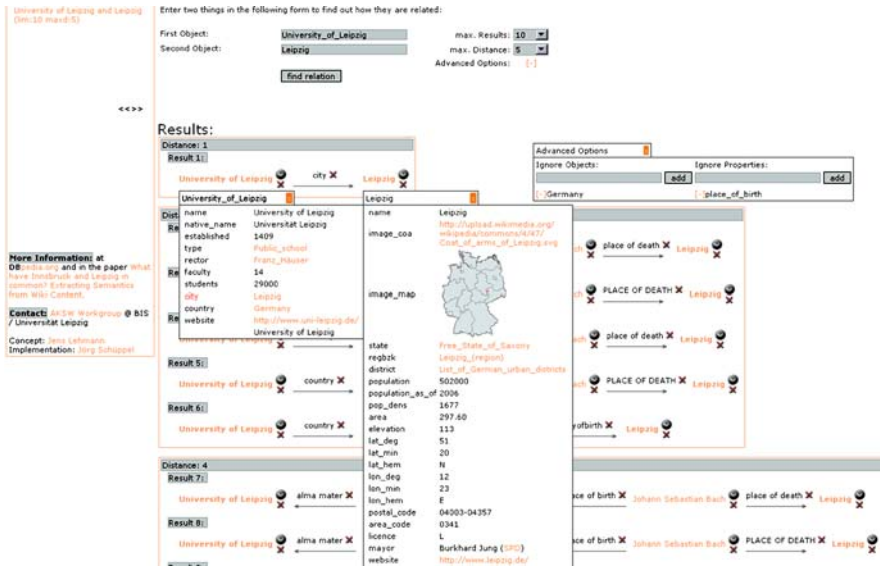


Abb. 8. DBpedia Relationship Finder im Einsatz

Jedes Objekt wird als Link zu der entsprechenden Wikipedia-Seite dargestellt. Durch Klicken eines Icons erhält man in DBpedia enthaltene Zusatzinformationen zu jedem Objekt. Diese Informationen werden, falls notwendig, als Grafiken, Listen, Links usw. dargestellt.

Semantische Mashups

Dieser Abschnitt gibt einen Überblick über verschiedene Mashups, die vernetzte Daten nutzen. Es werden sowohl generische Mashups wie Browser und Suchmaschinen für vernetzte Daten vorgestellt als auch anwendungsspezifische Portale wie z. B. der DOAP Store.

Generische Browser für vernetzte Daten

Generische Browser für vernetzte Daten ermöglichen die integrierte Darstellung von Daten aus verschiedenen Datenquellen und die Navigation zwischen Datenquellen anhand von RDF-Verweisen. Browser für vernetzte Daten unterscheiden sich von allgemeinen RDF-Browsern darin, dass sie nicht davon ausgehen, dass die zu visualisierenden RDF-Daten bereits lokal in einem Repository vorliegen, sondern dass sie Daten, je nach Navigationspfad des Nutzers, dynamisch aus dem Web nachladen.




Abb. 9. Benutzerschnittstelle des DISCO Browsers

Beispiele generischer Browser für vernetzte Daten:

- *Tabulator* [29] war der erste verfügbare Browser für vernetzte Daten. Der Browser wurde von der Arbeitsgruppe um Tim Berners-Lee am Massachusetts Institute of Technology entwickelt. Tabulator visualisiert vernetzte Daten in Form eines Baums, in dem jeder Knoten einer Ressource entspricht. Durch Ausklappen einzelner Ressourcen navigiert der Benutzer zwischen Datenquellen. Zusätzlich zur Baumansicht bietet Tabulator auch die Möglichkeit, Abfragen gegen geladene Daten zu stellen und geladene Daten auf einer Landkarte zu visualisieren.
- Der *OpenLink RDF Browser*⁷ ermöglicht es, vernetzte Daten mittels unterschiedlicher AJAX-Komponenten in Tabellenform, als Graph, als Zeitreihe sowie als Fotoalbum oder auf einer Landkarte darzustellen. Der Browser unterstützt die RDF-Stylesheet-Sprache Fresnel [9].

⁷ <http://demo.openlinksw.com/DAV/JS/rdfbrowser/index.html>

- Der *Zitgist-Browser*⁸ bietet unterschiedliche Vorlagen zur benutzerfreundlichen Visualisierung bekannter Typen von Daten wie Personen, Musikern oder Musikalben.
- Der *DISCO Browser*⁹ wurde an der Freien Universität Berlin entwickelt. Ziel war es, einen Browser mit einer minimalistischen Benutzerschnittstelle zu entwerfen, welche die Herkunft von Daten aus unterschiedlichen Quellen klar hervorhebt. Abbildung 9 zeigt die Benutzerschnittstelle des DISCO Browsers. Unterhalb der Navigationsbox werden alle Informationen, die der Browser in unterschiedlichen Datenquellen zu einer Ressource gefunden hat, gemeinsam angezeigt. Am Ende jeder Zeile werden die Datenquellen aufgeführt, aus denen die jeweilige Information stammt.

Suchmaschinen und Verzeichnisdienste für vernetzte Daten

Suchmaschinen für vernetzte Daten verwenden Crawler, die Verknüpfungen zwischen Datensätzen folgen, um Daten aus verschiedenen Web-Datenquellen zu einer lokalen Datenbasis zusammenzufassen. Die Suchmaschinen indizieren diese Datenbasis und ermöglichen es Anfragen gegen die indizierten Inhalte zu stellen.

Beispiele derartiger Suchmaschinen:

- *Swoogle*¹⁰ ist einer der ersten Vertreter semantischer Suchmaschinen. Swoogle sucht stichwortbasiert und nutzt damit die Möglichkeiten semantischer Auszeichnung nur sehr begrenzt. Technisch basiert Swoogle auf der Text-Suchmaschine Lucene des Apache-Projekts.
- Die *Semantic Web Search Engine (SWSE)*¹¹ geht einen Schritt weiter, indem zusätzlich zu einem Volltextindex über den Inhalten von Wissensbasen der jeweilige Inhaltstyp indiziert wird. Eine SWSE-Suche kann also auf in den Ergebnisdokumenten gefundene Typen (wie z. B. Personen, Orte etc.) eingeschränkt werden. Diese Typen müssen dabei nicht im Voraus festgelegt werden, sondern werden aus entsprechenden `[rdf:type]-Properties` (zu Objekten aus den RDF-Dokumenten) gewonnen. Swoogle indiziert derzeit etwa 2,3 Millionen RDF Dokumente.
- Die *Sindice*¹² Suchmaschine indiziert derzeit etwa 11 Millionen RDF-Dokumente. Die Suchmaschine ermöglicht es semantischen Mashups,

⁸ <http://browser.zitgist.com/>

⁹ <http://sites.wiwiss.fu-berlin.de/suhl/bizer/ng4j/disco/>

¹⁰ <http://swoogle.umbc.edu>

¹¹ <http://swse.deri.org>

¹² <http://www.sindice.com/>

alle bekannten Dokumente, in denen eine spezielle URI verwendet wird, zu finden.

- *Falcons*¹³ indiziert derzeit circa 2 Millionen RDF-Dokumente. Neben der eigentlichen Suchfunktionalität bietet Falcons auch einen Daten-Browser, mittels dessen sich die Suchergebnisse analysieren lassen.

Ein Beispiel eines Verzeichnisdienstes für Linked Data bzw. Verlinkte Daten ist PingtheSemanticWeb.com (PTSW). Ping-The-Semantic-Web ist ein Web Service, der Aufschluss darüber gibt, welche RDF-Dokumente kürzlich im Web erstellt oder aktualisiert wurden. Autoren und Editoren von solchen Dokumenten benachrichtigen PTSW darüber, indem sie die URL des erstellten oder geänderten Dokuments übermitteln. PTSW ist also eine Art Basiskomponente einer semantischen Suchmaschine, da sie von Crawlern und anderen Software-Agenten genutzt werden kann um herauszufinden, wo zuletzt aktualisierte RDF-Dokumente gefunden werden können.

Portale auf Basis vernetzter Daten

Portale sind Einstiegspunkte im Web zu bestimmten Themen. Portale greifen dazu auf mehrere Inhaltsquellen zu und aggregieren und präsentieren diese in einer anwendungsdomänenspezifischen Weise.

Ein Portal auf der Basis vernetzter Daten ist zum Beispiel Revyu.¹⁴ Revyu ermöglicht es, Dinge beliebiger Art zu bewerten und mit (persönlichen) Kommentaren zu versehen. Revyu nutzt nicht nur vernetzte Daten zum Annotieren von Bewertungen, sondern stellt vernetzte Daten für alle Dinge in der Revyu-Wissensbasis für Dritte bereit. Generell überwiegt bei Revyu der Anteil anwendergenerierter Daten im Gegensatz zur Nutzung bestehender Quellen vernetzter Daten.

Ein weiteres Beispiel eines semantischen Portals ist DOAP-Store,¹⁵ der Informationen über Forschungs- sowie Open Source Software-Entwicklungsprojekte bereitstellt. Die Funktionsweise von DOAP-Store unterscheidet sich stark von Revyu. DOAP-Store nutzt keinerlei direkt anwendergenerierten Inhalte, sondern sucht RDF-Dokumente im Web, die Informationen enthalten, die mittels des DOAP-Vokabulars¹⁶ ausgedrückt sind. Um entsprechende Dokumente zu finden nutzt DOAP-Store den Service Ping-The-Semantic-Web Verzeichnisdienst.

¹³ <http://iws.seu.edu.cn/services/falcons/>

¹⁴ <http://revyu.com>

¹⁵ <http://doapstore.org>

¹⁶ Description Of A Project: <http://usefulinc.com/doap>

Reasoning im Social Semantic Web

Mittels in Form von Ontologien repräsentierten Wissens lässt sich die Funktionalität von Semantischen Mashups weiter verbessern. Dabei wird auf Erkenntnisse innerhalb der Wissensrepräsentation zurückgegriffen, die sich über Jahrzehnte entwickelt haben. Neben der reinen Modellierung von Wissen, das heißt dem Festlegen einer Terminologie und den Beziehungen zwischen diesen Termen, wird dabei auch das Ziehen von Schlussfolgerungen (englisch: Reasoning) aus dem vorhandenen Wissen ermöglicht. Am häufigsten wird dabei sogenanntes deduktives Reasoning betrachtet. Es bedeutet, dass aus explizit gespeicherten Fakten weiteres implizit vorhandenes Wissen ermittelt werden kann. Wir betrachten hier zusätzlich das induktive Reasoning (eine Teildisziplin des maschinellen Lernens), bei dem aus dem vorhandenen Wissen allgemeinere Behauptungen aufgestellt werden. Im Gegensatz zu anderen Bereichen der Wissensrepräsentation sind Wissensmodelle im Social Web oft weniger formalisierbar, sehr groß, unvollständig und oft sogar widersprüchlich. Wir werden beschreiben, wie auf diese spezifischen Anforderungen eingegangen werden kann.

Überblick über Reasoning

Das Modellieren von Wissen in Form von Ontologien ist zentraler Bestandteil des Semantic Web. Ausgehend von frühen Formen der Wissensrepräsentation, wie Frames und Semantischen Netzen, haben sich seit Ende der 1980er Jahre Beschreibungslogiken entwickelt. Aus einer Reihe verschiedener Gründe wurden Beschreibungslogiken als Basis der Ontologiesprache OWL gewählt, die das formale Rückgrat des Semantic Web bildet. Dank dieser logischen Basis haben OWL-Ontologien eine klare Semantik, das heißt neben der rein syntaktischen Repräsentation einer Ontologie kann man ihr auch eine Bedeutung zuweisen. Eine wohldefinierte Semantik bietet die Möglichkeit, Schlüsse aus dem gespeicherten Wissen zu ziehen. Mit dem Ziehen solcher Schlüsse speziell im Kontext eines Social Semantic Web befasst sich dieses Kapitel.

Die häufigste Form des Reasoning ist dabei das deduktive Reasoning, das heißt aus den explizit gespeicherten Fakten wird implizites Wissen geschlossen. Ein einfaches Beispiel ist folgendes:

Nehmen wir an, unsere Ontologie enthält das Wissen, dass Anna eine Mutter ist und jede Mutter auch eine Frau ist:

Anna	<code>rdf:type</code>	Mutter
Mutter	<code>rdfs:subClassOf</code>	Frau

Daraus lässt sich schlussfolgern, dass Anna eine Frau ist.

Durch die vielfältigen Sprachkonstrukte, die OWL besitzt, kann das Ziehen von Schlüssen ein komplexer Prozess sein. Es haben sich unterschiedliche Algorithmen und Programme entwickelt, von denen ein Ansatz in Abschn. 3 vorgestellt wird.

Neben dem deduktiven Reasoning möchten wir hier auch auf induktives Reasoning eingehen. Induktives Reasoning ist der Lernprozess, bei dem aus vorhandenem Faktenwissen allgemeinere Behauptungen aufgestellt werden. Dies sei wieder an einem kurzen Beispiel illustriert:

Nehmen wir wieder an, es sei eine Ontologie mit folgendem Wissen gegeben:

Anna	<code>rdf:type</code>	Frau
Anna	<code>hasChild</code>	Franz
Beate	<code>rdf:type</code>	Frau

Beim induktiven Reasoning wird eine bisher nicht existierende Klasse aus dem Faktenwissen gelernt. Man wählt dazu positive und negative Beispiele für eine Klasse aus. Nehmen wir an, ein bisher nicht definiertes Konzept Mutter soll gelernt werden und Anna wird als positives, sowie Beate als negatives Beispiel ausgewählt. Dann kann ein Lernprogramm die Klassendefinition $\text{Frau} \sqcap \exists \text{hasChild}$ („Frau mit Kind“ in üblicher Beschreibungsslogiksyntax ausgedruckt) aufstellen.

Im Gegensatz zum deduktiven Reasoning werden beim induktiven Reasoning keine sich aus der Ontologie ergebenden Erkenntnisse gefunden, sondern Behauptungen aufgestellt, die zu dem vorhandenen Wissen passen. Insbesondere kann es mehrere oder keine möglichen Lösungen für ein bestimmtes Lernproblem geben. Wie das induktive Reasoning funktioniert, wird in Kapitel 4 beschrieben. Zuerst soll auf einige Spezifika von Reasoning im Social Semantic Web eingegangen werden.

Social Semantic Web-Anforderungen

Wissensmodelle im Social Web sind oft weniger formalisierbar, sehr groß, unvollständig und oft sogar widersprüchlich. Daher müssen gängige Verfahren des Reasoning für das Social Semantic Web adaptiert werden. Beispiele für häufig auftretende Reasoningprobleme sind:

Symmetrie

Eines der meist verwendeten Vokabulare im Social Semantic Web ist das Friend-of-a-Friend Vokabular. Es erlaubt z. B. Aussagen der Form:

Klaus	<code>foaf:knows</code>	Petra
-------	-------------------------	-------

Erweiterungen zum FOAF-Vokabular (z. B. [23]) schlagen vor diese Beziehung weiter zu spezialisieren wie z. B. mit Eigenschaften `|friendOf`, `|spouseOf` oder `|siblingOf`. Diese Beziehungen sollten dabei in einer Social Semantic Web-Applikation als symmetrische Beziehung interpretiert werden und folglich soll aus der Aussage:

Petra spouseOf Klaus

die Aussage

Klaus spouseOf Petra

schlussgefolgert werden können. Auch DBpedia enthält eine Reihe solcher symmetrischer RDF-Properties.

Klassenhierarchie

Wissensbasen im Social Semantic Web enthalten oft eine Form von Kategorien oder Klassenhierarchie. DBpedia z. B. enthält über 200.000 Kategorien. Kategorien sind z. B. „Städte in Europa“, „Städte in Deutschland“ und „Städte in Sachsen“, die erste und zweite sowie die zweite und dritte sind durch eine Sub-Kategorienbeziehung miteinander verknüpft, nicht jedoch „Städte in Europa“ und „Städte in Sachsen“. Eine Social Semantic Web-Applikation soll nun in der Lage sein, dieses implizite Wissen der transitiven Sub-Klassenbeziehung zu nutzen.

Klassifikation

Das Inferenzproblem der Klassifikation tritt auf, wenn zu einer gegebenen Klasse (oder Kategorie) alle durch diese Klasse umfassten Instanzen ermittelt werden sollen. Nicht immer sind diese Klassen-Instanzen-Beziehungen explizit (mittels der RDF-Property `|rdf:type`) gegeben. So sind Artikel über Städte in Sachsen zwar der Kategorie „Städte in Sachsen“ zugeordnet, nicht jedoch den Kategorien „Städte in Deutschland“ oder „Städte in Europa“. Eine Social Semantic Web-Applikation, wie der im vorangegangenen Abschnitt vorgestellte Graph Pattern Builder, sollte solche impliziten Informationen jedoch berücksichtigen.

Wie der Anwendungsfall DBpedia zeigt, ist eine der wichtigsten Anforderungen von Social Semantic Web-Anwendungen an Reasoningalgorithmen Skalierbarkeit. Im folgenden Abschnitt stellen wir eine Strategie vor, wie skalierbares Reasoning auf der Basis relationaler Datenbanken, wie sie für die Implementierung von Semantischen Mashups und Social Semantic Web Anwendungen eingesetzt werden, realisiert werden kann.

Skalierbares Reasoning auf Basis relationaler Datenbanken

In Semantic Web-Anwendungen werden meist entweder relationale Datenbanken oder spezialisierte Triple-Stores zur persistenten Speicherung eingesetzt. Vertreter spezialisierter Triple-Stores sind Sesame [18] oder Redland [6], auf relationaler Datenbankbasis arbeitet z. B. RAP [25]. Reasoner arbeiten dagegen meist im Hauptspeicher und mit Datenstrukturen, die mit relationalen Datenbanken inkompatibel sind. Die Serialisierung, Übertragung und Verarbeitung von Wissensbasen zwischen Datenbank oder Triple-Store und Reasoner ist sehr zeitaufwändig, daher für Semantic Web Anwendungen mit großen Wissensbasen oft nicht praktikabel.

Eine Alternative sind regelbasierte Inferenzsysteme, die direkt auf dem Tripel-Datenmodell arbeiten. In der Arbeit von Royer und Quantz [27] werden Beschreibungslogiken analysiert und ein System (für bestimmte Reasoningaufgaben) vollständiger Inferenzregeln aufgestellt. Diese Inferenzregeln lassen sich direkt in Anfragen auf dem Triple-Datenmodell übersetzen, deren Anfrageergebnisse können als inferierte Aussagen direkt wieder zur Wissensbasis hinzugefügt werden.

Wir illustrieren das mit SPARQL-Anfragen für die drei erwähnten Reasoningaufgaben Symmetrie, Klassenhierarchie und Klassifikation:

```
CONSTRUCT {?i2?p?i1} WHERE {
  ?p <rdf:type> <owl:SymmetricProperty>.
  ?i1?p?i2
}
```

```
CONSTRUCT {?c1 <rdfs:subClassOf>?c3} WHERE {
  ?c1 <rdfs:subClassOf>?c2.
  ?c2 <rdfs:subClassOf>? c3
}
```

```
CONSTRUCT {?i <rdfs:type>?c2} WHERE {
  ?i <rdf:type>?c1.
  ?c1 <rdfs:subClassOf>?c2
}
```

Diese drei SPARQL-Anfragen liefern exakt die für Inferenzaufgaben notwendigen Triples. Die Ergebnisse der Anfragen können also zur Wissensbasis hinzugefügt werden und die impliziten Informationen sind damit für weitere Anfragen verfügbar. Die dargestellten Beispiele stellen allerdings nur einen kleinen Teil der Inferenzregeln dar, die aus der OWL-Semantik abgeleitet werden können. Für eine detailliertere und umfassendere Darstellung verweisen wir auf [27] und [1]. Einige Inferenzregeln lassen sich bislang auch nicht mittels SPARQL-Anfragen ausdrücken, da

SPARQL z. B. Funktionen zum Zählen und Aggregieren von Ergebnissen fehlen. Mit SQL-Anfragen, die auf einem Datenbankschema zur Speicherung von Triples ausgeführt werden, sind entsprechende Inferenzen jedoch möglich. Da die inferierten Aussagen einer Inferenzregel (oder SPARQL/SQL-Anfrage) die Ergebnisse weiterer Inferenzregeln beeinflussen, ist eine mehrfache Ausführung der Abfragen bis zum Erreichen eines Fixpunktes notwendig.

Die in diesem Abschnitt beispielhaft umrissene Vorgehensweise zur Implementierung skalierbaren Reasonings auf Basis relationaler Datenbanken hat einige entscheidende Vorteile: Die Algorithmen arbeiten direkt mit der nativen Datenhaltung der Wissensbasen in Semantischen Web-Anwendungen. Das Serialisieren, Übertragen, De-Serialisieren etc., das bei Verwendung verschiedener Repräsentationsformen, wie z. B. Datenbanken und tableaubasierten Reasoner auftritt, entfällt. Es kann sehr spezifisch festgelegt werden, welche Inferenzregeln berücksichtigt werden sollen und welche nicht, und es können dadurch wesentliche Geschwindigkeitsverbesserungen für spezifische Reasoningaufgaben erreicht werden.

Induktives Reasoning im Social Semantic Web

Das in der Einleitung des Reasoning-Abschnitts kurz eingeführte induktive Reasoning soll hier kurz dargestellt werden. Das sogenannte Lernproblem (genauer gesagt, eine mögliche Variante des Lernproblems) besteht darin, bei gegebenem Hintergrundwissen und positiven und negativen Beispielen eine Konzeptdefinition zu finden, so dass alle positiven Beispiele aus dieser Definition (und dem bereits vorhandenen Hintergrundwissen) folgen, die negativen Beispiele jedoch nicht. Das Problem lässt sich auch für andere Wissensrepräsentationssprachen außer OWL betrachten und wird hauptsächlich im Bereich der induktiven Logikprogrammierung [24] erforscht. In der Literatur wurden verschiedene Ansätze zur Lösung des Lernproblems vorgestellt [4, 15, 16, 17].

Eines der existierenden Lernsysteme ist DL-Learner,¹⁷ welches als Open Source verfügbar ist.¹⁸ Eine schematische Darstellung der groben Funktionsweise des DL-Learner und anderer Ansätze findet sich in Abb. 10. Die Funktionsweise beruht darauf, dass ein intelligenter Algorithmus mögliche Konzeptdefinitionen vorschlägt. Diese werden durch einen Reasoner getestet und das dadurch erhaltene Feedback fließt wieder in den Kernalgorithmus ein. Konkrete Beschreibungen der verwendeten Algorithmen im DL-Learner finden sich in [20, 21, 22]. Induktives Reasoning beruht

¹⁷ <http://dl-learner.org>

¹⁸ <http://sf.net/projects/dl-learner>




Abb. 10. Lernansatz „generate and test“

in diesem Fall also auf einer potentiell großen Anzahl an deduktiven Reasoning-Anfragen.

Im Social Semantic Web hat man häufig sehr große verteilte Wissensbasen, so dass sich die Frage stellt, ob solche Lernsysteme geeignet sind um in diesem Kontext angewandt werden zu können. Oft sind diese Wissensbasen, wie im Beispiel DBpedia, als vernetzte Daten vorhanden, über die man mit Hilfe eines SPARQL-Endpunkts Anfragen stellen kann. Aus diesem Grund unterstützt das DL-Learner-Tool direkt SPARQL-Endpunkte als Hintergrundwissen. Um eine Skalierbarkeit der Ansätze zu gewähren, wählt der DL-Learner dabei durch mehrere SPARQL-Anfragen einen Teil des im SPARQL-Endpunkt vorhandenen Wissens aus und schickt dieses an den Reasoner. Somit wird beim Lernen nicht das komplette Wissen berücksichtigt, sondern nur ein für das konkrete Problem möglichst relevanter Teil ausgewählt.

Als Beispiel für ein solches Problem kehren wir wieder zu DBpedia als einer der größten Wissensbasen zurück. Nehmen wir an, jemand stellt eine Anfrage mit den positiven Beispielen „Pythagoras“, „Philolaus“ und „Archytas“ und den negativen Beispielen „Socrates“, „Plato“, „Zeno of Elea“ und „Democritus“ mit DBpedia als Hintergrundwissen. Das kann zum Beispiel für eine Internetrecherche relevant sein, bei der jemand Wissen über bestimmte Personen (die positiven Beispiele) und zu ihnen

semantisch verbunden Personen gewinnen möchte, aber andere Personen, die nicht Teile seiner Recherche sind (die negativen Beispiele) ausschließt. Das DL-Learner-SPARQL-Modul setzt dann zuerst Anfragen an den DBpedia-SPARQL-Endpunkt ab um relevante Informationen zu erhalten. Das gewonnene Wissen in OWL-Form wird dem Reasoner mitgeteilt und der Kernalgorithmus gestartet. Dieser ermittelt in diesem Fall `mathematician  $\sqcap$  (physicist  $\sqcup$  vegetarian)` (Mathematiker, die zusätzlich entweder Vegetarier oder Physiker sind) als eine mögliche Lösung. Alle positiven und keines der negativen Beispiele folgen aus dieser Definition. Mit diesen Techniken könnten in Zukunft auch für das Social Semantic Web typische große Wissensbasen, die über einen SPARQL-Endpoint oder als vernetzte Daten (siehe Abschn. 2) publiziert wurden, analysiert werden oder neue Klassen in diesen Wissensbasen gelernt werden, insbesondere um das Anfragen großer heterogener Datenbestände zu unterstützen.

Zusammenfassung und Ausblick

Dieses Kapitel stellte mit dem Web-Datenintegrationsrahmenwerk vernetzte Daten, dem DBpedia-Projekt zur Extraktion strukturierter Informationen aus Wikipedia und Ansätzen zur Lösung spezifischer Inferenzprobleme drei zentrale Elemente semantischer Mashups vor. Wir haben einen Überblick über erste Beispiele semantischer Mashups gegeben. Die vorgestellten Ansätze und Beispiele sind jedoch nur der Beginn einer Entwicklung, die einerseits weitere technologische Felder erfassen und andererseits die bestehenden Ansätze weiter vertiefen muss, um einen nachhaltigen Einfluss auf das Web zu entfalten.

Herausforderungen, denen wir gegenüberstehen, sind zum Beispiel:

- Semantische Mashups, die Daten aus einer Vielzahl an Quellen nutzen, sind mit verschiedenen Informationsqualitätsproblemen konfrontiert. Eine Analyse der DBpedia-Datenpakete z. B. zeigt, dass Informationen oft noch nicht auf eine Weise repräsentiert sind, die einfache Integration und Querying ermöglichen.
- Wenn es um die Integration personenbezogener Daten im Web geht, sind der Schutz der Privatsphäre sowie die klare Auszeichnung der Daten mit Lizenzinformationen, die bestimmen, wofür Daten verwendet werden dürfen, essentiell. Erste Ansätze in dieser Hinsicht sind die Abbildung von Privacy-Präferenzen z. B. mittels P3P oder das Lizenzieren von Semantic Webinhalten mittels Creative Commons.

- Projekte wie CyC oder SUMO haben relativ umfassende Upper-Level-Ontologien, Klassifikationssysteme und Informations-Taxonomien hervorgebracht. Im Rahmen von DBpedia wurden vor allem Instanz-Daten aus Wikipedia extrahiert. Wir sind zuversichtlich, dass eine stärkere Integration von Upper-Level-Ontologien und DBpedia ein enormes Potential zur Erleichterung von Informationsintegration im Web birgt.
- Die erwähnte Integration von Upper-Level-Ontologien und Instanzdaten kann andererseits dazu beitragen, Inkonsistenzen und Lücken in Informationsquellen und Wissensbasen des sozialen Webs (wie z. B. Wikipedia) aufzudecken und zu schließen.
- Das semantisch reichste DBpedia-Datenpaket resultiert aus der Infobox-Extraktion. Dies wurde bislang nur für die englische Wikipedia-Version erstellt. Die Erstellung von Infobox-Extraktionen für weitere Sprachversionen birgt das Potential, die DBpedia-Wissensbasis wesentlich zu vergrößern, stellt uns aber andererseits vor die Herausforderungen diese verschiedenen Sprachversionen sinnvoll zu integrieren.

Viele dieser Probleme können gelöst werden, indem bestehende Ansätze und Technologien sinnvoll kombiniert und erweitert werden. Wir sind überzeugt, dass eine solche iterative Weiterentwicklung und Konsolidierung des Konzeptes semantischer Mashups letztendlich einen entscheidenden Beitrag leisten wird, das Potential semantischer Repräsentationen für Suchfunktionen und Informationsaustausch im Netz zu realisieren.

Literatur

1. Sören Auer and Zachary Ives. Integrating ontologies and relational data. Technical Report MS-CIS-07-24, Computer and Information Sciences Department, School of Engineering and Applied Science, University of Pennsylvania, 3330 Walnut Street Philadelphia, PA 19104-6389, Oct 2007.
2. Sören Auer, Christian Bizer, Jens Lehmann, Georgi Kobilarov, Richard Cyganiak, and Zachary Ives. DBpedia: A nucleus for a web of open data. In Proceedings of the International Semantic Web Conference (ISWC 2007), 2007.
3. Sören Auer and Jens Lehmann. What have innsbruck and leipzig in common? extracting semantics from wiki content. In Enrico Franconi, Michael Kifer, and Wolfgang May, editors, ESWC, volume 4519 of Lecture Notes in Computer Science, pages 503–517. Springer, 2007.
4. Liviu Badea and Shan-Hwei Nienhuys-Cheng. A refinement operator for description logics. In J. Cussens and A. Frisch, editors, Proceedings of the 10th International Conference on Inductive Logic Programming, volume 1866 of Lecture Notes in Artificial Intelligence, pages 40–59. Springer-Verlag, 2000.
5. D. Beckett. Turtle – Terse RDF Triple Language.
<http://www.ilrt.bris.ac.uk/discovery/2004/01/turtle/>, 2004.

6. David Beckett. The design and implementation of the redland RDF application framework. In *Proceedings of the Tenth InternationalWorldWideWeb Conference (WWW2001)*, February 16 2001.
7. Tim Berners-Lee. Linked data, 2006. <http://www.w3.org/DesignIssues/LinkedData.html>.
8. Chris Bizer and Richard Cyganiak. D2r server – publishing relational databases on the semantic web, 2007. <http://sites.wiwiss.fu-berlin.de/suhl/bizer/d2r-server/>.
9. Chris Bizer, Ryan Lee, and Emmanuel Pietriga. Fresnel – display vocabulary for RDF, 2004.
10. Christian Bizer, Richard Cyganiak, and Tobias Gauß. The RDF Book Mashup: From Web APIs to a Web of Data. In *Proceedings of the 3rd Workshop on Scripting for the Semantic Web*, 2007.
11. Christian Bizer, Richard Cyganiak, and Tom Heath. How to publish linked data on the web, 2007. <http://sites.wiwiss.fu-berlin.de/suhl/bizer/pub/LinkedDataTutorial/>.
12. John Breslin. Sioc exporters, 2007. <http://sioc-project.org/exporters>.
13. Richard Cyganiak and Chris Bizer. Pubby – a linked data frontend for sparql endpoints, 2007. <http://www4.wiwiss.fu-berlin.de/pubby/>.
14. Orri Erling and Ivan Mikhailov. RDF support in the Virtuoso DBMS. volume P-113 of *GI-Edition – Lecture Notes in Informatics (LNI)*, ISSN 1617-5468. Bonner Köllen Verlag, September 2007.
15. Nicola Fanizzi, Luigi Iannone, Ignazio Palmisano, and Giovanni Semeraro. Concept formation in expressive description logics. In *Machine Learning: ECML 2004, 15th European Conference on Machine Learning, Pisa, Italy, September 20–24, 2004, Proceedings*. Springer, 2004.
16. Luigi Iannone and Ignazio Palmisano. An algorithm based on counterfactuals for concept learning in the semantic web. In *Proceedings of the 18th International Conference on Industrial and Engineering Applications of Artificial Intelligence and Expert Systems*, pages 370–379, Bari, Italy, June 2005.
17. Luigi Iannone, Ignazio Palmisano, and Nicola Fanizzi. An algorithm based on counterfactuals for concept learning in the semantic web. *Applied Intelligence*, 26(2):139–159, 2007.
18. Arjohn Kampman, Frank Van Harmelen, and Jeen Broekstra. Sesame: An architecture for storing and querying RDF data and schema information, July 03 2001.
19. Graham Klyne and Jeremy J. Carroll. Resource Description Framework (RDF): Concepts and Abstract Syntax – W3C Recommendation, 2004. <http://www.w3.org/TR/rdf-concepts/>.
20. Jens Lehmann. Hybrid learning of ontology classes. In *Proceedings of the 5th International Conference on Machine Learning and Data Mining, MLDM 2007*. Springer, 2007.
21. Jens Lehmann and Pascal Hitzler. Foundations of refinement operators for description logics. In *Proceedings of the 17th International Conference on Inductive Logic Programming (ILP)*. Springer, 2007.

22. Jens Lehmann and Pascal Hitzler. A refinement operator based learning algorithm for the alc description logic. In *Proceedings of the 17th International Conference on Inductive Logic Programming (ILP)*. Springer, 2007.
23. Yutaka Matsuo, Masahiro Hamasaki, Junichiro Mori, Hideaki Takeda, and Koiti Hasida. Ontological consideration on human relationship vocabulary for foaf. In *SWAD-Europe Final Workshop „Friend of a Friend, Social Networking and the Semantic Web“*, held 1–2 September 2004 in Galway, Ireland, 2004.
24. Shan-Hwei Nienhuys-Cheng and Ronald de Wolf, editors. *Foundations of Inductive Logic Programming*. Lecture Notes in Computer Science. Springer, 1997.
25. Radoslaw Oldakowski, Christian Bizer, and Daniel Westphal. RAP: RDF API for PHP. In Sören Auer, Chris Bizer, and Libby Miller, editors, *Proceedings of the Workshop Scripting for the Semantic Web*, number 135 in *CEUR-Workshop Proceedings*, Heraklion, Greece, 05 2005.
26. o.V. Linking open data – w3c sweo community project, 2007. <http://esw.w3.org/topic/SweoIG/TaskForces/CommunityProjects/LinkingOpenData>.
27. Veronique Royer and J. Joachim Quantz. Deriving inference rules for description logics: a rewriting approach into sequent calculi. Technical Report TUB-FB13-KIT-111, KIT Project Group Publications, December 1 1993. Tue, 07 Nov 1995 19:31:17 GMT.
28. Fabian M. Suchanek, Gjergji Kasneci, and Gerhard Weikum. Yago: A Core of Semantic Knowledge. In *16th international World Wide Web conference (WWW 2007)*, New York, NY, USA, 2007. ACM Press.
29. Tim Berners-Lee et al. Tabulator: Exploring and analyzing linked data on the semanticweb. In *Proceedings of the 3rd International Semantic Web User Interaction Workshop*, 2006. <http://swui.semanticweb.org/swui06/papers/Berners-Lee/Berners-Lee.pdf>.

III Anwendungen und Perspektiven

15. Web-gestütztes Social Networking am Beispiel der „Plattform Wissensmanagement“

Stefanie N. Lindstaedt und Claudia Thurner

Know-Center, Graz, Austria
{slind; cthurner}@know-center.at

Zusammenfassung: Anhand der Plattform Wissensmanagement, der größten deutschsprachigen Community im Themenfeld Wissensmanagement, werden organisationale Rahmenbedingungen, technische Werkzeuge und Rollen der Moderatorin diskutiert, die Bedingungen für den erfolgreichen Betrieb einer Community im Web 2.0 sind. Weiters wird dargestellt, wie Communities für das betriebliche Wissensmanagement eingesetzt werden können.

Einleitung

Technologien, die Online-Kollaborationen und Mitarbeiterbeteiligungen fördern, gewinnen unternehmensweit an Zugkraft. Bekannte Beispiele dafür sind u. a. Blogs, die um Verbraucher- bzw. Käuferfeedback bitten, und Wikis, die den Mitarbeitern einer Firma erlauben, zusammen an Dokumenten zu arbeiten. Allerdings haben nur wenige Firmen bzw. Organisationen ein klares Verständnis von den tatsächlichen Motiven, die einen Nutzer dazu bewegen, sich an derartigen Projekten zu beteiligen.¹ Das Verständnis um diese Motive und Bedingungen bildet eine wichtige Voraussetzung zum Einsatz von Social Networking Tools. Das bedeutet weiters, dass aufbauend auf den Beweggründen des kollaborativen Zusammenarbeitens, das Verständnis um Social Networking weiterentwickelt werden kann.

Ziel dieses Kapitels ist es, die Möglichkeiten, Nutzung und Erfahrungen mit Social Networking Ansätzen und Technologien am Beispiel der Plattform Wissensmanagement (PWM) zu beleuchten. Hierzu werden zunächst die wichtigsten Social Networking Charakteristiken herausgearbeitet und

¹ Vgl. „How businesses are using Web 2.0: A McKinsey Global Survey“, The McKinsey Quarterly, Web exclusive, March 2007.

dann am Beispiel der PWM illustriert. Hierbei wird einerseits auf die Einbettung in die Community eingegangen und andererseits die technische Umsetzung auf Basis von Web 2.0 Technologien erörtert. Erste Nutzungserfahrungen und Umfrageanalysen runden das Bild ab. Die PWM-Community ist seit ihrer Gründung stetig im Wachsen begriffen, so wurde zum Vergleich im Mai 2006 das 1000. Mitglied gezählt; im Juli 2007 meldete sich das 1.260. Mitglied auf der Plattform an. Das Internet-Portal verzeichnete im Mai 2006 rund 800 Besucher täglich und wird ein Jahr später von durchschnittlich 1.900 Besuchern täglich genutzt. Zudem erreicht die PWM mit ihrem monatlichen Infoletter über 1.600 Interessierte zum Thema Wissensmanagement in Österreich, in der Schweiz und in Deutschland.

Aufbauend auf den PWM-spezifischen Erfahrungen wird dann dargestellt, wie Web 2.0 Technologien auch innerbetrieblich angewendet werden können. Das Kapitel schließt mit Überlegungen ab, wie neue Entwicklungen den eingeleiteten Trend unterstützen können.

Plattform Wissensmanagement

Die größte deutschsprachige Community zum Thema Wissensmanagement hat mit der Plattform Wissensmanagement ein reales und virtuelles Zuhause. Sie ist informativ, erweitert ihr Wissen mit jedem weiteren Community-Mitglied und vernetzt im Sinne des Social Networking.

Die Plattform Wissensmanagement (PWM, siehe auch www.pwm.at) ist das führende Netzwerk zum Thema Wissensmanagement im deutschsprachigen Raum. Ihr Erfolgskonzept ist die enge Verknüpfung von persönlichen Vernetzungsaktivitäten wie Community-Treffen und Wissensrunden und der Web-Plattform, die einerseits die Verteilung von Ergebnissen der Vernetzungsaktivitäten erleichtert und andererseits als breites Informationsportal zum Thema Wissensmanagement dient. Im Weiteren wird deutlich, dass gerade diese enge Verknüpfung der Real World und virtuellen Aktivitäten zusammen mit stark vernetzenden Persönlichkeiten der Moderatorinnen maßgeblich zu dem Erfolg der PWM beigetragen haben.

Die PWM wurde im März 2001 als Initiative der Stadt Wien gegründet. Bereits nach sechs Jahren Erfolgsgeschichte verzeichnet die Plattform über 1.260 registrierte Mitglieder (Stand Juli 2007). Das Wissensschaftszentrum Wien war bis März 2007 der Eigentümer und Betreiber der PWM. Im März 2007 erfolgte der Betreiberwechsel auf das Know-Center, Österreichs Kompetenzzentrum für Wissensmanagement (siehe auch www.know-center.at). Zeitgleich mit dem Betreiberwechsel vollzog sich auch ein Wechsel der Moderatorinnen.

Das Know-Center ist Österreichs größte außeruniversitäre Forschungseinrichtung für Wissensmanagement und wissensbasierte Systeme. An der Schnittstelle zwischen Wissenschaft und Wirtschaft der anwendungsorientierten Forschung verschrieben, verfolgt das Know-Center besonders auch den Ausbau der technischen Web-Plattform auf Basis von Social Software, semantischen Technologien und Web 2.0.

PWM Organisation

Die PWM Community ist ein offenes, personenbezogenes und lebendes Netzwerk. Ihr Hauptinhalt ist das Thema Wissensmanagement und sie legt ihren Fokus auf den deutschsprachigen Raum. Dieses Kapitel beschreibt die Mission, Regeln, Ziele und Leistungen, Zielgruppen, Standbeine, Kommunikations- und Vernetzungsmöglichkeiten der PWM.

Bei der Gründung der PWM im Jahr 2001 wurde ein Mission-Statement formuliert, das im Jahr 2004 wie folgt novelliert wurde und bis heute seine Anwendung findet.

Die PWM ist die führende Community zum Thema Wissensmanagement. Sie ist unabhängig, interdisziplinär und nicht-kommerziell. Ihre Mitglieder haben sich zum Ziel gesetzt, das Thema Wissensmanagement zu fördern, Interessierten einen Überblick zu bieten und Impulse zu setzen. Die PWM ist ein Raum für Interaktion, Inhalte und Lösungen. Die Mitglieder gestalten die PWM und vermehren ihr Wissen durch Teilen.²

Die PWM spricht folgende fünf Zielgruppen an:

- Praxis und Anwendung
- Aus- und Weiterbildung
- Beratung
- Studierende
- Wissenschaft

Ein Regelwerk der PWM stellt ein verantwortungsvolles Miteinander der Community sicher und fördert ein gemeinsames Normen- und Werteverständnis der PWM-Mitglieder. Die Regeln werden somit als integrativer Bestandteil der Werte verstanden, welche die PWM nach innen und außen vertritt. Die Einhaltung der Regeln durch alle Mitglieder unterstützt

² Mission Statement der PWM, <http://www.pwm.at/index.php?id=2#43>, 09. August 2007

die Zielerreichung der PWM und für die Einhaltung der Regeln ist jedes Community-Mitglied verantwortlich. Neueinsteigern werden mit diesen Richtlinien jene Gepflogenheiten gezeigt, die sich in der Vergangenheit eingebürgert und bewährt haben.

Die Ziele und Leistungen³ der PWM umfassen:

- Die PWM erleichtert und fördert den fachlichen Austausch, gemeinsames Lernen und die allgemeine Kommunikation zum Thema Wissensmanagement.
- Die PWM ermöglicht den Zugang zu Informationen über Fachveranstaltungen und Schulungsmöglichkeiten in allen Bereichen des Wissensmanagements.
- Die PWM hilft bei der Entwicklung, Dokumentation und beim Auffinden von Content zum Thema Wissensmanagement.
- Die PWM stellt als lebende Community eine Vernetzungsplattform dar und bietet allen an Wissensmanagement Interessierten reale Treffen, ein Zuhause für die Community sowie ein Informationsportal.
- Die PWM betreibt Öffentlichkeitsarbeit. Diese bewirkt Bewusstseinsbildung und aktive Nachfrage nach dem Einsatz von Wissensmanagement in all seinen Anwendungsfeldern.
- Die PWM setzt sich mit Theorie und Praxis zum Thema Wissensmanagement auseinander. Dazu wird der aktuelle Entwicklungsstand (Begriffe, Methoden, Praxiserfahrungen, etc.) dargestellt und weiterentwickelt.

In unterstützender Funktion für eine dauerhafte Zielerreichung der PWM, leistet das Gremium „Management-Team“ einen wertvollen Beitrag. Das Management-Team, bestehend aus sechs Personen, hat die ersten Strukturen der PWM geformt, ein Leitbild sowie allgemeine Regeln der Zusammenarbeit in enger Abstimmung mit der Community ausgearbeitet und diese erstmalig im Februar 2002 offiziell vorgestellt. Zu den Aufgaben des Management-Teams zählt der aktive Beitrag in den folgenden Bereichen:

- Strategie und Organisation
- Finanzen und Sponsoring
- Ausbau der operativen Struktur
- Marketingkonzept und Corporate Identity
- Vernetzung und Kooperationen
- Bewusstseinsbildung zum Thema WM
- Fördern inhaltlicher Akzente

³ Vgl. Ziele und Leistungen der PWM, <http://www.pwm.at/index.php?id=2#43>, 09. August 2007

Durch den Übergang an das Know-Center wurde das bewährte Konzept im Kontext des Know-Center beibehalten und ein neues Management-Team bestellt. Dieses Team besteht aus fünf Personen und wurde aus den 17 Partnerunternehmen und 9 F&E-Instituten des Know-Center ausgewählt. Es setzt sich aus Vertretern der Bereiche Praxis, Wissenschaft und Beratung zusammen und ist ehrenamtlich tätig. In seiner Rolle steht das Management-Team in der Strategieentwicklung der Community und des Portals unterstützend zur Verfügung. Insbesondere in Fragen der Vernetzung und Sichtbarkeit im deutschsprachigen Raum wirkt das Management-Team fördernd und steht in Öffentlichkeitsfragen beratend der PWM zur Seite. Damit ist zum einen der objektive Charakter der Plattform gewährleistet und zum anderen eine gute Basis für eine breite Sichtbarkeit der PWM nach außen gegeben.

Eine Neuerung stellt die Aufnahme von assoziierten Partnern dar. Nach dem Prinzip des nutzenstiftenden Beitrags für beide Seiten besteht für Organisationen und Unternehmen die Möglichkeit, dem Netzwerk der PWM beizutreten und dieses zu bereichern. Dabei leisten die assoziierten Partner einen nicht-monetären Beitrag und erhalten dafür unterstützende Leistungen der PWM, die für die Leistungserbringung erforderlich ist. Für die PWM und ihre Mitglieder erwächst daraus ein Mehrwert und dient als treibende Kraft für das weitere Wachstum. In dieser „Win-Win-Perspektive“ entstand ein umfassendes Netzwerk von Partnern in Österreich, Deutschland und der Schweiz.

PWM Web-Portal

Neben der „Knowledge Community“ zählt das informative Portal zu den Erfolgsfaktoren der PWM. Mit der so genannten „Portalsicht“ soll ein gezielter Überblick über alle für Wissensmanagement relevanten Termine, Bücher- und Linklisten sowie Mitgliederpublikationen und unternehmensspezifische Produkte und Dienstleistungen im Bereich Wissensmanagement gegeben werden. Ergänzt wird die Portalsicht durch die Möglichkeit, den Infoletter abonnieren zu können und eine Zitatensammlung.

Die Informationsleiste umfasst das PWM-Leitbild, Kurzinformationen über die PWM, Pressemeldungen der und über die PWM, ein Glossar aller begrifflichen Inhalte des „WM-Wissensnetzes“, Informationen zum Sponsoring, Sitemap sowie Kontakt und Impressum.

Wenn ein Mitglied sich auf der PWM registriert und eingeloggt hat, erreicht es die „Community-Sicht“. Eine umfassende Tool-Landschaft zur kollaborativen Zusammenarbeit steht der gesamten Community zur Verfügung, insbesondere auch für die Arbeit in „Wissensrunden“. Die Tools umfassen Mitgliederprofile, die von den Mitgliedern selbst erstellt, verwal-

tet und eingesehen werden können, eine Webmail-Möglichkeit, das Verwalten von Dokumenten und Bildern, das Abonnement von Alerts – das sind monatliche Email-Informationen über Neuerungen am Portal – das Starten von Umfragen und das Posten von Pinnwandeinträgen. Eine „Neuigkeitenseite“ hält jedes Mitglied nach dem Login über neue Mitglieder, Dokumente, Bilder, etc. am aktuellen Stand.

Seit dem Portalrelaunch im Herbst 2005 wurde die PWM mit einem semantischen Netz hinterlegt. Dieses dient dem Erwerb von Wissen über Wissensmanagement und unterstützt die Suchfunktionalitäten der PWM. In der „Suchansicht“ gibt es einerseits die Möglichkeit, nach Inhalten des Portals wie auch des Community-Bereichs zu suchen, andererseits können Mitglieder über die „Mitgliedersuche“ Kontaktpersonen finden. Diese Suche wird unterstützt durch mehrere Einschränkungsmöglichkeiten.

Das WM-Wissensnetz unterstützt in der „Suche im www“ den Suchenden, indem es verknüpfte Begriffe vorschlägt, um die Suche zu spezifizieren, sofern der Suchbegriff im Wissensnetz vorhanden ist. Dabei werden Google-Datenbanken durchsucht.

Die dritte Art von Suchmodalitäten bildet die „Suche im WM-Wissensnetz“. Sie kann neben dem Glossar in der Informationsleiste als zweiter Einstiegspunkt in das WM-Wissensnetz gesehen werden. In diesem WM-Wissensnetz sind über 800 Begriffe aus dem Themenfeld WM in ein semantisches Netz verwoben. Auf diese Weise kann sich das Community-Mitglied über die Suche oder die grafische Ansicht durch das Netz bewegen.

Kommunikation und Vernetzung in der PWM Community

Um aktives Networking betreiben zu können, bietet die PWM zahlreiche Möglichkeiten im Real World wie im Virtual World-Modus. Häufig ergeben sich Mischformen aus den beiden Modi. Dabei unterstützen Kollaboration-Tools der PWM die zielgerichtete Zusammenarbeit der Mitglieder untereinander. Ungeachtet, um welche kooperierende Fragestellung es zwischen den Mitgliedern geht, können sie in ihren arbeitsteiligen Leistungsprozessen mit diesen Tools ihre Kommunikation zu einem gemeinsamen Sachverhalt bündeln und koordinieren. Übergeordnet steht das Ziel einen Mehrwert für die Community-Mitglieder zu generieren.

Es sei an dieser Stelle angemerkt, dass in diesem Beitrag bewusst eine Trennung in eine „Real World“ und „Virtual World“ vorgenommen wurde. Dies ist darauf zurück zu führen, dass Web-gestütztes Social Networking am Beispiel der PWM weniger im technischen Kontext, sondern vielmehr im Zusammenhang mit der (PWM-) Community begriffen wurde. Ein wesentlicher Fokus liegt in der Aufarbeitung von den Faktoren, den

Merkmale und den Werkzeugen, die in einer „Community Environment“ für den Erfolg einer Community maßgeblich sind. Die Bezeichnung von „Online“ und „Offline“ erschienen in dieser Hinsicht eher zu „technisch“, denn es geht um mehr als lediglich in einem System ein- oder ausgeloggt zu sein. Umso mehr erschien die Trennung in eine reale und eine virtuelle Community-Welt als passend und sie genügte auch dem Anspruch, die „weichen“ Assoziationen, die für die beiden Community-Welt-Ansichten notwendig sind, zu berücksichtigen.

Real World-Vernetzungsinstrumente der PWM-Community

Die Basis für die Vernetzungsaktivitäten einer Community ist eine möglichst variantenreiche Kommunikationsebene. Die PWM bietet ihren Community-Mitgliedern folgende virtuelle wie reale Möglichkeiten:

- Mix aus realen und virtuellen Kommunikationsmöglichkeiten,
- Infoletter,
- Alerts,
- Umfragen,
- Mitgliedersuche,
- Community-Umgebung,
- Kommunikation via Moderatorin und
- PWM-Jahrbücher.

Die PWM-Community kommt bei folgenden Aktivitäten offline bzw. in Real World-Umgebungen zusammen:

- Community-Treffen,
- Wissensrunden (Arbeitsgruppen zu spezifischen Themen),
- Jahrestreffen/Geburtstage,
- Wissenstag Österreich,
- Wissensgespräche und
- „Mitglieder für Mitglieder“-Seminare.

Zu den viermal im Jahr stattfindenden „PWM-Community-Treffen“ werden Mitglieder und die interessierte Öffentlichkeit eingeladen. Jeweils ein Mitglied übernimmt die Gastgeberrolle, die Vortragenden kommen aus dem Kreis der PWM und gemeinsam wird ein sowohl informativer als auch geselliger Vernetzungsevent veranstaltet.

Unter „PWM-Wissensrunden“ werden von den Mitgliedern eigenverantwortlich und inhaltlich geleitete Arbeitsgruppen zu unterschiedlichen Themenstellungen des Wissensmanagements verstanden. Dabei stellt die

PWM die Kommunikations- und Dokumentationsinfrastruktur zur Verfügung. Die inhaltlichen Ergebnisse fließen dabei an die Community zurück.

Zu den sozialen Hauptevents zählen die so genannten „PWM-Jahrestreffen“ bzw. „Geburtstage“. Sie können als der jährlich stattfindende soziale und gesellige Vernetzungshöhepunkt der Community verstanden werden. In diesem Rahmen werden Rück- und Ausblicke der PWM präsentiert und den PWM-Mitgliedern die Gelegenheit gegeben, sich ausführlich zu vernetzen.

Im Sinne einer Fachtagung im lockeren Konferenzrahmen zeigt der „Wissenstag Österreich“ die Praxisseite des Wissensmanagements auf. Dieser dient zur Weiterentwicklung des bestehenden Wissens über Wissensmanagement und fördert den Erfahrungsaustausch zwischen Praktikern, Wissenschaftlern und Beratern.

Die in der Vergangenheit durchgeführten „Wissensgespräche“ waren zum gegenseitigen Expertenaustausch rund um das Thema Wissensmanagement gedacht. Seit 2006 lösten die „Mitglieder für Mitglieder“-Seminare die Wissensgespräche ab. Jeweils ein Mitglied der PWM stellt den Gastgeber und veranstaltet ein Event, z. B. im Rahmen eines „Wissensmanagement-Frühstücks“ an einem Vormittag. Die Mitglieder für Mitglieder-Seminare dienen der Diskussion und dem Austausch von neuen Perspektiven des Wissensmanagements in der Wissenschaft und der Praxis.

Die PWM-Veranstaltungsschiene bildet wie oben beschrieben das dritte Standbein der PWM und bietet vielfältige Kommunikations- und Vernetzungsaktivitäten für die Mitglieder. Insbesondere die Veranstaltungen dienen einem bewussten Austausch und fördern das Vertrauen in intakte Netzwerkbeziehungen. Viele Mitglieder entwickeln aus den bekannten Offline-Beziehungen neue Online-Vernetzungsaktivitäten und beginnen sich somit im Sinne des Social Networking zu vernetzen. Somit bilden die Offline-Veranstaltungen einen wesentlichen Beitrag für eine langfristig erfolgreiche und lebendige Community im Sinne des Social Networking.

Im Zeitraum von März 2001 bis Juli 2007 haben folgende Events im Rahmen der PWM-Community stattgefunden:

- 28 Community-Treffen,
- sechs Jahresfeiern,
- drei „Wissenstag Österreich“,
- ca. 15 Wissensrunden,
- zwei Jahrbücher,
- zwei DVD-Produktionen,
- vier Wissensgespräche und
- ein Portalrelaunch.

Die Moderatorin übernimmt bei den Real World-Vernetzungsinstrumenten der PWM die Rolle der Kommunikatorin und Organisatorin. Sie trägt die organisatorische Verantwortung für die Veranstaltungen sowie moderiert sie das jeweilige Event. Sie gewährleistet einen effizienten Informationsfluss aus der Welt des Wissensmanagements in die Community sowie zwischen den Community-Mitgliedern. Zudem stellt sie die Rahmenbedingungen zur Verfügung, in denen eine aktive Vernetzung der PWM-Community gedeihen kann. Die Moderatorin gibt den Anstoß zum Social Networking, die Community greift diesen Impuls auf und entwickelt diesen für sich weiter.

Der wesentliche Nutzen der Real World-Vernetzungsinstrumente der PWM-Community kann in der Stärkung realer Beziehungen der Community-Mitglieder gesehen werden. Eine Vernetzung von Mitgliedern kann auf realer sowie virtueller Ebene stattfinden. Allerdings festigt bzw. verstärkt die face-to-face Kommunikation innerhalb der Community und mit der Moderatorin die ursprüngliche Beziehung zu einem anderen Community-Mitglied. Viele „instabile“ Beziehungen in einer Community werden mittels der Real World-Vernetzungsinstrumente in „stabile“ Verflechtungen umgewandelt. Bei der Moderatorin laufen die unterschiedlichen Verbindungen in eine zentrale Anlaufstelle zusammen. Als Vermittlerin kann sie den Impuls geben, die Richtung anzuzeigen und über einen längeren Zeit-horizont hinweg ein wichtiges Thema beleuchten, um Social Networking innerhalb der Community voranzutreiben.

Virtual World-Vernetzungsinstrumente der PWM-Community

In diesem Kontext rücken die angebotenen Kommunikationstools der PWM in den Mittelpunkt der folgenden Betrachtung. Folgende Kommunikationstools lassen den kollaborativen Charakter der PWM erkennen:

- die integrierte Email-Funktion des PWM-Portals,
- die Gestaltung des Mitgliederprofils und damit die Visitenkarte des jeweiligen Mitglieds,
- das Forum,
- die Umfrage,
- die Pinnwand,
- die Eröffnung und Verwaltung von „Wissensrunden“,
- die Mitglieidersuche,
- das Senden von Feedback direkt an die Moderatorin der Plattform und
- das Vorschlagen von Buch-, Termin-, Link-, Call for Papers- und Wissenstipps.

Ergänzt wurden die Services für die PWM-Community-Mitglieder durch die Einführung der Mitgliedersuche und diverser Web 2.0-Technologien im Februar 2007. Im „Community-Bereich“ der PWM stehen somit **drei neue Social Software Tools** den Mitgliedern zur Verfügung. Sie können in diesem Kontext auch als Knowledge Services [8] für die PWM-Community verstanden werden.

Erstens können die Mitglieder mit „**MyFriends**“ ihre „Freunde“ aus der PWM-Community auswählen und so interessante Verknüpfungen herstellen und diese auch anzeigen. Durch Klick auf den Namen eines Mitglieds wird das jeweilige Mitgliederprofil ersichtlich, wo zusätzlich zu den Registrierungsdaten folgende Informationen zu sehen sind:

- *Interessensprofil*: Es umfasst jene Begriffe aus dem „WM-Wissensnetz“, für die sich das Mitglied interessiert.
- *Tags*: Dies sind jene Begriffe, mit denen das Mitglied Bookmarks beschlagwortet hat. Durch Klick auf einen Begriff gelangt das Mitglied in die Community-Bookmarks und kann dort Links zu dem Thema finden.
- *Friends*: Hier ist die Liste der Friends ersichtlich, welche das Mitglied ausgewählt hat.

Die Färbung von bestimmten Worten verweist auf eine Übereinstimmung zwischen dem eigentlichen Community-Mitglied und einem ausgewählten. Die rot angezeigten Angaben in der rechten Spalte zeigen, welche Interessen, Friends und Tags jeweils mit dieser Person gemein sind. Hieraus lassen sich interessante Verknüpfungen und Verbindungen zu anderen Mitgliedern erkennen.

Der Nutzen der „MyFriends“-Anwendung liegt im Finden gemeinsamer Themen und Freunde. Hieraus können interessante Verknüpfungen hergestellt und angezeigt werden. Damit soll die Vernetzung der Community-Mitglieder unterstützt werden.

Zweitens können die PWM-Mitglieder mit „**MyBookmarks**“ Bookmarks inklusive Beschlagwortung (so genannter „Tags“) anlegen und so eine persönliche WM-Favoritenliste generieren und ortsunabhängig via Web darauf zugreifen. Das Community-Mitglied kann seine Favoriten des Web „Ablegen“, „Verschlagworten“ und „Kategorisieren“. Damit legt sich das jeweilige Mitglied seine persönliche WM-Bookmarkliste an und trägt somit zur Erweiterung der Community-Bookmarks bei. Neben einer erstellten Bookmarkliste ist eine persönliche „Tagcloud“ des jeweiligen Community-Mitglieds zu sehen. Diese setzt sich aus den Tags (Stichworte zur Beschlagwortung) zusammen, welche es vergeben hat. Die häufig benutzten Worte sind dabei hervorgehoben. Durch einen Klick auf einen Tag, erhält das Mitglied eine Liste aller Bookmarks, die es mit diesem Begriff beschlagwortet hat.

The screenshot displays the 'Community Bookmarks' section of the PWM (Plattform Wissensmanagement) website. The header includes the PWM logo and navigation links. The main content area lists various bookmarks with tags such as 'ajax', 'assessment', 'ausbildung', 'automatische musterkennung', 'cms', 'communities', 'community', 'community management', 'concept mapping', 'content management', 'content management system', 'content-pflege', 'deregulierung', 'digital library', 'electronic market', 'forschung', 'gfw m', 'google', 'graz', 'information extraction', 'informationsetik', 'instrumente', 'intranet', 'kmap', 'know-center', 'kompetenzmanagement', 'kompetenzmanagement', 'kompetenzzentrum', 'lehrgang', 'lehrgang lernen', 'lernsoftware', 'management', 'commitment zu wm', 'schaffen', 'managementwissen', 'markt', 'markttrend', 'mashup', 'meshup', 'meta-information', 'methodenkompetenz', 'multimedia', 'nlp', 'notebooks', 'ontology', 'ontology engineering', 'open source', 'personalmanagement', 'praxis', 'projektmanagement', 'pwm', 'rahmenbedingungen', 'rdf', 'recommender system', 'research', 'ruby', 'second life', 'semantic web', 'framework', 'semantik', 'semantisches wissensmanagement', 'skills management', 'sna', 'social bookmarking', 'social network analysis', 'social networking', 'social software', 'social tagging', 'social web', 'social_networking', 'softwarehersteller', 'soziales netzwerk', 'suche', 'suche nach wissensarbeitern im partnernetzwerk', 'suchmaschine', 'suchmaschinen', 'tagging', 'textanalyse', 'triple store', 'umsetzung', 'web 2.0', 'web2.0', 'weiterbildung', 'wikipedia', 'wissenorganisation', 'wissensgesellschaft', 'wissenslandkarte', 'wissensmanagement', 'wissensmanagement-modell', 'wissensmanagement-system', 'wissenstransfer', 'wissensträgervernetzung', 'wissensvernetzung'.

On the right, there is a summary: 'Im Mittelfeld sehen Sie die Tagcloud der PWM-Community. Sie setzt sich aus den meistverwendeten Tags (i.e. Begriffe zur Beschlagwortung von Bookmarks) der Mitglieder zusammen. 92 Tags gesamt 30 Bookmarks gesamt'.

Below the list, it says 'Die letzten 30 gespeicherten Bookmarks:' and shows two entries:

- Das GFWM-WM-Modell @ 31. Community-Treffen der Plattform...**
Im Rahmen der Veranstaltung wurde unter anderem das Wissensmanagement-Modell der Gesellschaft für WM e.V. (Deutschland) präsentiert. Dieser Blogbeitrag soll den Teilnehmern des Vortrags und anderen die Gelegenheit bieten einen Kommentar zum Modell abzugeben.
Tags [wissensmanagement-modell](#) [gfw m](#)
Angelegt von [Boris Jäger](#)
05.02.2008 - oder: 2008-02-05 21:20:59
- Corporate Web 2.0 - Semantic Web Company - Semantische Te...**
Gute Einführung zum Thema Web 2.0 im unternehmerischen Umfeld.
Tags [semantic web](#) [web 2.0](#) [ontology](#) [semantik](#) [social network](#) [analysis](#) [textanalyse](#)
Angelegt von [Andreas Blumauer](#)
01.12.2007 - oder: 2007-12-01 12:06:14

The left sidebar contains navigation options: 'Portal', 'Community', 'Suche', 'Persönliche Ansicht', 'Community Ansicht', 'Terminkalender', 'Dokumentenablage', 'Wissensrunden', 'Mitglieder', 'Forum', 'Umfragen', 'Bildgalerien', 'Pinnwand', 'Feedback', 'Community Bookmarks', 'Testgruppe Wissensrundenstart', 'Vertrauen'.

Abb. 1. Screenshot „Community Bookmarks“ in der Community-Ansicht der PWM (Stand Februar 2008)

Für das Community-Mitglied hat das Knowledge Service den Vorteil ortsunabhängig auf seine WM-Bookmarks via Web zuzugreifen. Es wird auch in der Recherche nach Inhalten und Ressourcen unterstützt, das in einem rascheren und effizienten Suchergebnis resultiert.

Das dritte Social Software Tool „**Community Bookmarks**“ informiert die Mitglieder darüber, was die Community in ihrer Gesamtheit gerade bewegt und welche Mitglieder sich für welche Themen interessieren. Die Summe aller persönlicher Bookmarks der PWM-Mitglieder werden kumuliert und in Form der „Community Bookmarks“ wiedergegeben. Hierin finden sich alle von PWM-Mitgliedern angelegten Bookmarks geordnet nach Speicherdatum.

Vor der Liste mit den Bookmarks (getaggte Links) findet sich die Tagcloud der gesamten PWM-Community. Diese setzt sich aus den Tags (Stichworten) zusammen, welche Mitglieder für die Bookmarks vergeben haben. Je häufiger ein Wort verwendet wurde, umso stärker wird dieses hervorgehoben. Durch Klick auf eines der Tagwörter erhält das Mitglied

eine Liste mit allen Bookmarks, welche mit diesem Tag beschlagwortet wurden. In der „**Community Tagcloud**“ wird somit die Kumulierung der unterschiedlichen Interessen der PWM-Mitglieder visuell dargestellt.

Nach Klick auf einen Tag erscheint in der rechten Spalte ein zusätzliches Feld „relevante Tags“. Dies sind Tags, welche Mitglieder der PWM gemeinsam mit dem ausgewählten Tag verwendet haben. Durch Klick auf das Google-Logo kann direkt eine Google-Abfrage zu den fünf bedeutendsten Tag-Begriffen rund um das ausgewählte Wort gestartet werden.

Wenn ein Wort aus der Tagcloud ausgewählt wird, so erhält das Community-Mitglied gleichzeitig zu der Liste mit den Bookmarks in der rechten Spalte die Information, welche Mitglieder diesen Tag verwendet haben. Wenn nun der Name des Mitglieds angeklickt wird, so gelangt man zu dessen Bookmarkliste. Gleichzeitig erscheint in der rechten Spalte die Tagcloud des betreffenden Mitglieds.

Primär soll das dritte Knowledge Service das Community-Mitglied über die Visualisierung der kumulierten Tags in der weiteren Vernetzung der Mitglieder untereinander unterstützen. „Auf einen Blick“ werden interessante virtuelle Verbindungen aufgezeigt, die über Werkzeuge in der virtuellen und realen Welt die realen Beziehungen umgarnen und festigen.

PWM-Modell für Wissensaustausch und Vernetzung

Das PWM-Modell ist gekennzeichnet durch das Zusammenspiel wichtiger Elemente einer Community [7]. Wie in einem großen Puzzle müssen die einzelnen Puzzle-Teile zusammenpassen und somit zusammenwirken. Die einzelnen Puzzle-Teile beschreiben im PWM-Modell die Real World, die Virtual World und die Moderatorin. Das größte Puzzle bildet die Real World bzw. Community, da die Community wiederum einen Teil der realen Welt ausmacht. Jedem Puzzle-Teil ist eine entsprechende Vernetzungsinstrumente-Liste zugeordnet, die dem jeweiligen Mitglied bzw. der Moderatorin zur Verfügung steht. Die größte Fläche – in dem Modellbild veranschaulicht als graues Puzzle-Teil – weist eine Besonderheit auf. Die natürliche Grenze der Real World bzw. Community kann in dem Modell verstanden werden als eine durchlässige Membran. Zum einen hält sie die Community in der Real World zusammen und zum anderen ist sie für Zuwächse in Form von neuen Mitgliedern oder neuen Communities offen. Die beiden Puzzle-Teile der Real World und der Moderatorin werden ebenso in Form einer natürlichen Membran begrenzt. Im Gegensatz dazu erscheint die Virtual World mit ihren Vernetzungsinstrumenten eher als abgegrenztes Teilgebiet innerhalb des Modellbildes. Dies lässt sich dahingehend erklären, dass die virtuellen Vernetzungsinstrumente bislang nicht im Mittelpunkt der Nutzung gestanden sind und historisch bedingt als




Abb. 2. Zusammenspiel wichtiger Elemente der PWM-Community

„nice to have“ angesehen wurden. Die sich nicht ausgrenzenden, sondern vielmehr sich gegenseitig befruchtenden, Grenzverhältnisse werden in diesem Zusammenhang als zentrale Erfolgskomponente innerhalb einer Community erachtet.

Wie bereits oben beschrieben, spielen die Vernetzungsaktivitäten der Real World und der Virtual World zusammen. In der folgenden Grafik wird das Zusammenspiel wichtiger Elemente der PWM-Community modellhaft dargestellt.

Ein Beispiel soll das komplexe Zusammenspiel verschiedener Kommunikationskanäle und die Festigung von Netzwerken durch persönliche Kontakte in der PWM verdeutlichen. Angenommen ein PWM-Community-Mitglied möchte eine Wissensrunde zu einem Thema XY eröffnen. Das Mitglied tritt an die Moderatorin heran mit der Bitte einen Aufruf zur Teilnahme beim nächsten Community-Treffen zu machen. In dieser Veranstaltung hat das Community-Mitglied die Möglichkeit das Wissensrundenthema vorzustellen und einen Aufruf zur Teilnahme zu machen. Die Moderatorin sorgt für den technischen Support um eine solche Wissensrunde zu gestalten. Das Community-Mitglied ernennt sich zum Moderator dieser Wissensrunde und nimmt interessierte Mitglieder in seine Runde auf. Den weiteren Ablauf – technisch wie organisatorisch –

übernimmt der Moderator der Wissensrunde. Er veranstaltet virtuelle und reale Treffen um ein Thema zu erarbeiten. Dabei finden virtuelle und reale Vernetzungsaktivitäten statt, die mit den Kollaborationswerkzeugen der PWM unterstützt werden. Die erarbeiteten Zwischen- wie Endergebnisse fließen in das PWM-Portal ein und werden mithilfe verschiedener Dokumenten-Sharing-Tools verwaltet. Am Ende einer Wissensrunde werden die wichtigsten Ergebnisse von den Mitgliedern und dem Moderator der Wissensrunde bei einem Community-Treffen vorgestellt. Somit kommt eine direkte Wissensteilung zustande und die Community kann von den neuen Ergebnissen aus der Wissensrunde profitieren.

Aus den vielen virtuellen Kontakten entstehen Beziehungen unter den Wissensrunden-Mitgliedern, die durch Vernetzungsaktivitäten in der Real World erst an Tiefe erfahren. Die persönlichen Kommunikationsmaßnahmen fördern und festigen ein nachhaltiges Netzwerk mit vertrauensvollen und zukunftsfähigen Beziehungsgeflechten.

Umfrage & Nutzung

Im Zeitraum von 06. Juli bis 23. August 2007 wurde mit einer PWM-Online-Umfrage die Community bezüglich der Weiterentwicklung der PWM befragt. Dazu wurde ein Fragebogen entwickelt, den 75 Personen in der vorgegebenen Zeit beantwortet haben. Das entsprach einer Rücklaufquote von 6%. Mit der Umfrage wurde das Ziel verfolgt, wichtige Schlüsse für die weitere Gestaltung der PWM zu gewinnen. Insbesondere wurde dabei Augenmerk auf die Akzeptanz und Nutzung der Social Software Tools gelegt. Zudem wurde die Community zu ihrem Netzwerk-Verhalten befragt. Der Fragebogen erfasste die folgenden Bereiche: Daten zur Person, Nutzungsverhalten, Motivation, Gestaltung der Community-Umgebung, Kontakte/Vernetzungsaktivitäten, Informationskanäle.

Betrachtet man die Relation von passiver Nutzung – wie dem reinen Lesen/Anschauen/Runterladen – im Vergleich zu aktiver Nutzung – wie dem Schreiben/Hochladen von Inhalten – ergab die Umfrage, dass insgesamt die passive Partizipation stärker ausgeprägt ist als die aktive Partizipation: Etwa 80% der Benutzer sind passiv in Bezug auf das Lesen, das Anschauen und das Runterladen in der Rubrik „Wissen am Portal“ tätig, hingegen steigt der aktive Anteil auf über 40% in den Bereichen Forum, Umfrage und Pinnwand der Community.

Bezüglich der Motivation der Nutzung zeigte sich, dass der konkrete Informationsbedarf, das Weiterlernen, die Weitergabe und der Austausch von Wissen durchschnittlich stärker das PWM-Mitglied bewegen die Community zu nutzen, als das Stöbern im Wissensbestand und die Ab-




Abb. 3. Durchschnittliche Wichtigkeit der unterschiedlichen Motive

sicherung von Wissen. Daraus lässt sich ableiten, dass es einen Bedarf an interaktiven Services gibt und die Community diesen auch nutzen würde.

Zum Vergleich ergab eine deutschlandweite Studie von McKinsey [1], dass einerseits der Wunsch nach Ruhm und andererseits der Spaßfaktor die Online-Kollaboration und Mitarbeiterbeteiligung fördern. Als dritte, gewichtige Antwort wurde der Wunsch nach Erfahrungsaustausch mit Freunden genannt. Diese Studie bezog sich zwar auf Unternehmen, doch lassen sich hieraus Vergleiche und Schlüsse für die Identifikation mit einer Online-Community ziehen. Beiden Studien ist somit das interaktive Element des „Austauschens“ von Wissen bzw. Erfahrung gemein und besonders wichtig.

Das interaktive Element der PWM findet sich bereits im Leitbild der PWM, indem die Mitglieder dazu aufgerufen werden, die PWM zu gestalten und ihr Wissen durch Teilen zu vermehren. Hierin wird bereits klar zum Ausdruck gebracht, dass Interaktivität die Basis für den weiteren Aufbau des Wissensbestandes der Community ist. Aus dem Kreislauf von „Geben und Nehmen“ soll die Wissensbasis der PWM weiter aufgebaut werden. Dies bestätigt die oben festgestellte Tatsache, dass Interaktivität zu den Schlüsselfaktoren der PWM zählt. Entsprechend als notwendig erachtet, sind kollaborative Tools, mit denen die Community-Mitglieder leicht miteinander in Beziehung treten können und sich austauschen können. Dadurch wird bereits auf den sozialen Vernetzungsgedanken im Sinne des Web 2.0 hingewiesen.

PWM Weiterentwicklung und Ausblick

Nun hat sich das PWM-Modell in den vergangenen sieben Jahren gut bewährt und soll nun auf Basis aktueller Entwicklungen weiter fortgeführt werden. Mit dem derzeitigen Blick in Richtung „Zukunft“ gerichtet, lassen sich zwei wesentliche Weiterentwicklungsmöglichkeiten der PWM beschreiben: „Open-Access“ und „Web 2.0“.

Die neuen Herausforderungen im Umfeld von Web 2.0 sind die Kommunikation, den Wissensaustausch und das Vernetzen effektiver zu machen. Welcher Fortschritt bedarf es in einer Wissensmanagement-Community, um einen nachhaltigen Erfolg zu erzielen? Wo kann am besten angesetzt werden, um Quick-Wins sowie langfristig positive Ergebnisse für die Community zu erreichen?

Das in diesem Kontext erfolgversprechende Lösungskonzept lautet „Kommunikation im Sinne des Web 2.0“. Damit wird bereits auf die zunehmende Annäherung zweier Ebenen hingewiesen. Zum einen greifen die virtuellen Vernetzungsinstrumente vermehrt in die Real World ein und zum anderen werden aufgrund realer Beziehungen verstärkt virtuelle Instrumente eingesetzt.

Das Ziel ist eine möglichst tief greifende Verzahnung der beiden Ebenen und damit einher gehend ein Zusammenziehen der Real und Virtual World. Aus den realen Beziehungen werden über virtuelle Vernetzungsinstrumente neue virtuelle Kontakte gefunden und über reale Instrumente in echte und gestärkte Real World Netzwerke umgewandelt. Der Weg kann auch umgekehrt gegangen werden, das übergeordnete Ziel bleibt die Entfaltung und Realisierung realer Netzwerkbeziehungen.

Ganz nach dem Motto – den Erfolg der PWM auf Basis des Geschaffenen weiter auszubauen – sollen Innovationen auf Basis von Kontinuität für die Community einen Mehrwert generieren. Die PWM als ein offenes, personenbezogenes und lebendes Netzwerk repräsentiert die führende Community zum Thema Wissensmanagement im deutschsprachigen Raum. Sie ist damit eine lebende WM-Community mit Mitgliedern aus Wissenschaft, Wirtschaft und Bildungsinstitutionen. Die PWM entwickelte sich bis zum Betreiberwechsel als Netzwerkplattform im klassischen bzw. im Web 1.0-Sinn. Durch den Übergang auf das Know-Center bot sich die Chance, die PWM im Sinne des Web 2.0 zu entfalten und über den klassischen Web 1.0-Gedanken weiter auszubauen. Damit war ein wichtiger Grundstein für die Weiterentwicklung des PWM-Portals im Sinne des „Open-Access“ und damit des Web 2.0 gelegt. Zudem sollen neue Anwendungen im Kontext des Social Semantic Web erschlossen werden.

„Open-Access“ der PWM

Aus den geänderten Informations- und Kommunikationstechnologien ergeben sich zahlreiche neue Kommunikationsformen in bzw. über Unternehmen und Organisationen hinweg. Daraus können Veränderungen des Kommunikationsverhaltens der Mitarbeiter innerhalb wie außerhalb von Unternehmen beobachtet werden. Damit verbunden ist auch die Forderung nach neuen Kommunikationsmöglichkeiten in Communities zu den verschiedenen Fachthemen. Das Internet hilft bei der Verknüpfung von Inhalten und kommunizierenden Menschen und trägt somit zu einer gesteigerten Nachfrage an Web 2.0-Entwicklungen [3] in Unternehmen und Organisationen bei. In diesem Kapitel werden einerseits der „Open-Access-Gedanke“ der PWM erklärt und andererseits mögliche Ansatzpunkte von Social Networking Tools in der PWM aufgezeigt.

Als ein Schlüssel zum Erfolg kann in diesem Zusammenhang das Prinzip **„Users Add Value“** [6] verstanden werden. Hierbei ist wesentlich, dass das Potenzial der UserInnen noch lange nicht voll ausgeschöpft ist. Mit den Web 2.0 Interaktions- und Partizipationsmöglichkeiten wird der User zusätzlich auch zum Informationsproduzenten und damit verschiebt sich auch sein Nutzen. Dieser wichtige Aspekt hat bislang noch nicht Einzug in die Struktur der PWM gehalten. Doch was ist nun unter dem „Open-Access-Gedanken“ zu verstehen?

Die Neuausrichtung „Open-Access“ bedeutet für die PWM, die Community in das Zentrum der PWM zu stellen und diese verstärkt einzubeziehen. Damit soll der Community ein vermehrtes „Sich Einbringen“ gewährt werden, was in einem gesteigerten Verantwortungsgefühl der Mitglieder resultiert.

Nach der Häufigkeit bzw. Wichtigkeit der Nutzung von PWM-Services gefragt, ergab die Umfrage, dass der konkrete Informationsbedarf, der Austausch und die Weitergabe von Wissen zwar als wichtig erachtet werden, aber die entsprechenden Technologien noch nicht in vollem Umfang genutzt werden. Hieraus lässt sich einerseits ein Bedarf an Social Software Tools ableiten, andererseits ist es erforderlich, dass diese Tools in ihrer Anwendbarkeit und Wirkung umfassend erklärt und dem Community-Mitglied näher gebracht werden. Die Social Software Tools umfassen „MyBookmarks“, „Community Bookmarks“ und „MyFriends“.

Die Ziele und Zwecke der Community-Umgebung zu kennen, ist für fast 70% der Befragten sehr wichtig. Dazu korreliert auch die Bekanntheit der Social Software Tools, die jedoch noch nicht entsprechend beworben worden sind. Hierin besteht noch konkreter Handlungsbedarf, um das gesamte Potenzial von Social Software Tools den Community-Mitgliedern näher zu bringen.




Abb. 4. Durchschnittliche Wichtigkeit bzw. Häufigkeit der Nutzung unterschiedlicher Social Software Tools auf der PWM

Als ein weiterer Schlüsselfaktor kann Tim O'Reilly's „Co-operate – Don't Control“ [6] Gedanke betrachtet werden. An seine Vorstellung angelehnt, kann für die PWM das Prinzip übersetzt werden, als möglichst umfassende Aufhebung Passwort-geschützter Bereiche. Damit sollen zum einen so viele wie möglich Passwort-geschützte Portalseiten aufgehoben werden und zum anderen der Eintritt in die PWM-Community möglichst offen gestaltet werden.

Wie bereits in der Grafik oben verdeutlicht, zählen zu den als am wichtigsten erachteten und am häufigsten verwendeten Technologien der PWM die verschiedenen „Suchfunktionen“. Hieraus lässt sich ableiten, dass das Community-Mitglied gezielt nach Informationen sucht und dieser Prozess dem weiteren Austausch und der Weitergabe von Wissen dienlich sein kann. So können auf Basis der Suchergebnisse der Wissensbestand der PWM nach speziellen Themen vertieft werden und interessante Verknüpfungen und Querverbindungen gefunden werden. Es entsteht ein Prozess des Suchens und Findens, welcher durch ein Mitglied-spezifisches Partizipieren in Form von Forumsbeiträgen, dem Upload von Studien, etc. ergänzt werden kann.

Web 2.0 in der PWM

Grundsätzlich lässt sich festhalten, dass die PWM noch als Plattform mit den Eigenschaften des Web 1.0 charakterisiert werden kann. Trotz der Bemühungen, drei Social Software Tools in einem Zeitraum von sechs Monaten einzuführen, gelang es (noch) nicht, die Benutzer ausreichend

über deren Zweck und Ziel zu informieren. Um die Plattform im Sinne des Web 2.0 weiter zu entwickeln, bedarf es einer umfassenden Kommunikation und Anleitung der Community-Mitglieder seitens der Moderatoren. Ihre Aufgabe wird es sein, zum einen Informationslücken zu schließen und zum anderen mit gutem Beispiel voran zu gehen. In dem PWM-Modell sind die einzelnen Puzzle-Teile als membranartige Elemente zu verstehen. Einzige Ausnahme bildet bislang die Virtual World, da sich die Virtual World-Netzwerkinstrumente eher im technischen Bereich aufhalten und vom Zusammenspiel mit anderen Instrumenten eher starrer und isolierender sind. Die Idee des Web 2.0 könnte in der Weiterentwicklung der PWM eine tragende Rolle in Richtung verstärkter Ein- und Anbindung mit den Real World-Vernetzungsinstrumenten spielen.

Zunächst sollen die wichtigsten Veränderungen im Zeitalter des Web 2.0 näher betrachtet werden und zwei Hauptaspekte in Bezug auf Social Networking heraus gegriffen werden.

Zum einen entstanden nach und nach immer mehr neue Techniken, Webseiten und -applikationen (z. B. ICQ), welche dem User von **sozialem Nutzen** sind. Ihre Weiterentwicklung führte zu den so genannten Social-Networking-Plattformen. Damit wird das „klassische“ Vernetzungsangebot um ein modernes und der heutigen Zeit entsprechendes Konzept erweitert. Auch moderne Geschäftsbeziehungen lassen sich in diesen Kontext einordnen.

Zum anderen bietet das Web 2.0 zahlreiche, neue **Partizipationsmöglichkeiten**, die es in der Tradition des Web 1.0 noch nicht gab. Darunter sind Web 2.0-Applikationen im Internet zu verstehen, die dem User eine bessere Mobilität, Zugänglichkeit und Austauschmöglichkeit bieten. Das Ziel ist ein flexibler Informationsaustausch innerhalb der Community und die Entwicklung eines für alle jederzeit verfügbaren Wissenspools, der einen optimalen Zugriff auf die bestehenden Ressourcen bereitstellt.

Will man die Ergebnisse der PWM-Umfrage auf aktuelle Entwicklungen zum Aufbau einer Community im Web 2.0 umlegen, so können folgende Empfehlungen gefolgert werden.

Um dem Aspekt von Interaktivität Rechnung zu tragen, kann als möglicher Ansatz beispielsweise das Abfragen der Meinungen aus der Community zu verschiedenen Themen, z. B. durch Voting, Recommendations und Polls etwa für Themen von Wissensrunden, erachtet werden. Damit wird die Community als Ganzes in den Mittelpunkt gerückt, jedes Mitglied kann seine Meinung bzw. Sicht der Dinge kundtun und somit wird bereits ein interaktiver Vernetzungsprozess angestoßen.

Wie die PWM-Umfrage aufgezeigt hat, nutzt die Mehrheit der Benutzer eine Community-Umgebung vorrangig passiv, d. h. im Sinne des Lesens von Inhalten. Bezüglich der Aktivität der Nutzer bedarf es eines hohen Moderationseinsatzes. Die Bereitstellung von Inhalten muss entweder

durch den Betreiber selbst erfolgen, z. B. durch Einsatz eines Expertenteams oder eines oder mehrerer Moderatoren. Wünschenswert wäre der aktive Einsatz der Benutzer selbst, der dann allerdings in kritischer Masse vorhanden sein sollte. Dafür wäre es notwendig, den Anteil der User, die für qualitativ hochwertige Beiträge verantwortlich sind, zu finden und entsprechend zu fördern bzw. wachsen zu lassen. Damit wäre eine Sicherstellung der Qualität der Beiträge im Sinne des Web 2.0 gewährleistet.

Ganz ohne einen Abgleich und Koordination der Moderatoren wird eine Plattform allerdings nicht auskommen. Damit hat sich auch die Rolle der Moderatoren geändert: aus einer klassischen Web 1.0-Administration, d. h. dem chronologischen Reagieren auf Useranfragen und dem Einstellen von Inhalten in gewohnter Top-Down-Manier, hin zu einer flexiblen und unterstützenden Moderationsaufgabe. Hierbei ist es besonders wichtig, dass die Moderation die Community-Mitglieder vermehrt „von unten“ unterstützt und zum selbständigen Verfassen von Beiträgen anregt. Eine Balance von unterstützenden Eingriffen und dem Gewähren beiträgender Freiheit zu finden, stellt eine zentrale Herausforderung für die Moderation im Sinne des Web 2.0 dar.

Aus der PWM-Umfrage 2007 ging schließlich hervor, dass die meisten Mitglieder durch Mundpropaganda bzgl. neuer Communities empfänglich sind. Dieser hohe Stellenwert repräsentiert den persönlichen Vernetzungsaspekt wieder und belegt die Wichtigkeit von persönlichen Empfehlungen über Bekannte, Freunde oder Kollegen. Somit kann ein persönlicher Kontakt die Basis für das Social Networking via Web sein. In der PWM-Umfrage gaben 66% der Befragten an, bis zu 20 Personen aus der PWM-Community privat oder persönlich zu kennen. Für 70% der Befragten sind private bzw. berufliche Kontakte in der PWM-Community ein sehr wichtiger Beweggrund, die Community weiter zu nutzen. Daraus lässt sich der Erfolg einer Online-Community bestätigen, in der sich die Personen nicht nur virtuell, sondern real kennen. Social Networking funktioniert gerade deshalb so erfolgreich, weil sich die Community in virtuellen und realen Beziehungen ergänzt.

Anwendung des PWM Modells auf betriebliches Wissensmanagement

Aus dem PWM-Modell lassen sich wie bereits oben beschrieben viele Anleitungen für das Funktionieren von Communities folgern. Werden nun diese PWM-Community spezifischen Aspekte in ein abstraktes Modell zusammengefasst, können daraus wichtige Schlüsse für das Funktionieren von Communities im betrieblichen Wissensmanagement gezogen werden.

Das bedeutet, dass das PWM-Modell auf eine Ebene abstrahiert wird, die als Grundlage für eine innerbetriebliche Diskussion dienen kann.

Für den Zusammenhang von Communities und Betrieben, ist die Community of Practice die wohl am bekannteste, die nach Lave und Wenger [4] Mitglieder mit gemeinsamen Verantwortlichkeiten oder Tätigkeiten bezogen auf ein bestimmtes Thema vereinen.

Somit kann das Unternehmen in eine innere und äußere Umwelt gegliedert werden. Die innere Umwelt kann verstanden werden als die Mitarbeiter innerhalb des Unternehmens, hingegen spiegelt die äußere Umwelt die Stakeholder eines Unternehmens wider. Die Real World bzw. Community stellt damit eine brauchbare Umgebung für das Unternehmen dar. Das Unternehmen steht selbst mit einer Vielzahl an Stakeholdern in Verbindung und wird von einer membranartigen bzw. durchlässigen Grenze umgeben.

Im Zentrum der Betrachtung bilden die Mitarbeiter die Wissensbasis eines Unternehmens. Im Hinblick auf ein effizientes betriebliches Wissensmanagement geht es um ihre Wissensteilungsprozesse, -generierungsvorgänge und -archivierungsschritte. Der typische Arbeitsplatz eines Wissensarbeiters umfasst einen Arbeits-, Lern- und Wissensraum [5]. Hierbei sollen die Vernetzungsinstrumente eine unterstützende Hilfe leisten und das betriebliche Wissensmanagement bestmöglich vorantreiben. In dem Modell werden wichtige Komponenten einer Community herausgearbeitet, die wesentlich für das Funktionieren von Wissensmanagement in einem Unternehmen sind.

Komponenten einer betrieblichen Community

Grundsätzlich können vier Hauptkomponenten für das Zusammenspiel einer betrieblichen Community unterschieden werden. Erstens bildet die **Real World bzw. Community** die innere Umwelt eines Unternehmens. Dieser Teil ist zugleich der größte und auch Veränderungen am stärksten unterworfenen Bereich.

Zweitens unterstützen **Real World-Vernetzungsinstrumente** den face-to-face-Austausch zwischen den Mitarbeitern eines Unternehmens sowie betriebsfremden Personen. Dazu zählen u. a. Themen-Arbeitskreise und Veranstaltungen wie Treffen, Seminare und Tagungen.

Das dritte Puzzle-Teil bilden die **Virtual World-Vernetzungsinstrumente**, die eine dezentrale und effiziente Kommunikation unter den Mitarbeitern gewährleisten sollen. Über virtuelle Kommunikationsinstrumente, technischen Support für Themenarbeitskreise sowie das rasche Suchen und Finden von Experten bzw. Mitgliedern bestimmter Fachbereiche können Mitarbeiter in ihren Arbeits- und Lösungsfindungsprozessen bestmöglich unterstützt werden. Ein reicher Wissens- bzw. Informationsbestand kann

Lösungen zur Verfügung stellen, die in der Vergangenheit bereits gefunden wurden und durch einen automatisch unterstützten Arbeitsplatz vorgeschlagen werden. Dies erfordert eine konstante Pflege und Wartung des Informationsbestandes durch die Mitarbeiter selbst und mithilfe von Experten zum jeweiligen Thema.

Da der Austausch zwischen den Mitgliedern ein wesentlicher Erfolgsfaktor für Communities ist, sollten Social-Software-Tools angeboten werden, die einen einfachen und raschen Austausch ermöglichen. Dabei braucht allerdings nicht die ganze Palette verfügbarer Anwendungen, vom Weblog bis hin zum gemeinschaftlichen Bookmarking, angeboten werden, sondern sollen solche Anwendungen zum Einsatz kommen, die die gewünschten Ziele bestmöglich unterstützen [2].

Den vierten Bereich bildet die **Moderatorin bzw. der Moderator**, das ist eine oder mehrere zu bestimmende Personen, die sowohl Anlaufs- wie Initiatoraufgaben über hat bzw. haben. Die Moderatorin sorgt in weiterer Folge für einen effizienten Informationsaustausch zwischen den Mitarbeitern eines Unternehmens, unterstützt die Vernetzung einzelner Communities im Unternehmen sowie fördert die Vernetzung mit interessanten unternehmensexternen Communities.

Das vorrangige Ziel einer betrieblichen WM-Community sollte sein, eine enge Verknüpfung von face-to-face-Aktivitäten und starken, vernet-




Abb. 5. Zusammenspiel wichtiger Elemente einer betrieblichen Community

zenden Technologien zu erreichen. Dabei spielen die realen und virtuellen Komponenten einer betrieblichen Community zusammen. Umso stärker die einzelnen Vernetzungsinstrumente genutzt werden, desto intensiver ist die Verschmelzung von realen und virtuellen Instrumenten und somit auch von der Real mit der Virtual World. In weiterer Folge kann es für das betriebliche Wissensmanagement gleichwertig sein, ob eine Problemlösung über die virtuellen und/oder realen Vernetzungsaktivitäten zustande gekommen ist. Es können Netzwerkverbindungen über den realen oder virtuellen Weg hergestellt werden, über beide, und es wäre sogar denkbar, dass sich Communities bilden ohne genau zu wissen, woher der ursprüngliche Kontakt entstanden ist. Für die Lösung einer Problemstellung ist es im Grunde genommen unwichtig, ob nun reale und/oder virtuelle Vernetzungsinstrumente herangezogen werden. Gerade die Kombination aller Puzzle-Teile – Real World, Virtual World, Moderatorin und Community – scheinen ein viel größeres Potenzial an Lösungsmöglichkeiten für das betriebliche Wissensmanagement zu haben als ein isolierter Zugang.

Wird das Zusammenspiel wesentlicher Elemente einer Community aus einem Perspektiven-Blickwinkel betrachtet, ließe sich außerdem der Schluss ziehen, dass die Verschmelzung von vier Dimensionen in einer gesteigerten Umsicht und eines größeren Verständnisses resultiert. Mehr Dimensionen eröffnen einen breiteren Zugang zu einem Problem und auch zum Finden neuer Netzwerkbeziehungen. So werden aus neuen Kontakten neue Impulse in einen Problemlösungsprozess eingebracht und gleichzeitig die realen Beziehungen zu den Mitgliedern eines Netzwerks gestärkt. Damit erweitert sich das bestehende Netzwerk um reale Personen, die mittels Real World- oder Virtual World-Netzwerkinstrumenten gewonnen wurden. Aus dieser Annäherung der beiden Welten, können die Grenzen der Real World- und Virtual World-Instrumente zunehmend verwischen und verfließen.

Zusammenfassung

Der Beitrag soll aufzeigen unter welchen Grundbedingungen Communities im Web 2.0 funktionieren. Hierfür wurde das Beispiel der Plattform Wissensmanagement als eine erfolgreiche WM-Community im deutschsprachigen Raum herangezogen. Es wurden die wesentlichen Elemente einer Community erarbeitet und das Thema Web 2.0 als Chance für eine mögliche Weiterentwicklung angesehen. Abgeleitet aus den PWM-spezifischen Erkenntnissen können wichtige Elemente für das betriebliche WM abstrahiert werden.

Social Networking verfolgt das übergeordnete Ziel (bestehende) Netzwerkbeziehungen zu intensivieren und weiter auszubauen. Dabei kommen

Real World als auch Virtual World-Vernetzungsaktivitäten zusammen, die im Web 2.0 zunehmend miteinander verschmelzen. Der Erfolgsfaktor von Communities kann in den durch reale Netzwerkaktivitäten entwickelten und gefestigten Beziehungen der Community-Mitglieder gesehen werden. Erst aufgrund von realen Begegnungen werden virtuelle Netzwerkverbindungen in greifbare und verwertbare Beziehungen verwandelt.

Danksagung

Das Know-Center wird im Rahmen des Österreichischen COMET-Programms – Competence Centers for Excellent Technologies – gefördert. Das Programm steht unter der Schirmherrschaft des Österreichischen Bundesministeriums für Verkehr, Innovation und Technologie, des Österreichischen Bundesministeriums für Wirtschaft und Arbeit und des Landes Steiermark. Die Abwicklung des Programms erfolgt durch die Österreichische Forschungsförderungsgesellschaft FFG.

Literatur

1. Bughin, J. R. (2007) How companies can make the most of user-generated content: The success of online participatory media – video-sharing sites and corporate wikis alike – depends on the quality contributions of a small core of enthusiasts, *The McKinsey Quarterly*, Web exclusive
2. Dösinger, G., Thurner, C. (2007) Wissenscommunities – Was funktioniert und was nicht! *wissensmanagement – Das Magazin für Führungskräfte* 8/07, S. 22–23
3. Hasler Roumois, U. (2007) Studienbuch Wissensmanagement: Grundlagen der Wissensarbeit in Wirtschafts-, Non-Profit- und Public-Organisationen, Zürich, S. 99–104
4. Lave, J., Wenger, E. (1991) *Situated learning: Legitimate peripheral participation*, New York
5. Lindstaedt, S. N., Farmer, J. (2004) Kooperatives Lernen in Organisationen, in: *CSCL-Kompodium – Lehr- und Handbuch für das computerunterstützte kooperative Lernen*, München, S. 191–200
6. O'Reilly, Tim (2002) What is Web 2.0, In: <http://www.oreillynet.com/pub/a/oreilly/tim/news/2005/09/30/what-is-web-20.html>, 14. August 2007
7. Preece, J. (2001) Online communities: Usability, Sociability, Theory and Methods, in: Earnshaw R., Guedj R., van Dam A. and Vince T. (Eds) *Frontiers of Human-Centred Computing, Online Communities and Virtual Environments*, Amsterdam, S. 263–277
8. Rath A. S., Weber N., Kröll M., Dietzel O., Granitzer M. and Lindstaedt S. N., *Context-aware Knowledge Services, Personal Information Management: PIM 2008, CHI 2008 Workshop, April 5–6, 2008, Florence, Italy* (in press)

16. Explorative Netzwerkanalyse im Living Web

Gernot Tscherteu¹ und Christian Langreiter²

¹ Realitylab – mediadesign and research, Wien, Österreich
gt@realitylab.at

² synerge development services, Langkampfen, Österreich
chris@langreiter.com

Zusammenfassung: Die Zahl von Netzwerkakteuren steigt ebenso beständig wie die Menge an Inhalten, die von denselbigen produziert wird. Wir stellen visuell orientierte explorative Werkzeuge vor, die bisher unsichtbare Netzwerkprozesse und Zusammenhänge aus der Vogelperspektive darstellen sollen. Anhand unseres Projekts „MemeMapper“ untersuchen wir weiters, wie wir als Designer und Entwickler dazu beitragen können, dass sich Nutzer effektiver informieren und an der Produktion von Inhalten in ihrem Netzwerk beteiligen können.

Einleitung

Die Entwicklung des Webs hin zu einem Living Web¹ stellt neue Anforderungen an Suchwerkzeuge. Eine immer größere Zahl von Nutzern nimmt eine aktive Rolle im Web wahr: als Weblog-Autoren, als Akteure auf Sites wie Flickr (Photo Sharing), del.icio.us (Link Sharing), Facebook und MySpace (Social Networking).²

Mit diesem Rollenwechsel ändert sich auch die Wahrnehmung von Netzwerkprozessen und es entsteht ein verändertes Bedürfnis nach Übersicht und Information: Neben der anlassorientierten Suche mittels Google und ähnlicher traditioneller Suchmaschinen entsteht bei Autoren und Akteuren zunehmend das Bedürfnis, sich ihre Netzwerkumgebung und bestimmte Bereiche aus der Vogelperspektive zu betrachten und systematisch zu erkunden.

¹ Living Web wird oft synonym mit „Web 2.0“ verwendet und steht für die Gesamtheit aller Internetmedienformate, bei denen eine Vielzahl von Nutzern selbst „Content“ schaffen, also von Konsumenten zu Produzenten werden.

² Siehe: <http://www.flickr.com>, <http://del.icio.us/>, <http://www.facebook.com>, <http://www.myspace.com/>, aufgerufen jeweils am 09.01.2008

In diesem Artikel folgen wir dieser Entwicklung und stellen Werkzeuge für die Exploration solcher Netzwerke vor.

Klassische Suche à la Google

So sehr sich Google derzeit auch mit Web-2.0-Applikationen schmücken mag, der eigentliche Such-Service stammt aus einer Zeit, in der das Web noch klar in Produzenten und Konsumenten geteilt war. Er wendet sich primär an den Konsumenten, der spezifische Informationen schnell und präzise finden will.

Es wird allgemein anerkannt, dass Google diese Aufgabe nach wie vor ausgezeichnet erfüllt und somit verdient die Marktführerschaft verteidigt. Google ist zu einem De-facto-Standard geworden und hat unser Suchverhalten und unsere Erfahrung des Webs nachhaltig geprägt; dies könnte man wie folgt charakterisieren:

- Der Suchvorgang ist anlassorientiert und folgt dem Pull-Paradigma. Suchmaschinen werden nicht selbständig aktiv, sondern erst auf Initiative des Nutzers.
- Es wird nur gefunden, was in Form einer Suchabfrage textuell formuliert werden kann. Nach Themen, deren Existenz oder textuelle Repräsentation noch nicht bekannt ist, kann demnach schwerlich gesucht werden. Oft sind passende Schlüsselbegriffe erst das Ergebnis langwieriger Recherche.
- Ergebnisse sind nach Relevanz geordnet. Ziel ist es, „hochwertige“ Information zu finden – dies ist nicht gleichbedeutend mit dem Ziel, die ursprüngliche Quelle einer Information zu finden.
- Google ist völlig textorientiert. Auf die Möglichkeit weitergehender Visualisierung wird verzichtet. Die Anmutung der Ergebnislisten ist zum oft kopierten Vorbild für viele andere Dienste geworden.
- Insgesamt fördert Google ein Nutzungsverhalten, bei dem Sucher von Site zu Site springen. Ein Bewusstsein für eventuell dahinter liegende Organisationsmuster kann sich kaum entwickeln.

Akteure suchen anders

In den letzten Jahren ist die Zahl der Web-Akteure, die Information nicht nur konsumieren, sondern auch produzieren, gewaltig gestiegen.³ Produ-

³ Technorati trackt derzeit 112.8 Millionen Weblogs. Siehe <http://technorati.com/about/>, Stand: Februar 2008

zenten von Information zeigen notwendigerweise ein anderes Such- und Informationsbeschaffungsverhalten. Sie sind nicht nur daran interessiert, Informationen zu finden, von deren Existenz sie schon wissen, sondern sie verfolgen als Akteure strategische Ziele und haben das Bedürfnis, ihre Netzwerkumgebung besser kennenzulernen. Aus unserer Sicht sind in diesem Kontext vor allem zwei Ressourcen von großer Wichtigkeit:

- **Aufmerksamkeit.** Akteure wollen nicht notwendigerweise ein Maximum an Besuchern. Die meisten Autoren wünschen sich aber ein gewisses Ausmaß an Resonanz, das den Aufwand, ein Weblog zu führen oder in einem Netzwerk aktiv teilzunehmen, rechtfertigt. Aufmerksamkeit ist somit ein wesentlicher Motivationsfaktor und kann in manchen Fällen auch in andere Werte wie Anerkennung, Prestige oder auch beruflichen und finanziellen Erfolg (etwa durch das Schalten von Anzeigen) umgesetzt werden.
- **Inhalte.** Um Aufmerksamkeit zu erregen, müssen Akteure etwas bieten, das Rezipienten anlockt. Entweder sie führen ein aufregendes Leben, sind besonders kreativ, sind Experten auf gewissen Gebieten oder haben einfach nur eine originelle Form, Dinge zu kommentieren. Die Produktion von Inhalten im Web erfolgt sehr selten völlig autonom. In der Regel ist es für Produzenten wichtig, gut informiert zu sein; letztlich werden in vielen Fällen die Inhalte Dritter verarbeitet.

Aufmerksamkeit und Inhalte sind somit zugleich Input und Output von Netz-Aktivitäten. Inhalte werden benötigt, um selbst Inhalte und damit Aufmerksamkeit zu erzeugen. Die so erzeugte Aufmerksamkeit ist wiederum die Triebfeder, weiterzumachen.⁴

Nicht zuletzt aus diesem Grund sind in den letzten Jahren zahlreiche Services entstanden, die es Akteuren wesentlich erleichtern, sich nachhaltig mit diesen Ressourcen zu versorgen bzw. in Netzwerkprozesse einzuklinken. Oftmals verfügen diese Services über Push-Elemente, die Nutzer zu interessanten Informationen führen, ohne dass diese explizit danach suchen hätten müssen; dies sei anhand des Beispiels del.icio.us⁵ näher erklärt.

Auch ohne jegliche soziale Funktionalität wäre del.icio.us ein ausgezeichnetes Werkzeug, um Bookmarks mithilfe von Tags (Schlagwörtern) zu organisieren. Der Umstand, dass viele andere Personen ebenso del.icio.us und Tags verwenden, macht es zu einer einzigartigen Informationsquelle, die man – einmal ausprobiert – nicht mehr missen möchte.

⁴ Beide Güter sind zwar beschränkt vorhanden, aber nicht notwendigerweise knapp: Sowohl das Bedürfnis nach Aufmerksamkeit als auch der Wunsch nach Information sind sehr subjektive Größen.

⁵ Siehe: <http://del.icio.us>, aufgerufen am 09.01.2008

Im Folgenden sei ein typisches del.icio.us-Erlebnis illustriert:

- Surferin A entdeckt eine informative Site und bookmarkt sie mittels del.icio.us.
- Die eben entdeckte Site trifft ihr aktuelles Interesse so genau, dass sie sich die Frage stellt, welche Personen die Site sonst noch gebookmarkt haben mögen – denn diese Personen könnten eines, vielleicht auch mehrere, ihrer Interessen teilen. del.icio.us listet erfreulicherweise nur eine Handvoll Personen auf, was die Nachforschungen wesentlich erleichtert.
- Bei der Recherche stellt sich heraus, dass Surfer B eine Reihe ähnlicher Projekte mit dem Tag Y beschlagwortet hat. Surfer B scheint also in Bezug auf *Tag Y* ähnliche Interessen zu verfolgen.
- Surferin A abonniert *Tag Y* von Surfer B und fügt ihn ihrem del.icio.us-„Network“ hinzu.
- Immer, wenn Surfer B eine neue Seite mit dem Tag Y hinzufügt, ist Surferin A unmittelbar informiert. Dadurch, dass sich die Interessen in diesem (durch ein Tag repräsentierten) Punkt überlagern, können sie sich gegenseitig helfen, sich mit relevanten Inhalten zu versorgen.

Hier muss angemerkt werden, dass man bei der Recherche noch keineswegs optimal unterstützt wird. In der Praxis führen Netzwerkexplorationen in del.icio.us von Nutzer zu Nutzer und von Tag zu Tag, bis schließlich eine Liste von handverlesenen Quellen lokalisiert werden kann. Die Mühe lohnt, denn bestimmte Nutzer/Tag-Kombinationen können für die eigene Informationsarbeit von ganz essentieller Bedeutung sein. Die Recherchearbeit anderer Nutzer kann in die eigene Informationsarbeit integriert und Teil einer umfassenderen Informationsökologie werden.

Es gibt bereits eine Reihe von Prototypen, welche die Netzwerkexploration des del.icio.us-Netzwerks erleichtern können.⁶ Keiner dieser Ansätze wurde allerdings bis dato direkt in den Service übernommen.

Explorative Werkzeuge

Auch in vielen anderen Bereichen gibt es intensive Bemühungen, Netzwerke zu visualisieren und damit die Suche nach interessanten Knotenpunkten und nachhaltigen Informationsquellen zu erleichtern.

Im Folgenden werden einige Beispiele vorgestellt, die eine Ahnung davon vermitteln, wie uns insbesondere visuell orientierte Tools in Zukunft unterstützen könnten, aber ebenso, mit welchen Schwierigkeiten sie zu kämpfen haben.

⁶ Siehe <http://www.visualcomplexity.com/vc/search.cfm?input=del.icio.us>, aufgerufen am 09.01.2008

Social Circles

Social Circles⁷ visualisiert den Mail-Verkehr von Mailing-Listen.

- Mitglieder der Mailing-Liste werden als Knoten dargestellt.
- Die Knotengröße korreliert mit der Anzahl von Mails, die von einem Akteur versandt wurden.
- Antwortet ein Akteur auf Mails eines anderen Akteurs, so wird zwischen ihnen eine Kante eingezeichnet.
- Akteure mit vielen Verbindungen schreiben offensichtlich über Dinge, welche auf allgemeines Interesse stoßen. Diese Akteure werden im Graphen zentral dargestellt.

Interessant ist zu beobachten, dass Größe nicht notwendigerweise mit Zentralität einhergeht. Es gibt Akteure, die viel schreiben, aber auf deren




Abb. 1. Social Circles von Marcos Weskamp

⁷ Erreichbar unter: <http://www.marumushi.com/apps/socialcircles/index.cfm>, aufgerufen am 09.01.2008

Mails selten reagiert wird, und es gibt Akteure, die wenig schreiben, deren Beiträge aber regelmäßig breites Echo in der Community auslösen. So bietet Social Circles nützliche Anhaltspunkte für Neuankömmlinge, die sich orientieren wollen.

Blogopole

Blogopole⁸ wurde anlässlich der Wahl des französischen Staatspräsidenten 2007 entwickelt und stellt die Landschaft politisch orientierter französischer Sites und Weblogs dar.




Abb. 2. Blogopole.fr. Quelle: ebd.

⁸ Erreichbar unter: <http://www.blogopole.fr/>. Anlässlich der US Präsidentschaftswahlen 2008 gibt es von den Blogopole-Autoren einen ähnlichen Service unter <http://presidentialwatch08.com>. Aufgerufen jeweils am 09.01.2008.

Zur besseren Übersicht wurden diese in verschiedene politische Lager gruppiert. Eine besondere Gruppe bilden „Les Analystes“, bei denen es sich im Wesentlichen um Weblogs professioneller Kommentatoren und engagierter Privatpersonen handelt. Sie nehmen – wenig überraschend – eine zentrale Position ein, da sie ganz wesentlich zur wechselseitigen Verknüpfung aller Lager beitragen.

- Knoten repräsentieren Sites und Kanten Links zwischen diesen.
- Wählt man einen Knoten aus, so werden dessen Verbindungen farbig hervorgehoben.
- Spezielle Tools erlauben tiefergehende Analysen des Graphen.
- Zentral für die Aussage der Blogopole-Visualisierung ist die Darstellung von Nähe- und Fernverhältnissen, die aus der Linkstruktur abgeleitet werden. Je ähnlicher zwei Knoten in Bezug auf ihre Linkstruktur sind, umso näher werden sie in der Karte abgebildet.
- Das Tool eignet sich zur wissenschaftlichen Auseinandersetzung. Am interessantesten ist es aber wohl für die politischen Akteure und Autoren selbst, die sich in bestimmten Lagern und an bestimmten Positionen verortet wiederfinden.

Vizster


Vizster⁹ ist eine Software-Studie, die Freundschaftsbeziehungen auf der Dating-Plattform „Friendster“ visualisiert.

„Friendster was designed to be an online dating site, complete with profiles, demographic and interest driven search, and a private messaging system. What made Friendster unique was its articulated social networking component and testimonial feature. Users were asked to declare „friends“ on the system whose pictures would also appear on the profile when the friends confirmed the relationship. [...] Yet, when the early adopters began to use the service, they did not view it as a dating service, but a site where they could gather and communicate with their friends, surf for entertaining profiles and explore public displays of identity and relationships.“ [11, S. 2]

Mit Vizster können Friendster-Nutzer ihre soziale Umgebung erforschen:

- Bewegt man den Mauszeiger über einen Knoten, so werden Profildaten wie Name, Geschlecht, Anzahl der Freunde, Interessen, Lieblingsfilme, -bücher und dergleichen eingeblendet.

⁹ Die Studie ist abrufbar unter: <http://jheer.org/vizster/>, aufgerufen am 09.01.2008



- Durch die Selektion bestimmter Merkmale (populär zum Beispiel „weiblich“ und „single“) werden alle Akteure im Netzwerk hervorgehoben, die diese Merkmale aufweisen.
- Es können auch gemeinsame Freunde entdeckt und Personen identifiziert werden, die für den Zusammenhang einer Gruppe wichtig sind; des weiteren Akteure, die für die Kommunikation zwischen Gruppen als Brücken fungieren.
- Es werden Teilnetze identifiziert, in denen es eine höhere Dichte an Relationen zwischen den Akteuren gibt. Zur leichteren Erkennbarkeit werden diese Teilnetze farbig hinterlegt.

¹⁰ Informationen im Web unter: <http://vlado.fmf.uni-lj.si/pub/networks/pajek/>,
aufgerufen am 09.01.2008

und UCINet¹¹ Laien anspricht. Ziel sind kaum wissenschaftliche Erkenntnisse, sondern die Entdeckung von Freundschaftsbeziehungen und Ähnlichkeiten zwischen Personen. Durch Spezialisierung und gleichzeitige Vereinfachung des Vorgangs der Netzwerkanalyse gab Vizster die Entwicklungsrichtung für eine Reihe weiterer Projekte vor.

Mittlerweile gibt es für alle größeren Social Networking Services wie MySpace, Facebook und dessen deutschsprachigen Klon StudiVZ Visualisierungstools zumindest in Form ernstzunehmender Prototypen.¹²

TouchGraph Facebook Browser

Eines dieser Tools möchten wir hier exemplarisch vorstellen; nicht zuletzt deshalb, weil dieses auch uns bisher am besten vermitteln konnte, wie sich interaktiv-explorative Netzwerkanalyse „anfühlen“ kann.

Die „explorative Erfahrung“ des TouchGraph Facebook Browsers können wir als durchaus prägend bezeichnen, auch wenn dieser einer solchen Erfahrung seitens Facebook (wohl zu Recht) einige Hindernisse in den Weg gelegt wurden: So ist es unmöglich, in Profile Einsicht zu nehmen, wenn diese nicht freigegeben wurden. Innerhalb eines „Facebook-Netzwerks“¹³ ist es aber durchgehend die Regel, dass Profile mehr oder weniger vollständig sichtbar sind – und somit Freundschaftsbeziehungen abgebildet werden können.

Um der drohenden Datenknappheit zu entgehen, bedient sich das Tool eines Kniffs – es werden nicht nur explizit angegebene Freundschaftsbeziehungen dargestellt, sondern auch gemeinsames Vorkommen auf entsprechend annotierten Photos. Wenn zwei Personen gemeinsam auf einem Photo zu finden sind, werden sie durch eine Kante miteinander verbunden. Der Wert auf der Kante gibt an, auf wie vielen Bildern die Personen ge-

¹¹ Informationen im Web unter: <http://www.analytictech.com/ucinet/ucinet.htm>, aufgerufen am 09.01.2008

¹² Für MySpace: „Comment Flow“, erreichbar unter: <http://web.media.mit.edu/~dietmar/myspace.html>, aufgerufen am 09.01.2008
Für StudiVZ: „StudiaAnalyse“, erreichbar unter: <http://turrican.unixag-zw.fh-kl.de/studianalyse/>, aufgerufen am 09.01.2008
Für Facebook: „Interactive Friends Graph“ erreichbar unter: <http://www.facebook.com/apps/application.php?id=4079090761&b&ref=pd>, aufgerufen am 09.01.2008

¹³ Irreführenderweise bezeichnet Facebook eine Menge von Personen mit gemeinsamen Merkmalen in Bezug auf Ausbildung und Nationalität als „Netzwerk“. Alle Personen, die in Österreich leben oder ebenfalls die Universität Wien besuchen oder besucht haben, gehören deshalb potentiell demselben „Netzwerk“ an.

meinsam fotografiert wurden. Diese Funktion ist gleichermaßen unterhaltsam wie informativ, da sich dadurch relativ leicht rekonstruieren lässt, wer bspw. dieselbe Klasse besucht und wer sich mit wem auf welchen Partys herumgetrieben hat.

Innerhalb des eigenen Netzwerks (insbesondere im Falle von großen Netzwerken mit zehntausenden Mitgliedern – z. B. „Österreich“) ist es damit beängstigend einfach geworden, die Aktivitäten von Cliques und das Verhältnis von Personen (Bilder sagen in der Tat mehr als Worte) zu verfolgen.¹⁴

Die TouchGraph-Erfahrung ist eine wesentlich andere als etwa das Schmökern auf einzelnen Profelseiten. Die Stärke der Beziehungen zwischen Personen und ihrer Zusammengehörigkeit in Cliques ist unmittelbar ersichtlich.




Abb. 4. TouchGraph Facebook Browser. Quelle: Screenshot

¹⁴ Einige der Akteure werden ihre Facebook-Zeit vermutlich noch bereuen, weil ihre Jugendsünden minutiös dokumentiert werden.

Die Sprache der Netzwerkgraphen

Die visuelle Sprache von Netzwerkdarstellungen erscheint zunächst recht einfach: Es ist intuitiv nachzuvollziehen, dass ein Knoten einen Akteur repräsentiert und die Kanten zwischen diesen für Verbindungen stehen. Bei genauerer Betrachtung zeigt sich allerdings, dass es unterschiedlichste Formen der Verbindung zwischen Akteuren geben kann und dass die meisten Darstellungen den Nutzer im Unklaren darüber lassen, um welche Art von Verbindung es sich im Konkreten handelt.

In den oben genannten Fällen stehen Kanten für:

- Social Circles: Antwort auf Mail.
- Blogopole: Link einer Site zu einer anderen.
- Vizster: Freundschaftsbeziehung.
- TouchGraph Facebook Browser: Freundschaftsbeziehung oder gemeinsames Aufscheinen auf einem Photo.

Die Bedeutung von Kanten ist in vielen Fällen nicht unmittelbar ersichtlich, was ein großes Hindernis auf dem Weg zum Verständnis einer Visualisierung darstellt.

Gerichtete Kanten werden oft in Form von Pfeilen visualisiert. Ungerichtete Kanten stellen üblicherweise symmetrische Verbindungen dar: Person A wählt B zum Freund und umgekehrt. Blogopole hingegen stellt die Richtungen der Verbindungen nicht in Pfeilform dar, sondern mithilfe von Farbcodes – und verwendet dabei nicht weniger als fünf Farben, was die Lesbarkeit nicht unbedingt erleichtert. Gerade bei Links zwischen Sites ist die Richtung eine zentrale Information, die ohne größere Anstrengung gut erkennbar sein sollte.

Auch die räumliche Anordnung – insbesondere die Nähe von Akteuren zueinander – muss durchaus unterschiedlich interpretiert werden:

- Social Circles: Alle Akteure sind auf einem Kreis angeordnet, doch jene Akteure, deren Mails besonders viele Antworten erhalten haben, rücken ins Zentrum.
- Blogopole: Akteure, zwischen denen viele Verbindungen bestehen, „verklumpen“ zu Clustern.
- Vizster: Im Zentrum steht ein bestimmter Akteur, rundherum bilden sich dort Cluster, wo Freunde untereinander besonders viele Verknüpfungen aufweisen.
- TouchGraph Facebook Browser: Siehe Vizster.

Offensichtlich hat man sehr großes Vertrauen in die Geduld und die interpretativen Fähigkeiten der Nutzer, was sich aber nicht mit unseren Erfahrungen aus der Praxis des Interface- und Interaction-Designs deckt.

Während Social Circles und Blogopole Netze allgemeiner Art darstellen, handelt es sich im Falle von Vizster und TouchGraph Facebook Browser um sogenannte Ego-Netzwerke. In solchen werden nur Akteure dargestellt, die mit dem zentralen Akteur („Ego“) direkt oder in zumindest naher Verbindung stehen. Entferntere Akteure werden ausgeblendet.

Da das Netz von „Ego“ ausgehend ermittelt wird, scheint der zentrale Knoten in solchen Darstellungen oft überproportional gut verbunden – was den tatsächlichen Verhältnissen nicht notwendigerweise entspricht. Um diese Verzerrung beseitigen zu können, bietet bspw. der TouchGraph Facebook Browser die Möglichkeit, „Ego“ und seine Verbindungen auszublenden, woraufhin sich der Graph neu anordnet und ein sozio-zentriertes Netzwerk bildet. In dieser Darstellung lassen sich leichter zentrale Akteure (nach wie vor allerdings aus der Umgebung „Egos“!) ermitteln.

Schließlich kann auch die Größe eines Knotens unterschiedliche Bedeutung haben.

- Social Circles: Größe korreliert mit Anzahl der von einem Akteur verfassten Mails.
- Blogopole: Größe korreliert mit Anzahl eingehender Links Autorität oder Page Rank
- Vizster: Alle Knoten werden gleich groß dargestellt.
- TouchGraph Facebook Browser: Je mehr Freundschaftswahlen ein Akteur erhält, umso größer wird der Knoten dargestellt.

Diese Beispiele genügen, um zu zeigen, dass Netzwerkgraphen nicht so einfach zu interpretieren sind, wie es auf den ersten Blick scheinen mag. Intuitiv erfassbar sind zentrale Positionen und Größenverhältnisse, doch wie gezeigt wurde, können diese völlig Unterschiedliches bedeuten; wie die Rückmeldungen von Laiennutzern zeigen, ist keines der vorgestellten Werkzeuge selbsterklärend – ganz im Gegenteil, Nutzer hatten beträchtliche Schwierigkeiten beim Lesen der Darstellungen:

„To be honest, I had some trouble getting the hang of how to use this app. It was kind of confusing. After a few minutes, though, I was having some fun.“¹⁵

Es lassen sich beim Kennenlernen von Netzwerkdarstellungen folgende Phasen erkennen:

- Neugierde: Man wird von der Anmutung – oft auch der Komplexität – der Darstellung angezogen.
- Interaktives Ausprobieren: Was passiert, wenn ich auf einen Knoten klicke oder ihn ziehe?

¹⁵ Siehe <http://www.bestfacebookapplications.com/2007/06/28/touchgraph-photos-facebook-application/>, aufgerufen am 09.01.2008

- Fragestellen: Was bedeutet diese oder jene Darstellungsform genau?
- Je nachdem, ob das jeweilige Tool solche Fragen zufriedenstellend beantworten kann, folgt darauf entweder Nachlassen des Interesses oder intensivere Erforschung des Graphen.

Somit scheint es sinnvoll, Netzwerkdarstellungen nicht nur mit einer Legende zu versehen, sondern auch Interaktionsmöglichkeiten wie Mouse-Overs bzw. Tool-Tipps ausgiebig zu nutzen, um den Betrachter zu instruieren. Narrative Elemente wie kontextspezifisch angebotene Erklärungen diverser Visualisierungsdetails können den Lernprozess vereinfachen. Unserer Einschätzung nach sollten die Interaktion mit Netzwerkdarstellungen und das Erlernen ihrer Bildsprache gleichzeitig vermittelt „learning by doing“ und nicht sequentiell erfolgen.

Metriken

Noch schwieriger als das Lesen einer visuellen Darstellung fällt es Laien oft, Metriken und analytische Konzepte der sozialen Netzwerkanalyse zu verstehen.

Indegree/Outdegree

Es gibt allerdings auch Metriken, die auch von einem Laien leicht erfasst werden können, wie z. B. „Indegree“ und „Outdegree“: Eine Seite im Web linkt zu anderen Seiten und umgekehrt.

- *Indegree*: Anzahl der eingehenden Verbindungen (incoming links, referers).
- *Outdegree*: Anzahl der ausgehenden Verbindungen (outgoing links, references).¹⁶

Im Falle einer Web-Seite ist es trivial, den Outdegree zu ermitteln: Man zählt die darin enthaltenen Links. Um den Indegree zu ermitteln, müsste man alle anderen Seiten des Netzwerks (das im schlimmsten Fall das gesamte Web umfassen könnte) besuchen und die darin enthaltenen Links zur betreffenden Seite zählen – der Indegree ist somit technisch wesentlich schwieriger zu ermitteln, konzeptionell aber nicht schwerer zu verstehen als der Outdegree und eignet sich somit als einfaches Zentralitäts- und Prestigemaß.

¹⁶ Vgl. [12] sowie [22]

Innerhalb eines Freundschaftsnetzwerks à la Facebook werden „Cliquenchefs“ typischerweise hohe Degrees aufweisen¹⁷. Abb. 4 zeigt Akteur „Julius“ mit dem höchsten Degree – wenig überraschend, denn es handelt sich um das „Ego“ in diesem Egonetzwerk. Auch Akteur „Theodor“ verfügt über hohe Degrees.

Um nachverfolgen zu können, wie sich Neuigkeiten innerhalb eines Netzwerks verbreiten, ist es von besonderem Interesse, zu eruieren, wie Nachrichten die Grenze einzelner Cliques überwinden. Für die Nachrichtenverbreitung sind aber nicht notwendigerweise jene Akteure verantwortlich, die einen hohen Degree aufweisen – es sind oft Akteure, die summa summarum eine geringere Zahl von Verbindungen aufweisen können, aber in unterschiedlichen Cliques verkehren. Um diese zu identifizieren, ist ein Maß wie die Betweenness-basierte Zentralität besser geeignet.

Betweenness-basierte Zentralität

Die betweenness-basierte Zentralität misst die Abhängigkeit der restlichen Akteure von einem bestimmten Netzwerkknoten: Wie oft liegt Akteur X auf der geodesischen (kürzesten) Verbindung zwischen zwei Akteuren?¹⁸ Im Falle von m Akteuren gibt es $m \cdot (m-1)$ geodesische Verbindungen.¹⁹ Cut-Points, Akteure, die zwei Teilnetze miteinander verbinden, weisen eine hohe Betweenness auf.

Praktischerweise kann auch der TouchGraph Facebook Browser diese Metrik berechnen: Dabei zeigt sich beispielsweise, dass „Josefine“ einen wichtigen Cut-Point zwischen zwei Teilnetzen darstellt – wenn Nachrichten vom einen ins andere fließen sollen, dann könnte Josefine dabei eine wichtige Rolle spielen, obwohl sie relativ wenige Freundschaftswahlen aufweist.

Soziale Netzwerke versus Blogosphäre

Während relationale Daten (z. B. Freundschaftsbeziehungen) in sozialen Netzwerken oft nur beschränkt allgemein zugänglich sind, um die Privatsphäre der Akteure zu schützen, sind solche Daten, insbesondere Linkstrukturen, in der Blogosphäre zum großen Teil öffentlich. Allein anhand der Links, die Weblogs empfangen bzw. setzen, lassen sich aussagekräftige Netzwerke generieren. Doch obwohl die Daten in diesem Fall relativ

¹⁷ Da es sich hier um ein ungerichtetes Netzwerk (ohne Pfeile) handelt, gibt es keine Trennung in In- und Outdegree.

¹⁸ Vgl. [12, 134 ff], [22, 86 f.] sowie [25, 188 ff.]

¹⁹ Vgl. [20, 127]

leicht zugänglich sind, gibt es nur wenige Analysewerkzeuge, die sich direkt an die Akteure richten. Meist werden solche Tools in der Medienanalyse²⁰ bzw. für wissenschaftliche Zwecke²¹ eingesetzt. Es finden sich erst zaghafte Ansätze zur Netzwerkexploration für den Endverbraucher. Diese Lücke von Angeboten zur Netzwerkvisualisierung für Akteure des Living Web wollen wir mit unserem Projekt MemeMapper schließen.

MemeMapper

Das Projekt MemeMapper ist eine Fortführung und Weiterentwicklung eines durch die Autoren anlässlich der ersten BlogTalk-Konferenz 2003 konzipierten und prototypisch implementierten Experiments – der Blogosphere Map [23, 24].

Die grundsätzliche Fragestellung ist nach wie vor dieselbe: Wie verbreiten sich Nachrichten (aller Arten) in dezentralen, vornehmlich öffentlich zugänglichen Informationsnetzwerken wie bspw. der Blogosphäre? Daran anschließend ergeben sich zahlreiche weitere Detailfragen:

- Wie können solche zeitdynamischen Diffusionsprozesse effektiv visualisiert und somit wahrgenommen werden?
- Welche Metriken aus der „klassischen“ sozialen Netzwerkanalyse [12, 22] lassen sich auch in diesem Kontext anwenden? Welche Schlüsse kann man aus den eruierten Werten ziehen?

Die Blogosphere Map war nur eines von so manchen zeitnah durchgeführten Projekten mit ähnlicher Stoßrichtung. Exemplarisch seien hier „Information Diffusion Through Blogspace“ von Gruhl et al. [9] und Blogviz von Manuel Lima [15] angeführt. All diesen ist gemeinsam, dass die Entwicklung bislang nicht in einem von Konsumenten frei verwendbaren Service gemündet hat; genau dieses Ziel verfolgen wir mit dem Projekt MemeMapper.

An potentiellen Anwendungsfällen mangelt es nicht. Zum einen sind Firmen und Marketing-Agenturen naturgemäß an Medienmonitoring in vielgestaltiger Ausformung interessiert, auf der anderen Seite wollen wir Akteuren im Living Web aus schon zuvor dargelegten Gründen ein Werkzeug in die Hand geben, das sie bei der Selbstverortung, Vernetzung und Informationsbeschaffung unterstützt.

²⁰ z. B. Buzzmetrics (<http://nielsenbuzzmetrics.com/>), Buzzlogic (<http://buzzlogic.com/>), Umbria (<http://www.umbrialistens.com/>), aufgerufen jeweils am 09.01.2008

²¹ z. B. LinkRank (<http://linkrank.cs.ucla.edu/>) oder commetrix (<http://www.commetrix.de/>), aufgerufen jeweils am 09.01.2008

Was wird gemappt?

War die Erhebung sozialer Netzwerkdaten in großem Stil in vergangenen Jahrzehnten oft mit beinahe unbewältigbarem Aufwand verbunden, so hat sich die Situation durch das WWW im Allgemeinen und der zunehmenden Verbreitung sozialer Medien im Besonderen geradezu ins Gegenteil verkehrt: Es gibt kaum netzbasierte Services und Phänomene, die nicht zu einer netzwerkanalytischen Betrachtungsweise einladen würden; die Erhebung der entsprechenden Daten zu analytischen Zwecken kann oftmals vollautomatisiert durchgeführt werden oder geschieht auf Betreiberseite implizit und ohne weiteres Zutun im Rahmen des Regelbetriebs.

Im ersten Schritt fokussieren wir unsere Anstrengungen auf die „Blogosphäre“ – mit diesem Begriff wird die Gesamtheit aller Weblogs bezeichnet; während im Fall der Blogosphere Map nur ca. 500 Weblogs regelmäßig (4 mal täglich) eingelesen wurden, so streben wir im MemeMapper-Fall in der ersten Ausbaustufe eine Abdeckung von ca. 100.000 Quellen an. Im Folgenden geben wir einen Überblick über das dahinterliegende technische Konzept.

Feeds

Der allergrößte Teil heutzutage publizierter Weblogs und vieler sonstiger regelmäßig aktualisierter Quellen bietet sog. News-Feeds in XML-basierten Formaten wie RSS oder Atom an [27]. Diese Feeds beinhalten Informationen bezüglich der zuletzt geänderten Postings (im allgemeinsten Sinne – es können mittlerweile auch Börsenkurse, Wetterberichte und ganze Bücher vermittelt RSS abonniert werden); sie stellen unsere primäre Datenquelle dar.

Zur Konsumation solcher Feeds werden üblicherweise Aggregatoren verwendet – diese gibt es in allen Spielarten, sowohl als Desktop-Applikationen als auch als Angebote wie Bloglines oder Google Reader. Aggregatoren lesen abonnierte Feeds in regelmäßigen Abständen ein. Dasselbe passiert im MemeMapper-Fall durch einen Crawler – nur in entsprechend größerem Maßstab.

Diff-Feeds

Steht für eine Quelle kein RSS-Feed zur Verfügung, so kann ein solcher dennoch zumindest approximativ generiert werden, indem Text-Änderungen auf algorithmischem Wege direkt aus dem letztlich zur menschlichen Konsumation gedachten HTML-Quellcode einer Seite eruiert werden; dazu kann bspw. das UNIX-Tool „diff“ zum Einsatz kommen.

Aufgrund der Vielzahl dynamisch generierter Elemente auf heutzutage in „freier Wildbahn“ auftretenden Seiten (angefangen von Timestamps über Comment-Counter bis hin zu automatisch eingefügten Textanzeigen) kann allerdings oftmals bei jedem einzelnen Zugriff eine Vielzahl von Änderungen festgestellt werden, deren Relevanz denkbar gering ist und somit gefiltert werden muss.

Post-Processing & Archivierung

Nachdem Postings durch den Crawler eingelesen wurden und überprüft werden konnte, dass sie tatsächlich neu sind (oftmals erscheinen durch Bugs oder Bedienungsfehler schon veröffentlichte Postings nochmals in RSS-Feeds), werden sie komprimiert und unmittelbar archiviert, um Daten für noch nicht absehbare Forschungsfragen möglichst im Originalzustand vorhalten zu können.

Gleichzeitig werden für die Zwecke des Produktiv-Systems Postings bezüglich Text-Encoding und Feed-Format normalisiert. Auf Basis dieser normalisierten Daten operiert eine ganze Reihe weiterer Analysetools (Konvertierung nach Plain Text, Link-Extraktion, präliminäre Textanalyse etc.), die sukzessive das Original-Posting mit zusätzlichen bzw. restrukturierten Informationen anreichern. Sind alle aktivierten Analyseschritte abgeschlossen, wird das Posting wiederum komprimiert und archiviert.

Indizierung

Schließlich und endlich wird ein um temporale Informationen ergänzter – aber ansonsten klassischer – Volltext-Index mit dem textuellen Inhalt der neuen Postings ergänzt. Zusätzlich wird eine Reihe weiterer Indexstrukturen angelegt, die spezielle Analysen bspw. bezüglich Änderungen in der Linkstruktur performant möglich machen.

Visualisierung

Zur Visualisierung von Netzwerkstrukturen kommen üblicherweise physikalisch motivierte Verfahren zum Einsatz: Zumeist werden Knoten als sich abstoßende elektrische Teilchen, Kanten als diese Teilchen verbindende Sprungfedern modelliert (Spring Embedder/Force-Directed Layout); auf dieses grundsätzliche Modell aufbauend gibt es allerdings eine Vielzahl von Variationen, die zumeist für spezifische Konfigurationen optimiert wurden [13]. Im Fall von Graphen mit hoher Kanten-Anzahl konnten wir mit dem Edge-Repulsion LinLog Model [19] gute Ergebnisse erzielen.

Negativ an vielen Graph-Layout-Algorithmen ist, dass die Berechnungszeit – etwas salopp formuliert – exponentiell mit der Größe des Graphen steigt. Zum Glück wurden in den letzten Jahren u. a. auf dem Gebiet der Molecular Dynamics (Simulation atomarer Interaktionen) bedeutsame algorithmische Fortschritte erzielt. Diese helfen ebenso, den Herausforderungen der Graph-Visualisierung entgegenzutreten [10], was vor allem das qualitativ hochwertige Layout sehr großer Graphen in vielen Fällen erst ermöglicht.

Themen-Tracking

Das finale Infrastrukturelement stellt die Identifikation von Themen dar. Dies geschieht zum einen durch Entity Extraction (die Identifikation von Personen- bzw. Ortsnamen, Firmenbezeichnungen etc.) und zum anderen durch das Erstellen eines „semantischen Fingerabdrucks“.

Diesbezüglich stellt sich vor allem ein Verfahren namens Explicit Semantic Analysis [8] als äußerst vielversprechend dar: In diesem wird auf Basis des in Wikipedia textuell abgebildeten Weltwissens ein Konzeptraum induziert. Repräsentiert man einen Text (bzw. Textfragmente) als gewichteten Vektor in diesem Raum, so können Standardoperationen der linearen Algebra (Vektorkosinus, euklidische Distanz) Aufschluss bspw. über die Ähnlichkeit zweier Fragmente geben [26].

Ein wichtiges Ziel besteht darin, Postings zu ermitteln, die nicht nur in einem thematischen Zusammenhang stehen, sondern die mit hoher Wahrscheinlichkeit über Diffusionsprozesse miteinander verbunden sind. Weblogs können Inhalte direkt von anderen Weblogs übernehmen und/oder sich auf gemeinsame Quellen beziehen. In beiden Fällen werden sich die Postings ähneln und die darin angesprochenen Inhalte kaskadenförmig im Netz ausbreiten. Ist über den zeitlichen und räumlichen Diffusionsprozess hinweg ein inhaltlich thematischer Zusammenhang gegeben, so kann man in Anlehnung an Dawkins von einem „Replikator“ und unter bestimmten Umständen von einer „Meme“ sprechen, die durch die Blogosphäre diffundiert.

Memetik

„Meme“ als Begriff wurde 1976 durch den Biologen Richard Dawkins im letzten Kapitel seines Wissenschafts-Bestsellers „The Selfish Gene“ [5] eingeführt und geprägt:

„The new soup is the soup of human culture. We need a name for the new replicator, a noun that conveys the idea of a unit of cultural transmission, or

a unit of *imitation*. ‚Mimeme‘ comes from a suitable Greek root, but I want a monosyllable that sounds a bit like ‚gene‘. I hope my classicist friends will forgive me if I abbreviate mimeme to *meme*.“ [5, S. 192]

Unabhängig von Dawkins wurden ähnliche Ansätze bspw. auch von Aaron Lynch entwickelt [16, 17] (der ursprünglich eine andere Terminologie verwendete, letztendlich aber sozusagen die Meme des Memenbegriffs übernahm).

Die Idee erwies sich als überaus fruchtbar; nichtsdestotrotz wurde sie auch kontroversiell aufgenommen und hatte von Anfang an mit beträchtlichem Widerspruch zu kämpfen, was sich vor allem aus der praktischen Unüberprüfbarkeit der meisten Vorhersagen im Prä-Web-Zeitalter erklärt. Vielleicht auch durch die inhärente Interdisziplinarität bedingt hat die Memetik nach wie vor kein allzu komfortables Zuhause im Wissenschaftsgebäude gefunden.

Zudem gibt es nicht *die* Theorie der Memetik, die allgemein anerkannt wäre; vielmehr scheint das Rad in dieser Hinsicht gern neu erfunden zu werden: So bezeichnete sich Seth Godin noch im Jahr 2000 als der Initiator des Konzepts eines „ideaviruses“, was unmittelbar zu Plagiatsvorwürfen seitens Lynch führte.

Wir verwenden den Memenbegriff sehr liberal; unsere Definition ist in erster Linie eine operationalisierbare. So mappt der MemeMapper streng gesehen nicht Memes im Lynch’schen Sinne (diese nämlich finden sich nur in den Köpfen „infizierter“ Personen), sondern mediale Artefakte, die das Vorhandensein von Memes vermuten lassen (meme-induced medial artefacts, MIMAs). Dazu zählen URLs, die als Link-Ziel angegeben werden, Schlüsselwörter und vermittels der zuvor erwähnten Verfahren identifizierte Themen bzw. beliebige Kombinationen aus all diesen Möglichkeiten.

Netzwerkinduktion

Strukturell betrachtet gibt es nicht *ein* Netzwerk innerhalb der Blogosphäre, sondern verschiedenste, die je nach Interesse und Aufgabenstellung anhand unterschiedlicher Relationen konstruiert werden können:

- *Blogrolls*: In Blogrolls führen Weblog-Autoren diejenigen Weblogs an, die sie regelmäßig lesen (oder zumindest zu irgendeinem Zeitpunkt regelmäßig gelesen haben – viele Blogrolls scheinen sich allzu selten zu ändern.)
- *Tatsächliches Linkverhalten in Postings*: Werden Links zu anderen Postings explizit gesetzt, so stellt diese die stärkste verfügbare Evidenz einer erfolgten Informationsweitergabe dar.

- *Thematische Ähnlichkeit:* In diesem Zusammenhang sind neuroinspirierte Modelle von großem Interesse – treten ähnliche Themen oft synchron (bzw. leicht zeitversetzt) in zwei Quellen auf, so kann die (gerichtete) Verbindung im Modell verstärkt werden.

Modellbildung

In der Literatur findet sich eine Vielzahl von Ansätzen zur Modellierung von Informationsweitergabeprozessen; in der nachfolgenden Kurzübersicht folgen wir im Wesentlichen [9]:

- In epidemiologisch inspirierten Informationsdiffusionsmodellen wird Themenübernahme durch den Infektionszyklus SIR bzw. SIRS modelliert: Susceptible, Infected/Infectious, Recovered²²; Re-Infektion könnte bspw. durch Themen-Mutationen auftreten.
- In in der Soziologie primär zur Analyse von Innovationsübernahmen entwickelten Threshold-Modellen sind Personen durch gewichtete Kanten verbunden. Eine Innovation wird übernommen, sobald die Summe der eingehenden Kantenwerte aller Adopter (Personen, die eine Innovation schon übernommen haben) einen personenspezifischen Schwellenwert überschreitet.
- Ebenso aus der Soziologie stammende Kaskaden-Modelle zeichnen sich dadurch aus, dass bei jeder Innovationsübernahme in der Nachbarschaft einer Person P mit einer gewissen Wahrscheinlichkeit die Möglichkeit einer ebensolchen Innovationsübernahme *durch* Person P besteht.
- In spieltheoretischen Modellen wird vor allem darauf fokussiert, welchen Nutzen die Übernahme einer Meme Spielteilnehmern bringt; als Beispiel führen Gruhl et al. [9] bspw. die Ablöse von VHS-Geräten durch DVD-Player an – der Nutzen und somit die Wahrscheinlichkeit der Übernahme steigt, wenn sich ein Akteur DVDs aus seiner Netzwerk-Nachbarschaft ausborgen kann.

Empirie vs. Theoriebildung

Unser Interesse besteht allerdings zum gegenwärtigen Zeitpunkt eher darin, der Empirie gegenüber vorschneller Theoriebildung den Vortritt zu lassen und Werkzeuge zu entwickeln, die es ermöglichen, Ausbreitungsprozesse post hoc möglichst comprehensiv zu analysieren und weniger, diese vorauszusagen. Dies scheint auf dem momentanen Stand der Technik nicht mit Praxisrelevanz herstellender Präzision möglich zu sein; wohl

²² Empfänglich (für eine Nachricht), infiziert/infektiös, nicht (mehr) empfänglich

auch deshalb, da die erwähnten Modelle das vielgestaltige Phänomen der Informationsweitergabe und -übernahme nur äußerst fragmentarisch abzubilden versuchen.

Applikationen

Wir verstehen soziale Netzwerkanalyse vornehmlich als analytischen Ansatz, der die (auch und vor allem visuelle!) Exploration eines Datenraums in den Mittelpunkt stellt. Die primäre Applikation auf Basis der Meme-Mapper-Infrastruktur präsentiert sich als animierte Netzwerkansicht im Stile der ursprünglichen Blogosphere Map, doch mit zusätzlichen Selektions-, Such- und Filtering-Werkzeugen. So sollen bspw. folgende Fragen beantwortet werden können:

- Wie ändert sich der durch Blogrolls konstruierbare Graph von einem Tag zum anderen?
- Inwieweit decken sich Blogroll-Graph und Actual-Linking-Graph?
- Welche Themen sind global gesehen bzw. in definierten Sub-Clustern aktuell populär?

Allerdings sind auch visuell völlig andersartige Applikationen auf Basis der MemeMapper-Infrastruktur denkbar. Die durch die implementierten Analysetools ermittelten Metriken würden bspw. auch die Entwicklung spezialisierter Services wie etwa auf spezifische Themengebiete fokussierte Aggregatoren im Stile von Techmeme erlauben.

Ausblick

Die erste praktische Anwendung, die auf der oben skizzierten Meme-Mapper-Infrastruktur aufbaut, ist ein Tracking-Tool zur US-Präsidentenwahl 2008. Das Werkzeug richtet sich an Blogger, Journalisten und die interessierte Öffentlichkeit. Die politische Blogosphäre der Vereinigten Staaten (ca. 2000 Blogs) wird inhaltlich analysiert und verschiedenen Netzwerkanalysen unterzogen, die es dem Nutzer erleichtern soll, jene Postings zu finden, die für ein bestimmtes Wahlkampfthema oder für eine bestimmte Person besonders relevant sind. Darüberhinaus werden Verlinkeungsstrukturen zwischen den Weblogs und häufig wiederkehrende Diffusionsmuster dargestellt.

Die so gewonnenen Erfahrungen wollen wir für weitere themenorientierte Newsservices, aber auch für den allgemeinen MemeMapper-Service nutzen.

Zusammenfassung

Den ständig wachsenden Informationsmengen ist nur noch durch Arbeitsteilung beizukommen. Medienformate wie Weblogs und Services wie del.icio.us fungieren dabei als verteilte, soziale Informationsfilter, die das altbekannte Konzept der Mundpropaganda auf das Internet übertragen und damit von zeitlichen und räumlichen Einschränkungen weitgehend befreien. Editoriale Entscheidungen und Qualitätssicherung – bislang die Domäne von Chefredaktionen – werden zunehmend einem Netzwerk von Akteuren übergeben, in dem sich kollektive Validierungs- und Annotierungsprozesse etablieren. Visuell orientierte Tools können helfen, Informationsflüsse in solch komplexen Umgebungen nachvollziehbarer und verständlicher zu machen. Die zentrale Herausforderung wird darin bestehen, diese potentiell mächtigen Werkzeuge so zu gestalten, dass sie sich in den Arbeits- und Lebensalltag von Bloggern und andern Netzwerkakteuren möglichst natürlich integrieren.

Literatur

1. Janet Abrams und Peter Hall. *Else/Where: Mapping*. University of Minnesota Press, 2006.
2. Eytan Adar, Li Zhang, Lada A. Adamic und Rajan M. Lukose: *Implicit Structure and the Dynamics of Blogspace*. Online verfügbar unter <http://www.hpl.hp.com/research/idl/papers/blogs/index.html>, zuletzt geprüft am 10.05.2007.
3. Albert-László Barabási. *Linked: How everything is connected to everything else and what it means for business, science, and everyday life*. New York: Plume Books, 2003.
4. Sergey Brin und Lawrence Page. *The Anatomy of a Large-Scale Hypertextual Web Search Engine*. In: *Computer Networks and ISDN Systems*, Jg. 30, H. 1–7, S. 107–117. Online verfügbar unter doi:10.1016/S0169-7552(98)00110-X.
5. Richard Dawkins. *The Selfish Gene: 30th Anniversary Edition*. Oxford University Press, 2006.
6. Brad Fitzpatrick und David Recordon. *Thoughts on the Social Graph*. Online verfügbar unter <http://bradfitz.com/social-graph-problem/>, zuletzt aktualisiert am 17.08.2007, zuletzt geprüft am 30.10.2007.
7. Linton Freeman. *Visualizing Social Networks*. In: *Journal of Social Structure*, Jg. 2000, H. Volume 1. Online verfügbar unter <http://www.cmu.edu/joss/content/articles/volume1/Freeman.html>, zuletzt geprüft am 31.05.2007.
8. Evgeniy Gabrilovich und Shaul Markovitch. *Computing Semantic Relatedness using Wikipedia-based Explicit Semantic Analysis*. In: *Proceedings of The Twentieth International Joint Conference for Artificial Intelligence*, S. 1606–1611. AAAI Press, 2007.

9. Daniel Gruhl, R. Guha, David Liben-Nowell und Andrew Tomkins. Information Diffusion Through Blogspace. In: Proceedings of the 13th international conference on World Wide Web. New York: ACM, 2004.
10. Stefan Hachul und Michael Jünger. Large-Graph Layout with the Fast Multipole Multilevel Method. Online verfügbar unter <http://www.zaik.uni-koeln.de/~paper/preprints.html?show=zaik2006-509>, zuletzt geprüft am 09.01.2008.
11. Jeffrey Heer und Danah Boyd. Vizster: Visualizing Online Social Networks. In: INFOVIS '05: Proceedings of the 2005 IEEE Symposium on Information Visualization. IEEE Computer Society, 2005.
12. Dorothea Jansen. Einführung in die Netzwerkanalyse: Grundlagen, Methoden, Forschungsbeispiele. 3., überarb. Aufl. Wiesbaden: VS Verl. für Sozialwiss.
13. Michael Jünger und Petra Mutzel (Hg.). Graph Drawing Software. Springer, 2003.
14. Lothar Krempel. Visualisierung komplexer Strukturen: Grundlagen der Darstellung mehrdimensionaler Netzwerke. Frankfurt am Main: Campus-Verlag.
15. Manuel Lima. blogviz: Mapping the dynamics of Information Diffusion in Blogspace. Master Thesis, Parsons School of Design, 2005.
16. Aaron Lynch. Thought Contagion. New York, NY: Basic Books, 1996.
17. Aaron Lynch. Units, Events and Dynamics in Memetic Evolution. Journal of Memetics – Evolutionary Models of Information Transmission, 2. 1998. Online verfügbar unter http://jom-emit.cfpm.org/1998/vol2/lynch_a.htm, zuletzt geprüft am 09.01.2008.
18. Mark Newman, Albert-László Barabási und Duncan Watts. The Structure and Dynamics of Networks. Princeton, NJ: Princeton University Press, 2006.
19. Andreas Noack. An energy model for visual graph clustering. In: Proc. GD 2003, S. 425–436. Springer-Verlag, 2004.
20. Wouter de Nooy, Andrej Mrvar und Vladimir Batagelj. Exploratory Social Network Analysis with Pajek. Cambridge: Cambridge University Press, 2006.
21. David Recordon. We Are Opening the Social Graph. Online verfügbar unter http://www.sixapart.com/about/news/2007/09/were_opening_th.html, zuletzt geprüft am 30.10.2007.
22. John Scott, Social Network Analysis: A Handbook, London: Sage, 2006.
23. Gernot Tscherteu. The Blogosphere Map 2. Visualising Microcontent Dissemination – Inspired by Maria Montessori. In: Theo Hug, Martin Lindner und Peter A. Bruck (Hg.). Microlearning: Emerging Concepts, Practices and Technologies, S. 109–121. Innsbruck: Innsbruck University Press, 2006.
24. Gernot Tscherteu und Christian Langreiter. The BlogosphereMap. In: Thomas N. Burg (Hg.): BlogTalks, S. 174–190. Wien: Cultural Research – Zentrum für Wissenschaftl. Forschung u. Dienstleistung, 2003.
25. Stanley Wasserman und Katherine Faust. Social Network Analysis: Methods and Applications. Cambridge: Cambridge University Press, 1999.
26. Dominic Widdows. Geometry and Meaning. Center for the Study of Language and Information/SRI, 2004.
27. Heinz Wittenbrink. Newsfeeds mit RSS und Atom – Nachrichtenaustausch mit Really Simple Syndication und Atom. Galileo, 2005.

17. Semantic Desktop

Leo Sauermann, Malte Kiesel, Kinga Schumacher und Ansgar Bernardi

Knowledge Management Department, German Research Center for Artificial
Intelligence DFKI GmbH, Kaiserslautern, Germany
{vorname.nachname}@dfki.de

Zusammenfassung: In diesem Beitrag wird gezeigt, wie der Arbeitsplatz der Zukunft aussehen könnte und wo das Semantic Web neue Möglichkeiten eröffnet. Dazu werden Ansätze aus dem Bereich Semantic Web, Knowledge Representation, Desktop-Anwendungen und Visualisierung vorgestellt, die es uns ermöglichen, die bestehenden Daten eines Benutzers neu zu interpretieren und zu verwenden. Dabei bringt die Kombination von Semantic Web und Desktop Computern besondere Vorteile – ein Paradigma, das unter dem Titel *Semantic Desktop* bekannt ist. Die beschriebenen Möglichkeiten der Applikationsintegration sind aber nicht auf den Desktop beschränkt, sondern können genauso in Web-Anwendungen Verwendung finden.

Einleitung

Paul arbeitet gerade an einem neuen anspruchsvollen Projekt: seine Organisation will eine neue Filiale in Rom, Italien, eröffnen. Er kann aus seiner langen Erfahrung mit ähnlichen Projekten in der Türkei und Griechenland schöpfen, und das Produkt seiner Firma hat auch noch einen attraktiven Markt. In seinem Terminkalender verwaltet er die nötigen Termine. Seine E-Mails mit den lokalen Partnern hat er alle aufbewahrt und organisiert, die organisationsinterne Datenbank enthält viel Information, und Tim, sein Assistent, hilft ihm bei der Planung. Auch sein Partner Peter, mit dem er schon ähnliche Projekte durchgeführt hat, ist von der Idee begeistert, und sie tauschen sich regelmäßig über den Projektfortschritt aus. Nur ein Problem beschäftigt Paul: Er verwendet viele verschiedene Systeme, um die Informationen aufzuzeichnen, und er kann nur schwer aus dem einen System in das andere Verweise erstellen. Auch ist es schwierig, Peter eine Übersicht des Projektes zu geben, denn sie sind beide Sturköpfe und bestehen auf jeweils unterschiedlichen Ablage- und Kategorie-Systemen. Doch

außer, dass der Termin sich immer wieder verzögert, deutet alles auf ein interessantes Projekt hin.

So werden seit etwa 2000 Jahren Projekte durchgeführt: Der erwähnte Paul könnte früher als Paulus bekannt gewesen sein – auch seine Kollegen Timotheus und Petrus sind Teil der Weltgeschichte. Ihre Filiale besteht heute noch und ist unter dem Namen Petersdom bekannt. Die organisationsinterne Korrespondenz, die Briefe des Paulus und Petrus, ist uns aber erhalten geblieben.

Was hat sich heutzutage gegenüber damals verändert? Heute ist die Kommunikation sicherlich schneller und das Diktieren der Briefe einfacher. Aber das Problem, eine gute Übersicht zu vermitteln, Information strukturiert aufzuzeichnen und weiterzugeben, bleibt bestehen. Wir geben einen Text ein, schicken ihn per E-Mail weiter, wo dieser wiederum als Text gelesen wird. Hilfen, wie z. B. Suchwerkzeuge, gab es damals wie heute – damals in Form handgestellter Indizes, heute als (Desktop-) Suchmaschinen. Komfort und Geschwindigkeit haben sich erhöht, konzeptionell hat sich jedoch nicht viel verändert.

In diesem Kapitel wird gezeigt, wie der Arbeitsplatz der Zukunft aussehen könnte und wo das Semantic Web neue Möglichkeiten eröffnet. Wir werden Paul Mittel in die Hand geben, die er an seinem Arbeitsplatz benötigt, um den Überblick über seine Dokumente zu behalten, um sich aber auch mit anderen besser zu koordinieren. Das Social Semantic Web wird real, wenn es bei alltäglichen Aufgaben Verwendung findet. Dann profitieren die Benutzer sofort von den Annotationen, die sie erstellen.

Was wir aktuell von der Entwicklung des *Web 2.0* lernen, wollen wir auch am Desktop sehen. Wir wollen die Möglichkeiten von bequemer Volltextsuche (Google), Klassifizierung (Tagging) und gemeinsamen Ontologien wie Wikipedia am Desktop nicht missen. Das Web ist Teil unseres Denkens und wird Teil des Arbeitsplatzes, die Dokumente, die wir am Arbeitsplatz erstellen, werden ein Teil des Webs.

Die Idee des Semantic Desktop

Wie dargestellt steht Paul vor dem Problem, dass jede Applikation seines Arbeitsplatzes eine eigene Art zur Verwaltung der Dokumente mitbringt. Bookmarks im Webbrowser, Ordnerstrukturen im Dateisystem, weitere Ordnerstrukturen für die E-Mails: Jedes Programm am Desktop benutzt ein getrenntes Ordnungssystem zur Verwaltung von Dokumenten, genauso wie jede Web- oder Intranet-Anwendung. Querverweise, etwa vom Projekt „Filiale in Rom“ zu den Mitarbeitern und Terminen, sind nur eingeschränkt möglich. Momentan wird es dem Benutzer zugemutet, hier applikationsübergreifend ein konsequentes Schema durchzuhalten und die

Übersicht zu bewahren. Das Betriebssystem ignoriert die Tatsache, dass ein Benutzer vor dem Bildschirm sitzt, dessen Gedankenwelt aus Projekten, Orten, Zeit, Mitarbeitern und deren Zusammenhang besteht, und zwar immer dieselben Gedanken, unabhängig der Anwendung.

Ein weiteres Problem ist die Weitergabe von Information. Selbst wenn der Benutzer ein Ordnungssystem für sich erstellt, werden die Metadaten nicht weitergegeben, wenn ein Dokument per E-Mail versendet wird oder ins Web hochgeladen wird.

Hier setzt der Semantic Desktop an: das Semantic Web und das Resource Description Framework (RDF) ermöglichen es, die Ressourcen am Desktop unabhängig von der Anwendung in einem einheitlichen Ordnungssystem zu verwalten. Mittels Ontologien werden Ressourcen mit sinnvollen Metadaten annotiert, und die komplexen Zusammenhänge zwischen Personen, Projekten und Orten als Netz dargestellt.

Ontologien, ein heißes Thema für Softwareanbieter im Bereich Wissensmanagement, haben Einzug in tägliche Arbeitsabläufe gefunden [10, 8]. Tools wie *USU Knowledge Miner* [27] ermöglichen es, bei der Suche Information im Kontext zu sehen; *OntoOffice* [17] bindet Ontologien direkt in den täglichen Arbeitsablauf mit ein. Eine mühsam erstellte Ontologie ist völlig nutzlos, wenn Sie nicht direkt in die tägliche Arbeit integriert ist. Wenn der Nutzer die Ontologie zur Suche verwendet, seine Dokumente darin einordnet und sie bei Bedarf erweitern und verändern kann, dann sind wir dem Social Semantic Web einen Schritt näher gekommen.

Heute sind bereits viele vom Benutzer angelegte Daten in strukturierter Form verfügbar:

- Hierarchien in Bookmarks, Mail-Ordern und Dateiverzeichnissen
- Annotierte Ressourcen in Web-Anwendungen wie Flickr und del.icio.us, oder in Intranetanwendungen

Des Weiteren gibt es Ontologien für größere Benutzergruppen:

- Top Level Ontologien wie SUMO, Cyc oder WordNet, die allgemeine Aussagen über die Welt ermöglichen
- Domänen-Ontologien für Medizin, Biotechnologie, etc.
- Firmen-Ontologien definiert in Organigrammen, Taxonomien von Web-Strukturen oder ERP Systemen

Was hier noch fehlt, ist der Benutzer, der eine subjektive Sicht auf die Welt hat:

- Persönliche Ontologien – jeder Mensch hat eine individuelle Sicht auf die Welt
- Die Verknüpfung von Domänen-Ontologien mit persönlichen Ontologien

Der Semantic Desktop versucht einige dieser Ebenen zu vereinen.

Definition Semantic Desktop

Unter dem Begriff *Semantic Desktop* verstehen wir einen konsequenten Einsatz von Semantic Web-Technologien auf Desktop-Computern. Die semantischen Funktionen sollen als integraler Bestandteil des (Betriebs-) Systems gelten. Die verschiedenen Anwendungen können dann auf diesen Technologien aufbauen und verwenden somit semantische Dienste, tragen aber auch dazu bei, das System mit Daten zu füllen und Vernetzungen zu erkennen. Semantische Technologie soll nicht mehr ein „Add-On“ sein, das nachinstalliert werden muss, sondern die Basis, auf der alle Anwendungen aufbauen. Wir definieren den Semantic Desktop vorerst wie folgt [22]:

A *Semantic Desktop* is a device in which an individual stores all her digital information like documents, multimedia, and messages. These are interpreted as Semantic Web resources – each is identified by a Uniform Resource Identifier (URI). All data is accessible and queryable as RDF graph. Resources from the web can be stored; authored content can be shared with others. Ontologies allow the user to express personal mental models and form the *semantic glue*, interconnecting information and systems. Applications respect this and store, read, and communicate via ontologies and Semantic Web protocols. The Semantic Desktop is an enlarged supplement to the user's memory.

Zentrales Element dieser Begriffsbestimmung ist – neben der Fokussierung auf die technischen Grundlagen des Semantic Web – die explizite Modellierung der Sichtweisen der Benutzer. Begriffe, Zusammenhänge und individuelle Interpretationen werden auf der Basis von Ontologien dargestellt.

Im Folgenden stellen wir Projekte vor, die Ansätze des Semantic Desktop darstellen. Danach gehen wir auf die konkrete Modellierung des persönlichen Informationsmodells in einem dieser Projekte näher ein.

Ansätze zur Realisierung des Semantic Desktop

Eine Reihe von Forschungs- und Entwicklungsprojekten hat sich bis zur Stunde mit der Realisierung des Semantic Desktop befasst. Zur Charakterisierung der in den verschiedenen Projekten implementierten Systeme unterscheiden wir seit der ersten Arbeit über den Semantic Desktop [23] zwischen dem *monolithischen* Ansatz und dem *integrativen* Ansatz. Der *monolithische* Ansatz versucht, möglichst viel Funktionalität in einer integrierten Anwendung anzubieten. Ein klassisches Beispiel hierfür ist

Microsoft Outlook: Wenn Sie Outlook starten, erscheint eine Oberfläche, die Ihnen sagen will: Alles was heute zu tun ist, finden Sie hier. Externe Software-Anbieter müssen nun ihre Anwendungen und Erweiterungen dieser monolithischen Applikation anpassen – als Plugin etwa, das dem Look-and-Feel der Originalanwendung folgt, aber auch an die interne und proprietäre Datenstruktur und Architektur gebunden ist. Der *integrative* Ansatz versucht hingegen, bestehende Desktop Applikationen einzubinden und so deren Funktionalität zu integrieren. Änderungen an bestehenden Applikationen sind – wenn überhaupt – auf deren Anbindung an Standardschnittstellen beschränkt. *Google Desktop* ist ein typischer Vertreter dieser Richtung: Die Datenbestände zahlreicher Desktop-Applikationen werden ohne weitere Änderungen zugänglich gemacht; umgekehrt wird die Suchfunktionalität durch Einbettung minimaler Plugins in vielen Anwendungen bereitgestellt.

Das Open-Source Forschungsprojekt „Haystack“ [18] ist ein Beispiel für den monolithischen Ansatz zur Realisierung eines Semantic Desktop. In diesem Projekt des MIT Computer Science and Artificial Intelligence Laboratory wurde ein Prototyp geschaffen, der alle wichtigen Funktionen eines Semantic Desktop integriert. Das System besteht aus einer RDF Datenbank, einem generischen User-Interface und konkreten Anwendungen, die in diesem User-Interface realisiert wurden, etwa einem E-Mail Programm. Alle Aufgaben des Wissensarbeiters sind in einer einheitlichen Oberfläche integriert. Die Datenstruktur dahinter ist mittels Ontologien modelliert. Der Vorteil dieses Ansatzes liegt in der Integration der Funktionalität: Wenn der Benutzer etwa ein Bild betrachtet, sind alle Methoden, die auf das Bild angewendet werden können, per Rechtsklick verfügbar. Alle Programme bauen auf die gleiche, integrierte Ontologie auf. Genau hier tritt aber auch der Nachteil dieses Systems zu Tage: Programmierer müssen neue Funktionalität mit der Programmierumgebung von Haystack realisieren.

Den integrativen Ansatz verfolgt die Open Source-Plattform „Gnowsis“. Das Gnowsis Projekt hat seine Wurzeln in einer Diplomarbeit [23] und wird mittlerweile am Deutschen Forschungsinstitut für Künstliche Intelligenz (DFKI) weiterentwickelt. Eine Beschreibung ist in [20] zu finden. Kern dieses Projektes ist der Gedanke, dass die Ideen eines Benutzers über alle Applikationen verteilt sind. Diese verteilten Informationsquellen werden in RDF umgewandelt in einem persönlichen Informationsmodell integriert. Der Benutzer soll bestehende Applikationen weiter verwenden, wobei diese durch Adaptoren integriert werden. In bestehende Benutzerschnittstellen werden nur minimale Änderungen eingebaut. Dabei beschränken wir uns auf die Kernfunktionalitäten „Link“ und „Browse“, das Vernetzen von verschiedenen Ressourcen und die Anzeige der verwandten Ressourcen. Eine integrierte Desktop-Suche rundet das System ab. Der

Vorteil besteht darin, dass die Benutzer weiterhin in den gewohnten Programmen arbeiten können und ihnen zusätzlich alle Informationen in der RDF-Repräsentation zur Verfügung stehen, was das System für Entwickler attraktiv macht. Der Nachteil ist der technische Aufwand und die geminderte Benutzerfreundlichkeit: nicht jede Applikation lässt sich integrieren. Selbst wenn sie integriert ist, stehen nicht unbedingt alle Funktionen zur Verfügung, die eigentlich möglich sind.

Während also der integrative Ansatz maximale Flexibilität und Erweiterbarkeit bei Einbußen an Bedienfreundlichkeit und Homogenität erlaubt, ermöglicht der monolithische Ansatz grundsätzlich eine einheitlichere Bedienbarkeit, allerdings auf Kosten einer geringeren Flexibilität und möglicherweise proprietär eingeschränkter Erweiterbarkeit.

Gelingt es, sich auf die Definition der für den Semantic Desktop fundamentalen Schnittstellen und Repräsentationen zu beschränken, und gleichzeitig vielfältige Anwendungsbeispiele und entsprechende Nutzergruppen für den Ansatz zu begeistern, so halten wir den integrativen Ansatz für den erfolversprechenderen der beiden.

Ein Beispiel für ein solches umfassendes Vorhaben ist das von der Europäischen Union geförderte Integrierte Projekt „*NEPOMUK*“, das unter Koordination durch das DFKI in den Jahren 2006 bis 2008 die Realisierung eines Semantic Desktop vorantreibt. Neben der Informationsintegration im persönlichen Arbeitsraum werden zusätzlich auch die sozialen Aspekte (Kommunikation, Austausch von Dateien und Metadaten) und die praktische Anwendung untersucht. Das Projekt soll auch eine globale Gemeinschaft von Entwicklern schaffen, weshalb die Kernelemente als Open-Source Projekt realisiert werden. Die so verfolgte Vision des *Networked Social Semantic Desktop* geht dabei maßgeblich auf Stefan Decker, Direktor des DERI Galway, zurück, der auch den Namen „Semantic Desktop“ geprägt hat.

Im Rahmen des NEPOMUK Projektes werden die grundlegenden Architekturentscheidungen als offene und standardisierbare Techniken und Formalismen repräsentiert. NRL (Nepomuk Representational Language) und PIMO (Personal Information Model) upper ontologies sind Beispiele; auch die Verwendung von Kommunikationsprotokollen wie SOAP gehören zu diesen Grundlagen.

Die Realisierung der so definierten Konzepte und die Entwicklung vielfältiger, domänenspezifischer Erweiterungen geschehen innerhalb von NEPOMUK durch verschiedene Nutzer- und Entwicklergruppen, die aus eigener Motivation zu den Open-Source-Entwicklungen beitragen. So werden die fundamentalen Techniken beispielsweise implementiert als Teil des *K-Desktop Environment (KDE)*, einer populären Benutzerschnittstelle für Linux (und andere Betriebssysteme). Die semantischen Funk-

tionen sind dann direkt als Erweiterung des Betriebssystems verfügbar. In einem Open-Source Betriebssystem ist dies entsprechend einfacher umzusetzen als in vergleichbaren geschlossenen Systemen. Wenn Sie also Interesse haben, eine Integration von semantischen Features im Datei-Explorer, Addressbuch, E-Mail Client und Browser zur Verfügung zu haben, verwenden Sie dieses Open-Source Projekt, oder unterstützen Sie es. Weitere Open-Source Entwicklungsaktivitäten betreffen die prototypische Implementierung in Java (als plattformübergreifende Referenz); die Integration in die ECLIPSE Entwicklungsplattform; die Verbindung mit dem Mozilla-Browser und damit verbundenen Entwicklungen. Insgesamt steht die Realisierung so auf einer weit breiteren Basis, als es mit einem rein monolithischen Closed-Source Ansatz denkbar wäre. Weitere Informationen zu den verschiedenen Entwicklergruppen finden Sie auf den Entwickler-Webseiten des NEPOMUK-Projekts¹, wo Sie auch zu den Entwicklungen beitragen können.

Schließlich erprobt NEPOMUK das Konzept eines Semantic Desktop in verschiedenen Anwendungsdomänen: Im BioScience-Bereich dient ein Semantic Desktop als intelligentes Laborbuch, in Beraterunternehmen hilft eine Implementierung bei der Erarbeitung kundenspezifischer Dokumente, in einer Software-Entwicklungsabteilung werden große Forschungsprojekte unterstützt, und ein Online Community Helpdesk zeigt die Vorteile in verteilten kommunikativen Szenarien.

Woraus besteht ein Semantic Desktop?

Der Semantic Desktop besteht aus einer Vielzahl an Komponenten. Die Modellierung des persönlichen Informationsmodells, das die Grundlage der anwendungsübergreifenden und kommunizierbaren Strukturierungen aller Informationselemente darstellt, ist dabei ein zentrales Element.

Das Persönliche Informationsmodell (PIMO)

Ein Persönliches Informationsmodell (PIMO) ist eine formale Repräsentation des mentalen Modells eines Benutzers. Ein Konzept aus dem mentalen Modell wird dabei als Instanz der Klasse Ding (*Thing*) repräsentiert, oder einer spezifischeren Sub-Klasse. Bestehende Ressourcen auf dem Arbeitsplatz (das schließt verwendete Informationen von Desktop, Intranet und Web ein) werden als Erscheinung (*occurrence*) der Dinge verstanden. Durch Relationen und Metadaten können Dinge klassifiziert und vernetzt werden.

¹ <http://dev.nepomuk.semanticdesktop.org/>

Bei der Erstellung des PIMO beschränkt man sich auf die Dinge und Ressourcen, die in der Aufmerksamkeit des Benutzers sind, also E-Mails, Termine, Orte, Personen, Projekte usw., nicht jedoch Ressourcen, die nie vom Benutzer erkannt werden (Konfigurationsdateien, Systemressourcen).

Ein Beispiel: Wenn Paul in seinem Dateisystem einen Ordner *Filiale in Rom* erstellt, um dort sein Wissen zu diesem Thema abzuspeichern, benötigt er den gleichen Ordner im E-Mail Programm, im Web-Browser, im Chat-Programm, in der Buchhaltung usw.. Das gedankliche Konzept „Ich eröffne eine Filiale in Rom“ ist ein Teil von Pauls mentalem Modell. In seinem PIMO wird dies als Instanz der Klasse *Projekt* mit dem Titel *Filiale in Rom* angelegt. Die Instanz wird mit einem neuen URI identifiziert. *Rom* kann nun als Instanz der Klasse *Stadt* angelegt werden, *Tim* und *Peter* als Personen. Die Relation *arbeitet an* verbindet die Personen mit dem Projekt.

Die Programme verstehen nun die Gedankenwelt von Paul, weil sie auf seine Ontologie zurückgreifen. Wenn Paul nun Software verwendet um Information einzugeben, wird diese Software versuchen, die neue Information mit den bestehenden Ressourcen aus seiner Ontologie zu verknüpfen. Die neue Kategorie wird mit dem Ort *Rom* und verwandten Projekten verbunden, etwa mit *Filiale in Jerusalem* und *Filiale in Ephesus*. Die Erfahrungen von früheren Projekten in anderen Städten und das Wissen über *Rom* sind nun explizit als semantische Links verfügbar. E-Mails, Termine und Dokumente, die sich mit dem Projekt beschäftigen, können mit dem Projekt „getaggt“ werden, anstatt von Schlagworten werden diese aber mit der URI des Projektes verbunden. Der Ansatz verbindet also formale Ontologien mit Ansätzen, die leichtgewichtiger Strukturen bieten, etwa Tags oder der W3C Standard „Simple Knowledge Organisation Systems“ (SKOS).

Ein PIMO in RDF repräsentieren

Zur Repräsentation eines PIMO in RDF gibt es ein standardisiertes Vokabular, das im Projekt EPOS erarbeitet und in NEPOMUK weitgehend überarbeitet und standardisiert wurde. Dabei wurde als repräsentative Sprache die NEPOMUK Representational Language (NRL) verwendet, eine Erweiterung von RDFS. Einfache Annotationen (= Tags) werden mit einer einfachen Annotationsontologie (NAO) ermöglicht. Eine detailliertere Einführung zu PIMO mit exakten Beispielen und weiterführenden Links finden Sie im Web auf den Seiten der standardisierten Semantic Desktop Ontologien².

² <http://www.semanticdesktop.org/ontologies/>

Der PIMO Standard ist dort ab Dezember 2007 verfügbar, ältere Versionen finden sich im Netz: <http://ontologies.opendfki.de/repos/ontologies/pim/report/pimOntologyLanguageReport.html>

Folgend beschreiben wir kurz die wichtigsten Elemente des PIMO-Vokabulars. Es besteht aus den grundlegenden Klassen *Thing*, *Personal Information Model* und der Relation, dass ein Mensch ein solches hat. Dies ist die sogenannte PIMO-Basic Ebene. Die weiteren Ebenen sind dann PIMO-Upper mit einer handvoll wichtigen Klassen, Domänen-Ontologien, die in einer Gruppe oder Domäne verwendet werden, und die eigentlichen persönlichen Erweiterungen des Benutzers.

PIMO-Upper: Allgemeine Klassen

Dieser Teil des Vokabulars definiert Klassen, die generell für persönliches Informationsmanagement interessant sind, weil sie jeden Menschen betreffen: Personen, Orte, Ereignisse, Organisationen, Themen, Dokumente, Rollen und Zeit. Damit können die zentralen Fragen Wer? Wo? Wann? Was? modelliert werden. Zwischen diesen Dingen sind generelle Relationen möglich:

- *related*: ein Ding ist mit einem anderen verbunden
- *hasPart, is Part Of*: ein Ding ist Teil eines anderen
- *hasTopic, is Topic Of*: ein Ding beschreibt oder referenziert ein anderes

Eine genaue Auflistung finden Sie auf der oben genannten Webseite und in der formalen RDFS+NRL Ontologie.

PIMO-Mid: Ontologien, die in einer Domäne oder Gruppe geteilt werden

Die Stärke des Social Semantic Web besteht darin, dass Menschen Ontologien gemeinsam verwenden können. Die Strukturen innerhalb einer Organisation und die Projekte und Themen dieser sind wichtig für Menschen, die innerhalb der Organisation tätig sind. Formale Modelle von Domänen (etwa die Domäne der Humanmedizin oder die Domäne elektronischer Musikrichtungen) sind relevant für Menschen, die in dem jeweiligen Bereich arbeiten.

Diese Ontologien werden, wie im Semantic Web üblich, repräsentiert und verwaltet. Um sie am Semantic Desktop und mit einem PIMO zu verbinden, ist es notwendig, die verwendeten Klassen und Relationen mit der PIMO-Upper Ontologie zu verknüpfen. Dies geschieht entweder per Hand oder automatisch, anhand Sub-Klasse und Sub-Property Relationen. Um Instanzen zu verbinden, bietet PIMO die *has Other Representation*-Relation. Damit wird dann die persönliche Repräsentation eines Dings mit der Repräsentation desselben Dings in einer geteilten Ontologie verbunden. Im Beispiel von Paul kann ihr Unternehmen eine Unternehmensontologie zur Verfügung stellen, Paul, Tim und Peter verbinden dann ihre

persönliche Sicht auf das *Projekt Rom* mit der Firmenrepräsentation des Projekts *Filiale in Rom*.

Persönliche Klassen, Relationen und Erweiterungen

Der Endbenutzer bekommt am Semantic Desktop die grundlegenden Klassen der PIMO-Upper und die geteilten Ontologien der PIMO-Mid bereits vorinstalliert. Bei Bedarf kann der Benutzer jederzeit neue Klassen und Relationen einführen. Etwa „Digitalkamera“ und „Canon Digital Rebel XT“, wenn Tim Informationen über die Kamera festhalten will, mit der er die Bilder in Rom geschossen hat, und das Attribut *hat Preis*, um sich diesen zu merken.

Wichtig ist nun, dass das System automatisch jede Ressource am Arbeitsplatz (jede Datei, E-Mail, Webseite, jedes Produkt, Projekt etc.) als Teil der PIMO repräsentiert. Um eine Datei aus dem Dateisystem mit dem Tag *Tim* zu markieren, wird zuerst die Datei als Ding repräsentiert und dann mit der Person *Tim* mittels eines RDF-Tripels verbunden. Somit ist dann auch implizit Tim mit der Datei verknüpft, was Paul auch die Frage beantwortet: „Woran muss ich denken, wenn ich mit Tim rede?“

Im Forschungsprojekt EPOS (Evolving Personal to Organizational Knowledge Spaces) haben wir uns mit der Frage beschäftigt, wie aus den persönlichen Ontologien nun organisationale Ontologien entstehen können. Der Ontologie-Entwurf findet also sowohl Top-Down statt, indem Experten und Führungskräfte versuchen zu modellieren, was bereits besteht oder wie in Zukunft die Firma zu sein hat. Zusätzlich entstehen persönliche Ontologien Bottom-Up, in der täglichen Arbeit der Mitarbeiter. In dem Moment, in dem ein neues Konzept als Gedanke entstanden ist, soll es bereits Teil der persönlichen Ontologie werden. Mittels Ontology-Matching Algorithmen kann man nun die persönlichen Ontologien mit der Unternehmensontologie oder miteinander vergleichen, und Vorschläge machen, die geteilten Ontologien zu erweitern.

Entscheidend ist nun das Persönliche Informationsmodell ausnahmslos in alle Anwendungen zu integrieren, mit der ein Individuum zu tun hat. Eine Software-Anwendung ist für den Benutzer wie ein Fenster, durch das der Blick auf die Welt gegeben wird. Jedes dieser Fenster zeigt einen bestimmten Ausschnitt, doch sind die betrachteten Informationen verknüpft durch das Persönliche Informationsmodell.

Technische Komponenten des Semantic Desktop

Betrachten wir nun den technischen Kern des Semantic Desktop. Ob der Ansatz integrativ oder monolithisch ist, ist dabei unwichtig, die Kernele-

mente bleiben dieselben. Ich vergleiche den Semantic Desktop gerne mit einem Baum, dessen Wurzeln die Daten und Ontologien des Benutzers sind. Darauf wächst ein Stamm, der diese Daten integriert. Schließlich bilden Benutzerschnittstellen und Anwendungen die für den Benutzer sichtbaren Früchte dieses Baumes (siehe Abb. 1 unten). Die bestehenden Datenquellen bilden die Basis, auf die der Semantic Desktop aufbaut. Wobei man üblicherweise Adaptoren verwendet um bestehende Systeme einzubinden: Datenbanken, Adressbücher, Dateien des Benutzers werden durch diese in das Datenformat RDF umgewandelt. Falls es aus Performanz-Gründen nötig sein sollte, kann man diese Datenquellen mittels eines Desktop-Crawlers durchsuchen (mehr dazu weiter unten) und in eine zentrale RDF-Datenbank speichern. Derartige Datenbanken gibt es viele, wobei hierzu eine Studie von Simile einen guten Überblick gibt [16].

Ein wichtiges Problem ist nun die semantische Integration der heterogenen Datenquellen in das Persönliche Informationsmodell. An dieser Stelle sei nur gesagt: Die automatische Integration ist nicht trivial und wird noch erforscht. Ziel der Datenintegration ist es, das PIMO automatisch mit Klassen und Instanzen zu füllen, und die erstellten Dinge miteinander zu vernetzen. Mittels einer Natursprach-Analyse Komponente werden die Briefe von Peter und Paul analysiert, die Person Tim und der Ort Rom automatisch extrahiert und in die Ontologie übernommen.




Abb. 1. Architektur des Gnowsis Semantic Desktop

Der nächste technische Schritt ist nun ein *Personal Semantic Web Server*, also das, was unter dem Schlagwort „*Semantic Web Services*“ geführt wird, bloß für einen einzelnen Computer. Wir schlagen vor, die Technologien, die für das globale Semantic Web entwickelt wurden, zur Interprozesskommunikation zu verwenden. Wenn Pauls E-Mail Programm wissen will, an welche Römer der „Brief an die Römer“ eigentlich adressiert ist, befragt es den Semantic Desktop Server nach „Personen, die mit dem Projekt *Filiale in Rom* verbunden sind“. Dabei hat sich die Abfragesprache SPARQL [24] als nützlicher Standard herauskristallisiert, der mittlerweile von vielen RDF Datenbanken implementiert wird.

Damit kommen wir auch schon zu den Anwendungen. Ob semantische Anwendungen nun als integrierte Oberfläche (wie etwa Protégé³ oder Haystack⁴) oder als Sidebar (wie Piggybank⁵) erscheinen, sie sollten immer mit der persönlichen Ontologie und den Datenquellen des Benutzers interagieren. Die Anwendungen müssen nicht mehr Adaptoren, Datenbank und Ontologien vereinen, sondern können mit anderen Anwendungen über die gemeinsame Datenbasis integriert werden.

Eine genauere Beschreibung der Architektur finden Sie in [11].

Personalisierte Semi-Automatische Klassifikation

Bevor das Semantic Web seinen Hype hatte, gab es bereits in den 1980er Jahren ein anderes Phänomen, in das viel Geld und Hoffnung investiert wurde: die Künstliche Intelligenz. Ein Ergebnis dieser Investitionen sind *Natural Language Processing* (NLP) Systeme, also Systeme, die Texte analysieren und die enthaltenen Worte zumindest teilweise verstehen und klassifizieren können. Ein anderes Ergebnis sind lernende Algorithmen, die auf dem Prinzip von Beispielen funktionieren. Etwa bei der Spam-Klassifizierung werden E-Mails als Trainingsdaten in einen Algorithmus gespeist, der auf Bayes'schen Netzen aufbaut. Eine derartige Technologie kann auch zu anderen Klassifikationsaufgaben, wenn die Frage über „Spam oder nicht Spam“ hinausgeht, verwendet werden.

Klassifikation lässt sich auch für das persönliche Informationsmodell des Benutzers verwenden. Paul hat das Projekt „Neue Filiale in Rom“ – sein persönlicher Klassifikator muss nun lernen, wann eine eingehende E-Mail zu diesem Projekt gehört. Dazu muss Paul den Klassifikator zuerst trainieren, in dem er bestehende Dokumente zu dem Projekt hinzufügt.

³ <http://protege.stanford.edu/>

⁴ <http://groups.csail.mit.edu/haystack/home.html>

⁵ http://simile.mit.edu/wiki/Piggy_Bank

Genauso, wie wir Spamfilter trainieren, können wir auch Konzepte unserer persönlichen Ontologie trainieren. Dabei werden nicht nur der Text, sondern auch die Metadaten einer Nachricht genutzt (Betreff, E-Mail Server, Absender), werden als Trainingsdaten für Klassifikatoren verwendet. Wenn nun statt einem E-Mail ein Termin klassifiziert werden soll, kann die ganze bekannte Information aus dem Semantic Desktop herangezogen werden. Bei dem Termin „Eröffnung der Filiale, Rom“ etwa ist nicht nur Zeit und Ort annotiert, der Semantic Desktop kann auch den Kontext analysieren, in dem der Termin erstellt wurde. Hat der Benutzer eine Website über Rom betrachtet, bevor er den Termin angelegt hat, oder hat Paul Peter mittels seines ISDN Telefons angerufen?

Der ganze *Arbeitskontext*, in dem die Informationsressource steht, kann zur Klassifikation verwendet werden. Mehr zum Thema Kontext finden Sie im nächsten Abschnitt. Ist der Klassifikator einmal trainiert, können neue Informationen automatisch zu Konzepten in der persönlichen Ontologie zugeordnet werden. Die eingehenden E-Mails werden automatisch Projekten, Personen und Themen zugeordnet, aber nicht nur E-Mails sondern Termine, Dokumente und Webseiten ebenso. So wird im DFKI-Projekt „Mymory“ die Integration von Kontextinformation in den persönlichen Desktop verfolgt. Kontext wird hier vom Benutzerverhalten abgeleitet: Aus den geöffneten Dokumenten und ihren semantischen Verknüpfungen wird auf den aktuellen Benutzerkontext geschlossen. So kann das System z. B. aus der Tatsache, dass Paul eine E-Mail eines Mitarbeiters der Filiale in Rom liest, schließen, dass Paul sich gerade mit eben dieser Filiale befasst und z. B. nachfolgend verfasste E-Mails sich vermutlich um das gleiche Thema drehen. Die so gewonnene Kontextinformation wird zu den betreffenden Ressourcen hinzugefügt und kann für nachfolgendes Browsing und Suche genutzt werden. Um die Genauigkeit des erfassten Kontextes zu erhöhen und weitere Informationen zu erhalten, wird dabei zusätzlich auf Informationen eines Desktop-Switchers und insbesondere auch eines Eyetrackers zurückgegriffen, mit dem eine feingranulare Aufmerksamkeitsbewertung gemacht und in Grenzen auch Rückschlüsse auf Relevanz einzelner Textteile getroffen werden können.

Am *Semantic Desktop* bestechen Klassifikationen durch einen zusätzlichen Reiz: Sie sind als Teil des Betriebssystems integriert und somit werden sie von allen Applikationen gemeinsam verwendet. Für einen Benutzer heißt das: Die persönliche Ontologie – einmal trainiert – wird in allen Anwendungen genutzt und Web-Dokumente im Browser, Termine, E-Mails, etc. werden automatisch klassifiziert, eingeordnet und mit bestehender Information verknüpft – ohne großen Aufwand für den Programmierer.

Adaption von Datenquellen – Aperture

Es gibt zwei Möglichkeiten Datenquellen ins Semantic Web zu integrieren:

- Als virtuelle RDF Graphen, mittels dynamischer Adapter, die eine RDF Anfrage zur Laufzeit auf der Datenquelle ausführen und die Antwort in RDF umwandeln.
- Indiziert, indem man alle Datenquellen vorab in RDF umwandelt und dann in einer RDF Datenbank hält.

Beide Ansätze haben ihre Vor- und Nachteile (Sauermann & Schwarz 2005). Der virtuelle Ansatz hat den Reiz, dass die Daten nicht redundant gehalten werden und nur „on demand“ in RDF umgewandelt werden. Der gravierende Nachteil ist, dass eine brauchbare Suche mit schnellen Antwortzeiten nicht implementierbar ist. Selbst mit sehr fortgeschrittenen Adaptern ist es nicht machbar, jede mögliche SPARQL Anfrage zu beantworten, wenn die unterliegende Datenquelle über keinen Index verfügt. Darum arbeiten in der Praxis Suchmaschinen (wie etwa Google Desktop oder Apples Spotlight) mit indizierten Daten, die in einer Datenbank gehalten werden. Diese Lösungen, die auf einem Index aufbauen, haben wiederum den Nachteil, dass die Daten redundant gehalten werden müssen, sowohl im ursprünglichen Format als auch im Index. Das verdoppelt den Speicherplatz und setzt eine regelmäßige Synchronisation voraus, was auch wieder eine Fehlerquelle sein kann.

Am Semantic Desktop kann man verschiedene Ansätze zur Integration verwenden. Das Projekt *Aperture*⁶ bietet eine allgemeine Implementierung in Java, die unter einer Open Source-Lizenz verfügbar ist.

Aperture wurde vom DFKI und Aduna-Software gemeinsam entwickelt, als einfaches, erweiterbares und anpassbares Framework zur Anbindung von Datenquellen. Es unterstützt gängige RDF APIs (etwa Jena und Sesame), dank der Nutzung des RDF2Go Abstraktionsframeworks. Es kann unabhängig verwendet werden, ist aber auch Bestandteil von kommerzieller Software, wie etwa dem OpenLinkSoftware Virtuoso Server oder dem Aduna Autofocus Server. Die realisierten Komponenten ermöglichen es allein oder in Kombination Daten aus verschiedensten Quellen zu lesen. *Crawler* verbinden sich mit einer Datenquelle und identifizieren alle Objekte mit einer URI. Es gibt verschiedene Crawler für IMAP E-Mail Server, das Dateisystem, MS-Outlook, Web-Crawler (die Links verfolgen), Adaptern für die Web-Apis von Flickr.com, del.icio.us, und weitere Systeme. *DataAccessor* verwenden diese URIs, um die Objekte zu holen und als *DataObject* zu repräsentieren. Dabei werden bereits grundsätzliche Metadaten erfasst, die die Datenquelle zur Verfügung stellt (Titel,

⁶ Aperture ist hier frei verfügbar: <http://aperture.sourceforge.net>

Änderungsdatum...). Weiters besteht die Möglichkeit, auf den binären Datenstream des Objektes zuzugreifen. Anhand des MIME-type kann nun ein *Extractor* ausgewählt werden, der diese Daten lesen und in RDF umwandeln kann. Dabei werden der Volltext und etwaige Metadaten, die im Dateiformat definiert sind, ausgelesen. Zusätzlich bietet Aperture einige angenehme und nützliche Werkzeuge, etwa einen Detektor, der den MIME-type heuristisch erkennen kann, Link-Extraktion für Webcrawler und die Verwaltung sicherer Verbindungen. Extraktoren gibt es für alle gängigen Office-Dokumente (MS-Word, MS-Powerpoint, MS-Excel, Open-Office, OpenDocument), gängige Multimedia-Dateien (EXIF) und Volltext-Exraktoren für zahlreiche weitere Formate.

Mittels derartiger Adapter-Software ist es dem Semantic Desktop möglich, verschiedene Datenquellen in die Desktop RDF Datenbank einzupflegen. Bei effizient durchsuchbaren Datenquellen, wie beispielsweise SQL Datenbanken, sollte man dynamische Verfahren anwenden, wie sie etwa durch D2RQ angeboten werden [3].

Suche auf dem Semantic Desktop

Nun könnte Paul durch eine Schlüsselwortsuche nach „Filiale in Rom“ auf seinem Semantic Desktop nicht nur die Dokumente finden, die im Dateisystem abgelegt sind und die Wörter „Filiale“ und/oder „Rom“ enthalten, sondern auch seine E-Mails, Chatprotokolle usw., also alle Informationen, die als „Filiale in Rom“ klassifiziert sind. Wie findet er aber die E-Mail-Adressen der Teilnehmer des nächsten Meetings, wenn er die Verschiebung des Termins mitteilen möchte? Und den kompletten Schriftverkehr der letzten vier Wochen mit Peter? Sie haben eine interessante Idee diskutiert, und es wäre schön, die Ergebnisse zusammenzufassen und Tim zu präsentieren. Die Antwort liegt in seinem persönlichen Informationsmodell, in den abstrakten Konzepten wie Personen, Projekten, Orten, in der Vernetzung der Konzepte, Dokumente und in den Dokumentinhalten.

Betrachtet man den Semantic Desktop aus der Sicht der Suche, so findet man eine Struktur aus drei Schichten vor [7, 6]. Die Term-Schicht enthält alle inhaltlich bedeutsamen Wörter, die sogenannten Indexterme, die in den Dokumenten und in den textuellen Inhalten (Labels) der Konzepte vorkommen. Die Dokument-Schicht beinhaltet die Dokumente, die Konzept-Schicht die Konzepte des persönlichen Informationsmodells. Diese Schichten sind miteinander verknüpft und untereinander vernetzt. Zudem handelt es sich bei den Verknüpfungen um semantische Relationen, wie z. B. eine Person ist *author of* ihrer Publikationen, *attendee* einer Besprechung und hat eine *phone number*.

Es gibt mehrere Möglichkeiten, auf diesem Modell zu suchen, wobei hier zwischen der Benutzerschnittstelle und dem Suchalgorithmus unter-

schieden werden muss. Nach der Benutzerschnittstelle gibt es laut Lei, Uhren und Motta (2006):

- Formularbasierte Suchmaschinen: erlauben dem Benutzer mit Hilfe von Ontologien, Klassen, Eigenschaften und deren Werten die Suchanfrage zu spezifizieren
- Suchmaschinen mit RDF-basierten Abfragesprachen: bieten die Spezifikation der Anfrage durch eine definierte Sprache (etwa SPARQL)
- Semantik-basierte Schlüsselwortsuchmaschinen: verbessern die Performance traditioneller Schlüsselwortsuche durch Verwenden verfügbarer Metadaten (verwenden oft eine Abfragesprache um genau zu spezifizieren, welche Bedeutung ein Term hat, z. B. *person:Paul*)
- Question Answering Tools: natürlichsprachliche Fragen werden aufgrund der semantischen Informationen beantwortet.

Je präziser die Anfrage formuliert ist (wie es z. B. bei den formularbasierten Suchmaschinen möglich ist), umso weniger tritt das Problem der lexikalischen und strukturellen⁷ Mehrdeutigkeit auf. Der Suchalgorithmus kann einfacher gestaltet werden, ohne Verlust an Qualität der Ergebnisse (Precision/Recall). Gleichzeitig ist die Konstruktion der Anfrage umso aufwändiger bzw. komplizierter für den Benutzer.

Der Suchraum auf dem Semantic Desktop ist, im Gegensatz zum Semantic Web, beschränkt und – durch das persönliche Informationsmodell – zu einem bestimmten Maß personalisiert. Für die Suche bieten somit semantikbasierte Schlüsselwortsuchmaschinen einen guten Kompromiss. Beispiele sind TAP [12] oder DBpedia⁸. Solche Suchmaschinen führen zuerst eine Schlüsselwortsuche durch, um in dem textuellen Inhalt der Konzepte und Dokumente die Treffer zu bestimmen (syntactic matching). Danach erfolgt eine Suche auf der Ebene der Ontologie (semantic matching), was die Struktur des RDF-Graphen und/oder die Semantiken darin betrachtet, um die Ergebnisse der syntaktischen Suche zu erweitern [13]. Dabei können drei miteinander kombinierbare Ebenen unterschieden werden [26]:

- Traversierung auf dem Graph betrachtet die Struktur des Graphen
- das explizite Verwenden von Thesauri zur Anfrageerweiterung mit verwandten Begriffen
- logisches Schließen auf Basis formaler Semantiken (in RDF, RDFS, OWL).

⁷ Lexikalische Mehrdeutigkeit bezeichnet die Mehrdeutigkeit der Wörter. Strukturelle Mehrdeutigkeit entsteht dadurch, dass komplexe Ausdrücke mehrere grundlegende Strukturen haben können. In solchen Fällen ist die Rolle der Wörter in dem Ausdruck nicht eindeutig (z. B. Er sah die Frau mit dem Fernglas). (Hildebrand et al. 2007)

⁸ <http://dbpedia.org/> (26.10.2007)




Abb. 2. Suche auf dem Semantic Desktop – ein vereinfachtes Beispiel

Mit Hilfe dieser Suchtechnologien kann nun Pauls Anfrage nach den E-Mail-Adressen aller Teilnehmer des geplanten Meetings beantwortet (s. Abb. 2) oder der Schriftverkehr der letzten 4 Wochen zwischen Paul und Peter aufgelistet werden.

Bei der Visualisierung und Nutzung der Suchergebnisse sind weitere Möglichkeiten vorhanden, um den Benutzer bei der Suche zu unterstützen. Barreau und Nardi erkannten 1995, dass meist zuerst mittels des (von Hand gepflegten) Ordnersystems gesucht und erst dann Volltextsuche verwendet wird. Nun kann man umgekehrt von einem Suchergebnis zu dessen Kategorien springen und weitere Treffer finden, oder die Relationen der Ergebnisse visualisieren. In Abb. 3 ist ein Beispiel dieser Visualisierung gezeigt [20].

Die Suche nach dem Schlüsselwort „EPOS“ lieferte sowohl ein Projekt dieses Namens zurück, als auch den Projektleiter. Zu der ausgewählten Person aus der Ergebnisliste werden rechts (mit hellem Hintergrund) vernetzte Elemente aus der PIMO angezeigt (andere Projekte, etc).

Stichwortbasierte Suche ist ein wesentlicher Baustein der Suche auf dem Semantic Desktop; bestimmte Anwendungsfälle lassen sich damit aber nur schwer abdecken. Sobald zum Beispiel in kontinuierlichen Daten gesucht werden muss (also Zeiträume oder auch statistisch erhobene Daten ins Spiel kommen) oder die relevanten Stichworte nicht im Voraus bekannt sind, trifft diese Form der Suche auf ihre Grenzen. Es bietet sich dann an, Suche und Browsing miteinander zu verknüpfen, also aus der relativ harten Suche (Suchbegriff eingeben, Ergebnisse ansehen) einen Prozess zu machen, in dem die Suche stückweise verfeinert wird. Diese Idee wird von verschiedenen Ansätzen verfolgt, z. B. beim sogenannten *Facetted Browsing*, bei dem

nwsis search

EPOS

☐ search peers
☐ search only peers

[help](#)

PERSONS	PROJECTS	CONCEPTS	EVENTS
Heiko Maus Heiko Maus	EPOS	myBookmarks/Projekte/EPOS My eMail/DFKI/EPOS Projects/EPOS Projects/EPOS/EPOS Evaluati Projects/EPOS/EPOS proposa Projects/EPOS/EPOS - projec Projects/EPOS/Case Study/E more ... (7)	EPOS

Person ↑

[Heiko Maus](#)

http://km.dfki.de/model/org#OrganisationalModel_00075
 manager of project

Project ↑

[EPOS](#)

http://dfki.rdf.util.rdf2java/default#id_20030314_170505

type
[org:User](#)
<http://km.dfki.de/model/org#Person>
<http://xmlns.com/foaf/0.1/Person>

belongsToUnit
[EPOS](#)
http://dfki.rdf.util.rdf2java/default#id_20030314_170505
[FRODO](#)
<http://km.dfki.de/model/org#Knowledge Management>

Abb. 3. Visualisierung einer semantik-basierten Schlüsselwortsuche

permanent eine Ergebnismenge sowie mögliche Einschränkungen darauf angezeigt werden, was die Grenze zwischen Suche und Browsing verwischt und auch explorative Suche ermöglicht (also z. B. eine Suche nach interessanten Zusammenhängen ohne absolut feststehendes Ziel). Facetted Browsing hat inzwischen in viele Anwendungen Einzug gehalten und erleichtert z. B. das Auffinden relevanter Artikel in Onlineshops. Auf dem Semantic Desktop lässt es sich grundsätzlich verhältnismäßig einfach implementieren, da sich die interne Darstellung der vorhandenen Daten in RDF gut auf einem facettenorientierten Benutzerinterface abbilden lässt (auf RDF-Ressourcen wird gesucht, die Werte der an den Ressourcen hängenden Prädikaten dienen als mögliche Einschränkungen) – so existieren einige generische facettenbasierte Browser für RDF-Daten.

Das persönliche Wiki

Bei wissensintensiven Tätigkeiten fallen häufig große Mengen an Informationen an, die zur Strukturierung des eigenen Arbeitsplatzes dienen und

Notizzettelcharakter haben. Viele Applikationen bieten für Informationen dieser Art Kommentarfelder. Diese sind jedoch meist strikt an eine bestimmte Ressource gebunden, sind also nicht unbedingt leicht wieder aufzufinden geschweige denn per Volltextsuche zu durchsuchen.

Im Zuge der zunehmenden Bekanntheit von Wikis ist die Idee aufgekommen, Wikis auch auf dem Desktop zu benutzen und dementsprechend eine verhältnismäßig komfortable Möglichkeit zur Verwaltung von Notizen zu erschließen, die Merkmale wie Volltextsuche, gute Strukturierbarkeit, gute Integration mit anderen Medien (durch Links) sowie einfache Benutzbarkeit vereint. Für den Semantic Desktop wiederum liegt es nahe, ein Wiki als eines der zentralen Werkzeuge zur Eingabe und Verknüpfung der Ressourcen auf dem Desktop zu benutzen. So erlaubt das in Gnowsis integrierte Wiki *Kaukolu*⁹ [15] dem Benutzer, Kommentare zu den in Gnowsis verwalteten Ressourcen zu schreiben sowie über eine besondere Wiki-Syntax Verbindungen zwischen den Ressourcen zu erstellen. Das „Semantic Desktop Wiki“ steht damit zwischen dem rigiden (aber exakten) Benutzer-Interface herkömmlicher Datenbank-ähnlicher Anwendungen und dem offenen (aber wenig formalisierten) Interface eines normalen Wikis. Es erlaubt dem Benutzer also, so viel Formalisierung bei der Eingabe der Informationen zu machen wie für sinnvoll erachtet wird.

Paul kann nun im Kommentarfeld seines Adressbuchs in das Feld zum Eintrag „Tim“ die Notiz schreiben:

„[Er] arbeitet an [Filiale in Rom]. Weiterhin kennt er [Peter]. Da fällt mir ein, auch [Peter] arbeitet an [Filiale in Rom].“

Diese kurze Notiz kann direkt übernommen werden – Tim und Peter werden dem Projekt zugeordnet und eine weitere Beziehung zwischen Tim und Peter hergestellt. Beachten Sie, dass es auch möglich ist, im Kommentarfeld von Tim Informationen über ganz andere Dinge auszusagen.

Im Projekt „NEPOMUK“ werden Wikis in etwa wie oben beschrieben eingesetzt; im Projekt „Mymory“ werden weitere Ideen verfolgt, so gibt es eine Integration eines Eyetrackers mit dem Wiki (d. h. mit hoher Aufmerksamkeit gelesene Textabschnitte werden besonders ausgezeichnet und können entsprechend durchsucht werden), aber auch feingranulare Annotationen: Paul kann aus einer Wiki-Seite zur Filiale in Rom nicht nur auf Dateien zum Thema verweisen, sondern sie auch in das Wiki importieren, Abschnitte auszeichnen („Dieses Dokument ist ein Vertragstext; in *diesem*

⁹ Kaukolu ist frei verfügbar unter <http://kaukoluwiki.opendfki.de/>. Es gibt alternative Implementierungen von Semantic Wikis, etwa *IkeWiki*, *OntoWiki* oder *Semantic MediaWiki*, diese sind jedoch nicht integriert.

Abschnitt geht es um die Pflichten meines Vertragspartners“) und neu zusammenstellen („Bitte ein neues Dokument erstellen, in dem die Daten aller Vertragspartner aller Filialen aufgelistet werden“).

Semantifizierung bestehender Anwendungen

Das Semantic Desktop Wiki ist also der perfekte Ersatz für die Notizfelder in Desktop-Anwendungen, aber die Integration kann noch weiter gehen. Ein gern vorgebrachter Einwand gegen das Semantic Web ist: „Aber es ist doch ein zusätzlicher Aufwand, alles korrekt zu annotieren, das macht doch kein Mensch“. Völlig falsch, sie tun es, aber es kommt auf die Benutzerschnittstelle und den Nutzen an.

Luis von Ahn hat 2005 in seiner Dissertation bewiesen, dass Menschen sehr gerne stundenlang Annotieren, wenn man es ihnen schmackhaft macht (nebenbei hat er dabei Captchas erfunden, eine Methode die heute global eingesetzt wird, um Mensch von Maschine zu unterscheiden). Durch ein gelungenes Interface, das als Spiel gestaltet ist, wurden in seinem Experiment so viele Bilder annotiert, dass Google inzwischen die Idee eingekauft hat.

Es besteht also Bedarf an benutzerfreundlichen Werkzeugen zur Erstellung semantischer Information. Genau diese Lücke haben nun aber bereits Flickr für Photos, del.icio.us für Bookmarks oder myspace.com für persönliche Webseiten gefüllt. Sie ermöglichen Millionen von Menschen, semantische Annotationen zu Photos oder Webseiten zu erstellen. Am Desktop werden andere Anwendungen verwendet: Office, Multimedia Editoren wie Photoshop oder Adobe Premiere, Enterprise Ressource Planning (ERP), Spiele, usw. Jede dieser Anwendungen, sei es am Web oder am Desktop, kann zur Semantic Desktop Anwendung werden. Einzige Voraussetzung ist die Integration des Persönlichen Informationsmodells des Benutzers – die Projekte, Themen, Kontakte, Orte und sonstigen wichtigen Daten müssen bei der Annotation verfügbar sein. Ein einfaches Beispiel sehen wir in Abb. 4, ein Plugin zur Annotation von E-Mails (kompatibel mit Gnowsis).



Abb. 4. Tagging von E-Mails mit Konzepten aus der PIMO




Abb. 5. Annotation eines Dokumentes mittels SeMouse

Dabei wird ein E-Mail über eine Zimmerreservierung mit der zugehörigen Konferenz verbunden:

Ein weiteres Beispiel ist das SeMouse Projekt [14], mit dem es möglich ist, Webseiten im Browser, MS-Word Dokumente und weitere Textdokumente zu annotieren, eingebettet in die bestehenden Anwendungen. In Abb. 5 sehen wir, wie ein PDF Dokument in das persönliche Informationsmodell eingepflegt wird. Zuerst wurde die Dokumentart festgelegt (*Proposal*), danach können Texte markiert und mittels der mittleren Maustaste als Annotationen verwendet werden. SeMouse passt sich dabei an die Ontologien und das Persönliche Informationsmodell an.

Das Einzige, was man also machen muss, um Web 2.0 Anwendungen kompatibel zu machen, ist, das Persönliche Informationsmodell zur Verwaltung der Tags zu verwenden. Damit werden die Tags und Ordnerstrukturen auch über Anwendungsgrenzen hinweg geteilt, ein Konzept, das in einer Anwendung definiert wird, kann im PIMO gespeichert werden und ist dort für andere Anwendungen verfügbar.

Die personalisierte, semi-automatische Klassifikation (wie oben beschrieben) soll dabei den Benutzer mit Vorschlägen zur Annotation unterstützen, somit besteht der Aufwand meist nur darin „OK“ zu klicken, um die durch das System vorgeschlagenen Annotationen zu bestätigen. Es besteht auch ein sofort sichtbarer Nutzen: die Dokumente werden besser in der semantischen Suche gefunden und verknüpfte Ressourcen können von

jeder Anwendung aus geöffnet werden. Vom Deliverable aus kann man dann etwa die Projektmanagement-Anwendung öffnen.

Auf dem Business-Desktop werden wir bald sehen, dass Scharen von Anwendern freudig Ressourcen mit semantischer Technologie annotieren, integriert mit dem Organizational Memory per Ontologie.

Sie dachten wirklich, ein Desktop ist ein Schreibtisch?

Im Film „Disclosure“ (1994, deutscher Titel: „Enthüllung“) von Barry Levinson, mit Michael Douglas und Demi Moore in den Hauptrollen, spielt die entscheidende Szene zwischen den beiden (nicht was sie jetzt denken, die andere Szene) im Cyberspace: In einer virtuellen Bibliothek, dreidimensional und begehbar, befinden sich die zwei Hauptdarsteller und interagieren mit dem Informationssystem ihres Unternehmens. Dort befinden sich alle Akten, Unterlagen, Notizen, sprich: das gesamte Wissen des Unternehmens. Die Aufgabe ist delikat: Die beiden stehlen sich gegenseitig Akten und die weibliche Hauptfigur vernichtet Beweise. Obwohl sie physisch an zwei verschiedenen Arbeitsplätzen sind, sind sie sich der Gegenwart des anderen aber bewusst: Michael Douglas kann Demi Moore beobachten und erkennt ihre finsternen Absichten. Die Entscheidung, wer nun das betriebliche Mobbing gewinnt, wird wie in einem Computerspiel erkämpft, in der Welt der Informationen, wo Entscheidungen getroffen werden, entfernt von physischen Gebäuden und Strukturen.

Nun, das führt uns zu der Frage: *Sie dachten wirklich, sie haben einen Schreibtisch, einen physischen Ort?* In einem Kapitel über den Semantic Desktop im Social Semantic Web müssen wir die ganze Umgebung betrachten, in der ein Wissensarbeiter tätig ist, und nicht nur den Personal Computer und die Software darauf. Wenn ein aktuelles ISDN Telefon bei einem Anruf nicht automatisch den zugehörigen Kontakt in meinem Adressbuch öffnet, warum sollte ich es dann noch kaufen? IP-Telefone von Cisco (etwa die Serie 7940) greifen auf das Firmeninterne LDAP-Verzeichnis zu, um Telefonnummern nachzuschlagen, andere Datenquellen können angepasst werden. Der Arbeitsplatz endet nicht bei Computer und Telefon: eine Chipkarte, die meine Bürotür öffnet, dient auch der Arbeitszeiterfassung und ich kann damit in der Betriebs-Cafeteria einen Cappuccino bezahlen (wie am Microsoft Campus in Redmond). Mobiltelefone verschmelzen mit dem Internet und werden laut Howard Rheingold's Buch „Smart Mobs“ zur „Fernsteuerung meines Lebens“ [19]. Barcodes, Chipkarten, und RFID Chips ermöglichen es, jeden beliebigen Gegenstand mit Annotationen aus dem Semantic Web zu verknüpfen, sei es nun ein T-Shirt, ein ausgedrucktes Dokument oder ein Fass Bier. Die Verknüpfung

von realen Orten und Gegenständen mit Information aus Wikipedia kann durch jedermann erfolgen, wie es etwa das *Semapedia* Projekt anregt (www.semapedia.org).

All diese Entwicklungen sagen uns etwas: Das Social Semantic Web fängt nicht am Desktop an, sondern in der realen Welt, in der wir leben und arbeiten. Diese Welt wird mit der Informationswelt unzertrennlich verwoben. Der Semantic Desktop ist nicht auf einen Desktop Computer beschränkt. Die zentrale Idee ist es, Ressourcen, die die Aufmerksamkeit des Benutzers erregen, zuerst im Semantic Web und dann in einem Persönlichen Informationsmodell zu erfassen. Ob dieses PIMO nun auf dem Desktop oder auf einem Web-Server gespeichert wird, ist nebensächlich. Alle beschriebenen Technologien sind heute für den Semantic Desktop erforscht worden, sollen aber genauso als Plug-Ins in den Web-Anwendungen vorkommen, die ein Benutzer verwendet. Genauso sollen Telefon, Kleidung, Fernseher, Spielkonsole und Auto wissen, wer gerade der Benutzer ist, und entsprechend persönliche Informationsmodelle zur Verfügung stellen. Gegenstände, die über Barcode oder RFID identifiziert werden können, sind Ressourcen im Sinne des Semantic Web, und wenn ein Buch physisch im Regal steht, ist es so identifizierbar und Teil des PIMO des Lesers. Im privaten Bereich geschieht dies schon seit geraumer Zeit, aber die gleiche Entwicklung wird auch in der Betriebsinformatik stattfinden. Ihr Arbeitsplatz ist nicht ein Tisch (Desktop) mit vier Beinen, Computer, Telefon und Lampe darauf – das ist nur der Teil des Arbeitsplatzes, den die anderen sehen. Ihr wirklicher Arbeitsplatz, der Ort, an dem Sie ihre Informationsarbeit erledigen, ist woanders, nämlich in den Konzepten, den Dokumenten und den Personen – sprich in der Informationswelt. Der Einsatz von Semantic Desktop und Social Semantic Web Technologien fängt nicht erst beim Arbeitsplatz-PC an, sondern im Unternehmen. Die Entscheidung, semantische Technologien zu verwenden, dehnt sich aus. Auf die Mobiltelefone der Mitarbeiter und die räumlichen Markierungen in Betrieben (Raumnummern, Regale in Lagerhäusern), die Position von Gütern in der Logistik, die Position von Fahrzeugen, etc.. Der Einsatz von Ontologien endet nicht in Ihrem Call-Center oder in Ihrer Intranet-Suche, sondern wird früher oder später alle Bereiche eines Betriebs umfassen. Das Unternehmen steht aber nicht allein auf weiter Flur, Lieferanten und Kunden sind Teil des globalen Social Semantic Web, und jede Information, die auf der Webseite nach außen kommuniziert wird oder die per E-Mail versendet wird, kann in Zukunft mit Metadaten und dem Bezug zu einem Persönlichen Informationsmodell versehen werden.

Fazit

Die vorgestellten Ansätze aus dem Semantic Desktop Bereich ermöglichen es, das persönliche Weltbild eines Benutzers im Computer zu repräsentieren, um somit Daten aus verschiedenen Quellen besser integrieren und verstehen zu können. Der *Semantic Desktop* wird es Peter und Paul ermöglichen, das Projekt „Gründung einer Filiale in Rom“ im vollen Umfang zu sehen. Verknüpfte E-Mails, Termine, Orte, Themen, Dokumente, Webseiten, Wissen aus dem Organizational Memory, aktuelle Daten aus dem ERP, alle können ontologiebasiert kontextualisiert, vernetzt und visualisiert werden. Das *Social Semantic Web* ist Datenquelle für den Benutzer und Informationen aus dem *Persönlichen Informationsmodell* können dort wiederum veröffentlicht werden. Ansätze aus der Textklassifizierung und der Sprachverarbeitung können in diesem Umfeld ihre Stärken besser ausspielen, da sie speziell an den Benutzer adaptiert werden. Als Schnittstelle sehen wir sowohl Desktop Computer, als auch Web-basierte und mobile Lösungen. Die künstliche Intelligenz des Computers denkt nicht autonom, sie wird zum Mit-Denker des Benutzers.

Danksagung

Wir möchten allen Mitgliedern des NEPOMUK Projektes danken, die das Herz der Semantic Desktop Community bilden. Die erweiterte Semantic Desktop Community finden Sie auf www.semanticdesktop.org, viele davon in der zitierten Literatur. Weiters danken wir den Kollegen am DFKI für die angenehme Arbeitsatmosphäre und die tatkräftige Unterstützung, sowohl theoretisch als auch praktisch. Johannes Kuhn von Cisco Österreich hat uns über Internettelefonie informiert. Der Screenshot von SeMouse wurde freundlicherweise von Sergio F. Anzuola zur Verfügung gestellt. Besonderen Dank an Tim Berners-Lee, der das ganze überhaupt erst ins Rollen gebracht hat und immer noch verantwortungsvoll koordiniert.

Literatur

1. von Ahn, Luis (2005) Human Computation. Dissertation, Carnegie Mellon University
2. Barreau D, Nardi B.A. (1995) Finding and Reminding: File Organization from the Desktop
3. Bizer C, Seaborne A (2004) D2RQ-Treating Non-RDF Databases as Virtual RDF Graphs. International Semantic Web Conference 2004

4. Castulus K, Baur T (2004): Living a Virtual Life: Social Dynamics of Online Gaming. *Game Studies* 4(1). In: <http://www.gamestudies.org/0401/kolo/>, aufgerufen November 2005
5. Chao D (2001) Doom as an Interface for Process Management. *Proceedings of the CHI2001 Conference on Human Factors in Computing Systems*
6. Crestani F., Van Rijsbergen C.J. (1997) A Model for Adaptive Information Retrieval. *Journal of Intelligent Information Systems*, v.8 n.1, pp. 29–56, Jan./Feb. 1997
7. Croft W. B., Thompson R. H. (1987) I3R: a new approach to the design of document retrieval systems. *Journal of the American Society for Information Science*, v.38 n.6, pp. 389–404, Nov 1987
8. Dengel A, Abecker A, Bernardi A, van Elst L, Maus H, Schwarz S, Sintek M (2002) Konzepte zur Gestaltung von Unternehmensgedächtnissen. In: *KI Journal* Nr. 1, 2002
9. Einsfeld K, Ebert A, Agne S, Klein B (2005) DocuWorld — A 3D User Interface to the Semantic Desktop. *Proceedings of the 1st Semantic Desktop Workshop*, 2005
10. van Elst L, Abecker A (2001) Ontologies for information management: balancing formality, stability, and sharing scope. In: *Expert Systems with Applications* Nr. 23, 2001
11. Groza T., Handschuh S., Moeller K., Grimnes G., Sauermann L., Minack E., Mesnage C., Jazayeri M., Reif G, Gudjonsdottir R. (2007): The NEPOMUK Project – On the way to the Social Semantic Desktop. *Proc. of I-Semantics 2007*
12. Guha R., McCool R., Miller E. (2003) Semantic Search. In *Proceedings of the 12th international conference on World Wide Web*, pp. 700–709
13. Hildebrand M., van Ossenbruggen J.R., Hardman L. (2007) An analysis of search-based user interaction on the Semantic Web. *CWI Report, INS-E0706*, ISSN 1386-3681
14. Iturrioz J., Anzuola S. F., Díaz O. (2006) Turning the mouse into a semantic device: the seMouse experience. *Proc. of the 3rd European Semantic Web Conference*, Budva, Montenegro
15. Kiesel M. (2006) Kaukolu: Hub of the Semantic Corporate Intranet, In *Proceedings of the Workshop SemWiki2006 at the ESWC2006 Conference*
16. Lei Y., Uren V.S., Motta E. (2006) SemSearch: a search engine for the semantic web. In *Proceedings EKAW 2006, Managing Knowledge in a World of Networks*, pp. 238–245
17. Ontoprise GmbH. Ontooffice In: <http://www.ontoprise.de/>, aufgerufen November 2005
18. Quan D, Huynh D, Karger DR (2003) Haystack: A Platform for Authoring End User Semantic Web Applications. *International Semantic Web Conference 2003*
19. Rheingold H (2002) *Smart Mobs. The Next Social Revolution*. Basic Books
20. Sauermann L, Grimnes G.A., Kiesel M, Fluit C, Maus H, Heim D, Nadeem D, Horak B, Dengel A (2006) *Semantic Desktop 2.0: The Gnowsisis Experience*, *Proceedings of the ISWC* pp. 887–900

21. Sauermann L, Bernardi A, Dengel A (2005) Overview and Outlook on the Semantic Desktop, Proceedings of the 1st Semantic Desktop Workshop, 2005
22. Sauermann L, Schwarz S. (2005) Gnowsis Adapter Framework: Treating Structured Data Sources as Virtual RDF Graphs. In Proceedings of the ISWC 2005
23. Sauermann L (2003) The Gnowsis-Using Semantic Web Technologies to build a Semantic Desktop. Diplomarbeit
24. Sparql In: Prud'hommeaux E, Seaborne A (eds) SPARQL Query Language for RDF. W3C Working Draft (2005), <http://www.w3.org/TR/rdf-sparql-query/>, aufgerufen November 2005
25. Lee R (2004) Scalability Report on Triple Store Applications. Technical Report, July 2004. In: <http://simile.mit.edu/reports/stores/>, aufgerufen November 2005
26. Uschold, M. (2003) Where are the Semantics in the Semantic Web? AI Magazine 24(3), pp. 25–36
27. Usu Knowlegde Miner. In: <http://www.usu.de/>, aufgerufen November 2005

18. Social Bookmarking am Beispiel BibSonomy

Andreas Hotho¹, Robert Jäschke^{1,2}, Dominik Benz¹, Miranda Grahl¹,
Beate Krause^{1,2}, Christoph Schmitz¹ und Gerd Stumme^{1,2}

¹ Hertie-Lehrstuhl Wissensverarbeitung, FB Elektrotechnik/Informatik,
Universität Kassel; nachname@cs.uni-kassel.de

² Forschungszentrum L3S, Hannover

Zusammenfassung: BibSonomy ist ein kooperatives Verschlagwortungssystem (Social Bookmarking System), betrieben vom Fachgebiet Wissensverarbeitung der Universität Kassel. Es erlaubt das Speichern und Organisieren von Web-Lesezeichen und Metadaten für wissenschaftliche Publikationen. In diesem Beitrag beschreiben wir die von BibSonomy bereitgestellte Funktionalität, die dahinter stehende Architektur sowie das zugrunde liegende Datenmodell. Ferner erläutern wir Anwendungsbeispiele und gehen auf Methoden zur Analyse der in BibSonomy und ähnlichen Systemen enthaltenen Daten ein.

Einleitung

BibSonomy ist ein kooperatives Verschlagwortungssystem (Social Bookmarking System) zur Verwaltung von Web-Lesezeichen und Publikationen. Das System ist seit Dezember 2005 unter der Adresse <http://www.bibsonomy.org/> online und wird vom Fachgebiet Wissensverarbeitung der Universität Kassel betrieben. Dieses für jeden freinutzbare System erlaubt es, Lesezeichen (Favoriten, Bookmarks) für Webseiten zentral auf dem BibSonomy-Server abzuspeichern und zu verschlagworten. Die vom Nutzer frei wählbaren Schlagwörter, auch ‚Tags‘ genannt, erlauben es ihm, seine Lesezeichen- und Literatursammlung zu strukturieren und mit Hilfe der Schlagwörter einen Eintrag später einfach wieder zu finden. Die Sammlungen aller Benutzer sind in einer ‚Folksonomie‘ zusammengefasst. Das System bietet jedem Benutzer die Möglichkeit, in dieser Folksonomie auch nach Lesezeichen und Publikationsreferenzen anderer Benutzer mit verwandten Interessen zu suchen. Diese soziale Komponente erzeugt also personalisierte Empfehlungen, die globale Suchmaschinen wie Google nicht leisten können, da sie die Interessen

des Anfragenden nicht kennen. Durch die zentrale Speicherung hat der Benutzer außerdem jederzeit von jedem Rechner Zugriff auf seine Lesezeichen und Publikationsdaten.

Ein Grund für die Entwicklung von BibSonomy war die Tatsache, dass Literaturrecherche und -verwaltung eine zentrale Rolle in der täglichen Arbeit eines Wissenschaftlers spielt, es für die systematische Katalogisierung der gefundenen Publikationen jedoch wenig Unterstützung gibt – jeder Forscher entwickelt typischerweise sein eigenes Verwaltungs- und Ablageschema, und jedes Institut führt darüber hinaus mit hohem Aufwand jeweils eigene Literaturlisten. Da diese Schwierigkeiten auch in unserem Fachgebiet auftraten, und wir die Möglichkeit sahen, diese in Kooperation mit anderen Forschern effektiver und effizienter anzugehen, wurde die kollektive Literaturverwaltung in BibSonomy als zweite Kern-Komponente neben der Lesezeichenverwaltung eingebaut. Für interessierte Gruppen (z. B. Universitätsinstitute oder Projektkonsortien) bietet das Fachgebiet die Einrichtung von Benutzergruppen im System an, mit denen sowohl der interne als auch der externe Literaturaustausch organisiert werden kann.

BibSonomy basiert auf dem BibTEX-Format [19] zur Speicherung von Publikationsdaten. Seine Publikationsverwaltung ist somit leicht in das Satz-System LATEX [14] integrierbar, mit dem Forscher – insbesondere aus den Naturwissenschaften – ihre wissenschaftlichen Veröffentlichungen druckfertig gestalten. Das System erzeugt automatisch Literaturlisten in weiteren Formaten und verringert so den Gesamtaufwand, der Wissenschaftlern zur Erstellung ihrer Publikationslisten für verschiedene Zwecke (Web-Publikationslisten der einzelnen Wissenschaftler und der ganzen Forschungsgruppe, Referenzlisten in Publikationen, Projekt-Berichte, Berichte an die Hochschulleitung, etc.) – vielfach durch die Verwendung unterschiedlicher Systeme – aufgezwungen wird. In BibSonomy wird die gesamte Literaturliste einmal zentral verwaltet. Aus ihr können dann die gewünschten Teillisten automatisch in die gewünschten Formate exportiert werden. Dafür werden neben BibTEX auch die für Anwender von Microsoft Word interessanten Formate RTF und EndNote erzeugt, aber auch Formate wie XML, RSS-Feeds und formatiertes HTML. Ausgewählte Anwendungsszenarien werden in den Kapiteln 4 und 5 beschrieben.

BibSonomy ist eines von mehreren kooperativen Verschlagwortungssystemen, die im Zuge des Web 2.0 – der nächsten Generation des World Wide Webs – entstanden sind. Andere Verschlagwortungssysteme dienen der Verwaltung von Photos und Musik – und selbst dem Austausch von guten Vorsätzen. BibSonomy ist derzeit das einzige System, das die Ver-

waltung von Lesezeichen und Publikationen verbindet.¹ Im Zentrum der Entwicklung stand die Anwendbarkeit im akademischen Bereich; die Rückmeldungen von vielen Wissenschaftlern sind in die Entwicklung des Systems mit eingeflossen. Zurzeit (Stand 7.3.2008) hat das System 2.632 aktive Benutzer, die sich 199.849 Web-Lesezeichen und 76.984 Publikationen teilen. Hinzu kommen 18.193 Web-Lesezeichen und 979.033 Publikationen, die automatisch von der Computer Science Library der Universität Trier übernommen werden. Das System verzeichnet derzeit im Schnitt 810.487 Seitenzugriffe pro Tag; die Tendenz ist steigend. Ein besonderer Schwerpunkt bei der Implementierung wurde auf die effiziente Beantwortung der Anfragen gelegt. Details zur Implementierung sowie zur Funktionalität des Systems sind in den Kapiteln 2 und 3 beschrieben.

Die frei wählbaren Schlagwörter ergänzen die üblichen Publikationsdaten wie Autor, Titel, Verlag, Jahr etc. Ähnlich gehen Bibliotheken vor, wenn sie Bücher in ihren Bestand aufnehmen und diese zum Zwecke des Wiederfindens verschlagworten. Während in einer Bibliothek jedoch – wie in Semantic-Web-Anwendungen – die Schlagwörter aus einem fest vorgegebenen Katalog ausgewählt werden, kann in BibSonomy jeder Nutzer seine Schlagwörter frei wählen und so auch aktuelle Themen beschreiben, die in einem vorgegebenen Katalog (noch) nicht erfasst oder die nicht offensichtlich mit dem Werk verbunden sind. Die Bibliothekslösung hat dagegen den Vorteil, dass die Literatursuche nicht durch mehrdeutige Schlagwörter erschwert wird. Bibliothekare werden allerdings für die systematische Verschlagwortung geschult, was für einen breiteren Benutzerkreis nicht vorausgesetzt werden kann.

Die zentrale Frage, um die Vorteile von Web 2.0 (Nähe zum Anwender und daraus resultierende umfangreiche Datensammlungen) und Semantic Web (Wissensrepräsentation mit formaler Semantik und daraus resultierender Unterstützung von strukturierter Navigation und Wissensableitung durch logisches Schließen) zu verbinden – eine Kombination, die mancherorts schon als ‚Web 3.0‘ vermarktet wird – ist daher, wie untrainierte Anwender effektiv unterstützt werden können, ohne durch eine komplexe Interaktion mit den zugrunde liegenden Wissensverarbeitungsverfahren irritiert zu werden. Wir haben in diese Richtung mehrere Ansätze in den Bereichen Datenanalyse, Information Retrieval und Wissensentdeckung auf die neue Datenstruktur von Folksonomien erweitert. Diese Ansätze werden wir in Kapitel 6 kurz beschreiben.

¹ Bekannte Systeme zur kooperativen Publikationsverwaltung sind <http://www.citeulike.org> und <http://www.connotea.org> sowie <http://del.icio.us> zur Lesezeichenverwaltung. Ein Vergleich von BibSonomy mit diesen Systemen wurde in [23] durchgeführt.

Aufbau des Systems

In diesem Abschnitt beschreiben wir das BibSonomy-System. Nach einer Einführung in die Benutzeroberfläche, der Vorstellung des zentralen formalen Folksonomie-Modelles, der Semantik und der Architektur von BibSonomy erklären wir weitere Eigenschaften sowie zukünftige Verbesserungen. Eine Beschreibung der Funktionalität und der internen Datenstrukturen der ersten Version von BibSonomy findet man in [7]. Das aktuell laufende System basiert auf einem neuen internen Modell. Es bietet eine in vielen Punkten erweiterte Funktionalität an. Der neue modulare Aufbau vereinfacht die Wartung und Weiterentwicklung des Systems erheblich.




Abb. 1. BibSonomy zeigt gleichzeitig Lesezeichen und auf BibTEX basierende Literaturverweise an

Benutzeroberfläche

Abbildung 1 zeigt eine typische Liste von Einträgen bestehend aus Lesezeichen und Literaturreferenzen, die mit dem Schlagwort *web* annotiert wurden. Die Seite besteht aus vier Abschnitten: dem Kopf (mit Informa-

tionen zur aktuellen Seite, dem aktuellen Pfad, Navigationselementen und Suchfeldern), zwei Listen von Einträgen – eine für Lesezeichen und eine für Literaturreferenzen – die jeweils absteigend nach Datum sortiert sind, und einer Liste von Schlagwörtern, die mit den Einträgen verwandt sind. Dieses Schema gilt für alle Seiten, die Einträge anzeigen, und ermöglicht das Navigieren in allen Dimensionen der Folksonomie. Die darunterliegende Semantik dieser Seiten wird in Abschn. 3 erklärt.

REST web services

Good intro to the REST "architecture"

to [web service tutorial guidelines api rest](#) by [hotho](#) and [3 other people](#) on 2006-04-04 16:11:47 [copy](#)

Abb. 2. Detaillierte Ansicht eines einzelnen Lesezeicheneintrags

Semantic Network Analysis of Ontologies

Bettina Hoser and Andreas Hotho and Robert Jäschke and Christoph Schmitz and Gerd Stumme. *Proceedings of the 3rd European Semantic Web Conference* *\emph{(accepted for publication)}* (2006)

to [web 2006 social ontology myown semantic analysis network sna](#) by [hotho](#) and [1 other person](#) on 2006-04-06 21:32:23 [pick copy URL BibTeX](#)

Abb. 3. Detaillierte Ansicht eines einzelnen Literatureintrags

Abbildung 2 zeigt eine detaillierte Ansicht eines Lesezeichen-Eintrags aus der Liste in Abb. 1. Die erste Zeile zeigt fett gedruckt den Titel des Lesezeichens in Form eines Hyperlinks. Die zweite Zeile zeigt eine optionale Beschreibung, die der Benutzer jedem Eintrag zuordnen kann. Die letzten zwei Zeilen gehören zusammen und zeigen detaillierte Informationen: Erstens alle Schlagwörter, die der Benutzer diesem Eintrag zugeordnet hat (*web*, *service*, *tutorial*, *guidelines* und *api*), zweitens den Benutzernamen dieses Benutzers (*hotho*) gefolgt von einem Hinweis, wie viele Benutzer insgesamt diese spezifische Ressource verschlagwortet haben. Diese Informationen fungieren als Hyperlinks zu den entsprechenden Schlagwort-Seiten des Benutzers (*/user/hotho/web*, */user/hotho/service*, ...), der Seite des Benutzers selbst (*/user/hotho*) und einer Seite, die alle vier Einträge (d. h. den einen des Benutzers *hotho* und die der drei anderen) dieser Ressource zeigt (*/url/r*). Abschn. 3 erklärt die Pfade, die bis auf

weiteres in Klammern angegeben sind. Der letzte Teil zeigt Datum und Uhrzeit des Eintrags, gefolgt von Links auf Aktionen, die der Benutzer ausführen kann – je nachdem, ob es sein eigener Eintrag ist (*bearbeiten*, *löschen*) oder der eines anderen Benutzers (*kopieren*).

Die Struktur eines Literatureintrags in BibSonomy ist ähnlich (siehe Abb. 3). Die erste Zeile zeigt wieder den Titel des Eintrags, der derselbe ist wie der Titel der Publikation in BibTEX. Er hat einen darunter liegenden Hyperlink, der zu einer Seite führt, die detaillierte Informationen zu diesem Eintrag präsentiert. Nach dieser Zeile kommen die Autoren oder Herausgeber der Publikation sowie der Titel der Zeitschrift oder des Buchs mit dem Erscheinungsjahr. Die nächsten Zeilen zeigen die Schlagwörter, die diesem Eintrag vom Benutzer zugeordnet wurden, danach dessen Benutzername, gefolgt von einem Hinweis, wieviele Personen diese Publikation verschlagwortet haben. So wie schon für die Lesezeicheneinträge beschrieben, verweisen diese Teile auf entsprechende weiterführende Seiten. Nach der Angabe von Datum und Zeit, zu denen der Benutzer diesen Eintrag gemacht hat, folgen die Aktionen, die der Benutzer ausführen kann (in diesem Fall Auswahl des Eintrags für einen späteren Download, Kopieren, Folgen eines Hyperlinks zu einer externen Referenz des Eintrags und Ansicht des BibTEX-Quellcodes).

Das System enthält eine Reihe spezieller Funktionen, die an dieser Stelle kurz vorgestellt werden.

Gruppen

BibSonomy verfügt über Benutzergruppen, die das gemeinsame Sammeln von Einträgen in offenen und geschlossenen Gruppen unterstützen. Eine Liste aller im System registrierten Gruppen findet man unter `/groups`. Die Gruppen fungieren auf der einen Seite als organisatorische Einheiten und erlauben zusammengefasste Sichten über die Einträge aller Gruppenmitglieder. Auf der anderen Seite dienen sie zur Verwaltung der Zugriffsrechte. Auf diesem Weg können Einträge auch gruppenintern geteilt und gemeinsam bearbeitet werden. Jeder Nutzer kann zwischen mindestens drei Gruppen wählen: `public`, `private` und `friends`. In `public` werden alle für jedermann sichtbaren Einträge gesammelt und in `private` die ausschließlich privaten Einträge. `Friends` ist eine Gruppe, in der jeder Benutzer seine befreundeten Benutzer festlegen und mit ihnen Einträge gemeinsam sammeln kann. Die Liste aller Freunde und der dazugehörenden Einträge findet man unter `/friends`.

Warenkorb

Eine weitere Funktion zur Unterstützung der Nutzer bei der Arbeit mit BibSonomy ist der `basket`, ein Warenkorb für Literatureinträge. Er dient dazu, Listen mit Literaturverweisen zusammenstellen zu können. Jeder Literaturverweis im System, unabhängig davon ob es ein eigener oder ein fremder Eintrag ist, kann mittels der `pick`-Funktion in den Warenkorb aufgenommen werden. Für den Warenkorb stehen alle typischen Funktionen, wie das Editieren von Schlagwörtern oder Exporte in andere Formate, zur Verfügung.

Dublettenerkennung

Insbesondere bei Literaturverweisen besteht das Problem doppelter Einträge, da die Art und Weise, wie Benutzer Felder wie ‚Name der Zeitschrift‘ oder ‚Autoren‘ ausfüllen, sehr unterschiedlich ist. Einerseits ist es wünschenswert, dass Benutzer verschiedene Einträge haben können, die nur wenig variieren. Andererseits möchte man die Einträge anderer Benutzer, die sich auf denselben Artikel beziehen, auch dann finden können, wenn die Einträge leicht voneinander abweichen.

Jeder Nutzer erhält auf der Seite `/myDuplicates` einen Überblick über die vom System als Duplikate erachteten Einträge in seiner Literaturliste. Um diese zu erkennen, werden spezielle Hashes aus den Literaturreferenzen des Benutzers errechnet. Sind zwei Hashes identisch, so deutet dies auf ein Duplikat hin und es wird auf der `myDuplicates`-Seite angezeigt. Die gegenwärtige Dublettenerkennung ist sehr einfach; Fehler in der Schreibweise, Unterschiede bei der Eingabe besonderer Zeichen (wie der deutschen Umlaute), und zusätzliche $^L_A T_E X$ -Befehle werden derzeit nicht erkannt. Diese Themen stehen auf unserer Agenda und sind leicht zu ergänzen, denn unsere Implementierung erlaubt die einfache Integration neuer Hashes in das System.

Import- und Export-Funktionen

Um Benutzer zum Wechsel von anderen Systemen hin zu BibSonomy zu ermutigen, haben wir Importfunktionen eingebaut. Lesezeichen können von `del.icio.us` oder aus dem Webbrowser Firefox automatisch übernommen werden. Bei der Literatur ist der Import aus BibTEX-Dateien Standard; man kann auch Daten im EndNote-Format importieren. Zusätzlich sind im System mehr als 25 so genannte Screenscraper² integriert. Sie ermöglichen die automatische Übernahme der Publikationsdaten aus Digi-

² <http://www.bibsonomy.org/scraperinfo>

talen Bibliotheken (beispielsweise SpringerLink und CiteSeer). Literaturdaten von weniger strukturierten Webseiten werden durch Informationsextraktion [20] in BibSonomy übernommen. Unsere Implementierung basiert auf dem MALLET-System [17].

Verschiedene Export-Formate vereinfachen die Interaktion von BibSonomy mit anderen Systemen. RSS-Feeds ermöglichen die einfache Integration von Listen in Webseiten oder RSS-Aggregatoren, und die BibTEX- bzw. EndNote-Ausgabe kann dazu verwendet werden, automatisch Publikationslisten für Veröffentlichungen zu generieren. Weiterhin stehen spezielle HTML-Export-Formate zur Verfügung. Einen Überblick über alle unterstützten Exportformate findet man unter `/export/`. Besonders leicht kann der Nutzer die Ausgabe von BibSonomy mit dem aus dem Open-Source-Projekt JabRef übernommenen Layout-Filter³ erzeugen. Der Layout-Filter bietet die Möglichkeit, in einer einfachen Sprache ein eigenes Ausgabeformat für Literaturreferenzen festzulegen. Der Nutzer kann den selbst definierten Filter ins System hochladen und dann alle BibSonomy-Seiten passend ausgeben.

mySearch

Zur Exploration der eigenen Literaturreferenzen kann man die Funktion `/mySearch` verwenden. Sie bietet ein übersichtliches, Javascript-basiertes Benutzer-Interface, über das man die Referenzen entlang der Schlagwörter und Autoren durchforsten kann.

Formales Folksonomie-Modell

Benutzer, Ressourcen (Webseiten, BibTEX-Einträge o. ä.) und Schlagwörter bilden die Basis einer Folksonomie, des zentralen Datenmodells von kooperativen Verschlagwortungssystemen. Im Folgenden präsentieren wir die formale Definition einer Folksonomie, wie sie auch dem BibSonomy-System zugrunde liegt.

Definition 1: Eine *Folksonomie* ist ein Tupel $F := (U, T, R, Y, <)$ wobei

- U , T und R endliche Mengen sind, deren Elemente man *Benutzer (users)*, *Schlagwörter (tags)* und *Ressourcen (resources)* nennt,
- Y eine ternäre Beziehung zwischen diesen ist, d. h. $Y \subseteq U \times T \times R$ gilt, und

³ <http://jabref.sourceforge.net/help/CustomExports.php> (Dieser, sowie alle folgenden Links auf Webseiten, wurde am 3.3.2008 aufgerufen.)

- $\prec$ eine benutzerspezifische *Unterschlagwort/Oberschlagwort-Beziehung* ist, d. h. $\prec \subseteq U \times T \times T$ gilt.

Die Elemente von Y heißen *Schlagwort-Zuweisungen* (tag assignments). Ein *Eintrag* (post) von F ist ein Tripel (u, S, r) mit $u \in U$, $r \in R$, und $S := \{t \in T \mid (u, t, r) \in Y\}$ mit $S \neq \emptyset$. Die Menge aller Einträge einer Folksonomie wird mit P bezeichnet.

Die *Personomy* P_u eines Users $u \in U$ ist die Einschränkung F auf u , d. h. $P_u := (T_u, R_u, I_u, \prec_u)$ mit $I_u := \{(t, r) \in T \times R \mid (u, t, r) \in Y\}$, $T_u := \pi_1(I_u)$, $R_u := \pi_2(I_u)$ und $\prec_u := \{(t_1, t_2) \in T \times T \mid (u, t_1, t_2) \in \prec\}$.

Benutzer werden typischerweise durch eine User-ID und Schlagwörter durch beliebige Zeichenketten beschrieben. Was man als Ressource betrachtet, hängt vom Systemtyp ab. Ressourcen sind in del.icio.us zum Beispiel Bookmarks und in Flickr Bilder. Unser System BibSonomy enthält zwei Arten von Ressourcen: Lesezeichen und BIBTEX-Einträge. Verschiedene Typen von Ressourcen unterscheiden sich strukturell nicht, da sie unabhängig vom Typ intern durch eine ID repräsentiert werden. Nur die Art der Bildschirmanzeige hängt von der Art der Ressource ab.

Semantik des URL-Schemas

Alle hier beschriebenen relativen URLs beziehen sich auf <http://www.bibsonomy.org>. Wir beschränken die Beschreibung auf die für das System zentralen URLs; organisatorische Seiten wie /help, /settings oder /post_bookmark lassen wir in dieser Übersicht aus. Am Ende dieses Abschnittes gehen wir auf einige interessante Erweiterungen ein. Die folgende Liste gibt zu jeder URL die Menge C der Einträge (Lesezeichen oder Literaturreferenzen) an, die von BibSonomy angezeigt werden.

- **/tag/** $t_1 \dots t_n$ zeigt jeden Eintrag, dem alle Schlagwörter $t_1, \dots, t_n$ zugeordnet sind:

$$C_{t_1, \dots, t_n} := \{(u, S, r) \in P \mid \{t_1, \dots, t_n\} \subseteq S\} \quad (1)$$

- **/user/** u zeigt alle Einträge des Benutzers u :

$$C_u := \{(\hat{u}, S, r) \in P \mid \hat{u} = u\} \quad (2)$$

- **/user/** u / $t_1 \dots t_n$ zeigt jeden Eintrag des Benutzers u , dem alle Schlagwörter $t_1, \dots, t_n$ zugeordnet sind:

$$C_{u, t_1, \dots, t_n} := \{(\hat{u}, S, r) \in P \mid \hat{u} = u, \{t_1, \dots, t_n\} \subseteq S\} \quad (3)$$

- **/concept/** $t_1 \dots t_n$ zeigt jeden Eintrag, dem für jedes Schlagwort $t \in \{t_1, \dots, t_n\}$ mindestens eines seiner Unterschlagwörter oder t selbst zugeordnet sind (siehe auch Abschn. 1):

$$C_{t_1, \dots, t_n} := \{(u, S, r) \in P \mid \forall t_i (i = 1, \dots, n) \exists t \in S : (u, t, t_i) \in \prec \vee t = t_i\} \quad (4)$$

- **/concept/user/** $u / t_1 \dots t_n$ zeigt jeden Eintrag des Benutzers u , dem für jedes Schlagwort $t \in \{t_1, \dots, t_n\}$ mindestens eines seiner Unter-schlagwörter oder t selbst zugeordnet ist (siehe auch Abschn. 1):

$$C_{u, t_1, \dots, t_n} := \{(\hat{u}, S, r) \in P \mid \hat{u} = u, \forall t_i (i = 1, \dots, n) \exists t \in S : (\hat{u}, t, t_i) \in \prec \vee t = t_i\} \quad (5)$$

- **/url/** r zeigt alle Einträge zu Ressource r , wenn sie ein Lesezeichen ist:

$$C_r := \{(u, S, \hat{r}) \in P \mid \hat{r} = r\} \quad (6)$$

- **/url/** r / u zeigt den Eintrag von Benutzer u zu Ressource r , wenn sie ein Lesezeichen ist:

$$C_{r, u} := \{(\hat{u}, S, \hat{r}) \in P \mid \hat{r} = r, \hat{u} = u\} \quad (7)$$

- **/bibtex/** r zeigt alle Einträge zu Ressource r , wenn sie ein Literaturverweis ist:

$$C_r := \{(u, S, \hat{r}) \in P \mid \hat{r} = r\} \quad (8)$$

- **/bibtex/** r / u zeigt den Eintrag von Benutzer u der Ressource r wenn sie ein Literaturverweis ist:

$$C_{r, u} := \{(\hat{u}, S, \hat{r}) \in P \mid \hat{r} = r, \hat{u} = u\} \quad (9)$$

- **/groups** zeigt alle Gruppen des Systems. Mehr zu Gruppen siehe Abschn. 1.

- **/group/** g zeigt alle Einträge aller Benutzer, die zu Gruppe g gehören:

$$C_g := \{(u, S, r) \in P \mid u \in g\} \quad (10)$$

- **/group/** $g / t_1 \dots t_n$ zeigt jeden Eintrag, dem alle Schlagwörter $t_1, \dots, t_n$ zugeordnet sind, und dessen Benutzer zu Gruppe g gehört:

$$C_{g, t_1, \dots, t_n} := \{(u, S, r) \in P \mid u \in g, \{t_1, \dots, t_n\} \subseteq S\} \quad (11)$$

- **/viewable/** g zeigt alle Einträge, die für Mitglieder der Gruppe g sichtbar eingestellt sind.

- **/viewable/** $g / t_1 \dots t_n$ zeigt alle Einträge, die für Mitglieder der Gruppe g als sichtbar eingestellt sind und denen alle Schlagwörter $t_1, \dots, t_n$ zugeordnet sind.

- **/search/** s zeigt (basierend auf der MySQL-Volltext-Suchfunktion⁴) alle Einträge, deren Volltext oder Schlagwörter dem Suchausdruck s entsprechen.

⁴ <http://dev.mysql.com/doc/refman/5.0/en/fulltext-boolean.html>

- **/basket** zeigt alle Literatureinträge, die der Benutzer in den Warenkorb gelegt hat, wie in Abschn. 1 beschrieben.
- **/popular** zeigt die 100 am häufigsten abgespeicherten Ressourcen innerhalb der letzten 1000 Einträge. (Diese Liste unterliegt einem stetigen Wechsel.)
- **/** ist die Homepage von BibSonomy; sie zeigt die aktuellsten Einträge.
- **/author/** $a_1 \dots a_n$ zeigt jeden Eintrag, der alle Namen aus $a_1 \dots a_n$ als Nachnamen enthält. Dabei spielt es keine Rolle, ob der Name im Autor- oder Herausgeber-Feld vorkommt. Die übergebenen Namen werden auf Nachnamen normalisiert. Ist ein Name von Anführungszeichen umgeben, so werden nur Einträge ausgegeben, die im Autor- oder Herausgeber-Feld exakt diesen Namen enthalten.
- **/uri/...** ist eine für den Zusammenschluss mit anderen Semantic-Web-Diensten notwendige URL-Erweiterung. Sie erlaubt die Auswahl des auszugebenden Datenformats durch den anfragenden Dienst unabhängig von der URL und leitet auf die Seite mit dem gewünschten Ausgabeformat weiter (siehe Abschn. 2).
- **/bibtexkey/** k zeigt die Einträge an, die den BIBTEX-Key k haben.
- **/api/** ist die Basis-URL für den Zugriff auf die REST-API von BibSonomy. Details findet man in Abschn. 3.
- **/export/** zeigt die Liste aller zur Verfügung stehenden Exportformate für die aktuelle Seite an. Einige Formate werden in den Abschnitten 1 und 2 beschrieben.
- **/my...** umfasst eine Reihe von URLs, die dem Benutzer einen einfachen Zugriff auf seine gespeicherten Daten erlauben: `/myBibSonomy`, `/mySearch`, `/myPDF`, `/myRelations` und `/myDuplicates`.

Allen oben beschriebenen URL-Pfaden kann eine Zeichenkette vorangestellt werden, die das Ausgabeformat ändert (siehe Abschn. 4). Im Allgemeinen werden Einträge als HTML-Listen angezeigt, die von Navigationselementen und einer Schlagwort-Wolke umgeben sind (siehe Abb. 1), aber diese Eigenschaft ermöglicht es dem Benutzer, aufgabenspezifische Ausgabeformate wie BIBTEX, RSS oder passend formatierte HTML-Seiten (nach eigenen Layoutvorgaben) zu erhalten.

Architektur

Die Grundbausteine von BibSonomy sind ein Apache Tomcat⁵ Servlet Container, der Java Server Pages⁶ und Java Servlet⁷-Technologie verwen-

⁵ <http://tomcat.apache.org>

⁶ <http://java.sun.com/products/jsp>




Abb. 4. UML-Diagramm der Komponenten von BibSonomy

det, sowie eine MySQL⁸-Datenbank. Gegenwärtig beinhaltet das Projekt mehrere zehntausend Codezeilen und verwendet das Model View Controller (MVC) Programmier-Paradigma [12], um die logische Verarbeitung der Daten von deren Präsentation zu trennen. Dies ermöglicht es, Ausgaben in verschiedenen Formaten zu erzeugen (siehe Abschn. 4), da das Hinzufügen eines neuen Ausgabeformats lediglich den Austausch einer JSP als Modellansicht erfordert. Weiterhin wird das Spring-MVC-Framework⁹ verwendet, um die unterschiedlichen Teile einer HTML-Seite unabhängig voneinander zu erzeugen und so das System zusätzlich zu modularisieren.

Einen Überblick über die Komponenten des Systems gibt Abb. 4. Man erkennt die zentralen Komponenten `DatabaseLogic` und `Model` des Systems, um die sich auf der einen Seite `RESTServer` und `WebApplication` als Elemente zur Kommunikation mit der Außenwelt, auf der anderen Seite die Hilfskomponenten `RESTCommon`, `Common`, `Scraper`, `DL-Importer` und `BibTeX-Parser` gruppieren.

- **DatabaseLogic.** Diese Komponente kapselt alle Datenbankabfragen und stellt ein internes Interface für den Datenzugriff bereit. Zur Kodierung der SQL-Anfragen wird IBATIS¹⁰ eingesetzt. Ein Hauptgrund für die Auswahl dieses Persistenz-Frameworks war die Möglichkeit, direkte

⁷ <http://java.sun.com/products/servlets>

⁸ <http://www.mysql.com>

⁹ <http://static.springframework.org/spring/docs/2.0.x/reference/mvc.html>

¹⁰ <http://ibatis.apache.org/>




Abb. 5. UML-Diagramm des BibSonomy zugrunde liegenden Datenmodells

Kontrolle über die SQL-Anfragen beizubehalten und sie somit ‚von Hand‘ optimieren zu können – was bei anderen Frameworks wie z. B. Hibernate¹¹ nicht in diesem Maß möglich ist.

- **Model.** Das Modell bildet alle zentralen Elemente einer Folksonomie in Javaobjekten ab (siehe Abb. 5). Es bildet die Grundlage für alle weiteren Datenverarbeitungs- und Austauschprozesse innerhalb des Systems sowie für die Kommunikation mit der Außenwelt. Ein wichtiger Bestandteil ist die Definition eines XML-Schemas, welches das Format für den Datenaustausch über die REST-API festlegt. Die zentralen Elemente des Modells entsprechen den Elementen der formalen Definition einer Folksonomie aus Abschn. 2.

¹¹ <http://www.hibernate.org/>

- **RESTServer.** Implementiert die REST-API (siehe Abschn. 3). Das zentrale Element hierbei ist das `RETServlet`, das alle eingehenden API-Anfragen entgegennimmt und je nach Typ der Anfrage (z. B. GET, POST,...) sowie nach der Struktur der angefragten URL eine passende Strategie zur Bearbeitung der Anfrage auswählt. Nachdem die passenden Daten über `DatabaseLogic` geholt beziehungsweise geschrieben wurden, sendet das Servlet die Antwort an den Client zurück.
- **WebApplication.** Diese Komponente ist für die BibSonomy-Webseiten zuständig. Wie oben erwähnt, kommt an dieser Stelle das Spring-MVC-Framework zum Einsatz, das sich nahtlos in die Model-View-Controller-Architektur des gesamten Systems einfügt. Für eingehende Anfragen sind verschiedene Controller zuständig, die die angeforderten Daten (wiederum basierend auf dem definierten Datenmodell) über die `DatabaseLogic` anfragen. Diese werden dann mittels einer entsprechenden View-Komponente gerendert.
- **RESTCommon.** Enthält Funktionen, die sowohl auf Seiten des REST-Servers wie auch auf Seiten des REST-Clients benötigt werden. Hierzu gehört beispielsweise das Parsen und Serialisieren von XML-Dateien. Diese Funktion wurde mittels JAXB¹² implementiert.
- **Common.** Enthält allgemeine Hilfsfunktionen, die im gesamten System benötigt werden. Hier befinden sich unter anderem typische „Utility“-Funktionen, zum Beispiel um mit `BibTEX`-Objekten oder Zeichenketten zu arbeiten. Des Weiteren sind an dieser Stelle mehrere Konstanten definiert, auf die von allen anderen Modulen aus zugegriffen werden kann.
- **Scraper.** Extrahiert automatisch die Metadaten aus bekannten elektronischen Bibliotheksseiten. Enthält auch ein Modul zur automatischen Extraktion von Metadaten aus Text, welcher z. B. per Copy-and-Paste aus einer Webseite eingefügt werden kann. Diese Funktionalität nimmt dem Benutzer die (etwas mühsame) Aufgabe ab, alle Metadaten wie Autor, Titel, Seitenzahl, etc. zu einer Publikation manuell über ein Formular einzugeben. Stattdessen reicht ein Klick auf der entsprechenden Bibliotheksseite und das Scraper-Modul führt den jeweiligen Extraktionsvorgang automatisch aus.
- **DL-Importer.** Dient dazu, größere Metadaten-Bestände aus bekannten Bibliotheken zu importieren. Zur Zeit wird über diese Komponente der Import von DBLP¹³ abgewickelt. Um die Aktualität der Metadaten zu gewährleisten, wird dieser Import regelmäßig durchgeführt.
- **BibTEX-Parser.** `BibTEX` stellt ein zentrales Import- und Export-Format des Systems dar. Diese Komponente ist dafür zuständig, `BibTEX`-

¹² Java Architecture for XML Binding: <https://jaxb.dev.java.net/>

¹³ <http://www.informatik.uni-trier.de/ley/db/>

Einträge oder ganze BibTEX-Dateien in Java-Objekte zu parsen, um sie dann weiterverarbeiten zu können. Darüber hinaus wird dieses Modul dazu verwendet, BibTEX-Einträge auf syntaktische Korrektheit zu überprüfen.

Das Datenbankschema (Abb. 6) von BibSonomy basiert im Wesentlichen auf vier Tabellen: je eine für Lesezeichen- und Literaturbeiträge (`posts`), eine für die Schlagwort-Zuordnungen (`tas`) und eine für die Relationen (`relations`). Zwei weitere Tabellen speichern Informationen über Benutzer (`users`) und Gruppen (`groups`). Die beiden `posts`-Tabellen für Lesezeichen- beziehungsweise Literatureinträge verhalten sich sehr ähnlich (und sind daher in Abb. 6 zusammengefasst), die Literatureintrags-Tabelle hat lediglich einige zusätzliche Spalten, um die BibTEX-Felder aufzunehmen. In der Datenbank sind sie aus Gründen der Effizienz getrennt, da diese zusätzlichen Spalten nur für Publikationen gespeichert werden müssen.

Die `posts`-Tabellen sind mit der `tas`-Tabelle durch den Schlüssel `post_id` verbunden. Das Schema ist nicht normalisiert, es wurde im Gegenteil sogar viel Redundanz hinzugefügt, um Abfragen zu beschleunigen. Zum Beispiel speichern wir Gruppe, Benutzername und Datum nicht nur




Abb. 6. Beziehungsschema der wichtigsten Tabellen

in den `posts`-Tabellen, sondern auch in der `tas`-Tabelle, um bei der Anfragebearbeitung die Anzahl der benötigten Joins klein zu halten. Außerdem wurden viele Zähler materialisiert (beispielsweise die Anzahl der Einträge für eine Ressource oder die Häufigkeit der Verwendung eines Schlagwortes), und sehr viele Indizes (allein zwölf in der `tas`-Tabelle) eingefügt, um die Antwortzeiten klein zu halten.

Insgesamt verbrachten wir viel Zeit damit, das Datenbank-Schema und die SQL-Anfragen zu optimieren, und testeten beides mit Folksonomie-Daten mit bis zu 8.000.000 Einträgen. Da das System gut skaliert, benötigen wir momentan keine besondere Pufferung oder physische Verteilung der Datenbank, um angemessene Antwortzeiten zu erhalten. Eine Verteilung von Anfragen über synchronisierte Datenbanken ist mit MySQL möglich.

Ein zentraler Bestandteil des aktuellen BibSonomy-Systems ist die REST-API (Details in Abschn. 3). Ihre wesentlichen Komponenten sind der REST-Server und der REST-Client (siehe Abb. 4). Der REST-Server stellt dabei über definierte URLs den Zugriff auf die Daten von BibSonomy bereit. Die Daten werden in XML ausgegeben. Das Schema entspricht dem internen Modell und erlaubt das automatische Erzeugen von Java Objekten aus XML mittels der ‚Java Architecture for XML Binding‘, kurz JAXB.¹⁴

Semantische Funktionalitäten und Interoperabilität

Dieser Abschnitt beschreibt einige semantische Erweiterungen und Funktionen zur Integration von BibSonomy in andere Systeme, die nicht Teil des Grundsystems sind, sich aber als notwendig für die tägliche Nutzung von BibSonomy erwiesen haben.

Tag-Hierarchie

Das ‚Tagging‘ hat in den letzten zwei Jahren eine solche Popularität erlangt, weil es einfach ist und keine besonderen Fertigkeiten voraussetzt. Bei wachsender Datenmenge kommt dann jedoch schnell das Bedürfnis auf, die (eigene) Schlagwortsammlung stärker strukturieren zu können. Eine Schlagwort-Hierarchie ($\prec$ in unserem Folksonomie-Modell in Abschn. 2) ist eine einfache Möglichkeit, Tags zu ordnen.

Um das Hinzufügen von Elementen zur Relation bereits während des Verschlagwortens zu ermöglichen, wurden die Zeichenfolgen $\prec$ und $\succ$ reserviert. Wenn der Benutzer u die Folge $t_1 \succ t_2$ eingibt, ordnen wir

¹⁴ <https://jaxb.dev.java.net/>

die Tags t_1 und t_2 dem entsprechenden Eintrag zu und fügen das Tripel (u, t_1, t_2) zur Relation $\prec$ hinzu. Die Eingabe $t_2 < -t_1$ wird als $t_1 - > t_2$ ausgewertet. Dabei wird $t_1 - > t_2$ gelesen als „ t_1 ist ein t_2 “ oder „ t_1 ist ein Unterschlagwort des Schlagworts t_2 “. Es gibt auch andere Möglichkeiten, Elemente zu $\prec$ hinzuzufügen, insbesondere mit einem Relationen-Editor.

Relationen werden in verschiedenen Situationen genutzt. Erstens kann der Benutzer seine Schlagwort-Wolke strukturieren, indem er alle Unterschlagwörter eines bestimmten Schlagworts anzeigen lässt und dadurch die Schlagwörter in einer Hierarchie sehen kann. Zweitens bietet BibSonomy die Möglichkeit, auf der Schlagwort-Seite eines Benutzers nicht nur die einem Schlagwort zugeordneten Einträge anzuzeigen, sondern auch die Einträge, die einem seiner Unterschlagwörter zugeordnet wurden. Dies funktioniert auch bei der Kombination von Schlagwörtern: Für die Schlagwörter $t_1, \dots, t_n$ und einen Benutzer $u \in U$ erhält man eine Seite mit den in Gl. 5 in Abschn. 3 beschriebenen Einträgen. Weiterhin ist es möglich, die Aggregation über alle Unterschlagwörter nicht nur benutzerspezifisch, sondern über alle Benutzer im System anzeigen zu lassen. Eine Übersicht der am häufigsten verwendeten Relationen findet man auf der Seite `/relations`. Verglichen mit den in `delicio.us` erhältlichen *tag-bundles* sind Relationen in BibSonomy allgemeiner und ausdrucksstärker.

Interoperabilität mit anderen Semantic-Web-Diensten

Eines der Ziele des Semantic Web ist die Nutzung von verteilten, maschinenlesbaren und -nutzbaren Daten. Ein aktueller Schritt in diese Richtung besteht im Erstellen eines großen, verteilten Datenrepositories (Linked Data on the Web)¹⁵, welches seinerseits die Daten in verschiedensten Formaten zur Verfügung stellt. Die unterschiedlichen Datenquellen sind miteinander verlinkt und können als ein gemeinsamer großer Datensatz angesehen werden. Dieses Ziel verfolgt die W3C-Gruppe „Semantic Web Education and Outreach“. Ende Oktober 2007 bestand der Datensatz aus mehr als zwei Milliarden RDF-Tripeln.

Für den Zusammenschluss dieser heterogenen, verteilten Daten müssen die Daten in verschiedenen Formaten vom Inhaltsanbieter zur Verfügung gestellt werden, damit sowohl Menschen als auch Maschinen mit den Daten arbeiten können. Weiterhin muss der Inhaltsanbieter zwischen Menschen und Maschinen als Anfragern unterscheiden und zur Anfragezeit die Daten passend ausliefern. In BibSonomy wurden erste Schritte umgesetzt, um an der Linked Data Initiative teilnehmen zu können.

¹⁵ <http://www.w3.org/DesignIssues/LinkedData.html> und ein Tutorial unter: <http://www4.wiwiw.fu-berlin.de/bizer/pub/LinkedDataTutorial/>

BibSonomy stellt die Daten nicht nur in verschiedenen HTML-Formaten und in BibTEX zur Verfügung, sondern implementiert auch eine Reihe von RDF-Ausgabe-Formaten. Die bekanntesten Formate sind RSS, SWRC und BURST. Bei SWRC handelt es sich um eine RDF-Ausgabe passend zur SWRC-Ontologie, die in [27] definiert wurde. BURST ist eine Ontologie, die SWRC, DC und RSS zusammenfasst.¹⁶ Ausgabeformate geben nur die passenden Literaturreferenzen aus. Sie lassen sich mit allen inhaltlichen URLs kombinieren (siehe Abschn. 3). Diese Seiten können direkt zum Linked Data Repository hinzugefügt werden. Sie sind allerdings für den Menschen sehr schwer verständlich.

Die Auswahl des passenden Ausgabe-Formates ermöglicht die URL-Erweiterung `/uri/`. Sie kann mit ausgewählten BibSonomy -URLs kombiniert werden. Beim Aufruf dieser erweiterten URL wird ein Header erwartet, der das Ausgabeformat spezifiziert. Als Antwort bekommt man nicht den eigentlichen Inhalt, sondern einen Verweis auf die BibSonomy -Seite, die den Inhalt im passenden Format ausgibt, beispielsweise für den Web-Browser HTML und für eine Semantic-Web-Applikation RDF. Dieser Vorgang ist in der Literatur unter dem Begriff „Content Negotiation“ bekannt und wird über den Statuscode 303 des Web-Servers, der eine Weiterleitung auf eine andere Seite anzeigt, realisiert.

REST-API

Die Erfahrung hat gezeigt, dass eine Anwendungs-Programmier-Schnittstelle (API) entscheidend für den Erfolg eines Systems ist. Sie wurde von vielen BibSonomy-Anwendern gefordert und ermöglicht ein gutes Zusammenspiel zwischen BibSonomy und anderen Systemen. Die meisten Systeme verwenden leichtgewichtige APIs, die der Idee von REST (Representational State Transfer) [3] ähneln. Diese können auch von nicht so erfahrenen Programmierern verwendet werden, da ihre Funktionalität leicht verständlich ist. Daher wurde REST dem Standard SOAP¹⁷ vorgezogen. Für BibSonomy wurde eine REST-API implementiert. Sie ist für alle Nutzer unter `/api/` zugreifbar.

Die prinzipiellen Eigenschaften der REST-API fußen auf dem internen Datenmodell von BibSonomy, welches mittels JAXB in XML serialisiert werden kann. Fragt man Daten über die API an oder möchte neue Daten über die API in das System laden, so werden die Daten gemäß des Modells in XML abgelegt.

¹⁶ <http://www.cs.vu.nl/pmika/research/burst/BuRST.html>

¹⁷ <http://www.w3.org/TR/soap/>

Das Konzept der REST-API nutzt die typischen HTTP-Verben GET, PUT, POST und DELETE, um Aktionen auf den URLs durchzuführen. Dabei wurden für alle API-URLs entsprechende Namen gewählt. So kann man z. B. mit einem GET-Befehl unter `/api/tags` die Liste aller Schlagwörter des Systems erfragen oder mittels POST über `/api/users/[username]/posts` einen neuen Eintrag ins System einstellen. Details zur API findet man auf den Hilfeseiten.¹⁸

Für den einfachen Zugriff auf die API steht ein Java-Client zur Verfügung, der einen einfachen Zugriff auf die BibSonomy -Daten über Java-Objekte gemäß dem definierten Modell erlaubt. Als weitere Beispielanwendung der API wurde BibSonomy in die Literaturverwaltungs-Software JabRef integriert, siehe Kap. 3.

Anwendungen

Die Möglichkeiten, Literatur-Referenzen in BibSonomy zu verwalten, thematisch zu sortieren und mit Kollegen auszutauschen, werden ergänzt durch einige nützliche Erweiterungen, die wir hier kurz an Beispielen vorstellen.

Erzeugung von Publikationslisten für das Web

Die in den Abschnitten 1 und 2 diskutierten Ausgabeformate können genutzt werden, um Publikationslisten für verschiedene Zwecke zu generieren. So verschlagworten beispielsweise alle Mitglieder unserer Arbeitsgruppe ihre eigenen Publikationen mit *myown*, um ihre privaten Publikationslisten¹⁹ und die des Fachgebiets²⁰ aktuell und synchron zu halten. Auch eine persönliche Schlagwort-Wolke²¹ kann so aus BibSonomy übernommen werden.

Publikationslisten für Projekte können auf die gleiche Weise aus demselben Datenbestand generiert werden. So werden beispielsweise die Publikationslisten der Europäischen Projekte ‚Nepomuk – The Social Semantic Desktop‘²² und ‚TAGora – Emergent Semiotics in Online Social Communities‘²³ aus BibSonomy generiert. Für das Nepomuk-Projekt wird

¹⁸ <http://www.bibsonomy.org/help/doc/api.html>

¹⁹ Zum Beispiel <http://www.kde.cs.uni-kassel.de/stumme/publications.html>

²⁰ <http://www.kde.cs.uni-kassel.de/pub>

²¹ Siehe beispielsweise <http://www.kde.cs.uni-kassel.de/stumme>

²² <http://nepomuk.semanticdesktop.org/xwiki/bin/view/Main1/Publications>

²³ <http://www.tagora-project.eu/publications/>

zusätzlich der Teil des für die Europäische Kommission erforderlichen Berichtswesens, der publikationsbezogen ist, über ein zusätzlich implementiertes, projektintern erreichbares Formular abgewickelt.

Auch für Lehrveranstaltungen kann BibSonomy genutzt werden. So wurden beispielsweise für das Seminar „Online-Communities und Web 2.0“²⁴ die Literaturreferenzen unter dem Schlagwort *seminar2006* online bereit gestellt; und die Studierenden wurden aufgefordert, diese durch weitere Referenzen zu ergänzen. Auch die Publikationslisten für Vorlesungen werden auf diese Weise erstellt.²⁵

Je nach verwendetem Webserver und Content-Management-System bieten sich unterschiedliche Formen des Zugriffs auf BibSonomy an. Die oben genannten Beispiele für private und Fachgebietswebseiten laufen etwa auf einem ZOPE-System²⁶, das die Publikationslisten direkt im HTML-Format von BibSonomy importiert. Die Nepomuk-Publikations-Webseite wird durch XWiki²⁷ generiert; die Daten werden hierzu von BibSonomy als RSS-Feed übertragen. Die TAGora-Seite wird mit WordPress erstellt; auch hierfür werden die Publikationsdaten per RSS übertragen.

BibSonomy kann auch verwendet werden, um für Tagungen die Sammlung der Publikationen zu den Vorträgen navigierbar zu machen. So wurden beispielsweise für die 23. IUPAP International Conference on Statistical Physics²⁸ und für die 6. International Semantic Web Conference²⁹ alle Einträge der Tagungsbände bereits vor der Veranstaltung in BibSonomy eingeladen, auf die über speziell für die Tagung erzeugte Schlagwort-Wolken zugegriffen werden kann. Je nach Publikations-Strategie der Tagung ist auf diese Weise auch der direkte Zugriff auf Online-Proceedings denkbar.

Merklisten für Bibliotheksrecherchen und E-Learning-Anwendungen

Für die regelmäßige Arbeit mit einem Online-Bibliothekskatalog ist ein „Merkzettel“ eine hilfreiche Funktion. Der Kölner Universitäts-Gesamtkatalog³⁰ hat daher auf allen Seiten, auf denen die Treffer zu den Kataloganfragen angezeigt werden, einen Link eingerichtet, der es dem Benutzer

²⁴ http://www.kde.cs.uni-kassel.de/lehre/ss2006/online_communities

²⁵ Siehe beispielsweise <http://www.kde.cs.uni-kassel.de/lehre/ws2007-08/IR>

²⁶ <http://zope.org/>

²⁷ <http://www.xwiki.org/>

²⁸ <http://www.bibsonomy.org/events/statphys23>

²⁹ <http://www.bibsonomy.org/events/iswc2007>

³⁰ <http://kug.ub.uni-koeln.de/>

erlaubt, die gefundenen Publikationsdaten direkt in BibSonomy abzuspeichern. Dieselbe Funktionalität bietet die E-Learning-Plattform eduCampus³¹ der Universität Kassel. Umgekehrt kann man in BibSonomy durch Anklicken des Knopfes ‚OpenURL‘ hinter einem Eintrag direkt nach der entsprechenden Publikation in seiner Heimat-Bibliothek suchen, wenn diese einen OpenURL-Server betreibt und dieser auf der Seite der persönlichen Einstellungen in BibSonomy vermerkt ist.

Lokale Verwaltung von Literaturdaten mit JabRef

JabRef³² ist ein Java-Tool zum Verwalten von Literaturdaten. Es wurde eine spezielle BibSonomy-Version³³ entwickelt, die den Im- und Export von Referenzen in und aus JabRef über die API-Schnittstelle ermöglicht. Damit steht allen JabRef-Nutzern eine einfache Schnittstelle zu BibSonomy zur Verfügung, so dass sie ihre Daten sowohl lokal als auch auf dem BibSonomy-Server speichern und verwalten können. Die Literatureinträge können somit auch im Offline-Modus genutzt werden.

Wissensmanagement in Unternehmen

Die leichte Bedienbarkeit von kooperativen Verschlagwortungssystemen macht sie zu viel versprechenden Kandidaten für Wissensmanagement-Anwendungen in einem kommerziellen Umfeld, insbesondere in Bereichen, in denen sich strukturierte Intranetlösungen noch nicht etablieren konnten, oder die so schnelllebig sind, dass die regelmäßige Pflege der Bestände durch Wissensingenieure zu kostspielig ist. Dies trifft insbesondere auf Anwendungen zu, die von Wissensmodellierungslaien bedient werden müssen. Da Intranet-Inhalte häufig aus Office-Dokumenten bestehen, die in der Regel keine Navigation zu verwandten Inhalten ermöglichen, können Folksonomien hier als Mittel zur Strukturierung helfen. Diese Vorteile in Bezug auf die Erstellung und insbesondere Wartung von Wissensmanagement-Systemen im Intranet haben auch große Firmen erkannt. So erwägt z. B. IBM die Benutzung von Folksonomien im Intranet, und auch [18] diskutiert eine solche Anwendung.

Aus demselben Grund haben wir in einem Industrieprojekt einen auf BibSonomy basierenden Prototyp entwickelt. Die gemeinsame Anmeldung an BibSonomy und das im Unternehmen eingesetzte SAP-Portal erfolgt

³¹ <http://educampus.uni-kassel.de/>

³² <http://jabref.sourceforge.net/>

³³ <http://www.bibsonomy.org/help/doc/jabrefclient.html>

per Single-Sign-On. Für den internationalen Einsatz wurde BibSonomy um die Möglichkeit erweitert, die Inhalte in verschiedenen Sprachen anzubieten. Zur Erhöhung der Akzeptanz wurde darüber hinaus eine automatische Validierung der Links aller vorhandenen Lesezeichen eines Benutzers implementiert und es wurden integrierte Bookmarklets zur Unterstützung der Navigation über die Systemgrenzen hinweg erstellt. Um Nutzer des Intranets auf den neuen Dienst aufmerksam zu machen, wurde in jede Seite des Intranets ein Link zum automatischen Speichern der Seite in BibSonomy integriert. Mit Hilfe der iViews-Funktionalität des SAP-Portals werden darüber hinaus die Top-5-Schlagwörter eines Nutzers sowie die letzten fünf von ihm eingestellten Einträge angezeigt. Ziel ist auch hier, die Sichtbarkeit und den Austausch von Informationen im Portal zu erhöhen.

Datenanalyse, Information Retrieval und Wissensentdeckung

Ein wesentlicher Grund für uns, BibSonomy zu entwickeln und zu betreiben, ist, dass das System praxisrelevante Fragestellungen der Wissensverarbeitung im Web 2.0 aufzeigt und gleichzeitig Möglichkeiten zu deren Evaluierung bietet. Wir haben in den letzten beiden Jahren verschiedene Fragestellungen aus den Bereichen Datenanalyse, Information Retrieval und Wissensentdeckung auf kooperative Verschlagwortungssysteme übertragen und bearbeitet. In diesem Kapitel stellen wir in Kürze die Ansätze vor, die auf Daten von BibSonomy angewandt wurden oder bereits in das System integriert sind. Für Details verweisen wir auf die jeweiligen Referenzen.

Zu allen Ansätzen gibt es verwandte – aber nicht auf BibSonomy bezogene – Forschungsarbeiten. Es würde jedoch zu weit führen, diese hier zu diskutieren. Die jeweils zitierten Arbeiten beinhalten entsprechende weiterführende Übersichten. Publikationen über kooperative Verschlagwortungssysteme sind auch in BibSonomy unter dem Schlagwort *folksonomies*³⁴ zu finden.

Analyse der Folksonomie-Struktur

Analysen der Netzwerkeigenschaften der Folksonomie von BibSonomy [2, 24] haben gezeigt, dass sie die so genannten *Small-World*-Eigenschaften aufweist: ein kleiner Graph-Durchmesser (d.h. die Pfade zwischen je zwei Einträgen sind im Mittel kurz) und ein hoher Clustering-Koeffizient. Dies bedeutet, dass es zum einen thematische Gruppierungen

³⁴ <http://www.bibsonomy.org/tag/folksonomies>




Abb. 7. Kumulierte Häufigkeiten der Nutzer, Schlagwörter und Ressourcen in BibSonomy. Auf der x -Achse ist die Anzahl d der Schlagwortzuweisungen (tag assignments) abgetragen, und auf der y -Achse die relative Häufigkeit der Nutzer resp. Schlagwörter resp. Ressourcen, die in mehr als d Zuweisungen auftreten. Beide Achsen sind logarithmisch skaliert

der Einträge gibt, dass zum anderen aber eine erkundende Navigation durch das System sehr effizient ist, da man mit nur wenigen Clicks von einem Thema zu jedem anderen kommt. Dass die implizite Semantik der Schlagwörter einen strukturierenden Einfluss auf die Folksonomie hat, konnte durch eine Analyse der Gewichtsverteilungen im Schlagwort-Nachbarschaftsgraphen nachgewiesen werden.

Abbildung 7 zeigt darüber hinaus, dass die Häufigkeiten der Nutzer, Schlagwörter und Ressourcen in BibSonomy extrem schief verteilt sind: Einige wenige Elemente (Nutzer/Schlagwörter/Ressourcen) sind sehr stark vernetzt, fast alle Elemente jedoch sehr schwach. Damit hat BibSonomy (wie auch andere Folksonomies, siehe etwa [8, 2]) eine Struktur, die auch typisch ist für andere Netze, die aus sozialen Aktivitäten entstehen.

Ranking von Suchergebnissen

Die meisten kooperativen Verschlagwortungssysteme sortieren ihre Trefferlisten in umgekehrt chronologischer Reihenfolge: Einträge, die zuletzt

eingestellt wurden, werden am weitesten oben gelistet. Del.icio.us bietet darüber hinaus ein Ranking an, bei dem die Einträge, die in der letzten Zeit am häufigsten eingestellt wurden, die Liste anführen.

In [8] haben wir den relevanzbasierten FolkRank-Algorithmus vorgestellt. Ein Eintrag wird als relevant betrachtet, wenn er von vielen relevanten Nutzern mit vielen relevanten Schlagwörtern versehen wurde. Die Definition der Relevanz von Nutzern und Schlagwörtern erfolgt rekursiv auf die gleiche Weise. Diese Anpassung des von Google bekannten, auf Eigenvektor-Zentralität basierenden PageRank-Algorithmus [1] auf Folksonomies erlaubt es, für eine gegebene Anwenderpräferenz in einem Schritt ein Ranking für Schlagwörter, Anwender und Ressourcen zu erstellen. Das Verfahren ist in BibSonomy für die Schlagwort-Seiten implementiert.³⁵

Entdeckung von Communities

Neben organisatorischen Gruppen entstehen in kooperativen Verschlagwortungssystemen thematische Gruppen (Communities of Interest). Eine Identifikation solcher Gruppen böte die Möglichkeit, themenspezifisch auf andere Nutzer zu verweisen und so die Navigation durch das System zu lenken oder auf spannende Inhalte aufmerksam zu machen. Gruppen werden in der Regel automatisch mittels Clusterverfahren identifiziert, die aber in diesem Fall auf die spezielle Struktur der Daten angepasst werden müssen.

Ein Ansatz hierzu ist eine triadische Variante [15] der Formalen Begriffsanalyse [5]. In [9] haben wir TRIAS, eine triadische Version des Next-Closure-Algorithmus [4, 13], vorgestellt, der es ermöglicht, Gruppen von Benutzern zu bestimmen, die alle dieselben Ressourcen mit denselben Schlagwörtern verschlagwortet haben. Wir haben die BibSonomy-Publikationsdaten mit dem TRIAS-Algorithmus analysiert [10]. Der Datensatz enthält alle Publikationen, die bis zum 26. November 2006 eingegeben wurden. Ausgenommen wurden die Einträge der DBLP Computer Science Bibliography,³⁶ die von BibSonomy gespiegelt wird. Analysiert wurden so Daten von 262 Nutzern, die 11.101 Publikationen mit 5.954 verschiedenen Schlagwörtern versehen haben.³⁷

Ein *Tri-Begriff* besteht aus einer Menge A von Benutzern, einer Menge B von Schlagwörtern und einer Menge C von Ressourcen, so dass jeder Benutzer aus A jede Ressource aus C mit jedem Schlagwort aus B versehen hat und keine der drei Mengen vergrößert werden kann, ohne diese

³⁵ Siehe beispielsweise <http://www.bibsonomy.org/tag/ontology?order=folkrank>

³⁶ <http://www.informatik.uni-trier.de/ley/db/>

³⁷ BibSonomy-Benchmark-Datensätze sind für wissenschaftliche Zwecke auf Anfrage erhältlich, siehe <http://www.bibsonomy.org/faq>

Bedingung zu verletzen. In den Publikationsdaten finden sich insgesamt 13.992 solche Tri-Begriffe. Abbildung 8 zeigt alle 21 Tri-Begriffe der BibSonomy-Publikationsdaten mit mindestens drei Nutzern, zwei Schlagwörtern und zwei Ressourcen. Die Publikationstitel wurden aus Platzgründen durch Nummern ersetzt und können unter http://www.bibsonomy.org/group/kde/trias_example nachgeschlagen werden; sie sind in lexikographischer Ordnung der Titel nummeriert.

Die 21 Punkte in der Mitte des Diagramms repräsentieren die 21 häufigen Tri-Begriffe. Die Mengen von Nutzern, Schlagwörtern und Ressourcen, die jeweils einen Tri-Begriff konstituieren, können an den drei Seiten des Diagramms abgelesen werden. Ein Knoten in einer der drei Hierar-




Abb. 8. Die häufigen Tri-Begriffe in den BibSonomy-Publikationsdaten

chien beinhaltet immer alle Nutzer, Schlagwörter bzw. Ressourcen, die direkt an ihm dran stehen, sowie die, die im Sinne der Pfeilrichtung unter ihm liegen. Dies bedeutet beispielsweise in der Schlagworthierarchie, dass der äußerste rechte Knoten neben den Schlagwörtern *ai*, ..., *tags* auch das Schlagwort *social* enthält. Ein Tri-Begriff ist durch seine drei Projektionen eindeutig identifiziert. So repräsentiert zum Beispiel der unterste Punkt im Inneren des Diagramms den Tri-Begriff, der aus der Menge $\{jaeschke, schmitz, stumme\}$ von Nutzern, der Menge $\{fca, triadic\}$ von Schlagwörtern und der Menge $\{1, 37\}$ von Ressourcen (d. h. [26, 9]) besteht.

Die Schlagworthierarchie gibt einen Hinweis auf die zentralen Themen, die im November 2006 durch die Publikationssammlung in BibSonomy abgedeckt wurde. (Inzwischen hat sich die Anzahl der Einträge versechsfacht und thematisch verbreitert.) Das Schlagwort *social* tritt am häufigsten mit anderen Schlagwörtern auf. Dieses Schlagwort wurde zusammen mit den Schlagwörtern *ai* [= Artificial Intelligence], ..., *tags* durch die Benutzer *lkl_kss* und *yish* den Publikationen 19 und 30 [22, 21] zugeordnet, zusammen mit dem Schlagwort *bookmarking* durch die Benutzer *hotho*, *jaeschke*, *stumme* den Publikationen 4 und 28 [7, 6] zugeordnet, und wieder zusammen mit dem Schlagwort *bookmarking* durch die Benutzer *brotkasting*, *jaeschke*, *stumme* den Publikationen 28 und 29 [6, 16] zugewiesen. Dies deutet darauf hin, dass $\{lkl_kss, yish\}$ und $\{brotkasting, hotho, jaeschke, stumme\}$ zwei Communities of Interest bilden, die sich beide mit sozialen Phänomenen im Web 2.0 beschäftigen, aber mit unterschiedlicher Ausrichtung. Eine zweite Gruppe von Themen wird durch das Schlagwort *semantic* aufgespannt, welches in drei verschiedenen Zusammenhängen auftritt: semantische Wikis, Semantic Web Mining und im Zusammenhang mit Folksonomien.

Eine detaillierte Analyse dieses Datensatzes ist in [10] beschrieben.

Empfehlungen von Schlagwörtern

Die häufigste Anwendung von Recommendern im Social Bookmarking ist die Empfehlung von Schlagwörtern für aktuell abzuspeichernde Webseiten. Solche Systeme schlagen dem Benutzer meistens mehrere Schlagwörter vor. In BibSonomy ist derzeit ein erster Collaborative-Filtering-Ansatz eingebaut, basierend auf [25]. In [11] haben wir den FolkRank-Algorithmus für die Vorhersage von Schlagwörtern analysiert. Wir konnten empirisch eine deutliche Verbesserung der Performanz (gemessen in Precision und Recall) gegenüber inhaltsbasierten und CF-Ansätzen nachweisen. Dieselbe Güte wird außerdem (fast) durch eine Kombination von Nutzer- und Ressourcen-basierten Vorschlägen erreicht, die gegenüber dem Folk-

Rank-Algorithmus den Vorteil einer geringeren Komplexität zur Laufzeit hat. Die Implementierung dieses Ansatzes in BibSonomy ist geplant.

Ausblick

Mit der Kombination von Lesezeichen und Literaturreferenzen ist BibSonomy als Unterstützung für die tägliche Arbeit von Wissenschaftlern konzipiert, da diese typischerweise eine große Menge von Informationsquellen organisieren müssen. Wenn kooperative Verschlagwortungssysteme wie BibSonomy wachsen, muss die Benutzerunterstützung über einfache Funktionalitäten wie beispielsweise Volltextsuche hinausgehen. Dies bedingt eine verbesserte Organisation der Daten. Ein offensichtlicher Ansatz hierfür sind Technologien des Semantic Web. Die entscheidende Frage bleibt jedoch, wie man deren Vorteile nutzt, ohne ungeübte Benutzer mit dem Formalismus zu behelligen. Wir sind sicher, dass dieses Thema ein fruchtbares Forschungsgebiet für die Semantic Web-Community in den kommenden Jahren ist.

Danksagung

Die Entwicklung von BibSonomy wurde teilweise durch die Projekte „Nepomuk – the Social Semantic Desktop“ (FP6-027705) und „TAGora – Emergent Semiotics in Online Social Communities“ (FP6-IST5-34721) der Europäischen Kommission sowie dem durch Microsoft Research finanzierten Projekt „Social Search: Bringing the Social Component to the Web“ finanziert.

Literatur

1. Sergey Brin and Lawrence Page. The Anatomy of a Large-Scale Hypertextual Web Search Engine. *Computer Networks and ISDN Systems*, 30(1–7):107–117, April 1998.
2. Ciro Catutto, Christoph Schmitz, Andrea Baldassarri, Vito D. P. Servedio, Vittorio Loreto, Andreas Hotho, Miranda Grahl, and Gerd Stumme. Network properties of folksonomies. *AI Communications Journal*, Special Issue on "Network Analysis in Natural Sciences and Engineering" (im Druck), 2007.
3. Roy T. Fielding. Architectural Styles and the Design of Network-based Software Architectures. PhD thesis, University of California, Irvine, 2000.
4. B. Ganter. Algorithmen zur Formalen Begriffsanalyse. In B. Ganter, R. Wille, and K. E. Wolff, editors, *Beiträge zur Begriffsanalyse*, pages 241–254. B.I.Wissenschaftsverlag, 1987.

5. Bernhard Ganter and Rudolf Wille. *Formale Begriffsanalyse: Mathematische Grundlagen*. Springer, Heidelberg, 1996.
6. Tony Hammond, Timo Hannay, Ben Lund, and Joanna Scott. Social Bookmarking Tools (I): A General Review. *D-Lib Magazine*, 11(4), April 2005.
7. Andreas Hotho, Robert Jäschke, Christoph Schmitz, and Gerd Stumme. BibSonomy: A social bookmark and publication sharing system. In *Proceedings of the Conceptual Structures Tool Interoperability Workshop at the 14th International Conference on Conceptual Structures*, pages 87–102, 2006.
8. Andreas Hotho, Robert Jäschke, Christoph Schmitz, and Gerd Stumme. Information retrieval in folksonomies: Search and ranking. In York Sure and John Domingue, editors, *The Semantic Web: Research and Applications*, volume 4011 of *LNAI*, pages 411–426, Heidelberg, June 2006. Springer.
9. Robert Jäschke, Andreas Hotho, Christoph Schmitz, Bernhard Ganter, and Gerd Stumme. Trias – an algorithm for mining iceberg tri-lattices. In *Proceedings of the 6th IEEE International Conference on Data Mining (ICDM 06)*, pages 907–911, Hong Kong, December 2006. IEEE Computer Society.
10. Robert Jäschke, Andreas Hotho, Christoph Schmitz, Bernhard Ganter, and Gerd Stumme. Discovering shared conceptualizations in folksonomies. *Journal of Web Semantics*, 2008 (to appear).
11. Robert Jäschke, Leandro Balby Marinho, Andreas Hotho, Lars Schmidt-Thieme, and Gerd Stumme. Tag recommendations in folksonomies. In Joost N. Kok, Jacek Koronacki, Ramon López de Mántaras, Stan Matwin, Dunja Mladenic, and Andrzej Skowron, editors, *Knowledge Discovery in Databases: PKDD 2007, 11th European Conference on Principles and Practice of Knowledge Discovery in Databases*, volume 4702 of *Lecture Notes in Computer Science*, pages 506–514, Berlin, Heidelberg, 2007. Springer.
12. G. E. Krasner and S. T. Pope. A cookbook for using the model-view controller user interface paradigm in Smalltalk-80. *Journal of Object Oriented Programming*, 1(3):26–49, 1988.
13. S. Krolak-Schwerdt, P. Orlik, and B. Ganter. TRIPAT: a model for analyzing three-mode binary data. In H. H. Bock, W. Lenski, and M. M. Richter, editors, *Studies in Classification, Data Analysis, and Knowledge Organization*, volume 4 of *Information systems and data analysis*, pages 298–307. Springer, Berlin, 1994.
14. Leslie Lamport. *LaTeX: A Document Preparation System*. Addison-Wesley, 1986.
15. F. Lehmann and R. Wille. A triadic approach to formal concept analysis. In G. Ellis, R. Levinson, W. Rich, and J. F. Sowa, editors, *Conceptual structures: applications, implementation and theory*, volume 954 of *Lecture Notes in Artificial Intelligence*, pages 32–43. Springer Verlag, 1995.
16. Ben Lund, Tony Hammond, Martin Flack, and Timo Hannay. Social Bookmarking Tools (II): A Case Study – Connotea. *D-Lib Magazine*, 11(4), April 2005.
17. Andrew Kachites McCallum. *MALLET: A Machine Learning for Language Toolkit*. <http://mallet.cs.umass.edu>, 2002.
18. David R. Millen, Jonathan Feinberg, and Bernard Kerr. Dogear: Social bookmarking in the enterprise. In *CHI '06: Proceedings of the SIGCHI conference*

-
- on Human Factors in computing systems, pages 111–120, New York, NY, USA, 2006. ACM Press.
19. Oren Patashnik. BibTeXing, 1988. (Included in the BIBTEX distribution).
 20. Fuchun Peng and Andrew McCallum. Accurate information extraction from research papers using conditional random fields. In HLT-NAACL, pages 329–336, 2004.
 21. Vitorino Ramos, Carlos Fernandes, and Agostinho C. Rosa. Social cognitive maps, swarm collective perception and distributed search on dynamic landscapes. 2005.
 22. Vitorino Ramos, Carlos Fernandes, and Agostinho C. Rosa. On self-regulated swarms, societal memory, speed and dynamics. 2006.
 23. Katharina Regulski. Aufwand und Nutzen beim Einsatz von Social Bookmarking Services als Nachweisinstrument für wissenschaftliche Forschungsartikel am Beispiel von BibSonomy. <http://www.bibliothek-saur.de/preprint/2007/ar2460regulski.pdf>, 2007.
 24. Elizeu Santos-Neto, Matei Ripeanu, and Adriana Iamnitchi. Tracking user attention in collaborative tagging communities, 2007.
 25. Badrul M. Sarwar, George Karypis, Joseph A. Konstan, and John Riedl. Item-based collaborative filtering recommendation algorithms. In Proceedings of the 10th International WWW Conference, pages 285–295, 2001.
 26. Gerd Stumme. A finite state model for on-line analytical processing in triadic contexts. In Bernhard Ganter and Robert Godin, editors, Proceedings of the 3rd International Conference on Formal Concept Analysis, volume 3403 of Lecture Notes in Computer Science, pages 315–328. Springer, 2005.
 27. York Sure, Stephan Bloehdorn, Peter Haase, Jens Hartmann, and Daniel Oberle. The SWRC ontology – semantic web for research communities. In Carlos Bento, Amílcar Cardoso, and Gael Dias, editors, Proceedings of the 12th Portuguese Conference on Artificial Intelligence – Progress in Artificial Intelligence (EPIA 2005), volume 3803 of LNCS, pages 218–231, Covilha, Portugal, DEC 2005. Springer.

19. Semantic Wikipedia

Markus Krötzsch und Denny Vrandečić

Institut AIFB, Universität Karlsruhe (TH);
{kroetzsch; vrandecic}@aifb.uni-karlsruhe.de

Zusammenfassung: Wir stellen eine Erweiterung der klassischen Wiki-Software *MediaWiki* vor, mit der man Inhalte auf einfache Art und Weise mit semantischen Attributen und Beziehungen anreichern kann. Dies ermöglicht es einem weiten Kreis von Wikipedia-Nutzern, gemeinschaftlich eine semantische Wissensbasis aufzubauen, die im Hinblick auf Größe, Umfang, Dynamik, Offenheit und Reichweite einzigartig wäre. Die semantischen Erweiterungen bergen zahlreiche Vorteile für Wikipedia und andere große Wikis: Sie erlauben die automatische Kontrolle der Konsistenz und Vollständigkeit des Wikis, und sie eröffnen neuartige Möglichkeiten zur Suche nach Informationen und zum Browsen von Inhalten. Ein standardkonformer RDF-Export ermöglicht es darüberhinaus, Wissen aus Wikipedia auch in externen Anwendungen mit geringem Aufwand wiederzuverwenden.

Einführung

Wikis haben sich in den letzten Jahren zu bedeutenden Werkzeugen für die gemeinschaftliche, web-basierte Zusammenarbeit an Texten entwickelt. Sowohl im World Wide Web als auch in zahlreichen Intranets moderner Unternehmen werden Wikis mit Erfolg eingesetzt. Die Hauptziele der meisten Wikis, ob öffentlich zugänglich oder nicht, bestehen in der Sammlung, Organisation und Verbreitung relevanten Wissens. Für die Eingabe von Informationen verwenden die meisten heutigen Wikis eine einfache Auszeichnungssprache, oft als *Wikitext* bezeichnet, die eine verhältnismäßig einfache Eingabe wichtiger Formatierungen erlaubt, ohne tiefere Kenntnisse aktueller Web-Standards wie XHTML oder CSS vorauszusetzen.

Die freie Enzyklopädie *Wikipedia*, welche komplett auf der freiwilligen Mitarbeit einer offenen Gemeinschaft tausender Autoren basiert, ist sicherlich die zurzeit bekannteste Anwendung von Wikis im WWW. Wikipedia ist inzwischen die weltweit größte Quelle enzyklopädischen Wissens und

eine der am meisten aufgerufenen Webseiten überhaupt. Doch obwohl Wikipedia bereits eine wertvolle Informationsquelle darstellt, sind ihre Inhalte nur schwer in externen Anwendungen wiederverwendbar und kaum maschinenverständlich. Wikipedia zu *nutzen* bedeutet heute Artikel zu *lesen*. Die damit einhergehenden Einschränkungen werden offensichtlich, wenn Informationen aus vielen Artikeln zusammengeführt werden sollen. Um etwa die Liste aller Filme aus den 60er Jahren mit einem italienischen Regisseur zu ermitteln, müsste man zunächst die Artikel aller Filme und deren Regisseure lesen. Obwohl die Daten weitgehend strukturiert sind – jeder Film hat einen Artikel, es gibt Links zwischen den Regisseuren, den Filmen und den Jahreszahlen – ist die Bedeutung dieser Struktur nur implizit und für den Computer verschlossen.

Semantic MediaWiki (SMW) [13] ist eine semantische Erweiterung des MediaWiki-Systems, die es Benutzern erlaubt, Inhalte des Wikis mit expliziten, maschinenverständlichen Informationen zu annotieren. Mit diesen semantischen Daten kann SMW wichtigste Probleme heutiger Wikis in Angriff nehmen:

- *Konsistenz der Inhalte:* Die gleiche Information taucht oft auf vielen verschiedenen Seiten auf. Wie kann man die Konsistenz dieser Informationen sichern, insbesondere unter Berücksichtigung der verteilten und wenig kontrollierten Bearbeitung?
- *Zugriff auf Wissen:* Große Wikis haben Tausende von Seiten. Das Zusammentragen und Vergleichen von Informationen von vielen verschiedenen Seiten ist zeitaufwändig und schwierig.
- *Wissen wiederverwenden:* Viele Wikis entstanden aus dem Wunsch heraus, Informationen vielen Benutzern zugänglich zu machen. Aber der starre, text-basierte Inhalt klassischer Wikis ist nur durch das Lesen der Seiten in einem Browser oder einer ähnlichen Anwendung zugänglich.

SMW ist freie Software und Erweiterung für das beliebte Wikisystem MediaWiki. Abbildung 1 gibt einen Überblick über die Kernbestandteile von SMW, die wir in diesem Kapitel genauer beleuchten werden. Die Integration von MediaWiki und SMW beruht auf dem Erweiterungsmechanismus von MediaWiki: SMW registriert Funktionen für bestimmte Ereignisse, und MediaWiki lädt anschließend die jeweils nötigen Module und ruft sie bei Bedarf auf. SMW ist somit völlig modular, und kann auch auf bereits existierenden MediaWiki-Installationen ohne wesentliche Migrationskosten eingesetzt werden. Weitere Informationen, Hinweise zur Installation, sowie eine vollständige Dokumentation finden sich auf der Webseite von SMW (bislang nur in englischer Sprache).¹

¹ <http://ontoworld.org/wiki/SMW>




Abb. 1. Architektur von SMWs Hauptkomponenten und ihr Zusammenspiel mit MediaWiki

Der nächste Abschnitt beschreibt, wie Annotationen in SMW eingetragen und gesammelt werden und wie diese Annotationen sich auf die OWL DL Ontologiesprache abbilden. Abschnitt 3 beschreibt die wichtigsten Vorteile von SMW für den Wikinutzer: Semantisches Browsing, Anfragen an das Wissen im Wiki, und der Wissensaustausch mit dem Semantic Web. Anfragen sind das mächtigste Mittel um auf semantische Informationen in SMW zuzugreifen, und ihre Syntax und Semantik werden ausführlich beschrieben. Der praktische Einsatz von SMW wird in Abschn. 4 dargestellt. Wir beschreiben die Verwendung struktureller Möglichkeiten in der heutigen Wikipedia, diskutieren Benutzerdaten eines mittelgroßen semantischen Wikis, und betrachten typische aktuelle Verwendungen von SMW. Abschnitt 5 behandelt Geschwindigkeitsmessungen einer SMW-Installation, und vergleicht zudem die Geschwindigkeit von SMWs Anfragebeantwortung mit verschiedenen RDF-Speichern. Schließlich vergleichen wir SMW mit verwandten Systemen (Abschn. 6) und enden mit einer kurzen Zusammenfassung und einem Ausblick auf die weitere Arbeit. Die Systembeschreibungen beziehen sich auf die beim Schreiben dieses Kapitels aktuelle Version SMW 1.0.

Annotation von Seiten im Wiki

Die wichtigste Voraussetzung für den Einsatz semantischer Technologien ist die Verfügbarkeit strukturierter („semantischer“) Daten. Um diese be-

reitzustellen, erlaubt SMW, strukturelle Daten durch *Annotationen* bestehender Textinhalte in ein Wiki einzufügen. In diesem Abschnitt geben wir einen Überblick der bestehenden Möglichkeiten von MediaWiki, Daten zu strukturieren, und führen die SMW-spezifischen Annotationen mit Attributen ein. Schließlich stellen wir die formale semantische Interpretation dieser Strukturen im Wiki vor und bilden die auf OWL DL ab.

Die grundlegende Strukturierungsmöglichkeit in den meisten Wikis ist die Aufteilung des Inhalts auf Seiten des Wikis. In MediaWiki sind verschiedene Arten von Seiten weiterhin entsprechend ihrer Funktion auf verschiedene Namensräume aufgeteilt. Namensräume können nicht durch die Benutzer des Wikis definiert werden, sondern werden durch das installierte Wikisystem definiert. Der Namensraum einer Seite wird als Präfix zum Titel der Seite angezeigt, getrennt durch einen Doppelpunkt. Die persönlichen Seiten angemeldeter Nutzer z. B. werden durch das Präfix „Benutzer:“ von anderen Inhalten unterschieden. „Hilfe:“ bezeichnet Dokumentationsseiten des Wikis, und Diskussionsseiten werden durch Namensräume der Form „... Diskussion:“ ausgezeichnet. Titel ohne einen registrierten Namensraum gehören zum Hauptnamensraum, in dem sich auch der eigentliche Inhalt des Wikis befindet. Die meisten Seiten werden auf gleiche Weise erstellt und bearbeitet – die entsprechende Komponente ist in Abb. 1 als *page display and manipulation* bezeichnet. Die wichtigste Ausnahme sind so genannte *Spezialseiten* mit dem Präfix „Spezial:“, die vordefinierte Schnittstellen zu Abfragen und zu weiterer Funktionalität innerhalb des Wikis anbieten, und nicht wie andere Seiten bearbeitet werden können.

Den grundlegenden Prinzipien MediaWikis folgend, werden auch in SMWs zusätzliche semantische Daten an einzelne Seiten gebunden und durch die Aufteilung auf Seiten strukturiert. Semantisch gesehen beschreibt jede Seite ein ontologisches Element (einschließlich Klassen und Properties), welches durch weitere Annotationen auf eben dieser Seite beschrieben werden kann. Diese Bindung von Wissen an einzelne Seiten ist entscheidend für die Wartung der Inhalte: Auch wenn semantische Informationen auf vielen verschiedenen Seiten wiederverwendet werden können, müssen Benutzer stets nachvollziehen können, wo eine bestimmte Annotation eingegeben wurde, um sie eventuell korrigieren oder erweitern zu können. Verschiedene Namensräume werden dafür verwendet, verschiedene semantische Rollen der Wikiseiten zu unterscheiden. Dadurch werden Seiten unterteilt in einfache *Individuen* (Elemente der gegebenen Anwendungsdomäne und üblicherweise der Großteil der Seiten), *Kategorien* (Klassen zur Einordnung der Individuen, die hierarchisch geordnet sein können), *Attribute*² (Properties zur Beschreibung der Beziehungen

² Die Bezeichnung „Attribut“ wurde in der deutschen Übersetzung von SMW anstelle des Begriffs „Property“ aus der englischen Version gewählt.

einer Seite mit einer anderen Seite oder einem Datenwert) und *Typen* (Datentypen zur Unterscheidung verschiedener Arten von Attributen, wie in Abschn. 2 erklärt). Kategorien wurden in MediaWiki 2002 eingeführt, während Attribute und Typen durch SMW eingeführt werden.

In den folgenden Abschnitten beschreiben wir zunächst die bereits verfügbaren Strukturierungsmöglichkeiten in MediaWiki, und anschließend die neu eingeführten Annotationen in SMW. Abschnitt 3 schließlich definiert die Abbildung der SMW-Strukturen auf die OWL Ontologiesprache, die in SMW zum Exportieren von Informationen verwendet wird.

Strukturieren von Inhalten in MediaWiki

Die wichtigste Art der Informationseingabe in MediaWiki ist *Wikitext*, eine einfache Auszeichnungssprache, die durch MediaWiki in XHTML-Seiten übersetzt wird. Wikitext verfügt über zahlreiche Möglichkeiten, Texte zu formatieren und zum Teil auch zu strukturieren. Um die Beziehungen zwischen Seiten herzustellen, sind *Hyperlinks* sicher der wichtigste Mechanismus. Sie dienen der Navigation und werden vereinzelt sogar zur impliziten Klassifikation verwendet. Die englische Wikipedia z. B. verwendet Links wie „*As of 2005*“ um anzuzeigen, dass eine bestimmte Information (etwa eine Bevölkerungszahl) nach dem Jahr 2005 überholt sein könnte und überprüft werden muss. Durch die Spezialseite „Linkliste“ können alle Seiten gefunden werden, die einen solchen Link aufweisen.

Viele Wikis verwenden Links zum Klassifizieren von Seiten. Um etwa alle Seiten über Frankreich zu finden, sucht man einfach nach allen Seiten die auf „Frankreich“ verweisen. In MediaWiki wurde diese Lösung durch ein *Kategoriensystem* ersetzt. Jede Seite kann einer oder mehreren Kategorien zugeordnet werden, und jede Kategorie wird durch eine Seite im Namensraum „Kategorie:“ repräsentiert. Diese Kategorienseiten können dann zum Browsen der kategorisierten Seiten verwendet werden, aber auch um Kategorien hierarchisch zu organisieren. Sowohl die Kategorisierung einzelner Seiten als auch die Hierarchie der Kategorien kann von allen Benutzern durch entsprechende Auszeichnungen im Text erweitert, verändert und gewartet werden. Diesem Kategoriensystem ähneln auch die von SMW eingeführten Erweiterungen am meisten.

Ein weiteres Problem in vielen Wikis sind synonyme und homonyme Titel. Synonyme bedeuten hierbei, dass durch den verteilten und unkontrollierten Bearbeitungsprozess verschiedene Seiten zum selben Thema entstehen können (etwa „EU“ und „Europäische Union“). MediaWiki verfügt deswegen über ein *Weiterleitungs-System*, bei dem Anfragen an eine Seite auf eine andere weitergeleitet werden. Homonyme hingegen entstehen, wenn ein Titel mehrdeutig ist und verschiedene Themen bezeichnen

kann. Dieses Problem wird durch so genannte *Begriffsklärungsseiten* gelöst, welche die verschiedenen möglichen Bedeutungen eines Titels anzeigen. Häufig wird die entsprechende Bedeutung durch einen eingeklammerten Zusatz im Titel eindeutig, z. B. „Europa (Griechische Mythologie)“.

MediaWikis *Vorlagensystem* dient in erster Linie der Formatierung, hat aber auch strukturelle Bedeutung. Textbausteine können als Vorlagen mit einem eigenen Titel im Wiki abgelegt und anschließend auf anderen Seiten wiederverwendet werden. Vorlagen können auch parametrisiert sein, so dass bestimmte Teile des Vorlagentextes erst bei Verwendung der Vorlage als Parameter bestimmt werden. Dadurch kann eine höhere optische Konsistenz in einem Wiki erreicht werden, weil z. B. die Formatierung von Tabellen mit einheitlichen Vorlagen erfolgt und nur die Inhalte von Seite zu Seite variieren. Die Idee, semantische Daten mit Hilfe von Vorlagen einzufangen wurde schon innerhalb von Wikipedia umgesetzt, etwa beim Personendaten-Projekt³, und auch außerhalb von Wikipedia aufgegriffen [3].

Zusätzlich zu den genannten Ausdrucksmitteln verfügt MediaWiki über zahlreiche Möglichkeiten, den Inhalt einzelner Seiten zu strukturieren, etwa durch Tabellen, Überschriften und Grafiken. SMW hingegen sammelt in erster Linie Informationen über das Thema einer Seite, nicht über deren Text. Das Layout und die Struktur der Seite folgen normalerweise didaktischen Regeln, und erlauben wenige Rückschlüsse über den Inhalt einer Seite. Gleichfalls ist es in Wikipedia üblich, für wichtige Unterthemen eigene Seiten anzulegen, und SMW bezieht Annotationen daher grundsätzlich auf ganze Seiten und nicht auf einzelne Textabschnitte.

Semantische Annotationen in SMW

SMW sammelt semantische Daten, indem es den Benutzern ermöglicht, Annotationen explizit im Wikitext einer Seite durch besondere Auszeichnungen hinzuzufügen, welche durch den Parser und den Renderer bearbeitet werden (vgl. Abb. 1). Während diese Annotationen die wichtigste und sichtbarste Änderung am Editierprozess im Wiki darstellen, sind sie doch nur ein kleinerer Teil des SMW-Systems. Der zugrunde liegende konzeptionelle Rahmen, basierend auf *Attributen* und *Typen*, ist letztlich wichtiger als die konkrete Eingabesyntax.

In SMW beschreiben Attribute binäre Beziehungen zwischen einem semantischen Element (das durch eine Wikiseite repräsentiert wird) und einem zweiten solchen Element oder Datenwert. In jedem Wiki werden sich Benutzer natürlich für andere Attribute interessieren, abhängig vom Themenbereich des Wikis. Daher erlaubt SMW den Benutzern die verfü-

³ <http://de.wikipedia.org/wiki/Hilfe:Personendaten>

baren Attribute selbst zu erstellen, zu pflegen und zu benutzen. Das Attributssystem folgt dabei standardisierten Semantic-Web-Formalismen, in denen binäre Relationen das zentrale Mittel zur Beschreibung von Informationen sind. Doch im Gegensatz zu Formalismen wie RDF [11] betrachtet SMW nicht die einzelnen Annotationen (wie etwa RDF-Tripel aus Subjekt, Prädikat und Objekt) als die grundlegende Informationseinheit, sondern hat eine seitenzentrierte Sicht auf Informationen. Attribute und ihre Werte dienen der strukturierten Anreicherung des Inhalts einer Seite.

MediaWiki selbst sieht keinerlei Möglichkeit vor, Seiten Attributswerte zuzuweisen, und selbst durch die Angabe expliziter binärer Beziehungen zwischen Seiten können bereits viele zusätzliche Daten verfügbar gemacht werden. Die wesentliche in MediaWiki unterstützte Form binärer Beziehungen sind Hyperlinks. Jeder Link steht für eine Beziehung zwischen zwei Seiten, doch ist die Art und die Relevanz der Beziehung nur implizit durch den Text gegeben. SMW erlaubt es daher, die Bedeutung der Hyperlinks durch Attribute festzulegen, so dass das Ziel eines Links zum Wert eines bestimmten Attributs wird. Aber nicht alle Attribute haben andere Seiten als Wert: Zahlen, Kalenderdaten, geographische Koordinaten sind Beispiele weiterer in SMW verfügbarer Typen von Attributen.

Schauen wir uns ein Beispiel an. In Abb. 2 (oben) ist der Wikitext für einen Artikel über London gegeben. Die Auszeichnungselemente sind einfach zu verstehen: „...“ markiert Text, der besonders betont werden soll (etwa durch Fettdruck), und Wörter in eckigen Klammern [[...]] stellen einen Link zur Wikiseite des entsprechenden Namens dar. Die Verweise auf *England*, *United Kingdom*, und *2005* haben keine formale Bedeutung. Um nun in SMW auszudrücken, dass London die Hauptstadt von England ist, wird der Link auf [[England]] mit einem entsprechenden Attribut zu [[capital of::England]] erweitert. Dies entspricht der (maschinen-lesbaren) Aussage, dass „London“ ein Attribut mit dem Namen „capital of“ und dem Wert „England“ hat. Das ist auch möglich,

```
'''London''' is the capital city of [[England]] and
the [[United Kingdom]]. As of [[2005]], the population
of London was estimated 7,421,328. Greater London cov-
ers an area of 609 square miles. [[Category:City]]
```

```
'''London''' is the capital city of [[capital
of::England]] and the [[capital of::United Kingdom]].
As of [[2005]], the population of London was estimated
[[population::7,421,328]]. Greater London covers an
area of [[area::609 square miles]]. [[Category:City]]
```

Abb. 2. Quelltext einer Seite über London in MediaWiki (oben) und SMW (unten)



Abb. 3. Eine semantische Sicht auf London

wenn das Attribut „capital of“ im Wiki bisher noch nicht existiert.

Der obere Teil von Abb. 2 weist weitere interessante Daten auf, die nicht mit Hyperlinks ausgedrückt sind, wie z. B. die Einwohnerzahl. Die Syntax für solche bisher überhaupt nicht hervorgehobene Daten ist nicht so offensichtlich wie für Links, doch wir entschlossen uns schließlich für eine ähnliche Lösung. Eine Annotation für die Einwohnerzahl würde also hinzugefügt werden, indem man `[[Einwohnerzahl::7.421.328]]` schreibt. In diesem Fall bezeichnet „7.421.328“ keine andere Seite im Wiki, und dementsprechend ist die Erstellung eines Hyperlinks hier nicht erwünscht. Um das zu erreichen, müssen Attribute, die nicht auf andere Seiten verweisen, zuvor *deklariert* werden. In diesem Fall würden wir also das Attribut „Einwohnerzahl“ einführen und seinen Typ als Zahl spezifizieren, wie im nächsten Abschnitt beschrieben. Ist ein Attribut noch nicht deklariert, so nimmt SMW an, dass das Attribut auf Wikiseiten verweist, und der Wert wird als Link dargestellt. Eine entsprechend annotierte Version des London-Artikels findet sich in Abb. 2 (unten). Für Leser würde sich daraus die in Abb. 2 dargestellte Seitenansicht ergeben. Der Kasten am unteren Ende fasst die verstandenen Annotationen zusammen, und bietet eine Reihe weiterer Funktionen, die in Abschn. 1 näher beschrieben werden.

Neue Attribute werden im Wiki schon dadurch eingeführt, dass sie auf einer beliebigen Seite verwendet werden. Oft möchte man aber weitere Informationen *über* die Attribute festhalten. SMW ermöglicht das, indem jedes Attribut eine eigene Seite im Namensraum „Attribut:“ erhält. Ein Wiki könnte z. B. die Seite „Attribut:Einwohnerzahl“ enthalten. Eine Attributsseite kann eine informelle Beschreibung des Attributs enthalten, die für Benutzer dokumentiert, wie das Attribut verwendet werden sollte. Weiterhin können auf Attributsseiten aber auch semantische Eigenschaften des Attributs deklariert werden, wie z. B. der *(Daten-)Typ* des Attributs. Im

Fall von „Attribut:Einwohnerzahl“ würde die Seite eine Annotation `[[hat Datentyp:Zahl]]` enthalten. Dies erlaubt es SMW, Werte des Attributs korrekt zu interpretieren und angemessen darzustellen. Das Attribut „hat Datentyp“ ist ein vordefiniertes Attribut in SMW mit einer besonderen Bedeutung. Zwar kann es auch informell auf seiner Attributsseite beschrieben werden, aber es kann weder gelöscht noch in seiner Bedeutung verändert werden.

SMW bietet von Haus aus eine Reihe verschiedener Datentypen an. Das sind u. a. „Zeichenkette“ (für kurze Zeichenketten), „Text“, „Datum“, „Geografische Koordinaten“, „Ganze Zahl“, „Dezimalzahl“ und der Standardtyp „Seite“ für Wikiseiten. Für jeden dieser Datentypen implementiert SMW spezielle Funktionen zur Verarbeitung von Nutzereingaben und zur Darstellung von Werten. Darüber hinaus können Entwickler zusätzliche Datentypen implementieren und über eine einfache Schnittstelle modular in SMW einfügen (vgl. Abb. 1). Wie auch Attribute haben Datentypen eigene Seiten im Wiki, und jede Deklaration erzeugt einen Link zu der entsprechenden Typseite. Zu einem gewissen Grad ist es auch möglich, angepasste Datentypen durch das Anlegen neuer Typseiten zu erstellen: Nutzer können zwar keine vollständig neuen Datentypen anlegen, wohl aber bestehende Typen parametrisieren. Die wichtigste Anwendung hierfür sind numerische Typen mit Unterstützung für bestimmte Maßeinheiten, welche durch Angabe der entsprechenden Umrechnungsfaktoren auf einer neuen Typseite erzeugt werden können. So benutzt z. B. das Attribut „Fläche“ (*area*) in Abb. 2 (unten) einen solchen angepassten Datentyp, der die Umrechnung von km^2 in Quadratmeilen unterstützt. Die Unterstützung von Einheiten ist wichtig um die in größeren Wikis kaum vermeidbare Angabe von Datenwerten unterschiedlicher Einheiten zu erlauben.

Abbildung auf OWL

Die formale Semantik der Annotationen in SMW ist mittels einer Abbildung auf die OWL-DL-Ontologiesprache [11] gegeben. Die meisten Annotationen lassen sich dabei direkt in OWL DL darstellen, indem Wikiseiten auf die entsprechenden OWL-Elemente abgebildet werden: normale Seiten entsprechen OWL-Individuen, Attribute entsprechen OWL-Properties, und Kategorien repräsentieren OWL-Klassen. Attributswerte werden entweder durch abstrakte Individuen oder durch typisierte Literale dargestellt. Die meisten Annotationen lassen sich so direkt auf einfache OWL-Aussagen abbilden, ähnlich zu RDF-Tripeln. Die semantischen Daten sind dabei keine Annotationen des HTML-Dokuments der Seite, sondern des auf der Seite beschriebenen Gegenstands.

OWL unterscheidet zwischen *object properties*, *datatype properties* und *annotation properties*, und Attribute in SMW können, je nach Datentyp, jeder dieser Properties entsprechen. Datentypen selbst haben keine direkte Semantik in OWL, aber sie entscheiden über den XML-Schema-Typ, der für die Literalwerte einer *datatype property* verwendet wird. Des weiteren wird die Kategorisierung einer Seite als OWL Klasseninstanziierung interpretiert.

SMW bietet einige eingebaute Attribute mit besonderen semantischen Interpretation an. Das oben genannte Attribut „hat Datentyp“ ist ein solches spezielles Attribut und hat in der OWL Semantik keine Entsprechung. Deshalb wird es rein informativ als *annotation property* dargestellt. Viele weitere spezielle Attribute beschreiben nur SMW-spezifische Meta-Informationen, z. B. für die Einheitenumrechnung, und werden ebenfalls als *annotation property* exportiert. MediaWikis Unterstützung für die hierarchische Struktur der Kategorien kann von SMW als OWL-Klassenhierarchie übersetzt werden (was nicht für alle Wikis angemessen ist [18]). Außerdem unterstützt SMW ein Attribut „Untereigenschaft von“, um auch Attribute in eine entsprechende hierarchische Beziehung zu setzen, z. B. das Attribut „Tochter“ als Untereigenschaft von „Kind“. Es findet kein Typenvergleich über Untereigenschaften statt, aber Annotationen in unpassenden Typen werden ignoriert. Im Allgemeinen sind die in SMW ausdrückbaren Schemainformationen bewusst einfach gehalten, da das Wiki nicht als ein vollständiger Ontologie-Editor konzipiert ist, der vom Benutzer umfassendes Hintergrundwissen über Semantic-Web-Standards und deren formale Semantik verlangt. SMW kann allerdings durchaus in Kombination mit ausdrucksstärkeren Hintergrundontologien und einer externen OWL-Inferenzmaschine verwendet werden [19].

OWL DL schränkt Subjekte und Objekte von Aussagen auf Individuen ein, während SMW diese Einschränkung nicht kennt und daher eine Art Meta-Modellierung ermöglicht. Semantisch ist diese Meta-Modellierung ähnlich dem OWL 1.1 [11] eingeführten „*Punning*“, welches das Schlussfolgern bekanntermaßen nicht wesentlich erschwert.

Verwendung der semantischen Daten

Egal wie einfach das Annotieren von Wikiseiten sein sollte – die Mehrzahl der Benutzer werden diese Möglichkeiten zu Recht ignorieren, wenn sich daraus keine unmittelbaren Vorteile ergeben. In diesem Abschnitt stellen wir verschiedene Möglichkeiten vor, semantische Daten praktisch im Wiki zu verwenden.

Browsen

Wie man in Abb. 2 sehen kann, werden die Annotationen einer Seite jeweils in einem Kasten unterhalb der Seite angezeigt, ähnlich zu Kategorien in MediaWiki. So werden alle gegebenen Annotationen zusammengefasst dargestellt und Benutzer können sich schnell einen Überblick verschaffen. Auch Fehler bei der Eingabe von Datenwerten, etwa wenn die Eingabe nicht verstanden wurde oder nicht zum Typ des Attributs passt, werden hier angezeigt. Weitere Links bieten relevante Funktionen an.




Abb. 4. Beim Browsen durch die Wissensbasis des Wikis

Mittels dieser Links können Nutzer die semantischen Inhalte des Wikis browsen. Ein Verweis im Titel der Box führt zum *semantischen Browser*, der nicht nur die Annotationen einer bestimmten Seite zeigt, sondern auch alle Annotationen, in denen die Seite als Wert verwendet wurde (vgl. Abb. 3 links). Die Lupe hinter den Werten in Abb. 2 führt zu einer *inversen Suche*, bei der alle Seiten mit einer entsprechenden Annotation gezeigt werden, so dass Nutzer schnell ähnliche Subjekte finden können. Beide Schnittstellen sind in SMW durch *Spezialseiten* realisiert, also architektonisch ähnlich dem OWL-Export in Abb. 1. Die Browsingseiten verweisen zudem auf die Seite der jeweiligen Attribute, welche wiederum alle Annotationen dieses Attributs auflisten. Diese verschiedenen Seiten sind eng miteinander verknüpft, so dass Benutzer die semantischen Inhalte der Wikiwissensbasis auf eine vollkommen neue Weise erforschen können.

Anfragen

SMW verfügt über eine eigene Anfragesprache, die den direkten Zugriff auf das semantische Wissen im Wiki ermöglicht. Die Anfragesprache kann derzeit auf zwei Arten verwendet werden: entweder um über eine Schnitt-

stelle direkt Fragen einzugeben, oder aber um die Antwort zu einem Artikel in Form einer eingebetteten Anfrage (*inline query*) hinzuzufügen (vgl. Abb. 1). Letztere Methode ermöglicht es Autoren, auf den Seiten des Wikis dynamisch erstellte Listen und Tabellen hinzuzufügen, so dass aktuelle Anfrageergebnisse stets allen Lesern des Wikis zur Verfügung gestellt werden, selbst wenn sie die semantischen Fähigkeiten des Wikis kennen. In Abb. 6 sieht man das Ergebnis einer Anfrage, wie sie auf einer Seite über die Schweiz vorkommen könnte: aufgeführt werden alle Kantone mit ihren Hauptstädten, Bevölkerungszahlen und den jeweils gesprochenen Sprachen. Die hier dargestellten Bevölkerungszahlen z. B. werden damit stets aktuell und konsistent bleiben, denn wenn die Bevölkerungsangabe eines einzelnen Kantons auf dessen Seite aktualisiert wird, so werden auch die Zahlen in den Anfrageergebnissen angepasst. Verglichen mit manuell erstellten Listen sind eingebettete Anfragen von höherer Genauigkeit, einfacher zu erstellen und deutlich leichter zu warten.

Die Syntax der SMW-Anfragesprache ist stark an Wikitext angelehnt, während die Semantik mit bestimmten Klassenkonstruktoren von OWL DL korrespondiert. Jede Anfrage ist eine Disjunktion aus Konjunktionen. Bedingungen an das Suchergebnis werden als *atomare Anfragen* aufgeschrieben, deren Syntax an die Annotationen in SMW angelehnt ist. So ist z. B. `[[located in::England]]` die atomare Anfrage nach allen Seiten mit eben dieser Annotation. Anfragen nach anderen Arten von Attributen, oder auch nach der Mitgliedschaft in Kategorien, sind nach denselben Prinzipien aufgebaut. Anstatt fester Werte sind auch Wertebereiche oder verschachtelte Unteranfragen möglich.

Eine etwas vereinfachte Variante von SMWs Anfragesprache ist in Abb. 4 (oben) gegeben. Die wichtigsten Symbole, die zum Strukturieren der Anfragen verwendet werden, sind: `| |` als Disjunktionsoperator, `<q>`

QUERY::=CONJ (' ' CONJ) *	CONJ::=ATOM (' ' ATOM) *
ATOM::=SUB PROP CAT PAGE	SUB::='<q>' QUERY '</q>'
PROP::='[[' TITLE ' :: ' VALUE (' ' VALUE) * ']]'	
VALUE::='+' SUB ((' > ' ' < ' ' ! ') ? STR)	
CAT::='[[Kategorie: ' TITLE (' ' TITLE) * ']]'	
PAGE::='[[: ' FULLTITLE (' ' FULLTITLE) * ']]'	
QUERY::='(' CONJ (' ' CONJ) * ')'	CONJ::='(' ATOM (' ' ATOM) * ')'
ATOM::=SUB PROP CAT PAGE	SUB::='(' QUERY ')'
PROP::='∃' TITLE ' . (' VALUE (' ' VALUE) * ')'	
VALUE::='⊇' SUB (' ge(' ' le(' ' ne(' ' eq(') STR '))	
CAT::='(' TITLE (' ' TITLE) * ')'	
PAGE::='(' ({ ' FULLTITLE ' } ' ({ ' FULLTITLE ' }) * '))'	

Abb. 5. Eine generative Grammatik für SMW-Anfragen (oben) und die entsprechenden DL-Konstrukte (unten)

und $\langle /q \rangle$ als Klammerzeichen, $+$ als Existenzoperator, der auf jeden beliebigen Wert umfasst, und $\langle, \rangle, !$ für die Vergleichsoperatoren $\leq, \geq$, und $\neq$. Einige Nichtterminalsymbole sind in Abb. 4 wegen Platzgründen nicht definiert: `TITLE` steht für den Titel einer Seite, `FULLTITLE` für den Titel einer Seite mitsamt des Namensraums, und `STR` steht für Unicode-Strings. In diesen sind keine Zeichen erlaubt, die mit strukturellen Symbolen verwechselt werden können. So dürfen z. B. Titel nicht mit $\langle$ beginnen. SMW bietet verschiedene weitergehende Mechanismen, durch die solche Zeichen dennoch verwendet werden können.

Als Beispiel betrachten wir die Frage nach allen Städten, die entweder mehr als 500.000 Einwohner haben oder in einem EU-Mitgliedsland liegen:

```
[[Kategorie:Stadt]] <q> [[Einwohner::>500.000]] ||
[[liegt_in::<q>[[Kategorie:Staat]]
[[Mitglied::EU]]</q>]]</q>
```

Die formale Semantik der Anfrage ist durch die Abbildung in OWL-DL-Klassenkonstrukte gegeben, d. h. eine Anfrage ermittelt Instanzen einer entsprechenden OWL-Klasse. Man kann leicht sehen, dass alle SMW-Anfragen durch die Anwendung von Grammatikregeln in einer eindeutigen Reihenfolge entstehen. Wendet man die entsprechenden Regeln der Grammatik im unteren Teil von Abb. 4 nun in gleicher Reihenfolge an, so ist das Ergebnis ein beschreibungslogischer Klassenausdruck, welcher in bekannter Art nach OWL DL übersetzt werden kann. Wir verzichten hier aus Platzgründen auf die Details dieser Standardabbildung (siehe z. B. [11]). Formal würde außerdem die Definition der zugrunde liegenden Beschreibungslogik, die Einführung von *Punning*, um Rollen, Klassen und Individuen gleichen Namens zu ermöglichen, die Einführung konkreter Domänen für die Datentypen von SMW, sowie die eindeutige Definition der Symbole *ge*, *le*, *ne*, *eq* und $\top$ (für Rollen mit Datentypen) nötig sein. Aus Platzgründen überspringen wir hier diese einfachen, doch etwas umständlichen Schritte, und halten lediglich fest, dass die oben betrachtete Beispielanfrage in die folgende beschreibungslogische Klasse übersetzt würde:

$$\text{Stadt} \sqcap (\exists \text{Einwohnerzahl.} ge(500,000) \sqcup \\ \exists \text{liegt_in.} (\text{Staat} \sqcap \exists \text{Mitglied.} \{EU\})).$$

Die SMW-Anfragesprache unterstützt, wie auch OWL DL, keine benannten Variablen, so dass Querreferenzen zwischen den verschiedenen Teilen einer Anfrage nicht umsetzbar sind. So ist es z. B. nicht möglich, nach allen Personen zu fragen, die in der selben Stadt geboren wurden, in der sie später

	Capital	Population	Languages
Aargau	Aarau	573,654	German language
Ticino	Bellinzona	319,800	
Graubünden	Chur		German language Italian language Romansh

Abb. 6. Das Ergebnis einer Anfrage nach allen Schweizer Kantonen, ihren Hauptstädten, Einwohnerzahlen und Sprachen. Die Lücken entstehen durch unvollständige Daten in den zugrunde liegenden Artikeln. Die Daten stammen aus einer automatisch annotierten Kopie der englischen Wikipedia

starben. Diese Einschränkung führt zu einer polynomiellen Komplexität der Anfragebeantwortung, welche für den Einsatz von SMW in großen Wikis unerlässlich ist. Im Gegensatz dazu führen Variablen in Anfragen zu einem mindestens NP-harten Problem, das durch weitere Sprachkonstrukte schnell noch schwieriger wird, selbst wenn man sich auf sehr einfache beschreibungslogische Fragmente von OWL 1.1 bechränkt [12].

SMW-Anfragen liefern zunächst eine bestimmte Menge von Seiten als Resultat zurück. Um weitere Informationen zu dieser Menge auszugeben, erlaubt SMW die eigentliche Anfrage um so genannte Ausgabeanfragen (*print requests*) zu erweitern. Dadurch werden nicht nur die Seitennamen selbst, sondern auch die Werte dieser Seiten, für die bestimmte Attribute gelten, Teil des Anfrageergebnisses.

Die Ausgabeanfrage `[ [Hauptstadt:: * ] ]` z. B. erwirkt bei allen Ergebnisseiten außerdem die Ermittlung und Ausgabe der Werte des Attributs „Hauptstadt“. Abbildung 5 stellt eine typische Anfrage dar, in der mehrere Ausgabeanfragen enthalten sind. Weitere Parameter bei Anfragen erlauben es, das Ergebnis auf verschiedene Arten zu formatieren, wie etwa Tabellen, Listen, benutzerdefinierten Formaten oder auch interaktiven Zeitleisten⁴.

Export und Wiederverwendung semantischer Daten

Im Semantic Web geht es vor allem um den Austausch und die Wiederverwendung von Wissen, vereinfacht durch standardisierte Formate für die Übertragung strukturierter Informationen zwischen Wissensproduzenten und -konsumenten. In Abschn. 3 wurde beschrieben, wie sich SMWs semantische Informationen in OWL DL ausdrücken lassen. SMW stellt

⁴ <http://simile.mit.edu/timeline/>

diese Daten über den *OWL-Export* in Form einer geeigneten OWL/RDF-Serialisierung zur Verfügung. Wie man in Abb. 1 sehen kann, wird auch dieser Dienst durch eine Spezialseite realisiert, die man nach den Daten bestimmter Seiten fragen kann. Auch der Link „RDF feed“ innerhalb der Wikiseite verweist auf den zur Seite gehörigen OWL-Export (siehe Abb. 2).

Die als OWL/RDF exportierten Daten verwenden passende URIs zur Identifizierung der Individuen im Wiki. Diese unterscheiden sich von den URLs der einzelnen Wikiseiten, um so den Unterschied zwischen der (HTML-)Seite und dem darin beschriebenen (abstrakten) Gegenstand zu unterstreichen. Die erzeugten OWL/RDF-Daten sind miteinander verlinkt und lassen sich z. B. von externen RDF-Browsern verwenden. Die URIs können mit Hilfe des HTTP-Protokolls aufgelöst werden, so dass Agenten entweder auf den OWL-Export oder auf die HTML-Seiten verwiesen werden. Durch die Kompatibilität sowohl zu OWL als auch zu RDF ergeben sich eine Vielzahl von Möglichkeiten zur Weiterverwendung der Informationen aus einem SMW-Wiki. Bereits heute bietet nahezu jede verbreitete Programmiersprache RDF-Bibliotheken, welche die Entwicklung von Anwendungen zur Weiterverwendung semantischer Wiki-Daten sehr vereinfachen. Anwendungen wie der RDF-Browser *Tabulator* [4] können zudem inkrementell semantische Inhalte aus dem Wiki nachladen, sobald ein Nutzer ein entsprechendes Element betrachten möchte. SMW verfügt zudem über Skripte, die einen Gesamtexport aller Daten in eine einzige Wissensbasis ermöglichen. Dies vereinfacht den Zugriff für Programme wie den facetten-basierten Browser *Longwell*⁵, welcher zunächst alle Daten zwecks schnelleren Zugriffs in eine eigene Datenbank überträgt. Beispiele aktueller OWL-Exporte stehen im Web zur Verfügung.⁶

Praktische Erfahrungen

In diesem Abschnitt beschreiben wir die Erfahrungen, die mit SMW im praktischen Einsatz gemacht wurden. Wir diskutieren dabei die typische Verwendung von einzelnen Funktionen und die beobachteten Probleme und Vorteile des Einsatzes von SMW. Dadurch versuchen wir zu erkennen, wie Annotationen praktisch verwendet werden, und wie sich bestehende Prozesse durch den Einsatz semantischer Technologien verändern. Allerdings ist diese Frage nicht so einfach zu beantworten, wie es zunächst scheint, da jedes Wiki eine eigene Benutzergemeinde mit eigenen Regeln, Traditionen und Dynamiken besitzt. Allgemeingültige Aussagen über die

⁵ <http://simile.mit.edu/wiki/Longwell>

⁶ <http://ontoworld.org/RDF/>

Verwendung von Wikis – semantisch oder nicht – lassen sich daher kaum treffen. Ohne umfassende Untersuchungen über den Einsatz von Wikis zu bestimmten Aufgaben oder in bestimmten Umgebungen müssen Voraussetzungen über die Einführung semantischer Technologien also sehr vorsichtig getroffen werden. Auch stehen im Allgemeinen nur wenige Nutzungsdaten zur Verfügung: zwar bieten öffentlich zugängliche Wikis ihren ganzen Inhalt und ihre vollständige Versionshistorie an, doch stellt das Bearbeiten von Inhalten bei einem Wiki nur einen kleinen Teil seiner Benutzung dar. Informationen über das Lesen oder die Suche in Wikis stehen dagegen meist nicht zur Verfügung, da deren Erfassung für große Systeme wie Wikipedia beträchtliche technische Anforderungen stellen würde.

Im Folgenden versuchen wir, ausgehend von verschiedenen Datenquellen, Erkenntnisse über die Benutzung semantischer Wikis zu gewinnen. Zunächst betrachten wir vergleichbare Arbeitsabläufe bei der Verwendung von Wikipedia – dem wohl am besten untersuchten und am wenigsten typischen Wiki. Danach betrachten wir die Zugriffsdaten von *ontoworld.org*, einem deutlich kleineren Wiki. Da *ontoworld.org* von uns verwaltet wird, haben wir vollständige Einsicht in die Daten dieses Wikis. Schließlich beschreiben wir den Einsatz von SMW in weiteren Wikis, und betrachten dabei aufgetretene Schwierigkeiten und Erfolgsgeschichten.

Strukturen von Inhalten in Wikipedia

Um die Nützlichkeit der in SMW eingeführten Techniken abzuschätzen, vergleichen wir sie mit ähnlichen, bereits vorhandenen Möglichkeiten in Wikipedia. Wir betrachten dabei insbesondere Wikipedias Kategoriensystem. Ebenso wie die Attribute in SMW werden Kategorien als Hilfsmittel zur Strukturierung betrachtet. Benutzer verwalten hierbei nicht nur die Zuweisung von Seiten zu bestimmten Kategorien, sondern auch die Namen der Kategorien, ihre Abgrenzung und ihre Beziehungen untereinander in Form von Kategorienhierarchien. Von Benutzerseite aus ist der Zweck der Kategorien das leichtere Auffinden von Informationen, und die vorhandenen Möglichkeiten zum Browsen der Kategorien sind ähnlich zu den Möglichkeiten in SMW, durch die Attribute und ihre Werte zu browsen. Die komplexeren Anfragen, die SMW zusätzlich erlaubt, haben bei Kategorien in MediaWiki keine Entsprechung, auch wenn Erweiterungen wie DPL⁷ derartige Möglichkeiten vorsehen (allerdings ist DPL nicht Teil von Wikipedia, so dass wir es hier nicht für den Vergleich heranziehen können). Wir betrachten deswegen im Folgenden den Einsatz von Kategorien in

⁷ <http://www.mediawiki.org/wiki/Extension:DynamicPageList>

Wikipedia, in der Annahme daraus gültige Aussagen über den möglichen Einsatz von Attributen in Wikipedia ableiten zu können.

Lesezugriffe auf Wikipedia werden nur sehr grob erfasst, aber wir sind zunächst vor allem an dem Editierprozess interessiert, insbesondere hinsichtlich des Hinzufügens von Annotationen (seien es Kategorien oder Attribute). Im Allgemeinen wird der Editierprozess in Wikipedia auch heute kaum verstanden. Eine erste Analyse wurde in [16] durchgeführt und legte den Schluss nahe, dass Editoren in Wikis grob in zwei Klassen unterteilt werden können: die meisten Änderungen stammen von einem relativ kleinen Kern von Personen, wohingegen der größte Teil des Inhalts von einer weitaus größeren Gruppe beigetragen wird. Kernmitarbeiter haben oft deutlich tiefergehende Kenntnisse über den Einsatz der technischen Möglichkeiten des Wikis und über die Prozesse innerhalb von Wikipedia, und sind zudem stärker um die ganzheitliche Entwicklung von Wikipedia besorgt. Die meisten anderen Autoren kümmern sich dagegen in erster Linie um die Inhalte einer kleineren Zahl von Artikeln, denen sie aufgrund ihrer persönlichen Kenntnisse und Interessen besonders zugeneigt sind. [16] formuliert es so:

„ein Outsider macht eine Veränderung, in der er einen ganzen Batzen Informationen hinzufügt, und dann folgen durch Insider mehrere Bearbeitungen, die diese Informationen anpassen und umformatieren. So sammeln die Insider tausende von Edits, indem sie Dinge tun, wie den Namen einer Kategorie durch das ganze Wiki hindurch zu ändern – die Art von Dingen, um die sich nur Insider echte Gedanken machen.“⁸

Weitere und umfangreichere Untersuchungen sind notwendig, um unser Verständnis darüber zu vertiefen, wie Inhalte in Wikipedia tatsächlich verfasst werden. Diese ersten Ergebnisse deuten aber darauf hin, dass strukturelle Verbesserungen wie das Kategorisieren großteils von einer kleinen Gruppe von Benutzern durchgeführt werden.

Ein weiterer wichtiger Aspekt der Kategorisierung in Wikipedia sind die damit verbundenen Arbeitsabläufe, Richtlinien und Regeln. Solcherlei Beschreibungen sind ein wichtiger Teil der Organisation und Struktur von Wikipedia im Allgemeinen [17]. Für Kategorien finden sich detaillierte Beschreibungen, um zu entscheiden, wann die Einführung einer Kategorie angebracht ist und welche Artikel jeweils damit kategorisiert werden

⁸ „an outsider makes one edit to add a chunk of information, then insiders make several edits tweaking and reformatting it. In addition, insiders rack up thousands of edits doing things like changing the name of a category across the entire site – the kind of thing only insiders deeply care about.“

sollten.⁹ Richtlinien zum Kategorisieren und deren Anwendung unterliegen einer fortlaufenden Veränderung, Bewertung und Diskussion durch die daran interessierten Wikipedianer – die wichtigste Form der Entscheidungsfindung in Wikipedia.

Hinsichtlich der Richtlinien sollen Kategorien als Annotationen in dem Sinne betrachtet werden, dass sie dem Artikeltext keine weiteren Informationen hinzufügen. Die Information, welche die Kategorisierung enthält, muss auch aus dem Text heraus offenbar sein. Es geht also darum, einen bestimmten Aspekt des Artikelinhalts zu explizieren. Eine solche Verwendung von Kategorien ist nicht in der technischen Umsetzung des Kategoriensystems begründet, sondern Bestandteil der sozialen Prozesse von Wikipedia.

Schließlich halten wir fest, dass der Einsatz von Kategorien in Wikipedia vor allem durch praktische Überlegungen geleitet wird. Der Sinn der Kategorisierung ist nicht eine Hierarchie des Wissens der Welt zu erstellen, sondern hilfreiche Strukturen für den Leser bereitzustellen, mit denen Wissen erforscht und entdeckt werden kann. Ebenso sind Attribute in SMW kein Versuch das utopische Ziel einer einheitlichen Weltontologie zu erreichen. Sie sind lediglich eine praktische Ergänzung, die bei der alltäglichen Verwendung von Wikipedia helfen soll.

Verwendung auf *ontoworld.org*

Wie schon erläutert, sind die detaillierten Zugriffslogs von Wikipedia aus diversen Gründen nicht verfügbar. Wir betreiben aber auch *ontoworld.org*, ein Wiki für die Semantic-Web-Community, und dessen Logs stehen damit für genauere Untersuchungen zur Verfügung. Auf *ontoworld.org* werden Informationen über Konferenzen, Forscher, und Projekte gesammelt, und es diente bei verschiedenen Konferenzen – ISWC 2006 und 2007, ESWC 2007 – als Konferenzwiki. Es wird aber auch als Testwiki für SMW verwendet, zur Demonstration neuer Features und zum Testen und Erlernen bestehender Funktionen. Dadurch ergibt sich eine dezentrale Benutzergemeinschaft und eine recht heterogene Struktur in den Wikiseiten – nicht unähnlich Wikipedia. Allerdings ist auch zu erwarten, dass auf *ontoworld.org* die semantischen Eigenschaften im Vergleich zu anderen Wikis stärker betont sind.

Zum gegebenen Zeitpunkt umfasst *ontoworld.org* 6.319 Artikel (einschließlich mancher sehr kurzer Seiten). 930 Benutzer haben sich bisher registriert, von denen die meisten sehr wenig zu den bisher getätigten 37.880 Bearbeitungen beigetragen haben. Die semantische Wissensbasis

⁹ <http://de.wikipedia.org/wiki/Hilfe:Kategorien>

umfasst 17.562 Annotationen mit 808 Attributen. Die meisten Attribute haben eine Seite im Wiki und etwa die Hälfte der Attribute verweist auf Wikiseiten, während der Rest anderen Datentypen zugeordnet ist.

Es ist charakteristisch, dass die 5% am häufigsten verwendeten Attribute etwa 74% der Annotationen ausmachen, wohingegen die am wenigsten verwendeten 80% an weniger als 9% der semantischen Aussagen teilhaben. Auch das Kategoriensystem von Wikipedia zeigt eine ähnliche Exponentialverteilung [18], wie sie in vielen verteilten, gemeinschaftlich und dezentral erstellten Datensammlungen festzustellen sind. Dies ist eine wichtige Charakteristik benutzererstellter Inhalte, während kleinere und stärker kontrollierte Wikis eher künstlich anmutende, gleichmäßigere Verteilungen aufweisen.

Wir haben die Benutzung von *ontoworld.org* über einen Zeitraum von sieben Tagen beobachtet. In der Zeit kam es zu 68.000 einfachen Lesezugriffen (ohne Schreibzugriffe und Zugriffe auf Spezialseiten). Erwartungsgemäß stammen die meisten Zugriffe von Webcrawlern (etwa 75%) und von Spammern (die etwa 16.000 verweigernde Schreibzugriffe verursachten, die nicht in der oberen Zahl auftauchen). Es ist schwierig, Spambots von echten Benutzern zu unterscheiden, aber es ist eher unwahrscheinlich, dass Such- und Browserfunktionen durch solche Programme aufgerufen werden. Das bedeutet, dass die hier festgehaltenen Zahlen die tatsächliche Verwendung semantischer Technologien im Vergleich zu normalen Lesezugriffen eher unterschätzen.

Die Zugriffszahlen für den beobachteten Zeitraum finden sich in Tabelle 6. Die linke Tabelle zeigt die Anzahl von Zugriffen, aufgeschlüsselt nach Namensräumen. Wir normalisieren die Zugriffe mit der Anzahl der Seiten in dem jeweiligen Namensraum, um die Zahlen vergleichbarer zu machen. Attribute scheinen ein etwas geringeres Interesse zu wecken, insbesondere bei Bots, doch das rührt höchstwahrscheinlich von der erst kürzlich durchgeführten Umbenennung dieses Namensraums im englischen SMW her, wodurch viele bestehende URLs ungültig wurden. Abgesehen davon scheinen Kategorien und Attribute bei den Benutzern ähnlich

Lesen	u#	r#	p#	u#/p#	r#/p#	Spezial	u#	Spezial	u#
Gesamt	16,525	52,192	6,319	2.62	8.26	Browse	637	Changes	479
Kategorie:	598	4,166	484	1.24	8.61	PropQuery	1,326	Backlinks	284
Attribut:	781	3,150	756	1.03	4.17	Query	222	Suche	419
Typ:	263	336	43	6.12	7.81	Attribute	83	Kategorien	65
Hilfe:	1,766	773	41	43.07	18.85	Typen	59	OWL-Export	575

Abb. 7. Zugriffszahlen auf *ontoworld.org* über einen Zeitraum von sieben Tagen. Die Spalten u#, r# und p# sind die Anzahl der Benutzerzugriffe, Botzugriffe und die Anzahl der im Namensraum vorkommenden Seiten

beliebt zu sein. Die Hilfs- und Typennamensräume beinhalten vor allem auch die Benutzerdokumentation von SMW, was auch das deutlich erhöhte Interesse an diesen Seiten erklären könnte.

Die mittlere und rechte Tabelle zeigen die Zugriffe auf bestimmte Spezialseiten. Dadurch wissen wir, wie häufig die jeweils damit verbundene Funktion aufgerufen wird. *Browse* und *PropQuery* stellen SMWs Browsingmöglichkeiten dar (siehe Abschn. 1). *Query* ist eine Schnittstelle zum Eingeben von Anfragen auf die semantischen Inhalte im Wiki (s. Abschn. 2). *Attribute*, *Typen* und *Kategorien* bezeichnen Seiten, welche die Artikel des jeweiligen Namensraums auflisten. *Suche* bezeichnet die Volltextsuche von MediaWiki. *OWL-Export* ist der Export der semantischen Inhalte im RDF/XML-codierten OWL-Format.

Wir können feststellen, dass die Browsing-Funktionen (Attributsseiten, Browse, Attributssuche) häufig verwendet werden – auch im Vergleich zu den von MediaWiki ohnehin schon bekannten Browsing-Funktionen (Kategorienseiten und zurückweisende Links). SMWs Schnittstelle für die Eingabe semantischer Anfragen wird ebenfalls von vielen Benutzern verwendet, obwohl sie ein deutlich tiefergehendes Verständnis von SMW erfordert. Das wird auch dadurch offenbar, dass die bekannten Bots etwa 20.000 Aufrufe der Browsing-Seiten verursachten, aber nur 28 Mal diese Anfrageseite aufriefen. SMWs Wartungsseiten für Attribute und Typen sind ähnlich beliebt wie MediaWikis Wartungsseite für Kategorien.

Abschließend können wir also festhalten, dass die neue Funktionalität von SMW zumindest so oft verwendet wird wie die entsprechende Funktionalität von MediaWiki. Man kann darüber hinaus aus den detaillierten Logs erkennen, dass die Abfragen und Browsing-Funktionen meist die Kerninhalte des Wikis – die Semantic-Web-Forschung – betreffen, und oft zur Navigation auf verwandte Inhalte verwendet werden. Es ist wahrscheinlich, dass diese Abrufe mit einer echten inhaltlichen Verwendung des Wikis zusammenhängen, und nicht nur dem Test der Features von SMW dienen. Natürlich erlauben uns Zugriffsstatistiken keine Rückschlüsse darauf, ob die verwendeten Funktionen auch tatsächlich als sinnvoll oder hilfreich erachtet werden. Um diese Fragen beantworten zu können ist weitere Forschung nötig, die mit der Untersuchung der Nutzung von MediaWiki selbst im Rahmen von Wikipedia beginnen sollte.

Schließlich ist auch die Verwendung von SMWs OWL-Export bemerkenswert. Eine überraschend hohe Zahl von 575 Benutzern griff auf die exportierten Daten zu (190 davon kamen durch Agenten zustande, die automatisch den Links in den Metadaten von SMWs HTML-Seiten folgten). Nur wenige der restlichen 385 Zugriffe kamen durch absichtliche Benutzeranfragen zustande, weitere stammten von Suchmaschinen oder unidentifizierten Agenten (was auf experimentelle RDF-Crawler oder RDF-

Browser hinweist). Der bei weitem größte Anteil an Exportanfragen stammt jedoch von Bots. Während klassische Suchmaschinen die Exporte eher seltener aufrufen, gibt es eine Reihe von Semantic-Web-Anwendungen wie *Swoogle* (<http://swoogle.umbc.edu>), die ein verstärktes Interesse am OWL-Export zeigen. SMW als eine Quelle für wiederverwendbare semantische Daten zu nutzen ist ganz im Sinne des Semantic Web und kann, wie die Logs erkennen lassen, über externe semantische Suchmaschinen auch neue Nutzer zu einem Wiki führen.

SMW in weiteren Wikis

Zuletzt geben wir noch in Kürze einige weitere Beispiele für den Einsatz von SMW in praktischen Anwendungen. Es ist kaum möglich, neue Installationen von SMW zu verfolgen, aber es gibt zumindest eine unvollständige Liste von SMW-Wikis, die freiwillig von Benutzern der Erweiterung gepflegt wird¹⁰. Viele dieser Wikis haben einen klar umrissenen inhaltlichen Rahmen und eine überschaubare und oft recht homogene Nutzergemeinschaft. Dadurch wird sich in vielen Fällen die Art ihrer Verwendung von großen Wikis mit heterogenen Benutzergruppen unterscheiden. Dennoch können wir einige Erfolgsgeschichten, aber auch Probleme im Einsatz beobachten.

Das *Protégé Wiki*¹¹ ist ein gutes Beispiel für ein mit viel Sorgfalt und Vorbereitung strukturiertes Wiki. Es wurde erst vor kurzem eingerichtet, und verfügt zurzeit über etwa 160 Seiten, 16 registrierte Benutzer und 350 Annotationen. Dementsprechend werden die meisten Attribute und Kategorien intensiv genutzt, und das Wiki ist allgemein sehr aufgeräumt und gut organisiert. Dies hängt auch mit der klar umrissenen Aufgabe des Wikis zusammen: es soll den Benutzern und der Entwicklungsgemeinde des Ontologieeditors Protégé [10] eine Plattform zum Informationsaustausch bieten. Dies gilt insbesondere für die zahlreichen Erweiterungen und Plug-Ins von Protégé, welche im Wiki jeweils mit eigenen semantisch annotierten Seiten vertreten sind. Dadurch können im Wiki leicht Übersichten relevanter Erweiterungspakete erstellt werden, und die semantischen Daten können gar in Protégé selbst geladen werden. Es ist offensichtlich, dass ein Wiki wie Protégé Wiki anders verwendet wird als *ontoworld.org*, und dennoch ist es ein gutes Beispiel für den Einsatz von SMW. Es hält ein Gleichgewicht zwischen textuellen und semantischen Inhalten, weist einen gezielten und nützlichen Einsatz von eingebetteten Anfragen auf, und es verfügt über eine gute, auf das Wiki maßgeschneiderte Hilfe und Dokumentation.

¹⁰ http://ontoworld.org/wiki/Sites_using_Semantic_MediaWiki

¹¹ <http://protegewiki.stanford.edu>

United States should attack Iran

For	The Perils of Using 'The Allies' by Charles Krauthammer (<i>The Washington Post</i>, 2006-08-25) (view )
	The Mideast's Munich by Arthur Herman (<i>New York Post</i>, 2006-08-16) (view )
	It's Our War by William Kristol (<i>The Weekly Standard</i>, 2006-07-24) (view )
Against	Diplomacy, Not War, With Iran by Bill Richardson (<i>The Washington Post</i>, 2007-02-24) (view )
	StopIranWar.com by Wesley Clark (<i>The Huffington Post</i>, 2007-02-21) (view )
	The Iran Options by The Washington Post editorial board (<i>The Washington Post</i>, 2007-02-18) (view )
	Fight Iran with a war of ideas by Azar Nafisi (<i>Los Angeles Times</i>, 2007-02-15) (view )

Abb. 8. DiscourseDB verwendet SMW um eine Übersicht über laufende politische Debatten zu erzeugen. Die hier dargestellte eingebettete Anfrage zeigt die verschiedenen Positionen im Hinblick auf die Atomkrise im Iran

SMW wurde als eine Erweiterung für text-basierte Wikis eingeführt, aber es kann auch dann Verwendung finden, wenn die meisten Inhalte stark strukturiert sind. SMW ähnelt dann weniger einem klassischen Wiki, sondern eher einer Datenbank-Anwendung mit einer Webschnittstelle zur gemeinschaftlichen Bearbeitung und Wartung. Ein interessantes Beispiel für diese Art semantischer Wikis ist *DiscourseDB*¹², in dem Informationen zu laufenden politischen Debatten in den US-amerikanischen Medien, vor allem Zeitungen, gesammelt werden. Die eigentlichen Inhalte sind kurz, enthalten aber zahlreiche Annotationen über einzelne Zeitungsartikel. Andererseits enthält das Wiki aber eine Vielzahl von automatisch erzeugten Anfrageseiten, die es erlauben, sich den Debatten auf vielen verschiedenen Arten zu nähern, und die Struktur einer Debatte und ihre Teilnehmer gezielt zu analysieren, wie Abb. 8 beispielhaft zeigt.

Diese Beispiele sind typisch für eine Reihe von SMW-Instanzen, aber SMW kommt auch in vielen anderen Arten zum Einsatz. Wir konnten nur selten beobachten, dass die Benutzer nicht wussten, wie sie anfangen sollten, oder dass sie Schwierigkeiten hatten, Attribute zur weiteren Verwendung einzuführen. Bestimmte Themen, etwa Theologie und Bibelkunde (wie etwa im Bibelwiki¹³), lassen sich aber nur schwer formal beschreiben, und in diesen Fällen ist auch die Verwendung von SMW nur bedingt hilfreich. Weitere Probleme tauchen auf, wenn ein Großteil der Inhalte nicht textuell sondern multimedial vorliegt. Hierfür gibt es zurzeit bereits interessante Prototypen, welche SMW erweitern, um auch Videos und Videoausschnitte semantisch zu annotieren und neu zu verknüpfen [8].

¹² <http://discoursedb.org>

¹³ <http://bible.tmtm.com>

Performanz von SMW

Geschwindigkeit und Leistung sind bei heutigen Webanwendungen kritische Gesichtspunkte, insbesondere bei Wikipedia als einer der zehn meist-besuchten Webseiten weltweit, oftmals mit mehr als 30.000 Zugriffen pro Sekunde. Diese hohe Zugriffszahl führt zu hoher Last auf den Servern, was wiederum wesentliche Kosten verursacht. Eine Technologie wie SMW muss daher möglichst effizient und ressourcenschonend arbeiten, um überhaupt praktikabel zu sein. Daher wurden während der Erhebung der Daten für Abschn. 2 gleichzeitig Leistungsmessungen durchgeführt, die Aufschluss über die praktische Belastung durch die beobachteten SMW-Funktionen gibt.¹⁴

Die absolute Belastung eines Webserverns durch ein Wiki hängt stark von den Kenngrößen des Servers ab, und wird von einer Vielzahl komplexer Faktoren, wie etwa dem aufgetretenen Datenbank-Caching, beeinflusst. Einzelne Messungen an einem praktisch eingesetzten System können daher nicht direkt auf andere Systeme übertragen werden, aber sie liefern Aussagen darüber, wie sich SMW im Vergleich zu anderen MediaWiki-Funktionen auf die Geschwindigkeit eines Wikis auswirkt. Im Messzeitraum wurde SMW 214.356-mal aufgerufen, was zu einer Gesamtlaufzeit von $4,54 \times 10^5$ s führte. Zusammengenommen benötigten die Funktionen von SMW nur 8,6% dieser Gesamtzeit. Diese Zeit wiederum wurde vor allem benötigt für die Auswertung semantischer Anfragen (40,5%), die verschiedenen Browsing-Funktionen (22,5%), den OWL-Export (22,2%) und das Parsen der Annotationen (12,3%). Diese Laufzeiten hängen natürlich von der Anzahl der Annotationen ab, so dass Geschwindigkeitseinbußen nur in dem Maße auftreten, in dem semantische Funktionen überhaupt verwendet werden. Das unvermeidliche Initialisieren von SMW bei *jeder* Anfrage dagegen verbraucht nur 2,3% der SMW-Zeit, was weniger als 0,2% der Gesamtlaufzeit entspricht.

Wie man im vorhergehenden Abschnitt sehen konnte, verfügt *ontoworld.org* über eine beträchtliche Anzahl von Annotationen und Nutzern, und die im Vergleich dazu recht niedrige zusätzliche Belastung ist ermutigend. Dennoch können insbesondere komplexe semantische Anfragen leicht sehr teuer werden. Im Messzeitraum wurden 51.569 Anfragen ausgewertet, die zu 99,6% in Wikiseiten eingebettet waren, und dennoch verantworten die verbleibenden 0,4% direkter Nutzeranfragen etwa 11% der Bearbeitungszeit.

¹⁴ Aktuelle Rohdaten von *ontoworld.org* sind im Web abrufbar:
<http://ontoworld.org/profileinfo.php>

Zur Kontrolle und zur Verbesserung des Anfrageverhaltens in einem bestimmten Wiki sieht SMW verschiedene Mechanismen vor. Zunächst werden Anfrageresultate, die in Seiten eingebettet sind, mit dem Artikeltext in einem Cache gespeichert. Weiterhin kann die Komplexität der Anfrage und der Answererstellung mit verschiedenen Einstellungen eingeschränkt werden: einzelne Schlussfolgerungsmechanismen (z. B. die Auflösung von Weiterleitungen oder die Berücksichtigung von Subsumptionsbeziehungen zwischen Kategorien) können deaktiviert werden, und die Größe der Anfrage allgemein kann eingeschränkt werden. Auf diese Weise kann je nach Anwendung eine geeignete Balance zwischen der Ausdrucksmächtigkeit und den Leistungsanforderungen des Wikis gefunden werden.

Im Prinzip ist die Anfragebeantwortung in SMW ein polynomielles Problem [12], doch der tatsächliche Aufwand hängt stark von der Implementierung ab. In SMW werden alle Abfragen von der *Speicherimplementierung* bearbeitet (*storage implementation* in Abb. 1). Diese Komponente wird von einer *Speicherschnittstelle* (*storage abstraction*) aufgerufen, welche die Implementierungsdetails verbirgt. Die derzeitig vorgegebene Implementierung beruht auf der in MediaWiki bereits verwendeten relationalen Datenbank MySQL, aber sie könnte dank der modularen Architektur auch durch schnellere Speicherlösungen ersetzt werden. Um verschiedene denkbare Lösungen gegenüberstellen zu können, haben wir Experimente mit verschiedenen typischen SMW-Anfragen durchgeführt und die Laufzeiten verschiedener Speichersysteme verglichen. Im Gegensatz zu den obigen Messungen wurden diese Ergebnisse nicht durch MediaWikis PHP-Parser, Netzwerkeffekte oder Caching beeinflusst, sondern direkt an den verschiedenen Testsystemen durchgeführt.

Um einen großen und realistischen Datensatz zu erhalten, haben wir eine lokale Kopie der englischen Wikipedia angelegt und mit SMW ausgestattet. Um dieses Wiki anfänglich mit Annotationen zu füllen, griffen wir auf einen von *dbpedia.org* bereitgestellten Datensatz zurück, der aus den in Wikipedia verwendeten Vorlagen durch Interpretation der Parameter als RDF-Properties gewonnen wurde [3]. Da diese Daten auf den internen Bezeichnungen der Vorlagen in Wikipedia beruhen, enthalten sie auch viele inkorrekte oder auch einfach sinnfreie Aussagen. Dennoch beruhen alle Daten auf manuell erstellten Inhalten und haben dadurch realistische Verteilungseigenschaften, die für unsere Experimente wichtiger sind als Korrektheit. Nach dem Import dieses Datensatzes wurden die semantischen Inhalte des Wikis wiederum durch SMW exportiert. Dieser Datensatz spiegelte nunmehr sehr genau die tatsächlich von SMW interpretierten Annotationen wider und wurde zuletzt nur leicht von einigen Kommentaren und Hilfsaussagen bereinigt. Der so ermittelte Datensatz bestand aus 13.802.002 RDF-Tripeln über 3.524.650 Elemente.

Wir erstellten sechs unterschiedliche Testanfragen, die wir hier nur als q_1 (1), q_2 (8677), q_3 (56), q_4 (13), q_5 (3612) und q_6 (4) bezeichnen (Anzahl der Antworten in Klammern). Die Anfragen q_1 bis q_3 bestehen aus verschachtelten Bedingungen, beinhalten also Ketten von Attributen. Anfrage q_4 hat keine verschachtelten Unteranfragen, aber eine Reihe von konjunktiv verknüpften einfachen Bedingungen, und q_5 beschränkt die Antworten auf einen bestimmten Wertebereich bei einem Attribut des Typs Zahl. q_6 schließlich kombiniert all diese Ausdrucksmittel in einer einzigen Anfrage. Gleichbedeutende Anfragen wurden manuell in SMWs Anfrage-sprache und in SPARQL formuliert, und die SMW-Anfragen wurden sodann durch SMW in SQL-Anfragen umgewandelt. Alle Anfragen und der vollständige Datensatz sind online verfügbar.¹⁵

Wir haben die Antwortzeiten der SQL-Anfragen auf SMWs MySQL-Datenbank mit den Zeiten verglichen, die vier verschiedene RDF-Systeme für die entsprechenden SPARQL-Anfragen benötigten. Die vier verwendeten Systeme sind Jena im Hauptspeicher, Jena auf der enthaltenen Apache-Derby-Datenbank [7], Sesame 2 im Hauptspeicher und Sesame 2 auf der nativen B-Tree-Implementierung [6]. Für dieses Experiment betrachteten wir nur die Laufzeit und ignorierten den Speicherverbrauch und die Ladezeiten, obwohl diese im praktischen Einsatz ebenfalls von Bedeutung wären. Sesame 2 im Hauptspeicher erwies sich als der deutlich schnellste Speicher, üblicherweise um den Faktor 10 bis 50 mal schneller als MySQL (mit der Ausnahme von q_3 , bei der Sesame 2 um den Faktor 5 *langsamer* war). Überraschenderweise erwies sich selbst die B-Tree-Implementierung von Sesame 2 für q_3 schneller als Sesame 2 im Hauptspeicher, war aber dennoch etwa 4-mal langsamer als MySQL. Mit Ausnahme von q_3 und q_1 benötigt die MySQL-Datenbank bis zu zweimal länger als die persistente Variante von Sesame 2, aber insgesamt muss SMWs relativ einfache Speicherimplementierung durchaus als wettbewerbsfähig angesehen werden. Auf Sesame 2 wurden jeweils alle möglichen Indices erzeugt, da die Zeiten sich ansonsten (insbesondere für q_1 , q_2 und q_4) bis um das 40-fache verlangsamten. Jena hingegen konnte mit den anderen Systemen kaum mithalten. Jena im Hauptspeicher konnte die Daten bei 6 GB verfügbarem Hauptspeicher nur mit Mühe laden und stürzte bei allen Abfragen ab. Jena auf Derby war bei q_6 ein wenig schneller als MySQL, doch ansonsten bis zu 40-mal langsamer.

Zusammenfassend erweist sich SMWs MySQL-Speicher als überraschend stark gegenüber den anderen Systemen. Sesame 2 ist im Allgemeinen schneller, bricht jedoch bei bestimmten Abfragen zusammen, während MySQL eine schwächere aber weniger stark schwankende Laufzeit aufzeigt. Wie erwartet sind Hauptspeicherlösungen im Allgemeinen deutlich

¹⁵ <http://ontoworld.org/RDF/>

schneller, doch die fehlende Persistenz und der hohe Speicherbedarf beeinträchtigen ihren Einsatz bei sehr großen Datensätzen.

Verwandte Systeme

Neben SMW entstanden in den letzten Jahren einige weitere semantische Wikis. Die wohl beachtenswertesten (und stabilsten) Systeme sind zur Zeit *IkeWiki* [15] und *MaknaWiki* [14]. In Hinsicht auf die einfache Annotation von Wikitexten sind beide Systeme von SMW inspiriert, und auch Such- und Browsing-Funktionen werden jeweils unterstützt. Beide Systeme führen Ontologien und zu einem gewissen Grad auch URIs auf Nutzerebene ein, während diese Konzepte in SMW versteckt sind. Dadurch kann man IkeWiki und MaknaWiki sinnvoll zur gemeinschaftlichen Erstellung und Wartung von Ontologien verwenden, welches nicht die wesentlichen Ziele von SMW darstellen.

MaknaWiki ist auf abgegrenzte Themengebiete zugeschnitten, für die das zur Annotation verwendete Schema im Vorfeld bekannt ist. MaknaWiki unterstützt dabei auch ausdrucks mächtige Ontologien, deren logische Konsequenzen dann bis zu einem gewissen Grad im Wiki verfügbar sind. Das Schema kann allerdings nur von Benutzern mit speziellen Rechten geändert werden. IkeWiki verwendet URIs um Elemente im Wiki zu identifizieren, hat aber eine umfangreiche grafische Benutzerschnittstelle, die das Einfügen bestimmter Annotationen stark vereinfachen kann. Nutzer mit entsprechenden Fachkenntnissen können semantische Informationen aber auch direkt in RDF-Syntax eingeben. Im Gegensatz zu MaknaWiki und SMW beruht IkeWiki nicht auf einem bereits bestehenden Wiki, sondern ist eine vollständige Neuentwicklung mit allen daraus resultierenden Vor- und Nachteilen.

Neben text-zentrierten semantischen Wikis wurde in letzter Zeit eine Reihe von gemeinschaftlichen Datenbanksystemen veröffentlicht. Beispiele hierfür sind *OntoWiki* [2], *OpenRecord*¹⁶, *Metaweb* mit der Beispielanwendung *Freebase*¹⁷ und *OmegaWiki*¹⁸. Diese Systeme bieten üblicherweise formularbasierte Eingabemasken an, um gemeinsam Datensätze zu erstellen und zu verwalten, wohingegen SMW auf Text setzt, und damit klassischen Wikis deutlich ähnlicher ist¹⁹. Von den genannten Systemen

¹⁶ <http://www.openrecord.org>

¹⁷ <http://www.freebase.com>

¹⁸ <http://www.omegawiki.org>

¹⁹ Die für SMW entwickelte Erweiterung *Semantic Forms* von Yaron Koren, ermöglicht auch in SMW die formularbasierte Eingabe von Daten. Siehe http://www.mediawiki.org/wiki/Extension:Semantic_Forms

beruht lediglich OntoWiki auf semantischen Technologien, und kann dadurch einen eingebauten RDF-Browser anbieten, während sich die anderen Implementierungen eher an relationalen Datenbanken orientieren.

Ausblick

Semantic MediaWiki wird ständig weiterentwickelt, und verschiedene zusätzliche Funktionen sind zurzeit geplant oder in Entwicklung. Dazu gehören Annotationshilfen (wie z. B. die automatische Vervollständigung von Attributnamen bei der Eingabe), weitere Funktionen für die Verwaltung des entstehenden Vokabulars im Wiki, und neue Importfunktionen für die Wiederverwendung bestehender Vokabulare. Außerdem werden SMWs Programmierschnittstellen weiter ausgebaut, um anderen Entwicklern die Erweiterung des Systems zu erleichtern. Bereits jetzt existieren verschiedene unabhängige Projekte, die zusätzliche Komponenten für SMW anbieten.

Parallel dazu planen wir Wikipedia-verwandte Demonstratoren, welche die Einsetzbarkeit und den Nutzen in diesem besonderen Szenario veranschaulichen. Voraussichtlich wird das auf den derzeitigen Testdaten beruhen [3], aber wir hoffen auch auf Daten aus anderen, sprachverarbeitenden Methoden [9, 5]. Derartige automatisch erstellte Daten können einer semantischen Wikipedia zu einem schnellen Start verhelfen, indem sie vorhandene Texte zunächst ergänzen und anschließend im Wiki korrigiert und gepflegt werden. Das entstehende System wäre die größte Sammlung gemeinschaftlich erstellten semantischen Wissens, und würde zahlreiche neue Forschungsfragen und Anwendungsmöglichkeiten erschließen.

Heute ist Semantic MediaWiki eines der bekanntesten semantischen Systeme zum gemeinschaftlichen Wissensmanagement, da es auch Wiki-Nutzer ohne besondere Expertise im Bereich semantischer Technologien anspricht. Auch die Übersetzung in inzwischen neun verschiedene Sprachen hat sicherlich zum praktischen Nutzen beigetragen. Doch obwohl SMW bereits viele faszinierende und oftmals unerwartete Anwendungen gefunden hat, bleibt das ursprüngliche Ziel – die semantische Wikipedia – die wichtigste Motivation zukünftiger Entwicklungen.

Danksagung

Die hier vorgestellte Arbeit wurde durch die Europäische Union in den Projekten SEKT, NEON und Nepomuk und durch Vulcan Inc. im Projekt Halo unterstützt. Besonderer Dank gilt Max Völkel und Heiko Haller für

die Hilfe in den frühen Phasen des Projekts, und den Mitentwicklern und Interessierten, die uns begleiten.

Literatur

1. et al., B.C.G.: OWL 1.1 Web Ontology Language Guide. Available at http://owl1_1.cs.manchester.ac.uk/ (March 2007)
2. Auer, S., Dietzold, S., Riechert, T.: OntoWiki – A tool for social, semantic collaboration. In: Y. Gil, E. Motta, R.V. Benjamins, M. Musen (eds.) Proc. 5th Int. Semantic Web Conference (ISWC'05), no. 4273 in LNCS, pp. 736–749. Springer (2006)
3. Auer, S., Lehmann, J.: What have Innsbruck and Leipzig in common? Extracting semantics from wiki content. In: E. Franconi, M. Kifer, W. May (eds.) Proc. 4th European Semantic Web Conference (ESWC) (2007)
4. Berners-Lee, T., Chen, Y., Chilton, L., Connolly, D., Dhanaraj, R., Hollenbach, J., Lerer, A., Sheets, D.: Tabulator: Exploring and analyzing linked data on the Semantic Web. In: L. Rutledge, M. Schraefel, A. Bernstein, D. Degler (eds.) Proc. 3rd Int. Semantic Web User Interaction Workshop (2006)
5. Bloehdorn, S., Blohm, S.: A self organizing map for relation extraction from wikipedia using structured data representations. In: W. Buntine, H. Tirri (eds.) Proc. Int. Workshop on Intelligent Information Access (IIIA-2006) (2006)
6. Broekstra, J., Kampman, A., van Harmelen, F.: Sesame: A generic architecture for storing and querying RDF and RDF Schema. In: I. Horrocks, J. Hendler (eds.) Proc. 1st Int. Semantic Web Conference (ISWC'02), no. 2342 in LNCS, pp. 54–68 (2002)
7. Carroll, J.J., Dickinson, I., Dollin, C., Reynolds, D., Seaborne, A., Wilkinson, K.: Jena: implementing the Semantic Web recommendations. In: S.I. Feldman, M. Uretsky, M. Najork, C.E. Wills (eds.) Proc. 13th Int. World Wide Web Conference (WWW'04 alternate track papers & posters), pp. 74–83 (2004)
8. Dale, M.: Metavid Wiki – Real time collaborative semantic audio/video metadata in MediaWiki (2007). URL <http://wikimania2007.wikimedia.org/wiki/Proceedings:MD1>. Talk presented at WikiMania2007
9. Gabrilovich, E., Markovitch, S.: Computing semantic relatedness using Wikipedia-based explicit semantic analysis. In: M. Veloso (ed.) Proc. 20th Int. Joint Conference on Artificial Intelligence (IJCAI'07) (2007)
10. Grosso, W., Eriksson, H., Fergerson, R., Gennari, J., Tu, S., Musen, M.: Knowledge modelling at the millenium: The design and evolution of Protégé. In: Proceedings of the 12th International Workshop on Knowledge Acquisition, Modeling and Mangement (KAW'99) (1999)
11. Hitzler, P., Krötzsch, M., Rudolph, S., Sure, Y.: SemanticWeb – Grundlagen. Springer (2007)
12. Krötzsch, M., Rudolph, S., Hitzler, P.: Conjunctive queries for a tractable fragment of OWL 1.1. In: K. Aberer, K.S. Choi, N. Noy (eds.) Proc. 6th Int. Semantic Web Conf. (ISWC'07). Springer (2007)

13. Krötzsch, M., Vrandečić, D., Völkel, M., Haller, H., Studer, R.: Semantic Wikipedia. *Journal of Web Semantics* (2007). To appear.
14. Nixon, L.J.B., Simperl, E.P.B.: Makna and MultiMakna: towards semantic and multimedia capability in wikis for the emerging web. In: S. Schaffert, Y. Sure (eds.) *Proc. Semantics 2006*. Österreichische Computer Gesellschaft (2006)
15. Schaffert, S.: IkeWiki: A semantic wiki for collaborative knowledge management. In: R. Tolksdorf, E.P. Bontas, K. Schild (eds.) *1st Int. Workshop on Semantic Technologies in Collaborative Applications (STICA'06)*. Manchester, UK (2006)
16. Swartz, A.: Who writes Wikipedia? (2006). Available at <http://www.aaronsw.com/weblog/whowriteswikipedia>
17. Viegas, F., Wattenberg, M., Kriss, J., van Ham, F.: Talk before you type: Coordination in Wikipedia. In: *Proc. 40th Hawaii International Conference of System Sciences*. Computer Society Press (2007)
18. Voss, J.: Collaborative thesaurus tagging the Wikipedia way (2006). Available at <http://arxiv.org/abs/cs/0604036v2>
19. Vrandečić, D., Krötzsch, M.: Reusing ontological background knowledge in semantic wikis. In: M. Völkel, S. Schaffert, S. Decker (eds.) *Proc. of the 1st Workshop on Semantic Wikis – From Wikis to Semantics* (2006). URL <http://www.aifb.uni-karlsruhe.de/WBS/dvr/publications/ontowiki.pdf>

20. Die Zeitung der Zukunft

Christoph Wieser und Sebastian Schaffert

Salzburg Research Forschungsgesellschaft;
christoph.wieser@salzburgresearch.at

Zusammenfassung: Schon lange wird spekuliert, wie wir in Zukunft Zeitung lesen werden. Werden wir am Frühstückstisch wie gewohnt in einer Zeitung aus Papier schmökern oder werden wir die Zeitung als biegsame Folie beschrieben mit elektronischer Tinte in Händen halten? Wird die Zeitung mit anderen Medien wie Radio und Fernsehen verschmelzen? Viele Varianten sind denkbar. Heute lässt sich schon ein Trend ablesen: Immer mehr Leser entdecken die Online-Zeitung als Informationsmedium, eine Voraussetzung für die Nutzung neuer Technologien in der Zeitung der Zukunft. In diesem Kapitel stellen wir Entwicklungsmöglichkeiten der Online-Zeitung dar, wie sie im Social Semantic Web möglich werden.

Die Entdeckung der Online-Zeitung

Nur wenige Jahre nach der Einführung des World Wide Web begannen Zeitungsverlage, ihre Artikel auch online zur Verfügung zu stellen. Inzwischen informiert sich bereits jeder fünfte Deutsche online. Laut Bundesverband Informationswirtschaft Telekommunikation und neue Medien BITKOM [6] wurden im ersten Halbjahr 2007 die 20 meistgenutzten News-Portale in Deutschland rund 1,8 Milliarden Mal besucht. Das entspricht einem Plus von rund 16% im Vergleich zum Vorjahr. Bei den Print-Medien erkennt man wegen der Konkurrenz durch Online-Zeitungen erste Substitutionseffekte, wie eine Trendanalyse der Fachzeitschrift Media Perspektiven [1] zeigt.

Die Vorteile von Online-Zeitungen liegen auf der Hand. Informationen sind jederzeit verfügbar und können um Audio- und Videoangebote erweitert werden, um nur zwei der Vorteile zu nennen. Das durch die Produktion einer Zeitung bedingte Korsett aus Text und Bild im festgelegten Satzspiegel war gesprengt. Jedoch setzten die Zeitungen anfangs vor allem ihre

Offline-Ausgabe zeitgleich mit dem Erscheinen in eine Online-Variante um. So bot das Internet lediglich einen zusätzlichen Informationskanal.

Heute gehen Verlage zunehmend zu der Strategie „Online first“ über, ein Indiz dafür, dass die Online-Zeitung stark an Bedeutung gewonnen hat. So veröffentlicht inzwischen beispielsweise die deutsche Bild-Zeitung Meldungen zuerst online, bevor die Redakteure darüber entscheiden, was in der Papier-Version des nächsten Tages erscheint. Das bietet den Lesern der Internet-Ausgabe einen Zeitvorteil, da sie nicht auf Druck und Auslieferung warten müssen. Jederzeit können die Redakteure Artikel einstellen, überarbeiten oder ergänzen, wenn neue Fakten bekannt werden.

Dennoch sind Zeitungsinhalte – online wie offline – bisher noch statisch: Jeder Leser, der die Zeitung aufschlägt oder die entsprechende Internetseite ansteuert, sieht die gleichen Meldungen. Der Leser wird also die Meldungen überfliegen, bleibt an denen hängen, die ihm auf den ersten Blick interessant erscheinen, überspringt die anderen, und navigiert so durch die verschiedenen Ressorts. Und wenn er etwas Bestimmtes sucht, dann muss der Leser jeden Artikel anlesen, um herauszufinden, ob er das gesuchte Thema berührt. Hierbei kann auch die Suchfunktion in der Internetpräsenz nur bedingt helfen: Aktuell kann man mit der Suchfunktion nur nach den exakten Schlagworten in einem Text suchen. Verwendet der Autor beispielsweise ein Synonym oder streift der Artikel das relevante Thema, ohne aber den in das Suchfenster eingegebenen Begriff zu enthalten, wird ein Artikel nicht gefunden. Beispielsweise kann ein Kultur-Artikel über ein Konzert mit Stücken von Henry Purcell nur unter dem Suchbegriff „Barock“ gefunden werden, wenn das Wort „Barock“ auch tatsächlich im Artikel enthalten ist. Die Folge: Der Leser muss sich überlegen, welche Worte sein Thema betreffen könnten, all diese nacheinander in der Suche testen und die gefundenen Artikel auf ihre Relevanz prüfen. Ein ziemlich umständlicher Prozess.

Zusammengefasst heißt das: Wer eine Papierzeitung kauft, hat zwar das Leseerlebnis, wenn er in den Seiten blättert, jedoch bekommt er keine top-aktuellen Informationen und muss pauschal eine Artikelsammlung kaufen, auch wenn ihn davon diverse Artikel und wahrscheinlich ganze Ressorts nicht interessieren. Dafür bekommt er aber einen umfassenderen Überblick über das Geschehen in der Welt, wenn er alle Artikel anliest, um herauszufiltern, was er zu Ende lesen möchte. Greift er hingegen zu Tastatur und Maus, um eine Online-Zeitung zu nutzen, muss er entweder ebenfalls alle Seiten, Ressorts und Artikel durchgehen, oder die Volltext-Suche verwenden.

Bei dem stetig wachsenden Angebot (1997 waren laut Neuburger et al. erst 50 Zeitungen im World Wide Web vertreten [1]) wird die Suche nach richtigen Inhalten immer aufwändiger. Deswegen werden Online-Zeitung in Zukunft verstärkt Wert auf die Unterstützung des Lesers bei der Naviga-

tion legen, so dass Inhalte auf der eigenen News-Plattform gefunden werden statt auf den News-Plattformen der Konkurrenten. So können Online-Zeiten ihre Einnahmen durch Online-Werbung steigern.

Szenarios für die Zeitung der Zukunft

Im folgenden Abschnitt stellen wir Szenarios vor, um Anwendungen für Zeitungen im Social Semantic Web aus Leser-Sicht zu illustrieren. In späteren Abschnitten gehen wir auf die einzelnen Anwendungsfälle der Szenarios ein.

Szenario 1: Schmökern am Morgen

In vielen Haushalten spielt sich täglich ein Automatismus ab: Der allmorgendliche Gang zur Haustüre und dann in die Kälte, um die Zeitung aus dem Briefkasten zu anglen. In Zukunft könnte eine der ersten Handlungen am Morgen nicht mehr der Gang zum Briefkasten sein. Stattdessen liegt die Zeitung der Zukunft wie schon gestern auf dem Tisch. Genauer gesagt, liegt das Medium, beispielsweise eine elektronische Folie, noch immer auf dem Tisch. Beim Aufrollen der Folie, verbindet sich die Zeitung mit einem drahtlosen Funknetz und holt die jüngsten Nachrichten aus dem Internet. Einen Redaktionsschluss wie bei Papier-Zeitungen gibt es also nicht mehr. Ständig ist die Zeitung auf dem aktuellen Informationsstand. Einen Prototyp stellten E ink Research und Philips bereits im Jahr 2006 vor [3]. Laut Hersteller ist die belgische Zeitung *de Tijd* die erste Zeitung auf elektronischem Papier.

Beim ersten Blick auf die Seite, fällt im Unterschied zur traditionellen Zeitung auf, dass jeder Leser eine andere Auswahl an Artikeln präsentiert bekommt. So bekommen Frau und Herr Schuster nun normalerweise einen Überblick über das aktuelle politische Geschehen, während ihr Sohn Stephan auf der ersten Seite die Sportergebnisse präsentiert bekommt. Je nach Interessen und Vorlieben wird für jeden Leser ein individuelles Angebot an Informationen geschneidert.

Heute, an einem Tag in der Zukunft, hat ein Artikel für die Eltern Vorrang vor der Politik, wie auch für die anderen Bewohner derselben Straße. In zwei Wochen werden Anwohnerparkplätze eingeführt. Ohne speziellen Park-Ausweis ist dann das Parken vor dem Haus nicht mehr erlaubt. Deswegen wird der Artikel mit der Überschrift „Anwohnerparken kommt in zwei Wochen“ weit vorne aufgeführt. Für Leser aus anderen Stadtteilen ist dieser Artikel weniger relevant und wird deswegen weiter hinten in der

Zeitung platziert. Familie Schuster und ihre Nachbarn freuen sich dagegen über die Information, so dass sie nun noch rechtzeitig einen Park-Ausweis bestellen können.

Ein genauerer Blick auf den ersten Artikel lässt weitere Unterschiede zum gewohnten Aussehen der Zeitung noch vor ein paar Jahren erkennen. In einem Kästchen neben dem Text mit Bildern und Videos, werden Zusatzinformationen und -dienste angeboten. So gibt es eine maschinenlesbare Kurzbeschreibung des Artikels. Die Kurzbeschreibung hilft Herrn Schuster bei der Orientierung im Artikel, denn einzelne Worte sind mit entsprechenden Textpassagen verlinkt. Ein Klick genügt und Herr Schuster kann zu einer beliebigen Textpassage springen, um mehr Details zu erfahren. Anhand der Kurzbeschreibung können automatisch auch ähnliche Artikel verlinkt werden. Dadurch kann man sich in einem Themengebiet wie „deutsch-amerikanische Beziehungen“ schnell zurechtfinden, wenn man in den letzten Tagen noch keine Artikel über die letzten Entwicklungen gelesen hat.

Die Kurzbeschreibung stammt von einem Programm, das Texte automatisch analysiert und dann Vorschläge zu behandelten Themen unterbreitet. Bereits heute bieten Tools wie Calais [4] solche Dienste an. Den letzten Feinschliff der Beschreibung haben Redakteure und Leser geleistet, die den Artikel schon vor Herrn Schuster gelesen und bewertet haben. Das ist ein Vorteil an einem sozialen Netz. Man kann das Wissen und die Erfahrung von vielen anderen Lesern nutzen. Schon seit dem Jahr 2002 gibt es den Dienst last.fm, der auf einem sozialen Netz aufbaut. Nutzer hören dort Musik von ihrem persönlichen Radio-Sender. Die Informationen zur Auswahl der richtigen Stücke basiert auf Erfahrungen anderer Nutzer, mit ähnlichem Geschmack.

Neben der Möglichkeit einen Artikel zu beschreiben, um ihn für andere Benutzer besser auffindbar zu machen, kann auch die Qualität bewertet werden. Die Redakteure wissen so direkt von den Lesern, ob Sie nachbessern müssen, um einen Artikel noch attraktiver zu gestalten.

Szenario 2: Citizen Journalist

Auf dem Weg zur Arbeit mit dem Zug wird Herr Schuster Zeuge eines Beinahe-Unfalls. Aus voller Fahrt hat sein Zug eine Notbremsung eingelegt, weil ein Sturm einen Baumstamm auf die Gleise geweht hat. Die Weiterfahrt des Zuges ist blockiert.

Als einer der ersten vor Ort des Geschehens holt Herr Schuster sein Mobiltelefon aus der Tasche und fotografiert die Lokomotive vor dem umgeknickten Baumstamm. Beim Auslösen wird nicht nur die Zeit gespei-

chert, zu der das Foto geschossen wurde, sondern auch der Ort wird mit Hilfe eines GPS-Ortungssystems aufgezeichnet. Während Herr Schuster das Bild drahtlos an die Zeitung schickt, schreibt ein anderer Fahrgast eine kurze Meldung über den Unfall. Auch die Meldung wird umgehend an die Zeitung geschickt.

In der Redaktion können die beiden Nachrichten leicht automatisch einander zugeordnet werden, weil Ort und Zeit in der semantischen Beschreibung der Nachrichten übereinstimmen. Auf diese Weise treffen in der Redaktion dutzende Nachrichten ein.

Wegen der genauen semantischen Beschreibung der Nachrichten aber, muss nicht jeder Leser alle veröffentlichten Nachrichten durchforsten, sondern bekommt in der Regel nur für ihn interessante Nachrichten zu sehen. Davon profitieren auch die anderen Fahrgäste im Zug, die schon vor der Ansage des Zugbegleiters im wahrsten Sinne im Bilde sind.

Leser, die selbst an der Bereitstellung von Informationen mitwirken, heißen Citizen Journalists. Durch sie entsteht eine immens hohe redaktionelle Dichte. Sie decken alle Gebiete als journalistische Laien ab, die Journalisten nie erreichen können. Zwar werden Nachrichten von Citizen Journalists in der Zeitung veröffentlicht. Allerdings sind Beiträge von Citizen Journalists klar als solche gekennzeichnet, um klarzustellen, dass die Informationen nicht gesichert sind. Erst wenn ein Redakteur eine Nachricht bestätigt, wird sie nicht mehr als unsicher gekennzeichnet. Sobald eine Nachricht den Status gesichert erlangt, kann sie sinnvoll weiterverwendet werden. Hilfe leisten Leser der Zeitung der Zukunft den Redakteuren bei der Freigabe von Artikeln aus der Feder von Citizen Journalists. In Herrn Schusters Zug sind dies andere Fahrgäste, die sofort ihre Zeitung aufgerollt haben, um zu erfahren, warum ihr Zug nicht weiterfährt.

Sobald eine Meldung als gesichert gilt, können im Falle einer blockierten Bahnstrecke andere Leser informiert werden. Besonders freuen sich Leser, die später in den Zug einsteigen wollten.

Szenario 3: Gezielte Informationssuche

Die Zeitung der Zukunft hat einen weiteren Vorteil. Informationen müssen nicht mehr über Volltext-Suche gefunden werden, sondern können über ihre tatsächliche Bedeutung abgefragt werden.

Auf dem Weg nach der Arbeit zurück nach Hause rollt Herr Schuster die Zeitung erneut auf. Es ist bald Wochenende, und er plant mit seinen Kindern, etwas zu unternehmen. Die Zeitung der Zukunft ist ihm dabei behilflich. Statt wie früher die Volltext-Suche unterstützt Herrn Schuster nun die neue Semantische Suche. So trägt Herr Schuster in der Suchmaske

ein: „Veranstaltungen für Kinder“. Zusätzlich schränkt Herr Schuster die Suche noch stärker mit Hilfe einer Zeitachse ein, so dass nur Veranstaltungen am Wochenende in der Ergebnisliste auftauchen. Nach der zeitlichen Eingrenzung wendet sich Herr Schuster der Landkarte unter der Zeitachse zu, um den Veranstaltungsort einzugrenzen. Er markiert ein Gebiet, das von den Schusters innerhalb einer Stunde mit öffentlichen Verkehrsmitteln erreichbar ist.

Die Mühe bei der Eingabe wird belohnt. Eine Liste von Veranstaltungen erscheint, die geeignete Veranstaltungen nach Relevanz ordnet. Dabei sind schon alle Veranstaltungen aussortiert, die bereits ausgebucht sind oder nicht mehr dem Alter von Herrn Schusters Kindern entsprechen. Früher wären solche Informationen nur schwer herauszufinden gewesen. Herr Schuster hätte die Liste der Veranstaltungen in der Zeitung durcharbeiten müssen. Für Detailinformationen wären noch Recherchen auf anderen Web-Sites notwendig gewesen. Mit der Zeitung der Zukunft ist Herrn Schuster die Auswahl aber nicht schwer gefallen.

Mit seiner Suche schärft Herr Schuster darüber hinaus automatisch sein Profil. Bei späteren Abfragen kann er mit Informationen aus seinem Profil bei der Suche unterstützt werden. Neben Herrn Schuster könnte auch die Zeitung der Zukunft von seinem Profil profitieren. Die Informationen könnten genutzt werden, um Werbung gezielter einzusetzen. So erhielte Herr Schuster nur noch Werbebotschaften, die ihn tatsächlich interessieren. Allerdings wurde der Ansatz der personalisierten Werbung bereits in der Vergangenheit kontrovers diskutiert. Bei Nutzern sozialer Netze stieß die personalisierte Werbung auf breite Ablehnung. Laut einer Umfrage von Spiegel-Online vom November 2007 [5] lehnen rund 77% der Leser personalisierte Werbung ab. Die Zukunft wird zeigen, ob sich personalisierte Werbung stärker durchsetzen wird als bisher.

Die Semantik von Artikeln

Aus den Szenarios wird deutlich, dass Zeitungen ein großes Potenzial haben, uns Menschen in Zukunft bei der Bewältigung der Informationsflut zu unterstützen. Ein wichtiger Schritt auf dem Weg zur Zeitung der Zukunft ist, Computern die Bedeutung von Artikeln verständlich darzustellen [2]. Gegenwärtig haben Computer einen ähnlichen Blick auf Zeitungsartikel wie wir auf fremdsprachige Texte. Der Blick auf Artikel einer japanischen Zeitung gibt nur wenige Informationen preis, wenn man kein Japanisch beherrscht. Vielleicht können wir im japanischen Text errahnen, wo eine Überschrift steht oder wir können Firmennamen entziffern. Der Rest ist jedoch vollkommen unverständlich. Genauso geht es heute dem Computer.

Semantische Annotation mittels Tagging

Als einfache Methode für die semantische Anreicherung von Zeitungsartikeln gibt es das im Internet bereits weit verbreitete Tagging. Unter Tagging wird das Auszeichnen von Artikeln mit Worten (sog. Tags) bezeichnet. Schon viele Online-Zeitungen haben diese Technik für sich entdeckt und erlauben ihre Artikel mit Tags zu verschlagworten. Leser profitieren von solchen Tags bei der Suche nach neuen und dem Wiederfinden alter Artikel.

Eine besonders prominente Anwendung von Tags ist die sogenannte Tag-Cloud. In einer Tag-Cloud werden Tags gelistet und abhängig von Ihrer Vergabehäufigkeit in verschiedenen Schriftgrößen dargestellt. Je häufiger und damit wichtiger ein Tag ist, desto größer und auffälliger wird das Tag in der Tag-Cloud angezeigt. Beispielsweise könnte ein Artikel mit dem Tag „Fußball“ ausgezeichnet werden. In der Tag-Cloud könnte dann das Tag Fußball angezeigt werden. Bei einem Klick auf das Tag erscheinen dann alle Artikel, die mit „Fußball“ getaggt sind. Dabei ist die Tag-Cloud nicht statisch. Je näher beispielsweise der Termin für ein wichtiges Fußballspiel rückt, desto öfter werden Leser das Tag Fußball vergeben und umso auffälliger würde in Folge das Wort Fußball in der Tag-Cloud platziert.

Tagging funktioniert aktuell auf Ebene des gesamten Artikels. Die Beschreibung der Semantik von Artikeln könnte aber noch viel tiefer gehen. Zeitungen könnten den Informationswert Ihrer Artikel erheblich steigern, indem auch auf Inhaltsebene die Semantik von Artikeln verfügbar wäre. So könnte ein Artikel über ein Fußballspiel auch Informationen über, den Ausgang des Spiels, den Torschützen und den Reporter direkt bieten.

Typisierte Tags

Je nach vergebenen Haupttags könnten zusätzlich typisierte Tags auf Textebene bereitstehen, um Stellen im Text auszuzeichnen. Durch eine Typisierung wird dem Computer die Bedeutung von Tags bekannt gegeben. So eröffnet die Typisierung dem Computer einen Zugang zur automatischen Verarbeitung von Tags. Tags von Tagging- oder Social-Bookmarking-Diensten wie del.icio.us und mister-wong.com sind untypisiert. Zwar können untypisierte Tags wie „Fußball“ Menschen weiterhelfen, für den Computer sind sie jedoch ohne Erklärung bedeutungslos.

Mit typisierten Tags könnte der Computer automatisch nützliche Schlussfolgerungen ziehen. Bei einem Fußballspiel könnten in einem Fenster neben dem Text Typen gelistet sein wie Endergebnis oder Schiedsrichter, die dann von Redakteuren oder Lesern vergeben werden könnten. An Hand solcher semantischer Auszeichnungen werden beispielsweise

automatische Ergebnislisten möglich. In politischen Artikeln könnten Aussagen von Politikern leicht miteinander verglichen werden.

Eine semantische Auszeichnung auf Text-Ebene statt auf Ebene des Artikels als Ganzes, wäre ein großer Anreiz, die Zeitung intensiver zu verwenden. So könnten beispielsweise die letzten Ergebnisse der Fußballmannschaft einfach gefunden werden. Auch auf Seiten der Redakteure gäbe es direkte Vorteile. Artikel könnten einfach auf Informationsgehalt überprüft werden und so die Qualität von Artikeln gesichert werden.

Qualitätssicherung für User-Generated Content

Neben dem semantischen Auszeichnen von bereits bestehenden Artikeln beteiligen sich Leser auch an der Gestaltung der Zeitung und tragen aktiv mit eigenen Artikeln zum Inhalt bei. Damit gibt es praktisch keinen Ort mehr, von dem aus die Zeitung nicht mehr regelmäßig mit den neuesten Nachrichten versorgt werden kann. Mit der Einführung von sog. Citizen Journalists besteht jedoch potenziell die Gefahr, dass Meldungen zwar schnell und von allerorts eintreffen, die Richtigkeit von Meldungen aber nur schwer geprüft werden kann. Einerseits sind zwar hochaktuelle Nachrichten gewünscht, auf der anderen Seite sollen diese aber auch möglichst objektiv sein.

Eine Lösung zur Qualitätssicherung besteht aus einem Verfahren zur Überführung von Leser-Artikeln in redaktionell gesicherte Artikel im Zusammenspiel von Lesern und Redakteuren. In diesem Verfahren gibt es drei Qualitätsstufen.

- Die *unterste Stufe* erreicht automatisch jeder Artikel, der von einem Leser geschrieben wurde. Artikel auf der untersten Stufe sind in der Regel hochaktuell, gelten aber noch als ungesichert. Hier treffen Bilder von Unfällen oder Informationen über Abstürze von Aktienkursen ein. Gerade bei ungesicherten Artikeln ist eine auffällige Markierung wichtig, so dass Leser gewarnt sind, dass enthaltene Informationen leicht eine Fehlinformation enthalten können.
- Auf die *mittlere Stufe* gelangt ein Artikel, wenn er von Lesern als objektiv eingestuft wurde. Dabei können nur Leser einen Artikel als objektiv einstufen, wenn sie sich eine entsprechende Reputation erarbeitet haben. Die mittlere Stufe erlaubt eine Bewertung neuer Artikel durch Laien. Verschiedene Systeme können die Reputation von Lesern zu einem Thema beurteilen. Dazu zählen die Bewertung von Beiträgen und Einstufungsaktionen des Lesers durch andere Leser und Redakteure. Auf der mittleren Stufe sind Meldungen normalerweise schon sehr objektiv und enthalten nur noch in Ausnahmefällen falsche Informationen.

- Die *höchste Stufe* enthält nur Artikel, die redaktionell gesichert sind. Fehlinformationen sind auf dieser Stufe höchst unwahrscheinlich, da Redakteure und Nachrichtenagenturen für die Authentizität verantwortlich zeichnen.

Neue Artikel gelangen in das System nur über die unterste Stufe, falls sie von Lesern geschrieben wurden oder über die höchste Stufe, wenn sie von Redakteuren geschrieben wurden. Ein Abstieg von einer höheren auf eine niedrigere Stufe ist nicht möglich. Sollte sich herausstellen, dass ein Artikel auf einer beliebigen Stufe falsche Informationen enthält, wird er aus der Zeitung entfernt und dem Redakteur oder der Leserschaft zum Nachbessern vorgelegt.

Dieses Verfahren ermöglicht eine hohe Aktualität von Nachrichten bei gleichzeitig möglichst hoher Authentizität. Teilweise werden ähnliche Systeme schon heute bei Online-Zeitungen wie webnews.de oder onlinezeitung.de eingesetzt.

Semantische Suche

Die Mühe, die Redakteure und Leser in die semantische Beschreibung von Artikeln investiert haben, zahlt sich bei der Suche aus. Wie bereits erwähnt, kann man nun nach Themen suchen. Nicht wie bisher bei der Volltext-Suche ist man darauf angewiesen, möglichst gut zu raten, welche Phrasen in einem Artikel enthalten sind. Die semantische Suche geht aber weit über die Themen-Suche hinaus.

Kartenbasiert können Artikel gefunden werden, die mit Koordinaten versehen wurden. Auf einer Karte kann dann der Ort oder der Bereich angezeigt werden, auf den sich ein Artikel bezieht. Bei einem Artikel über ein Fußballspiel wäre der Ort des Fußballspiels auf der Karte eingezeichnet. Ebenso wären verwandte Artikel in der Karte eingezeichnet, wie beispielsweise Bilder von jubelnden Fans bei einem Auto-Korso durch die Innenstadt. Intuitiv lassen sich die Gebiete mit Rechtecken oder frei wählbaren Formen selektieren, um die Auswahl an Artikeln einzuschränken. So könnten Berichte über Fußballspiele in der Umgebung des Wohnortes einfach gefunden werden.

Zeitlich können Artikel ebenso visualisiert werden. Statt auf einer Karte werden Artikel in diesem Fall mit Hilfe einer Zeit-Achse zeitlich eingeordnet. Ähnlich wie bei der kartenbasierten Suche kann der Leser auch hier Zeiträume selektieren, in denen Artikel veröffentlicht wurden oder in denen im Artikel beschriebene Ereignisse stattfinden. Schon lange ist eine zeitliche Selektierung mit exakten Zeiträumen möglich. Eine Behandlung von Anfragen mit ungenauen oder symbolischen Zeitangaben ist allerdings

noch nicht vollständig gelöst. Beispielsweise ist die Zeitangabe „morgen früh“ schwierig zu deuten, weil sie vom Profil des Fragestellers abhängt. So kann „morgen früh“ 5 Uhr oder 9 Uhr am folgenden Tag bedeuten.

Die Semantische Suche kann in viele Facetten aufgegliedert werden, die für sich schon gute Antworten auf Suchanfragen liefern.

Beeindruckender als die Einzelergebnisse ist aber das Zusammenspiel vieler Facetten, die eine sehr gute Eingrenzung von Ergebnissen zulassen, wie das beschriebene Szenario „Gezielte Informationssuche“ mit der Suche nach einer geeigneten Veranstaltung demonstriert.

Benutzerprofile

Die Semantik von Artikeln lässt sich nicht nur aktiv nutzen, wie bei der Semantischen Suche, sondern auch passiv, um Artikel automatisch nach persönlichen Vorlieben des Lesers auszuwählen. Mit Hilfe eines Nutzerprofils kann der Leser aktiv oder passiv darauf Einfluss nehmen, welche Nachrichten er auf der Seite 1 einer Online-Zeitung vorfindet. Aktiv bedeutet in diesem Fall, dass er in seinem Profil bestimmte Angaben über sich hinterlegt, wie zum Beispiel seinen Wohnort, sein Hobby oder ein Thema, das ihn aktuell interessiert. So bekommen Meldungen beispielsweise aus dem Stadtteil des Lesers mehr Gewicht.

Außerdem kann in der Zeitung der Zukunft (als passive Einflussnahme) das Leserverhalten des Nutzers ausgewertet werden: Klickt der Leser beispielsweise besonders häufig Artikel über Sicherheitslücken seines Betriebssystems an, bekommen Artikel über IT-Risiken eine höhere Relevanz zugeordnet und erscheinen prinzipiell weiter oben auf der individuellen Seite 1 des Nutzers. Dieses Prinzip machen sich beispielsweise auch die Nachrichtendienste digg.com und webnews.de zu Nutze: Texte, die viele Leser als relevant bewerten, wandern weiter nach oben, das kollektive Interesse im sozialen Netz entscheidet darüber, was vorne steht und damit mehr Aufmerksamkeit bekommt. Bei der Zeitung der Zukunft muss man als Leser nun aber nicht mehr hoffen, dass das Interesse dem Massengeschmack entspricht, sondern bekommt eine individuelle Nachrichtensammlung anhand nur der persönlichen Interessen.

Neue Nutzungsmöglichkeiten

Das Social Semantic Web bietet Online-Zeitungen viele Möglichkeiten ihre klassischen Angebote weiterzuentwickeln. Leser profitieren vor allem von der individuellen Auswahl aus der großen Flut von verfügbaren Informationen. Neben traditionellen Angeboten der Online-Zeitungen lassen

sich im Social Semantic Web auch neue Dienste anbieten, die weitere Leser binden dürften.

Notifizierung bei interessanten Ereignissen

Bisher besucht man die Webseiten von Online-Zeitungen regelmäßig, um auf dem jüngsten Informationsstand zu sein. Mit Hilfe von Benutzerprofilen kann die Zeitung Ihre Leser auch über sog. Push-Dienste benachrichtigen, wenn Nachrichten veröffentlicht werden, die für einen Leser von besonderem Interesse sind.

Eine Notifizierung könnte auch bei detaillierten Suchanfragen mit Orts- und Zeit-Angabe angeboten werden, die keine Ergebnisse liefern. Erst bei der Veröffentlichung von Meldungen, die der Suchanfrage entsprechen, würde der Leser informiert. Ein Leser könnte so beispielsweise die Eckdaten von einem Brand, bei dem er soeben Zeuge wurde, auf den Online-Seiten der Zeitung suchen. Wenn noch keine Artikel angeboten werden, ließe sich der Leser informieren, sobald aktuelle Informationen verfügbar wären. Einen ähnlichen Dienst bietet Google bereits heute an. Mit „Google Alert“ können Nachrichten am Web automatisch durchforstet werden. Allerdings ist Google Alert noch nicht im Social Semantic Web angekommen und funktioniert deswegen nur auf Basis der Volltext-Suche.

Der Informationsgehalt von Artikeln

Eine interessante Anwendung für Redakteure wäre, den Informationsgehalt von Artikeln zu überprüfen. Ein Redakteur könnte mit Hilfe einer detaillierten semantischen Beschreibung eines Artikels leicht herausfinden, ob Informationen enthalten sind, die normalerweise in ähnlichen Artikeln angeboten werden. Beispielsweise könnte ein Redakteur darauf aufmerksam gemacht werden, wenn bei einem Artikel über ein Fußballspiel das konkrete Spielergebnis fehlt. Automatisch könnten auch Artikel von konkurrierenden Zeitungen daraufhin untersucht werden, ob schon weiterführende oder neue Informationen vorliegen.

Conclusio

Wie das Kapitel zeigt, bietet das Anwendungsfeld Online-Zeitung eine Reihe von Einsatzmöglichkeiten für Technologien des Social Semantic Web mit praktischem Nutzen für den Leser. Die inhaltliche Abgrenzbarkeit (closed world) des Anwendungsgebietes im Vergleich zum quasi un-

endlichen World Wide Web (open world) lässt hoffen, dass Online-Zeitungen eine gute Keimzelle für eine größere Verbreitung von Social Semantic Web-Technologien ist.

Im Social Semantic Web als Weiterentwicklung des heutigen World Wide Web könnten sich Zeitungen einen festen Platz als Trusted Information Provider sichern. Aktuelle Anbieter von sozialem Wissen wie Wikipedia haben schon fast den Charakter von Online-Zeitungen. Dies wird deutlich, wenn man auf die Eingangs-Seite von Wikipedia oder wiki-news.org schaut und sich über aktuelle Ereignisse informieren lassen kann. Allerdings kämpfen offene Wissensplattformen mit der Authentizität. Es ist schwer nachzuprüfen, ob Informationen richtig sind oder ob es sich um Fehlinformationen handelt. Online-Zeitungen könnten in Zukunft als professionelle Anbieter die Sicherung von Informationen übernehmen und so eine wichtige Rolle im Social Semantic Web spielen.

Technisch müssen bisherige Systeme von Online-Zeitungen für Anwendungen im Social Semantic Web aufgerüstet werden. Weitere Komponenten, wie zum Speichern von sozialem Wissen, zur automatischen Analyse von Texten und zum Berechnen für logische Schlussfolgerungen müssten eingebaut werden. Das Forschungsprojekt *Future Content Platforms* des Salzburg New Media Lab bei Salzburg Research hat die Entwicklung der Zeitung der Zukunft zum Ziel. In Zusammenarbeit mit den Salzburger Nachrichten werden dort Technologien des Social Semantic Web erprobt.

Literatur

1. Christoph Neuberger, Jan Tonnemacher, Matthias Biebl, Andr Duck: Die deutschen Tageszeitungen im World Wide Web. Redaktionen, Nutzer, Angebote, in: Media Perspektiven 12/1997, S. 652–662
2. Adrian Holovaty, „A fundamental way newspaper sites need to change“, <http://www.holovaty.com/blog/archive/2006/09/06/0307/>, aufgerufen am 20.03.2008
3. Belgian newspaper publishes on E-paper, <http://www.freshtechology.net/gadgets-tijd-epaper.php>, besucht am 21.3.2008
4. OpenCalais, <http://www.opencalais.com/>, aufgerufen am 20.03.2008
5. „Weber spähen Surfverhalten aus“, Spiegel-Online, 7.11.2007, <http://www.spiegel.de/netzwelt/web/0,1518,515932,00.html>, aufgerufen am 20.03.2008
6. BITKOM, „Jeder fünfte Deutsche liest Nachrichten im Internet“, http://www.bitkom.org/de/presse/49914_47223.aspx, aufgerufen am 28.3.2008

21. Das Semantic Web als Werkzeug in der biomedizinischen Forschung

Holger Stenzhorn^{1,2} und Matthias Samwald^{2,3}

¹ Institut für Medizinische Biometrie und Medizinische Informatik, Universitätsklinikum Freiburg, Freiburg im Breisgau, Deutschland

² Digital Enterprise Research Institute (DERI), National University of Ireland, Galway, Irland

³ Institut für Medizinische Experten- und Wissensbasierte Systeme, Medizinische Universität Wien, Wien, Österreich

holger.stenzhorn@uniklinik-freiburg.de,
matthias.samwald@meduniwien.ac.at

Zusammenfassung: In der biomedizinischen Forschung werden besonders in den letzten Jahren vermehrt enorme Mengen an neuen Daten produziert und diese in Folge verstärkt per Internet veröffentlicht. Viele Experten sehen in dieser Vorgehensweise die Chance zur Entdeckung bisher unbekannter biomedizinischer Erkenntnisse. Um dies jedoch zu ermöglichen, müssen neue Wege gefunden werden, die gewonnenen Daten effizient zu verarbeiten und zu verwalten. In dem vorliegenden Artikel werden die Möglichkeiten betrachtet, die das Semantic Web hierzu anbieten kann. Hierfür werden die relevanten Technologien des Semantic Web im speziellen Kontext der biomedizinischen Forschung betrachtet. Ein Fokus liegt auf der Anwendung von Ontologien in der Biomedizin: Es wird auf deren Vorteile eingegangen, aber auch auf möglichen Probleme, die deren Einsatz in einem erweiterten wissenschaftlichen Umfeld mit sich bringen können.

Einleitung

Wie auch in anderen Forschungsgebieten, wird sowohl in der Biologie als auch in der Medizin neu gewonnenes Wissen in wissenschaftlichen Publikationen der Öffentlichkeit zugänglich gemacht. In den letzten Jahren jedoch ist die Menge der gewonnenen Daten in einer bisher nicht gekannten Geschwindigkeit, z. B. durch technologische Fortschritte in der Genforschung, massiv angewachsen. Einige Experten stehen dieser Sammlung an Daten mit Skepsis gegenüber und bezweifeln deren Nutzen für die Wissen-

schaft. Andere Experten wiederum sehen aber gerade in diesem exponentiellen Wachstum die Chance, das Verständnis biomedizinischer Vorgänge zu beschleunigen und damit einhergehend, eine wissenschaftliche Revolution einzuläuten: Für sie ist nicht die schiere Menge an produzierten Daten das Problem, sondern vielmehr das Fehlen von einfachen Methoden, diese effizient zu verarbeiten, zu organisieren und schließlich zu „verstehen“.

In diesem Kontext stellt das Internet zwar eine einfache Möglichkeit bereit, Daten schnell weltweit zu veröffentlichen. Dadurch jedoch, dass unterschiedliche Organisationen mit unterschiedlichen Zielrichtungen Daten sammeln bzw. entwickeln, sind diese meist weit über das Internet verstreut und voneinander isoliert. Damit einhergehend besitzen diese oft keine übergreifende, einheitliche Struktur, sondern verwenden vielmals lokal optimierte Datenschemata. In vielen Fällen fehlt eine computerverwertbare Struktur komplett, z. B. bei wissenschaftlichen Texten oder Dokumentationen. Zudem stellt die Tatsache ein großes Problem dar, dass es zumeist sehr schwer, wenn nicht gar unmöglich ist, die Qualität bestimmter Quellen sicher einzuschätzen, um somit deren Wert für die eigene Arbeit richtig zu beurteilen.

Kombiniert man letztlich all diese Punkte miteinander, so wird schnell klar, dass es selbst für erfahrene Experten im biomedizinischen Bereich schwer ist, alle zu einem bestimmten Thema (aus ihrem Bereich) verfügbaren, relevanten Informationen zu finden, geschweige denn diese in Folge gründlich und richtig auszuwerten.

Die Menge an biomedizinischen Daten ist explosionsartig gewachsen. Experten brauchen daher Instrumente, die sie bei der Arbeit mit diesen Daten unterstützen.

Eine Möglichkeit zur effizienten Lösung dieses Problems stellen z. B. erweiterte Suchfunktionen für wissenschaftliche Veröffentlichungen dar, welche Experten kontextsensitiv unterstützen und durch ihre Suche leiten. Um solch eine Funktion zu realisieren, müssen bestehende Publikationsdatenbanken um ontologiebasierte Komponenten erweitert werden, welche alle relevanten biomedizinischen Konzepte und deren logische Beziehungen mit einschließen. Diese Komponenten können wiederum Ontologien mit weiteren semantisch beschriebenen biomedizinischen Datenquellen kombinieren, die im Internet verfügbar sind und verschiedene, konkretere Spezialgebiete behandeln. Diese erweiterte Suchfunktion würde beispielsweise das Finden von Artikeln ermöglichen, welche die vom Benutzer angegebenen Schlüsselwörter zwar nicht direkt enthalten, jedoch konzeptuell mit diesen eng verwandt und somit für die gegebene Suche ebenfalls relevant sind. (Erste Schritte in diese Richtung werden bereits von Litera-

tursuchmaschinen wie GoPubMed [23] oder dem Project Prospect von RSC Publishing [14] unternommen.)

Zudem könnten wichtige zusätzliche Informationen, wie z. B. Verweise auf Experimentaldaten, mitgeliefert werden: Als Beispiel würde die Suche nach einem speziellen Gen auch Artikel über funktionell ähnliche Gene einschließen und auch auf Daten in (semantisch annotierten) Forschungsdatenbanken hinweisen, wie z. B. Bilder mikroskopischer Abbildungen (siehe Abb. 3).

Der folgende Artikel beschreibt die technischen und organisatorischen Grundlagen, um ein solches Beispiel praktisch realisieren zu können. Hierfür wird zunächst auf die grundsätzlichen Konzepte des Semantic Web im Kontext der Biomedizin eingegangen. Gefolgt wird dies von einer Beschreibung des Begriffs der Ontologie und bestehender biomedizinischer Ontologien. Es wird auf Vorteile des Einsatzes von Ontologien eingegangen, aber auch auf mögliche Probleme, die beim nicht-trivialen Einsatz von Ontologien auftreten (mit Ansätzen zu deren Vermeidung und Lösung).

Das biomedizinische Semantic Web im Überblick

Über viele Jahre hinweg war das Semantic Web kaum mehr als eine Vision, die von Tim-Berners Lee, dem „Erfinder“ des World Wide Web propagiert wurde [2,18]. Es bestand einzig aus einer Ansammlung von neuartigen Technologiestandards, die noch nicht ausgereift genug waren, um sie in alltäglichen Anwendungsszenarien einsetzen zu können, und für welche keine praxistauglichen Softwarewerkzeuge existierten. Heute sind diese Technologien jedoch bereits soweit ausgereift, dass man einen starken Anstieg verfügbarer Anwendungen sehen kann, welche für den praktischen Einsatz relevant sind. Andererseits tauchen natürlich auch hier die typischen Probleme und „Kinderkrankheiten“ beim Einsatz neuer Technologien auf: Es entwickelt sich zum derzeitigen Zeitpunkt gerade erst die kritische Masse von Entwicklern und Anwendern, welche bereit ist, fehlende Funktionalität bzw. Fehlfunktionen in Kauf zu nehmen. Durch die Bereitschaft, diese Aufgabe zu übernehmen und über die Technologie „das Wort zu verbreiten“, wird es erst möglich, dass aus einem relativ kleinen „Insiderthema“ eine Technologie wird, welche von einer erweiterten Gruppe wahrgenommen und schließlich in der täglichen Arbeit auch verwendet wird.

Das Semantic Web erwächst seinen „Kinderschuh“ – konkrete Real-World-Anwendungen in der Biomedizin werden möglich.

Semantic Web Technologien

Grundsätzlich stellt das Semantic Web eine übergreifende Plattform dar, um Daten und Informationen mit Hilfe eines einheitlichen Mechanismus aus verschiedenen Quellen im Internet miteinander zu verbinden, zu integrieren und weiterzuverwenden. Dadurch, dass sowohl RDF als auch OWL (siehe Abschnitt über Ontologien) eine formale, standardisierte Spezifikation zu Grunde liegt, wird es Computeranwendungen möglich, solche Daten zu „verstehen“ und intelligent zu verarbeiten.

Datenenkodierung via RDF

In RDF [10] werden Daten durch Tripel aus Subjekt, Prädikat und Objekt modelliert, um einfache Aussagen abzubilden wie z. B.: `article:10698743 sc:describes_gene ncbi_gene:1812`: der Artikel 10698743 aus der medizinischen Publikationsdatenbank PubMed [12] (Subjekt) beschreibt (Prädikat) das Gen mit der Nummer 1812 aus den Daten des National Center for Biotechnology Information (NCBI) [11] (Objekt).

Das Objekt eines Tripels kann hierbei auch Subjekt eines weiteren Tripels sein (z. B. `ncbi_gene:1812 rdfs:label „human DRD1“`: das bereits erwähnte Gen hat den Bezeichner „human DRD1“), womit durch die Kombination mehrerer Tripel auf einfache Weise komplexe Graphen gebildet werden können. Es werden hierbei die einzelnen Knoten und Kanten mit global (über das komplette Internet) eindeutigen Uniform Resource Identifiern (URIs) benannt (siehe Abb. 1), was eine eindeutige Referenz auf die in den Tripeln beschriebenen Entitäten erlaubt. (Um das Notieren zu vereinfachen werden hierbei sogenannte Namespaces als Abkürzung verwendet. So steht die Kurzschreibweise `ncbi_gene:1812` für `http://purl.org/commons/record/ncbi_gene/1812`.)

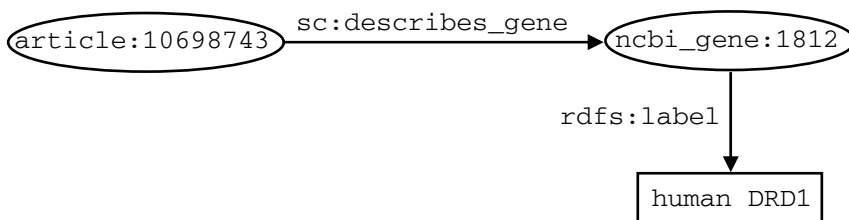


Abb. 1. Beispiel eines komplexen RDF-Graphen. Das Gen mit dem Identifier „ncbi_gene:1812“ (links oben) und dem Label „human DRD1“ wird in einem Artikel mit dem Identifier „article:10698743“ beschrieben

Wie dieses sehr einfache Beispiel andeutet, ist das RDF-Graphenmodell trotz (oder gerade wegen) seiner Einfachheit in der Lage, verschiedene Typen von Daten (z. B. Gen-, Publikationsdaten) aus verschiedenen Quellen (z. B. Forschungszentren, Publikationsdatenbanken) in einer einheitlichen Form zu repräsentieren. Dies steht in komplettem Gegensatz zu bisher verwendeten konventionellen XML- oder Datenbankschemata, welche außerhalb ihres eigentlichen Einsatzgebietes nur schwer anwendbar sind, da diese auf lokale Gegebenheiten (z. B. eingesetzte Datenbankserver) zugeschnitten sind. Andererseits ist es aber auch notwendig, RDF-Daten eine gewisse Struktur zu geben, indem man diese durch übergreifende Konzepte und Eigenschaften verbindet, welche in Ontologien definiert werden. Also auch wenn das RDF-Modell die gemeinschaftliche Datennutzung sehr vereinfacht, ist es für eine gemeinschaftliche Dateninterpretation notwendig, mit Hilfe von Ontologien über die Konzepte zur Datenbeschreibung übereinzustimmen (siehe Abschnitt über Ontologien).

Datenabruf via SPARQL

Natürlich nutzt es nichts, wenn Daten zwar einheitlich im RDF-Format enkodiert und abgespeichert werden, wenn diese Daten in Folge nicht strukturiert abgefragt werden können. Daher wurden ähnlich zu SQL für den Zugriff auf Datenbankinhalte, semantische Abfragesprachen entwickelt, wobei sich SPARQL [10] inzwischen hierfür zum Standard im Semantic Web entwickelt hat. Wie das Beispiel in Abb. 2 zeigt, ist es mit SPARQL möglich auf mehrere Graphen (also Datenquellen) in einer Abfrage zuzugreifen und diese so miteinander zu kombinieren. Was dieses Beispiel ebenfalls verdeutlicht, ist, dass solche Abfragen (ebenso wie in SQL) schnell sehr komplex werden und daher, ebenso wie RDF, direkt für Endanwender wenig geeignet sind.

Daten waren bisher durch verschiedene XML-/Datenbankschemata oft nur lokal anwendbar – generische RDF-Graphenmodelle vereinfachen den Datenaustausch und die Abfrage via SPARQL.

Mappingwerkzeuge

Es gibt bereits einige große biomedizinische Datenquellen, welche ihre Daten direkt im RDF-Format öffentlich zur Verfügung stellen, wie z. B. die Universal Protein Resource (UniProt) [25], eine Datenbank von Proteinssequenzen. Obgleich ein Trend zu erkennen ist, dass andere Organisationen diesem Beispiel bald folgen werden, stehen zum jetzigen Zeitpunkt die meisten Datenquellen noch nicht RDF-enkodiert zur Verfügung.

```

prefix go: <http://purl.org/obo/owl/GO#>
prefix mesh: <http://purl.org/commons/record/mesh/>
prefix owl: <http://www.w3.org/2002/07/owl#>
prefix rdfs: <http://www.w3.org/2000/01/rdf-schema#>
prefix sc: <http://purl.org/science/owl/sciencecommons/>
prefix ro: <http://www.obofoundry.org/ro/ro.owl#>
SELECT DISTINCT ?gene ?process WHERE {
  graph <http://purl.org/commons/hcls/pubmesh>
  { ?pubmedrecord ?p mesh:D017966.
    ?article sc:identified_by_pmid ?pubmedrecord.
    ?generecord sc:describes_gene_or_gene_product_mentioned_by
    ?article. }
  graph <http://purl.org/commons/hcls/goa>
  { ?protein rdfs:subClassOf ?res.
    ?res owl:onProperty ro:has_function.
    ?res owl:someValuesFrom ?res2.
    ?res2 owl:onProperty ro:realized_as.
    ?res2 owl:someValuesFrom ?process.
  }
  graph <http://purl.org/commons/hcls/20070416/classrelations>
  { { ?process http://purl.org/obo/owl/obo#part_of
    go:GO_0007166. }
    union { ?process rdfs:subClassOf go:GO_0007166. } }
  ?protein rdfs:subClassOf ?parent.
  ?parent owl:equivalentClass ?res3.
  ?res3 owl:hasValue ?generecord. } }

```

Abb. 2. Eine komplexe SPARQL Abfrage. Die Abfrage liefert eine Liste von Genen, welche mit bestimmten Nervenzellen assoziiert sind und eine Rolle in der Signalweiterleitung innehaben. Diese Abfrage ist nur möglich, da durch Semantic Web Technologien eine Vielzahl von Datenquellen als ein zusammenhängender Graph abgefragt werden kann. Die durch die Abfrage identifizierten Gene können z. B. eine Rolle im Verständnis der Alzheimerschen Erkrankung spielen

Bereits einige biomedizinische Quellen sind in RDF verfügbar, die meisten jedoch nicht. Mappingwerkzeuge erlauben auch Zugriff auf solche Daten per SPARQL.

Jedoch ist offensichtlich, dass auch auf diese Daten nicht verzichtet werden kann, da die Gesamtheit aller existierenden Daten für die Forschung notwendig ist. Daher muss es möglich sein, auch auf solche Daten mit Semantic Web Technologien zuzugreifen: Dies wird mit Hilfe von Mappingwerkzeugen realisiert, wie z. B. D2RQ [4], einer deklarativen Sprache zur Beschreibung von Abbildungen relationaler Datenbankschemata auf RDF. Konkret bedeutet ein solches Mapping, dass Datenbanktabellen, -spalten und -werte dynamisch durch eine Menge vorgegebener Regeln auf URIs für Klassen, Eigenschaften und Instanzen abgebildet werden. (Eine weitere Möglichkeit stellt die „manuelle“ Konvertierung von Daten aus verschiedenen anderen Formaten nach RDF dar [17]. Hierbei werden speziell auf die lokalen Gegebenheiten zugeschnittene Skripte oder Programme geschrieben, die Datenbankinhalte nach RDF konvertieren.)

Dies ermöglicht es, via SPARQL transparent auf Datenbankinhalte zuzugreifen, als wären diese direkt in RDF kodiert: Dies bedeutet in der Pra-

xis, dass Daten und damit Wissen, welches in der Forschung über Jahre (und Jahrzehnte) gesammelt wurde, nicht verloren geht sondern auch in Zukunft weiterverwendet werden kann. Darüber hinaus erlauben solche Mappingwerkzeuge, dass Daten, die bisher in verschiedenen Datenbanken lokal „gefangen“ waren, nunmehr der Wissenschaftsgemeinschaft für weitere Forschung offen stehen.

Probleme mit Semantic Web Technologien

Zu Beginn des vorherigen Abschnitts wurde bereits erwähnt, dass Semantic Web Technologien in der Biomedizin stetig aber langsam reifen. Dies bedeutet genau, dass zwar immer mehr Werkzeuge verfügbar sind, mit denen RDF-Daten bearbeitet werden können, diese Werkzeuge derzeit jedoch noch weit entfernt von der Stabilität und Ausgereiftheit sind, welche z.B. etablierte Datenbankprodukte oder Büroanwendungen besitzen [6]. Ein weiteres Problem liegt in der Tatsache, dass diese Werkzeuge meist auf Semantic Web Experten zugeschnitten sind und nicht auf Endanwender: Es gibt zwar Programme, mit denen man z.B. direkt SPARQL-Abfragen auf einer Datenquelle ausführen kann, jedoch fehlt es an einfach zu bedienenden Werkzeugen, welche die alltägliche Arbeit mit Daten ohne (große) Kenntnisse der zugrundeliegenden Technologien erlaubt. Um die Effizienz der biomedizinischen Forschung zu steigern, müssen diese Werkzeuge den speziellen Gegebenheiten in der Biomedizin angepasst sein, Bedienoberflächen bieten, welche sich nahtlos in gewohnte Umgebungen einpassen (z.B. Integration als Plug-ins in Laboranalysesoftware) und die Zusammenarbeit zwischen verschiedenen Forschungsgruppen gewährleisten. Da dies derzeit jedoch leider noch nicht der Fall ist, ist das Semantic Web in seinem jetzigen Status für (technisch unversierte) Endanwender nur sehr beschränkt nutzbar.

Ein erster Schritt in Richtung einer für Forscher verwendbaren Schnittstelle stellt die in Abb. 3 dargestellte Webschnittstelle dar. Diese wurde im Rahmen eines Demonstrationsprojektes der W3C HCLS (Health Care and Life Sciences) Gruppe [24] (eine „Task-Force“ des W3C zum Vorantreiben der Anwendung des Semantic Web in der Biomedizin) erstellt [16, 22], um die Möglichkeiten des Semantic Web im Rahmen der Forschung an neurodegenerativen Krankheiten aufzuzeigen. Mit quelloffenen Werkzeugen wurde eine einfache, leicht zu handhabende Schnittstelle entwickelt, welche Informationen aus der Hirnforschung mit Bildern von Schnitten eines Mäusegehirns kombiniert (eingefärbt zum Sichtbarmachen der Aktivitäten bestimmter Gene). Da diese Anwendung offen über das Internet zugänglich ist, erlaubt sie das weltweite, kollaborative Nutzen der zugrundeliegenden Daten und ist somit ein Beispiel für einen ersten




Abb. 3. Ausgabe für eine Anfrage nach Genprodukten im Kontext von Hirnzellen bei Mäusen – Kombination von Daten und Bildern aus dem Allen Brain Atlas [1] und Entrez Gene [11]

Schritt in Richtung eines gemeinschaftlichen Wissensnetzes auf Basis des Semantic Web.

Ontologien

Der Begriff des Semantic Web ist sehr eng mit dem der „Ontologie“ verbunden. Während er ursprünglich in der Philosophie für „die Erforschung des Seins“ stand, bekam er in den letzten Jahren die sehr technische Definition der „Spezifikation einer Konzeptualisation“ [7]. In einer Ontologie in diesem Sinne wird das Wissen über einen bestimmten Bereich, wie z. B. der Biomedizin, oder eines speziellen Unterbereichs, wie der menschlichen Anatomie, modelliert. Die Konzepte eines Bereiches (z. B. „Vene“, „Blut“) zusammen mit deren logischen Beziehungen (z. B. „Venen transportieren sauerstoffarmes Blut“) werden durch formale Regeln strukturiert und mittels einer computerinterpretierbaren Sprache, wie dem derzeitigen Standard OWL, implementiert. Es ist an diesem Punkt wichtig zu betonen, dass eine Ontologie *ein* bestimmtes Modell für *eine* gewisse Aufgabenstellung repräsentiert, verschiedene Modelle sollten daher durch verschiedene On-

tologien repräsentiert werden, z. B. für das Modellieren von Erkrankungen des Kreislaufsystems müssen alle Konzepte des menschlichen Kreislaufs detailliert modelliert werden, jedoch ist für ein Modell von Krebserkrankungen ein weniger detailliertes Modell des Kreislaufs ausreichend.

OWL

Wie gesagt, ist OWL [21] der derzeitige Standard zur Implementierung von Ontologien für das Semantic Web, wobei Konzepte und Beziehungen durch Klassen und Properties implementiert werden. Durch graphische Editoren für OWL, wie z. B. Protégé [8], wird es auch biomedizinischen Experten möglich, nach relativ kurzer Einarbeitung eigene Ontologien zu erstellen, diese über einen Webserver im Internet zu veröffentlichen und anschließend zu Kommentaren oder weiteren Anregungen aufzurufen. Andere Forscher können solche Ontologien entweder direkt für ihre Arbeit verwenden, (für die eigenen Bedürfnisse) erweitern und ändern oder komplett neue Ontologien auf den ursprünglichen aufbauen. Solche Weiterentwicklungen können dann wiederum veröffentlicht werden, womit ein Entwicklungskreislauf entsteht, der es allen Interessierten erlaubt, gemeinsam die Entwicklung einer Ontologie oder von Gruppen von Ontologien voranzutreiben.

Um die Akzeptanz einer solchen Ontologie in Folge zu gewährleisten, sollte sichergestellt werden, dass:

- sie eine gewisse Stabilität aufweist und anzunehmen ist, dass sie sich nicht massiv ändern und auf lange Zeit verfügbar sein wird;
- sie nach Möglichkeit andere, etablierte Ontologien wiederverwendet und so mit bestehender Software interoperabel ist (z. B. Gene Ontology);
- sie leicht im Internet gefunden werden kann, indem sie z. B. in bestehenden Ontologieverzeichnissen registriert wird (siehe unten);
- sie von einer großen Entwickler- und Nutzergemeinschaft vorangetrieben wird;
- es den Nutzern durch klare Beschreibungen des Inhalts der Ontologie leicht gemacht wird, sie für eigene Zwecke zu erweitern.

Verwendung

Es existieren bereits einige große Ontologien für die biomedizinische Domäne definierter Ontologien, wie z. B. Anatomie, Genetik oder die Krebsforschung [9]. Zwei der bekanntesten (und umfangreichsten) unter den biomedizinischen Ontologien sind der National Cancer Institute (NCI) Thesaurus [19] und die Gene Ontology [5], welche sehr große Vokabulare von Termen (derzeit über 18.000 bzw. 16.000) repräsentieren. Diese Onto-

logien sind zum Standard in der Krebsforschung bzw. molekularen Biologie und der Bioinformatik geworden: Der NCI Thesaurus bietet Definitionen, Synonyme und weitere Informationen über Krebs, verwandte Krankheiten und Therapien an. Die Gene Ontology speziell dient zum Charakterisieren oder Finden von Genen gemäß derer Molekularfunktion (ca. 7500 Terme), biologischen Prozesse (ca. 9200 Terme) oder Zellkomponenten (ca. 1800 Terme). Die Gene Ontology versucht eine konsistente Beschreibung von Genprodukten zu geben.

Probleme und Voraussetzungen

Die Verwendung von Ontologien stellt grundsätzlich eine Möglichkeit dar, die Forschung mit großen Mengen heterogener, verteilter Daten effizienter zu gestalten. Jedoch kann das Verwenden großer Ontologien auch Schwierigkeiten bereiten, die das Erstellen von kleineren für spezielle Anwendungen angepassten Unterontologien wünschenswert machen: Große Ontologien haben meist eine sehr komplexe Struktur mit vielen Konzepten und Relationen, die es dem Anwender schwer machen, die Zusammenhänge innerhalb der Ontologie zu verstehen und somit diese korrekt anzuwenden. Wird aber nun eine solche Unterontologie erstellt, so muss eine klare Methodik vorhanden sein, diese mit der ursprünglichen Ontologie in Relation zu setzen und so eine fehlende Interoperabilität zu vermeiden. Das Erstellen einer eigenen Ontologie kann nur ein „letzter Schritt“ sein, da dies zu einem Fragmentieren von Ontologien führt. Bei Problemen mit bestehenden Ontologien ist es oftmals eher ratsam, sich mit den Ontologieentwicklern und anderen Anwendern auszutauschen und zu diskutieren, ob eine bestimmte Änderung nicht sogar in der gegebenen Ontologie sinnvoll wäre (siehe auch Abschnitt über Mapping).

Große Ontologien haben komplexe Strukturen und es gibt viele Gruppen, die Ontologien entwickeln – eine klare Methodik für deren Integration und Interoperabilität ist notwendig.

Viele individuelle biomedizinische Gruppen leisten Beiträge zur Entwicklung von Ontologien, jedoch oft unkoordiniert und daher fragmentiert und nicht interoperabel. Sie geben Wissenschaftlern eine verwirrende und manchmal widersprüchliche Auflistung von Termen zur Auswahl, um experimentelle Daten zu annotieren, und zwingen den Forscher, an verschiedenen Quellen im Internet manuell nach passenden Ontologien zu suchen. Daher ist offensichtlich, dass je mehr Ontologien verfügbar sind, es umso schwerer wird, eine Ontologie zur Wiederverwendung für eine

bestimmte Aufgabe zu finden. Oft scheint es daher einfacher, eine eigene Ontologie komplett neu zu entwickeln, als eine passende, existierende zu suchen. Dies führt im Umkehrschluss natürlich dazu, dass immer mehr „Insel“-Ontologien entstehen, welche speziell auf isolierte Anwendungen „getrimmt“ sind und so dem eigentlichen Ziel von Ontologien, die Interoperabilität zu fördern, entgegenwirken.

Ein Problem, das aus dem letzten Sachverhalt folgt, ist, dass Ontologien in einem hohen Grad in Qualität, Abdeckung, Detail, etc. schwanken. Diese Problematik wird noch dadurch verschärft, dass keine objektiv berechenbaren Kriterien existieren, um die Qualität einer bestimmten Ontologie anzugeben. Es ist daher (fast) unmöglich eine Übereinstimmung zu finden, wann eine Ontologie „gut“ bzw. „schlecht“ ist. Vielmehr ist es eine rein subjektive Entscheidung, ob eine Ontologie für einen bestimmten Zweck geeignet ist oder nicht.

Zusätzlich ist in den meisten Fällen nicht bekannt, in welchem Umfeld und zu welchem Zweck eine bestimmte Ontologie bereits verwendet wurde. Wenn ein potentieller Nutzer einer Ontologie jedoch wüsste, für welche Anwendungen eine Ontologie als passend empfunden wurde und welche Probleme aufgetreten sind, dann wäre dies eine große Hilfe für eine informierte Entscheidung.

Darüber hinaus ist in manchen ontologiebasierten Projekten zu bemerken, dass die Entwickler es grundsätzlich ablehnen, auf Ontologien aufzubauen, die von anderen Gruppen entwickelt wurden. Die Gründe dafür sind oft eher sozialer Natur und nicht in technischen oder organisatorischen Mängeln zu suchen. Das Bewusstsein, dass die Wiederverwendung bestehender Ontologien nicht nur Arbeit spart, sondern auch die Interoperabilität und Zusammenarbeit im Semantic Web fördert, muss hier erst entwickelt werden.

Wenn man die obigen Punkte einbezieht, was wird konkret benötigt, damit Ontologien sinnvoll und effizient entwickelt und eingesetzt werden?

Suche

Es muss Anwendern möglich sein, nach und in verfügbaren Ontologien zu suchen, in ihnen zu navigieren und sie zu visualisieren, um herauszufinden, welche für eine bestimmte Aufgabe verwendbar sind. Es existieren derzeit zwar verschiedene Arten von Ontologieverzeichnissen; manche werden durch Crawling automatisch erstellt, andere werden manuell erstellt und gewartet (z.B. die Open Biomedical Ontologies Sammlung (OBO) [20], die in das National Center for Biomedical Ontology [15] integriert ist). Diese Verzeichnisse, sind jedoch meistens nur Orte um Ontologien abzuspeichern und wieder abzurufen und erlauben höchstens Suchen über mehrere Ontologien hinweg. Sie erlauben dem Benutzer aber

nicht die Ontologien zu bewerten, diese intelligent zu suchen oder zu erfahren, wo diese bereits verwendet wurden und was andere Benutzer über diese Ontologien denken. Durch die Erweiterung um solche Funktionalitäten würden aus diesen (einfachen) Verzeichnissen „soziale Orte“ entstehen, an denen sich Wissenschaftler direkt austauschen und, so vereinfacht, gemeinsam die Entwicklung der Ontologien vorantreiben könnten.

Mapping und Merging

Den Entwicklern von Ontologien muss es möglich sein, verschiedene Ontologien und Terminologien mit sich überschneidenden Inhalten in Beziehung zu setzen, aufeinander zu mappen (abzubilden) und miteinander zu verschmelzen. Es müssen benutzerfreundliche, graphische Werkzeuge entwickelt werden, um Ontologien für bestimmte Aufgaben auf einfache Art und Weise anzupassen und bestimmte Perspektiven zu generieren. Wenn solche Werkzeuge nicht entwickelt werden, kann dies dazu führen, dass für jede spezielle Aufgabe eine neue Ontologie entwickelt würde anstelle der Wiederverwertung und Anpassung bestehender Ontologien. Dies würde dann genau dem Ziel von Ontologien widersprechen, nämlich zu einem gemeinschaftlichen Verständnis von verteilten Daten und Anwendungen zu gelangen.

Trust

„Vertrauen“ in einer berechenbaren Form ist in allen Situationen notwendig, in der potentiell jeder Nutzer Daten auf einfache Weise verbreiten kann. Dieses Problem ist heute bereits auf dem „normalen“ Web offensichtlich, wenn man die Bandbreite verfügbarer Webseiten betrachtet, welche von vertrauenswürdigen Content-Anbietern (z. B. große Tageszeitungen) bis zu Spamwebseiten reicht. Da auf dem „normalen“ Web Informationen meist von Menschen verarbeitet werden, können diese ihr Hintergrundwissen und ihre Intuition verwenden, um die Vertrauenswürdigkeit einer bestimmten Quelle einzuschätzen. Erfahrungswissen – welches schwer für Maschinen kodierbar ist – hilft sehr in der Bestimmung, was „gut“ und was „schlecht“ ist. Trotzdem müssen auch in diesem Umfeld Mechanismen entwickelt werden, die uns bei den Entscheidungen helfen, da Menschen nicht Experten in allen Feldern sein können.

Im Rahmen des Semantic Web, in dem Computer die Daten verarbeiten ohne die menschliche Intuition, ist dies noch weitaus problematischer. Es gibt derzeit keinen offiziellen, maschinenverwertbaren Standard, um Informationen über bestimmte Ontologien auszudrücken, also z. B. wie eine Ontologie entstanden ist und in welchem Kontext. (Das gleiche Problem trifft im Übrigen auch auf RDF-Daten zu. Hier ist es auch notwendig, z. B. die

genaue Herkunft zu kennen und wie diese Daten be- und verarbeitet wurden. Jedoch gibt es hierfür ebenfalls keinen standardisierten Mechanismus.)

Verschiedene Enkodierungen

In der Semantic Web Gemeinschaft gibt es vielfach die Vorstellung, dass jedes Datenset mit jedem anderen interoperabel sein sollte. In der Realität existieren jedoch verschiedene Repräsentationen von gleichen Datensets nebeneinander (siehe das Anatomiebeispiel in der Einführung der Ontologien). Semantic Web Technologien helfen hier, indem Sie durch das simple RDF-Graphenmodell die technische Basis für eine mögliche Vereinheitlichung liefern, jedoch müssen Methoden erforscht werden, die erlauben auch verschiedene Sichtweisen nebeneinander zu halten und diese aufeinander abzubilden (z.B. durch das oben erwähnte Mapping). Auch hier muss gewährleistet sein, dass verschiedene Enkodierungen für den Forscher als Endanwender durch geeignete Werkzeuge transparent dargestellt und nutzbar gemacht werden.

Ausdrucksstärke

Ein Beispiel dafür, dass, selbst wenn eine einzelne Ontologie von verschiedenen Gruppen gemeinsam verwendet wird, dies keine erfolgreiche Integration garantiert, ist BioPAX [3]. Diese OWL-basierte Ontologie ist die Basis eines Austauschformats zur Integration von Datenquellen für zelluläre Pfadinformationen. Trotz dieser gemeinsamen Ontologie ist es schwierig, diese verschiedenen Quellen im BioPAX-Format gemeinsam zu verwenden, da die Ontologie keine ausreichende Abdeckung dieses wissenschaftlichen Bereiches und der darin verwendeten Terme bietet. Dieses Beispiel zeigt, dass die gemeinschaftliche Arbeit und Einigung auf gemeinsame Ontologien nicht in jedem Fall zu einem Erfolg führen muss. Andererseits ist es natürlich für weitere Entwicklungen im Ontologiebereich von großem Wert, dass auch solche Fälle von Problemen mit Ontologien veröffentlicht werden, da diese als „Lernbeispiele“ für zukünftige Projekte dienen können.

Fazit

Obwohl die Technologien rund um das Semantic Web sich erst in der Entwicklung befinden, existieren bereits jetzt Standards, Technologien und Anwendungen, welche in einem weiten Spektrum biomedizinischer Anwendungsszenarien praktisch eingesetzt werden können. Problematisch für den verbreiteten Einsatz des Semantic Webs ist, dass Teile der Technolo-

gien noch in der Entwicklung sind und bisher noch nicht in größerem Rahmen getestet wurden. Es bedarf außerdem Schulung und Unterstützung, um die neuen Technologien zu verstehen und zu verwenden.

Eine wichtige Rolle in der Adaption des Semantic Web in der Medizin spielen Ontologien. Um deren Anwendung sicherzustellen, müssen die Ontologien eine gewisse Stabilität aufweisen, leicht gefunden und wieder- verwendet bzw. erweitert werden können. Es müssen Werkzeuge entwickelt werden, die es Endanwendern in der Forschung ermöglichen, Ontologien in ihrer täglichen Arbeit mit gewohnten Oberflächen zu verwenden, zu erweitern und miteinander zu kombinieren.

Danksagung

Die Autoren möchten sich bei allen Teilnehmern der W3C HCLS Gruppe bedanken, welche bei der Erstellung der beschriebenen Demonstrations- anwendung mitgewirkt haben.

Literatur

1. Allen Institute for Brain Science (2007) Allen Brain Atlas: [<http://www.brain-map.org>]
2. Berners-Lee T, Hendler J, Lassila O. (2001) The Semantic Web. *Scientific American* (284), p 34–43
3. BioPAX – Biological Pathways Exchange (2005) [<http://www.biopax.org>]
4. Bizer, C (2007) The D2RQ Plattform – Treating Non-RDF Databases as Virtual RDF Graphs [<http://sites.wiwiss.fu-berlin.de/suhl/bizer/D2RQ/>]
5. Gene Ontology Consortium (2007) The Gene Ontology Project in 2008. *Nucleic Acids Res.* (36) pp. 440–4
6. Good BM, Wilkinson MD (2006) The Life Sciences Semantic Web is full of creeps! *Briefings in bioinformatics* 2006, 7:275–286.
7. Gruber TR (1993) *A Translation Approach to Portable Ontology Specifications*. Academic Press, New York.
8. Knublauch H, Dameron O, Musen M. (2004) Weaving the Biomedical Semantic Web with the Protege OWL Plug-in. In: *Proceedings of the Workshop on Formal Biomedical Knowledge Representation (KR-MED)*, Whistler
9. Lambrix P, Tan H, Jakoniene V, Strömbäck L (2007) Biological Ontologies. In: Cheung K (eds) *Semantic Web: Revolutionizing Knowledge Discovery in the Life Sciences*, pp. 85–99, Springer, 2007. ISBN-10: 0-387-48436-1, ISBN-13: 978-0-387-48436-5.
10. Manola F, Miller E (2004) *RDF Primer* [<http://www.w3.org/TR/rdf-primer/>]
11. National Center for Biotechnology Information (2007) Entrez Gene [www.ncbi.nlm.nih.gov/entrez/query.fcgi?db=gene]

12. National Library of Medicine (2007) PubMed
[<http://www.ncbi.nlm.nih.gov/PubMed/>]
13. Prud'hommeaux E und Seaborne A. (2008) SPARQL Query Language for RDF [<http://www.w3.org/TR/rdf-sparql-query/>]
14. RSC Publishing (2007) Project Prospect
[www.rsc.org/Publishing/Journals/ProjectProspect]
15. Rubin DL, Lewis SE, Mungall CJ, Misra S, Westerfield M, Ashburner M, Sim I, Chute CG, Solbrig H, Storey MA, Smith B, Day-Richter J, Noy NF, Musen MA. (2006) National Center for Biomedical Ontology: Advancing Biomedicine through Structured Organization of Scientific Knowledge. OMICS: A Journal of Integrative Biology. 10(2), pp. 185–198
16. Ruttenberg A, Clark T, Bug W, Samwald M, Bodenreider O, Chen H, Doherty D, Forsberg K, Gao Y, Kashyap V, Kinoshita J, Luciano J, Scott Marshall M, Ogbuji C, Rees J, Stephens S, Wong GT, Wu E, Zaccagnini D, Hongsermeier T, Neumann E, Herman I, Cheu. (2007) Advancing Translational Research with the Semantic Web. BMC Bioinformatics 8
17. Sahoo SS, Zeng K, Bodenreider O, Sheth AP. (2007) From „Glycosyltransferase“ to „Congenital Muscular Dystrophy“: Integrating Knowledge from NCBI Entrez Gene and the Gene Ontology. Proceedings of the 12nd World Congress on Health (Medical) Informatics (Medinfo 2007), Brisbane
18. Shadbolt N, Berners-Lee T, Hall W. (2006) The Semantic Web Revisited. IEEE Intelligent Systems, 21 (3) pp. 96–101
19. Sioutos N, de Coronado S, Haber MW, Hartel FW, Shaiu WL, Wright LW (2007) NCI Thesaurus: a semantic model integrating cancer-related clinical and molecular information. Journal of biomedical informatics, 40:30–43.
20. Smith B, Ashburner M, Rosse C, Bard C, Bug W, Ceusters W, Goldberg LJ, Eilbeck K, Ireland A, Mungall CJ, The OBI Consortium, Leontis N, Rocca-Serra P, Ruttenberg A, Sansone SA, Scheuermann RH, Shah N, Whetzel PL, Lewis S (2007). The OBO Foundry: Coordinated Evolution of Ontologies to Support Biomedical Data Integration. Nature Biotechnology (25), pp. 1251–5
21. Smith M, Welty C, McGuinness D (Eds): OWL Web Ontology Language, 2004 [<http://www.w3.org/TR/owl-guide/>]
22. Stenzhorn H, Srinivas K, Samwald M, Ruttenberg A. (2008) Simplifying Access to Large-Scale Health Care and Life Sciences Datasets.(Demo Description) Proceedings of the 5th European Semantic Web Conference (ESWC 2008), Teneriffa
23. Transinsight (2008) GoPubMed [<http://www.gopubmed.com>]
24. W3C HCLS (2001) Semantic Web Health Care and Life Sciences Interest Group [<http://www.w3.org/2001/sw/hcls/>]
25. Wu CH, Apweiler R, Bairoch A, Natale DA, Barker WC, Boeckmann B, Ferro S, Gasteiger E, Huang H, Lopez R, et al.:The Universal Protein Resource (UniProt): an expanding universe of protein information. Nucleic acids research 2006, 34:D187–191.

IV Reflexion

22. Das Social Semantic Web aus kommunikationssoziologischer Perspektive

Jan Schmidt¹ und Tassilo Pellegrini²

¹ Hans-Bredow-Institut für Medienforschung;
j.schmidt@hans-bredow-institut.de

² Semantic Web Company;
t.pellegrini@semantic-web.at

Zusammenfassung: Zwei Trends prägen derzeit die Gestalt des Internets: Auf der einen Seite finden sich Entwicklungen rund um das „Web 2.0“ oder „Social Web“, die dem einzelnen Nutzer neue Möglichkeiten des onlinegestützten Identitäts-, Beziehungs- und Informationsmanagements eröffnen. Auf der anderen Seite stehen die Innovationen des Semantic Web, die Relationen zwischen Datenbeständen strukturieren helfen, um so zu verbesserten maschinellen Repräsentationen von Wissen zu gelangen. Dieser Beitrag skizziert die Idee eines „Social Semantic Web“, in dem beide Entwicklungen zusammenfließen. Als Scharnier dient dabei der Begriff der Prodnutzung, der die aktive Rolle des Nutzers bei der Erstellung, Verbreitung und Weiterentwicklung von Inhalten wie von strukturiertem Wissen betont.

Einleitung

Beschreibungen und Analysen des gegenwärtigen Internets kranken bisweilen daran, dass sie einen revolutionären Sprung in der Entwicklung des weltumspannenden Informations- und Kommunikationsnetzes annehmen. Besonders deutlich wird dies im Begriff des „Web 2.0“, der von Tim O'Reilly [17] geprägt wurde und in den vergangenen Jahren Einzug in öffentliche Diskussionen gehalten hat. Die momentane Phase wird dabei anhand verschiedener Entwicklungen gegenüber dem „Web 1.0“ abgegrenzt:

- Die Veralltäglichsung von Anwendungen, die das Bereitstellen und Teilen von Inhalten erleichtern (wie z. B. Weblogs, Wikis oder Videoplattformen) sowie das Abbilden und Pflegen von sozialen Beziehungen unterstützen (bspw. XING oder studiVZ).
- Veränderungen in der Art und Weise, wie Software entwickelt und bereitgestellt wird. Schlagworte wären hier beispielsweise „perpetual beta“, „mashup“ oder „webtop“.

- Das Erproben von Geschäftsmodellen, die das Erschließen von Nischenmärkten im „long tail“ [1] oder die kommerzielle Verwertung von „user-generated content“ [25] vorsehen.

Für die weite Verbreitung des Begriffs „Web 2.0“ in den einschlägigen Diskursen von Beratern, Software-Entwicklern, Unternehmern oder journalistischen Beobachtern ist – neben seiner relativen Unbestimmtheit, die viele Interpretationen zulässt – wohl auch der Umstand verantwortlich, dass er verschiedene Hoffnungen weckt: Auf geschäftliche Erfolge in einer Branche, die nach dem Ende des New-Economy-Booms durch spektakuläre Übernahmen wieder an Dynamik gewinnt, aber auch auf Verbesserungen in der Art und Weise, wie Menschen im Internet ihre privaten oder beruflichen Beziehungen pflegen und Informationen austauschen können. Allerdings ist aus kommunikationssoziologischer Sicht, die sich auf Nutzungspraktiken und ihre gesellschaftlichen Konsequenzen konzentriert, die Vorstellung eines „diskreten Versionssprungs“ in der Entwicklung des Internets nur bedingt haltbar, weswegen hier der Begriff des „Social Web“ vorgezogen wird.

Ziel dieses Beitrags ist es, dessen soziotechnische Grundprinzipien und Dynamiken zu skizzieren und um Perspektiven aus dem Semantic Web zu ergänzen. Dazu wird zunächst eine praxistheoretische Perspektive auf das Social Web präsentiert und das Konzept der „Prodnutzung“ vorgestellt, das vier Geschäftsmodelle zum Umgang mit nutzergenerierten Inhalten erlaubt. Der dritte Abschnitt gibt einen kurzen Überblick über die konzeptuellen und technologischen Bausteine des Semantic Web und leitet zu einer Skizze des „Social Semantic Web“ über. Dieses Konzept wird im vierten Abschnitt anhand von vier unterschiedlichen Wissenstypen analytisch weiter differenziert. Der Text schließt mit einer Conclusio, in der das Verhältnis von bottom-up- und top-down-Modellen der Wissensgenerierung noch einmal zusammenfassend bewertet wird.

Das Social Web aus praxistheoretischer Perspektive

Der spezifische Zugang der Soziologie zur Welt besteht darin, die Verbundenheit von Handeln und Struktur herauszuarbeiten, also zu zeigen, wie sich individuelles Tun und kollektive Strukturen wechselseitig bedingen [10, 20]. Der Begriff der „Praxis“ leistet diese Vermittlung, weil er beide Ebenen der sozialen Welt in Beziehung setzt: Praktiken äußern sich immer in konkreten Episoden des Handelns, die jedoch von strukturellen Gegebenheiten (wie z. B. Normen und Konventionen, aber auch bestimmten Ressourcenverteilungen) gerahmt werden. Strukturen legen also bestimmtes Handeln nahe, ohne es vollständig zu determinieren; vielmehr werden

sie im Handeln immer wieder neu hervorgebracht, wobei sowohl eine Reproduktion bestehender Strukturen als auch ein mehr oder weniger inkrementeller Wandel denkbar ist.

An anderer Stelle [23, 24] wurde eine solche praxistheoretische Perspektive für aktuelle Bereiche der Internetnutzung ausführlicher beschrieben. Zusammenfassend lässt sich festhalten, dass die individuelle Nutzung von Social-Web-Anwendungen¹ durch drei strukturelle Dimensionen gerahmt wird:

1. *Regeln* sind mehr oder weniger explizite und sanktionierte Vorgaben innerhalb bestimmter Nutzergemeinschaften, für welche Zwecke und wie eine bestimmte Software anzuwenden ist – man denke an Konventionen wie die „Netiquette“, allgemeine Geschäftsbedingungen von Anbietern oder auch formaljuristische Vorgaben in Hinblick auf Impressumspflichten oder das Recht auf freie Meinungsäußerung.
2. *Relationen* sind existierende oder neu hervorgebrachte Beziehungen, die als hypertextuelle Verknüpfungen zwischen Objekten sichtbar sind, oft aber auf zugrunde liegende soziale Beziehungen zwischen den Nutzern schließen lassen.
3. Der *Code* meint schließlich die Gestaltung und Architektur der Software, die bestimmte Handlungsoptionen erst ermöglicht und andere ausschließt, wobei dies einem spielerischen oder unintendierten Umgang mit gegebenen Anwendungen nicht entgegensteht [6].

Anwendungen des Social Web erlauben ihren Nutzern, sich und ihre Interessen, Kompetenzen, Erfahrungen und Meinungen im Netz zu veröffentlichen (Identitätsmanagement) sowie darüber mit anderen Menschen in Kontakt zu treten bzw. bestehende Beziehungen zu pflegen (Beziehungsmanagement). Dies geschieht in „Verwendungsgemeinschaften“ [13], das heißt in Gruppen von Menschen, die sich bestimmter Software auf ähnliche Art und Weise bedienen und bestimmte Erwartungen darüber teilen, was sie mit gegebenen Anwendungen bewirken können. Aus diesen Handlungen resultiert eine Vielzahl von thematisch teilweise sehr spezialisierten Öffentlichkeiten, die wiederum zur Recherche und zum Austausch genutzt werden können (Informationsmanagement). Manche von ihnen ergänzen die journalistisch hergestellten massenmedialen Öffentlichkeiten, die Mehrzahl lässt sich aber als „persönliche Öffentlichkeiten“ charakterisieren, die vorrangig Themen von persönlicher Relevanz behandeln. Die Kanalisierung von Aufmerksamkeit in den Öffentlichkeiten des Social Web erfolgt daher auch nicht mehr ausschließlich durch professionell ausgebil-

¹ Zwar dominieren in den aktuellen Diskussionen vor allem neuere Anwendungen wie Weblogs, Podcasts, Wikis, kollaborative Verschlagwortungssysteme oder Social Networking-Plattformen, doch bereits Foren, persönliche Homepages oder Chat-Systeme haben diese Praktiken unterstützt.

dete Gatekeeper (d. h. Journalisten), sondern zusätzlich durch zwei Mechanismen, die dem einzelnen Nutzer höheren Stellenwert einräumen:

- Mechanismen der „*Weisheit der Masse*“, in denen individuelle Bewertungen oder Klassifizierungen automatisch aggregiert werden, um besonders populäre oder auch thematisch verwandte Inhalte zu identifizieren. Beispiele finden sich in den Blog-Rankings von technorati.com oder blogscout.de, in den Listen der meist gesehenen Videos auf YouTube, aber auch in Plattformen zur kollaborativen Verschlagwortung von Bookmarks (vgl. del.icio.us oder mister-wong.de), Fotos (vgl. flickr.com) oder Büchern (vgl. librarything.com).
- Mechanismen der „*Weisheit des eigenen Netzwerks*“, bei denen einzelne Nutzer mit Hilfe von RSS Feeds individuelle Repertoires von Quellen zusammenstellen. Dies erlaubt das ganz an den eigenen Bedürfnissen und Relevanzstrukturen ausgerichtete Rezipieren von online verfügbaren Inhalten; die Selektionsleistung verbleibt damit zwar beim einzelnen Nutzer, doch ist eine sehr viel detailliertere Auswahl möglich, als dies aus den Massenmedien bekannt ist.

Diese beiden Mechanismen verweisen bereits darauf, dass sich Nutzungspraktiken im Social Web nicht mehr klar zwischen Produzieren und Konsumieren von Wissen (im weitesten Sinn) unterscheiden lassen. Vielmehr gewinnen Prozesse der „produsage“ bzw. der „Prodnutzung“ an Bedeutung, d. h. die Nutzer sind gleichermaßen Rezipienten wie Produzenten von Daten, Informationen, Inhalten und Softwareprodukten. Dieses Konzept wird im folgenden Abschnitt näher erläutert.

Prodnutzung im Social Web

Der Begriff der „Prodnutzung“ [7, 8, 11] beschreibt den Umstand, dass den einzelnen Nutzern im Social Web eine tragende Rolle zukommt. Autorenschaft, Bewertung, Rezeption, Nutzung und Verbreitung von Wissens- und Kulturgütern im Social Web lassen sich zwar analytisch auseinander halten, sind in der täglichen Nutzungspraxis jedoch untrennbar verbunden. Der aktive Anwender von Wikis, Weblogs, Networking-Plattformen oder Verschlagwortungssystemen ist daher gleichermaßen Rezipient wie Produzent von Daten, Informationen und Inhalten, wird also zum „Produser“ bzw. „Prodnutzer“.²

² Verwandte Konzepte der kollaborativen Wertgenerierung reichen zurück in die 1970er Jahre und finden sich unter Begriffen wie „Prosuming“ [27], „Co-Produktion“ [18], „Co-Design“ [21] oder „Co-Creation“ [19].

Viele der entsprechenden Handlungsepisoden – das Verfassen eines Eintrags oder Kommentars in einem Weblog, das Einstellen und Verschlagworten eines Videos auf einer einschlägigen Plattform oder die Revision eines Artikels in einem Wiki – dienen zwar zunächst dem persönlichen Identitäts-, Beziehungs- und Informationsmanagement. Auf kollektiver Ebene erzeugen diese individuellen Handlungen aber eigene, vom einzelnen zum Teil unintendierte Strukturen. Prodnutzung ist dadurch auch ein kollaborativer, öffentlicher und prinzipiell unabgeschlossener Prozess, dessen Resultate als erweiterungs-, überarbeitungs-, aktualisierungs- und übertragungsbedürftig gelten. Besonders deutlich wird dies an der Organisation der Internet-Enzyklopädie Wikipedia: Jeder Artikel ist der Bearbeitung durch andere Autoren und Nutzer zugänglich, deren Veränderungen in einer „Versionshistorie“ dokumentiert sind. Auf einer zugehörigen und allgemein zugänglichen Diskussionsseite werden Differenzen zwischen verschiedenen Versionen eines Artikels besprochen und mögliche Konflikte ausgehandelt.

Autoren wie Yochai Benkler [3] oder Henry Jenkins [14] arbeiten heraus, dass Prodnutzung vielfach in sozialen Settings stattfindet, die jenseits von Märkten (als Distributions- und Belohnungsmechanismus) und von formalen Organisationen bzw. hierarchischen Organisationsweisen geknüpft sind. Prodnutzer arbeiten vielmehr oft freiwillig und unentgeltlich zusammen, um Wissens- und Kulturgüter nicht-proprietär zu erzeugen, zu vervielfältigen und zu verbreiten. Im Bereich der Software-Entwicklung hat vor allem die Open-Source-Bewegung in den vergangenen Jahren alternative Formen der Wissensproduktion und -distribution etabliert [12, 9]. Lizenzierungsmodelle wie die „Creative Commons“ oder die „GNU General Public License“ treten neben die Rechtskonstruktion des Copyrights und gestatten es dem Urheber einer Information, deren Verbreitung, Vervielfältigung, öffentliche Präsentation, Veränderung und Nachbearbeitung von Fall zu Fall zu spezifizieren [15].

Diese Beispiele verdeutlichen, dass Prodnutzung eine Konkurrenz zum „klassischen“ Paradigma der Content-Produktion darstellt, das auf geistigem Eigentum und marktlicher Distribution beruht. In Anschluss an Bruns [7] lassen sich vier Strategien bzw. Geschäftsmodelle unterscheiden, wie privatwirtschaftliche Unternehmen oder andere Organisationen auf diese Entwicklung reagieren (können):

1. Bei der Strategie „*Harnessing the Hive*“ verwenden Organisationen die von den Prodnutzern erstellten Produkte weiter und reichern sie gegebenenfalls um zusätzliche Informationen an, respektieren aber deren Arbeitseinsatz und Rechte. Technorati.com beispielsweise stellt Informationen aus der Blogosphäre in aggregierter, statistisch aufbereiteter Form zur Verfügung und ermöglicht Recherchen zu beliebigen Themen.

Del.icio.us erbringt denselben Dienst in Bezug auf Internetseiten im Allgemeinen, die von Prodnutzern als öffentlich zugängliche Bookmarks gespeichert und verschlagwortet werden.

2. „*Harvesting the Hive*“ meint, dass Arbeitsergebnisse der Prodnutzer durch kommerzielle Institutionen gesammelt, aufbereitet und einer breiteren Öffentlichkeit zugänglich gemacht werden. Die Firma „Red Hat“ erzielt z. B. Wertschöpfung, indem sie Open-Source-Software bedarfsgerecht und installationsfertig Kunden zur Verfügung stellt, die sich selbst aber nicht an der Weiterentwicklung beteiligen. Ein anderes Beispiel sind Buchveröffentlichungen von ursprünglich in Weblogs publizierten Texten [16].
3. Als „*Harboring the Hive*“ lassen sich Strategien kommerziell orientierter Organisationen bezeichnen, erfolgreiche Angebote der Prodnutzer-Community aufzukaufen und so Besitz von deren Arbeitsergebnissen zu ergreifen. Prominente Beispiele der vergangenen Jahre waren die Übernahme der Videoplattform YouTube.com durch Google oder des studentischen Networkingportals studiVZ.de durch die Holtzbrinck-Verlagsgruppe. Sie zeigen, wie die unentgeltlich erbrachten Inhalte für kommerzielle Zwecke erschlossen und beispielsweise durch das Anbieten zusätzlicher (kostenpflichtiger) Funktionen oder das Einbinden von Werbung vermarktet werden.
4. Die Strategie des „*Hijacking the Hive*“ beruht schließlich darauf, Nutzerrechte so zu definieren, dass die Prodnutzer beim Veröffentlichen von Inhalten die Rechte der kommerziellen Nutzung an den Anbieter der jeweiligen Plattform übertragen, zugleich jedoch weiterhin erheblichen Zeit- und Arbeitsaufwand investieren, um die unentgeltlich erzeugten Informationen, Wissens- und Kulturgüter in gutem, aktuellem Zustand zu erhalten. Ein Beispiel bietet das „end user licence agreement“ (EULA) von YouTube, das die Vermarktungsrechte eingestellter Videos auf die Plattformbetreiber überträgt. Diese könnten also eine DVD mit einer Auswahl von Videos veröffentlichen, ohne die Urheber finanziell beteiligen zu müssen. Ein Beispiel aus dem Bereich der Computerspielentwicklung sind „Modding Competitions“, bei denen die Verwertungsrechte an den Einreichungen von Spielerweiterungen auf das Spieleunternehmen übergehen [26].

Social Semantic Web – Konvergenz von Social Software & Semantic Web

Technische Grundlagen des Semantic Web

Wie geschildert liegt der Innovationswert des Social Web weniger in technologischen Durchbrüchen, sondern vielmehr in den veränderten Nutzungs-

praktiken.³ Weitgehend abseits der öffentlichen Wahrnehmung vollzieht sich derzeit jedoch auch eine technologische Komplementärentwicklung, die in ihren Grundzügen bereits in den ersten Tagen des World Wide Web vorgesehen war. Schon im Jahr 1994 wurde in der Forschergruppe um Tim Berners-Lee darüber nachgedacht, wie große, disperse Datenbestände durch formale Beschreibungen geordnet und erschließbar gemacht werden können. [4] Es ist anzunehmen, dass dieser Aspekt aus strategischen Gründen in der Frühphase des Webs nicht forciert wurde, um einen schnellen Roll-Out und die Erreichung einer kritischen Masse an Nutzern zu gewährleisten.

Mit HTML lag ab 1995 eine niedrighschwellige, stabile Beschreibungssprache für Web-Dokumente vor, die in Kombination mit simplen Autorentools den Boom des heutigen World Wide Web auslöste. Content, der in HTML geschrieben wurde, wurde von Menschen für Menschen und nicht für Maschinen erstellt. Dies erübrigte eine Trennung zwischen Inhalt und Darstellung, setzte jedoch der maschinellen Verarbeitung von Content enge Grenzen. Das frühe Web galt daher bis zum Web 2.0-Boom im Jahr 2005 als ein „Web of Documents“, in dem das Dokument das zentrale Wissensobjekt darstellte.

In den letzten Jahren kam es zu einer graduellen – wenn schon nicht technologischen, zumindest doch konzeptuellen – Veränderung. Was Tim O'Reilly [17] auf die griffige Formel „Data is the next Intel inside“ reduzierte, wird vor allem in Technikerkreisen als „Web of Data“ oder Semantic Web bezeichnet. Als zentrale Wissensobjekte fungieren nicht mehr Dokumente sondern Contenteinheiten⁴ (Klassen, Instanzen, Attribute, Links etc.), aus denen sich ein Dokument zusammensetzt. An einem Beispiel verdeutlicht: Nicht mehr die Webseite von George Bush ist relevant, sondern die Tatsache, dass George Bush eine Person (und keine Pflanzengattung) ist, dass diese Person ein Politiker ist, dass sie in den USA lebt und eine Webseite bzw. Emailadresse hat. Die ursprüngliche Webseite von George Bush wird in ihre inhaltlichen Bestandteile (Contenteinheiten) zerlegt und semantisch beschrieben. Dies führt zu einer höheren Granularität und Kontextualisierung von Web-Content und ermöglicht in weiterer Folge einen höheren Automatisierungsgrad bei der Bereitstellung und Verarbeitung der Contenteinheiten.

³ Dies soll die gesellschaftspolitische Dimension von Social Software nicht mindern, doch von einem technologischen Quantensprung kann nicht gesprochen werden. Vgl. Robert Cailliau's Vortrag auf dem OpenWeb2.0 Seminar, am 20. April 2007 in Genf. In: http://www.youtube.com/watch?v=n0_0s_tbY9E

⁴ Im Semantic Web Jargon spricht man von „Ressourcen“. Aus Gründen der Verständlichkeit wird im Folgenden jedoch der Begriff der Contenteinheit verwendet, der an die in Abschnitt 4 gebrauchten Wissenstypen anschließt.

Im Vergleich zum gegenwärtigen, auf HTML basierenden Web bedarf es dazu (neben der Trennung von Form und Inhalt z. B. mit Hilfe von XML und XSL) auch der eindeutigen Referenzierbarkeit von Contenteinheiten durch sog. Uniform Resource Identifiers (URIs). Mittels Daten- oder Wissensmodellen in Form von Ontologien werden auf Basis formalisierter Beschreibungssprachen – wie RDF⁵ oder OWL⁶ – die Beziehungen und Regeln, die zwischen den Webressourcen existieren, modelliert und dadurch kontextualisiert. Kurz: Ontologien geben Auskunft darüber, *warum* eine Ressource mit einer anderen verbunden ist⁷, und erzeugen damit eine wichtige Zusatzinformation, die im gegenwärtigen Web weitgehend fehlt.

Die formale Beschreibung von Contenteinheiten mittels Metadaten bildet die wichtigste Kulturtechnik im Semantic Web. Metadaten werden mittels Ontologien organisiert und in sinnvolle Zusammenhänge gesetzt, sodass Content weitaus präziser beschrieben und auf seine semantischen Zusammenhänge analysiert werden kann. Um im Beispiel zu bleiben: Mittels Ontologien wird etwa zum Ausdruck gebracht, dass ein Politiker bestimmte Funktionen erfüllt, dass er einer politischen Fraktion angehört, dass er eine Amtsperiode hat, und dass er über Rechte und Pflichten verfügt, für die er sich vor dem Volk verantworten muss. Damit steigt die Granularität, mit der Wissensobjekte im Web (wie z. B. Personen, Produkte, Texte, Videos, Fotos, Links etc.) beschrieben und – gegebenenfalls – miteinander kombiniert werden können. Voraussetzung dafür ist die Beschreibung von Ressourcen mittels standardisierter, interoperabler Vokabulare, wie beispielsweise DC⁸ für Dokumente, FOAF⁹ für Personen und soziale Netzwerke oder SIOC¹⁰ für Communities.

Zusammenfassend sei festgehalten: Das Semantic Web ist eine Art globales Mashup aus Content-Einheiten und Relationen.¹¹ Es beruht auf einer

⁵ RDF = Resource Description Framework, siehe: <http://www.w3.org/rdf>

⁶ OWL = Web Ontology Language, siehe: <http://www.w3.org/2004/owl>

⁷ Hierbei ist jedoch wichtig anzumerken, dass Ontologien nicht zum Ziel haben „Wahrheit“ abzubilden, sondern lediglich eine Methode darstellen, Zusammenhänge und Abhängigkeiten zwischen zwei Objekten im jeweiligen Verwendungskontext wiederzugeben. Ein- und dasselbe Objekt kann deshalb in unterschiedlichen Kontexten unterschiedliche Bedeutung und damit auch Gültigkeit erlangen.

⁸ DC = Dublin Core (vgl. <http://dublincore.org>)

⁹ FOAF = Friend Of A Friend (vgl. www.foaf-project.org)

¹⁰ SIOC = Semantically Interlinked Online Communities (vgl. <http://sioc-project.org>)

¹¹ Tim Berners Lee formuliert es in Bezug auf das Semantic Web folgendermaßen: "It's not the first time I've had this paradigm-shift problem. Early on, people really didn't understand why the Web was interesting. They saw it in the smaller scale, and it's not interesting in the smaller scale. Same thing with the Semantic Web." Siehe: www.technologyreview.com/Infotech/13784/

Vielzahl von Methoden und Technologien, mit denen *syntaktische Interoperabilität* zwischen Maschinen hergestellt werden kann, um digitale Datenbestände und deren Zusammenhänge formal zu ordnen. Der funktionale Fokus des Semantic Web liegt auf der *Daten- und Informationsintegration* bzw. *-logistik* zu Zwecken der kontextsensitiven Unterstützung von Entscheidungsprozessen und der automatisierten Kompilation von Daten und Diensten entsprechend der Praxisbedürfnisse der Nutzer. Ontologien wirken hierbei als strukturgebendes Element. Sie geleiten uns durch den Informationsstrom, funktionieren als Filter- und Navigationssysteme, lenken unsere Aufmerksamkeit und setzen das individuelle Tun in Beziehung zum übergeordneten Modell. Doch wo bleibt in einem solcherart formalisierten System die soziale Rückkoppelung?

Vom Social Web zum Social Semantic Web

Die wachsende Adaption semantischer Technologien zu Zwecken der strukturierten Erschließung von Inhalten des Social Web, aber auch zu deren kollaborativer Anreicherung mit maschinenlesbaren Metadaten ist Ausdruck eines Trends in Richtung „Social Semantic Web“. In diesem leisten die Nutzer – unterstützt durch Maschinen und die stetig wachsende Datenbasis – einen Beitrag zur strukturierten Aufbereitung von Web-Content.¹² Das Social Semantic Web beruht also auf der voranschreitenden Konvergenz von Human Computing und maschineller Datenaufbereitung. Diese vollzieht sich in Form von erweiterten „semantischen“ Funktionalitäten von Social Software Anwendungen, wie Recommender-Funktionalitäten (z. B. empfohlene Tags), Verwaltungswidgets (z. B. farbliche Hinterlegung von relevanten Begriffen), Kontext-Boxen (z. B. zusammenfassender Überblick der wichtigsten Daten) und moderierte Systeme (z. B. „Meinten-Sie“-Funktionen). Die darunter liegende Komplexität bleibt den Endnutzern jedoch weitgehend verborgen.

Social Semantic Web ist eine Back-End-Technologie, die durch das Look & Feel des Web 2.0 an die dort gebräuchlichen Praktiken anschließt. Die Einbindung von Nutzern ermöglicht die nachträgliche und kontinuierliche semantische Anreicherung von digital repräsentierbaren Wissensob-

¹² Wieviel Mehrwert der bewusst und intentional generierten Metadaten an die Endnutzer zurückfließt, ist schwer messbar, unterliegt jedoch weitestgehend der Selbstregulierung. Problematisch wird es hingegen bei von den Nutzern unbemerkt erhobenen Metadaten zu Profiling- oder Überwachungszwecken. Die aktuellen Privacy-Debatten rund um Themen wie Bundestrojaner, Vorratsdatenspeicherung oder den „Datenhunger“ von Unternehmen wie Google zeigen die Konflikte, die in diesem Bereich gelöst werden müssen [2].

jekten: So können beispielsweise Tags, mit denen Nutzer Lesezeichen verschlagworten, automatisch in einer maschinenverarbeitbaren Form abgelegt und in die dahinter liegende Ontologie eingebettet werden. Ausgereifte Methoden des Textmining und der natürlich-sprachlichen Verarbeitung unterstützen den Nutzer gleichzeitig bei der Verschlagwortung von Dokumenten, indem sie Vorschläge unterbreiten, nicht offensichtliche Relationen zwischen zwei Objekten aufzeigen und Ressourcen mit einer eindeutigen Kennung (URIs) versehen.

Im Gegenzug dient der Input der Nutzer dazu, die Ontologie, in welcher die Zusammenhänge und Funktionalitäten eines Themengebietes (Domain) oder deren begriffliche Ausgestaltung (Terminologie) modelliert sind, ständig den Präferenzen der Nutzer anzupassen, neue Zusammenhänge zu ergänzen und obsoletere Bereiche der Ontologie zu entfernen. Ontologien im Social Semantic Web müssen als dynamische Konstrukte verstanden werden, deren Gültigkeitsbereich Veränderungen unterliegt – besonders wenn sie im „Kernbereich“ des Social Web eingesetzt werden und beispielsweise soziale Beziehungen oder thematisch vernetzte Diskurse repräsentieren. In konzeptioneller Hinsicht lässt sich daher die Verknüpfung zwischen dem Social Web und dem Semantic Web über den Begriff des „Wissens“ bzw. über eine Analyse unterschiedlicher Wissensformen im Social Semantic Web herstellen, die im folgenden Abschnitt vorgenommen wird.

Prodnutzung von Wissen im Social Semantic Web

Die Nutzungsweisen und Nutzungsmuster des Internet sind immer sozial überformt, werden also durch persönliche Merkmale wie Bildungsniveau, Alter, Geschlecht oder Schicht- und Milieuzugehörigkeit beeinflusst (vgl. exemplarisch die Ergebnisse der jüngsten ARD/ZDF-Onlinestudie bei [28]). Die Trennung zwischen einer „Virtual Reality“ innerhalb und einer sozialen Wirklichkeit außerhalb des Internets ist daher nicht haltbar; vielmehr äußern sich in der Internetnutzung im Allgemeinen und der Prodnutzung im Speziellen Bedürfnisse, Routinen und Kulturtechniken, die Wirkung auch außerhalb des Internets entfalten. Sie knüpft unmittelbar an Alltagswirklichkeiten an, das heißt an Wissensbestände und Kulturtechniken, die den Menschen in unterschiedlichen sozialen Situationen, ob privater oder beruflicher Natur, zur Verfügung stehen. Gleichzeitig erzeugt Prodnutzung weiteres Wissen, Normen und Kulturtechniken, die dem Einzelnen bei der Befriedigung von Informations- oder Kommunikationsbedürfnissen helfen. Fokussiert man auf die Formen des erzeugten und dadurch für weitere Handlungen zur Verfügung stehenden Wissens, lassen sich idealtypisch drei verschiedene Typen unterscheiden [11]:

- *Content* bezeichnet Texte unterschiedlicher Medialität (also Schrift, Fotos, Video- und Audiodateien), mit denen ein Internetnutzer eine Aussage, gleich welcher Art, macht und diese zum Zweck der Verbreitung und Rezeption durch ein Publikum publiziert, d.h. ins Netz „schreibt“. Content kann in Form eigenständig adressierbarer Dokumente vorliegen, umfasst aber auch Inhalte von Datenbanken, die erst durch spezifische Nutzerabfragen dynamisch generiert werden. Content besitzt zudem keine inhaltliche Festlegung, kann also bspw. kognitiv-instrumentelle Äußerungen genauso beinhalten wie moralisch-praktische, evaluative oder expressive Aussagen.
- Der Wissenstyp *Code* umfasst die softwaretechnischen Grundlagen, die das Veröffentlichen und Verknüpfen von Content und Metadaten (s. u.) aus verschiedenen Online-Quellen ermöglichen. Er basiert auf Algorithmen, die wiederum Manifestation eines spezifischen informationstechnischen Wissens sind. Anwender mit eingeschränktem oder gar keinem informationstechnischen Wissen nehmen über Benutzerschnittstellen Einfluss auf das Programm, um die eigenen Nutzungsbedürfnisse befriedigen zu können. Eine Besonderheit der Anwendungen des Social Web ist, dass die Schwellen für das Bedienen, aber auch das Modifizieren von Code gegenüber früheren Werkzeugen weiter gesunken sind, also weniger spezialisiertes Wissen notwendig ist.
- *Metadaten* schließlich enthalten Informationen über andere Wissenstypen, insbesondere über Content. Es gibt verschiedene, einander nicht zwingend ausschließende Wege, um Metadaten zu produzieren. Sie können automatisiert mittels Textanalyseverfahren aus dem Content extrahiert werden oder durch Experten erstellt werden. Im Social Web hat das Prinzip des „Tagging“ besondere Bedeutung erlangt: Prodnutzer vergeben frei oder eingeschränkt wählbare Schlagwörter für selbst erstellten Content (z. B. zur Kategorisierung eines eigenen Videos auf sevenload.de) oder für Content anderer Nutzer, beispielsweise bei der Verschlagwortung eines Weblogeintrags auf einer Plattform wie misterwong.de oder del.icio.us.

Diese Wissenstypen stehen als Datenbestände für weitere Kommunikationen zur Verfügung, die zwischen Menschen, zwischen Mensch und Maschine oder auch zwischen Maschinen ablaufen können. Sie werden im Social Semantic Web um einen vierten Wissenstyp ergänzt:

- *Ontologien* sind Ordnungssysteme für Metadaten. Sie bilden die basalen semantischen Zusammenhänge von Wissensobjekten ab und dienen Maschinen als Abbild hermeneutischer Bedingungen. Sie generieren dazu Wissen aus Metadaten, das nicht explizit in den Metadaten vorhanden ist (z. B. über Reasoning oder Inferencing). Ontologien können nach

dem Grad ihrer Ausdruckskraft unterschieden werden [22]. Sie reichen von einfachen Indices bis zu ausgeprägten Regelsystemen und sind je nach Abstraktionsebene und Anwendungsbereich unterschiedlich stark formalisiert [5]. Grundsätzlich lässt sich feststellen, dass die Komplexität einer Ontologie mit dem Grad ihrer Ausdruckskraft steigt. Folksonomies sind Ontologien niedriger Komplexität. Auf höheren Ordnungsstufen finden sich Taxonomien, Thesauri, semantische Netze und Logik-Modelle.

Während Content, Code und Metadaten als idealtypische Wissenstypen der Prodnutzung bezeichnet werden können, weil der einzelne Nutzer gleichermaßen als deren Rezipient, Produzent und Distributor fungiert, ist das Konzept nur eingeschränkt auf Ontologien anwendbar. Diese sind Top-Down-Steuerungsinstrumente, die nur geringe Freiheitsgrade für eine kollaborative Erstellung unter Prodnutzungsbedingungen besitzen. Dafür ist verantwortlich, dass Ontologien nicht nur das Ordnungsschema von Metadaten darstellen, sondern auch deren logische und funktionale Zusammenhänge. Ontologien sind ergo keine Daten, sondern Modelle unterschiedlicher Komplexität für die Organisation derselben. Am Ende der Ontology-Value-Chain steht deswegen immer eine zentrale Instanz, welche die Ontologie wartet. So werden z. B. Folksonomies nicht von den Nutzern, sondern vom Anbieter nach einem bestimmten Algorithmus generiert.¹³ Der Nutzer hat nur beschränkt Einfluss auf die Ontologie und kann in den seltensten Fällen ihre Funktionalität verändern. Er sieht de facto nur das Ergebnis.

Zusätzlich ist festzuhalten, dass je nach Anwendungsbereich unterschiedliche Arten von Ontologien zum Einsatz kommen. Je eingrenzbarer ein Gegenstand ist, umso höher ist der Grad der Formalisierbarkeit einer Ontologie. Deswegen eignen sich technische Bereiche wie Maschinenbau hervorragend für Ontologien hoher Komplexität. Je höher die Komplexität, umso höher ist auch der Anteil der automatisch generierten Metadaten. Je größer dagegen der Interpretationsspielraum bzw. die Kontingenz eines zu repräsentierenden Gegenstandes (wie im Falle von sozialen Beziehungen, Interessen, Diskursen etc.), desto größer wird der Trade-Off zwischen Ausdruckskraft der Ontologie und Nutzerakzeptanz. In den heterarchischen Strukturen des Social Web beschränken sich Ontologien daher bislang hauptsächlich auf Folksonomies und Taxonomien.

¹³ In den meisten Fällen handelt es sich dabei um simple statistische Aggregationen von Tags zu Tagclouds (z.B. del.icio.us) oder Taxonomien (z.B. flickr.com).

Conclusio

Dieser Beitrag hat Grundlagen des Social Web und des Semantic Web skizziert sowie erste Ansatzpunkte für eine Integration beider Trends unter dem Oberbegriff des „Social Semantic Web“ diskutiert. Die Besonderheit dieses Konzepts liegt darin, die spezifischen Vorzüge der unterschiedlichen Entwicklungen zusammen zu führen. Auf Seiten des Social Web ist das der Bedeutungsgewinn der Prodnutzung, worunter das Zusammenwachsen von Produktion, Verbreitung, Bewertung und Konsumtion bzw. Rezeption von Wissens- und Kulturgütern verstanden werden soll. Auf Seiten des Semantic Web ist es die formale Struktur, welche es Maschinen ermöglicht sinnvolle Zusammenhänge zwischen Daten zu erkennen und dadurch den Nutzer bei der Navigation durch große Datenbestände und dem Auffinden von relevanten Informationen zu unterstützen. Die Synthese beider Bereiche würde ein neues Modell der Genese, Organisation und Distribution von Informationen ergeben, das zum Beispiel die Auffindbarkeit und Verfügbarmachung von User Generated Content verbessern oder Vertrauensprozesse unterstützen könnte, die für die Bewertung von Ressourcen notwendig sind.

Abgesehen davon, dass ein solch ambitioniertes Vorhaben im Rahmen eines Aufsatzes nicht einmal ansatzweise ausführlich beschrieben werden kann, ist im Zusammenhang mit der Differenzierung unterschiedlicher Wissenstypen ein grundsätzliches Problem deutlich geworden: Praktiken des Social Web beruhen auf dezentralen Produktions-, Distributions- und Bewertungsmechanismen, die sich deutlich von der hergebrachten Top-Down-Kontrolle durch professionelle Experten (wie Journalisten, Entwickler, Bibliothekare, Verleger, etc.) lösen. Es ist allerdings fraglich, inwieweit Ontologien als einer der vier grundlegenden Wissenstypen im Social Semantic Web überhaupt kollaborativ herstellbar sind, da der Endnutzer – zumindest in den meisten Fällen – nur geringen Einfluss auf das der Ontologie zugrunde liegende Ordnungsprinzip hat.

Dadurch hat aber das Social Semantic Web eine neue Kluft zwischen „Laien“ und „Experten“ eingebaut, die genau am Übergang von Metadaten (die auch bottom-up hergestellt werden können) zu Ontologien (die top-down angelegt sind) liegt. Auf letztere wird aber auch das Social Web, und damit das Internet als Ganzes in Zukunft immer weniger verzichten können, da Ontologien ein mächtiges strukturgebendes Instrument der sozialen Organisation darstellen: Sie dienen als Filter- und Steuerungssysteme und beeinflussen dadurch die Zugänglichkeit (Accessibility) und Verfügbarmachung (Provision) von Information. Diese Leistungen werden gerade dadurch immer wichtiger, dass Prodnutzung ja mit einer ungekannten Zunahme von Wissen einhergeht und so Mechanismen des Informations-

managements zwingend erforderlich macht. Damit wäre gleichzeitig die Gefahr des „*Hijacking the Hive*“ (s. o.) gegeben, also einer Ausbeutung der Arbeitsleistungen von Prodnutzern durch die Entwickler oder Anbieter von ontologiebasierten Diensten, die Orientierung im Datenmeer bieten.

Diesem Szenario steht jedoch entgegen, dass Prodnutzungsumgebungen vom Vertrauen ihrer User leben. Vorausgesetzt, den Nutzern stehen gleichwertige alternative Angebote zur Verfügung (um Lock-In-Effekte zu vermeiden), ist von einer Selbstregulierung auszugehen, die „unfair“ agierende Service-Anbieter reguliert. Selbst wenn die Steuerungsmacht zwischen den Akteuren in einer Prodnutzungsumgebung ungleich verteilt ist, so zeigt die momentane Entwicklung im Social Web aber auch, dass es Alternativstrategien gibt – möglicherweise ist daher die Kluft kein tatsächliches Problem, sondern es wird zu einer „Koexistenz“ von Top Down- und Bottom-Up-Ansätzen in der Wertschöpfung kommen. Zudem: Stellt man in Rechnung, dass das momentane Niveau von Prodnutzung noch vor wenigen Jahren nicht absehbar war, dürfen wir nicht ausschließen, dass die parallele Entwicklung von innovativen Technologien und sozialen Praktiken zu ganz neuen Formen der Wissensgenerierung führt, die heutige Unterscheidungen völlig obsolet machen.

Literatur

1. Anderson, Chris (2006). The long tail. Why the future of business is selling less of more. New York: Hyperion.
2. Bendrath, Ralf (2007). Der „gläserne Bürger“ und der vorsorgliche Staat. Zum Verhältnis von Überwachung und Sicherheit in der Informationsgesellschaft. In: kommunikation@gesellschaft, Jg. 8, Beitrag 7. Online-Publikation: http://www.soz.unifrankfurt.de/K.G/B7_2007_Bendrath.pdf.
3. Benkler, Yochai (2006). The wealth of networks. How social production transforms markets and freedom. New Haven/London: Yale University Press
4. Berners-Lee, T.; Cailliau, R.; Luotonen, A.; Nielsen, H. F.; Secret, A. (1994). The world-wide web. Communications of the ACM, 37(8), S. 76–82.
5. Blumauer, Andreas; Pellegrini, Tassilo (2006). Semantic Web und semantische Technologien. Zentrale Begriffe und Unterscheidungen. In: Pellegrini, Tassilo; Blumauer, Andreas (Hg.). Semantic Web. Wege zur vernetzten Wissensgesellschaft. Berlin: Springer Verlag, S. 9–25.
6. Boyd, Danah (2007). The significance of social software. In: Burg, Thomas N./ Jan Schmidt (Eds.): BlogTalks reloaded. Norderstedt: Books on Demand. S. 15–30.
7. Bruns, Axel (2007a). Produsage: Toward a broader framework of user-led content creation. Vortrag bei der „Creativity & Cognition Conference“, 13.–15.6.2007, Washington D.C. Online verfügbar: [http://produsage.org/files/Produsage%20\(Creativity%20and%20Cognition%202007\).pdf](http://produsage.org/files/Produsage%20(Creativity%20and%20Cognition%202007).pdf).

8. Bruns, Axel (2007b). The future is user-led. Vortrag bei der „PerthDAC conference“, 15.–18.9.2007, Perth. Online verfügbar: [http://produsage.org/files/The%20Future%20Is%20User-Led%20\(PerthDAC%202007\).pdf](http://produsage.org/files/The%20Future%20Is%20User-Led%20(PerthDAC%202007).pdf).
9. Ghosh, Rishab Aiyer (2006). Economic Impact of Open Source Software on Innovation and the Competitiveness of the Information and Communication Technologies (ICT) Sector in the EU. Final report to the European Commission. Online verfügbar: <http://ec.europa.eu/enterprise/ict/policy/doc/2006-11-20-flossimpact.pdf>.
10. Giddens, Anthony (1988). Die Konstitution der Gesellschaft. Frankfurt/New York: Campus.
11. Guenther, Tina; Jan Schmidt (im Druck). Wissenstypen im „Web 2.0“ – eine wissenssoziologische Deutung von Prodnutzung im Internet. In: Willems, Herbert (Hrsg.). Weltweite Welten. Internet-Figurationen aus wissenssoziologischer Perspektive. Wiesbaden: VS Verlag.
12. Heinrich, Hartmut; Holl, Friedrich-L.; Menzel, Katharina; Mühlberg, Jan; Schäfer, Ingo; Schüngel, Hanno (2006). Open-Source-Software und ihre Bedeutung für innovatives Handeln. Berlin. Online verfügbar: http://www.bmbf.de/pub/oss_studie.pdf.
13. Höflich, Joachim R. (2003). Mensch, Computer und Kommunikation: Theoretische Verortungen und empirische Befunde. Frankfurt a.M.: Peter Lang.
14. Jenkins, Henry (2006). Convergence Culture: Where Old and New Media Collide. New York/London: New York University Press.
15. Lessig, Lawrence (2004). Free Culture. The nature and future of creativity. New York: Penguin.
16. Mittendorfer, Kristina (Hrsg.) (2006). Mindestens haltbar. Buch für Meinungen. Norderstedt: Books on Demand.
17. O'Reilly, Tim (2005). What is the Web 2.0? Design patterns and business models for the next generation of software. Online-Publikation: <http://www.oreilly.de/artikel/web20.html>.
18. Ostrom, Elinor (1990). Governing the Commons: The Evolution of Institutions for Collective Action. New York: Cambridge University Press.
19. Prahalad, C. K.; Ramaswamy, Venkat (2004). Co-creation experiences: The next practice in value creation. In: Journal of Interactive Marketing, 2004/18, 3, S. 5–14.
20. Reckwitz, Andreas (1997). Struktur. Zur sozialwissenschaftlichen Analyse von Regeln und Regelmäßigkeiten. Opladen: VS Verlag.
21. Reichwald, Ralf; Piller, Frank (2003). Von Massenproduktion zu Co-Produktion: Kunden als Wertschöpfungspartner. In: Wirtschaftsinformatik, 45/5, 2003, S. 515–519.
22. Schaffert, Sebastian; Gruber, Andreas; Westenthaler, Rupert (2006). A Semantic Wiki for Collaborative Knowledge Creation. In: Reich, Siegfried; Güntner, Georg; Pellegrini, Tassilo; Wahler, Alexander (Hg.). Semantic Content Engineering. Linz: Trauner Verlag, S. 188–202.
23. Schmidt, Jan (2006). Weblogs. Eine kommunikationssoziologische Studie. Konstanz: UVK.

24. Schmidt, Jan (2007). Social Software: Facilitating information-, identity- and relationship management. In: Burg, Thomas N.; Jan Schmidt (Eds.): *Blog-Talks reloaded*. Norderstedt: Books on Demand. S. 31–49.
25. Schweiger, W.; Quiring, O. (2006). User-Generated Content auf massenmedialen Websites – eine Systematik. In Friedrichsen, M.; Mühl-Benninghaus, W.; Schweiger, W. (Hrsg.), *Neue Technik, neue Medien, neue Gesellschaft? Ökonomische Herausforderungen der Onlinekommunikation*, München: Reinhard Fischer, S. 97–120.
26. Sotamaa, Olli (2007). On modder labour, commodification of play, and mod competitions. In: *First Monday*, volume 12, number 9 (September 2007), URL: http://firstmonday.org/issues/issue12_9/sotamaa/index.html.
27. Toffler, Alvin (1980). *Die Zukunftschance. Von der Industriegesellschaft zu einer humaneren Zivilisation*: München: Bertelsmann Verlag.
28. van Eimeren, Birgit; Frees, Beate (2007). Internetzung zwischen Pragmatismus und YouTube-Euphorie. ARD/ZDF-Online-Studie 2007. In: *Media-Perspektiven*, Nr. 8/2007, S. 362–378.

23. Implications of Emerging Data Mining

Narayanan Kulathuramaiyer¹ and Hermann Maurer²

¹ Faculty of Computer Science and Information Technology,
University Malaysia Sarawak, Malaysia; nara@iicm.edu

² Institute for Information Systems and Computer Media (IICM), Graz
University of Technology, Austria; hmaurer@iicm.edu

Abstract: Data Mining describes a technology that discovers non-trivial hidden patterns in a large collection of data. Although this technology has a tremendous impact on our lives, the invaluable contributions of this invisible technology often go unnoticed. This paper discusses advances in data mining while focusing on the emerging data mining capability. Such data mining applications perform multidimensional mining on a wide variety of heterogeneous data sources, providing solutions to many unresolved problems. This paper also highlights the advantages and disadvantages arising from the ever-expanding scope of data mining. Data Mining augments human intelligence by equipping us with a wealth of knowledge and by empowering us to perform our daily tasks better. As the mining scope and capacity increases, users and organizations become more willing to compromise privacy. The huge data stores of the ‘master miners’ allow them to gain deep insights into individual lifestyles and their social and behavioural patterns. Data integration and analysis capability of combining business and financial trends together with the ability to deterministically track market changes will drastically affect our lives.

Introduction

As we become overwhelmed by an influx of data, Data Mining presents a refreshing means to deal with this onslaught. Data Mining thus holds the key to many unresolved, age-old problems. Having access to data thus becomes a powerful capability which can be effectively harnessed by sophisticated mining software.

According to [9], data mining is defined as the extraction of interesting (non trivial, implicit, previously unknown and potentially useful) information or patterns from data in large databases. We take a broad view of data mining, where we also include other related machine based discoveries

such as deductive query processing and visual data mining. Databases may include both structured data (in relational databases), semi-structured data (e.g. metadata in XML documents) as well as unstructured documents such as text documents and multimedia content.

Data mining has been widely employed for the learning of consumer behaviour based on historical data of purchases made at retail outlets. Demographic data as collected from loyalty cards is combined with behavioural patterns of buyers to enable retailers in designing promotional programmes for specific customer segments. Similarly, credit card companies use data mining to discover deviations in spending patterns of customers to overcome fraud. Through this, these companies are able to guarantee the highest quality of service to their customers.

Despite these success stories in areas such as customer relationship modelling, fraud detection, banking [15], the majority of applications tend to employ generic approaches and lack due integration with workflow systems. As such, Data Mining is currently seen as being at a chasm state and has yet to become widely adopted by the large majority [9].

Overview of Data Mining Process

Having access to data thus becomes a powerful capability which can then effectively be harnessed by sophisticated mining software. The statement by O'Reilly [5] that 'Data is the Next Intel Inside' illustrates its hidden potency. Data at the hands of credit card companies will allow them to profile customers according to lifestyles, spending pattern and brand loyalty. Political parties are now able to predict with reasonable accuracy how voters are likely to vote [27].

Data Mining involves the extraction of patterns from a collection of data via the use of machine learning algorithms. Sophisticated mining technologies of today integrate multiple machine learning algorithms to perform one or more of the following functions:

- construct an aggregated or personalised, predictive model of systems, events and individuals being studied and supporting decision making by employing these models in a number of ways (extraction of classification patterns)
- identify similarity/dissimilarity in terms of distributional patterns of data items and their relationships with associated entities (clustering)
- uncover associational and behavioural patterns based on relationship drawn from transactional data (associational pattern mining)

- determine trends highlighting both the norm as well as deviations based on observable patterns (e.g. mathematical data modelling)
- determine sequential patterns amongst a number events or state of data objects to depict behavioural patterns (sequential pattern mining)

Data Mining typically describes an automated acquisition of knowledge from a large collection of data. This traditional view corresponds to the knowledge creation phase in knowledge management. Current developments of data mining have expanded this to also cover support for knowledge organization and consolidation with respect to existing domain knowledge, and data visualization for iterative learning. Data Mining can thus be seen as complementing and supplementing knowledge management in a variety of phases.

Data Mining Process

In order to describe the processes involved in performing data mining we divide it into 3 phases: domain focusing, model construction (actual mining using machine learning algorithms), and decision making (applying the model to unseen instances).

The domain focusing phase involves the application of some form of clustering or may incorporate intensive knowledge engineering for complex applications. At the model construction phase, a model of generalized patterns is constructed to capture the intrinsic patterns stored in the data.

The model generated is then employed for decision-making. Simplistic applications of data mining tend to merely employ the model to predict the likelihood of events and occurrences, based largely on past patterns. Amazon, for example, is able to recommend books according to a user's profile. Similarly, network operators are able to track fraudulent activities in the usage of phone lines by tracking deviation patterns as compared to standard usage characterization. Figure 1 compares the elaborate mining tasks performed in an emerging application as opposed to a traditional data mining system.

In emerging applications, domain focusing will be concerned with the discovery of causal relationships (e.g. using Bayesian networks) as a modelling step. Multiple sources of data need to be incorporated in the discovery of likely causal relationship patterns. A complex form of data mining is required even at the phase of domain focusing. This will involve an iterative process whereby hypothesis generation could be employed to narrow the scope of the problem to allow for a constrained but meaningful data collection. For complex domains such as this, domain focusing can also




Fig. 1. Illustration of steps involved in a DM Process

provide insights on constraining and refining the data collection process. Domain focusing would thus perform problem detection, finding deterministic factors and to hypothesize relationships that will be applied in the model [3].

The model construction phase will then employ a variety of learning algorithms, to profile events or entities being modelled. As this stage may negate model relationships, domain focusing will need to be repeated and iteratively performed. The model construction phase will allow the incremental development of a model, based on a complex representation of the causal networks [3].

Mining methods (e.g. clustering, associational rule mining, Bayesian or neural network classifiers) could be used to verify the validity of causal associations. Once a potential causal link is hypothesized, verification can be done via the application of data mining methods. A combination of approaches could be employed to include deviation detection, classification, dependence model and causal model generation [3].

The Decision Making phase will subsequently apply the validated causal relationship model in exploring life case studies. An environment for an interactive explorative visual domain focusing is crucial, to highlight directions for further research. Data mining could serve as a means of characterization of profiles for both areas prone to disasters or those that are safe. The results of the data mining process would need to be seen merely as recommendations or suggested relationship in complex applications. It is thus typical to engage the community in verifying the results in an on-the-job scenario (as described in [25]).

Applications of Data Mining

Emerging forms of data mining applications deal with complex-structured domain problems, e.g. environmental modelling and medical data mining. The lack of awareness of the structure of complex domain problems reveals the importance of data collection presenting a need for discovery of social behavioural patterns. Social relationship discovery will serve as a means of providing a deeper understanding for many of such domain problems.

Environmental Modelling Application

For complex-structured problems, data mining could be used to provide answers by uncovering patterns hidden beneath layers of data. In many cases, domain focusing has in the past been the biggest challenge. Data mining could be employed for the modelling of environmental conditions in the development of an early warning system to address a wide range of natural disasters such as avalanches, landslides, tsunami and other environment events such as global warming. The main challenge in addressing such problems is in the lack of understanding of structural patterns characterizing various parameters.

As highlighted by [22], although a large variety of computer-based methods have been used for the prediction of natural disasters, the ideal instrument for forecasting has not been found yet. As highlighted in their paper, there are also situations where novel techniques have been employed but only to a narrow domain of limited circumstances.

Integration of multiple databases and the compilation of new sources of data are required in the development of full-scale environmental solutions. As advances in technology allow the construction of massive databases through the availability of new modes of input such as multimedia data and other forms of sensory data, data mining could well provide a solution. In order to shed insights on a complex problem such as this, massive databases that were not previously available need to be constructed, e.g. data about after event situations of the past [22]. Such data on past events could be useful in highlighting patterns related to potentially in-danger sites. Data to be employed in this mining will thus comprise of both of weather and terrestrial parameters together with other human induced parameters such as vegetation or deforestation over a period of time [22]. As such the mining of social and behavioural patterns will also play an important role in such complex applications.

Medical Application

In the medical domain, data mining can be applied to discover unknown causes to diseases such as ‘sudden death’ syndrome or heart attacks which remain unresolved in the medical domain. The main difficulty in performing such discoveries is also in collecting the data necessary to make rational judgments. Large databases need to be developed to provide the modelling capabilities. These databases will comprise of clinical data on patients found to have the disease, and those who are free of it. Additionally non-traditional data such as including retail sales data to determine the purchase of drugs, and calls to emergency rooms together with auxiliary data such as micro array data in genomic databases and environmental data would also be required. [20]

Non traditional data could also incorporate major emotional states of patients by analyzing and clustering the magnetic field of human brains which can be measured non-invasively using electrodes to a person’s head [22]. Social patterns can also be determined through profile mining as described in the previous section to augment the findings of this system. The power of considering social patterns in gaining deeper insights on focused individuals is explained in the next section.

The development of large databases for medical explorations will also open possibilities for other discoveries such as mining family medical history and survival analysis to predict life spans [9]. The process of data mining in such domains will involve numerous iterations in data focusing and scooping before data mining validates relationships.

Web Mining and Search as a Social Data Mining Application

Web Mining can typically be divided into Web Page content mining, Web structure mining and Web log mining (including search log). Traditional search engines basically utilised web content only for building their index of the Web. Web structure has however become important in current search engines which employs web structure patterns to determine popularity of websites (i.e. the PageRank algorithm). Web log mining is also becoming an important source of data mining for providing an analysis of customer relationship modelling and other form of user profiling. Global search engines of today combine these three forms of mining to provide results that are able to meet users’ needs better. As the Semantic Web emerges, content mining of semantic relationships will also begin to be explored. As such travel agents could mine Web contents to populate their semantic web of flight schedules, or hotel price listings. We will now

focus on Web Search as a complex form of data mining at both a collective level and at a personal level, in revealing the true potential of unlimited data mining.

Search engines have turned the Web into a massive data warehouse as well as a playground for automated discovery of hidden treasures. Web Search is thus viewed as an extensive form of multidimensional heterogeneous mining of a largely unstructured database for uncovering an unlimited number of mind-boggling facts. The strength of search engines stems from its absolute control over vast collections of data and the various analytical tools it has. These tools include text processing and mining systems, translators, content aggregators, data visualisation tools, data integration tools, data traffic analyzers, financial trend analyzers, context aware systems, etc. The analytical tools provide alternative mining resources for enhancing the quality of discoveries.

The data at their disposal include, but are not limited to web pages, email collections, discussion groups and forums, images, video, books, financial data, news, desktop content, scholarly papers, patents, geographical data, chronological data, community-generated, dynamically tagged content (video, music, text), product offerings, local business data, shared documents, and user profiles. The expanse of data resources is effectively exploited in their ability to support users' decision-making process, as well as in providing alternative channels for further investigation. The scale of data available is in the range of petabytes, and it much greater than the terabytes of data available at the hands of large global corporations such as Walmart.

Search engines can either simultaneously or incrementally mine these datasets to provide a variety of search results which include phone contacts, street addresses, news feeds, dynamic web content, images, video, audio, speech, books, artifacts.

The distinguishing feature of the mining performed is seen in domain focusing. A model allowing the characterization of aggregated user search behaviour is constructed [4]. This phase may also involve associational subject link analysis, requiring a context-sensitive domain analysis (as done for mobile users). This Mining phase involves the derivation of aggregated usage profiles based on a multidimensional mining of usage patterns according to clustered characterization. Figure 2 illustrates the scope and extent of mining performed by search engines.

By analyzing search history over a period of time, search engines have access to a great deal of insights into lives of presumably 'anonymous' searchers. A search query can indicate the intent of a user to acquire particular information to accomplish a task at hand. Search engines can thus track patterns and drifts in global user intentions, moods, and thoughts.




Fig. 2. Extensive Mining of Heterogeneous Data sources

Search traffic patterns are another data source that can be applied to highlight relationships between search terms and events. For instance the number of searches for „Christmas presents“ peaks in the early part of the month of December [11]. Search traffic data analysis has also been shown to reveal social and market patterns such as unemployment and property market trends (see [33]). Apart from that, the intentions of global users can be modelled by terms employed in search. An illustration of intent revealing search queries can be discovered via the AOL search database [37] (which allows the search results leaked by AOL [14] to be used for academic purposes). The intent logs make the intentions of users absolutely obvious to global search companies. Examples of such search queries include ‚finance major vs. accounting major‘, ‚shoes from India‘, ‚what does vintage mean‘, ‚baby looney tunes baby shower party invitations‘, ‚how many web pages are on the internet‘, ‚feline heartworm remedies‘, ‚salaries for forensic accountants‘, ‚hamilton county chinese stores that sell chinese candy white rabbit‘, ‚how do you read the stock market or invest in stock‘, ‚on the basis of the settlement of unfortunate past and the outstanding issues of concern‘, ‚riverview towers apartment information in Pittsburg‘. A sudden burst of search term frequency has been observed seeking quick answers to questions posed in reality shows, such as „Who wants to be a Millionaire“ [36]. An emerging paradigm, mashups (see [18]) together with mobile web services further allows the discovery of localised contextual profiles.




Fig. 3. Insightful Connected Discoveries

Targeted advertisements based on keyword-bidding are currently employed by search engines. In the near future, complex mining capabilities will provide personalised, context-specific suggestions which will intrude into our daily life. E.g. it would be possible via RFID technology, for a user passing by an intelligent electronic billboard (as described in [26]) to en-




Fig. 4. Search and Social Interaction History can reveal a great deal of information about users

counter a highly personalized messages such as ‘Nara, you have not purchased your airline ticket yet, you have only 2 weeks for your intended flight. I do know of a discount you can’t refuse’. Such a level of user profiling could easily be achieved by merely connecting shopping cart analysis, together with cookies and calendar entries. Figure 3 illustrates the layered mining that could be employed to facilitate such a discovery. This is described by [17] as connecting the dots, to illustrate the ability to extract and harness knowledge from massive databases at an unprecedented level.

Figure 4 then illustrates the amount of knowledge about anonymous users that could be established by global search engines, via the connection of dots (see [17]). We will now concentrate on the implications of this technology on our lives.

Implications of Data Mining

The Advantages of Data Mining

Data mining has crept into our lives in a variety of forms. It has empowered individuals across the world to vastly improve the capacity of decision making in focussed areas. Powerful mining tools are going to become available for a large number of people in the near future.

The benefits of data mining will include preserving domestic security through a number of surveillance systems, providing better health through medical mining applications, protection against many other forms of intriguing dangers, and access to just-in-time technology to address specific needs. E.g. police in the United States are using a software called CopLink that is able to discover relationships leading to identification of suspects by connecting data from multiple sources [7]. Data Mining will also provide companies with effective means of managing and utilizing resources. People and organizations will acquire the ability to perform well-informed (and possibly well-researched) decision-making. Data mining also provides answers through sifting through multiple sources of information which were never known to exist, or could not be conceivably acquired to provide enlightening answers. Data Mining could be combined with collaborative tools to further facilitate and enhance decision-making in a variety of ways. Data mining is thus able to explicate personal or organizational knowledge which may be locked in the heads of individuals (tacit knowledge) or in legacy databases, and make it available. Many more new benefits will emerge as technology advances.

Disadvantages of Data Mining

A great deal of knowledge about users is also being maintained by governments, airlines, medical profiles or shopping consortiums. Mining applications with dramatic privacy infringement implications include search history, real-time outbreak and disease surveillance program, early warning for bio-terrorism [30] and Total Information Awareness program [1]. For example, search history data represents an extremely personal flow of thought patterns of users that reflects ones quest for knowledge, curiosity, desires, aspirations, as well as social inclinations and tendencies. Such logs can reveal a large amount of psychographic data such as users' attitudes towards topics, interests, lifestyles, intents and beliefs. A valid concern would be that the slightest leak could be disastrous. The extent of possible discoveries has been clearly illustrated by the incidence where AOL released personal data of 658,000 subscribers [13, 14].

Another common danger is profiling where there is a possibility of drastic implications such as a conviction being made based on the incriminating evidences of mining results. There is also a danger of over-generalization based on factors such as race, ethnicity, or gender. This could result in false positives, where an entirely innocent individual or group is targeted for investigation based on a poor decision making process. For the domestic security application, a reasonable data mining success rate of 80% implies that 20% of all US citizens (or 48 million people) would be considered false positives [21].

Data mining will further empower mining kingpins to be able to go beyond the ability to PREDICT what is going to happen in a number of areas of economic importance, but actually have the power to KNOW what will happen. It is possible to detect trends and social behavioural patterns (e.g. stock purchase, property acquisition) by analyzing traffic data and data logs of millions of users. Could such a capability not be applied to exploit the stock market in an unprecedented way?

By connected domain focusing, they will also have the capacity to make judgments on issues and persons with scary accuracy. There have been instances when the data archived by global search engines were used as incriminating evidences in criminal proceedings which have led to convictions.

What can we do?

Most related works are concerned more about privacy, but it is no longer the main issue of concern. [16] has proposed a means of protecting anonymity by the use of anonymity agents and pseudonym agents to avoid

users from being identified. Their paper also proposed the use of negotiation and trust agents to assist users in reviewing a request from a service before making a rational decision of allowing the use of personal data.

A similar agent-based approach is described by [31] via rule-based processing. An „intelligent agent“ is used for dispatching a query to distributed databases. The agent will negotiate access and permitted uses for each database. Data items are labelled with meta-data describing how that item must be processed. Thus, a data item is protected as it retains relevant rules by which it describes the way it has to be processed. The main challenge then lies in coming up with guidelines and rules such that site administrators or software agents can use to direct various analyses on data without compromising the identity of an individual user. This approach however is not applicable for areas such as Web search, where a standard framework for conscientious mining is far from sight.

Furthermore, the concern with the emergence of extensive mining is no longer solved by addressing privacy issues only. As more and more people are willing to compromise privacy, the questions that we pose are: Who do we trust as the gatekeeper of all our data? Do we then trust all our private data at the hands of a commercial global company?

One approach to overcome the concerns mentioned above is by employing a distributed data mining approach, where separate agencies will maintain and become responsible and accountable for different (independent segments of) data repositories. This proposal further ensures that no central agency will have an exclusive control over the powerful mining technology and all resources [18]. In order to realize this solution, governments have to start playing a more proactive role in maintaining and preserving national or regional data sources. If such initiatives can be put in place, then it will be possible to also explore the sensitivities associated with data control even at an applications design phase. The research by [6] can be applied in considering data sensitivities at the design process.

We are also beginning to see partnerships between global search engines and governments in this respect. Such partnerships should however be built upon a balanced distribution of earnings. Such a solution can be complemented by the existence of a large number of autonomous context-specific or task specific miners.

Conclusion

As data mining matures and becomes widely deployed in even more encompassing ways, we need to learn to effectively apply it to enrich our lives. At the same time, the dangers associated with this technology needs

to be minimized by deliberate efforts on the part of the enforcement agencies, data mining agencies and the users of the system. There should be strict regulations to prevent the abuse or misuse of data. Users should also be made aware of the privacy policies in order to make an informed decision about revealing their personal data. The success of such regulations and guidelines can only be guaranteed if they are backed up by a legal framework.

References

1. Anderson, S.R., Total Information Awareness and Beyond, Bill of Rights Defense Committee; White paper. The Dangers of Using Data Mining Technology to Prevent Terrorism, July 2004.
2. Battelle, J., The Search--How Google and Its Rivals Rewrote the Rules of Business and Transformed our Culture, Portfolio, Penguin Group, New York, 2005.
3. Beulens, A., Li, Y., Kramer, M., van der Vorst, J., Possibilities for applying data mining for early Warning in Food Supply Networks, CSM'06, 20th Workshop on Methodologies and Tools for Complex System Modeling and Integrated Policy Assessment, August, 2006 http://www.iiasa.ac.at/~marek/ftppub/Pubs/csm06/beulens_pap.pdf.
4. Coole, R. Mobasher, B., Srivastava, J., Grouping Web Page References into Transactions for Mining World Wide Web Browsing Patterns, Proceedings of the 1997 IEEE Knowledge and Data Engineering Exchange Workshop Page: 2, 1997 ISBN:0-8186-8230-2 IEEE Computer Society.
5. American Travelers to Get Secret 'Risk Assessment' Scores, Electronic Frontier Foundation (EFF), November 30, 2006, http://www.eff.org/news/archives/2006_11.php.
6. Friedman, B., Kahn, P. H., Borning, A., Value Sensitive Design: Theory and Methods, June 2003, <http://www.ischool.washington.edu/vsd/vsd-theory-methods-draft-june2003.pdf>.
7. Goldman, J., Google for Cops: Revolutionary software helps cops bust criminals, TechTV, April 12, 2003, <http://www.techtv.com/news/scitech/story/0,24195,3424108,00.html>
8. Graham, J., Page, C. D., Kamal, A., Accelerating the Drug Design Process through Parallel Inductive Logic Programming Data Mining. Proceedings of the Computational Systems Bioinformatics IEEE Computer Society, 2003 <http://ieeexplore.ieee.org/iel5/8699/27543/01227345.pdf>.
9. Han, J., and Kamber, M., Data Mining: Concepts and Techniques, 2nd ed., The Morgan Kaufmann Series in Data Management Systems, Jim Gray, Series Editor, Morgan Kaufmann Publishers, March 2006.
10. Hofgesang, P. I., and Kowalczyk, W., Analysing Clickstream Data: From Anomaly Detection to Visitor Profiling, ECML/PKDD Discovery Challenge 2005 <http://www.cs.vu.nl/ci/DataMine/DIANA/papers/hofgesang05pkdd.pdf>.

11. Hopkins, H., Poker & Fantasy Football – Lessons on Finding Affiliate Partnerships, Hitwise Weblogs, 22 Jan 2005 <http://weblogs.hitwise.com/heather-hopkins/2005/11/>.
12. Jenssen, D., Data mining in networks. Invited talk to the Roundtable on Social and Behavior Sciences and Terrorism. National Research Council, Division of Behavioral and Social Sciences and Education, Committee on Law and Justice. Washington, DC. December 11, 2002.
13. Jones, K.C., Fallout From AOL's Data Leak Is Just Beginning, <http://www.informationweek.com/news/showArticle.jhtml?articleID=191900935>, accessed 2007.
14. Kantor, A., AOL search data release reveals a great deal, USA Today, August, 17, 2006, http://usatoday.com/tech/columnist/andrewkantor/2006-08-17-aol-data_x.htm.
15. KDnuggets: Polls: Successful Data Mining Applications, July 2005 http://www.kdnuggets.com/polls/2005/successful_data_mining_applications.htm.
16. Kovatcheva, E., Tadinen, H., The technological and social aspects of data mining by means of web server access logs <http://www.pafis.shh.fi/~elikov02/SFISWS2/SFIS2.html> 18 January 2002
17. Kulathuramaiyer, N., Balke, W.-T., Restricting the View and Connecting the Dots – Dangers of a Web Search Engine Monopoly, J UCS Vol. 12, Issue 12, pp. 1731–1740, 2006.
18. Kulathuramaiyer, N., Maurer, H., „Why is Fighting Plagiarism and IPR Violation Suddenly of Paramount Importance?“ Proc. of International Conference on Knowledge Management, Vienna, August 2007.
19. Lane, M., How Terror Talk is Tracked, BBC News Online Wednesday, 21 May, 2003, http://news.bbc.co.uk/2/hi/uk_news/3041151.stm.
20. Li, C. S., Survey of Early Warning Systems for Environmental and Public Health Applications, in Wong, S., Li, C. S. (eds.), Life Science Data Mining, Science, Engineering, and Biology Informatics, Vol. 2, 2007 http://www.worldscibooks.com/compsci/etextbook/6268/6268_chap01.pdf.
21. Manjoo, F., Is Big Brother Our Only Hope Against Bin Laden?, Dec. 3, 2002 http://www.salon.com/tech/feature/2002/12/03/tia/index_np.html.
22. Maurer, L., Klingler, C., Pachauri, R. K., Tochtermann, K., Data Mining as Tool for Protection against Avalanches and Landslides, Proc. Environmental Informatics Conference, Warsaw, 2007.
23. Milne, G. R., Privacy and ethical issues in database/interactive marketing and public policy: A research framework and overview of the special issue, Journal of Public Policy & Marketing, Spring 2000.
24. Mobasher, B., Web Usage Mining and Personalisation, in Singh, M. P. (ed.) Practical Handbook of Internet Computing, Chapman & Hall/ CRC Press, 2005 <http://maya.cs.depaul.edu/~mobasher/papers/IC-Handbook-04.pdf>.
25. Mobasher, B., Data Mining for Personalization. In The Adaptive Web: Methods and Strategies of Web Personalization, Brusilovsky, P., Kobsa, A., Nejdl, W. (eds.). Lecture Notes in Computer Science, Vol. 4321. Springer-Verlag, Berlin Heidelberg, 2006, <http://maya.cs.depaul.edu/~mobasher/papers/aw06-mobasher.pdf>.

26. NewScientistTech. Street advertising gets local-stock-savvy, NewScientist.com, January 10, 2007 <http://technology.newscientist.com/article/mg19325854.900-street-advertising-gets-localstocksavvy.html>.
27. Rash, W., Political Parties Reap Data Mining Benefits, eWeek.com enterprise News and reviews, November 16, 2006 <http://www.eweek.com/article2/0,1895,2060543,00.asp>.
28. Shermach, K. Data Mining: where legality and ethics rarely meet, <http://www.crmbuyer.com/story/52616.html>, 25th January 2006.
29. Singel, R., Sep, 18, 2003 <http://www.wired.com/news/privacy/0,1848,60489,00.html>.
30. Spice, B., Privacy in age of data mining topic of workshop at CMU, March 28, 2003 <http://www.post-gazette.com/nation/20030328snoopingnat4p4.asp>.
31. Taipale, K.A. „Data Mining and Domestic Security: Connecting the Dots to Make Sense of Data“. *Colum. Sci. & Tech. L. Rev.* 5 (2). SSRN 546782/OCLC 45263753, December 15, 2003.
32. Tanasa, D., and Trousse, B., Advanced Data Preprocessing for Intersites Web Usage Mining, AxIS Project Team, INRIA Sophia Antipolis Published by the IEEE Computer Society MARCH/APRIL 2004 <http://ieeexplore.ieee.org/iel5/9670/28523/01274912.pdf?arnumber=1274912>.
33. Trancer, B. 2007, July Unemployment Numbers (U.S.) – Calling All Economists http://weblogs.hitwise.com/bill-tancer/2006/08/july_unemployment_numbers_us_c.html Accessed 17 January 2007.
34. Vaughan-Nichols, S. J., Researchers make Search more intelligent, Industry Trends in Computer, (Eds.) Lee Garber, IEEE Computer Society, December 2006.
35. Vise, D.A., Malseed, M., 2006, The Google Story- Inside the Hottest Business, Media and Technology Success of our Time, Pan MacMillan Books, Great Britain, 2006.
36. Witten, I.H., Gori, M., Numerico, T., Web Dragons, 2007, Inside the Myths of Search Engine Technology, Morgan Kaufmann, San Francisco, 2007.
37. Zao, D., Sapp, T., 2006 AOL Search Database, <http://www.aolsearchdatabase.com/>.

24. Privacy im Social Semantic Web

Michael Nagenborg

Universität Tübingen, Interfakultatives Zentrum für Ethik in den Wissenschaften,
Projekt THEBEN, Tübingen, Deutschland
michael.nagenborg@izew.uni-tuebingen.de

Zusammenfassung: Der Schwerpunkt dieses Beitrages liegt auf dem Design von Infrastrukturen, welche es ermöglichen sollen, private Daten kontrolliert preiszugeben und auszutauschen. Zunächst wird daran erinnert, dass rechtliche und technische Maßnahmen zum Datenschutz stets auch dazu dienen, den Austausch von Daten zu ermöglichen. Die grundlegende Herausforderung besteht darin, der sozialen und politischen Bedeutung des Privaten Rechnung zu tragen. Privatheit wird aus der Perspektive der Informationsethik dabei als ein normatives, handlungsleitendes Konzept verstanden. Als Maßstab für die Gestaltung der entsprechenden Infrastrukturen wird auf Helen Nissenbaums Konzept der „privacy as contextual integrity“ zurückgegriffen, um u. a. die Ansätze der „end-to-end information accountability“ [38] und des „Privacy Identity Management for Europe“-Projektes zu diskutieren.

Vergesst Privacy?

In Anschluss an Beate Rössler (2001) wird in der deutschen Diskussion zwischen der dezisionalen, informationellen und lokalen Bedeutungsdimension des Privaten unterschieden. Wo in der deutschen Diskussion um Informations- und Kommunikationstechnologien (IuK-Technologien) von „privacy“ die Rede ist, ist die informationelle Privatheit gemeint: „Im Kern geht es hier ... darum, wer was wie über eine Person weiß, also um die Kontrolle über Informationen, die eine Person betreffen“ [1].

Die Übersetzung von „Privatheit“ mit „Privacy“ ist zwar nicht unproblematisch [9], jedoch wird im Folgenden stets die informationelle Bedeutungsdimension gemeint sein, wenn von *privacy* die Rede ist. Es sei jedoch gleich angemerkt, dass die analytische Unterscheidung zwischen den drei

Bedeutungsdimensionen irreführend sein kann [15]. In der Diskussion um ubiquitäre Computersysteme z. B. gilt es die deutlichen Überschneidungen zwischen der lokalen und informationellen Privatheit zu beachten.

Auch der von Rössler benannte Kern ist umstritten: Wie Hermann Tavani [32] zu recht betont, ist eine Beschränkung auf den Kontroll-Aspekt wenig hilfreich. Wenn wir ganz strikt annehmen wollen, dass wir nur dort sinnvoll von *privacy* sprechen können, wo Personen die vollständige Kontrolle über alle sie betreffenden Daten haben, dann leben wir bereits heute in einer Zeit, in der es *privacy* in diesem strikten Sinne nicht mehr gibt [32].

Sollen wir also unseren Anspruch auf Privatheit als Relikt des 19. Jahrhunderts auf den Müllberg der Geschichte werfen? Dagegen spricht, dass für Demokratien das Private als jener Ort, an dem sich das Subjekt als selbst bestimmtes Individuum wahrnehmen und konstituieren kann, eine zentrale Rolle einnimmt. Dementsprechend ist der Schutz der Privatsphäre eines jener Grundrechte, welches sowohl in der „Allgemeinen Erklärung der Menschenrechte“ der Vereinten Nationen als auch in der „Charta der Grundrechte der Europäischen Union“ verbürgt wird. Somit sei also gleich zu Beginn die soziale und politische Dimension des Privaten betont: Es geht nicht nur um den Anspruch von Individuen, ihren jeweils individuellen Anspruch auf Privatheit zu verwirklichen, sondern es geht um die Frage, in welcher Art von Gesellschaft wir leben wollen.

Da Computer in vielen Fällen jedoch von Individuen genutzt werden, ist es verständlich, dass die soziale Dimension des Privaten oftmals nicht in den Blick gerät, wenn über die Möglichkeiten diskutiert wird, auch bei der Nutzung entsprechender Technologien den grundrechtlich verbrieften Anspruch auf Privatheit zu respektieren, insbesondere dort, wo es um den privaten Endnutzer geht. Besondere Beachtung findet so etwa die Nutzung von Online-Diensten zum Kauf von Gütern, wobei der Käufer zwangsläufig einige Daten über seine Person preisgeben muss (vgl. die Beispiele bei [10, 38]).

Gerade an Beispielen aus dem Bereich des E-Commerce lassen sich die Probleme der Diskussion um *privacy* aber auch gut verdeutlichen: Zunächst einmal ist festzustellen, dass das klassische Thema der Debatte das Verhältnis von Bürger und Staat betrifft. Dies ist historisch dadurch zu erklären, dass lange Zeit nur der Staat über die Möglichkeit verfügte, große Mengen von Daten über Individuen zu erheben, zu verarbeiten und in für die Betroffenen relevanten Entscheidungsprozessen zu verwenden. Die frühen Datenschutzbestimmungen sind somit zunächst als eine Selbstverpflichtung des Staates zu lesen, auf bestimmte Möglichkeiten zu verzichten. Nachdem die notwendigen Technologien immer mehr Akteuren zur Verfügung standen, bekam der Staat eine bemerkenswerte Doppelfunktion: Auf der einen Seite wird von ihm weiterhin erwartet, dass er selbst einen

verantwortungsvollen Umgang mit den technischen Möglichkeiten pflegt, auf der anderen Seite ist er dafür verantwortlich, dass der Datenaustausch zwischen privaten Akteuren in geregelten Bahnen erfolgt, welche einen Missbrauch weitestgehend ausschließen, ohne jedoch die Freiheiten seiner Bürger unnötig einzuengen. Maßnahmen zum rechtlichen Datenschutz lassen sich deshalb als Versuch verstehen, Interessenskonflikte zu regeln, die etwa im Bereich des E-Commerce zwischen Kunden und Anbietern entstehen. Insofern sollte nicht übersehen werden, dass rechtliche Regelungen zum Datenschutz gerade auch den Austausch von Daten ermöglichen sollen [2].

Dies gilt auch für Technologien, welche den Nutzern ein Mehr an Kontrolle über die ihn betreffenden Daten ermöglichen sollen. So heißt es im „P3P Implementation Guide“ beispielsweise: „P3P enables businesses to build trust with their customers and potential customers by making the privacy/data-gathering process more transparent. This allows consumers to better understand why and how companies collect information” [8]. Erklärtes Ziel ist es also auch hier, den Datenaustausch zu ermöglichen.

Da rechtlicher und technischer Datenschutz in diesem Sinne dazu beiträgt, den Austausch von personenbezogenen Daten zwischen privaten (im Sinne von: nicht staatlichen) Akteuren zu ermöglichen, ist davon auszugehen, dass zumindest über die Nutzer von Online-Medien heute mehr Daten erhoben, verarbeitet und gespeichert werden, als dies je zuvor möglich war. Deswegen spricht einiges dafür unsere Gesellschaft als „surveillance society“ [31] zu klassifizieren, wobei strikt zwischen „Überwachungsgesellschaft“ und „Überwachungsstaat“ zu unterscheiden ist. Allerdings darf nicht übersehen werden, dass der Übergang von einer Gesellschaft, die durch eine Vielzahl von Überwachungsprozessen gekennzeichnet ist, zu einem Überwachungsstaat sehr rasch erfolgen kann, wie die Debatte um das US-amerikanische „Total Information Awareness“-Programm gezeigt hat. Bemerkenswert scheint mir hinsichtlich des geplanten Programms nämlich nicht nur zu sein, dass ein Staat in Erwägung zieht, alle ihm zur Verfügung stehenden technischen Mittel auszuschöpfen, sondern dass die auszuwertenden Daten bereits von privaten Akteuren (wie z. B. Choice-Point) erhoben und gespeichert waren. Dass TIA-Programm ist aber auch deswegen in Erinnerung zu rufen, weil seine Realisierung in der ursprünglichen Form letztendlich am politischen Widerstand gescheitert ist [23, 24].

Auch Entwicklerinnen und Entwickler von Technologien, die dazu beitragen sollen, die Rechte der Nutzerinnen und Nutzer zu stärken, müssen sich deswegen bewusst sein, dass diese letztendlich dazu beitragen werden, Datensammlungen zu ermöglichen. Deswegen sind sie als Bürgerinnen und Bürger in einem besonderen Maße dazu verpflichtet, wachsam zu sein und mit ihren Kenntnissen dazu beizutragen, dass die Öffentlichkeit dar-

über informiert wird, was beim gegenwärtigen Stand der Technik und aufgrund der vorhandenen Daten möglich ist und möglich wäre. Insofern darf die soziale und politische Dimension des Privaten nicht aus dem Blickfeld geraten.

Das bedeutet jedoch nicht, dass es sich nicht lohnt, darüber nachzudenken, wie entsprechende Technologien dazu beitragen können, die Rechte von Individuen zu stärken, indem diese entweder unmittelbar dazu beitragen, die Wahrnehmung von spezifischen Rechten wie jenem auf *privacy* zu unterstützen, oder die Zugänglichkeit zu relevanten Informationen sowie die Kommunikation zwischen Personen und Personengruppen zu verbessern. Darum soll es im folgenden Beitrag gehen.

Ich schreibe aus der Perspektive der Informationsethik. Die Informationsethik ist ein Teilgebiet der Angewandten Ethik und befasst sich mit den moralischen Fragestellungen, welche durch die zunehmende Digitalisierung von Inhalten und der Kommunikation aufgeworfen werden [5]. Betrachten wir das Internet und vergleichbare Technologien als Medien, so können wir an Befunde zu Medien im Allgemeinen anknüpfen – etwa an den Vorschlag zu einem integrativen Medienkonzept von Siegfried Schmidt (2000) – und betonen, dass Medien nicht allein durch die zugrunde liegende Medientechnologie gekennzeichnet sind, gleichwohl hat die Technologie natürlich einen Einfluss darauf, was ein Nutzer mit einem Medium machen kann [28]. Medien stehen wie alle technischen Artefakte dabei in Wechselwirkung mit der Gesellschaft, so dass sich wiederum betonen lässt, dass auch die Medientechnologien nicht im luftleeren Raum entstehen. Eine informationsethische Perspektive kann dazu beitragen, bei dem Entwurf von IuK-Technologien eine Distanz zu den eigenen Selbstverständlichkeiten zu gewinnen, die dabei hilft, Technik bewusster zu gestalten. Im Folgenden wird der Schwerpunkt vor allem auf dieser Ebene des Designs von technischen Infrastrukturen liegen.

Tavani [32] hat auch darauf hingewiesen, dass es hinsichtlich von *privacy* zwischen dem „concept of privacy“ und der „justification and the management of privacy“ zu unterscheiden gilt. In diesem Beitrag wird es vor allem um das „management of privacy“ gehen, also um den Umgang mit privaten Daten.

Code und Gesetz

In seinem Buch „Code and other Laws of Cyberspace“ [11] hatte Lawrence Lessig überzeugend dargelegt, dass der Cyberspace einerseits kein rechtsfreier Raum ist, in dem nur die zur Verfügung stehende Technik dem menschlichen Handeln Grenzen setzt, andererseits die Übertragung beste-

hender Gesetze jedoch nicht ausreichend ist. Stattdessen plädiert er für ein fein auf einander abgestimmtes Zusammenspiel von Recht und Technik [11]. Insofern kann es nicht überraschen, wenn er in seinem Aufsatz „Privacy as Property“ (2002) vorschlägt, personenbezogene Daten zum Eigentum der sie betreffenden Person zu erklären, damit diese – unterstützt durch eine entsprechende technische Infrastruktur – eine bessere und vor allem auch justiziable Kontrolle über „ihre“ Daten erhält [12].

Dieser Vorschlag ist zugleich nahe liegend und befremdlich. Nahe liegend ist er deswegen, weil hier die offensichtliche Nähe zum Problem des Schutzes von geistigem Eigentum im Allgemeinen betont wird: In beiden Fällen ginge es darum, die Kontrolle über Daten zu behalten. Befremdlich ist der Vorschlag hingegen deswegen, weil bereits im Jahr 1890 Louis Warren und Warren Brandeis betont hatten, dass das Copyright zum Schutz von privaten Daten seinem Wesen nach ungeeignet sei, da es der Verbreitung und Weitergabe von Werken diene, während das *right to privacy* gerade die Verbreitung von Informationen verhindern solle [36].

Diese Kritik läßt sich jedoch vermeiden, wenn genauer bestimmt wird, was es bedeutet, wenn personenbezogene Daten in Analogie zum geistigen Eigentum geschützt werden sollen. So unterscheidet das deutsche Urheberrecht z. B. zwischen verschiedenen Nutzungsrechten an einem Werk, welche der Autor räumlich, zeitlich oder inhaltlich begrenzt an Dritte abtreten kann. In Analogie wird im Rahmen des „Policy Aware Webs“ über derartige Nutzungsrechte (*usage rights*) hinsichtlich von Daten diskutiert [38].

Dennoch ist die Verschränkung von Recht und Technik im Zeitalter globaler Datenströme nicht unproblematisch, was insbesondere hinsichtlich einer Zusammenführung von *privacy* und *property* gilt. Zunächst gilt allgemein, dass eine akzeptable Lösung für den Umgang mit privaten Daten, welche ein bestimmtes Rechtssystem voraus setzt, nur dort akzeptabel ist, wo auch ein entsprechendes Recht herrscht. Abgesehen von den Schwierigkeiten, die sich daraus bzgl. der unterschiedlichen Rechtsauffassungen ergeben, heißt dies auch, dass Änderungen im Rechtssystem die Legitimität einer Technologie in Frage stellen können. Hinsichtlich von *privacy* und *property* ist des Weiteren speziell zu beachten, dass hier auf globaler Ebene gerade ein Konflikt zwischen der US-amerikanischen und der europäischen Auffassung festzustellen ist [4], wobei der Schutz des geistigen Eigentums zur Zeit eher von der US-amerikanischen Auffassung bestimmt wird, während im Bereich der *privacy* zur Zeit die europäische Auffassung an Bedeutung gewinnen konnte. Abgesehen davon, dass durch den Konflikt zwischen den USA und der Europäischen Union weitere Alternativen an den Rand gedrängt werden [4], gilt es zu beachten, dass eine Technologie, welche unmittelbar auf ein bestimmtes Rechtssystem abgestimmt ist, zum Teil dieses Konfliktes wird. Insofern ist es nicht unwichtig,

dass Lessig in [12] von einer amerikanischen im Gegensatz zu einer europäischen Lösung spricht oder Weitzner et al. in [38] Beispiele aus dem US-amerikanischen Recht wählen (vgl. [14]). Dass die Schwierigkeiten, welche die Anpassung einer bestimmten Technologie an ein bestehendes Rechtssystem bereiten kann, nicht zu unterschätzen sind, darauf hat beispielsweise Jan Möller (2003) hinsichtlich der juristischen Lokalisierung von P3P hingewiesen [13].

Insofern hat ein Ansatz, der zunächst auf die Zuschreibung von Verantwortlichkeit setzt, einen leichten taktischen Vorsprung gegenüber Technologien, welche die Einhaltung bestimmter Datenschutzrichtlinien gewährleisten sollen. Allerdings ist auch zu fragen, ob die Möglichkeit, einen Missbrauch von personenbezogenen Daten festzustellen, ausreichend ist, um die Position der Endnutzer effektiv zu stärken. Dies gilt insbesondere dann, wenn Daten im Ausland verarbeitet werden.

Der Konflikt auf der rechtlichen Ebene sei hier auch erwähnt, weil sich im Rahmen der interkulturellen Ethik gezeigt hat, dass aus nicht-westlicher Sicht der Export westlicher Werte (und westlich meint hier allen Differenzen zum Trotz) zusammenfassend vor allem Europa und die USA in anderen Kulturen als eine Form von „digitalem Imperialismus“ wahrgenommen werden (vgl. z. B. [7]). Man sollte also zumindest auf diesen Vorwurf gefasst sein, wenn man sich mit der Entwicklung von Technologien beschäftigt, die eine bestimmte Vorstellung von *privacy* schützen sollen.

Die Politik der Sichtbarkeit

Angeichts der Beispiele für *user generated content*, die auf den Plattformen des sog. „Web 2.0“ zu finden sind, stellt sich natürlich die Frage, ob denn die Nutzer überhaupt ein Interesse daran haben, dass ihre *privacy* geschützt wird. Dabei handelt es sich freilich um ein Grundproblem jeglicher Form von Datenschutz, da in den meisten Fällen ein Interesse am Schutz der eigenen Daten vorausgesetzt wird [25].

Im Folgenden soll es aber nicht um die Motivation von denjenigen gehen, die bereitwillig eine Vielzahl von Informationen über ihre Person preisgeben, sondern darum, wie mit diesen Informationen umgegangen werden sollte, und welche Herausforderungen sich bei der Entwicklung von Technologien ergeben, welche explizit die digitale Repräsentation von Personen zum Gegenstand haben.

Ein gutes Beispiel für die Schwierigkeiten mit dem Umgang mit öffentlichen, personenbezogenen Daten bietet etwa die Diskussion um die US-amerikanische Suchmaschine „Spock“ (<http://www.spock.com/>), die beispielsweise von Peter Bihr in der TAZ umgehend als „Alptraum der

Datenschützer“ bezeichnet wurde [3]. Die Aufmerksamkeit, die „Spock“ erregt hat, scheint mir darauf zurückzuführen sein, dass „Spock“ explizit nach personenbezogenen Daten sucht, wobei die Entwickler betonen, dass sie versuchen, jedwede „personally identifiable information“ auszufiltern. Als Beispiele werden in der „Privacy Policy“ genannt: „home address, phone number, birth date, social security number, or email address“ [30]. Dennoch wirkt eine Suchmaschine, die sich auf personenbezogene Daten konzentriert, zunächst offensichtlich befremdlich, wobei m. E. allerdings nicht übersehen werden sollte, dass ein derartiger Service *auch* dazu beitragen kann, Personen darüber zu informieren, welche Informationen über sie verfügbar sind.

Dass ein Service wie „Spock“ in den USA legal möglich ist, hängt auch damit zusammen, dass das US-amerikanische Recht keinen Anspruch auf informationelle Autonomie kennt. Es gibt auch keine einheitlichen, nationalen Regelungen zum Datenschutz, sondern es wird auf eine Vielzahl von Einzelbestimmungen gesetzt (sektorale Lösung, vgl. [4]), die in Kombination mit einer *privacy*-Auffassung, die vor allem den Schutz der lokalen Privatheit betont, zu der Frage nach dem Status von „privacy in public“ [19] führt. Helen Nissenbaum hat als Lösung ihr Konzept von „privacy as contextual integrity“ [20] vorgeschlagen, auf das noch einzugehen sein wird.

Zunächst wollen wir uns den Fragen widmen, welche sich aus der Tatsache ergeben, dass im zunehmenden Maße Personen in Informationssystemen repräsentiert werden. Sicherlich gilt es hier zwischen solchen Systemen zu unterscheiden, in denen Dritte Daten über meine Person erfassen und solchen in denen Personen die entsprechenden Daten bereitwillig selbst preisgeben. Im letzteren Fall ist dabei nicht nur an die Veröffentlichung der entsprechenden Daten zu denken, sondern auch an die Möglichkeit ein eigenes Profil zu erstellen oder erstellen zu lassen, um z. B. individualisierte Informationsangebote nutzen zu können.

Privatheit als normatives, also handlungsleitendes Konzept hat im Wesentlichen zwei Dimensionen: Zum einen erfordert es von Dritten Diskretion im Umgang mit privaten Informationen, zum anderen geht es auch einher mit der Forderung, nicht beliebige Informationen über sich selbst preiszugeben [15]. Die letztere Forderung ist insofern nicht unproblematisch, als dass sie unseren Handlungen Grenzen setzt – und z. B. die Möglichkeit zur Selbstdarstellung begrenzen kann. Als Beispiel möge im Folgenden die sexuelle Orientierung einer Person dienen. Dabei gehe ich davon aus, dass die Tatsache, dass eine Person z. B. homosexuell ist, in westlichen, liberalen Gesellschaften keine Information ist, die als moralisch relevant angesehen wird. Es ist also moralisch falsch, jemanden beispielsweise im Bildungssystem zu benachteiligen, weil sie oder er homosexuell

ist (vgl. [26]). Die Aussage „X ist homosexuell“ ist somit ein gutes Beispiel für private Informationen, da es in den meisten Fällen zumindest als ungeschicklich gilt, diese Information zu erheben, und das Wissen darüber, dass X homosexuell ist, in den meisten Entscheidungsprozessen keine Rolle spielen sollte.

Wie David J. Phillips [21, 22] dargelegt hat, ist dieser Schutz qua Anspruch auf Privatheit insofern ein doppelschneidiges Schwert, als Personen und Personengruppen in ihrer Möglichkeit der Selbstdarstellung eingeschränkt werden. Dies hat zum einen Folgen bzgl. der öffentlichen Wahrnehmung der betroffenen Personengruppen, zum anderen gibt es eben Situationen, in denen die Möglichkeit, sich als homosexuell zu erkennen zu geben, durchaus sinnvoll sein kann. Ein simples Beispiel wäre ein individualisiertes E-Commerce-Angebot, das entsprechende Produkte anbieten könnte.

Insofern stellt sich die Frage, ob „homosexuell“ ein Datum sein sollte, das bei der Erfassung und Verarbeitung von Daten eine Rolle spielt. Sicherlich gilt dies nicht in allen Bereichen, in denen IuK-Technologien zum Einsatz kommen. Aber wie sieht es beispielsweise bei Anwendungen aus, die wie beispielsweise Plazes (<http://www.plazes.com/>) oder Google Maps (<http://maps.google.de/>) Informationen über Orte zugänglich machen und die – wenn die Visionen des Mobil Context Aware Computing denn eines Tages Realität werden – an Bedeutung zunehmen werden. Sollen Orte, an denen sich die „gay community“ trifft, als solche gekennzeichnet werden? Sollen Benutzer, die Möglichkeit haben, sich als „gay“ kenntlich zu machen, um dann im Fall der personalisierten Nutzung auf entsprechende Orte hingewiesen zu werden? Betrachten wir z. B. die *base date definition* von P3P (V1.1) fällt auf, dass hier die Kennzeichnung einer Person als „homosexuell“ nicht vorgesehen ist. Das Friend-of-a-Friend-Vokabular bietet hingegen mittels der Eigenschaft „geekcode“ sehr differenzierte Darstellungsmöglichkeiten, wird allerdings in der „FOAF Vocabulary Specification 0.9“ als historisches Relikt gekennzeichnet. Der Vergleich von FOAF und P3P (V1.1) ist ohnehin hier aufschlussreich: so wird bei FOAF die Eigenschaft „gender“ als *string* definiert, wobei bewusst die Möglichkeit eröffnet wird, hier andere Angaben als „female“ oder „male“ einzutragen. P3P legt in der Beschreibung der Version 1.1 hingegen nahe, nur diese beiden Werte zu verwenden.

Nun mag man einwenden, dass dies nun sehr spezielle Probleme von einzelnen Personengruppen seien. Es geht mir hier jedoch weniger darum, darauf aufmerksam zu machen, dass die eindeutige Festlegung auf „female“ oder „male“ einigen als Einschränkung ihrer Möglichkeit zur Selbstdarstellung erscheinen wird, sondern darum, dass wir prinzipiell beachten müssen, dass die Standardisierung und Normierung der Daten, die eine

Person repräsentieren, insofern immer ein schwieriges Unterfangen darstellt, da hierdurch bestimmte Personeneigenschaften bevorzugt werden. Die Standardisierungen von Datensätzen, wie sie im Rahmen der P3P-Spezifikationen erfolgen, aber auch der Entwurf von entsprechenden Ontologien, die Personen zum Gegenstand haben, entscheiden mit darüber, welche personenbezogenen Daten besonders leicht erhoben, verarbeitet und ausgetauscht werden können. Sicherlich können ergänzend dazu Daten in der Kategorie „Sonstiges“ verarbeitet werden, dennoch wird die Verarbeitung durch die Wahrung von Standards erleichtert – und entsprechende Daten sind insofern (im Guten wie im Schlechten) leichter zu handhaben. Um dies an einem weiteren Beispiel zu verdeutlichen: Wenn wir uns dazu entscheiden, die musikalischen Vorlieben einer Person zu erfassen, so können wir etwa grob zwischen den drei Typen „E-Musik/U-Musik/mag keine Musik“ unterscheiden oder aber versuchen die musikalischen Vorlieben feiner zu erfassen.

Insofern führt kein Weg an einer Diskussion daran vorbei, wer für wen wie unter welchen Umständen (besser) wahrnehmbar wird. Und es erscheint mir geboten, diese Diskussion öffentlich und möglichst unter Einbeziehung der betroffenen Personen zu führen.

Kontextuelle Integrität als Maß für Privacy

In ihrem Aufsatz „Privacy as contextual integrity“ hat Helen Nissenbaum ein Konzept vorgeschlagen, das dazu beitragen kann, eine Reihe der bereits genannten Probleme in Angriff zu nehmen [20].

Die Grundannahme besteht darin, dass es innerhalb einer Gesellschaft verschiedene Sphären zu unterscheiden gilt, die jeweils durch spezifische Normen des Umgangs mit Informationen gekennzeichnet sind, welche insbesondere auch darüber entscheiden, welche Informationen zwischen verschiedenen Sphären ausgetauscht werden dürfen. Nissenbaum unterscheidet hierbei zwischen „norms of appropriateness“ und „norms of flow“, wobei mit Angemessenheit (appropriateness) die Frage adressiert wird, welche Informationen in einem bestimmten Handlungszusammenhang über eine Person preisgegeben werden dürfen. Dabei wird explizit davon ausgegangen, dass entweder die Person selber diese Information preisgibt oder die Preisgabe durch einen Dritten erfolgt. Wie ich später zeigen möchte, können aber auch Fragen nach der eigenen Person gegen diese Normen verstoßen.

Beispiele für solche Sphären sind etwa die medizinische und die ökonomische Sphäre. Eine Information, die legitim innerhalb der medizinischen Sphäre entsprechend den dort gültigen Regeln zirkulieren darf

(z. B. „X hat die Krankheit Y“) soll nicht in die ökonomische Sphäre gelangen. Dies würde einen Verstoß gegen die kontextuelle Integrität bedeuten. Der Arbeitgeber von X soll beispielsweise also nicht die Möglichkeit haben, auf die Information „X die Krankheit Y“ zuzugreifen. Auch innerhalb der Sphären sind entsprechend der dort geltenden Normen feine Abstufungen denkbar. Innerhalb der medizinischen Sphäre ist es im Rahmen einer Behandlung z. B. nicht notwendig, dass alle an der Behandlung beteiligten Personen über die gleichen Informationen verfügen. Wer einem Patienten Medikamente verabreicht, muss in der Regel eben nur wissen, welche Medikamente zu verabreichen sind, nicht aber Einblick in die komplette Krankenakte des Patienten haben (vgl. [16]).

Das Modell betont somit die Rolle des Kontextes, in dem jemand eine bestimmte Information über sich preisgibt, wobei die sicherlich richtige Grundannahme darin besteht, dass wir in bestimmten Handlungszusammenhängen (etwa wenn wir einen Arzt aufsuchen) eher dazu bereit sind, bestimmte Informationen über uns preiszugeben, als wir dies in anderen Zusammenhängen wären (wie etwa in einem Bewerbungsgespräch). Es ist sicherlich gut dafür geeignet, um Modelle und Ontologien für bestimmte Sphären zu entwerfen, wobei die genaue Bestimmung davon, was eine Sphäre ist, einen gewissen Schwachpunkt in dem Konzept darstellt. Nissenbaum baut hier auf Michael Walzers „Sphären der Gerechtigkeit“ [37] auf, der die Existenz bestimmter Sphären innerhalb einer Gesellschaft jedoch voraussetzt und dabei den Status von Informationen nicht klärt (vgl. [17]).

Das Modell ist jedoch meines Erachtens überall dort gut anwendbar, wo Sphären als solche wahrgenommen werden und sich innerhalb dieser bereits entsprechende Normen für den Umgang mit Informationen ausbilden konnten. Dies dürfte sowohl für die medizinische Sphäre als auch für zahlreiche administrative Bereiche gelten. Interessant ist dabei, dass insbesondere die Grenzziehung zwischen den Sphären in das Blickfeld gerät, wobei der bewusste Verzicht auf Interoperationalität zwischen den Sphären zu einer interessanten Option zum Schutz der *privacy* wird.

Der Ansatz betont zudem auch, dass sich die Normen für den Umgang mit Informationen in verschiedenen Sphären unterscheiden. Wer also auf einer *social network platform* eine Information über sich preisgibt, tut dies in einem bestimmten Kontext und gibt mitnichten seine Einwilligung dazu, dass die Daten in jedweder Form und für beliebige Zwecke ausgewertet werden dürfen. In Hinblick auf die Forderung nach kontextueller Integrität kann z. B. gegen Suchmaschinen a la „Spock“, die gezielt personenbezogene Daten aus verschiedenen Quellen nutzen, zweierlei eingewandt werden: Erstens werden Daten unabhängig von dem Kontext, in dem sie öffentlich gemacht wurden, zusammengeführt; zweitens entsteht durch die Zusammenführung ein neuer Kontext, da „Spock“ mit der Behauptung

auftritt, dass alle Daten frei verfügbar sein. Umgekehrt könnten Semantic Web Technologien zur Trennung der Sphären beitragen, in dem sie den Kontext, in dem bestimmte Daten erhoben oder preisgegeben wurden, den Daten hinzufügen sowie dafür Sorge tragen, dass der Kontext in der weiteren Verarbeitung beachtet wird. In der Darstellung einer Person zu beruflichen Zwecken sollten sich so etwa keine Daten finden lassen, die z. B. als *user generated content* in der Freizeit entstanden sind.

Vergleicht man den Ansatz von Nissenbaum mit dem Ansatz zur „Information Accountability“ im Rahmen eines Policy Aware Web von Weitzner et al. [38], so lassen sich sowohl Gemeinsamkeiten als auch Unterschiede feststellen. Beide Ansätze betonen, dass nicht jeder Umgang mit Informationen, die von Personen preisgegeben werden, angemessen ist, denn auch bei Weitzner et al. wird der Schwerpunkt vor allem auf den „inappropriate use of information“ gelegt. Was ein unangemessener Umgang mit Daten ist, wird dabei in beiden Ansätzen maßgeblich durch den Ursprung der Daten festgelegt. Allerdings zielen Weitzner et al. auf eine „End-to-End Information Accountability“, welche gewährleistet, dass im Falle eines unangemessenen Umgangs dieser wahrnehmbar wird. Aus der Perspektive des „privacy as contextual integrity“-Ansatzes wäre jedoch zu fragen, ob nicht bereits die Weitergabe einer Information an einen Akteur innerhalb einer anderen Sphäre als Missbrauchsfall zu deuten ist. Der Unterschied besteht also darin, dass bei Nissenbaum bereits dann von Missbrauch zu reden ist, wenn z. B. die medizinische Information „X hat die Krankheit Y“ in die ökonomische Sphäre gelangt, während bei Weitzner et al. der Missbrauch erst dort stattfindet, wo X auf Grundlage dieser Information ein Schaden entsteht (X also z. B. mit seiner Bewerbung nicht erfolgreich ist).

An dieser Stelle sei an die Unterscheidung von Van den Hoven [35] zwischen Schutz vor „information based harms“ und *privacy* erinnert. „Information based harms“ bezeichnen Möglichkeiten jemandem zu schaden, welche zwingend die Kenntnis von persönlichen Informationen über das Opfer voraussetzen. Diese Art des Fehlverhaltens ist jedoch falsch, weil jemandem geschadet wird, und nicht, weil private Informationen dazu verwendet wurden [35]. Im Unterschied dazu kann *privacy* auch dort verletzt werden, wo kein unmittelbarer Schaden entsteht. Ein Verstoß gegen die Normen, welche Individuen die Anspruchnahme eines privaten Frei-raums ermöglichen, können z. B. schlicht ein Zeichen von Respektlosigkeit sein, welche den Willen einer Person nicht achten, bestimmte Informationen über sich nicht gegenüber Dritten preiszugeben. Während die Vermeidung von *information based harms* technisch z. B. durch Mechanismen zur Geheimhaltung unterstützt werden kann, ist der angemessene Umgang mit privaten Informationen komplexer und stellt deshalb auch eine größere

technische Herausforderung dar. Dementsprechend scheint mir eine Technik, welche die Wahrung der kontextuellen Integrität im Umgang mit Daten gewährleistet, besser dazu geeignet zu sein, *privacy* zu ermöglichen. Es geht nicht nur darum, dass beispielsweise das Wissen über eine Erkrankung uns schaden kann, wenn es in die falschen Hände gerät, sondern dass wir sicher sein können, dass alles getan wird, um unsere Entscheidung zu respektieren, dass wir eine Information in einem bestimmten Kontext preisgegeben haben. Wir werden später auf diesen Punkt zurückkommen. Hier gilt es jedoch zunächst festzuhalten: Technik so zu entwickeln und zu gestalten, dass die Nutzer so weit als möglich vor „information based harms“ geschützt werden, ist sicherlich notwendig und löblich. Jedoch ist *privacy* komplexer und lässt sich auf den Schutz vor Missbrauch von Informationen reduzieren. Insofern sollten Technologien, die einen sinnvollen Umgang mit privaten Informationen ermöglichen und fördern sollen, mehr bieten. Dass Weitzner et al. vor allem aber die Vermeidung von „information based harm“ im Auge haben, zeigt die Stelle, an der davon die Rede ist, dass der „actual harm was caused not by the disclosure of information ... but by the decision to deny Alice the job“ [38].

Die beiden Vorschläge lassen sich allerdings auch als Ergänzungen lesen, wenn wir etwa davon ausgehen, dass es bestimmte Sphären gibt, in denen bestimmte Normen des Umgangs mit Daten herrschen, dann scheint es nahe liegend, eine *policy aware architecture* auf Nissenbaums Überlegungen aufzubauen, indem die Sphäre, in der die Information ursprünglich erhoben wurde, kenntlich gemacht würde und damit zugleich innerhalb der Sphäre geltende Normen zur Beantwortung der Frage, „what rules are known to be associated with that information“ [38] heranzuziehen. Ein nahe liegendes Beispiel wären hierbei die einschlägigen Datenschutzbestimmungen, die es im E-Commerce ohnehin zu beachten gilt.

Leider ist das Sphären-Modell jedoch auch mit einigen Schwierigkeiten verbunden. Zum einen sind nicht für alle Sphären die Normen explizit bekannt und u. U. sind sie gar nicht überall explizierbar. Zum anderen sind die Grenzen der Sphären in der Praxis nicht so leicht zu identifizieren.

Wer früher Informationen über eine Krankheit einholen wollte, nutzte entweder Medien, die einen anonyme Nutzung zuließen (z. B. Bücher oder Zeitschriften im Lesesaal einer öffentlichen Bibliothek), oder er konnte die Information innerhalb einer Institution einholen, die zu einem vertrauensvollen Umgang mit personenbezogenen Daten verpflichtet war (z. B. indem man einen Arzt um Rat fragte). Wie bereits mehrfach betont, konnten sich innerhalb der medizinischen Sphäre über lange Zeit Normen ausbilden, welche den Umgang mit als sensibel empfundenen Informationen betreffen. Man mag etwa in der Schweigepflicht des sog. „hippokratischen Eids“ eine der ältesten „privacy policies“ erblicken (vgl. [15]). Dement-

sprechend existiert auch eine Vielzahl von juristischen Regelungen, welche den Fluss der Informationen innerhalb des Gesundheitswesens betreffen. Z. B. verbietet die amerikanische Datenschutzrichtlinie für das Gesundheitswesen das Erheben von personenbeziehbaren Daten von den Nutzern von Online-Angeboten (vgl. [18]). Die Internet-Auftritte von Krankenhäusern z. B. sind so zu gestalten, dass nur ein Minimum von Daten erhoben wird. Diese strikten Regelungen gelten aber nicht für private Akteure – was die ganze Bandbreite von reinen Informationsangeboten bis hin zur Online-Apotheke betrifft. Problematisch ist dies insofern, als dass für die Nutzer von Angeboten zum Thema „Gesundheit“ nicht immer auf den ersten Blick erkennbar ist, welche Regeln nun wo gelten. Die Privatisierung des Gesundheitssystems tut ihr übriges, um die Grenze zwischen der medizinischen und der ökonomischen Sphäre zu verwischen.

Eine weitere Frage betrifft den Umgang mit kontextfreien Daten. Auch wenn die vorgeschlagenen Technologien dazu beitragen können, den angemessenen Umgang mit neu erhobenen Daten zu erleichtern, bleibt zu klären, was mit der Unmenge an zuvor erhobenen Daten geschehen soll. Hinsichtlich der Daten unbekannten Ursprungs wäre es sicherlich wünschenswert, wenn diese zumindest bei der Weiterverarbeitung als solche kenntlich gemacht werden. So mag eine Kontaktadresse einer Person bekannt sein, der Kontext in dem diese Information preisgegeben wurde, hingegen nicht. Stammt die E-Mail-Adresse beispielsweise von einer professionellen Homepage mit offensichtlichem Werbecharakter oder wurde sie in einem Forum hinterlassen? Wurde sie von der betroffenen Person selbst preisgegeben oder wurde sie von Dritten weitergegeben? Die Frage ist vor allem deswegen relevant, weil ein Szenario sehr unwahrscheinlich ist, in dem auf die Verwendung aller zuvor erhobenen Daten verzichtet wird und alle Nutzer sofort in allen Lebensbereichen anfangen werden, eine neue Technologie zu nutzen. Insofern ist dem Umgang mit diesen Daten ein hohes Maß an Aufmerksamkeit zu widmen.

Eine weitere relevante Gruppe sind anonymisierte Daten, bei denen es nicht mehr möglich ist, die einzelnen Daten auf bestimmte Personen zurückzuführen, die aber dennoch in für einzelne Personen relevante Entscheidungsprozesse einfließen können. Dies ist z. B. in vielen Überwachungsprozessen der Fall: Überwachungsmaßnahmen dienen oftmals nicht dazu, alles über einzelne Personen zu erfahren, sondern um Wissen über Personengruppen zu produzieren. Am Ende der Verarbeitung der Daten steht somit die Produktion von Personentypen, wobei dann in einem zweiten Schritt einzelne Personen wiederum diesen Typen zugeordnet werden. Die Herausforderung besteht hier darin, dass die Daten von den Personen X_1 bis X_n stammen können, die einer anonymisierten Auswertung ihrer Daten zugestimmt haben, und diese dann für die Beurteilung der Person

X_{n+1} verwendet werden, welche sogar der Verwendung von bestimmten, sie betreffenden Daten zustimmen mag. Insofern lässt sich in diesem Fall nur schwerlich von Missbrauch sprechen, da alle Personen (X_1 bis X_{n+1}) zugestimmt haben.

Die Beachtung der Sphären, innerhalb welcher die Daten erhoben wurden, kann dazu beitragen, die Herausforderung in Angriff zu nehmen. Zumindest kann aufgrund des jeweiligen Erhebungskontextes eine Standard-Annahme darüber getroffen werden, welche Normen bei der Verarbeitung im Regelfall zu beachten sind. Jedoch trifft dies eben nur auf den Regelfall zu. Der Anspruch auf *privacy* kann jedoch auch spontan innerhalb eines Kontextes erhoben werden. So betonen etwa James Moor und Hermann Tavani im Rahmen ihres Restricted Access/Limited Control-Ansatzes, dass ein Individuum oder Individuen vor allem in bestimmten Situationen den Anspruch auf *privacy* erheben [33]. Wenn wir uns etwa in einem Restaurant aufhalten, so ist dies ein öffentlicher Ort, an dem wir zunächst einen mäßigen Anspruch auf *privacy* erheben. Wir würden zwar nicht erwarten, dass die Information „X war im Restaurant Y“ weiterverbreitet wird, aber wir würden die Weiterverbreitung der Information auch nicht als schweren Verstoß gegen die geltenden Normen auffassen. Beginnen unsere Tischnachbarn jedoch einen Streit und werden in diesem Streit viele Details über das Privatleben der beteiligten Personen preisgegeben, so ergibt sich eine neue Situation und beispielsweise Tavani argumentiert dafür, dass die beiden Personen durchaus einen Anspruch auf *privacy* haben [32]. Sie können also erwarten, dass nicht alle Details des Streitgespräches ohne weiteres in der Öffentlichkeit preisgegeben werden. Ein analoges Beispiel wären hitzige Auseinandersetzungen in einem Online-Forum, bei denen vielleicht einiges an Informationen produziert wird, was die beteiligten Personen später bereuen. Ein ähnlich gelagerter Fall sind Gesprächssituationen im öffentlichen Raum, bei denen die Gesprächspartner z. B. dadurch, dass sie mit leiser Stimme sprechen und nahe bei einander stehen, signalisieren, dass der Inhalt des Gespräches nicht für Dritte bestimmt ist. Auch hier wird durch den Kommunikationsstil ein Anspruch auf Privatheit erhoben, der den Inhalt des Gespräches auch dann für privat erklärt, wenn das Gespräch in einem öffentlichen Raum stattfindet. Derartige Beispiele sind für die Diskussion deswegen relevant, weil sie verdeutlichen, dass der Ursprung von Daten im Regelfall zwar hilfreich ist, um abzuschätzen, welche Normen im Umgang mit den Daten einzuhalten sind. Es gilt aber auch zu beachten, dass gerade auch die Abweichung von der Norm durch die Datensubjekte einen Anspruch auf *privacy* begründen kann. Und eine große Herausforderung besteht darin, insbesondere bei der automatisierten Verarbeitung diese abweichenden Fälle zu erkennen.

Data mining und autonome moralische Agenten

In ihrem Aufsatz „Why machine ethics?“ machen Allen et al. [1] den interessanten Vorschlag, *artificial moral agents* (AMAs) zum Schutz von *privacy* einzusetzen. Ihr Ansatzpunkt ist es, dass autonome Agenten (wie Roboter, aber auch entsprechende Software-Agenten), welche über die Fähigkeit zur Selbststeuerung verfügen, auch moralische Normen und Werte berücksichtigen sollen [1]. Ein einfaches Beispiel hierfür wäre etwa ein Webbot, der nur solche Daten im Web sammelt, deren Quellen dieser Form der Verarbeitung im Rahmen einer entsprechenden Privacy-Policy zugestimmt haben. Ein komplexeres Beispiel wäre ein Bot, der in der Lage ist, Datenquellen gemäß der jeweiligen Sphäre einzustufen, und die Königsdisziplin wäre ein Agent, der in der Lage wäre, Abweichungen von der Norm zu erkennen, die einen Anspruch auf *privacy* begründen.

Artificial moral agents könnten also als „blob machines“ entworfen werden, um den Ausdruck von Jeffrey Rosen aufzugreifen [23, 24]. „Blob machines“ sind das Gegenteil von „naked machines“. Die Idee stammt aus dem Bereich der Flughafen-Sicherheit: Anstelle von Metalldetektoren treten neue Verfahren, die Personen vollständig durchleuchten und somit versteckte Waffen weitaus besser sichtbar machen als bisher. Insbesondere erlauben es die Geräte auch, Flüssigkeiten und nicht-metallische Gegenstände besser zu erkennen. Der Nachteil ist, dass die kontrollierte Person dabei praktisch nackt auf den Bildschirmen der Kontrolleure erscheint. Derartige Technologien nennt Rosen deswegen „naked machines“. Es besteht aber auch die Möglichkeit, die Technik so umzugestalten, dass zwar alle relevanten Daten erhalten bleiben, diese jedoch auf ein androgynes Modell projiziert werden. Diese Variante nennt Rosen „blob machines“, weil der Einzelne nur noch als „undefinierte Masse“ (blob) zur Darstellung gebracht wird. Das Problem mit Blob-Machines ist naturgemäß, dass sie aufwändiger zu entwerfen sind.

AMAs könnten in Analogie so entworfen werden, dass sie nur die wirklich benötigten Daten gemäß der herrschenden Normen sammeln und verarbeiten. Ein solcher Ansatz wird z. B. im Rahmen des „Privacy and Identity Management for Europe“-Projektes (PRIME) verfolgt: Im Prinzip setzt das Projekt bei der Minimierung von Daten an, wobei davon ausgegangen wird, dass heute in den meisten Fällen zu viele Daten erhoben und verarbeitet werden. Beispielsweise wird oftmals zur Überprüfung der Volljährigkeit das Geburtsdatum abgefragt. Im Rahmen des Projektes wird eine Architektur entwickelt, bei der die *middleware* dafür Sorge trägt, dass nur die relevante Information (volljährig? Ja/Nein) an denjenigen weitergegeben wird, der sie benötigt. Will also eine Person ein Angebot nutzen, das ein bestimmtes Alter voraussetzt, so braucht der Anbieter nicht das

Geburtsdatum der betreffenden Person zu kennen. Stattdessen kann er eine Anfrage an eine Zwischenstelle richten, die ihn mit der relevanten Information versorgt. Soll z. B. ein Film nur für Benutzer, die älter als X Jahre alt sind, zugänglich gemacht werden, dann kann der Anbieter die Anfrage stellen, ob der Nutzer älter als X ist, nachdem er vom Benutzer dazu ermächtigt wurde. Auch brauchen Händler nicht zwingend zu wissen, wo der Besteller einer Ware wohnt, denn auch der Versand kann wiederum durch eine dritte Partei erfolgen, die nur weiß, wohin die Ware geliefert werden soll, ohne zu wissen, was der Kunde gekauft hat [10]. PRIME hat somit die Entwicklung einer „blob machine“ zum Gegenstand, weil auf der einen Seite alle benötigten Daten zur Verfügung gestellt werden, auf der anderen Seite aber vermieden wird, ein zu detailliertes Bild der Nutzer entstehen zu lassen. Dies setzt aber eine Technologie voraus, die über eine bloße „End-to-End“-Kontrolle hinausgeht und bereits die Distribution von Daten kontrolliert.

Indem die Vision von PRIME darauf abzielt, die Daten zu einer Person möglichst dezentral zu verteilen, wird somit ein negativer Effekt abgeschwächt, der in dem UNESCO-Report „Ethical Implications of Emerging Technologies: A Survey“ [34] betont wird, nämlich dass die Etablierung eines *digital identity management* in der Praxis dazu führen kann, dass sich nur wenige Mediatoren auf dem Markt behaupten können und diese dann über eine sehr große Menge an Daten verfügen. Allerdings wird damit nicht die zweite Gefahr gebannt, die der UNESCO-Report ebenfalls betont: Die Automatisierung des Umgangs mit personenbezogenen Daten könnte zu einer Explosion des Bereichs der Maschine-Maschine-Kommunikation führen, deren Auswirkung nicht abzusehen ist [34]. Hier wiederholt sich also das Dilemma des juristischen Datenschutzes auf der technischen Ebene: Datenschutz dient seinem Wesen nach stets dazu, den Austausch von Daten zu ermöglichen. Insofern sind die Folgen eines automatisierten Datenaustausches mittels Agenten schwer abzuschätzen. Die mit dem semantischen Web angestrebte semantische Interoperabilität kann zu einem entscheidenden Faktor in dieser Entwicklung werden.

Dies gilt es auch bzgl. *data mining*-Technologien zu beachten, die ebenfalls von der entsprechenden Aufarbeitung der Daten profitieren können. Die Anwendung von derartigen Technologien auf öffentlich zugängliche Daten im Web stellt ein zentrales Thema in der Debatte um *privacy* dar. Die Herausforderung besteht darin, dass *data mining* das ansonsten grundlegende Prinzip des *informed consent* unterwandert, weil es Sinn und Zweck derartiger Technologien ist, relevante Zusammenhänge in Datensammlungen sichtbar zu machen, die vorher nicht bekannt waren. Dadurch entsteht ein Phänomen, das ich bereits an anderer Stelle als „Verlust der Bedeutungslosigkeit“ [15, 16] bezeichnet habe. Das Problem ist, dass vor

der Auswertung der Daten nur sehr allgemein gesagt werden kann, dass die Daten umfassend ausgewertet werden sollen. Welche Daten sich als relevant erweisen werden, kann hingegen nicht vorhergesagt werden. Dies gilt es besonders bzgl. der im Allgemeinen als sensibel empfundenen Daten zu bedenken, deren Relevanz weitaus geringer sein kann, als vermeintlich triviale Daten, denen in der Diskussion nicht so viel Aufmerksamkeit geschenkt wird.

Deswegen greifen hier auch Ansätze zu kurz, die durch eine Zustimmung zu einem bestimmten Verwendungszweck einen potentiellen Missbrauch verhindern wollen, ja, sie können sogar kontraproduktiv sein, weil die Aufmerksamkeit auf die falsche Art von Daten gelenkt wird. So können z. B. Personengruppen (Typen) auf Grundlage von „trivialen“ Verhaltensmustern (wie etwa der Reihenfolge, in der sie bestimmte Webseiten aufrufen) gebildet werden. Bei der Person X_{n+1} aus dem oben genannten Beispiel mag dann der Eindruck entstehen, dass sie *privacy* geschützt hat, weil sie keine für sie offensichtlich relevanten Daten über sich preisgeben will, und wird dennoch auf der Grundlage von ganz anderen Daten klassifiziert, obwohl sie dies in einem bestimmten Kontext vielleicht gar nicht wünscht.

Hierzu kommt ein weiteres Problem, mit dem wir zu dem Ausgangspunkt unserer Überlegungen zurückkehren, nämlich das Ineinandergreifen von Recht und Code. Eine einfache Möglichkeit, sich gegen die Auswertung seiner persönlichen Daten zurzeit zur Wehr zu setzen, besteht darin, dass wir lügen. Wie Simone Dietz [6] gezeigt hat, stellt der Schutz der eigenen Privatsphäre eine der wenigen Umstände dar, die eine Lüge rechtfertigen. Denn wer eine unangemessene Frage, welche sein Privatleben betrifft, mit einer nicht all zu schweren Notlüge beantwortet, der wehrt sich primär gegen die ungerechtfertigte Frage [6]. In Analogie scheint es mir durchaus gerechtfertigt zu sein, den in vielen Fällen nicht begründeten Datenhunger von Online-Angeboten mittels der Preisgabe falscher Daten zu quittieren. Dieses zu rechtfertigende Fehlverhalten wird im Rahmen eines Ansatzes, der auf den Missbrauch von korrekten Daten fokussiert und dabei vor allem die Richtigkeit von Daten voraussetzt, nicht berücksichtigt. Dies mag damit zusammenhängen, dass Weitzner et al. [38] letztendlich doch der „Vereigentumisierung“ (Spinner) von Wissen das Wort reden, auch wenn sie von Nutzungsrechten sprechen. Denn letztendlich wird unterstellt, dass die personenbezogenen Daten gegen einen Service oder ein Angebot getauscht werden, sofern sie nicht für die Abwicklung von Geschäften notwendig sind. Indem im Semantic Web der Zugriff von Daten stets als Interaktion definiert wird, liegt eine solche Betrachtungsweise sehr nahe. Denn im Gegensatz zum WWW, wo Benutzer ein Dokument abgerufen oder genutzt haben und dabei beobachtet wurden, basiert das Semantic Web nicht zuletzt auf der Grundlage von Anfragen und somit einem Austausch von Informationen,

der nicht nur auf das technisch Notwendige, wie im Falle des WWW, begrenzt ist. Rechtlich kann dies zu der unangenehmen Konsequenz führen, dass der Versuch seine Privatsphäre durch die Angabe falscher Daten zu schützen dann als Betrug strafbar wird (vgl. [15]).

Fazit und Ausblick

Ausgehend von einer allgemeinen Betrachtung über das Zusammenspiel von Code und Recht war zunächst darauf hingewiesen worden, dass die Entwicklung von Technologien, welche im engen Zusammenspiel mit rechtlichen Maßnahmen zum Datenschutz entwickelt werden, ein zweischneidiges Schwert sind, weil zur Zeit eine lebhafte Debatte darüber geführt wird, wie personenbezogene Daten im globalen Kontext zu schützen seien. Dennoch dürfte deutlich geworden sein, dass das Thema „privacy“ im semantischen Web nicht vernachlässigt werden kann.

Dies betrifft bereits die Entscheidung darüber, wie Personen im Netz repräsentiert werden sollen, was in diesem Beitrag vor allem in Hinblick auf die zu definierenden Datenstrukturen diskutiert wurde. Dabei wurde empfohlen, wo immer möglich die Nutzer in die Diskussion einzubinden.

Dann wurde das Sphären-Modell von Helen Nissenbaum eingeführt, das mit dem Kriterium der kontextuellen Integrität einen, zumindest für viele Anwendungsbeispiele operationalen Rahmen bieten kann. Im Rahmen des Modells wurde zum einem betont, dass es zwischen verschiedenen Sphären zu unterscheiden gilt, in denen verschiedene Normen herrschen, und dass vor allem auch den Grenzen zwischen den Sphären Aufmerksamkeit zu schenken ist. Dementsprechend wurde über eine Kontrolle der Verwendung der Daten hinaus empfohlen, auch bei der Gestaltung unter Umständen bewusste Interoperabilität herzustellen. Dabei wurde auch die Unterscheidung zwischen „information based harms“ und „privacy“ eingeführt, um zu verdeutlichen, dass privacy mehr umfasst, als den Schutz vor dem Missbrauch von Daten.

Es wurde des weiteren vorgeschlagen, den Kontext, in dem Daten erhoben werden, als semantisches Meta-Datum zu beachten, wobei auf die Schwierigkeiten bzgl. Daten, die ohne Kontext erhoben wurden, sowie von anonymisierten Daten hingewiesen werden muss, die zumindest entsprechend zu kennzeichnen sind.

Als ein Schwachpunkt einer Sphären-Auffassung des Privaten wurden schließlich Beispiele vorgestellt, in denen gerade die Abweichung der geltenden Normen einen Anspruch auf Privatheit begründen kann. Als Lösung wurde auf das Konzept von *artificial moral agents* verwiesen, die als „blob machines“ mit dazu beitragen könnten, nicht benötigte Daten auszu-

blenden und auch ansonsten der Wahrung von Normen Rechnung zu tragen, sofern sie in der Lage sind, verschiedene Sphären zu erkennen. Allerdings wurde auch darauf hingewiesen, dass die Automatisierung des Austausches von personenbezogenen Daten im Rahmen des *digital identity management* auch dazu führen kann, dass mehr Daten als je zuvor zwischen Maschinen ausgetauscht werden.

Schließlich wurde noch betont, dass *data mining*-Technologien innerhalb der Privacy-Debatte als problematisch empfunden werden, weil sie das Prinzip des *informed consent* unterwandern. Dies gilt insbesondere in Hinblick auf die Auswertung von privaten Daten, die im Web öffentlich zugänglich sind.

Die Idee des semantischen Web Daten statt Dokumente zugänglich zu machen, hat in Hinblick auf privacy zwei Seiten, welche vielleicht am Beispiel des data minings besonders deutlich werden. Auf der einen Seite können Ansätze in Richtung eines Policy Aware Web dazu beitragen, die Rechte der betroffenen Personen zu stärken, auf der anderen Seite erhöht die Aufbereitung der Daten die Möglichkeiten der automatisierten Verarbeitung. Dies ist ja auch durchaus gewollt, nur dass eben in den prominenten Beispielen für die mögliche Nutzung des Semantic Webs stets Informationen über Dinge behandelt werden (vgl. [29]) und die Frage, was passiert, wenn Informationen über Menschen auf die gleiche Weise verarbeitet werden wie Informationen über Dinge, nur selten gestellt wird (vgl. z. B. [34]).

Offensichtlich erlaubt die entsprechende Aufbereitung der Daten im Web auch neue Missbrauchsmöglichkeiten. Denn wenn im besten Fall ein Agent in der Lage ist, z. B. ein Dossier über eine Person zusammenzustellen, in der nur die den sozialen Normen angemessenen Informationen auftauchen, dann ist auch ein „böser“ Agent denkbar, der das genaue Gegenteil tut und genau die Daten sichtbar macht, die der gute Agent nicht berücksichtigt. Diese offensichtlichen Missbrauchsmöglichkeiten sind insofern irritierend zu nennen, als hierbei nur offen zu Tage tritt, was heute im World Wide Web bereits passieren kann. Nach dem bisher Gesagten, wäre zwar zu betonen, dass der Anspruch auf *privacy* nicht auf die Vermeidung von *information based harms* reduziert werden sollte und dem Datenfluss innerhalb des Webs mehr Aufmerksamkeit zu widmen ist. Allerdings ist auch festzustellen, dass bei einer entsprechenden Gestaltung der Technik auch eine Verbesserung der bisherigen Situation erwartet werden kann.

Literatur

1. Allen C, Wallach W, Smit I (2006) Why Machine Ethics? IEEE Intelligent Systems, July/August 2006, S 12–17
2. Bennett CJ, Raab C (2006) The Governance of Privacy. Policy Instruments in Global Perspective. MIT Press, Cambridge, MA London
3. Bihr P (2007) Der Alptraum der Datenschützer. TAZ vom 14.08.2007. Siehe: <http://www.taz.de/index.php?id=koepfe-artikel&art=3147&id=internet-artikel&cHash=35454ca5bd>, abgerufen am 12.10.2007
4. Burk D (2007) Privacy and Property in the Global Datasphere. In: Hongladarom S, Ess C (Hrsg.) Information Technology Ethics: Cultural Perspectives. Idea Group Reference: Hershey London Melbourne Singapore, S 94–107
5. Capurro R (2004) Informationsethik – Eine Standortbestimmung. International Journal of Information Ethics 1/2004, S 4–10, siehe: http://www.i-r-i-e.net/inhalt/001/ijie_001_02_capurro.pdf, abgerufen am 16.10.2007
6. Dietz S (2003) Die Kunst des Lügens. Eine sprachliche Fähigkeit und ihr moralischer Wert. Rowohlt Taschenbuch Verlag, Reinbek
7. Ess C (2007) Can the Local Reshape the Global? Ethical Imperatives for Humane Intercultural Communication Online. In: Capurro R, Frühbauer J, Hausmanning T (Hrsg.) Localising the Internet. Ethical aspects in intercultural perspective. Wilhelm Fink, München, S 153–170
8. Jamtgaard L, Internet Education Foundation (2005) The P3P Implementation Guide. Stand: 13.12.2005. Siehe: <http://www.p3ptoolbox.org/guide/>, abgerufen am 16.10.2007
9. Kuhlen R (2004) Informationsethik. UVK, Konstanz
10. Leenes R, Schallaböck J, Hansen M (2007) PRIME white paper v2 (27.06.2007), siehe: https://www.prime-project.eu/prime_products/whitepaper/PRIME-Whitepaper-V2.pdf, abgerufen am 16.10.2007
11. Lessig L (1999) Code and other laws of Cyberspace. Basic Books, New York
12. Lessig L (2002) Privacy as Property. Social Research 69, S 247–269
13. Möller J (2003) Legal localization of P3P as a requirement for its privacy enhancing effect. Siehe: <http://www.w3.org/2003/p3p-ws/pp/uld.html>, abgerufen am 11.10.2007
14. Nagenborg M (2004) Privacy and Terror: Some Remarks from Historical Perspective. International Journal of Information Ethics, 2/2004, siehe: http://container.zkm.de/ijie/ijie/no002/ijie_002_20_nagenborg.pdf, aufgerufen am 11.10.2007
15. Nagenborg M (2005) Das Private unter den Rahmenbedingungen der IuK-Technologie. Ein Beitrag zur Informationsethik. VS Verlag für Sozialwissenschaften, Wiesbaden
16. Nagenborg M (2005a) Datenschutz und der Verlust der Bedeutungslosigkeit. In: Woesler M (Hrsg.) Ethik in der Informationsgesellschaft. Bochumer Universitätsverlag
17. Nagenborg M (2007) Designing Spheres of Justice. In: Hinman L, Brey P, Floridi L, Grodzinsky F, Introna L (Hrsg) Proceedings CEPE 2007. The Sev-

-
- enth International Conference of Computer Ethics: Philosophical Enquiry. CTIT, Enschede 2007, S 310–317
18. Nelson S (2006) Privacy and Medical Information on the Internet. *Respiratory Care*, Vol. 51, No. 2, S 183–187
 19. Nissenbaum H (1998) Protecting Privacy in an Information Age: The Problem of Privacy in Public. *Law and Philosophy* 17, S 559–596.
 20. Nissenbaum H (2004) Privacy as contextual integrity. *Washington Law Review* 79, S 119–158
 21. Philipps DJ (2002) Negotiating the Digital Closet. Online pseudonymity and the politics of sexual identity. *Information, Communication & Society* 5(3), S 406–424
 22. Philipps DJ (2005) From Privacy to Visibility. Context, identity, and Power in Ubiquitous Computing Environments. *Social Text* 83, Vol. 23, No. 2, Summer 2005, S 95–108
 23. Rosen J (2004) The Naked Crowd. Balancing Privacy and Security in an Age of Terror. *Arizona Law Review* 46, S 607–619
 24. Rosen J (2005) The Naked Crowd. Reclaiming Security and Freedom in an anxious age. Random House Trade Paperback: New York
 25. Roßnagel A, Jandt S, Müller J, Gutscher A, Heesen J (2006) Datenschutzfragen mobiler kontextbezogener Systeme. Deutscher Universitäts-Verlag, Wiesbaden
 26. Rorty R (2001) Gerechtigkeit als erweiterte Loyalität. In: Rorty R (2001) *Philosophie und Zukunft*. Fischer, Frankfurt am Main, S 79–100
 27. Rössler B (2001) Der Wert des Privaten. Suhrkamp Taschenbuch Wissenschaft, Frankfurt
 28. Schmidt SJ (2000) Kalte Faszination. Medien, Kultur, Wissenschaft in der Mediengesellschaft. Velbrück Wissenschaft, Weilerswist
 29. Shadbolt N, Hall W, Berners-Lee T (2006) The Semantic Web Revisited. *IEEE Intelligent Systems* 21(3), S. 96–101. Siehe: http://eprints.ecs.soton.ac.uk/12614/01/Semantic_Web_Revisited.pdf, abgerufen am 15.10.2007
 30. Spock (2007) Spock Networks Privacy Policy (Stand: August 17, 2007). Siehe: <http://www.spock.com/privacy>, abgerufen am 12.10.2007
 31. Surveillance Studies Network (2006) A Report on the Surveillance Society for the Information Commissioner by the Surveillance Studies Network. September 2006. Siehe: http://www.ico.gov.uk/upload/documents/library/data_protection/practical_application/surveillance_society_full_report_2006.pdf, abgerufen am 16.10.2007
 32. Tavani, HT (1999) KDD, data mining, and the challenge for normative privacy. *Ethics and Information Technology* 1: 265–273
 33. Tavani, HT (2007) Philosophical Theories of Privacy – Implications for an adequate Online Privacy Policy. *Metaphilosophy* 38: 1–22
 34. UNSECO, Information Society Division, Communication and Information Sector (Hrsg.) (2007): *Ethical Implications of Emerging Technologies: A Survey*. UNESCO, Paris, siehe: <http://unesdoc.unesco.org/images/0014/001499/149992E.pdf>, abgerufen am 16.10.2007
 35. Van den Hoven MJ (1997) Privacy and the Varieties of Moral Wrong-doing in an Information Age. *Computers and Society*, September 1997, S 33–37

36. Warren SD Brandeis LD (1890) The Right to Privacy. Havard Law Review, Vol. IV, siehe: http://www-swiss.ai.mit.edu/6805/articles/privacy/Privacy_brand_warr2.html, abgerufen am 16.10.2007
37. Walzer M (1992) Sphären der Gerechtigkeit. Campus, Frankfurt am Main
38. Weitzner, DJ, Abelson H, Berners-Lee T, Feigenbaum J, Hendler J, Sussman GJ (2007) Information Accountability. Technical Report MIT-CSAIL-TR-2007-034. Siehe: <http://dspace.mit.edu/bitstream/1721.1/37600/2/MIT-CSAIL-TR-2007-034.pdf>, aufgerufen am 20.08.2007

Index

A

Affordance 90
Ajax 75, 88, 101
 Ajax-Engine 75
 Problematischer Einsatz 94
Annotation 56, 229, 344
Anwenderverhalten 159
 Bottom-Up-Modellierung 162
 Eigenschaft 162
 Top-Down-Modellierung 163
Application Programming Interface 69

B

Begriffsliste 131
BibSonomy *siehe* Social Bookmarking
 Anwendung 381
 Architektur 373
Blog 45, 65
 Blogsphäre 55, 66, 328, 331
 Semantic Blogging 57, 103
Browser 28
Bürgerjournalismus 39, 426

C

Community 100, 166, 291
 Betriebliche Community 309
 Community entdecken 386
 Community-Instrumente 297
 Motive für Partizipation 302
Content Management System 207
 Architektur 216

Herausforderung 211
 Profildaten 220
Content Syndication 76, 216
Crowd Sourcing 53

D

D2R 106, 219, 264, 440
Data Mining 469
 Anwendung 473
 Data Mining process 471
 Informed Consent 500
 Nachteile 479
 Vorteile 478
Datenbewirtschaftung 7
Datenintegration 103, 117
DBpedia *siehe* Open Data
Demokratie 37
Dot-Com-Blase 24
Dynamische Datenquelle 106

E

ExpertFinder 177
 Anwendungsszenarien 182
 Relevante Projekte 199
 Vokabular 186
 Vokabular Erweiterung 191

F

Facetted Browsing 353
FOAF 110, 166, 188, 492
 Property 188

Folksonomy 70
Formales Modell 370
Friend of a Friend *siehe* FOAF

G

Geschäftsmodell 457
Graphical User Interface 90

I

Identitätsmanagement 50, 500
OpenID 185
Informationsökonomie 4

K

Klassifikation 196
Kollaborationskosten 51
Kollektive Intelligenz 51
Konnektivität 11
Kontextualisierung 11
Kritik am Semantic Web 109

L

Long Tail 53, 165

M

Machine Learning 470
Mapping 111
Mappingwerkzeuge 439
Mashup 14, 78, 100, 222, 460
Semantic Mashup 259
MemeMapper 327
Mikroformat 56, 73, 113, 147, 231
GRDDL 73, 151
RDFa 73, 148

N

Natural Language Processing 348

O

Ontologie 111, 177, 214, 442, 463
Ausdrucksstark 114
Diligent 116
Ontology Engineering 255
Open Data 6
DBpedia 10, 260
DBpedia Komponente 267

DBpedia Schnittstelle 271
Linking Open Data 10, 264
Prinzip vernetzter Daten 261
Quelle vernetzter Daten 264
Suchmaschine für vernetzte Daten 275
Ordnungssystem 10
Ordnungstyp 129
OWL 137, 401, 443

P

PageRank 12
Performanz 115, 347, 388
Personal Information Model *siehe* PIMO
Personalisierung 107, 215
PIMO 343
PIMO-Mid 345
PIMO-Upper 345
Podcast 67
Policy Aware Web 489
Policy Aware Architecture 496
Privacy 38, 108, 485
Artificial Moral Agent 499
Contextual Profile 476
Information Accountability 495
Information Based Harm 495
Informed Consent 500
Kontextuelle Integrität 493
P3P 487
Sphärenmodell 498
Prodnutzung *siehe* produser
Produser 64, 456
Prosumer 64

R

RDF 135, 214, 438
RDF Browser 176, 273, 407
RDF Triple 260
RDF-Datenmodell 113
RDF-Graph 136, 262
Read-Write-Web 160
Reasoning 277
Recommender System 224, 388
Regelsprache 180
Relationssystem 133
Relationstyp 129
Restful Service 380
RFID 477
Rich Internet Application 68, 86
Technologie 75
Rich Web Client 69
RSS 46, 77

S

Science of the Web 6
 Semantic Blog *siehe* Blog
 Semantic Desktop 337
 Adaption von Datenquellen 350
 Ansatz zur Realisierung 340
 Architektur 347
 Definition 340
 Suche 351
 Semantic Mashup *siehe* Mashup
 Semantic Wiki *siehe* Wiki
 Semantic Wikipedia *siehe* Wikipedia
 Semantically-Interlinked Online
 Communities *siehe* SIOC
 Service-orientierte Architektur *siehe* SOA
 Simple Knowledge Organisation System
 siehe SKOS
 SIOC 166, 189
 SKOS 167, 190
 SmartTag 168
 SOA 219
 Social Awareness-Tool 46
 Social Bookmarking 45, 363
 Social Networking 46, 289
 Metrik 325
 Netzwerkgraph 323
 Netzwerkinduktion 331
 Visualisierung 316
 Social Production 4
 Social Software 44
 Einsatzmöglichkeiten 45
 Erfolgsfaktoren 46
 Social Web 161
 Hypothesen 102
 Strukturelle Dimension 455
 Weisheit der Masse 456
 Weisheit des Netzwerkes 456
 SPARQL 181, 250, 439
 SPARQL-Endpoint 270
 Substitutionseffekte 423
 Swoogle 107, 275

T

Tag-Cloud *siehe* Folksonomy
 Tagging 45, 71
 Abfrage 234
 Anwendung 240
 Ontologie-gestützt 238
 Prinzip 232
 Tag-Cloud 71
 Tag-Event 233
 Tag-Hierarchie 378

 Tag-Recommender 227
 Typisierter Tag 429
 Tag-Recommender *siehe* Recommender
 System
 Traffic Data 476
 Tri-Begriff 386

U

Uniform Resource Identifier *siehe* URI
 URI 214, 438
 Dereferenzierung 263
 Usability 83
 User Generated Content 13, 83, 490
 Qualitätssicherung 430

W

W3C 55
 Web 2.0 63
 Anwendung 65
 Technologie 70
 Web 2.0 Design Pattern 5, 26, 165
 Web 3.0 19, 365
 Web of Data 5, 227
 Web of Document 12, 459
 Weblog *siehe* Blog
 Webtop 50
 Wiki 45, 66
 Aktuelle Forschung 255
 Annotation 247, 395
 Semantic MediaWiki 394
 Semantic Wiki 507, 57, 245
 Semantic Wiki System 252, 418
 Semantische Navigation 248
 Semantische Suche 250
 Wiki-Syntax 247, 355
 Wikipedia 260
 Anwendung 410
 Architektur 395
 Inline Query 404
 Performanz 415
 Semantic MediaWiki 394
 Semantic Wikipedia 393
 Semantische Annotation 398
 Wissensmodellierung 134
 Phasen 137
 Wissensorganisation 7
 Wissensorganisationssysteme 128
 Wissenstypen 462

Y

Yahoo! Pipes 112, 179